

**TỔNG LIÊN ĐOÀN LAO ĐỘNG VIỆT NAM
TRƯỜNG ĐẠI HỌC TÔN ĐỨC THẮNG
KHOA CÔNG NGHỆ THÔNG TIN**



**LÊ MINH LÝ - 52300220
SỬ THỊ YẾN LINH - 52300218**

**XÂY DỰNG MÔ HÌNH HỌC TĂNG
CƯỜNG TỐI ƯU HÓA CHÍNH SÁCH ĐẶT
HÀNG LẠI TRONG QUẢN LÝ TỒN KHO
ĐA KHO**

**KHÓA LUẬN TỐT NGHIỆP
MẠNG MÁY TÍNH VÀ TRUYỀN THÔNG
DỮ LIỆU**

THÀNH PHỐ HỒ CHÍ MINH, NĂM 2026

**TỔNG LIÊN ĐOÀN LAO ĐỘNG VIỆT NAM
TRƯỜNG ĐẠI HỌC TÔN ĐỨC THẮNG
KHOA CÔNG NGHỆ THÔNG TIN**



**LÊ MINH LÝ - 52300220
SỬ THỊ YẾN LINH - 52300218**

**XÂY DỰNG MÔ HÌNH HỌC TẶNG
CƯỜNG TỐI ƯU HÓA CHÍNH SÁCH ĐẶT
HÀNG LẠI TRONG QUẢN LÝ TỒN KHO
ĐA KHO**

**KHÓA LUẬN TỐT NGHIỆP
MẠNG MÁY TÍNH VÀ TRUYỀN THÔNG
DỮ LIỆU**

Giảng viên hướng dẫn
TS. HỒ THỊ LINH

THÀNH PHỐ HỒ CHÍ MINH, NĂM 2026

LỜI CẢM ƠN

Đầu tiên, chúng em xin gửi lời cảm ơn chân thành và sâu sắc nhất đến TS. Hồ Thị Linh, giảng viên hướng dẫn khóa luận tốt nghiệp. Sự hướng dẫn tận tình, những ý kiến đóng góp quý báu và sự hỗ trợ kịp thời của cô đã định hướng và giúp chúng em hoàn thành tốt khóa luận này.

Bên cạnh đó, chúng em cũng xin cảm ơn khoa Công nghệ Thông tin, trường Đại học Tôn Đức Thắng đã tạo điều kiện học tập và cung cấp những nền tảng kiến thức vững chắc, tạo môi trường thuận lợi để chúng em có thể áp dụng vào thực tiễn. Do thời gian và trình độ còn những hạn chế nhất định, báo cáo chắc chắn không tránh khỏi những thiếu sót. Chúng em rất mong nhận được sự cảm thông và những lời góp ý chân thành từ quý thầy cô để đề tài được hoàn thiện hơn và chúng em rút ra được những bài học quý giá.

Chúng em xin chân thành cảm ơn!

TP. Hồ Chí Minh, ngày 09 tháng 05 năm 2026

Tác giả

(Ký và ghi rõ họ tên)

Lê Minh Lý

Tác giả

(Ký và ghi rõ họ tên)

Sử Thị Yến Linh

CÔNG TRÌNH ĐƯỢC HOÀN THÀNH TẠI TRƯỜNG ĐẠI HỌC TÔN ĐỨC THẮNG

Chúng tôi xin cam đoan đây là công trình nghiên cứu của chúng tôi và được sự hướng dẫn khoa học của TS. Hồ Thị Linh. Các nội dung nghiên cứu, kết quả trong đề tài này là trung thực và chưa công bố dưới bất kỳ hình thức nào trước đây. Những số liệu trong các bảng biểu phục vụ cho việc phân tích, nhận xét, đánh giá được chính tác giả thu thập từ các nguồn khác nhau có ghi rõ trong phần tài liệu tham khảo.

Ngoài ra, trong Khóa luận tốt nghiệp còn sử dụng một số nhận xét, đánh giá cũng như số liệu của các tác giả khác, cơ quan tổ chức khác đều có trích dẫn và chú thích nguồn gốc.

Nếu phát hiện có bất kỳ sự gian lận nào chúng tôi xin hoàn toàn chịu trách nhiệm về nội dung Khóa luận tốt nghiệp của mình. Trường Đại học Tôn Đức Thắng không liên quan đến những vi phạm tác quyền, bản quyền do chúng tôi gây ra trong quá trình thực hiện (nếu có).

TP. Hồ Chí Minh, ngày 09 tháng 05 năm 2026

Tác giả

(Ký và ghi rõ họ tên)

Tác giả

(Ký và ghi rõ họ tên)

Lê Minh Lý

Sử Thị Yến Linh

PHẦN XÁC NHẬN VÀ ĐÁNH GIÁ CỦA GIẢNG VIÊN

Phần xác nhận của GV hướng dẫn

Tp. Hồ Chí Minh, ngàytháng

.....năm

(Ký và ghi họ tên)

Phần đánh giá của GV chấm bài

Tp. Hồ Chí Minh, ngàytháng

.....năm

(Ký và ghi họ tên)

XÂY DỰNG MÔ HÌNH HỌC TĂNG CƯỜNG TỐI ƯU HÓA CHÍNH SÁCH ĐẶT HÀNG LẠI TRONG QUẢN LÝ TỒN KHO ĐA KHO

TÓM TẮT

Quản lý tồn kho trong mạng lưới bán lẻ gồm nhiều kho và nhiều mặt hàng là bài toán ra quyết định tuần tự dưới điều kiện bất định, đòi hỏi cân bằng đồng thời nhiều nhóm chi phí xung đột nhau: chi phí lưu kho, chi phí thiếu hàng, chi phí đặt hàng cố định, chi phí phạt tràn kho và yêu cầu duy trì mức phục vụ khách hàng. Các chính sách cổ điển như EOQ, (s, S) và Newsvendor được xây dựng trên những giả định chặt — nhu cầu xác định hoặc dừng, thời gian giao hàng cố định, không ràng buộc sức chứa — nên khó giữ được tính tối ưu khi nhu cầu ngẫu nhiên, thời gian giao hàng biến động và các mặt hàng phải chia sẻ một dung lượng kho hữu hạn.

Khóa luận đề xuất giải quyết bài toán trên bằng học tăng cường đa tác tử. Hệ thống gồm $N = 10$ kho và $M = 30$ mặt hàng đại diện được mô hình hóa thành 300 tác tử tương ứng với 300 cặp kho–mặt hàng, mỗi tác tử tự ra quyết định đặt hàng dựa trên quan sát cục bộ của mình. Các tác tử được huấn luyện bằng thuật toán Independent Multi-Agent Proximal Policy Optimization (IPPO) kết hợp cơ chế chia sẻ tham số (parameter sharing): toàn bộ 300 tác tử dùng chung một bộ trọng số Actor–Critic duy nhất, cho phép mở rộng quy mô mà không làm bùng nổ số lượng tham số cần học. Hàm phần thưởng được thiết kế theo hướng phân rã cục bộ (local reward decomposition) kèm thành phần phạt dựa trên tỷ lệ đáp ứng nhu cầu tính trên cửa sổ trượt 30 ngày và cơ chế chuẩn hóa phần thưởng theo từng cặp, nhằm giảm phương sai của tín hiệu học giữa các mặt hàng có quy mô chi phí chênh lệch nhiều bậc độ lớn.

Môi trường mô phỏng được xây dựng theo chuẩn Gymnasium, với tham số nhu cầu và giá bán được hiệu chỉnh từ bộ dữ liệu bán lẻ thực tế M5 Walmart (10 cửa hàng, 30 mặt hàng đại diện, 1.941 ngày doanh số) và thời gian giao hàng ngẫu nhiên trong khoảng từ một đến ba ngày. Hiệu năng của mô hình đề xuất được đối chứng với ba chính sách tồn kho cổ điển (EOQ, (s, S) , Newsvendor) đã được tinh chỉnh tham số bằng tìm kiếm lưới trên cùng môi trường, theo một giao thức đánh giá thống nhất gồm nhiều hạt giống ngẫu nhiên và kiểm định thống kê, trên bốn nhóm chỉ số: tổng chi phí vận hành, tỷ lệ đáp ứng nhu cầu, và cơ cấu các thành phần chi phí.

Kết quả thực nghiệm cho thấy ở điểm vận hành mà mỗi phương pháp tự chọn,

IPPO đạt tỷ lệ đáp ứng nhu cầu cao nhất (khoảng 90,5%, so với 75–84% của ba chính sách cổ điển) nhưng tổng chi phí cao hơn (s, S) và Newsvendor một khoảng vừa phải, dù vẫn rẻ hơn EOQ – một so sánh chưa đầy đủ vì bốn phương pháp nằm ở bốn điểm khác nhau trên đường đánh đổi chi phí–mức phục vụ. Khi so sánh ở cùng một mức phục vụ tối thiểu – loại bỏ được sai lệch nói trên – IPPO đạt tổng chi phí vận hành thấp nhất trong số các phương pháp đạt được mức phục vụ đó: rẻ hơn (s, S) 10,2% và rẻ hơn Newsvendor 14,4%, trong khi EOQ không có cấu hình nào đạt được mức phục vụ này. Cơ chế chia sẻ tham số tổng quát hóa tốt cho các mặt hàng có nhu cầu từ trung bình trở lên, nhưng chưa bù đắp hoàn toàn cho các mặt hàng có nhu cầu thấp và gián đoạn nhất. Khóa luận đồng thời trình bày trung thực những kịch bản mà phương pháp đề xuất chưa vượt trội so với chính sách cổ điển, cùng những hạn chế và hướng nghiên cứu tiếp theo.

BUILDING A REINFORCEMENT LEARNING MODEL FOR OPTIMIZING REORDER POLICY IN MULTI-WAREHOUSE INVENTORY MANAGEMENT

ABSTRACT

Inventory control across a retail network of multiple warehouses and multiple stock-keeping units (SKUs) is a sequential decision-making problem under uncertainty that requires balancing several conflicting cost components at once: holding cost, stockout cost, fixed ordering cost, warehouse overflow penalty, and the requirement to sustain a target customer service level. Classical policies such as EOQ, (s, S) and the Newsvendor model rest on restrictive assumptions — deterministic or stationary demand, fixed lead times, and unconstrained storage capacity — and therefore lose their optimality guarantees once demand is stochastic, lead times fluctuate, and multiple SKUs must share a finite warehouse capacity.

This thesis addresses the problem through multi-agent reinforcement learning. A system of $N = 10$ warehouses and $M = 30$ representative SKUs is modelled as 300 agents, one per warehouse–SKU pair, each issuing its own replenishment decisions from local observations. The agents are trained with Independent Multi-Agent Proximal Policy Optimization (IPPO) under full parameter sharing: a single set of Actor–Critic weights is shared across all 300 agents, which keeps the number of learnable parameters constant as the system scales. The reward is designed with local decomposition, a 30-day rolling-window fill-rate penalty term, and a per-pair normalization mechanism that reduces the variance of the learning signal across SKUs whose cost scales differ by several orders of magnitude.

The simulation environment follows the Gymnasium interface, with demand and price parameters calibrated from the real-world M5 Walmart retail dataset (10 stores, 30 representative SKUs, 1,941 days of sales data) and stochastic lead times drawn from one to three days. The proposed model is benchmarked against three classical inventory policies (EOQ, (s, S) , Newsvendor), each tuned by grid search on the same environment, under a unified evaluation protocol involving multiple random seeds and statistical significance testing, across four metric groups: total operational cost, fill rate, and the breakdown of individual cost components.

Experimental results show that, at the operating point each method chooses for

itself, IPPO reaches the highest fill rate (about 90.5%, versus 75–84% for the three classical policies) but a moderately higher total cost than (s, S) and the Newsvendor policy, while still remaining cheaper than EOQ – an incomplete comparison, since the four methods sit at four different points on the cost–service trade-off curve. When compared at a matched minimum service level, which removes this bias, IPPO achieves the lowest total operational cost among the methods that reach that service level – 10.2% cheaper than (s, S) and 14.4% cheaper than the Newsvendor policy – while no EOQ configuration reaches that service level at all. The shared-parameter policy generalizes well to medium- and high-demand SKUs but does not fully close the service-level gap for the lowest-demand, most intermittent SKUs. The thesis also reports, in full honesty, the scenarios in which the proposed method does not outperform the classical baselines, together with the study’s limitations and directions for future work.

MỤC LỤC

DANH MỤC HÌNH VẼ.....	xi
DANH MỤC BẢNG BIỂU.....	xii
DANH MỤC CÁC CHỮ VIẾT TẮT.....	xiii
CHƯƠNG 1. TỔNG QUAN VỀ ĐỀ TÀI.....	1
1.1 Bối cảnh nghiên cứu và tính cấp thiết của đề tài	1
1.1.1 <i>Thực trạng quản lý tồn kho trong mạng lưới bán lẻ đa điểm</i>	<i>1</i>
1.1.2 <i>Thách thức trong việc tối ưu hóa chính sách đặt hàng lại.....</i>	<i>2</i>
1.1.3 <i>Hạn chế của phương pháp truyền thống và sự cần thiết của học tăng cường đa tác tử.....</i>	<i>3</i>
1.2 Mục tiêu và câu hỏi nghiên cứu	4
1.2.1 <i>Mục tiêu nghiên cứu</i>	<i>4</i>
1.2.2 <i>Câu hỏi nghiên cứu</i>	<i>5</i>
1.3 Đối tượng và phạm vi nghiên cứu	5
1.3.1 <i>Đối tượng nghiên cứu</i>	<i>5</i>
1.3.2 <i>Phạm vi trong đề tài</i>	<i>6</i>
1.3.3 <i>Giới hạn phạm vi</i>	<i>6</i>
1.4 Phương pháp nghiên cứu	7
1.5 Ý nghĩa khoa học và thực tiễn của đề tài.....	7
1.6 Bố cục của khóa luận.....	7
CHƯƠNG 2. CƠ SỞ LÝ THUYẾT VÀ CÁC CÔNG TRÌNH LIÊN QUAN	9
2.1 Lý thuyết kiểm soát tồn kho ngẫu nhiên	9
2.1.1 <i>Mô hình tồn kho và các thành phần chi phí</i>	<i>9</i>
2.1.2 <i>Các chính sách đặt hàng lại cổ điển</i>	<i>10</i>
2.1.3 <i>Các thước đo mức phục vụ trong quản lý tồn kho</i>	<i>10</i>
2.2 Nền tảng học tăng cường.....	11
2.2.1 <i>Quá trình quyết định Markov (MDP)</i>	<i>11</i>

2.2.2	Hàm giá trị và phương trình Bellman.....	12
2.2.3	Ước lượng lợi thế tổng quát (GAE).....	12
2.2.4	Thuật toán PPO (Proximal Policy Optimization).....	12
2.3	Học tăng cường đa tác tử.....	13
2.3.1	Mô hình Dec-POMDP	13
2.3.2	Học độc lập (Independent Learning).....	13
2.3.3	IPPO — Independent Multi-Agent PPO	14
2.3.4	Chia sẻ tham số (Parameter Sharing)	14
2.3.5	Phần thưởng phân rã cục bộ và bài toán gán tín dụng.....	15
2.4	Các công trình nghiên cứu liên quan	15
2.4.1	Học tăng cường trong quản lý tồn kho	15
2.4.2	Hai công trình gần nhất cùng bối cảnh	16
2.4.3	Khoảng trống nghiên cứu và định vị đóng góp.....	17
	CHƯƠNG 3. PHÂN TÍCH VÀ THIẾT KẾ MÔ HÌNH	19
3.1	Mô hình hóa bài toán tồn kho đa kho	19
3.1.1	Mô tả mạng lưới.....	19
3.1.2	Thiết lập bài toán dưới dạng MDP đa tác tử.....	19
3.1.3	Ràng buộc sức chứa kho và cơ chế từ chối nhập hàng	23
3.1.4	Cơ chế phối hợp giữa các tác tử	24
3.2	Thiết kế hàm phần thưởng	25
3.2.1	Phần thưởng phân rã cục bộ	25
3.2.2	Vai trò của thành phần phạt fill rate	26
3.2.3	Các tham số chi phí.....	26
3.2.4	Chuẩn hóa phần thưởng theo từng cặp.....	27
3.3	Kiến trúc mạng Actor–Critic chia sẻ tham số.....	27
3.3.1	Mạng SharedActorCritic	27
3.3.2	Quy trình huấn luyện IPPO.....	28
3.4	Thiết kế môi trường mô phỏng	29

CHƯƠNG 4. THỰC NGHIỆM VÀ ĐÁNH GIÁ KẾT QUẢ	31
4.1 Cấu hình thực nghiệm.....	31
4.1.1 Môi trường phần cứng và phần mềm	31
4.1.2 Nguồn dữ liệu và tiền xử lý	31
4.1.3 Thiết lập kịch bản mô phỏng	32
4.2 Phương pháp đối chứng	33
4.3 Giao thức đánh giá.....	33
4.3.1 Quy trình đánh giá.....	33
4.3.2 Các chỉ số đánh giá.....	34
4.4 Kết quả thực nghiệm	34
4.4.1 Quá trình huấn luyện và tính hội tụ	34
4.4.2 So sánh trực tiếp với các chính sách cổ điển.....	36
4.4.3 Phân tích cơ cấu chi phí.....	37
4.4.4 So sánh ở cùng mức phục vụ	38
4.5 Phân tích chuyên sâu	39
4.5.1 Khả năng tổng quát hóa qua chia sẻ tham số (Câu hỏi 2).....	39
4.5.2 Ảnh hưởng của chuẩn hóa phần thưởng theo từng cặp (Câu hỏi 3)	42
4.5.3 Vai trò của việc tách Actor và Critic	42
4.5.4 Các kịch bản IPPO chưa vượt trội	42
4.6 Hạn chế của thực nghiệm	42
4.7 Thảo luận	42
CHƯƠNG 5. KẾT LUẬN VÀ HƯỚNG PHÁT TRIỂN.....	44
5.1 Tổng kết các kết quả đạt được	44
5.1.1 Trả lời các câu hỏi nghiên cứu	44
5.2 Những hạn chế còn tồn tại	45
5.3 Hướng phát triển trong tương lai.....	46
PHỤ LỤC A. ĐỐI CHIẾU LUẬN ĐIỂM VÀ NGUỒN TRÍCH DẪN	49
TÀI LIỆU THAM KHẢO.....	52

DANH MỤC HÌNH VẼ

Hình 4.1: Diễn biến huấn luyện qua 1.000 episode (hạt giống 42): (a) phần thưởng tích lũy; (b) tỷ lệ đáp ứng nhu cầu; (c) entropy của chính sách; (d) explained variance của Critic	35
Hình 4.2: So sánh bốn phương pháp trên miền đánh giá: (a) tổng chi phí vận hành; (b) tỷ lệ đáp ứng nhu cầu; (c) cơ cấu chi phí thành phần.....	37
Hình 4.3: Đường đánh đổi chi phí — mức phục vụ. Dấu chữ thập xám: cấu hình tối thiểu chi phí; dấu tròn: cấu hình ở cùng mức phục vụ với IPPO	40

DANH MỤC BẢNG BIỂU

Bảng 1.1: Phân loại dạng nhu cầu của 30.490 chuỗi cửa hàng–mặt hàng trong bộ dữ liệu M5 theo tiêu chí của Syntetos và cộng sự [4]	2
Bảng 1.2: Các nhóm chi phí trong bài toán tồn kho đang xét.....	3
Bảng 2.1: Đối chiếu khóa luận với hai công trình gần nhất cùng bối cảnh.....	17
Bảng 2.2: So sánh tổng quan các công trình nghiên cứu liên quan.....	18
Bảng 3.1: Đối chiếu biến trạng thái và biểu diễn trong vector quan sát.....	21
Bảng 3.2: Nhu cầu và sức chứa của từng kho trong cấu hình thực nghiệm	23
Bảng 3.3: Đặc tả tác tử trong hệ thống đề xuất	25
Bảng 3.4: Tham số chi phí trong môi trường mô phỏng	26
Bảng 3.5: Siêu tham số huấn luyện	29
Bảng 4.1: Đặc trưng nhu cầu của tập thực nghiệm so với bộ dữ liệu gốc	32
Bảng 4.2: Cấu hình môi trường mô phỏng.....	32
Bảng 4.3: Tham số tối ưu của các chính sách đối chứng sau tìm kiếm lưới.....	33
Bảng 4.4: Kết quả trên miền đánh giá (trung bình $\pm$ độ lệch chuẩn; IPPO trên 90 lần đánh giá gộp 3 hạt giống, baseline trên 30 episode). Chi phí tính bằng đơn vị tiền của mô hình.	36
Bảng 4.5: So sánh ở cùng mức phục vụ: cấu hình rẻ nhất của mỗi chính sách đối chứng đạt fill rate $\geq 90,07\%$ (hạt giống 42)	39
Bảng 4.6: Hiệu năng theo nhóm quy mô nhu cầu trên miền đánh giá (hạt giống 42). Chi phí cục bộ (gồm thành phần định hướng mức phục vụ) tính trung bình cho mỗi cặp trong một episode.	40
Bảng 5.1: So sánh kiến trúc IPPO và MCP theo các chiều điều phối.....	48

DANH MỤC CÁC CHỮ VIẾT TẮT

Dec-POMDP	Decentralized Partially Observable Markov Decision Process (Quá trình quyết định Markov có quan sát bộ phận phi tập trung)
EOQ	Economic Order Quantity (Lượng đặt hàng kinh tế)
GAE	Generalized Advantage Estimation (Ước lượng lợi thế tổng quát)
IPPO	Independent Proximal Policy Optimization (Tối ưu hóa chính sách cận đại độc lập)
MARL	Multi-Agent Reinforcement Learning (Học tăng cường đa tác tử)
MDP	Markov Decision Process (Quá trình quyết định Markov)
MLP	Multilayer Perceptron (Mạng nơ-ron truyền thẳng đa tầng)
PPO	Proximal Policy Optimization (Tối ưu hóa chính sách cận đại)
RL	Reinforcement Learning (Học tăng cường)
SCM	Supply Chain Management (Quản trị chuỗi cung ứng)
SKU	Stock Keeping Unit (Đơn vị quản lý tồn kho)
SNAP	Supplemental Nutrition Assistance Program (Chương trình trợ cấp dinh dưỡng)

CHƯƠNG 1. TỔNG QUAN VỀ ĐỀ TÀI

1.1 Bối cảnh nghiên cứu và tính cấp thiết của đề tài

1.1.1 Thực trạng quản lý tồn kho trong mạng lưới bán lẻ đa điểm

Trong hoạt động bán lẻ hiện đại, hàng hóa không được lưu trữ tập trung tại một điểm duy nhất mà được phân tán trên một mạng lưới gồm nhiều kho hoặc nhiều cửa hàng đặt tại các khu vực địa lý khác nhau. Mỗi điểm lưu trữ phục vụ một tập khách hàng riêng, đối mặt với một chuỗi nhu cầu riêng và phải tự ra quyết định bổ sung hàng hóa cho hàng trăm đến hàng nghìn mặt hàng khác nhau [1]. Bài toán vì vậy không còn là việc xác định một mức đặt hàng đơn lẻ, mà là việc điều phối đồng thời một số lượng rất lớn các quyết định có ràng buộc lẫn nhau.

Đặc điểm này thể hiện rõ trong dữ liệu bán lẻ thực tế. Bộ dữ liệu M5, công bố trong cuộc thi dự báo M5 do Makridakis và cộng sự [2] tổ chức, ghi nhận doanh số bán hàng theo ngày của 3.049 mặt hàng tại 10 cửa hàng của Walmart thuộc ba bang California, Texas và Wisconsin, trải trên 1.941 ngày từ ngày 29 tháng 01 năm 2011 đến ngày 22 tháng 05 năm 2016¹. Tổ hợp của hàng và mặt hàng tạo thành 30.490 chuỗi thời gian nhu cầu ở cấp độ chi tiết nhất.

Thống kê trên toàn bộ 30.490 chuỗi này cho thấy hai đặc trưng có ảnh hưởng trực tiếp tới thiết kế chính sách đặt hàng. Thứ nhất, nhu cầu ở cấp cửa hàng–mặt hàng có quy mô rất nhỏ và phân bố lệch mạnh: nhu cầu trung bình là 1,13 đơn vị mỗi ngày, nhưng trung vị chỉ là 0,45 đơn vị, và 73,4% số chuỗi có nhu cầu trung bình dưới một đơn vị mỗi ngày. Thứ hai, nhu cầu mang tính gián đoạn rõ rệt, với tỷ lệ ngày không phát sinh giao dịch trung bình đạt 68%. Áp dụng tiêu chí phân loại của Syntetos và cộng sự [4] với các ngưỡng khoảng cách giữa hai lần phát sinh nhu cầu $p = 1,32$ và bình phương hệ số biến thiên $CV^2 = 0,49$ (trong đó Kostenko và Hyndman [5] đã chứng minh kết quả biên chính xác với giá trị giới hạn $p = 4/3 \approx 1,333$ và đề xuất quy tắc phân loại chỉnh sửa), có tới 95,2% số chuỗi thuộc hai nhóm *intermittent* và *lumpy* (Bảng 1.1).

Cần nói rõ rằng các thống kê trên được tính trên toàn bộ 30.490 chuỗi của bộ dữ liệu gốc. Tập thực nghiệm của khóa luận là một tập con đã qua sàng lọc: các mặt hàng

¹Các thống kê được tính từ hai tệp `calendar.csv` và `sales_train_evaluation.csv` trong bộ dữ liệu M5 [3].

Bảng 1.1: Phân loại dạng nhu cầu của 30.490 chuỗi cửa hàng–mặt hàng trong bộ dữ liệu M5 theo tiêu chí của Syntetos và cộng sự [4]

Nhóm	Đặc điểm	Tỷ lệ
Smooth	$p < 1,32; CV^2 < 0,49$	3,2%
Erratic	$p < 1,32; CV^2 \geq 0,49$	1,6%
Intermittent	$p \geq 1,32; CV^2 < 0,49$	75,7%
Lumpy	$p \geq 1,32; CV^2 \geq 0,49$	19,5%

mà cửa hàng trên thực tế không kinh doanh (nhu cầu trung bình dưới 0,2 đơn vị mỗi ngày ở phần lớn cửa hàng) bị loại bỏ, vì chúng không tạo thành bài toán đặt hàng lại mà chỉ thêm nhiễu vào tín hiệu học. Sau sàng lọc, tập 300 cặp dùng trong thực nghiệm vẫn giữ tỷ lệ ngày không phát sinh giao dịch ở mức 57,4% — nghĩa là tính gián đoạn được bảo toàn — với nhu cầu trung bình 3,24 và trung vị 0,74 đơn vị mỗi ngày. Chi tiết quy trình sàng lọc được trình bày ở Mục 4.1.2.

Đặc điểm gián đoạn này khiến các phương pháp dự báo và các công thức tồn kho xây dựng trên giả định nhu cầu liên tục và phân phối chuẩn trở nên kém phù hợp [6], [7]. Quản lý tồn kho trên một mạng lưới như vậy đòi hỏi những công cụ ra quyết định có khả năng thích ứng, thay vì các bộ tham số tĩnh được thiết lập một lần và áp dụng cố định.

1.1.2 Thách thức trong việc tối ưu hóa chính sách đặt hàng lại

Việc xây dựng chính sách đặt hàng lại trong mạng lưới đa kho – đa mặt hàng đối mặt với bốn nhóm thách thức chính.

Thứ nhất, tính bất định kép của nhu cầu và thời gian giao hàng. Nhu cầu tiêu thụ biến động ngẫu nhiên theo thời gian, đồng thời thời gian từ lúc phát lệnh đặt hàng đến lúc hàng thực nhập kho cũng không cố định [8]. Khi thời gian giao hàng là biến ngẫu nhiên, các đơn hàng phát ra ở những thời điểm khác nhau có thể về kho không đúng thứ tự, khiến các công thức tính tồn kho an toàn cổ điển chỉ còn giữ vai trò xấp xỉ [1].

Thứ hai, bài toán đánh đổi giữa nhiều nhóm chi phí xung đột. Mục tiêu vận hành không quy về một đại lượng duy nhất mà là tổng hợp của nhiều thành phần có chiều tác động ngược nhau, được tóm tắt trong Bảng 1.2. Giảm tồn kho làm giảm chi phí lưu kho nhưng làm tăng rủi ro thiếu hàng; đặt hàng theo lô lớn làm giảm chi phí đặt hàng cố định nhưng làm tăng chi phí lưu kho và nguy cơ vượt sức chứa [8].

Thứ ba, ràng buộc sức chứa tạo ra sự phụ thuộc giữa các mặt hàng. Các mặt

Bảng 1.2: Các nhóm chi phí trong bài toán tồn kho đang xét

Thành phần chi phí	Ký hiệu	Chiều tác động
Chi phí lưu kho	c_{lk}	Tăng khi mức tồn kho cao
Chi phí thiếu hàng	c_{th}	Tăng khi xảy ra hết hàng
Chi phí đặt hàng cố định	c_{dh}	Tăng theo tần suất đặt hàng
Phạt tràn kho	p_{tk}	Tăng khi vượt sức chứa kho
Phạt vi phạm mức phục vụ	ϕ_{dv}	Tăng khi tỷ lệ đáp ứng dưới ngưỡng

hàng cùng nằm trong một kho chia sẻ một dung lượng hữu hạn. Quyết định đặt hàng của một mặt hàng do đó ảnh hưởng trực tiếp tới chi phí mà các mặt hàng khác trong cùng kho phải gánh chịu. Bài toán vì vậy không thể tách rời thành các bài toán độc lập, mà mang bản chất của một bài toán ra quyết định hợp tác [9].

Thứ tư, quy mô không gian hành động. Với N kho và M mặt hàng, mỗi cặp có K mức đặt hàng khả dĩ, không gian hành động chung là tích Descartes có kích thước K^{NM} . Với cấu hình của khóa luận ($N = 10$, $M = 30$, $K = 6$), con số này là 6^{300} — vượt xa khả năng xử lý của bất kỳ phương pháp tìm kiếm tập trung nào, và cũng vượt quá khả năng biểu diễn của các thuật toán học tăng cường dựa trên hàm giá trị vốn phải liệt kê toàn bộ hành động khả dĩ [10]. Trên phương diện lý thuyết độ phức tạp, bài toán điều khiển phi tập trung dạng này đã được chứng minh thuộc lớp NEXP—đầy đủ [11], nên các lời giải chính xác không khả thi ở quy mô thực tế.

1.1.3 Hạn chế của phương pháp truyền thống và sự cần thiết của học tăng cường đa tác tử

Các chính sách tồn kho cổ điển đều được xây dựng trên những tập giả định cụ thể. Mô hình lượng đặt hàng kinh tế của Harris [12] giả định nhu cầu xác định và đều, không có tình trạng thiếu hàng. Chính sách (s, S) được Scarf [13] chứng minh tối ưu cho hệ đơn kho với nhu cầu độc lập giữa các kỳ, chi phí đặt hàng cố định và cơ chế giữ đơn hàng chờ. Mô hình người bán báo của Arrow và cộng sự [14] chỉ tối ưu cho một chu kỳ đơn lẻ, không xét tới lượng hàng đang trên đường vận chuyển. Không mô hình nào trong số đó xử lý được đồng thời nhu cầu ngẫu nhiên, thời gian giao hàng biến động, ràng buộc sức chứa dùng chung và yêu cầu duy trì mức phục vụ tối thiểu. Riêng với cơ chế mất đơn hàng khi thiếu hàng — vốn phù hợp với bối cảnh bán lẻ — Zipkin [15] chỉ ra rằng bài toán không còn nghiệm giải tích dạng đóng và các chính sách cổ điển mất tính tối ưu đã được chứng minh.

Học tăng cường cung cấp một hướng tiếp cận khác: thay vì giả định trước dạng

phân phối của nhu cầu và suy ra chính sách bằng giải tích, tác tử học chính sách trực tiếp thông qua tương tác lặp lại với môi trường [10]. Hướng này đã được kiểm chứng trên các bài toán tồn kho quy mô nhỏ: Oroojlooyjadid và cộng sự [16] áp dụng mạng Q sâu cho trò chơi phân phối bia, còn Gijsbrechts và cộng sự [17] đánh giá học tăng cường sâu trên ba lớp bài toán tồn kho gồm mất đơn hàng, hai nguồn cung và đa cấp.

Tuy nhiên, việc áp dụng học tăng cường đơn tác tử cho toàn bộ mạng lưới vấp phải chính vấn đề quy mô đã nêu ở mục trên. Học tăng cường đa tác tử với cơ chế chia sẻ tham số cho phép vượt qua trở ngại này [18]: mỗi cặp kho–mặt hàng được xem là một tác tử ra quyết định độc lập trên quan sát cục bộ theo hướng tiếp cận học độc lập của Tan [19], trong khi toàn bộ các tác tử cùng học chung một bộ trọng số. Nhờ đó, không gian hành động mà mỗi tác tử phải xử lý thu về kích thước K , còn số tham số cần học không tăng theo quy mô hệ thống. Các nghiên cứu gần đây cho thấy phương pháp học độc lập dựa trên PPO đạt hiệu năng cạnh tranh trên nhiều môi trường hợp tác [20], [21].

Khảo sát tài liệu cho thấy phần lớn các nghiên cứu áp dụng học tăng cường cho quản lý tồn kho hiện nay được tiến hành ở quy mô nhỏ, với một vài kho và một vài mặt hàng, trên dữ liệu nhu cầu sinh theo phân phối lý thuyết. Ngay cả những công trình gần đây nhất cùng bối cảnh cũng để lại những khoảng trống rõ rệt. Zhu và Wu [22] cũng sử dụng bộ dữ liệu M5 và học tăng cường đa tác tử, nhưng giả định nguồn cung không giới hạn và không đưa sức chứa kho vào hàm mục tiêu, nên sự ràng buộc giữa các mặt hàng trong cùng một kho không được mô hình hóa. Ở chiều ngược lại, khung làm việc của Jeong và cộng sự [23] có xét ràng buộc sức chứa nhưng chỉ trên một kho duy nhất và trên dữ liệu tổng hợp, đồng thời hàm phần thưởng không quy về đơn vị tiền tệ nên khó diễn giải về mặt kinh tế.

Khoảng trống mà khóa luận hướng tới nằm ở giao của ba yếu tố: mở rộng tới quy mô hàng trăm cặp kho–mặt hàng bằng cơ chế chia sẻ tham số; mô hình hóa ràng buộc sức chứa hữu hạn dùng chung giữa các mặt hàng, tính riêng cho từng kho theo quy mô nhu cầu không đồng nhất của kho đó; và đánh giá so sánh với các chính sách cổ điển ở cùng một mức phục vụ, trên môi trường mô phỏng hiệu chỉnh từ dữ liệu bán lẻ thực tế.

1.2 Mục tiêu và câu hỏi nghiên cứu

1.2.1 Mục tiêu nghiên cứu

Khóa luận đặt ra bốn mục tiêu cụ thể:

- Xây dựng môi trường mô phỏng tồn kho đa kho – đa mặt hàng theo chuẩn Gymnasium [24], mô hình hóa đầy đủ nhu cầu ngẫu nhiên, thời gian giao hàng biến động, ràng buộc sức chứa và năm nhóm chi phí vận hành; tham số nhu cầu được hiệu chỉnh từ bộ dữ liệu M5 Walmart.
- Thiết kế hàm phần thưởng phân rã cục bộ kèm thành phần phạt dựa trên tỷ lệ đáp ứng nhu cầu tính trên cửa sổ trượt, bảo đảm tín hiệu học phản ánh đúng đóng góp của từng tác tử [25].
- Cài đặt và huấn luyện thuật toán Independent Multi-Agent PPO [20], [26] với cơ chế chia sẻ tham số cho 300 cặp kho–mặt hàng, sử dụng ước lượng lợi thế tổng quát [27] và chuẩn hóa lợi thế theo từng cặp.
- Đánh giá hiệu năng của mô hình đề xuất trong so sánh với ba chính sách tồn kho cổ điển, theo giao thức thực nghiệm đa hạt giống có kiểm định thống kê [28], [29].

1.2.2 Câu hỏi nghiên cứu

Khóa luận hướng tới trả lời ba câu hỏi:

1. Câu hỏi 1: Tác tử IPPO có học được chính sách đặt hàng lại cho tổng chi phí vận hành thấp hơn các chính sách tối ưu hóa cổ điển (EOQ, (s, S) , Newsvendor) trong môi trường đa kho – đa mặt hàng với nhu cầu ngẫu nhiên và thời gian giao hàng biến động hay không, và mức cải thiện đó có ý nghĩa thống kê hay không?
2. Câu hỏi 2: Cơ chế chia sẻ tham số giữa 300 tác tử có đủ để học một chính sách tổng quát hóa được cho các mặt hàng có quy mô nhu cầu khác biệt đáng kể hay không?
3. Câu hỏi 3: Hàm phần thưởng phân rã cục bộ kèm tỷ lệ đáp ứng theo cửa sổ trượt có cải thiện quá trình học so với hàm phần thưởng toàn cục dùng chung hay không?

1.3 Đối tượng và phạm vi nghiên cứu

1.3.1 Đối tượng nghiên cứu

Đối tượng nghiên cứu của khóa luận là bài toán tối ưu hóa chính sách đặt hàng lại trong hệ thống tồn kho đa kho – đa mặt hàng, và thuật toán học tăng cường đa tác tử Independent Multi-Agent PPO áp dụng cho bài toán này.

1.3.2 Phạm vi trong đề tài

- Cấu hình hệ thống: $N = 10$ kho, $M = 30$ mặt hàng, tương ứng 300 cặp ra quyết định; độ dài mỗi tập huấn luyện là 365 ngày; thời gian giao hàng ngẫu nhiên trong khoảng từ một đến ba ngày.
- Cấu trúc mạng lưới: các kho hoạt động song song và độc lập về nguồn cung, mỗi kho đặt hàng trực tiếp từ nhà cung cấp bên ngoài. Sự ràng buộc giữa các mặt hàng phát sinh từ dung lượng kho dùng chung.
- Nguồn dữ liệu: bộ dữ liệu bán lẻ M5 Walmart [2], cụ thể là hai tệp `sales_train_evaluation.csv` chứa 30.490 chuỗi doanh số theo ngày trên 1.941 ngày, và `calendar.csv` chứa thông tin lịch, ngày lễ và các sự kiện trợ cấp thực phẩm SNAP. Khóa luận đồng thời hỗ trợ sinh dữ liệu giả lập theo phân phối Poisson phục vụ thử nghiệm đối chứng.
- Phương pháp đối chứng: ba chính sách tồn kho cổ điển EOQ [12], (s, S) [13] và Newsvendor [14], với tham số được tối ưu bằng tìm kiếm lưới trên chính môi trường mô phỏng nhằm bảo đảm tính công bằng của so sánh.
- Chỉ số đánh giá: tổng chi phí vận hành, tỷ lệ đáp ứng nhu cầu, và cơ cấu các thành phần chi phí lưu kho, thiếu hàng, đặt hàng, tràn kho. Việc so sánh chi phí được thực hiện bổ sung ở cùng một mức phục vụ nhằm tránh kết luận sai lệch khi hai chính sách nằm ở hai điểm khác nhau trên đường đánh đổi chi phí — mức phục vụ.

1.3.3 Giới hạn phạm vi

Để bảo đảm chiều sâu nghiên cứu trong thời gian thực hiện, những nội dung sau được xác định nằm ngoài phạm vi khóa luận:

- Cấu trúc tồn kho đa cấp (multi-echelon) với quan hệ cung ứng giữa các kho theo mô hình của Clark và Scarf [30], cùng các hiện tượng đi kèm như hiệu ứng bullwhip [31].
- Bài toán điều chuyển hàng liên kho và tối ưu hóa tuyến vận chuyển.
- Dự báo nhu cầu bằng mô hình học sâu chuỗi thời gian; khóa luận sử dụng trực tiếp thông tin nhu cầu lịch sử trong vector quan sát.
- Cơ chế truyền thông giữa các tác tử; các tác tử ra quyết định hoàn toàn dựa trên quan sát cục bộ.
- Triển khai hệ thống thời gian thực hoặc tích hợp với nền tảng quản trị doanh

nghiệp; sản phẩm của khóa luận là kết quả mô phỏng và phân tích định lượng.

1.4 Phương pháp nghiên cứu

Khóa luận kết hợp ba nhóm phương pháp. Về lý thuyết, bài toán được mô hình hóa dưới dạng quá trình quyết định Markov phi tập trung có quan sát bộ phận [9], [11], trên nền tảng lý thuyết kiểm soát tồn kho ngẫu nhiên [8] và học tăng cường [10], [32]. Về thực nghiệm, nhóm xây dựng môi trường mô phỏng có kiểm thử đơn vị theo chuẩn giao diện Gymnasium [24], [33], hiệu chỉnh tham số từ dữ liệu M5, huấn luyện tác tử và thu thập số liệu vận hành. Về phân tích, mọi so sánh giữa các phương pháp đều được thực hiện trên cùng một tập hạt giống đánh giá, báo cáo giá trị trung bình kèm độ lệch chuẩn, và được xác nhận bằng kiểm định thống kê phù hợp trước khi kết luận — theo khuyến nghị về tính tái lập trong đánh giá học tăng cường sâu của Henderson và cộng sự [28] và Agarwal và cộng sự [29].

1.5 Ý nghĩa khoa học và thực tiễn của đề tài

Về mặt khoa học, khóa luận đóng góp một khung mô hình hóa bài toán tồn kho đa kho – đa mặt hàng dưới dạng hệ đa tác tử hợp tác quy mô lớn, cùng với đánh giá thực nghiệm có kiểm định thống kê về ảnh hưởng của cách phân rã hàm phần thưởng và cơ chế chia sẻ tham số — hai yếu tố thiết kế thường được sử dụng nhưng ít được khảo sát tách bạch trong các nghiên cứu trước.

Về mặt thực tiễn, kết quả của khóa luận cung cấp bằng chứng định lượng về mức độ khả thi của việc thay thế các chính sách đặt hàng theo tham số tĩnh bằng chính sách học được từ dữ liệu, trên một môi trường mô phỏng được hiệu chỉnh từ dữ liệu bán lẻ thực tế. Cấu trúc mã nguồn và giao thức đánh giá được tổ chức theo hướng có thể tái lập, tạo điều kiện cho các nghiên cứu mở rộng tiếp theo.

1.6 Bố cục của khóa luận

Khóa luận được tổ chức thành năm chương:

- Chương 1 — Tổng quan về đề tài: trình bày bối cảnh, tính cấp thiết, mục tiêu, câu hỏi nghiên cứu, phạm vi và phương pháp nghiên cứu.
- Chương 2 — Cơ sở lý thuyết và các công trình liên quan: hệ thống hóa lý thuyết kiểm soát tồn kho ngẫu nhiên, các chính sách cổ điển, nền tảng học

tăng cường và học tăng cường đa tác tử, cùng lược khảo các nghiên cứu tiền nhiệm.

- Chương 3 — Phân tích và thiết kế mô hình: chi tiết hóa mô hình toán học của môi trường, thiết kế không gian trạng thái, không gian hành động và hàm phần thưởng, kiến trúc mạng Actor–Critic chia sẻ tham số và quy trình huấn luyện.
- Chương 4 — Thực nghiệm và đánh giá kết quả: trình bày cấu hình thực nghiệm, kết quả so sánh với các chính sách cổ điển, các khảo sát loại trừ và phân tích độ nhạy.
- Chương 5 — Kết luận và hướng phát triển: tổng kết kết quả đạt được, chỉ ra hạn chế và đề xuất hướng nghiên cứu tiếp theo.

CHƯƠNG 2. CƠ SỞ LÝ THUYẾT VÀ CÁC CÔNG TRÌNH LIÊN QUAN

2.1 Lý thuyết kiểm soát tồn kho ngẫu nhiên

2.1.1 Mô hình tồn kho và các thành phần chi phí

Bài toán kiểm soát tồn kho xoay quanh việc xác định thời điểm và số lượng đặt hàng bổ sung nhằm cân bằng giữa chi phí phát sinh khi dự trữ quá nhiều và rủi ro khi dự trữ quá ít [8]. Xét một hệ thống đơn kho – đơn mặt hàng hoạt động theo chu kỳ rời rạc. Gọi I_t là mức tồn kho tại đầu kỳ t , a_t là số lượng đặt hàng, D_t là nhu cầu phát sinh trong kỳ t (biến ngẫu nhiên) và L_t là thời gian giao hàng. Chi phí vận hành mỗi kỳ bao gồm:

- Chi phí lưu kho $C_{\text{hold}} = c_{lk} \cdot \max(I_t, 0)$: chi phí tỷ lệ với lượng hàng tồn dương trong kho, bao gồm chi phí vốn, bảo quản và kho bãi.
- Chi phí thiếu hàng $C_{\text{stock}} = c_{th} \cdot \max(D_t - I_t, 0)$: chi phí phát sinh khi nhu cầu vượt quá lượng hàng có sẵn. Trong mô hình mất đơn hàng (lost sales), phần nhu cầu không được đáp ứng bị mất hoàn toàn thay vì chuyển sang kỳ sau [15].
- Chi phí đặt hàng cố định $C_{\text{order}} = c_{dh} \cdot \mathbb{1}(a_t > 0)$: chi phí phát sinh mỗi khi hệ thống phát lệnh đặt hàng, bất kể số lượng đặt.
- Phạt tràn kho $C_{\text{over}} = p_{tk} \cdot \max(I_t + q_t - W, 0)$: chi phí phát sinh khi tổng lượng hàng tồn và hàng nhập vượt quá sức chứa W của kho, trong đó q_t là lượng hàng nhập kho trong kỳ.
- Phạt vi phạm mức phục vụ dựa trên tỷ lệ đáp ứng nhu cầu (fill rate) trên cửa sổ trượt, phản ánh yêu cầu kinh doanh về chất lượng dịch vụ khách hàng.

Tổng chi phí vận hành của một cặp kho–mặt hàng trong kỳ t được tính:

$$C_t = C_{\text{hold}} + C_{\text{stock}} + C_{\text{order}} + C_{\text{over}} + \phi_{dv} \cdot \max(\tau - \text{FR}_t^{(w)}, 0) \quad (2.1)$$

trong đó $\text{FR}_t^{(w)}$ là tỷ lệ đáp ứng trên cửa sổ trượt w ngày, τ là ngưỡng mức phục vụ mục tiêu và ϕ_{dv} là hệ số phạt.

2.1.2 Các chính sách đặt hàng lại cổ điển

Ba chính sách cổ điển được sử dụng làm phương pháp đối chứng trong khóa luận.

Lượng đặt hàng kinh tế (EOQ). Harris [12] đề xuất công thức tối ưu hóa tần suất đặt hàng dưới giả định nhu cầu xác định và đều:

$$Q^* = \sqrt{\frac{2D \cdot c_{dh}}{c_{lk}}} \quad (2.2)$$

trong đó D là nhu cầu trung bình hàng năm. Mô hình giả định không có thiếu hàng, thời gian giao hàng cố định và không có ràng buộc sức chứa.

Chính sách (s, S) . Scarf [13] chứng minh rằng chính sách dạng (s, S) — đặt hàng để nâng mức tồn kho lên S khi mức hiện tại giảm xuống dưới s — là tối ưu cho hệ đơn kho với nhu cầu ngẫu nhiên, chi phí đặt hàng cố định, và cơ chế giữ đơn hàng chờ (backorder). Ngưỡng s thường được tính dựa trên nhu cầu trung bình và độ lệch chuẩn trong thời gian giao hàng:

$$s = \mu_L + z_\alpha \cdot \sigma_L \quad (2.3)$$

trong đó μ_L và σ_L là kỳ vọng và độ lệch chuẩn của nhu cầu tích lũy trong thời gian giao hàng, z_α là phân vị chuẩn tương ứng với mức phục vụ mong muốn.

Mô hình Newsvendor. Arrow và cộng sự [14] đề xuất mô hình cho bài toán đặt hàng đơn kỳ, trong đó lượng đặt hàng tối ưu là:

$$Q^* = F^{-1}\left(\frac{c_{th}}{c_{th} + c_{lk}}\right) \quad (2.4)$$

với F^{-1} là hàm phân vị của phân phối nhu cầu. Mô hình chỉ tối ưu cho một chu kỳ duy nhất, không xét lượng hàng đang trên đường vận chuyển.

Cả ba chính sách trên đều được xây dựng cho bài toán đơn kho – đơn mặt hàng và không tối ưu hóa đồng thời ràng buộc sức chứa dùng chung, phạt tràn kho và mức phục vụ — những đặc trưng quan trọng trong bài toán đa kho – đa mặt hàng mà khóa luận xét [1], [8].

2.1.3 Các thước đo mức phục vụ trong quản lý tồn kho

Trong quản lý tồn kho ngẫu nhiên, mức phục vụ (service level) được đánh giá thông qua ba thước đo phổ biến [1], [8]:

- *Mức phục vụ theo chu kỳ* (α – Cycle Service Level / Type-1): xác suất không xảy ra hiện tượng thiếu hàng trong một chu kỳ bổ sung tồn kho, tức $P(D_L \leq$

s) trong đó D_L là nhu cầu tích lũy trong thời gian giao hàng L và s là điểm đặt hàng lại. Tỷ số tới hạn trong mô hình Newsvendor (2.4) phản ánh chính xác phân vị z_α của thước đo này.

- *Tỷ lệ đáp ứng nhu cầu* (β – Fill Rate / Type-2): tỷ lệ phần trăm tổng nhu cầu của khách hàng được đáp ứng ngay lập tức từ lượng hàng sẵn có trong kho.
- *Tỷ lệ sẵn sàng* (γ – Ready Rate): tỷ lệ thời gian mà mức tồn kho khả dụng duy trì giá trị dương.

Cần lưu ý rằng tỷ số chi phí $c_{th}/(c_{th} + c_{lk})$ xác định mức phục vụ chu kỳ α , chứ không phải tỷ lệ fill rate β . Trong điều kiện nhu cầu ổn định và biến động vừa phải, β thường cao hơn α . Tuy nhiên, dưới tác động của nhu cầu gián đoạn (intermittent demand) và thời gian giao hàng ngẫu nhiên như trong dữ liệu M5 Walmart, mối quan hệ này không còn mang tính tuyệt đối và β có thể sụt giảm thấp hơn α [1].

Một quan sát thực nghiệm liên quan: với bộ tham số chi phí $c_{th} = 10,0$ và $c_{lk} = 1,0$ sử dụng trong thực nghiệm, tỷ số tới hạn lý thuyết của Newsvendor là $c_{th}/(c_{th} + c_{lk}) = 10/11 \approx 0,909$. Tuy nhiên, tìm kiếm lưới trên môi trường mô phỏng cho tham số tối ưu $CR^* = 0,85$ — thấp hơn nhưng không lệch quá xa lý thuyết. Chênh lệch còn lại không phải lỗi cài đặt mà phản ánh sự khác biệt khái niệm căn bản: tỷ số tới hạn cổ điển tối ưu cho mức phục vụ chu kỳ α trong bài toán *một kỳ* không có hàng đang vận chuyển, còn môi trường thực nghiệm là bài toán *đa kỳ* với pipeline 3 ngày, ràng buộc sức chứa kho và hàm mục tiêu fill rate trên cửa sổ trượt. Khoảng cách này được ghi nhận và phân tích trong mục thảo luận kết quả (Mục 4.4.4).

2.2 Nền tảng học tăng cường

2.2.1 Quá trình quyết định Markov (MDP)

Bài toán ra quyết định tuần tự dưới bất định được mô hình hóa bằng quá trình quyết định Markov [32], xác định bởi bộ năm (S, A, P, R, γ) trong đó:

- S : không gian trạng thái (state space).
- A : không gian hành động (action space).
- $P(s' | s, a)$: hàm xác suất chuyển trạng thái.
- $R(s, a)$: hàm phần thưởng (reward function).
- $\gamma \in [0, 1)$: hệ số chiết khấu (discount factor).

Mục tiêu của tác tử là tìm chính sách π^* cực đại hóa lợi tức kỳ vọng:

$$\pi^* = \arg \max_{\pi} \mathbb{E}_{\pi} \left[\sum_{t=0}^{\infty} \gamma^t R(s_t, a_t) \right] \quad (2.5)$$

2.2.2 Hàm giá trị và phương trình Bellman

Hàm giá trị trạng thái $V^{\pi}(s) = \mathbb{E}_{\pi}[\sum_{t=0}^{\infty} \gamma^t R_t \mid s_0 = s]$ và hàm giá trị hành động $Q^{\pi}(s, a)$ thỏa mãn phương trình Bellman [10]. Hàm lợi thế (advantage function) được định nghĩa:

$$A^{\pi}(s, a) = Q^{\pi}(s, a) - V^{\pi}(s) \quad (2.6)$$

đo mức độ tốt hơn (hoặc kém hơn) của hành động a so với hành vi trung bình của chính sách π tại trạng thái s .

2.2.3 Ước lượng lợi thế tổng quát (GAE)

Schulman và cộng sự [27] đề xuất phương pháp ước lượng lợi thế tổng quát (Generalized Advantage Estimation – GAE) nhằm kiểm soát đánh đổi giữa thiên lệch (bias) và phương sai (variance) trong ước lượng gradient chính sách:

$$\hat{A}_t^{\text{GAE}(\gamma, \lambda)} = \sum_{l=0}^{\infty} (\gamma \lambda)^l \delta_{t+l} \quad (2.7)$$

trong đó $\delta_t = r_t + \gamma V(s_{t+1}) - V(s_t)$ là sai số TD (temporal difference) và $\lambda \in [0, 1]$ là tham số kiểm soát đánh đổi. Khi $\lambda = 0$, GAE suy biến thành ước lượng một bước (thiên lệch cao, phương sai thấp); khi $\lambda = 1$, GAE tương đương Monte-Carlo (không thiên lệch, phương sai cao). Khóa luận sử dụng $\lambda = 0,95$ theo khuyến nghị thực nghiệm phổ biến.

2.2.4 Thuật toán PPO (Proximal Policy Optimization)

Schulman và cộng sự [26] đề xuất PPO nhằm khắc phục nhược điểm của phương pháp tối ưu hóa chính sách: các bước cập nhật quá lớn có thể phá hủy chính sách đã học. PPO sử dụng hàm mục tiêu cắt (clipped surrogate objective):

$$L^{\text{CLIP}}(\theta) = \mathbb{E}_t [\min(r_t(\theta) \hat{A}_t, \text{clip}(r_t(\theta), 1 - \epsilon, 1 + \epsilon) \hat{A}_t)] \quad (2.8)$$

trong đó $r_t(\theta) = \frac{\pi_{\theta}(a_t|s_t)}{\pi_{\theta_{\text{old}}}(a_t|s_t)}$ là tỷ lệ xác suất giữa chính sách mới và cũ, và ϵ (thường bằng 0,2) giới hạn biên độ thay đổi tối đa. PPO kết hợp cập nhật on-policy, hiệu quả tính toán cao và tính ổn định, phù hợp cho bài toán có không gian hành động rời rạc hoặc liên tục.

Ý tưởng cốt lõi của TRPO [34] — giới hạn bước cập nhật trong vùng tin cậy — được PPO thực hiện đơn giản hơn qua phép cắt, giúp cài đặt dễ dàng và huấn luyện nhanh hơn trên thực tế.

2.3 Học tăng cường đa tác tử

2.3.1 Mô hình Dec-POMDP

Khi hệ thống có nhiều tác tử ra quyết định đồng thời, bài toán được mô hình hóa bằng quá trình quyết định Markov phi tập trung có quan sát bộ phận (Decentralized Partially Observable Markov Decision Process – Dec-POMDP) [9]. Trong mô hình này, mỗi tác tử i chỉ quan sát được một phần trạng thái toàn cục thông qua hàm quan sát $o_i = O(s, i)$ và ra quyết định dựa trên quan sát cục bộ. Bài toán tìm chính sách chung tối ưu cho tất cả tác tử đã được chứng minh thuộc lớp NEXP-đầy đủ [11], nên các lời giải chính xác không khả thi ở quy mô lớn.

Bài toán tồn kho đa kho đa mặt hàng được mô hình hóa tự nhiên dưới dạng Dec-POMDP vì bốn đặc điểm cấu trúc phù hợp với lớp bài toán này:

1. **Quyết định tuần tự, hệ quả trễ.** Đơn đặt hàng hôm nay ảnh hưởng tồn kho 1–3 ngày sau. Không phải bài toán một bước.
2. **Trạng thái thay đổi theo hành động.** Đặt hàng làm đổi tồn kho, thay đổi luôn bài toán của ngày mai.
3. **Không có nhãn đúng.** Không ai biết lượng đặt tối ưu cho ngày t là bao nhiêu; chỉ biết chi phí sau khi thực hiện. Đây là lý do không dùng học có giám sát.
4. **Mục tiêu dài hạn.** Tối thiểu chi phí cả năm, không phải chỉ hôm nay. Tích trữ hôm nay tốn tiền nhưng tránh mất doanh thu ngày mai.

Quy hoạch động không khả dụng vì không gian trạng thái liên tục $43 \text{ chiều} \times 300 \text{ tác tử}$ và phân phối nhu cầu M5 không có dạng đóng — đây là “lời nguyền số chiều” mà các phương pháp bảng tra (tabular) không vượt qua được [35].

2.3.2 Học độc lập (*Independent Learning*)

Tan [19] đề xuất phương pháp học độc lập: mỗi tác tử coi các tác tử khác là một phần của môi trường và áp dụng thuật toán RL đơn tác tử riêng rẽ. Hạn chế lý thuyết chính là môi trường trở nên không dừng (non-stationary) do các tác tử khác cũng đang thay đổi chính sách. Tuy nhiên, các nghiên cứu thực nghiệm cho thấy phương pháp

này đạt hiệu quả bất ngờ trên nhiều bài toán hợp tác [20].

2.3.3 IPPO — *Independent Multi-Agent PPO*

IPPO là biến thể đa tác tử của PPO trong đó mỗi tác tử i chạy PPO độc lập dựa trên quan sát cục bộ o_i^t và phần thưởng riêng r_i^t [20]. Yu và cộng sự [21] đánh giá hệ thống trên nhiều môi trường hợp tác và kết luận rằng IPPO đạt hiệu năng cạnh tranh hoặc vượt trội so với các phương pháp phức tạp hơn như QMIX hay MAPPO trong nhiều kịch bản.

Đặc điểm quan trọng của IPPO khiến nó phù hợp cho bài toán tồn kho:

- Không yêu cầu trạng thái toàn cục: mỗi tác tử (cặp kho–mặt hàng) chỉ cần quan sát cục bộ.
- Khả năng mở rộng: không gian hành động của mỗi tác tử có kích thước K cố định, không phụ thuộc số tác tử.
- Tính đơn giản: cài đặt dựa trên PPO chuẩn, không cần mixing network hay cơ chế truyền thông.

Cần phân biệt rõ ba tầng nghĩa của “independent” trong IPPO, vì chúng hàm ý khác nhau:

- *Độc lập về ra quyết định*: mỗi tác tử chọn hành động chỉ dựa trên quan sát cục bộ của mình, không nhận thông tin từ tác tử khác. Đúng.
- *Độc lập về tính lợi thế*: GAE tính riêng theo trục thời gian cho từng cặp i , sử dụng phần thưởng riêng r_i^t và giá trị riêng $V(o_i^t)$. Đúng.
- *Độc lập về tham số*: mỗi tác tử có bộ trọng số riêng. Không — đây là điểm chia sẻ tham số (parameter sharing) được khảo sát ở Mục 2.3.4.

Hai cặp ở hai trạng thái khác nhau sẽ hành động khác nhau dù cùng θ — vì đầu vào khác nhau. Mỗi tác tử có chính sách riêng theo nghĩa hàm $\pi(a | o_i)$ nhận quan sát riêng và cho ra phân phối riêng, nhưng tham số θ dùng chung.

2.3.4 Chia sẻ tham số (*Parameter Sharing*)

Gupta và cộng sự [18] chỉ ra rằng khi các tác tử có cùng không gian quan sát và hành động, một mạng nơ-ron duy nhất có thể được chia sẻ giữa tất cả tác tử. Mỗi tác tử vẫn ra quyết định dựa trên quan sát riêng nhưng dùng chung bộ trọng số. Lợi ích:

- Số tham số cần học không tăng theo số tác tử (ở đây: 300).

- Mỗi bước cập nhật sử dụng dữ liệu từ tất cả tác tử, tăng hiệu quả mẫu.
- Chính sách học được có khả năng tổng quát hóa cho các mặt hàng có quy mô nhu cầu khác nhau.

Chẩn đáng lưu ý: chia sẻ tham số không tương đương với việc gộp 300 tác tử thành một tác tử duy nhất. Nếu gộp, không gian hành động sẽ là 6^{300} , không thể học được trên thực tế. Với kiến trúc chia sẻ tham số hiện tại, mạng nhận batch (300, 43) và forward một lần, nhưng mỗi tác tử chỉ xử lý $K = 6$ hành động — không gian cố định và có thể giải quyết được.

2.3.5 *Phần thưởng phân rẽ cục bộ và bài toán gán tín dụng*

Trong hệ đa tác tử, việc sử dụng phần thưởng toàn cục (tổng chi phí của toàn bộ hệ thống) cho mọi tác tử gây ra vấn đề gán tín dụng (credit assignment): tác tử khó phân biệt được đóng góp cá nhân trong tín hiệu tổng hợp [25]. Khóa luận áp dụng phân rẽ cục bộ: mỗi tác tử nhận phần thưởng riêng dựa trên chi phí và tỷ lệ đáp ứng của chính cặp kho–mặt hàng mà nó quản lý.

Khung lý thuyết định hình phần thưởng bảo toàn thế năng (Potential-Based Reward Shaping – PBRs) do Ng và cộng sự [36] chứng minh khẳng định rằng: một hàm biến đổi phần thưởng $F(s, a, s')$ bảo toàn tập chính sách tối ưu của MDP gốc khi và chỉ khi nó có dạng chênh lệch thế năng $F(s, a, s') = \gamma\Phi(s') - \Phi(s)$. Khung lý thuyết này sau đó được mở rộng sang hệ đa tác tử bởi Devlin và Kudenko [37] cũng như ứng dụng trong tồn kho bởi De Moor và cộng sự [38].

2.4 Các công trình nghiên cứu liên quan

2.4.1 *Học tăng cường trong quản lý tồn kho*

Oroojlooyjadid và cộng sự [16] áp dụng Deep Q-Network (DQN) cho trò chơi phân phối bia (beer game) — một bài toán chuỗi cung ứng 4 cấp cổ điển — và cho thấy DQN có thể học được chính sách giảm hiệu ứng bullwhip. Tuy nhiên, nghiên cứu giới hạn ở hệ đơn mặt hàng, bốn tác tử.

Gijsbrechts và cộng sự [17] đánh giá hệ thống khả năng của DRL trên ba lớp bài toán tồn kho: mất đơn hàng, hai nguồn cung và đa cấp. Kết quả cho thấy DRL đạt hiệu năng ngang hoặc tốt hơn chính sách cổ điển trong hầu hết trường hợp, nhưng tất cả thực nghiệm đều ở quy mô nhỏ (dưới 10 SKU).

Hubbs và cộng sự [39] giới thiệu bộ thư viện OR-Gym đóng vai trò là môi trường benchmark chuẩn cho các bài toán Vận trù học bằng RL, bao gồm cả mô hình

News vendor và quản lý tồn kho đa cấp lost-sales.

Nghiên cứu của Ding và cộng sự [40] (CD-PPO) phát biểu chính xác bài toán tồn kho đơn cửa hàng nhiều SKU dưới dạng tài nguyên kho dùng chung làm ghép nối các tác tử vốn độc lập. Họ so sánh trực tiếp IPPO và MAPPO có chia sẻ tham số (parameter sharing), chứng minh hiệu quả vượt trội khi quản lý tài nguyên kho chung.

Yang và cộng sự [41] phát triển MABIM — bộ benchmark MARL đa dạng cho tồn kho. MABIM coi mỗi SKU tại mỗi điểm lưu trữ là một tác tử độc lập, sử dụng dữ liệu nhu cầu thực tế của hơn 2.000 SKU với 51 tác vụ thử nghiệm (bao gồm nhóm tác vụ mở rộng quy mô scaling up), thử nghiệm các thuật toán MARL bao gồm IPPO dưới ràng buộc sức chứa dùng chung.

Kotecha và del Rio Chanona [42] tiến hành phân tích chuyên sâu các thuật toán MARL cho kiểm soát tồn kho phân tán, so sánh giữa IPPO thuần, IPPO chia sẻ tham số và MAPPO. Họ phát hiện rằng mặc dù parameter sharing giảm số lượng tham số cần học, hiệu năng của IPPO chia sẻ tham số có dấu hiệu giảm sút khi quy mô tác tử tăng lên rất lớn.

Gần đây nhất, Liu và cộng sự [43] áp dụng thuật toán Heterogeneous-Agent PPO (HAPPO) cho tồn kho đa cấp. Đáng chú ý, các tác giả phát hiện việc kết hợp chi phí cục bộ và chi phí toàn hệ thống vào tín hiệu thưởng thu được chính sách có độ ổn định và hiệu năng cao hơn so với chỉ dùng chi phí toàn hệ thống thuần túy.

2.4.2 Hai công trình gần nhất cùng bối cảnh

Hai công trình công bố gần đây có bối cảnh gần với khóa luận nhất và vì vậy cần được đối chiếu chi tiết.

Zhu và Wu [22] đề xuất khung DC-STGN-MARL kết hợp một mạng đồ thị không-thời gian cho dự báo nhu cầu với học tăng cường đa tác tử theo hướng phân rã hàm giá trị, đánh giá trên chính bộ dữ liệu M5. Công trình báo cáo mức giảm 13,6% tổng chi phí so với học tăng cường đơn tác tử và mức phục vụ 95,8%. Điểm cần lưu ý đối với khóa luận nằm ở khảo sát loại trừ của họ: khi thay cơ chế phối hợp bằng học độc lập, chi phí tăng từ 125,4 lên 152,7 và mức phục vụ giảm từ 95,8% xuống 92,1%. Kết quả này đặt ra câu hỏi trực tiếp về lựa chọn học độc lập của khóa luận.

Tuy nhiên, bối cảnh của hai nghiên cứu khác nhau ở một điểm mấu chốt. Môi trường của Zhu và Wu giả định năng lực cung ứng không giới hạn và không đưa sức chứa kho vào hàm mục tiêu, nên các tác tử chỉ ghép nối với nhau qua hàm phần thưởng chung chứ không qua một nguồn lực vật lý hữu hạn. Trong khóa luận, sức chứa kho dùng chung là một ràng buộc cứng và cũng chính là kênh phối hợp gián tiếp

(Mục 3.1.4); mức độ cần thiết của phối hợp tường minh trong bối cảnh này vì vậy là một câu hỏi thực nghiệm mở, chứ không thể suy trực tiếp từ kết quả của họ. Ngoài ra, một số chi tiết trong công trình cần được tiếp nhận thận trọng: các so sánh chi phí được thực hiện giữa những cấu hình có mức phục vụ khác nhau, và số lượng tác tử không được xác định rõ ràng — bài viết mô tả N tác tử “đại diện cho N kho hoặc nhóm sản phẩm” mà không xác định cụ thể.

Ở hướng thứ hai, một khung làm việc dựa trên kiến trúc hướng sự kiện kết hợp tác tử xếp vị trí lưu trữ và tác tử bổ sung hàng đã được đề xuất [23], với đóng góp chính là cơ chế *gán công liên kết hành động*: phần thưởng chỉ được tính khi lô hàng thực nhập kho sau thời gian giao hàng, rồi được quy ngược về đúng cặp trạng thái–hành động đã phát lệnh đặt. Đây là một cách xử lý trực diện độ trễ giữa quyết định và hệ quả của nó. Khảo sát loại trừ của công trình cho thấy khi bỏ cơ chế này, tỷ lệ thiếu hàng tăng vọt. Cần lưu ý rằng biến thể đối chứng của họ sử dụng trạng thái dự đoán tại thời điểm ra quyết định, chứ không phải ước lượng lợi thế tổng quát như khóa luận sử dụng; do đó con số của họ không thể chuyển trực tiếp sang bối cảnh này. Hạn chế của công trình là chỉ xét một kho duy nhất, trên dữ liệu tổng hợp, và hàm phần thưởng không quy về đơn vị tiền tệ.

Bảng 2.1 tóm tắt đối chiếu.

Bảng 2.1: Đối chiếu khóa luận với hai công trình gần nhất cùng bối cảnh

Tiêu chí	[23]	[22]	Khóa luận
Số kho	1	4	10
Ràng buộc sức chứa	một kho	không xét	riêng từng kho
Nguồn dữ liệu	tổng hợp	M5	M5
Hàm mục tiêu	không quy về tiền	chi phí	chi phí
Ghép nối giữa tác tử	không	phần thưởng chung	sức chứa dùng chung
So sánh cùng mức phục vụ	không	không	có

2.4.3 Khoảng trống nghiên cứu và định vị đóng góp

Bảng 2.2 tóm tắt so sánh tổng quan giữa khóa luận này và các công trình nghiên cứu liên quan tiêu biểu.

Đóng góp của khóa luận được định vị theo hướng tái lập và mở rộng có kiểm soát đối với ứng dụng học tăng cường đa tác tử trong kiểm soát tồn kho, tập trung vào ba trọng tâm sau:

1. Khảo sát cấu hình 10 kho song song thuần túy (non-multi-echelon) với ràng

Bảng 2.2: So sánh tổng quan các công trình nghiên cứu liên quan

Nghiên cứu	Cấu trúc mạng	Số SKU	Chia sẻ tham số	Dữ liệu thực	Thuật toán
Oroojlooyjadid (2022)	4 cấp chuỗi	1	Không	Không	DQN
Gijsbrechts (2022)	2 cấp / đa cấp	< 10	Không	Không	A2C / PPO
Hubbs et al. (2020)	Đa cấp lost-sales	Biến đổi	Không	Không	DQN / PPO
Ding et al. (2022)	1 cửa hàng	Nhiều SKU	Có	Không	CD-PPO / IPPO
Yang et al. (2023)	Đa cấp / Đa kho	> 2000	Có	Có	IPPO / MAPPO
Kotecha (2024)	Đa điểm phân tán	Biến đổi	Có	Không	IPPO / MAPPO
Liu et al. (2025)	Đa cấp phức tạp	Nhiều SKU	Có	Có	HAPPO
Khóa luận này	10 kho song song	30	Có	M5 Walmart	IPPO

buộc sức chứa kho dùng chung ở quy mô 300 cặp kho–mặt hàng, tạo điểm đối sánh trực tiếp với các mô hình đa cấp (multi-echelon) của MABIM [41] và Liu và cộng sự [43].

- Thực hiện khảo sát loại trừ có hệ thống nhằm định lượng tác động của tín hiệu phần thưởng phân rã cục bộ kèm ràng buộc tỷ lệ đáp ứng trên cửa sổ trượt, làm rõ cơ chế gán tín dụng và tốc độ hội tụ của IPPO ở quy mô 300 tác tử.
- Hiệu chỉnh môi trường mô phỏng lost-sales trực tiếp từ dữ liệu bán lẻ thực tế M5 Walmart và thực hiện kiểm chứng đối chứng có kiểm định thống kê với các chính sách cổ điển EOQ, (s, S) và Newsvendor.

CHƯƠNG 3. PHÂN TÍCH VÀ THIẾT KẾ MÔ HÌNH

3.1 Mô hình hóa bài toán tồn kho đa kho

3.1.1 Mô tả mạng lưới

Hệ thống gồm $N = 10$ kho hoạt động song song và độc lập về nguồn cung. Mỗi kho lưu trữ $M = 30$ mặt hàng (SKU), tạo thành tổng cộng $N \times M = 300$ cặp kho–mặt hàng. Mỗi kho có dung lượng hữu hạn W được chia sẻ giữa tất cả các mặt hàng. Mỗi cặp kho–mặt hàng đặt hàng trực tiếp từ nhà cung cấp bên ngoài với thời gian giao hàng ngẫu nhiên $L \sim \text{Uniform}(1, 3)$ ngày.

Sự ràng buộc giữa các mặt hàng trong cùng kho phát sinh từ dung lượng dùng chung: khi một mặt hàng đặt quá nhiều, các mặt hàng khác có thể bị phạt tràn kho. Đây chính là yếu tố khiến bài toán mang tính hợp tác và không thể tách rời thành 300 bài toán đơn lẻ.

Nhu cầu hàng ngày $D_t^{(i)}$ cho mỗi cặp kho–mặt hàng i được lấy từ hai nguồn:

- Dữ liệu M5 Walmart: tham số nhu cầu (λ trung bình, mẫu hình mùa vụ) được hiệu chỉnh từ chuỗi doanh số thực tế của 10 cửa hàng, mỗi cửa hàng 30 SKU [2].
- Dữ liệu giả lập: nhu cầu Poisson $D_t \sim \text{Poisson}(\lambda_i)$ với λ_i khác nhau giữa các SKU, phục vụ thử nghiệm đối chứng.

3.1.2 Thiết lập bài toán dưới dạng MDP đa tác tử

Phân rã nhiệm vụ và thiết kế tác tử. Trước khi hình thức hóa bài toán dưới dạng MDP đa tác tử, cần làm rõ vì sao hệ thống được phân rã thành đúng 300 tác tử theo cặp kho–mặt hàng, thay vì một cách phân rã khác.

Có hai hướng phân rã khả dĩ cho một hệ thống ra quyết định phân tán. Hướng thứ nhất là *phân rã theo chức năng* (functional decomposition): mỗi tác tử đảm nhận một khâu xử lý trong quy trình ra quyết định — chẳng hạn một tác tử quan sát làm nhiệm vụ tổng hợp thông tin (dự báo nhu cầu, theo dõi tồn kho toàn mạng lưới) và một tác tử điều phối riêng biệt chuyển các tổng hợp đó thành quyết định đặt hàng cho từng mặt hàng. Hướng thứ hai là *phân rã theo điểm ra quyết định nghiệp vụ* (decision-point decomposition): mỗi tác tử tương ứng chính xác với một điểm mà tổ chức thực sự đưa ra một quyết định độc lập.

Khóa luận chọn hướng thứ hai. Lý do xuất phát trực tiếp từ cách vận hành kho trong thực tế: người phụ trách một mã hàng tại một kho là người duy nhất ra quyết định đặt hàng lại cho đúng mã hàng đó, dựa trên tồn kho, lượng hàng đang về và lịch sử bán của chính mặt hàng mình phụ trách — không tồn tại một “tác tử quan sát” trung gian tổng hợp thông tin của cả 300 mã hàng rồi một “tác tử điều phối” khác mới ra quyết định. Nếu phân rã theo chức năng, khóa luận sẽ phải tự thiết kế thêm một giao diện truyền thông giữa tác tử quan sát và tác tử điều phối — một thành phần không tồn tại trong bài toán nghiệp vụ gốc và sẽ làm thay đổi chính đối tượng nghiên cứu, đồng thời đặt ra câu hỏi ai chịu trách nhiệm quyết định cuối cùng khi hai tác tử bất đồng. Phân rã theo điểm ra quyết định nghiệp vụ tránh được vấn đề này: không gian hành động của mỗi tác tử ánh xạ trực tiếp vào một đòn bẩy vận hành có thật (lượng đặt hàng lại), và bài toán gán tín dụng (credit assignment) của mỗi tác tử gắn liền với đúng một chi phí mà quyết định của nó gây ra, không phải một chi phí tổng hợp từ nhiều quyết định của các tác tử khác.

Hệ quả trực tiếp là số lượng tác tử bằng đúng số cặp kho–mặt hàng, $N \times M = 300$, chứ không phụ thuộc vào số khâu xử lý được thiết kế trong hệ thống. Cách phân rã này cũng là tiền đề cho kiến trúc phi tập trung hoàn toàn được trình bày ở Mục 3.1.4: một khi đã phân rã theo đúng điểm ra quyết định thực tế, việc bổ sung một tác tử điều phối trung tâm sẽ mâu thuẫn với chính căn cứ phân rã ban đầu.

Bài toán được mô hình hóa dưới dạng Dec-POMDP [9] với 300 tác tử. Mỗi tác tử i (tương ứng cặp kho–mặt hàng) có:

Không gian quan sát $o_i^t \in \mathbb{R}^d$: vector quan sát cục bộ tại kỳ t bao gồm:

- Mức tồn kho hiện tại (on-hand inventory): $I_t^{(i)}$.
- Lượng hàng đang trên đường vận chuyển (in-transit): tổng các đơn hàng đã phát mà chưa nhập kho.
- Nhu cầu lịch sử w ngày gần nhất: $(D_{t-w}^{(i)}, \dots, D_{t-1}^{(i)})$.
- Tỷ lệ đáp ứng nhu cầu trên cửa sổ trượt w ngày: $\text{FR}_t^{(i,w)}$.
- Tỷ lệ sử dụng sức chứa của kho chứa tác tử i : $u_t^{(w(i))} = \sum_{j \in w(i)} I_t^{(j)} / W_{w(i)}$, trong đó $w(i)$ là kho chứa cặp i và $W_{w(i)}$ là sức chứa của kho đó.
- Tỷ trọng tồn kho của chính cặp i trong kho: $I_t^{(i)} / \sum_{j \in w(i)} I_t^{(j)}$.
- Đặc trưng quy mô $\log(1 + \bar{D}^{(i)})$ chuẩn hóa, cho phép mạng dùng chung phân biệt các mặt hàng có quy mô nhu cầu khác nhau.
- Bối cảnh thời gian: thứ trong tuần (one-hot 7 chiều) và vector đặc trưng lịch 20 chiều trích từ `calendar.csv` (ba cờ SNAP, một cờ không có sự kiện, bốn

loại sự kiện, mười hai tháng).

Tổng cộng vector quan sát của mỗi tác tử có $d = 43$ chiều. Hai thành phần $u_t^{(w(i))}$ và tỷ trọng tồn kho giữ vai trò đặc biệt: hàm phần thưởng có thành phần phạt tràn kho phụ thuộc vào tổng tồn kho của cả kho, nên nếu quan sát không chứa thông tin ở cấp kho thì tác tử bị phạt vì một đại lượng nó không quan sát được, và hàm giá trị không thể nhất quán. Đây cũng chính là kênh ghép nối duy nhất giữa các tác tử trong thiết kế phi tập trung của khóa luận (Mục 3.1.4).

Bảng 3.1 đối chiếu các biến trạng thái đặc trưng của bài toán tồn kho với cách biểu diễn trong vector quan sát 43 chiều.

Bảng 3.1: Đối chiếu biến trạng thái và biểu diễn trong vector quan sát

Biến trạng thái	Có trong quan sát?	Ghi chú
Tồn kho hiện tại	Có (1 chiều)	Chuẩn hóa theo số ngày nhu cầu
Vị thế tồn kho (IP)	Có (1 chiều)	Tồn kho + hàng đang về
Nhu cầu lịch sử	Có (7 chiều)	7 ngày gần nhất, thang log
Nhu cầu hiện tại	Không	Có chú ý: quyết định đặt hàng xảy ra trước khi nhu cầu ngày hôm đó phát sinh; đưa vào là rò rỉ thông tin tương lai
Hàng đang về (pipeline)	Có (3 chiều)	Lượng hàng theo từng ngày còn lại đến hạn
Thời gian giao hàng (L)	Gián tiếp	Không quan sát trực tiếp L đã bốc; phản ánh qua pipeline — partial observability có chú ý (xem ghi chú bên dưới)
Tình trạng thiếu hàng	Có (1 chiều)	Fill rate cửa sổ trượt 30 ngày
Mức sử dụng sức chứa kho	Có (1 chiều)	$u_t^{(w(i))} = \sum_{j \in w(i)} I_t^{(j)} / W_{w(i)}$
Tỷ trọng tồn kho trong kho	Có (1 chiều)	Thông tin về mức độ chiếm dụng kho
Đặc trưng quy mô	Có (1 chiều)	$\log(1 + \bar{D}^{(i)})$, giúp mạng dùng chung phân biệt SKU
Ngày trong tuần	Có (7 chiều)	One-hot encoding
Đặc trưng lịch	Có (20 chiều)	SNAP, loại sự kiện, tháng

Ghi chú về thời gian giao hàng. Môi trường bốc thời gian giao hàng ngẫu nhiên $L \sim \text{Uniform}\{1, 2, 3\}$ cho từng đơn hàng, nhưng tác tử không quan sát trực tiếp giá trị L đã bốc. Thay vào đó, thông tin này được phản ánh gián tiếp qua vector pipeline 3

chiều. Đây là lựa chọn có chủ ý phù hợp với tinh thần Dec-POMDP: trong thực tế vận hành, nhà cung cấp cũng không cam kết chính xác ngày giao — tác tử chỉ biết hàng đang trên đường, không biết hôm nay hay ngày mai mới đến. Hạn chế này được ghi nhận rõ trong phân tích hạn chế thực nghiệm (Mục 4.6).

Không gian hành động $a_i^t \in \{0, 1, \dots, K-1\}$: mỗi tác tử chọn một trong $K = 6$ mức đặt hàng rời rạc. Các mức này được định nghĩa tương đối theo quy mô nhu cầu của chính cặp i :

$$q_i(k) = \left\lceil m_k \cdot \bar{D}^{(i)} \cdot \bar{L} \right\rceil, \quad \mathbf{m} = (0, 0,5; 1; 2; 3; 5), \quad (3.1)$$

trong đó $\bar{D}^{(i)}$ là nhu cầu trung bình một ngày của cặp i ước lượng trên miền huấn luyện và $\bar{L} = 2$ là thời gian giao hàng trung bình. Lựa chọn này xuất phát từ đặc điểm dữ liệu: 73,4% số chuỗi M5 có nhu cầu dưới một đơn vị mỗi ngày, nên một thang mức đặt hàng tuyệt đối dùng chung sẽ khiến mức nhỏ nhất khác không đã tương đương hàng chục ngày nhu cầu đối với các mặt hàng bán chậm, trong khi lại quá nhỏ đối với các mặt hàng bán nhanh.

Bảng mức đặt hàng được ép tăng nghiêm ngặt theo k : mức k luôn lớn hơn mức $k-1$ ít nhất một đơn vị. Nếu không có ràng buộc này, phép làm tròn sẽ khiến nhiều hành động khác nhau cho cùng một lượng đặt hàng — với các cặp có $\bar{D}^{(i)}$ nhỏ, sáu mức có thể thu về chỉ còn hai giá trị phân biệt — và tác tử nhận các tín hiệu lợi thế mâu thuẫn cho những hành động trên thực tế là đồng nhất.

Không gian hành động chung của toàn hệ thống là tích Descartes $K^{300} = 6^{300}$, nhưng mỗi tác tử chỉ xử lý $K = 6$ hành động.

Hàm chuyển trạng thái diễn ra theo sáu bước theo đúng thứ tự thực thi trong môi trường mô phỏng:

1. **Ánh xạ hành động:** hành động $a_i^t \in \{0, \dots, 5\}$ của mỗi tác tử được ánh xạ sang lượng đặt hàng $q_i(a_i^t)$ qua bảng mức tương đối (3.1).
2. **Nhận hàng từ pipeline:** hàng đang vận chuyển ở vị trí 0 của pipeline (đến hạn ngày t) được nhập kho.
3. **Thực thi ràng buộc sức chứa:** nếu tổng tồn kho kho w vượt W_w , phần vượt bị từ chối và phân bổ lại theo tỷ trọng tồn kho theo (3.3).
4. **Dịch pipeline và ghi đơn mới:** pipeline dịch trái một vị trí; đơn hàng mới được ghi vào vị trí $L-1$ với $L \sim \text{Uniform}\{1, 2, 3\}$ — đây là nguồn ngẫu nhiên thứ nhất.
5. **Phát sinh nhu cầu:** nhu cầu $D_t^{(i)}$ lấy từ chuỗi M5 thực tế — đây là nguồn

ngẫu nhiên thứ hai. Bán $\min(I_t^{(i)}, D_t^{(i)})$; phần thiếu bị mất hoàn toàn (lost sales).

6. **Cập nhật lịch sử và cửa sổ fill rate:** ghi nhận nhu cầu và lượng đáp ứng vào lịch sử 7 ngày; cập nhật fill rate cửa sổ trượt 30 ngày. Tính phần thưởng r_i^t và chuyển sang $t + 1$.

3.1.3 Ràng buộc sức chứa kho và cơ chế từ chối nhập hàng

Mỗi kho w có một sức chứa hữu hạn W_w dùng chung cho toàn bộ M mặt hàng đặt trong kho đó. Sức chứa được xác định theo số ngày nhu cầu mà kho có thể tích trữ:

$$W_w = \kappa \cdot \sum_{j=1}^M \bar{D}^{(w,j)}, \quad \kappa = 5,0 \text{ ngày}, \quad (3.2)$$

trong đó $\bar{D}^{(w,j)}$ là nhu cầu trung bình một ngày của mặt hàng j tại kho w , ước lượng trên miền huấn luyện.

Điểm cần lưu ý là sức chứa được tính riêng cho từng kho, theo chính quy mô nhu cầu của kho đó, chứ không phải một hằng số dùng chung. Trong tập dữ liệu thực nghiệm, nhu cầu giữa các kho chênh lệch tới 4,5 lần (Bảng 3.2); nếu áp một sức chứa chung, kho lớn nhất chỉ tích trữ được khoảng 1,4 ngày nhu cầu trong khi thời gian giao hàng có thể lên tới ba ngày. Khi đó mục tiêu mức phục vụ 85% trở thành bất khả thi về mặt cấu trúc: không tồn tại chính sách nào tránh được đồng thời hình phạt tràn kho và hình phạt vi phạm mức phục vụ, và tín hiệu học suy biến thành nhiễu.

Bảng 3.2: Nhu cầu và sức chứa của từng kho trong cấu hình thực nghiệm

Kho	Cầu/ngày	W_w	Kho	Cầu/ngày	W_w
CA_3	223,0	1.114,6	TX_3	101,3	506,4
CA_1	121,2	606,1	CA_2	70,3	351,6
TX_2	114,0	570,1	TX_1	89,0	444,9
WI_2	51,5	257,4	WI_1	49,1	245,4
WI_3	99,2	495,9	CA_4	54,2	270,9

Ràng buộc được thực thi tại thời điểm *nhập hàng*: sau khi các đơn hàng đến kho, nếu tổng tồn kho vượt W_w thì phần vượt bị từ chối nhập và phân bổ theo tỷ trọng tồn kho của từng mặt hàng,

$$O_t^{(i)} = \max\left(0, \sum_{j \in w(i)} \tilde{I}_t^{(j)} - W_{w(i)}\right) \cdot \frac{\tilde{I}_t^{(i)}}{\sum_{j \in w(i)} \tilde{I}_t^{(j)}}, \quad (3.3)$$

với $\tilde{I}_t$ là mức tồn kho ngay sau khi nhận hàng và trước khi bán. Cơ chế từ chối tại cửa nhập phản ánh đúng vận hành kho thực tế, khác với cách hủy hàng sau khi đã nhập — vốn khiến chi phí đặt hàng đã bỏ ra trở nên vô nghĩa và khó biện giải về mặt nghiệp vụ.

3.1.4 Cơ chế phối hợp giữa các tác tử

Khóa luận lựa chọn kiến trúc *phi tập trung hoàn toàn*: không có tác tử điều phối trung tâm, không có kênh truyền thông tường minh giữa các tác tử. Lựa chọn này là có chủ đích, xuất phát từ hai lý do.

Thứ nhất, về mặt nghiệp vụ, điểm ra quyết định đặt hàng lại trong vận hành kho là một mã hàng tại một kho: người phụ trách ngành hàng quyết định đặt bao nhiêu cho mặt hàng mình phụ trách, dựa trên tồn kho, lượng hàng đang về và lịch sử bán của chính mặt hàng đó. Việc phân rã thành 300 tác tử vì vậy đến từ cấu trúc bài toán chứ không phải từ mong muốn áp dụng mô hình đa tác tử.

Thứ hai, về mặt thuật toán, bổ sung một critic tập trung sẽ chuyển bài toán sang lớp phương pháp huấn luyện tập trung — thực thi phi tập trung (CTDE) như MAPPO [21], tức là thay đổi chính đối tượng nghiên cứu.

Sự phối hợp giữa các tác tử vì vậy diễn ra gián tiếp, qua hai kênh đã có sẵn trong thiết kế:

- Kênh quan sát: mỗi tác tử quan sát được tỷ lệ sử dụng sức chứa $u_t^{(w(i))}$ của kho mình thuộc về, nên biết khi nào kho sắp đầy.
- Kênh phần thưởng: hình phạt tràn kho theo công thức (3.3) được phân bổ theo tỷ trọng tồn kho, nên tác tử tích trữ nhiều chịu phần phạt lớn hơn.

Bằng chứng thực nghiệm cho thấy tác tử đã học cách sử dụng tín hiệu sức chứa. Để giải mã hành vi ẩn, khóa luận quét lưới trạng thái trên một cặp đại diện: cố định tất cả chiều quan sát ở mức trung vị và chỉ thay đổi mức sử dụng sức chứa kho $u_t^{(w)}$ từ 20% lên 95%, rồi đọc lại phân phối hành động của chính sách. Kết quả: ngưỡng đặt hàng s (số ngày nhu cầu) gần như không đổi (1,348 ngày tại $u = 20\%$ so với 1,362 ngày tại $u = 95\%$), nhưng mức đặt tối đa S giảm từ 5,65 xuống 5,09 ngày và 4 cặp ngưỡng đặt hàng hoàn toàn khi kho đạt 95% sức chứa. Nói cách khác, tác tử không thay đổi điều kiện kích hoạt đặt hàng mà chỉ thu hẹp lô hàng khi kho chật. Đây chính là dạng phối hợp nổi lên (emergent coordination) không được lập trình tường minh mà do tác tử tự học qua tín hiệu phần thưởng. Chính sách cổ điển như (s, S) không thể thực hiện hành vi này vì chúng không quan sát được trạng thái kho.

Bảng 3.3 tóm tắt đặc tả của một tác tử. Vì toàn bộ 300 tác tử đồng nhất về vai trò và chia sẻ chung một bộ trọng số, một bảng đặc tả duy nhất mô tả đầy đủ hệ thống.

Bảng 3.3: Đặc tả tác tử trong hệ thống đề xuất

Thành phần	Nội dung
Tác tử	Cặp (kho w , mặt hàng j); tổng cộng 300 tác tử đồng nhất
Vai trò	Quyết định lượng đặt hàng lại hằng ngày cho đúng một mặt hàng tại đúng một kho
Đầu vào	Vector quan sát cục bộ $o_i^t \in \mathbb{R}^{43}$
Quan sát	Tồn kho, vị thế tồn kho, nhu cầu 7 ngày gần nhất, hàng đang về theo từng ngày còn lại, fill rate cửa sổ 30 ngày, đặc trưng quy mô, tỷ lệ sử dụng kho, tỷ trọng tồn kho trong kho, thứ trong tuần, đặc trưng lịch
Nhiệm vụ	Tác vụ con của bài toán tổng “tối thiểu tổng chi phí vận hành toàn hệ thống dưới ràng buộc sức chứa và mức phục vụ”
Hành động	$a_i^t \in \{0, \dots, 5\}$, ánh xạ sang lượng đặt hàng theo (3.1)
Chính sách	$\pi_\theta(a \mid o)$ — mạng Actor dùng chung trọng số θ cho mọi tác tử
Đầu ra	Lượng đặt hàng $q_i(a_i^t)$ phát tới nhà cung cấp
Tương tác	Không truyền thông trực tiếp; phối hợp gián tiếp qua sức chứa kho dùng chung (Mục 3.1.4)

3.2 Thiết kế hàm phần thưởng

3.2.1 Phần thưởng phân rẽ cục bộ

Mỗi tác tử i nhận phần thưởng riêng dựa trên chi phí của chính cặp kho–mặt hàng mà nó quản lý, thay vì dùng chung phần thưởng toàn cục:

$$r_i^t = - \left(c_{lk} \cdot I_t^{(i)+} + c_{th} \cdot U_t^{(i)} + c_{dh} \cdot \mathbb{1}(a_i^t > 0) + p_{tk} \cdot O_t^{(i)} \right) - \phi_{dv} \cdot c_{th} \cdot \bar{D}^{(i)} \cdot \max(\tau - \text{FR}_t^{(i,w)}, 0) \quad (3.4)$$

trong đó:

- $I_t^{(i)+} = \max(I_t^{(i)}, 0)$: mức tồn kho dương.
- $U_t^{(i)} = \max(D_t^{(i)} - I_t^{(i)}, 0)$: lượng nhu cầu không được đáp ứng.
- $O_t^{(i)}$: lượng hàng tràn kho (phần vượt sức chứa).
- $\text{FR}_t^{(i,w)}$: tỷ lệ đáp ứng trên cửa sổ trượt $w = 30$ ngày.
- $\bar{D}^{(i)}$: nhu cầu trung bình một ngày của cặp i , ước lượng trên miền huấn luyện (cùng đại lượng dùng trong bảng mức đặt hàng (3.1)).

- $\tau = 0,85$: ngưỡng mức phục vụ mục tiêu.

3.2.2 Vai trò của thành phần phạt fill rate

Thành phần $\phi_{dv} \cdot c_{th} \cdot \bar{D}^{(i)} \cdot \max(\tau - \text{FR}_t^{(i,w)}, 0)$ bổ sung tín hiệu phạt ràng buộc (constraint penalty) theo tinh thần Lagrangian: thay vì chỉ phạt thiếu hàng tức thời (vốn có phương sai cao do nhu cầu gián đoạn), tỷ lệ đáp ứng trên cửa sổ trượt cung cấp đánh giá ổn định hơn về chất lượng phục vụ. Cần nhấn mạnh rằng hình phạt này không thuộc dạng chênh lệch thể năng của Ng và cộng sự [36], mà cố ý thay đổi cấu trúc phần thưởng của MDP gốc nhằm điều hướng chính sách tìm kiếm giải pháp thỏa mãn ràng buộc mức phục vụ kinh doanh.

Tích $c_{th} \cdot \bar{D}^{(i)}$ quy đổi độ hụt fill rate — một đại lượng không thứ nguyên trong $[0, 1]$ — về cùng thang đo tiền tệ với bốn thành phần chi phí còn lại (xấp xỉ chi phí thiếu hàng của một ngày hụt hoàn toàn ở mức nhu cầu trung bình của cặp i), để ϕ_{dv} đóng đúng vai trò một hệ số nhân thuần túy thay vì phải tự gánh cả việc quy đổi đơn vị. Cần lưu ý c_{th} ở đây luôn là *hằng số thiếu hàng chung* cho toàn hệ thống, không phải $c_{th}^{(i)}$ theo từng cặp dùng trong chi phí thiếu hàng thực (Mục 3.2.3): mục tiêu mức phục vụ 85% là một cam kết quản trị áp dụng đồng loạt, nên độ mạnh của hình phạt SLA không nên tỷ lệ theo đơn giá của riêng từng mặt hàng.

Cần phân biệt rõ hai thang chi phí trong báo cáo. **Thành phần phạt mức phục vụ $\phi_{dv}(\cdot)$ là tín hiệu định hướng học, không phải chi phí kế toán**: nó không được tính vào tổng chi phí vận hành báo cáo trong Chương 4. Mọi con số so sánh giữa các phương pháp đều dựa trên bốn thành phần chi phí thực phát sinh (lưu kho, thiếu hàng, đặt hàng, tràn kho), tương đương với chi phí mà doanh nghiệp thực sự phải trả.

3.2.3 Các tham số chi phí

Bảng 3.4 liệt kê các tham số chi phí sử dụng trong thực nghiệm.

Bảng 3.4: Tham số chi phí trong môi trường mô phỏng

Thành phần	Ký hiệu	Giá trị
Chi phí lưu kho	c_{lk}	1,0 /đơn vị/ngày
Chi phí thiếu hàng	c_{th}	10,0 /đơn vị
Chi phí đặt hàng	c_{dh}	5,0 /lần đặt
Phạt tràn kho	p_{tk}	5,0 /đơn vị tràn
Phạt vi phạm mức phục vụ	ϕ_{dv}	3,0
Ngưỡng fill rate	τ	85%
Cửa sổ fill rate	w	30 ngày

Lưu ý rằng với bộ tham số chi phí $c_{th} = 10,0$ và $c_{lk} = 1,0$, tỷ số chi phí thiếu hàng ngầm định mức phục vụ chu kỳ lý thuyết $\alpha \approx 90,9\%$. Do đó, ràng buộc fill rate $\beta \geq 85\%$ có khả năng rơi vào trạng thái không có hiệu lực (non-binding) trong quá trình thực nghiệm mô phỏng. Đây là một giả thuyết cần kiểm chứng qua kết quả huấn luyện.

3.2.4 Chuẩn hóa phần thưởng theo từng cặp

Phần thưởng thô của các cặp chênh lệch nhau tới bốn bậc độ lớn: một mặt hàng bán 0,2 đơn vị mỗi ngày phát sinh chi phí ngày ở mức đơn vị, trong khi mặt hàng bán 143 đơn vị mỗi ngày có thể phát sinh chi phí ngày lên tới hàng chục nghìn. Vì toàn bộ 300 tác tử dùng chung một mạng Critic, hàm giá trị phải khớp các mục tiêu trải trên dải rộng như vậy; khi đó hàm mất mát của Critic bị chi phối hoàn toàn bởi một nhóm cặp có quy mô lớn nhất, và gradient truyền về mạng bị lệch theo.

Khóa luận vì vậy chuẩn hóa phần thưởng của từng cặp theo một đơn vị chi phí đặc trưng của chính cặp đó:

$$\tilde{r}_t^{(i)} = \frac{r_t^{(i)}}{c_{th} \cdot \bar{D}^{(i)} + c_{dh}}, \quad (3.5)$$

trong đó mẫu số là chi phí tương ứng với một ngày vận hành xấu nhất điển hình của cặp i : hết hàng trong suốt cả ngày, cộng thêm một lần phát đơn đặt hàng. Hằng số c_{dh} giữ cho mẫu số không tiến về không đối với những mặt hàng gần như không bán. Phép chuẩn hóa này chỉ thay đổi thang đo của tín hiệu học, không thay đổi thứ tự ưu tiên giữa các hành động của cùng một tác tử; toàn bộ chi phí báo cáo trong Chương 4 đều là chi phí gốc chưa chuẩn hóa.

Ảnh hưởng của thành phần này tới quá trình hội tụ được khảo sát tường minh trong Mục 4.5.2.

3.3 Kiến trúc mạng Actor–Critic chia sẻ tham số

3.3.1 Mạng SharedActorCritic

Toàn bộ 300 tác tử dùng chung một mạng nơ-ron duy nhất [18], gồm:

- Mạng Actor: hai lớp ẩn fully-connected, mỗi lớp 128 nơ-ron, hàm kích hoạt Tanh, kết thúc bằng một lớp tuyến tính xuất ra phân phối xác suất trên $K = 6$ mức đặt hàng (softmax).
- Mạng Critic: cấu trúc tương tự nhưng độc lập hoàn toàn về tham số, xuất ra

giá trị $V(o_i)$.

Actor và Critic được cài đặt dưới dạng hai mạng tách rời, không dùng chung thân mạng. Quyết định này xuất phát từ một quan sát thực nghiệm cụ thể. Khi hai mạng dùng chung thân, độ lớn gradient sinh ra từ hàm mất mát giá trị vượt xa gradient sinh ra từ hàm mất mát chính sách — đo được trên chính môi trường của khóa luận là 28,13 so với 0,096, tức gấp khoảng 293 lần. Vì phép cắt chuẩn gradient (`clip_grad_norm`) áp cho toàn bộ tham số của mạng, mọi gradient bị nhân với cùng một hệ số $0,5/28,13 \approx 0,018$, khiến tốc độ học hiệu dụng của Actor tụt khoảng 55 lần so với giá trị đặt. Hệ quả quan sát được là entropy của chính sách đứng yên ở gần giá trị $\ln K$ của phân phối đều trong suốt giai đoạn đầu — nghĩa là Actor hầu như không học. Tách hai mạng và cắt gradient riêng cho từng mạng là cách khắc phục triệt để; hiện tượng này được khảo sát tường minh trong Mục 4.5.3.

- Ghi chú cài đặt: khởi tạo trực giao (orthogonal) với hệ số $\sqrt{2}$ cho các lớp ẩn, 0,01 cho lớp xuất của Actor và 1,0 cho lớp xuất của Critic; chuẩn hóa mục tiêu giá trị bằng trung bình và phương sai trượt.

Kiến trúc đầu vào nhận vector quan sát cục bộ o_i^t của một tác tử bất kỳ. Mỗi forward pass xử lý một batch gồm quan sát của nhiều tác tử cùng lúc. Số tham số cần học là hằng số, không phụ thuộc vào $N \times M$.

3.3.2 Quy trình huấn luyện IPPO

1. Thu thập dữ liệu (Rollout): Chạy $n_{\text{steps}} = 1024$ bước trong môi trường. Tại mỗi bước, tất cả 300 tác tử cùng chọn hành động, tổng cộng thu được $1024 \times 300 = 307.200$ mẫu (o_i, a_i, r_i, o_i') mỗi vòng rollout.
2. Tính GAE: Ước lượng lợi thế $\hat{A}_t^{(i)}$ cho từng tác tử i sử dụng công thức GAE (2.7) với $\gamma = 0,99$ và $\lambda = 0,95$.
3. Chuẩn hóa lợi thế theo từng cặp (per-pair advantage normalization): Chuẩn hóa $\hat{A}_t^{(i)}$ theo trung bình và độ lệch chuẩn tính riêng cho mỗi cặp kho–mặt hàng i , giúp các cặp có quy mô chi phí khác nhau đóng góp cân bằng vào gradient.
4. Cập nhật PPO: Thực hiện tối đa $E = 4$ epoch tối ưu hóa hàm mục tiêu clipped (2.8) trên toàn bộ dữ liệu rollout, với cơ chế dừng sớm khi độ lệch KL xấp xỉ vượt $1,5 \times$ ngưỡng $\text{KL}_{\text{target}} = 0,02$. Tốc độ học Actor $\eta_a = 3 \times 10^{-4}$, Critic $\eta_c = 1 \times 10^{-3}$; cả hai được suy giảm tuyến tính theo tiến độ huấn luyện.

5. Lặp lại bước 1–4 trong 1000 episode. Toàn bộ quy trình được lặp lại độc lập trên 3 hạt giống huấn luyện ($\text{seed} \in \{42, 1, 2\}$) nhằm kiểm tra độ tin cậy thống kê của kết quả theo khuyến nghị của Henderson và cộng sự [28] (Mục 4.3.1).

Bảng 3.5 tóm tắt các siêu tham số chính.

Bảng 3.5: Siêu tham số huấn luyện

Nhóm	Tham số	Giá trị
Môi trường	$N \times M$ (số tác tử)	$10 \times 30 = 300$
	Episode length	365 ngày
	Lead time	[1, 3] ngày
	Bội số mức đặt hàng (m)	$\{0; 0,5; 1; 2; 3; 5\}$
PPO	Rollout steps (n_{steps})	1024
	PPO epochs (E)	4
	Learning rate Actor	3×10^{-4}
	Learning rate Critic	1×10^{-3}
	γ	0,99
	λ_{GAE}	0,95
	Clip ϵ	0,2
	Total episodes	1000 ($\times 3$ hạt giống)
Mạng	Hidden layers (mỗi mạng) Actor / Critic	2×128 hai mạng tách rời
	Activation	Tanh

3.4 Thiết kế môi trường mô phỏng

Môi trường được xây dựng theo chuẩn Gymnasium [24], kế thừa giao diện từ OpenAI Gym [33], cung cấp các phương thức `reset()` và `step(action)` chuẩn.

MultiWarehouseInventoryEnv quản lý:

- Ma trận tồn kho $\mathbf{I} \in \mathbb{R}^{N \times M}$.
- Hàng đợi giao hàng cho mỗi cặp (tracking lead time).
- Lịch sử nhu cầu và fill rate trượt.
- Hàm tính chi phí và phần thưởng (công thức 3.4).

Mỗi episode kéo dài 365 bước (tương đương 1 năm), phản ánh chu kỳ kinh doanh thực tế.

Khóa luận lựa chọn tự xây dựng môi trường MultiWarehouseInventoryEnv thay vì sử dụng các bộ thư viện benchmark sẵn có như OR-Gym [39] hay MABIM

[41]. Lý do chính là các benchmark hiện hành chưa hỗ trợ sẵn cấu hình mạng lưới gồm 10 kho song song độc lập về nguồn cung kết hợp đồng thời với ràng buộc sức chứa kho dùng chung giữa 30 SKU và cơ chế phạt tỷ lệ đáp ứng trên cửa sổ trượt. Việc tự phát triển môi trường đảm bảo khả năng kiểm soát toàn diện các tham số mô phỏng và tính tương thích với mục tiêu nghiên cứu của đề tài.

CHƯƠNG 4. THỰC NGHIỆM VÀ ĐÁNH GIÁ KẾT QUẢ

4.1 Cấu hình thực nghiệm

4.1.1 Môi trường phần cứng và phần mềm

Môi trường thực nghiệm được triển khai trên nền tảng Python với các thư viện cốt lõi: PyTorch (cài đặt mạng Actor–Critic và thuật toán PPO), Gymnasium [24] (giao diện môi trường mô phỏng), NumPy và Pandas (xử lý dữ liệu M5 và tính toán thống kê), SciPy (kiểm định thống kê).

Toàn bộ quá trình huấn luyện được thực hiện trên CPU, không sử dụng GPU. Kết quả báo cáo trong chương này dựa trên 3 lần huấn luyện độc lập (Mục 4.3.1), mỗi lần 1.000 episode và mất khoảng 38–40 phút, tổng cộng xấp xỉ 116 phút cho cả 3 hạt giống. Con số này đáng chú ý khi đối chiếu với các công trình cùng lĩnh vực: khung DC-STGN-MARL của Zhu và Wu [22] cần khoảng 36 giờ trên một GPU NVIDIA V100 cho một lần huấn luyện duy nhất. Sự chênh lệch đến từ lựa chọn thiết kế: khóa luận không sử dụng mô-đun dự báo nhu cầu bằng học sâu mà để tác tử học trực tiếp từ lịch sử nhu cầu thô trong vector quan sát.

4.1.2 Nguồn dữ liệu và tiền xử lý

Khóa luận sử dụng hai tệp chính từ bộ dữ liệu M5 [2], [3]: `sales_train_evaluation.csv` chứa 30.490 chuỗi doanh số theo ngày ($3.049 \text{ mặt hàng} \times 10 \text{ cửa hàng}$) trên 1.941 ngày, và `calendar.csv` chứa thông tin lịch, ngày lễ và các sự kiện trợ cấp thực phẩm SNAP.

Quy trình sàng lọc mặt hàng. Không phải mọi tổ hợp cửa hàng — mặt hàng đều tạo thành một bài toán đặt hàng lại. Trong bộ dữ liệu gốc có một tỷ lệ đáng kể các cặp mà cửa hàng trên thực tế không kinh doanh mặt hàng đó, thể hiện qua chuỗi doanh số gần như bằng không suốt toàn bộ giai đoạn. Đưa những chuỗi này vào tập huấn luyện không làm bài toán khó hơn mà chỉ bổ sung nhiễu vào gradient của mạng dùng chung. Khóa luận vì vậy chỉ giữ lại các mặt hàng có nhu cầu trung bình từ 0,2 đơn vị mỗi ngày trở lên tại ít nhất 80% số cửa hàng, tính trên miền huấn luyện. Từ 3.049 mặt hàng ban đầu, 1.762 mặt hàng vượt ngưỡng; trong số đó $M = 30$ mặt hàng được chọn theo phương pháp phân tầng trên ba nhóm ngành hàng (Foods, Hobbies, Household) nhằm bảo đảm dải quy mô nhu cầu trải rộng.

Bảng 4.1 so sánh đặc trưng của tập thực nghiệm với bộ dữ liệu gốc. Điểm cần lưu ý là tỷ lệ ngày không phát sinh giao dịch vẫn ở mức 57,4%: quy trình sàng lọc loại bỏ các chuỗi thoái hóa nhưng không làm mất đi tính gián đoạn — vốn là đặc trưng khiến bài toán trở nên khó và là một trong những lập luận nền của khóa luận.

Bảng 4.1: Đặc trưng nhu cầu của tập thực nghiệm so với bộ dữ liệu gốc

Chỉ tiêu	M5 gốc	Tập thực nghiệm
Số chuỗi (cặp kho–mặt hàng)	30.490	300
Nhu cầu trung bình (đv/ngày)	1,13	3,24
Trung vị nhu cầu (đv/ngày)	0,45	0,74
Tỷ lệ ngày bằng không	68,0%	57,4%
Cặp có nhu cầu $< 0,1$ đv/ngày	—	5/300

Tách miền thời gian. Dữ liệu được chia theo trục thời gian tại ngày thứ 1.450: các episode huấn luyện lấy điểm khởi đầu ngẫu nhiên trong đoạn $[0, 1450 - 365]$, các episode đánh giá lấy trong đoạn $[1450, 1941 - 365]$. Hai miền không chồng lấn. Nhu cầu trung bình $\bar{D}^{(i)}$ dùng cho bảng mức đặt hàng, sức chứa kho và chuẩn hóa phần thưởng đều chỉ được ước lượng trên miền huấn luyện, nên không có rò rỉ thông tin từ miền đánh giá.

4.1.3 Thiết lập kịch bản mô phỏng

Bảng 4.2: Cấu hình môi trường mô phỏng

Tham số	Giá trị
Số kho (N)	10
Số mặt hàng (M)	30
Số tác tử ($N \times M$)	300
Độ dài episode	365 ngày
Cửa sổ nhìn lại (w)	7 ngày
Lead time	Uniform{1, 2, 3} ngày
Bộ số mức đặt hàng ($\mathbf{m}$)	{0; 0,5; 1; 2; 3; 5}
Sức chứa kho (κ)	5,0 ngày nhu cầu của từng kho
Ngưỡng fill rate (τ)	85%

Lựa chọn $\kappa = 5,0$ được xác định bằng thực nghiệm. Với $\kappa = 3,0$, mức phục vụ cao nhất mà bất kỳ chính sách nào đạt được chỉ là 79,5% — mục tiêu 85% trở thành bất khả thi. Với $\kappa \geq 12,0$, chi phí tràn kho bằng không: ràng buộc không còn hiệu lực và bài toán suy biến thành 300 bài toán độc lập, mất đi bản chất đa tác tử. Tại $\kappa = 5,0$,

mục tiêu 85% khả thi trong khi chi phí tràn kho vẫn chiếm khoảng 1–2% tổng chi phí, nghĩa là ràng buộc thực sự có hiệu lực.

4.2 Phương pháp đối chứng

Hiệu năng của IPPO được so sánh với ba chính sách tồn kho cổ điển: EOQ [12], (s, S) [13] và Newsvendor [14].

Điều kiện so sánh công bằng. Ba yếu tố được kiểm soát. Thứ nhất, tham số của cả ba chính sách được tối ưu bằng tìm kiếm lưới trên chính môi trường mô phỏng, ở miền huấn luyện, rồi mới áp dụng cho miền đánh giá — tương ứng với quy trình mà IPPO trải qua. Thứ hai, các chính sách cổ điển truy cập cùng một tập thông tin với tác tử IPPO: nhu cầu trung bình và độ lệch chuẩn ước lượng từ miền huấn luyện, cùng lịch sử nhu cầu gần nhất. Thứ ba, cả bốn phương pháp chịu cùng ràng buộc rời rạc hóa: lượng đặt hàng mong muốn được làm tròn về mức gần nhất trong sáu mức của công thức (3.1).

Bảng 4.3 liệt kê tham số tối ưu tìm được.

Bảng 4.3: Tham số tối ưu của các chính sách đối chứng sau tìm kiếm lưới

Chính sách	Tham số tối ưu
EOQ	$q_{\text{factor}} = 2,0; L = 3,0$
(s, S)	$\alpha = 0,70; q_{\text{factor}} = 0,5; L = 3,0$
Newsvendor	$CR = 0,85; L = 3,0$

Một quan sát đáng chú ý: tỷ số tới hạn lý thuyết của mô hình Newsvendor với bộ tham số chi phí đang dùng là $c_{th}/(c_{th} + c_{lk}) = 10/11 \approx 0,909$, nhưng tìm kiếm lưới cho giá trị tối ưu là 0,85 — thấp hơn nhưng không lệch quá xa lý thuyết. Chênh lệch còn lại không phải lỗi cài đặt mà phản ánh một khác biệt khái niệm: tỷ số tới hạn cổ điển tối ưu cho *mức phục vụ chu kỳ* α trong bài toán một kỳ không có hàng đang về, trong khi môi trường ở đây là nhiều kỳ, có lượng hàng trên đường vận chuyển và ràng buộc sức chứa. Kết quả thực nghiệm này ủng hộ nhận định của Zipkin [15] rằng các chính sách cổ điển mất tính tối ưu đã được chứng minh trong bối cảnh mất đơn hàng.

4.3 Giao thức đánh giá

4.3.1 Quy trình đánh giá

Chính sách IPPO được đánh giá ở chế độ tắt định (chọn hành động có xác suất cao nhất), trên 30 episode độc lập với 30 hạt giống môi trường khác nhau, mỗi hạt

giống quy định một điểm khởi đầu, một chuỗi nhu cầu và một chuỗi thời gian giao hàng riêng trong miền đánh giá. Ba chính sách đối chứng được chạy trên đúng cùng 30 hạt giống đó, nên so sánh là so sánh theo cặp trên cùng một hiện thực ngẫu nhiên.

Theo khuyến nghị của Henderson và cộng sự [28] và Agarwal và cộng sự [29] về việc không nên suy luận từ một lần huấn luyện duy nhất, IPPO được huấn luyện lại độc lập trên 3 hạt giống ($\text{seed} \in \{42, 1, 2\}$), mỗi hạt giống 1.000 episode. Checkpoint tốt nhất của từng hạt giống được đánh giá riêng trên đúng 30 hạt giống môi trường nói trên; trừ khi có ghi chú khác, số liệu tổng hợp trong chương này là trung bình gộp trên $3 \times 30 = 90$ lần đánh giá. Khác biệt giữa IPPO và chính sách đối chứng tốt nhất được kiểm định bằng kiểm định t Welch (không giả định phương sai bằng nhau) và kiểm định thứ hạng có dấu Wilcoxon, kèm hệ số ảnh hưởng Cohen's d , tính riêng cho từng hạt giống; cả ba hạt giống đều cho cùng chiều kết luận (Mục 4.4.2), nên phương sai giữa các lần huấn luyện không phải là nguyên nhân của kết luận cuối cùng. Số episode mỗi hạt giống (1.000) là một đánh đổi có chủ ý để huấn luyện được cả 3 hạt giống trong thời gian hợp lý; hệ quả của lựa chọn này được bàn ở Mục 4.6.

4.3.2 Các chỉ số đánh giá


1. Tổng chi phí vận hành: tổng bốn nhóm chi phí thực phát sinh (lưu kho, thiếu hàng, đặt hàng, tràn kho) trên 365 ngày và 300 cặp. Thành phần phạt vi phạm mức phục vụ không được tính vào chỉ số này, vì nó là tín hiệu định hướng học chứ không phải chi phí kế toán.
2. Tỷ lệ đáp ứng nhu cầu (fill rate β): tỷ số giữa tổng lượng hàng bán được và tổng nhu cầu phát sinh trên cả episode.
3. Cơ cấu chi phí thành phần: dùng để nhận diện chiến lược mà mỗi phương pháp áp dụng.
4. Đường cong học: phần thưởng, fill rate, entropy của chính sách và explained variance của Critic qua các episode huấn luyện.

4.4 Kết quả thực nghiệm

4.4.1 Quá trình huấn luyện và tính hội tụ

Hình 4.1 trình bày bốn chỉ số theo dõi quá trình huấn luyện của hạt giống $\text{seed} = 42$, đại diện cho hình dạng đường cong học chung của cả 3 hạt giống (Mục 4.3.1).

Phần thưởng tăng từ $-16,99$ triệu ở episode đầu lên ổn định quanh $-1,69$ triệu



Hình 4.1: Diễn biến huấn luyện qua 1.000 episode (hạt giống 42): (a) phần thưởng tích lũy; (b) tỷ lệ đáp ứng nhu cầu; (c) entropy của chính sách; (d) explained variance của Critic

(trung bình 200 episode cuối, dao động trong khoảng $-1,76$ đến $-1,64$ triệu) sau khoảng 600 episode, tức giảm khoảng 90% tổng chi phí so với chính sách khởi tạo ngẫu nhiên. Sau điểm hội tụ, đường cong không sụp đổ — đặc tính mong đợi của cơ chế mục tiêu bị chặn (clipped objective) trong PPO.

Hai chỉ số còn lại xác nhận rằng cả hai nửa của thuật toán đều thực sự học. Entropy của chính sách giảm từ 1,778 — gần đúng giá trị $\ln 6 = 1,792$ của phân phối đều trên sáu hành động — xuống 0,182 ở episode cuối, nghĩa là chính sách đã định hình rõ rệt thay vì còn chọn ngẫu nhiên. Explained variance của Critic tăng nhanh từ khoảng 0 lên trên 0,7 trong 100 episode đầu, sau đó dao động trong khoảng 0,70–0,87 (trung bình 0,77 ở 200 episode cuối), nghĩa là hàm giá trị giải thích được phần lớn phương sai của phần thưởng tích lũy thực tế trong suốt phần còn lại của quá trình huấn luyện. Độ lệch KL xấp xỉ ở episode cuối là $2,4 \times 10^{-4}$, nằm sâu dưới ngưỡng 0,02, cho thấy chính sách đã ổn định chứ không còn dao động mạnh giữa các lần cập nhật.

Tỷ lệ đáp ứng vượt ngưỡng mục tiêu 85% ngay từ khoảng episode 66 và duy trì ổn định quanh 90% (trung bình 300 episode cuối) trong suốt phần còn lại. Hai hạt giống còn lại ($\text{seed} \in \{1, 2\}$) kết thúc huấn luyện với entropy trong khoảng 0,159–0,178 và explained variance trong khoảng 0,73–0,78 — cùng bậc độ lớn với hạt giống 42 — nên các kết luận trên không phụ thuộc vào một lần khởi tạo ngẫu nhiên cụ thể.

4.4.2 So sánh trực tiếp với các chính sách cổ điển

Bảng 4.4 trình bày kết quả gộp trên 3 hạt giống huấn luyện $\times$ 30 episode đánh giá (90 lần đánh giá cho IPPO); ba chính sách đối chứng là tất định nên không đổi theo hạt giống huấn luyện, kết quả của chúng là trung bình trên đúng 30 episode đánh giá.

Bảng 4.4: Kết quả trên miền đánh giá (trung bình $\pm$ độ lệch chuẩn; IPPO trên 90 lần đánh giá gộp 3 hạt giống, baseline trên 30 episode). Chi phí tính bằng đơn vị tiền của mô hình.

Phương pháp	Tổng chi phí	Fill rate	Lưu kho	Thiếu hàng	Đặt hàng	Tràn kho
IPPO	1.594.686 ± 21.370	90,53% $\pm 0,18\%$	1.108.082	325.438	125.934	35.232
(s, S)	1.520.337 ± 14.634	84,13% $\pm 0,27\%$	807.198	545.684	149.203	18.252
Newsvendor	1.545.816 ± 13.801	84,40% $\pm 0,26\%$	808.608	536.469	184.572	16.166
EOQ	1.779.966 ± 11.244	74,76% $\pm 0,20\%$	789.953	868.000	92.864	29.148


Ở phép so sánh trực tiếp này — không kiểm soát mức phục vụ — IPPO không

còn chiếm ưu thế Pareto như kết quả sơ bộ ở một hạt giống huấn luyện đơn lẻ từng cho thấy trước khi khóa luận kiểm chứng lại trên 3 hạt giống độc lập (Mục 4.3.1). So với chính sách đối chứng tốt nhất theo tiêu chí chi phí thuần túy là (s, S) , IPPO đắt hơn 4,89% trung bình gộp (4,55–5,50% tùy hạt giống), đắt hơn Newsvendor 3,16%, nhưng vẫn rẻ hơn EOQ 10,41%. Đổi lại, tỷ lệ đáp ứng của IPPO cao hơn (s, S) và Newsvendor khoảng 6 điểm phần trăm và cao hơn EOQ gần 16 điểm phần trăm. Nói cách khác, ở điểm vận hành mà mỗi phương pháp tự chọn (baseline tối thiểu chi phí, IPPO tối thiểu chi phí dưới ràng buộc mức phục vụ 85%), bốn phương pháp nằm ở bốn điểm khác nhau trên đường đánh đổi chi phí — mức phục vụ, và IPPO trả một khoản phụ phí chi phí vừa phải để đổi lấy mức phục vụ cao hơn đáng kể chứ không dominate baseline một cách vô điều kiện.

Kiểm định thống kê xác nhận khác biệt về chi phí không phải do ngẫu nhiên, theo đúng chiều mới này: gộp 90 lần đánh giá của IPPO so với (s, S) , kiểm định t Welch cho $t = 21,27$ với $p = 5,45 \times 10^{-33}$; hệ số ảnh hưởng Cohen's $d = 4,06$, thuộc mức rất lớn theo phân loại thông dụng. Tính riêng theo từng hạt giống, cả ba lần huấn luyện độc lập đều cho $p < 10^{-18}$ và cùng chiều IPPO đắt hơn (s, S) (seed 42: +4,55%; seed 1: +4,63%; seed 2: +5,50%), nên kết luận này không phải hiện tượng ngẫu nhiên của một lần huấn luyện. Vì đây là phép so sánh chưa kiểm soát mức phục vụ, phép so sánh chặt chẽ hơn ở Mục 4.4.4 mới là căn cứ để trả lời Câu hỏi nghiên cứu 1.

4.4.3 Phân tích cơ cấu chi phí

Hình 4.2 và cơ cấu chi phí trong Bảng 4.4 cho thấy IPPO học được một chiến lược khác về chất so với ba chính sách cổ điển.



Hình 4.2: So sánh bốn phương pháp trên miền đánh giá: (a) tổng chi phí vận hành; (b) tỷ lệ đáp ứng nhu cầu; (c) cơ cấu chi phí thành phần

IPPO giữ mức tồn kho cao hơn hẳn — chi phí lưu kho 1.108.082 so với 807.198 của (s, S) , tức cao hơn 37,3% — và dùng mức tồn kho đó để cắt giảm chi phí thiếu

hàng, từ 545.684 xuống 325.438, tức giảm 40,4%. Khác với kết quả sơ bộ ở một hạt giống huấn luyện, phần tăng thêm ở lưu kho lần này lớn hơn phần tiết kiệm được ở thiếu hàng về giá trị tuyệt đối, nên tổng chi phí của IPPO cao hơn (s, S) ở điểm vận hành mà mỗi phương pháp tự chọn. Nói cách khác, tác tử đã đẩy chiến lược “tích trữ nhiều hơn để giảm thiếu hàng” đi xa hơn mức tối ưu về chi phí thuần túy, đúng như thiết kế của thành phần phạt mức phục vụ (Mục 3.2.2): tác tử được thưởng vì mức phục vụ cao chứ không phải vì chi phí thấp nhất tuyệt đối.

Chiến lược này vẫn khả thi vì tác tử biết được giới hạn của mình. Chi phí trần kho của IPPO là 35.232, tức khoảng 2,2% tổng chi phí — cao hơn các chính sách cổ điển nhưng không bùng nổ dù mức tồn kho trung bình đã tăng đáng kể. Điều này cho thấy tác tử vẫn đẩy mức tồn kho lên sát trần sức chứa mà không vượt qua một cách mất kiểm soát, tức vẫn sử dụng được tín hiệu $u_t^{(w(i))}$ trong vector quan sát dù chiến lược tổng thể đã thay đổi so với kết quả sơ bộ. Đây là bằng chứng cho hiệu lực của cơ chế phối hợp gián tiếp mô tả ở Mục 3.1.4, độc lập với việc chiến lược đó có tối ưu về chi phí tuyệt đối hay không.

Về tần suất đặt hàng, IPPO phát trung bình 25.187 đơn trên một episode, ít hơn (s, S) (29.841 đơn) và ít hơn đáng kể Newsvendor (36.914 đơn), trong khi vẫn đạt mức phục vụ cao hơn cả hai — duy chỉ EOQ phát ít đơn hơn (18.573) nhưng đổi lại có mức phục vụ thấp nhất. Như vậy, mức phục vụ cao hơn của IPPO không đến từ việc đặt hàng thường xuyên hơn, mà đến từ việc giữ mức tồn kho đệm cao hơn cho mỗi lần đặt; đây chính là nguồn gốc của khoản chi phí lưu kho tăng thêm nói trên.

4.4.4 So sánh ở cùng mức phục vụ

So sánh tổng chi phí giữa hai chính sách có mức phục vụ khác nhau là một phép so sánh không đầy đủ — đây chính xác là hạn chế của phép so sánh trực tiếp ở Mục 4.4.2. IPPO chịu hình phạt khi fill rate xuống dưới ngưỡng τ nên tự đẩy mức phục vụ lên 90,57% (hạt giống 42, dùng làm đại diện cho phân tích này), trong khi ba chính sách đối chứng được tìm kiếm lưới với mục tiêu tối thiểu chi phí nên dừng lại ở 75–84%. Bốn phương pháp vì vậy nằm ở bốn điểm khác nhau trên đường đánh đổi chi phí — mức phục vụ, và bảng so sánh trực tiếp không kiểm soát yếu tố này nên chưa đủ căn cứ để kết luận phương pháp nào ưu việt hơn.

Để loại bỏ yếu tố này, khóa luận thực hiện thêm một so sánh ở cùng mức phục vụ: với mỗi chính sách đối chứng, tìm kiếm lưới trên miền huấn luyện được lặp lại với ràng buộc fill rate $\geq 90,07\%$ (bằng mức của IPPO trừ sai số cho phép 0,5 điểm phần trăm), chọn cấu hình rẻ nhất trong số các cấu hình thỏa mãn, rồi đánh giá lại trên miền

đánh giá.

Bảng 4.5: So sánh ở cùng mức phục vụ: cấu hình rẻ nhất của mỗi chính sách đối chứng đạt fill rate $\geq 90,07\%$ (hạt giống 42)

Phương pháp	Tổng chi phí	Fill rate	So với IPPO	Cấu hình
IPPO	1.589.472	90,57%	—	—
(s, S)	1.770.256	89,95%	-10,2%	$\alpha = 0,95; q_f = 0,5; L = 3,0$
Newsvendor	1.856.657	90,57%	-14,4%	$CR = 0,99; L = 3,0$
EOQ	không cấu hình nào đạt được mức phục vụ này			

Kết quả ở Bảng 4.5 đảo ngược hoàn toàn kết luận của phép so sánh trực tiếp. Khi buộc phải đạt cùng mức phục vụ khoảng 90%, chi phí của (s, S) tăng vọt từ 1,52 triệu (Bảng 4.4) lên 1,77 triệu, và của Newsvendor tăng từ 1,55 lên 1,86 triệu; trong khi đó IPPO không cần thay đổi gì vì mức phục vụ 90,57% vốn là điểm vận hành nó tự chọn. Ở cùng mức phục vụ, IPPO trở thành phương án rẻ nhất: rẻ hơn (s, S) 10,2% và rẻ hơn Newsvendor 14,4%. Riêng EOQ không có cấu hình nào trong lưới tìm kiếm đạt được mức phục vụ 90,07% — do cấu trúc lượng đặt hàng cố định không cho phép phản ứng với biến động nhu cầu. Như vậy, kết luận về việc phương pháp nào “tốt hơn” phụ thuộc căn bản vào việc có kiểm soát mức phục vụ hay không: xét thuần chi phí tại điểm vận hành mặc định của mỗi phương pháp (Mục 4.4.2), IPPO đắt hơn (s, S) ; xét ở cùng mức phục vụ, IPPO rẻ hơn đáng kể. Khóa luận coi phép so sánh ở cùng mức phục vụ là căn cứ phù hợp hơn để trả lời Câu hỏi nghiên cứu 1, vì nó loại bỏ được sai lệch do các phương pháp tối ưu cho hai mục tiêu khác nhau (Mục 1.3.2).


Hình 4.3 biểu diễn trực quan cả hai phép so sánh trên cùng một mặt phẳng chi phí — mức phục vụ.

Nguyên nhân của khoảng cách này nằm ở cơ chế điều chỉnh của các chính sách cổ điển. Chúng chỉ có một cơ chế duy nhất để nâng mức phục vụ: nâng tham số an toàn — tăng α hoặc CR — và tham số đó áp dụng đồng loạt cho cả 300 cặp. Hệ quả là tồn kho tăng ở mọi mặt hàng, kể cả những mặt hàng vốn đã đạt mức phục vụ tốt. IPPO điều chỉnh theo từng trạng thái quan sát được, do đó có thể nâng mức phục vụ ở những cặp có nhu cầu cấp thiết mà không tích trữ thừa ở những cặp không cần.

4.5 Phân tích chuyên sâu

4.5.1 Khả năng tổng quát hóa qua chia sẻ tham số (Câu hỏi 2)

Một bộ trọng số duy nhất điều khiển đồng thời 300 cặp có quy mô nhu cầu trải từ dưới 0,1 đến gần 143 đơn vị mỗi ngày. Tỷ lệ đáp ứng 90,5% ở cấp hệ thống là một



Hình 4.3: Đường đánh đổi chi phí — mức phục vụ. Dấu chữ thập xám: cấu hình tối thiểu chi phí; dấu tròn: cấu hình ở cùng mức phục vụ với IPPO

con số có trọng số theo nhu cầu, nên nó chưa cho biết chính sách có hoạt động đồng đều trên mọi nhóm quy mô hay không. Để trả lời, 300 cặp được chia thành bốn nhóm theo $\bar{D}^{(i)}$ và các chỉ số được tính riêng cho từng nhóm (Bảng 4.6, hạt giống 42). Chi phí trong bảng là chi phí cục bộ trung bình mỗi cặp mỗi episode — cùng đại lượng mà tác tử thực sự tối ưu hóa, công thức (3.4) — nên bao gồm cả thành phần định hướng mức phục vụ ϕ_{dv} , khác với chi phí vận hành thuần túy đã báo cáo ở Bảng 4.4.

Bảng 4.6: Hiệu năng theo nhóm quy mô nhu cầu trên miền đánh giá (hạt giống 42). Chi phí cục bộ (gồm thành phần định hướng mức phục vụ) tính trung bình cho mỗi cặp trong một episode.

Nhóm ($\bar{D}$, đv/ngày)	Số cặp	Fill rate		Chi phí/cặp	
		IPPO	(s, S)	IPPO	(s, S)
Rất thấp ($< 0,5$)	105	70,5%	82,2%	2.020	1.964
Thấp (0,5–2)	126	81,0%	84,7%	3.114	3.005
Trung bình (2–10)	54	90,2%	83,6%	7.125	8.102
Cao (≥ 10)	15	96,8%	84,4%	47.312	57.710

Kết quả cho thấy sự phân hóa còn rõ rệt hơn so với kết quả sơ bộ ở một hạt giống huấn luyện, được phân tích chi tiết dưới đây.

Trên hai nhóm có nhu cầu từ 2 đơn vị mỗi ngày trở lên, IPPO vượt trội rõ rệt so với (s, S) trên *cả hai* tiêu chí: fill rate cao hơn 6,6 điểm phần trăm ở nhóm trung

bình và 12,4 điểm ở nhóm cao, đồng thời rẻ hơn 12,1% ở nhóm trung bình và 18,0% ở nhóm cao. Đây chính là nơi tạo ra phần lớn lợi thế chi phí của IPPO ở phép so sánh cùng mức phục vụ (Mục 4.4.4), vì các cặp có nhu cầu lớn đóng góp phần lớn tổng chi phí hệ thống.

Ngược lại, ở hai nhóm nhu cầu thấp và rất thấp, IPPO vừa đạt mức phục vụ thấp hơn (s, S) (rất thấp: 70,5% so với 82,2%, chênh 11,7 điểm; thấp: 81,0% so với 84,7%) vừa có chi phí cục bộ nhỉnh hơn một chút (2,8% và 3,6%). Đây là sự phân hóa rõ hơn so với kết quả sơ bộ trước đó, trong đó IPPO chỉ thua kém về fill rate nhưng vẫn nhỉnh hơn về chi phí ở nhóm thấp nhất.

Diễn giải của hiện tượng này mang tính kinh tế nhiều hơn là kỹ thuật. Với một mặt hàng bán 0,3 đơn vị mỗi ngày, chi phí một lần phát đơn ($c_{dh} = 5$) xấp xỉ chi phí thiếu hàng của gần hai ngày bán ($c_{th} \cdot \bar{D} = 3$ mỗi ngày). Việc duy trì mức phục vụ cao cho nhóm này đòi hỏi đặt hàng thường xuyên với lô rất nhỏ, và tổng chi phí phát sinh vượt phần tổn thất do thiếu hàng. Tác tử — vốn tối thiểu hóa chi phí — có xu hướng hạ mức phục vụ ở nhóm bán chậm, điều này phù hợp với mục tiêu tối ưu hóa chi phí mà thuật toán huấn luyện theo đuổi. Nói cách khác, chênh lệch không phải là dấu hiệu chia sẻ tham số thất bại ở nhóm bán chậm, mà là hệ quả của việc hai phương pháp theo đuổi hai mục tiêu khác nhau: (s, S) được tham số hóa quanh một mức phục vụ mục tiêu, còn IPPO tối thiểu hóa chi phí dưới ràng buộc mức phục vụ ở cấp hệ thống.

Hệ quả cần ghi nhận là thành phần phạt mức phục vụ hiện được tính trên trung bình toàn hệ thống, nên tác tử có thể bù trừ: nâng mức phục vụ ở nhóm bán nhanh — nơi đóng góp phần lớn khối lượng — để đổi lấy việc hạ mức phục vụ ở nhóm bán chậm. Nếu bài toán nghiệp vụ yêu cầu bảo đảm mức phục vụ tối thiểu cho từng mặt hàng, hàm phần thưởng cần được điều chỉnh để ràng buộc áp ở cấp cặp thay vì cấp hệ thống. Đây là một hạn chế thiết kế đã xác định, không phải lỗi cài đặt.

Cuối cùng, cần nói rõ phạm vi của kết luận này. Phân tích trên chứng minh chính sách chia sẻ tham số thích ứng được với các quy mô nhu cầu khác nhau đã gặp trong huấn luyện. Câu hỏi mạnh hơn — liệu chính sách có áp dụng được cho những mặt hàng chưa từng xuất hiện trong huấn luyện hay không — đòi hỏi một thí nghiệm tách tập mặt hàng riêng, hiện chưa được thực hiện.

4.5.2 Ảnh hưởng của chuẩn hóa phần thưởng theo từng cặp (Câu hỏi 3)

4.5.3 Vai trò của việc tách Actor và Critic

4.5.4 Các kịch bản IPPO chưa vượt trội

4.6 Hạn chế của thực nghiệm

Ba hạn chế cần được ghi nhận khi diễn giải các kết quả trên.

Thứ nhất, số episode huấn luyện mỗi hạt giống. Để huấn luyện được cả 3 hạt giống độc lập (Mục 4.3.1) trong thời gian hợp lý, mỗi hạt giống chỉ chạy 1.000 episode thay vì một cấu hình dài hơn. Đường cong học (Mục 4.4.1) cho thấy phần thưởng, entropy và explained variance đều đã ổn định từ khoảng episode 600–800 nên 1.000 episode nhiều khả năng đủ để hội tụ, nhưng chưa loại trừ hoàn toàn khả năng huấn luyện dài hơn tiếp tục cải thiện nhẹ chiến lược, đặc biệt ở phần đánh đổi giữa lưu kho và thiếu hàng vốn quyết định vị trí của IPPO trên đường đánh đổi chi phí — mức phục vụ (Mục 4.4.2). Điểm tích cực là việc lặp lại độc lập trên 3 hạt giống cho kết luận nhất quán (chênh lệch với (s, S) dao động trong khoảng hẹp 4,55–5,50%), nên phương sai giữa các lần khởi tạo ngẫu nhiên không phải là mối lo chính ở quy mô huấn luyện hiện tại.

Thứ hai, phạm vi của bộ tham số chi phí. Mọi kết luận gắn với một bộ tham số chi phí cụ thể. Tỷ số $c_{th}/c_{lk} = 10$ định hình mạnh chiến lược tối ưu; một tỷ số khác có thể dẫn tới thứ hạng khác giữa các phương pháp.

Thứ ba, tính đại diện của tập mặt hàng. 30 mặt hàng được chọn theo phân tầng để trải rộng dải quy mô nhu cầu, nhưng vẫn là một tập con nhỏ của 3.049 mặt hàng trong bộ dữ liệu gốc.

4.7 Thảo luận

Kết quả cho phép trả lời Câu hỏi nghiên cứu 1, nhưng câu trả lời cần được phát biểu cẩn trọng hơn một khẳng định đơn giản. Ở điểm vận hành mà mỗi phương pháp tự chọn (Mục 4.4.2), IPPO không rẻ hơn các chính sách cổ điển — ngược lại, đắt hơn (s, S) 4,89% và Newsvendor 3,16%, tuy vẫn rẻ hơn EOQ 10,41% — vì tác tử tự đẩy mức phục vụ lên cao hơn hẳn (90,5% so với 75–84%) theo đúng thiết kế của thành phần phạt SLA. Khi loại bỏ yếu tố này bằng phép so sánh ở cùng mức phục vụ (Mục 4.4.4) — phép so sánh chặt chẽ hơn về phương pháp luận — kết luận đảo chiều: IPPO rẻ hơn 10,2% so với (s, S) và 14,4% so với Newsvendor, còn EOQ không có cấu hình nào đạt được mức phục vụ tương đương. Khóa luận coi phép so sánh sau là căn

cứ chính đáng để trả lời Câu hỏi 1, vì nó loại bỏ được sai lệch do các phương pháp theo đuổi hai mục tiêu khác nhau; theo căn cứ đó, IPPO học được chính sách vừa rẻ hơn vừa duy trì mức phục vụ cao hơn đáng kể so với ba chính sách cổ điển. Tuy nhiên, khác với một kết quả sơ bộ ở một hạt giống huấn luyện duy nhất mà khóa luận từng có, kết quả đã kiểm chứng lại trên 3 hạt giống cho thấy ưu thế này *không* còn mang tính Pareto tuyệt đối khi không kiểm soát mức phục vụ — một phát hiện quan trọng về giới hạn của việc so sánh trực tiếp giữa các phương pháp tối ưu cho hai mục tiêu khác nhau, và là lý do phép so sánh ở cùng mức phục vụ cần được xem là bắt buộc chứ không phải một phân tích bổ sung tùy chọn.

Hai nhận xét bổ sung đáng ghi nhận.

Về vai trò của ràng buộc sức chứa, thí nghiệm hiệu chỉnh κ ở Mục 4.1.3 cho thấy khi sức chứa đủ rộng thì bài toán suy biến thành 300 bài toán độc lập. Nói cách khác, chính ràng buộc sức chứa dùng chung — chứ không phải số lượng tác tử — mới là thứ tạo nên bản chất đa tác tử của bài toán. Đây là yếu tố mà hai công trình gần nhất cùng bối cảnh đều không mô hình hóa: Zhu và Wu [22] giả định nguồn cung không giới hạn, còn Jeong và cộng sự [23] chỉ xét một kho duy nhất.

Về hiệu quả tính toán, việc đạt kết quả trên sau khoảng 40 phút huấn luyện mỗi hạt giống trên CPU cho thấy không nhất thiết phải ghép một mô-đun dự báo học sâu vào trước khâu ra quyết định. Tác tử học trực tiếp từ lịch sử nhu cầu thô đã đủ để vượt các chính sách cổ điển, đồng thời tránh được sự phụ thuộc vào chất lượng của một bộ dự báo riêng biệt — hạn chế mà chính Zhu và Wu [22] nêu ra trong phần thảo luận của họ. Kết quả này cũng phù hợp với nhận định của Gijsbrechts và cộng sự [17] rằng học tăng cường sâu có thể cạnh tranh với các chính sách được hiệu chỉnh kỹ trong lớp bài toán mất đơn hàng.

CHƯƠNG 5. KẾT LUẬN VÀ HƯỚNG PHÁT TRIỂN

5.1 Tổng kết các kết quả đạt được

Khóa luận đã hoàn thành bốn mục tiêu nghiên cứu đề ra:

1. Xây dựng môi trường mô phỏng: phát triển thành công `MultiWarehouseInventoryEnv` theo chuẩn Gymnasium [24], mô hình hóa đầy đủ hệ thống 10 kho, 30 mặt hàng (300 cặp tác tử), với nhu cầu ngẫu nhiên, thời gian giao hàng biến động [1, 3] ngày, ràng buộc sức chứa dùng chung tính riêng cho từng kho theo quy mô nhu cầu của kho đó, và năm nhóm chi phí vận hành. Tham số nhu cầu được hiệu chỉnh từ bộ dữ liệu M5 Walmart [2].
2. Thiết kế hàm phần thưởng: đề xuất hàm phần thưởng phân rã cục bộ (dựa trên nguyên lý phần thưởng chênh lệch [25]) kèm thành phần phạt fill rate ràng buộc theo tinh thần Lagrangian trên cửa sổ trượt 30 ngày.
3. Cài đặt và huấn luyện IPPO: triển khai thuật toán Independent Multi-Agent PPO [20] với cơ chế chia sẻ tham số [18], sử dụng GAE [27] và chuẩn hóa lợi thế theo từng cặp. Mô hình hội tụ ổn định trên quy mô 300 tác tử sau khoảng 600–800 episode, với entropy giảm từ 1,778 xuống 0,18 và explained variance của Critic duy trì quanh 0,75–0,80, nhất quán trên cả 3 hạt giống huấn luyện độc lập đã kiểm chứng.
4. Đánh giá đối chứng: so sánh IPPO với ba chính sách cổ điển (EOQ, (s, S) , Newsvendor) trên 30 episode đánh giá dùng chung hạt giống, lặp lại trên 3 hạt giống huấn luyện độc lập, có kiểm định thống kê [28], [29], và bổ sung phép so sánh ở cùng mức phục vụ nhằm loại bỏ sai lệch do các phương pháp nằm ở những điểm khác nhau trên đường đánh đổi.

5.1.1 Trả lời các câu hỏi nghiên cứu

Câu hỏi 1 (IPPO so với các chính sách cổ điển). Câu trả lời là khẳng định, nhưng chỉ khi mức phục vụ được kiểm soát. Ở điểm vận hành mà mỗi phương pháp tự chọn, IPPO **không** rẻ hơn các chính sách cổ điển: gộp trên 3 hạt giống huấn luyện $\times$ 30 episode đánh giá, IPPO đắt hơn (s, S) 4,89% và Newsvendor 3,16% (dù vẫn rẻ hơn EOQ 10,41%), khác biệt có ý nghĩa thống kê rất cao ($p = 5,45 \times 10^{-33}$ với kiểm định t Welch; Cohen's $d = 4,06$) và nhất quán trên cả 3 hạt giống độc lập. Nguyên nhân

là IPPO tự đẩy mức phục vụ lên 90,5% — cao hơn hẳn 75–84% của ba chính sách cổ điển — nên đây không phải là ưu thế Pareto mà là một điểm khác trên đường đánh đổi chi phí–mức phục vụ.

Khi so sánh ở cùng mức phục vụ ($\approx 90\%$) — phép so sánh chặt chẽ hơn về mặt phương pháp luận vì loại bỏ được sai lệch do hai mục tiêu tối ưu khác nhau — kết luận đảo chiều: IPPO rẻ hơn (s, S) 10,2% và rẻ hơn Newsvendor 14,4%, trong khi EOQ không có cấu hình nào đạt được mức phục vụ đó do cấu trúc lượng đặt hàng cố định. Nguyên nhân là các chính sách cổ điển chỉ có thể nâng mức phục vụ bằng cách tăng tham số an toàn áp dụng đồng loạt cho cả 300 cặp — khiến chi phí tăng vọt ở cả những mặt hàng vốn đã đạt mức phục vụ tốt — còn IPPO điều chỉnh theo từng trạng thái quan sát được. Khóa luận coi phép so sánh ở cùng mức phục vụ là căn cứ chính đáng để trả lời Câu hỏi 1, và ghi nhận rõ ràng rằng phép so sánh trực tiếp không kiểm soát mức phục vụ có thể dẫn tới kết luận ngược lại.

Câu hỏi 2 (tổng quát hóa qua chia sẻ tham số). Bằng chứng hiện có mới chỉ là gián tiếp. Việc một bộ trọng số duy nhất điều khiển đồng thời 300 cặp trải trên dải nhu cầu từ dưới 0,1 đến 143 đơn vị mỗi ngày, mà vẫn đạt mức phục vụ 90,5% trên toàn hệ thống, cho thấy mạng dùng chung phân biệt được các mặt hàng theo quy mô — nhiều khả năng thông qua đặc trưng quy mô $\log(1 + \bar{D}^{(i)})$ trong vector quan sát và bảng mức đặt hàng tương đối. Tuy nhiên, kết luận đầy đủ đòi hỏi hai phân tích chưa hoàn tất: phân tách kết quả theo nhóm quy mô nhu cầu, và thí nghiệm giữ lại một tập mặt hàng chưa từng xuất hiện trong huấn luyện (Mục 4.5.1).

Câu hỏi 3 (ảnh hưởng của cách phân rã phần thưởng). Chưa có câu trả lời định lượng. Khóa luận đã chuẩn bị sẵn cơ chế khảo sát loại trừ thông qua cờ cấu hình `normalize_reward_per_pair`, cho phép huấn luyện lại với cùng hạt giống và so sánh trực tiếp đường cong học (Mục 4.5.2). Về mặt lập luận thiết kế, phần thưởng thô của các cặp chênh lệch bốn bậc độ lớn nên một Critic dùng chung khó khớp được các mục tiêu trải rộng như vậy — nhưng đây là giả thuyết cần kiểm chứng bằng thực nghiệm, không phải kết luận.

5.2 Những hạn chế còn tồn tại

- Cấu trúc mạng lưới đơn giản: các kho hoạt động song song và độc lập về nguồn cung; chưa xét cấu trúc đa cấp (multi-echelon) với quan hệ cung ứng giữa các kho [30] và hiệu ứng bullwhip [31].
- Không có cơ chế phối hợp tường minh: các tác tử ra quyết định hoàn toàn

dựa trên quan sát cục bộ, phối hợp chỉ diễn ra gián tiếp qua tín hiệu sức chứa kho. Khóa luận chưa định lượng được phần giá trị mà một critic tập trung theo hướng CTDE [21] có thể mang lại — đặc biệt đáng lưu ý vì Zhu và Wu [22] báo cáo mức suy giảm đáng kể khi loại bỏ cơ chế phối hợp trong khung của họ.

- Số episode mỗi hạt giống huấn luyện: kết quả đã được kiểm chứng lại trên 3 hạt giống độc lập theo khuyến nghị của Henderson và cộng sự [28], và cho kết luận nhất quán. Tuy nhiên, mỗi hạt giống chỉ chạy 1.000 episode (thay vì một cấu hình dài hơn) để giữ thời gian huấn luyện cả 3 hạt giống trong phạm vi hợp lý; chưa loại trừ hoàn toàn khả năng huấn luyện dài hơn làm dịch chuyển thêm điểm vận hành của IPPO trên đường đánh đổi chi phí–mức phục vụ.
- Chưa có thực nghiệm phân tách theo mức độ biến động của nhu cầu: toàn bộ đánh giá được thực hiện trên các episode 365 ngày, chưa tách riêng các giai đoạn nhu cầu ổn định và giai đoạn biến động mạnh (dịp lễ, ngày SNAP) — vốn là nơi khả năng thích nghi của học tăng cường được kỳ vọng thể hiện rõ nhất.
- Không gian hành động rời rạc thô: chỉ có $K = 6$ mức đặt hàng; trong thực tế, doanh nghiệp có thể cần quyết định lượng đặt chính xác hơn.
- Chưa tích hợp dự báo nhu cầu: tác tử sử dụng trực tiếp nhu cầu lịch sử thay vì dự báo bằng mô hình học sâu chuỗi thời gian.
- Thực nghiệm trên môi trường mô phỏng: chưa được kiểm chứng trên hệ thống ERP thực tế hoặc dữ liệu vận hành trực tiếp.

5.3 Hướng phát triển trong tương lai

- Mở rộng sang cấu trúc đa cấp (multi-echelon): mô hình hóa quan hệ cung ứng giữa kho trung tâm và kho khu vực, cho phép tác tử học chiến lược điều phối liên kho.
- So sánh với kiến trúc huấn luyện tập trung — thực thi phi tập trung: bổ sung một nhánh MAPPO [21] trong đó Critic nhận thêm trạng thái ở cấp kho, nhằm đo lường trực tiếp giá trị của phối hợp tường minh so với phối hợp gián tiếp qua tín hiệu sức chứa. Đây là hướng mở rộng trực tiếp nhất về mặt cài đặt, vì kiến trúc hiện tại đã tách riêng mạng Actor và Critic; kết quả sẽ cho phép định lượng rõ giá trị của phối hợp tường minh trong cấu

hình nghiên cứu này.

- Tích hợp cơ chế truyền thông giữa tác tử: áp dụng các phương pháp như CommNet hoặc TarMAC để cho phép tác tử chia sẻ thông tin, đặc biệt về tình trạng sức chứa kho.
- Không gian hành động liên tục: sử dụng PPO cho hành động liên tục hoặc mạng hành động phân cấp (hierarchical action) để quyết định lượng đặt hàng chính xác.
- Gán công theo độ trễ giao hàng: chi phí phát sinh ở ngày t phần lớn là hệ quả của quyết định đặt hàng ở ngày $t - L$. Hiện việc gán công này được phó thác cho GAE với $\gamma = 0,99$; một cơ chế liên kết phần thưởng trực tiếp với hành động sinh ra nó, theo hướng của Jeong và cộng sự [23], có thể làm tín hiệu học sắc nét hơn.
- Tích hợp dự báo nhu cầu: nhúng mô hình dự báo chuỗi thời gian (LSTM, Transformer) vào vector quan sát của tác tử, tận dụng thông tin xu hướng và mùa vụ. Cần lưu ý rằng kết quả hiện tại cho thấy phương án không dùng dự báo đã đủ vượt các chính sách cổ điển với chi phí tính toán thấp hơn nhiều bậc, nên hướng này cần được đánh giá trên tương quan lợi ích — chi phí chứ không mặc nhiên là một cải tiến.
- Triển khai thử nghiệm thực tế: xây dựng hệ thống dạng SaaS kết nối API với nền tảng quản lý kho, cho phép đánh giá mô hình trên dữ liệu vận hành trực tiếp.
- Mở rộng quy mô: thử nghiệm với toàn bộ 3.049 SKU gốc của M5 và đánh giá khả năng mở rộng của cơ chế chia sẻ tham số.
- Tích hợp lớp điều phối ngôn ngữ (MCP). Model Context Protocol (MCP) là giao thức chuẩn hóa cho phép các mô hình ngôn ngữ lớn (LLM) gọi công cụ bên ngoài thông qua giao thức máy chủ–máy khách. Hệ thống IPPO hiện tại và kiến trúc MCP có thể so sánh theo bốn khía cạnh:
Hai kiến trúc phục vụ hai lớp bài toán khác nhau. IPPO phù hợp khi hành động là số lượng đặt hàng và tín hiệu phản hồi là chi phí — đây là miền của học tăng cường. MCP phù hợp khi hệ thống cần giao tiếp ngôn ngữ với người dùng, gọi nhiều công cụ đa dạng và tích hợp tri thức bên ngoài. Nếu mở rộng hệ thống thành trợ lý vận hành kho có giao tiếp ngôn ngữ tự nhiên, MCP là lớp điều phối khả dĩ để kết nối LLM với engine IPPO, nhưng nằm ngoài phạm vi khóa luận này.

Bảng 5.1: So sánh kiến trúc IPPO và MCP theo các chiều điều phối

Khía cạnh	IPPO (đề tài này)	Kiến trúc MCP
Phân công nhiệm vụ	Không có: mỗi tác tử có task cố định (một cặp kho–SKU)	Host/LLM phân công tường minh cho từng server
Chọn hành động	Mạng chính sách $\pi_{\theta}(a o)$ ánh xạ quan sát sang hành động	LLM suy luận và chọn tool phù hợp
Lấy ngữ cảnh	Vector quan sát 43 chiều từ môi trường	Server cung cấp context qua giao thức chuẩn
Kết quả trả về	Phần thưởng và trạng thái kế tiếp từ môi trường	Tool result trả về LLM để tiếp tục suy luận

PHỤ LỤC A. ĐỐI CHIẾU LUẬN ĐIỂM VÀ NGUỒN TRÍCH DẪN

Phụ lục này liệt kê từng luận điểm lý thuyết được sử dụng trong khóa luận kèm nguồn gốc học thuật tương ứng, nhằm bảo đảm mọi khẳng định đều truy nguyên được về tài liệu công bố chính thống.

Mục	Luận điểm	Nguồn
<i>A.1. Lý thuyết tồn kho</i>		
1.1.1	Quản lý tồn kho đa điểm, đa mặt hàng trong chuỗi cung ứng bán lẻ	Silver and others [1]; Zipkin [8]
1.1.1	Mô tả bộ dữ liệu M5: quy mô, cấu trúc phân cấp, giai đoạn thu thập	Makridakis and others [2]; Howard and others [3]
1.1.1	Tiêu chí phân loại dạng nhu cầu (ngưỡng $p = 1,32$; $CV^2 = 0,49$)	Syntetos and others [4]
1.1.1	Nhu cầu gián đoạn và hạn chế của phương pháp dự báo thông thường	Croston [6]; Syntetos and Boylan [7]
1.1.2	Bất định của nhu cầu và thời gian giao hàng; hiện tượng vượt đơn	Zipkin [8]; Silver and others [1]
1.1.2	Cấu trúc chi phí tồn kho và bài toán đánh đổi	Zipkin [8]
1.1.3	Mô hình lượng đặt hàng kinh tế (EOQ)	Harris [12]
1.1.3	Tính tối ưu của chính sách (s, S) và các điều kiện kèm theo	Scarf [13]
1.1.3	Mô hình người bán báo (Newsvendor) một chu kỳ	Arrow and others [14]
1.1.3	Bài toán mất đơn hàng không có nghiệm giải tích dạng đóng	Zipkin [15]
1.3.3	Cấu trúc tồn kho đa cấp (nằm ngoài phạm vi)	Clark and Scarf [30]
1.3.3	Hiệu ứng bullwhip (nằm ngoài phạm vi)	Lee and others [31]

Mục	Luận điểm	Nguồn
-----	-----------	-------

A.2. Học tăng cường

2.3.1	Quá trình quyết định Markov và quy hoạch động ngẫu nhiên	Puterman [32]
2.3.1	Hàm giá trị, phương trình Bellman, hàm lợi thế, định lý policy gradient	Sutton and Barto [10]
2.3.3	Ước lượng lợi thế tổng quát (GAE) và đánh đổi bias–variance	Schulman and others [27]
2.3.4	Vùng tin cậy trong tối ưu hóa chính sách	Schulman and others [34]
2.3.4	Hàm mục tiêu cắt của PPO	Schulman and others [26]
2.5.4	Điều kiện bảo toàn chính sách tối ưu khi định hình phần thưởng	Ng and others [36]

A.3. Học tăng cường đa tác tử

1.1.2	Độ phức tạp NEXP-đầy đủ của điều khiển phi tập trung	Bernstein and others [11]
2.4.1	Mô hình Dec-POMDP	Oliehoek and Amato [9]
2.4.2	Học độc lập và vấn đề môi trường không dừng	Tan [19]
2.4.3	Thuật toán IPPO	Schröder de Witt and others [20]
2.4.3	MAPPO và khung huấn luyện tập trung, thực thi phân tán	Yu and others [21]
2.4.4	Chia sẻ tham số giữa các tác tử đồng nhất	Gupta and others [18]
2.4.5	Phần thưởng chênh lệch và bài toán gán tín dụng đa tác tử	Wolpert and Tumer [25]

A.4. Ứng dụng, môi trường và giao thức đánh giá

2.8	Học tăng cường sâu cho trò chơi phân phối bia	Oroojlooyjadid and others [16]
2.8	Đánh giá học tăng cường sâu trên các lớp bài toán tồn kho	Gijsbrechts and others [17]
3.2	Chuẩn giao diện môi trường học tăng cường	Brockman and others [33]; Towers and others [24]

Mục	Luận điểm	Nguồn
2.7	Yêu cầu đa hạt giống và tính tái lập trong đánh giá	Henderson and others [28]
2.7	Phương pháp báo cáo kết quả có kiểm định thống kê	Agarwal and others [29]

Ghi chú. Các số liệu thống kê mô tả bộ dữ liệu M5 trình bày trong Mục 1.1.1 và Bảng 1.1 do nhóm tác giả tự tính toán từ hai tệp `sales_train_evaluation.csv` và `calendar.csv`; mã nguồn tính toán được đính kèm trong kho mã của khóa luận.

TÀI LIỆU THAM KHẢO

E. A. Silver, D. F. Pyke **and** D. J. Thomas, *Inventory and Production Management in Supply Chains*, 4 **edition**. Boca Raton, FL: CRC Press, 2016.

S. Makridakis, E. Spiliotis **and** V. Assimakopoulos, “The M5 competition: Background, organization, and implementation,” *International Journal of Forecasting*, **jourvol** 38, **number** 4, **pages** 1325–1336, 2022. DOI: 10.1016/j.ijforecast.2021.07.007

A. Howard, N. Vandeput, Makridakis, Spyros, Assimakopoulos, Vassilios **and** inversion, *M5 Forecasting – Accuracy*, Kaggle competition, 2020. **url**: <https://www.kaggle.com/competitions/m5-forecasting-accuracy>

A. A. Syntetos, J. E. Boylan **and** J. D. Croston, “On the categorization of demand patterns,” *Journal of the Operational Research Society*, **jourvol** 56, **number** 5, **pages** 495–503, 2005. DOI: 10.1057/palgrave.jors.2601841

A. I. Kostenko **and** R. J. Hyndman, “A note on the categorization of demand patterns,” *Journal of the Operational Research Society*, **jourvol** 57, **number** 10, **pages** 1256–1257, 2006. DOI: 10.1057/palgrave.jors.2602211

J. D. Croston, “Forecasting and stock control for intermittent demands,” *Operational Research Quarterly*, **jourvol** 23, **number** 3, **pages** 289–303, 1972. DOI: 10.1057/jors.1972.50

A. A. Syntetos **and** J. E. Boylan, “The accuracy of intermittent demand estimates,” *International Journal of Forecasting*, **jourvol** 21, **number** 2, **pages** 303–314, 2005. DOI: 10.1016/j.ijforecast.2004.10.001

P. H. Zipkin, *Foundations of Inventory Management*. Boston: McGraw-Hill, 2000.

F. A. Oliehoek **and** C. Amato, *A Concise Introduction to Decentralized POMDPs*. Cham: Springer, 2016. DOI: 10.1007/978-3-319-28929-8

R. S. Sutton **and** A. G. Barto, *Reinforcement Learning: An Introduction*, 2 **edition**. Cambridge, MA: MIT Press, 2018.

D. S. Bernstein, R. Givan, N. Immerman **and** S. Zilberstein, “The complexity of decentralized control of Markov decision processes,” *Mathematics of Operations Research*, **jourvol** 27, **number** 4, **pages** 819–840, 2002. DOI: 10.1287/moor.27.4.819.297

F. W. Harris, “How many parts to make at once,” *Factory, The Magazine of Management*, **jourvol** 10, **number** 2, **pages** 135–136, 152, 1913.

H. Scarf, “The optimality of (S, s) policies in the dynamic inventory problem,” in *Mathematical Methods in the Social Sciences* K. J. Arrow, S. Karlin **and** P. Suppes, **editors**, Stanford, CA: Stanford University Press, 1960, **pages** 196–202.

K. J. Arrow, T. Harris **and** J. Marschak, “Optimal inventory policy,” *Econometrica*, **jourvol** 19, **number** 3, **pages** 250–272, 1951. DOI: 10.2307/1906813

P. Zipkin, “Old and new methods for lost-sales inventory systems,” *Operations Research*, **jourvol** 56, **number** 5, **pages** 1256–1263, 2008. DOI: 10.1287/opre.1070.0471

A. Oroojlooyjadid, M. Nazari, L. V. Snyder **and** M. Takáč, “A deep Q-network for the beer game: Deep reinforcement learning for inventory optimization,” *Manufacturing & Service Operations Management*, **jourvol** 24, **number** 1, **pages** 285–304, 2022. DOI: 10.1287/msom.2020.0939

J. Gijsbrechts, R. N. Boute, J. A. Van Mieghem **and** D. J. Zhang, “Can deep reinforcement learning improve inventory management? Performance on lost sales, dual-sourcing, and multi-echelon problems,” *Manufacturing & Service Operations Management*, **jourvol** 24, **number** 3, **pages** 1349–1368, 2022. DOI: 10.1287/msom.2021.1064

J. K. Gupta, M. Egorov **and** M. Kochenderfer, “Cooperative multi-agent control using deep reinforcement learning,” in *Autonomous Agents and Multiagent Systems (AAMAS 2017 Workshops)* **jourser** Lecture Notes in Computer Science, **volume** 10642, Springer, 2017, **pages** 66–83. DOI: 10.1007/978-3-319-71682-4_5

M. Tan, “Multi-agent reinforcement learning: Independent vs. cooperative agents,” in *Proceedings of the 10th International Conference on Machine Learning* 1993, **pages** 330–337.

C. Schröder de Witt **and others**, *Is independent learning all you need in the StarCraft multi-agent challenge?* arXiv preprint arXiv:2011.09533, 2020. arXiv: 2011.09533.

C. Yu **and others**, “The surprising effectiveness of PPO in cooperative multi-agent games,” **in** *Advances in Neural Information Processing Systems 35 (NeurIPS 2022), Datasets and Benchmarks Track 2022*, **pages** 24 611–24 624.

H. Zhu **and** H. Wu, “Deep learning and multi-agent simulation for spatiotemporal inventory management in e-commerce,” *International Journal of Simulation and Process Modelling*, **jourvol** 23, **number** 5, **pages** 11–23, 2026. DOI: 10 . 1504 /IJSPM.2026 .10077092

Nhóm tác giả, *Action-Linked Credit Assignment for Event-Driven Warehouse Management via Multi-Agentic Reinforcement Learning*, SSRN, Preprint, chưa qua phản biện, 2026. **url**: <https://ssrn.com/abstract=7068293>

M. Towers, A. Kwiatkowski, J. Terry, J. U. Balis, G. De Cola, T. Deleu **and others**, *Gymnasium: A standard interface for reinforcement learning environments*, arXiv preprint arXiv:2407.17032, 2024. arXiv: 2407 . 17032.

D. H. Wolpert **and** K. Tumer, “Optimal payoff functions for members of collectives,” *Advances in Complex Systems*, **jourvol** 4, **number** 2–3, **pages** 265–279, 2001. DOI: 10 . 1142/S0219525901000188

J. Schulman, F. Wolski, P. Dhariwal, A. Radford **and** O. Klimov, *Proximal policy optimization algorithms*, arXiv preprint arXiv:1707.06347, 2017. arXiv: 1707 . 06347.

J. Schulman, P. Moritz, S. Levine, M. Jordan **and** P. Abbeel, “High-dimensional continuous control using generalized advantage estimation,” **in** *Proceedings of the 4th International Conference on Learning Representations (ICLR) 2016*. arXiv: 1506 . 0 2438.

P. Henderson, R. Islam, P. Bachman, J. Pineau, D. Precup **and** D. Meger, “Deep reinforcement learning that matters,” **in** *Proceedings of the 32nd AAAI Conference on Artificial Intelligence 2018*, **pages** 3207–3214.

R. Agarwal, M. Schwarzer, P. S. Castro, A. Courville **and** M. G. Bellemare, “Deep reinforcement learning at the edge of the statistical precipice,” in *Advances in Neural Information Processing Systems 34 (NeurIPS 2021)* 2021, **pages** 29 304–29 320.

A. J. Clark **and** H. Scarf, “Optimal policies for a multi-echelon inventory problem,” *Management Science*, **jourvol** 6, **number** 4, **pages** 475–490, 1960. DOI: 10.1287/mnsc.6.4.475

H. L. Lee, V. Padmanabhan **and** S. Whang, “Information distortion in a supply chain: The bullwhip effect,” *Management Science*, **jourvol** 43, **number** 4, **pages** 546–558, 1997. DOI: 10.1287/mnsc.43.4.546

M. L. Puterman, *Markov Decision Processes: Discrete Stochastic Dynamic Programming*. New York: John Wiley & Sons, 1994.

G. Brockman **and others**, *OpenAI Gym*, arXiv preprint arXiv:1606.01540, 2016. arXiv: 1606.01540.

J. Schulman, S. Levine, P. Abbeel, M. Jordan **and** P. Moritz, “Trust region policy optimization,” in *Proceedings of the 32nd International Conference on Machine Learning* 2015, **pages** 1889–1897.

R. E. Bellman, *Dynamic Programming*. Princeton, NJ: Princeton University Press, 1957.

A. Y. Ng, D. Harada **and** S. Russell, “Policy invariance under reward transformations: Theory and application to reward shaping,” in *Proceedings of the 16th International Conference on Machine Learning* 1999, **pages** 278–287.

S. Devlin **and** D. Kudenko, “Theoretical considerations of potential-based reward shaping for multi-agent systems,” in *Proceedings of the 10th International Conference on Autonomous Agents and Multiagent Systems (AAMAS 2011)* 2011, **pages** 225–232.

B. De Moor, J. Gijsbrechts **and** R. N. Boute, “Reward shaping to improve the performance of deep reinforcement learning in perishable inventory management,” *European Journal of Operational Research*, **jourvol** 301, **number** 2, **pages** 535–545, 2022. DOI: 10.1016/j.ejor.2021.11.026

C. D. Hubbs, H. D. Perez, O. Sarwar, N. V. Sahinidis, I. E. Grossmann **and** J. M. Wassick, *OR-Gym: A Reinforcement Learning Library for Operations Research Problems*, arXiv preprint arXiv:2008.06319, 2020. arXiv: 2008.06319.

J. Ding **and others**, *Multi-Agent Reinforcement Learning with Shared Resources for Inventory Management*, arXiv preprint arXiv:2212.07684 (NeurIPS 2022 RL4RealLife Workshop), 2022. arXiv: 2212.07684.

Y. Yang **and others**, *A Versatile Multi-Agent Reinforcement Learning Benchmark for Inventory Management*, arXiv preprint arXiv:2306.07542, 2023. arXiv: 2306.07542.

P. Kotecha **and** E. A. del Rio Chanona, “An analysis of multi-agent reinforcement learning for decentralized inventory control systems,” *Computers & Chemical Engineering*, 2024. arXiv: 2307.11432.

X. Liu, Y. Hu, Z. Peng **and** Y. Yang, “Multi-Agent Deep Reinforcement Learning for Multi-Echelon Inventory Management,” *Production and Operations Management*, 2025. DOI: 10.1177/10591478241305863