

**TỔNG LIÊN ĐOÀN LAO ĐỘNG VIỆT NAM
TRƯỜNG ĐẠI HỌC TÔN ĐỨC THẮNG
KHOA CÔNG NGHỆ THÔNG TIN**



**LÊ MINH LÝ - 52300220
SỬ THỊ YẾN LINH - 52300218**

**XÂY DỰNG MÔ HÌNH HỌC TĂNG
CƯỜNG TỐI ƯU HÓA CHÍNH SÁCH ĐẶT
HÀNG LẠI TRONG QUẢN LÝ TỒN KHO
ĐA KHO**

**KHÓA LUẬN TỐT NGHIỆP
MẠNG MÁY TÍNH VÀ TRUYỀN THÔNG
DỮ LIỆU**

THÀNH PHỐ HỒ CHÍ MINH, NĂM 2026

**TỔNG LIÊN ĐOÀN LAO ĐỘNG VIỆT NAM
TRƯỜNG ĐẠI HỌC TÔN ĐỨC THẮNG
KHOA CÔNG NGHỆ THÔNG TIN**



**LÊ MINH LÝ - 52300220
SỬ THỊ YẾN LINH - 52300218**

**XÂY DỰNG MÔ HÌNH HỌC TẶNG
CƯỜNG TỐI ƯU HÓA CHÍNH SÁCH ĐẶT
HÀNG LẠI TRONG QUẢN LÝ TỒN KHO
ĐA KHO**

**KHÓA LUẬN TỐT NGHIỆP
MẠNG MÁY TÍNH VÀ TRUYỀN THÔNG
DỮ LIỆU**

Giảng viên hướng dẫn
TS. HỒ THỊ LINH

THÀNH PHỐ HỒ CHÍ MINH, NĂM 2026

LỜI CẢM ƠN

Đầu tiên, chúng em xin gửi lời cảm ơn chân thành và sâu sắc nhất đến TS. Hồ Thị Linh, giảng viên hướng dẫn khóa luận tốt nghiệp. Sự hướng dẫn tận tình, những ý kiến đóng góp quý báu và sự hỗ trợ kịp thời của cô đã định hướng và giúp chúng em hoàn thành tốt khóa luận này.

Bên cạnh đó, chúng em cũng xin cảm ơn khoa Công nghệ Thông tin, trường Đại học Tôn Đức Thắng đã tạo điều kiện học tập và cung cấp những nền tảng kiến thức vững chắc, tạo môi trường thuận lợi để chúng em có thể áp dụng vào thực tiễn. Do thời gian và trình độ còn những hạn chế nhất định, báo cáo chắc chắn không tránh khỏi những thiếu sót. Chúng em rất mong nhận được sự cảm thông và những lời góp ý chân thành từ quý thầy cô để đề tài được hoàn thiện hơn và chúng em rút ra được những bài học quý giá.

Chúng em xin chân thành cảm ơn!

TP. Hồ Chí Minh, ngày 09 tháng 05 năm 2026

Tác giả

(Ký và ghi rõ họ tên)

Lê Minh Lý

Tác giả

(Ký và ghi rõ họ tên)

Sử Thị Yến Linh

CÔNG TRÌNH ĐƯỢC HOÀN THÀNH TẠI TRƯỜNG ĐẠI HỌC TÔN ĐỨC THẮNG

Chúng tôi xin cam đoan đây là công trình nghiên cứu của chúng tôi và được sự hướng dẫn khoa học của TS. Hồ Thị Linh. Các nội dung nghiên cứu, kết quả trong đề tài này là trung thực và chưa công bố dưới bất kỳ hình thức nào trước đây. Những số liệu trong các bảng biểu phục vụ cho việc phân tích, nhận xét, đánh giá được chính tác giả thu thập từ các nguồn khác nhau có ghi rõ trong phần tài liệu tham khảo.

Ngoài ra, trong Khóa luận tốt nghiệp còn sử dụng một số nhận xét, đánh giá cũng như số liệu của các tác giả khác, cơ quan tổ chức khác đều có trích dẫn và chú thích nguồn gốc.

Nếu phát hiện có bất kỳ sự gian lận nào chúng tôi xin hoàn toàn chịu trách nhiệm về nội dung Khóa luận tốt nghiệp của mình. Trường Đại học Tôn Đức Thắng không liên quan đến những vi phạm tác quyền, bản quyền do chúng tôi gây ra trong quá trình thực hiện (nếu có).

TP. Hồ Chí Minh, ngày 09 tháng 05 năm 2026

Tác giả

(Ký và ghi rõ họ tên)

Tác giả

(Ký và ghi rõ họ tên)

Lê Minh Lý

Sử Thị Yến Linh

PHẦN XÁC NHẬN VÀ ĐÁNH GIÁ CỦA GIẢNG VIÊN

Phần xác nhận của GV hướng dẫn

Tp. Hồ Chí Minh, ngàytháng

.....năm

(Ký và ghi họ tên)

Phần đánh giá của GV chấm bài

Tp. Hồ Chí Minh, ngàytháng

.....năm

(Ký và ghi họ tên)

XÂY DỰNG MÔ HÌNH HỌC TĂNG CƯỜNG TỐI ƯU HÓA CHÍNH SÁCH ĐẶT HÀNG LẠI TRONG QUẢN LÝ TỒN KHO ĐA KHO

TÓM TẮT

Quản lý tồn kho trong mạng lưới bán lẻ nhiều kho, nhiều mặt hàng là bài toán ra quyết định tuần tự dưới bất định: phải cân bằng chi phí lưu kho, thiếu hàng, đặt hàng và tràn kho trong khi vẫn giữ mức phục vụ khách hàng. Các chính sách cổ điển như EOQ, (s, S) và Newsvendor dựa trên giả định nhu cầu dừng, thời gian giao hàng cố định và không ràng buộc sức chứa, nên khó giữ tính tối ưu khi các giả định này bị vi phạm.

Khóa luận mô hình hóa 10 kho $\times$ 30 mặt hàng thành 300 tác tử, mỗi tác tử quyết định lượng đặt hàng cho một cặp kho–mặt hàng từ quan sát cục bộ, và các tác tử trong cùng kho chia sẻ một sức chứa hữu hạn. Các tác tử được huấn luyện bằng IPPO với chia sẻ tham số (PS-IPPO), dùng phần thưởng phân rã cục bộ theo từng cặp, chuẩn hóa theo quy mô chi phí của từng cặp, và mục tiêu mức phục vụ 85% triển khai dưới dạng ràng buộc mềm.

Môi trường mô phỏng dùng nhu cầu thực tế của bộ dữ liệu M5 Walmart (1.941 ngày), chia thành ba miền huấn luyện, validation và kiểm tra, với thời gian giao hàng ngẫu nhiên từ một đến ba ngày. PS-IPPO được so sánh với ba chính sách cổ điển đã tinh chỉnh trên miền validation, qua nhiều hạt giống huấn luyện và kiểm định thống kê theo cặp.

Kết quả cho thấy khi được so ở cùng mức phục vụ, PS-IPPO đạt tổng chi phí vận hành thấp hơn (s, S) 10,2% và thấp hơn Newsvendor 14,4%, còn EOQ không đạt được mức phục vụ đó. Ưu thế tập trung ở các giai đoạn nhu cầu biến động (ngày có sự kiện, cuối tuần); khi nhu cầu ổn định, (s, S) đạt chi phí thấp hơn. Chia sẻ tham số duy trì hiệu năng tốt ở nhóm mặt hàng có nhu cầu trung bình và cao, nhưng phân bổ mức phục vụ thấp hơn cho nhóm nhu cầu thấp. Đóng góp của khóa luận là một khung PS-IPPO có ràng buộc sức chứa dùng chung trên dữ liệu bán lẻ thực tế, cùng một giao thức đánh giá tách biệt rõ chi phí vận hành, mức phục vụ và tín hiệu huấn luyện.

Từ khóa: quản lý tồn kho; học tăng cường đa tác tử; IPPO; chia sẻ tham số; M5.

BUILDING A REINFORCEMENT LEARNING MODEL FOR OPTIMIZING REORDER POLICY IN MULTI-WAREHOUSE INVENTORY MANAGEMENT

ABSTRACT

Inventory control in a retail network with many warehouses and many products is a sequential decision problem under uncertainty: holding, stockout, ordering and overflow costs must be balanced while a customer service level is maintained. Classical policies such as EOQ, (s, S) and the Newsvendor model assume stationary demand, fixed lead times and unconstrained storage, and lose their optimality when these assumptions are violated.

This thesis models 10 warehouses $\times$ 30 products as 300 agents, each choosing the replenishment quantity of one warehouse–product pair from local observations, with the products of a warehouse sharing a finite capacity. The agents are trained with Independent PPO under parameter sharing (PS-IPPO), using a local factored reward per pair, per-pair reward normalization, and an 85% service-level target implemented as a soft constraint.

The simulation uses the real demand of the M5 Walmart dataset (1,941 days), split into training, validation and test periods, with stochastic lead times of one to three days. PS-IPPO is compared with three classical policies tuned on the validation period, over several training seeds and with paired statistical tests.

At a matched service level, PS-IPPO achieves a total operating cost 10.2% lower than (s, S) and 14.4% lower than the Newsvendor policy, while EOQ does not reach that service level. The advantage is concentrated in volatile demand periods (event days, weekends); under stable demand, (s, S) attains a lower cost. Parameter sharing maintains performance for medium- and high-demand products but allocates a lower service level to low-demand products. The contribution is a PS-IPPO framework with shared warehouse capacity on real retail data, together with an evaluation protocol that separates operating cost, service level and the training signal.

Keywords: inventory management; multi-agent reinforcement learning; IPPO; parameter sharing; M5.

MỤC LỤC

DANH MỤC HÌNH VẼ.....	x
DANH MỤC BẢNG BIỂU.....	xi
DANH MỤC CÁC CHỮ VIẾT TẮT	xiii
CHƯƠNG 1. TỔNG QUAN VỀ ĐỀ TÀI.....	1
1.1 Bối cảnh nghiên cứu và tính cấp thiết của đề tài	1
1.1.1 <i>Thực trạng quản lý tồn kho trong mạng lưới bán lẻ đa điểm</i>	<i>1</i>
1.1.2 <i>Thách thức trong việc tối ưu hóa chính sách đặt hàng lại.....</i>	<i>2</i>
1.1.3 <i>Hạn chế của phương pháp truyền thống và sự cần thiết của học tăng cường đa tác tử.....</i>	<i>3</i>
1.2 Mục tiêu và câu hỏi nghiên cứu	5
1.2.1 <i>Mục tiêu nghiên cứu</i>	<i>5</i>
1.2.2 <i>Câu hỏi nghiên cứu</i>	<i>5</i>
1.3 Đối tượng và phạm vi nghiên cứu	6
1.3.1 <i>Đối tượng nghiên cứu</i>	<i>6</i>
1.3.2 <i>Phạm vi trong đề tài</i>	<i>6</i>
1.3.3 <i>Giới hạn phạm vi</i>	<i>7</i>
1.4 Phương pháp nghiên cứu	7
1.5 Ý nghĩa khoa học và thực tiễn của đề tài.....	7
1.6 Bố cục của khóa luận.....	8
CHƯƠNG 2. CƠ SỞ LÝ THUYẾT VÀ CÁC CÔNG TRÌNH LIÊN QUAN	9
2.1 Lý thuyết kiểm soát tồn kho ngẫu nhiên	9
2.1.1 <i>Mô hình tồn kho và các thành phần chi phí</i>	<i>9</i>
2.1.2 <i>Các chính sách đặt hàng lại cổ điển</i>	<i>10</i>
2.1.3 <i>Các thước đo mức phục vụ trong quản lý tồn kho</i>	<i>10</i>
2.2 Nền tảng học tăng cường.....	11
2.2.1 <i>Quá trình quyết định Markov (MDP)</i>	<i>11</i>

2.2.2	Hàm giá trị và phương trình Bellman.....	12
2.2.3	Ước lượng lợi thế tổng quát (GAE).....	12
2.2.4	Thuật toán PPO (Proximal Policy Optimization).....	12
2.3	Học tăng cường đa tác tử.....	13
2.3.1	Mô hình Dec-POMDP	13
2.3.2	Học độc lập (Independent Learning).....	14
2.3.3	IPPO — Independent Multi-Agent PPO	14
2.3.4	Chia sẻ tham số (Parameter Sharing)	15
2.3.5	Phần thưởng phân rã cục bộ và bài toán gán tín dụng.....	15
2.4	Các công trình nghiên cứu liên quan	16
2.4.1	Học tăng cường trong quản lý tồn kho	16
2.4.2	Hai công trình gần nhất cùng bối cảnh	17
2.4.3	Khoảng trống nghiên cứu và định vị đóng góp.....	18
	CHƯƠNG 3. PHÂN TÍCH VÀ THIẾT KẾ MÔ HÌNH	20
3.1	Mô hình hóa bài toán tồn kho đa kho	20
3.1.1	Quy trình nghiệp vụ và mô hình khái niệm	20
3.1.2	Mô tả mạng lưới.....	21
3.1.3	Thiết lập bài toán dưới dạng MDP đa tác tử.....	22
3.1.4	Ràng buộc sức chứa kho và cơ chế từ chối nhập hàng	26
3.1.5	Cơ chế phối hợp giữa các tác tử	28
3.2	Thiết kế hàm phần thưởng	30
3.2.1	Phần thưởng phân rã cục bộ	30
3.2.2	Vai trò của thành phần phạt fill rate	32
3.2.3	Các tham số chi phí.....	33
3.2.4	Chuẩn hóa phần thưởng theo từng cặp.....	33
3.3	Kiến trúc mạng Actor–Critic chia sẻ tham số.....	34
3.3.1	Mạng SharedActorCritic	34
3.3.2	Quy trình huấn luyện IPPO.....	35

3.4	Thiết kế môi trường mô phỏng	35
CHƯƠNG 4. THỰC NGHIỆM VÀ ĐÁNH GIÁ KẾT QUẢ		37
4.1	Cấu hình thực nghiệm.....	37
4.1.1	Môi trường phần cứng và phần mềm	37
4.1.2	Nguồn dữ liệu và tiền xử lý	37
4.1.3	Thiết lập kịch bản mô phỏng	38
4.2	Phương pháp đối chứng	39
4.3	Giao thức đánh giá.....	40
4.3.1	Quy trình đánh giá.....	40
4.3.2	Các chỉ số đánh giá.....	41
4.4	Kết quả thực nghiệm	41
4.4.1	Quá trình huấn luyện và tính hội tụ	41
4.4.2	So sánh trực tiếp với các chính sách cổ điển.....	43
4.4.3	Phân tích cơ cấu chi phí.....	44
4.4.4	So sánh ở cùng mức phục vụ	45
4.5	Phân tích chuyên sâu	47
4.5.1	Hiệu năng theo nhóm quy mô nhu cầu (Câu hỏi 2)	47
4.5.2	Thiết kế tín hiệu phần thưởng (Câu hỏi 3).....	49
4.5.3	Vai trò của việc tách Actor và Critic	50
4.5.4	Thực nghiệm B: hiệu năng theo giai đoạn nhu cầu	50
4.5.5	Kiểm tra trạng thái và phần thưởng bằng thực nghiệm	54
4.5.6	Độ nhạy của kết luận theo đơn giá chi phí	56
4.6	Hạn chế của thực nghiệm	57
4.7	Thảo luận	58
CHƯƠNG 5. KẾT LUẬN VÀ HƯỚNG PHÁT TRIỂN.....		60
5.1	Tổng kết các kết quả đạt được	60
5.1.1	Trả lời các câu hỏi nghiên cứu	61
5.2	Những hạn chế còn tồn tại	62

5.3	Hướng phát triển trong tương lai	63
5.3.1	<i>Đợt thực nghiệm bổ sung đã cài đặt</i>	63
5.3.2	<i>Các hướng mở rộng khác</i>	64
PHỤ LỤC A. ĐỐI CHIẾU LUẬN ĐIỂM VÀ NGUỒN TRÍCH DẪN		67
PHỤ LỤC B. PROTOTYPE ĐIỀU PHỐI BẰNG MCP		70
TÀI LIỆU THAM KHẢO.....		72

DANH MỤC HÌNH VẼ

Hình 3.1: Mô hình khái niệm của bài toán bổ sung hàng đa kho	21
Hình 3.2: Vòng tương tác học tăng cường của một tác tử trong môi trường kho. Cả 300 tác tử chạy vòng này đồng thời mỗi ngày với cùng θ, ϕ	27
Hình 3.3: Kiến trúc đa tác tử: 300 tác tử (kho w , mặt hàng j) dùng chung một chính sách, tương tác gián tiếp qua sức chứa kho	29
Hình 4.1: Diễn biến huấn luyện qua 1.000 episode (hạt giống 42): (a) phần thưởng tích lũy; (b) tỷ lệ đáp ứng nhu cầu; (c) entropy của chính sách; (d) explained variance của Critic	42
Hình 4.2: So sánh bốn phương pháp trên miền đánh giá: (a) tổng chi phí vận hành; (b) tỷ lệ đáp ứng nhu cầu; (c) cơ cấu chi phí thành phần.....	44
Hình 4.3: Đường đánh đổi chi phí — mức phục vụ. Dấu chữ thập xám: cấu hình tối thiểu chi phí; dấu tròn: cấu hình ở cùng mức phục vụ với IPPO	47
Hình 4.4: Thực nghiệm B1: (a) fill rate của các chính sách theo giai đoạn nhu cầu; (b) chênh lệch chi phí mỗi ngày của IPPO so với hai baseline ở cùng mức phục vụ	51
Hình 4.5: Thực nghiệm B2: fill rate theo ngày (trung bình trượt 7 ngày) quanh cú sốc cầu; vùng tô đỏ là 28 ngày bị sốc	53
Hình 4.6: (a) Xác suất đặt hàng theo số ngày tồn kho; (b) phân bố fill rate của 300 cặp; (c) mức tăng chi phí khi xáo trộn từng nhóm đặc trưng trạng thái	54

DANH MỤC BẢNG BIỂU

Bảng 1.1: Phân loại dạng nhu cầu của 30.490 chuỗi cửa hàng–mặt hàng trong bộ dữ liệu M5 theo tiêu chí của Syntetos và cộng sự [4]	2
Bảng 1.2: Bốn thành phần chi phí vận hành và mục tiêu mức phục vụ trong bài toán tồn kho đang xét	3
Bảng 2.1: Đối chiếu khóa luận với hai công trình gần nhất cùng bối cảnh	18
Bảng 2.2: So sánh tổng quan các công trình nghiên cứu liên quan	18
Bảng 3.1: Đối chiếu biến trạng thái và biểu diễn trong vector quan sát	24
Bảng 3.2: Ánh xạ các thành phần MDP vào bài toán tồn kho đa kho	26
Bảng 3.3: Nhu cầu và sức chứa của từng kho trong cấu hình thực nghiệm	27
Bảng 3.4: Đặc tả tác tử trong hệ thống đề xuất	30
Bảng 3.5: Tham số chi phí trong môi trường mô phỏng	33
Bảng 3.6: Siêu tham số huấn luyện	36
Bảng 4.1: Đặc trưng nhu cầu của tập thực nghiệm so với bộ dữ liệu gốc	38
Bảng 4.2: Ba miền dữ liệu và vai trò của từng miền	38
Bảng 4.3: Cấu hình môi trường mô phỏng	39
Bảng 4.4: Tham số tối ưu của các chính sách đối chứng sau tìm kiếm lưới	40
Bảng 4.5: Kết quả trên miền đánh giá (trung bình $\pm$ độ lệch chuẩn; IPPO trên 90 lần đánh giá gộp 3 hạt giống, baseline trên 30 episode). Chi phí tính bằng đơn vị tiền của mô hình.	43
Bảng 4.6: So sánh ở cùng mức phục vụ: cấu hình rẻ nhất của mỗi chính sách đối chứng đạt fill rate $\geq 90,07\%$ (hạt giống 42)	46
Bảng 4.7: Hiệu năng theo nhóm quy mô nhu cầu trên miền đánh giá (hạt giống 42). Chi phí cục bộ (gồm thành phần định hướng mức phục vụ) tính trung bình cho mỗi cặp trong một episode.	47
Bảng 4.8: Thực nghiệm B1: fill rate và chi phí vận hành trung bình mỗi ngày theo giai đoạn nhu cầu (30 episode, miền test). Cột cuối là chênh lệch chi phí của IPPO so với (s, S) cùng mức phục vụ (âm là IPPO rẻ hơn).	51
Bảng 4.9: Chênh lệch chi phí mỗi ngày của IPPO và khoảng tin cậy 95% (bootstrap theo khối 7 ngày). Dấu *: khoảng tin cậy không chứa 0.	52

Bảng 4.10: Thực nghiệm B2: fill rate (và chi phí mỗi ngày) trước, trong và sau sốc cầu 28 ngày.....	53
Bảng 4.11: Tầm quan trọng của các nhóm đặc trưng trạng thái (xáo trộn nhóm đặc trưng giữa các cặp ở mỗi bước; riêng nhóm lịch được thay bằng lịch của một ngày ngẫu nhiên)	55
Bảng 4.12: Chênh lệch tổng chi phí của IPPO theo đơn giá ($c_{dh} = 5$). Mỗi ô: so với (s, S) trực tiếp / so với (s, S) cùng mức phục vụ; âm là IPPO rẻ hơn.	56
Bảng 5.1: Đợt thực nghiệm bổ sung: mã nguồn đã sẵn sàng, đang chờ huấn luyện	64
Bảng 5.3: So sánh kiến trúc IPPO và MCP theo các chiều điều phối.....	70
Bảng 5.4: Công cụ của prototype MCP.....	71

DANH MỤC CÁC CHỮ VIẾT TẮT

Dec-POMDP	Decentralized Partially Observable Markov Decision Process (Quá trình quyết định Markov có quan sát bộ phận phi tập trung)
EOQ	Economic Order Quantity (Lượng đặt hàng kinh tế)
GAE	Generalized Advantage Estimation (Ước lượng lợi thế tổng quát)
IPPO	Independent Proximal Policy Optimization (Tối ưu hóa chính sách cận đại độc lập)
MARL	Multi-Agent Reinforcement Learning (Học tăng cường đa tác tử)
MDP	Markov Decision Process (Quá trình quyết định Markov)
MLP	Multilayer Perceptron (Mạng nơ-ron truyền thẳng đa tầng)
PPO	Proximal Policy Optimization (Tối ưu hóa chính sách cận đại)
RL	Reinforcement Learning (Học tăng cường)
SCM	Supply Chain Management (Quản trị chuỗi cung ứng)
SKU	Stock Keeping Unit (Đơn vị quản lý tồn kho)
SNAP	Supplemental Nutrition Assistance Program (Chương trình trợ cấp dinh dưỡng)

CHƯƠNG 1. TỔNG QUAN VỀ ĐỀ TÀI

1.1 Bối cảnh nghiên cứu và tính cấp thiết của đề tài

1.1.1 Thực trạng quản lý tồn kho trong mạng lưới bán lẻ đa điểm

Trong hoạt động bán lẻ hiện đại, hàng hóa không được lưu trữ tập trung tại một điểm duy nhất mà được phân tán trên một mạng lưới gồm nhiều kho hoặc nhiều cửa hàng đặt tại các khu vực địa lý khác nhau. Mỗi điểm lưu trữ phục vụ một tập khách hàng riêng, đối mặt với một chuỗi nhu cầu riêng và phải tự ra quyết định bổ sung hàng hóa cho hàng trăm đến hàng nghìn mặt hàng khác nhau [1]. Bài toán vì vậy không còn là việc xác định một mức đặt hàng đơn lẻ, mà là việc điều phối đồng thời một số lượng rất lớn các quyết định có ràng buộc lẫn nhau.

Đặc điểm này thể hiện rõ trong dữ liệu bán lẻ thực tế. Bộ dữ liệu M5, công bố trong cuộc thi dự báo M5 do Makridakis và cộng sự [2] tổ chức, ghi nhận doanh số bán hàng theo ngày của 3.049 mặt hàng tại 10 cửa hàng của Walmart thuộc ba bang California, Texas và Wisconsin, trải trên 1.941 ngày từ ngày 29 tháng 01 năm 2011 đến ngày 22 tháng 05 năm 2016¹. Tổ hợp của hàng và mặt hàng tạo thành 30.490 chuỗi thời gian nhu cầu ở cấp độ chi tiết nhất.

Thống kê trên toàn bộ 30.490 chuỗi này cho thấy hai đặc trưng có ảnh hưởng trực tiếp tới thiết kế chính sách đặt hàng. Thứ nhất, nhu cầu ở cấp cửa hàng–mặt hàng có quy mô rất nhỏ và phân bố lệch mạnh: nhu cầu trung bình là 1,13 đơn vị mỗi ngày, nhưng trung vị chỉ là 0,45 đơn vị, và 73,4% số chuỗi có nhu cầu trung bình dưới một đơn vị mỗi ngày. Thứ hai, nhu cầu mang tính gián đoạn rõ rệt, với tỷ lệ ngày không phát sinh giao dịch trung bình đạt 68%. Áp dụng tiêu chí phân loại của Syntetos và cộng sự [4] với các ngưỡng khoảng cách giữa hai lần phát sinh nhu cầu $p = 1,32$ và bình phương hệ số biến thiên $CV^2 = 0,49$ (trong đó Kostenko và Hyndman [5] đã chứng minh kết quả biên chính xác với giá trị giới hạn $p = 4/3 \approx 1,333$ và đề xuất quy tắc phân loại chỉnh sửa), có tới 95,2% số chuỗi thuộc hai nhóm *intermittent* và *lumpy* (Bảng 1.1).

Cần nói rõ rằng các thống kê trên được tính trên toàn bộ 30.490 chuỗi của bộ dữ liệu gốc. Tập thực nghiệm của khóa luận là một tập con đã qua sàng lọc: các mặt hàng

¹Các thống kê được tính từ hai tệp `calendar.csv` và `sales_train_evaluation.csv` trong bộ dữ liệu M5 [3].

Bảng 1.1: Phân loại dạng nhu cầu của 30.490 chuỗi cửa hàng–mặt hàng trong bộ dữ liệu M5 theo tiêu chí của Syntetos và cộng sự [4]

Nhóm	Đặc điểm	Tỷ lệ
Smooth	$p < 1,32; CV^2 < 0,49$	3,2%
Erratic	$p < 1,32; CV^2 \geq 0,49$	1,6%
Intermittent	$p \geq 1,32; CV^2 < 0,49$	75,7%
Lumpy	$p \geq 1,32; CV^2 \geq 0,49$	19,5%

mà cửa hàng trên thực tế không kinh doanh (nhu cầu trung bình dưới 0,2 đơn vị mỗi ngày ở phần lớn cửa hàng) bị loại bỏ, vì chúng không tạo thành bài toán đặt hàng lại mà chỉ thêm nhiễu vào tín hiệu học. Sau sàng lọc, tập 300 cặp dùng trong thực nghiệm vẫn giữ tỷ lệ ngày không phát sinh giao dịch ở mức 57,4% — nghĩa là tính gián đoạn được bảo toàn — với nhu cầu trung bình 3,24 và trung vị 0,74 đơn vị mỗi ngày. Chi tiết quy trình sàng lọc được trình bày ở Mục 4.1.2.

Đặc điểm gián đoạn này khiến các phương pháp dự báo và các công thức tồn kho xây dựng trên giả định nhu cầu liên tục và phân phối chuẩn trở nên kém phù hợp [6], [7]. Quản lý tồn kho trên một mạng lưới như vậy đòi hỏi những công cụ ra quyết định có khả năng thích ứng, thay vì các bộ tham số tĩnh được thiết lập một lần và áp dụng cố định.

1.1.2 Thách thức trong việc tối ưu hóa chính sách đặt hàng lại

Việc xây dựng chính sách đặt hàng lại trong mạng lưới đa kho – đa mặt hàng đối mặt với bốn nhóm thách thức chính.

Thứ nhất, tính bất định kép của nhu cầu và thời gian giao hàng. Nhu cầu tiêu thụ biến động ngẫu nhiên theo thời gian, đồng thời thời gian từ lúc phát lệnh đặt hàng đến lúc hàng thực nhập kho cũng không cố định [8]. Khi thời gian giao hàng là biến ngẫu nhiên, các đơn hàng phát ra ở những thời điểm khác nhau có thể về kho không đúng thứ tự, khiến các công thức tính tồn kho an toàn cổ điển chỉ còn giữ vai trò xấp xỉ [1].

Thứ hai, bài toán đánh đổi giữa nhiều nhóm chi phí xung đột. Mục tiêu vận hành không quy về một đại lượng duy nhất mà là tổng hợp của nhiều thành phần có chiều tác động ngược nhau, được tóm tắt trong Bảng 1.2. Giảm tồn kho làm giảm chi phí lưu kho nhưng làm tăng rủi ro thiếu hàng; đặt hàng theo lô lớn làm giảm chi phí đặt hàng cố định nhưng làm tăng chi phí lưu kho và nguy cơ vượt sức chứa [8].

Thứ ba, ràng buộc sức chứa tạo ra sự phụ thuộc giữa các mặt hàng. Các mặt

Bảng 1.2: Bốn thành phần chi phí vận hành và mục tiêu mức phục vụ trong bài toán tồn kho đang xét

Thành phần	Ký hiệu	Chiều tác động
Chi phí lưu kho	c_{lk}	Tăng khi mức tồn kho cao
Chi phí thiếu hàng	c_{th}	Tăng khi xảy ra hết hàng
Chi phí đặt hàng cố định	c_{dh}	Tăng theo tần suất đặt hàng
Phạt tràn kho	p_{tk}	Tăng khi hàng về vượt sức chứa kho
Mục tiêu mức phục vụ	$\tau = 85\%$	Ràng buộc nghiệp vụ, không phải chi phí; khi huấn luyện được đưa vào dưới dạng hình phạt với hệ số ϕ_{dv}

hàng cùng nằm trong một kho chia sẻ một dung lượng hữu hạn. Quyết định đặt hàng của một mặt hàng do đó ảnh hưởng trực tiếp tới chi phí mà các mặt hàng khác trong cùng kho phải gánh chịu. Bài toán vì vậy không thể tách rời thành các bài toán độc lập, mà mang bản chất của một bài toán ra quyết định hợp tác [9].

Thứ tư, quy mô không gian hành động. Với N kho và M mặt hàng, mỗi cặp có K mức đặt hàng khả dĩ, không gian hành động chung là tích Descartes có kích thước K^{NM} . Với cấu hình của khóa luận ($N = 10$, $M = 30$, $K = 6$), con số này là 6^{300} — vượt xa khả năng xử lý của bất kỳ phương pháp tìm kiếm tập trung nào, và cũng vượt quá khả năng biểu diễn của các thuật toán học tăng cường dựa trên hàm giá trị vốn phải liệt kê toàn bộ hành động khả dĩ [10]. Trên phương diện lý thuyết độ phức tạp, bài toán điều khiển phi tập trung dạng này đã được chứng minh thuộc lớp NEXP-đầy đủ [11], nên các lời giải chính xác không khả thi ở quy mô thực tế.

1.1.3 Hạn chế của phương pháp truyền thống và sự cần thiết của học tăng cường đa tác tử

Các chính sách tồn kho cổ điển đều được xây dựng trên những tập giả định cụ thể. Mô hình lượng đặt hàng kinh tế của Harris [12] giả định nhu cầu xác định và đều, không có tình trạng thiếu hàng. Chính sách (s, S) được Scarf [13] chứng minh tối ưu cho hệ đơn kho với nhu cầu độc lập giữa các kỳ, chi phí đặt hàng cố định và cơ chế giữ đơn hàng chờ. Mô hình người bán báo của Arrow và cộng sự [14] chỉ tối ưu cho một chu kỳ đơn lẻ, không xét tới lượng hàng đang trên đường vận chuyển. Không mô hình nào trong số đó xử lý được đồng thời nhu cầu ngẫu nhiên, thời gian giao hàng

biến động, ràng buộc sức chứa dùng chung và yêu cầu duy trì mức phục vụ tối thiểu. Riêng với cơ chế mất đơn hàng khi thiếu hàng — vốn phù hợp với bối cảnh bán lẻ — Zipkin [15] chỉ ra rằng bài toán không còn nghiệm giải tích dạng đóng và các chính sách cổ điển mất tính tối ưu đã được chứng minh.

Học tăng cường cung cấp một hướng tiếp cận khác: thay vì giả định trước dạng phân phối của nhu cầu và suy ra chính sách bằng giải tích, tác tử học chính sách trực tiếp thông qua tương tác lặp lại với môi trường [10]. Hướng này đã được kiểm chứng trên các bài toán tồn kho quy mô nhỏ: Oroojlooyjadid và cộng sự [16] áp dụng mạng Q sâu cho trò chơi phân phối bia, còn Gijsbrechts và cộng sự [17] đánh giá học tăng cường sâu trên ba lớp bài toán tồn kho gồm mất đơn hàng, hai nguồn cung và đa cấp.

Tuy nhiên, việc áp dụng học tăng cường đơn tác tử cho toàn bộ mạng lưới vấp phải chính vấn đề quy mô đã nêu ở mục trên. Học tăng cường đa tác tử với cơ chế chia sẻ tham số cho phép vượt qua trở ngại này [18]: mỗi cặp kho–mặt hàng được xem là một tác tử ra quyết định độc lập trên quan sát cục bộ theo hướng tiếp cận học độc lập của Tan [19], trong khi toàn bộ các tác tử cùng học chung một bộ trọng số. Nhờ đó, không gian hành động mà mỗi tác tử phải xử lý thu về kích thước K , còn số tham số cần học không tăng theo quy mô hệ thống. Các nghiên cứu gần đây cho thấy phương pháp học độc lập dựa trên PPO đạt hiệu năng cạnh tranh trên nhiều môi trường hợp tác [20], [21].

Khảo sát tài liệu cho thấy phần lớn các nghiên cứu áp dụng học tăng cường cho quản lý tồn kho hiện nay được tiến hành ở quy mô nhỏ, với một vài kho và một vài mặt hàng, trên dữ liệu nhu cầu sinh theo phân phối lý thuyết. Ngay cả những công trình gần đây nhất cùng bối cảnh cũng để lại những khoảng trống rõ rệt. Zhu và Wu [22] cũng sử dụng bộ dữ liệu M5 và học tăng cường đa tác tử, nhưng giả định nguồn cung không giới hạn và không đưa sức chứa kho vào hàm mục tiêu, nên sự ràng buộc giữa các mặt hàng trong cùng một kho không được mô hình hóa. Ở chiều ngược lại, khung làm việc của Nam và cộng sự [23] có xét ràng buộc sức chứa nhưng chỉ trên một kho duy nhất và trên dữ liệu tổng hợp, đồng thời hàm phần thưởng không quy về đơn vị tiền tệ nên khó diễn giải về mặt kinh tế.

Khoảng trống mà khóa luận hướng tới nằm ở giao của ba yếu tố: mở rộng tới quy mô hàng trăm cặp kho–mặt hàng bằng cơ chế chia sẻ tham số; mô hình hóa ràng buộc sức chứa hữu hạn dùng chung giữa các mặt hàng, tính riêng cho từng kho theo quy mô nhu cầu không đồng nhất của kho đó; và đánh giá so sánh với các chính sách cổ điển ở cùng một mức phục vụ, trên môi trường mô phỏng hiệu chỉnh từ dữ liệu bán

lễ thực tế.

1.2 Mục tiêu và câu hỏi nghiên cứu

1.2.1 Mục tiêu nghiên cứu

Khóa luận đặt ra bốn mục tiêu cụ thể:

- Xây dựng môi trường mô phỏng tồn kho đa kho – đa mặt hàng theo chuẩn Gymnasium [24], mô hình hóa đầy đủ nhu cầu ngẫu nhiên, thời gian giao hàng biến động, ràng buộc sức chứa, bốn thành phần chi phí vận hành (lưu kho, thiếu hàng, đặt hàng, tràn kho) và mục tiêu mức phục vụ; nhu cầu lấy từ bộ dữ liệu M5 Walmart.
- Thiết kế tín hiệu phần thưởng phân rã cục bộ (local factored reward) cho từng cặp kho–mặt hàng, kèm thành phần phạt mức phục vụ tính trên cửa sổ trượt, nhằm giảm khó khăn của bài toán gán tín dụng giữa các tác tử [25].
- Cài đặt và huấn luyện thuật toán Independent Multi-Agent PPO [20], [26] với cơ chế chia sẻ tham số cho 300 cặp kho–mặt hàng, sử dụng ước lượng lợi thế tổng quát [27] và chuẩn hóa lợi thế theo từng cặp.
- Đánh giá hiệu năng của mô hình đề xuất trong so sánh với ba chính sách tồn kho cổ điển, theo giao thức thực nghiệm đa hạt giống có kiểm định thống kê [28], [29].

1.2.2 Câu hỏi nghiên cứu

Khóa luận hướng tới trả lời ba câu hỏi:

1. Câu hỏi 1: Trong cùng điều kiện mức phục vụ — tức khi mọi chính sách đều phải đạt tỷ lệ đáp ứng nhu cầu tối thiểu 85% — PS-IPPO (IPPO với chia sẻ tham số) có đạt tổng chi phí vận hành thấp hơn các chính sách tồn kho cổ điển (EOQ, (s, S) , Newsvendor) hay không, và khác biệt đó có ý nghĩa thống kê hay không?
2. Câu hỏi 2: Cơ chế chia sẻ tham số có duy trì được hiệu năng trên các cặp kho–mặt hàng có quy mô nhu cầu khác nhau hay không; và, như một câu hỏi mở rộng, chính sách học được có áp dụng được cho những mặt hàng không xuất hiện trong huấn luyện hay không?
3. Câu hỏi 3: Thiết kế tín hiệu phần thưởng — phần thưởng phân rã cục bộ theo từng cặp so với phần thưởng toàn cục của cả mạng lưới, và chuẩn hóa

phần thưởng theo từng cặp so với không chuẩn hóa — ảnh hưởng như thế nào đến độ ổn định huấn luyện và hiệu năng của PS-IPPO?

Câu hỏi 1 là câu hỏi chính. Mức 85% là mục tiêu nghiệp vụ được đặt trước khi thực nghiệm; phép so sánh ở một mức phục vụ cao hơn (bằng đúng mức IPPO đạt được) chỉ được dùng như phân tích bổ sung.

1.3 Đối tượng và phạm vi nghiên cứu

1.3.1 Đối tượng nghiên cứu

Đối tượng nghiên cứu của khóa luận là bài toán tối ưu hóa chính sách đặt hàng lại trong hệ thống tồn kho đa kho – đa mặt hàng, và thuật toán học tăng cường đa tác tử Independent Multi-Agent PPO áp dụng cho bài toán này.

1.3.2 Phạm vi trong đề tài

- Cấu hình hệ thống: $N = 10$ kho, $M = 30$ mặt hàng, tương ứng 300 cặp ra quyết định; độ dài mỗi tập huấn luyện là 365 ngày; thời gian giao hàng ngẫu nhiên trong khoảng từ một đến ba ngày.
- Cấu trúc mạng lưới: các kho hoạt động song song và độc lập về nguồn cung, mỗi kho đặt hàng trực tiếp từ nhà cung cấp bên ngoài. Sự ràng buộc giữa các mặt hàng phát sinh từ dung lượng kho dùng chung.
- Nguồn dữ liệu: bộ dữ liệu bán lẻ M5 Walmart [2], cụ thể là hai tệp `sales_train_evaluation.csv` chứa 30.490 chuỗi doanh số theo ngày trên 1.941 ngày, và `calendar.csv` chứa thông tin lịch, ngày lễ và các sự kiện trợ cấp thực phẩm SNAP. Khóa luận đồng thời hỗ trợ sinh dữ liệu giả lập theo phân phối Poisson phục vụ thử nghiệm đối chứng.
- Phương pháp đối chứng: ba chính sách tồn kho cổ điển EOQ [12], (s, S) [13] và Newsvendor [14], với tham số được tối ưu bằng tìm kiếm lưới trên chính môi trường mô phỏng nhằm bảo đảm tính công bằng của so sánh.
- Chỉ số đánh giá: tổng chi phí vận hành, tỷ lệ đáp ứng nhu cầu, và cơ cấu các thành phần chi phí lưu kho, thiếu hàng, đặt hàng, tràn kho. Việc so sánh chi phí được thực hiện bổ sung ở cùng một mức phục vụ nhằm tránh kết luận sai lệch khi hai chính sách nằm ở hai điểm khác nhau trên đường đánh đổi chi phí — mức phục vụ.

1.3.3 Giới hạn phạm vi

Để bảo đảm chiều sâu nghiên cứu trong thời gian thực hiện, những nội dung sau được xác định nằm ngoài phạm vi khóa luận:

- Cấu trúc tồn kho đa cấp (multi-echelon) với quan hệ cung ứng giữa các kho theo mô hình của Clark và Scarf [30], cùng các hiện tượng đi kèm như hiệu ứng bullwhip [31].
- Bài toán điều chuyển hàng liên kho và tối ưu hóa tuyến vận chuyển.
- Dự báo nhu cầu bằng mô hình học sâu chuỗi thời gian; khóa luận sử dụng trực tiếp thông tin nhu cầu lịch sử trong vector quan sát.
- Cơ chế truyền thông giữa các tác tử; các tác tử ra quyết định hoàn toàn dựa trên quan sát cục bộ.
- Triển khai hệ thống thời gian thực hoặc tích hợp với nền tảng quản trị doanh nghiệp; sản phẩm của khóa luận là kết quả mô phỏng và phân tích định lượng.

1.4 Phương pháp nghiên cứu

Khóa luận kết hợp ba nhóm phương pháp. Về lý thuyết, bài toán được mô hình hóa dưới dạng quá trình quyết định Markov phi tập trung có quan sát bộ phận [9], [11], trên nền tảng lý thuyết kiểm soát tồn kho ngẫu nhiên [8] và học tăng cường [10], [32]. Về thực nghiệm, nhóm xây dựng môi trường mô phỏng có kiểm thử đơn vị theo chuẩn giao diện Gymnasium [24], [33], hiệu chỉnh tham số từ dữ liệu M5, huấn luyện tác tử và thu thập số liệu vận hành. Về phân tích, mọi so sánh giữa các phương pháp đều được thực hiện trên cùng một tập hạt giống đánh giá, báo cáo giá trị trung bình kèm độ lệch chuẩn, và được xác nhận bằng kiểm định thống kê phù hợp trước khi kết luận — theo khuyến nghị về tính tái lập trong đánh giá học tăng cường sâu của Henderson và cộng sự [28] và Agarwal và cộng sự [29].

1.5 Ý nghĩa khoa học và thực tiễn của đề tài

Về mặt khoa học, khóa luận đóng góp một khung mô hình hóa bài toán tồn kho đa kho – đa mặt hàng dưới dạng hệ đa tác tử hợp tác quy mô lớn, cùng với đánh giá thực nghiệm có kiểm định thống kê về ảnh hưởng của cách phân rã hàm phần thưởng và cơ chế chia sẻ tham số — hai yếu tố thiết kế thường được sử dụng nhưng ít được khảo sát tách bạch trong các nghiên cứu trước.

Về mặt thực tiễn, kết quả của khóa luận cung cấp bằng chứng định lượng về mức độ khả thi của việc thay thế các chính sách đặt hàng theo tham số tĩnh bằng chính sách học được từ dữ liệu, trên một môi trường mô phỏng được hiệu chỉnh từ dữ liệu bán lẻ thực tế. Cấu trúc mã nguồn và giao thức đánh giá được tổ chức theo hướng có thể tái lập, tạo điều kiện cho các nghiên cứu mở rộng tiếp theo.

1.6 Bố cục của khóa luận

Khóa luận được tổ chức thành năm chương:

- Chương 1 — Tổng quan về đề tài: trình bày bối cảnh, tính cấp thiết, mục tiêu, câu hỏi nghiên cứu, phạm vi và phương pháp nghiên cứu.
- Chương 2 — Cơ sở lý thuyết và các công trình liên quan: hệ thống hóa lý thuyết kiểm soát tồn kho ngẫu nhiên, các chính sách cổ điển, nền tảng học tăng cường và học tăng cường đa tác tử, cùng lược khảo các nghiên cứu tiền nhiệm.
- Chương 3 — Phân tích và thiết kế mô hình: chi tiết hóa mô hình toán học của môi trường, thiết kế không gian trạng thái, không gian hành động và hàm phần thưởng, kiến trúc mạng Actor–Critic chia sẻ tham số và quy trình huấn luyện.
- Chương 4 — Thực nghiệm và đánh giá kết quả: trình bày cấu hình thực nghiệm, kết quả so sánh với các chính sách cổ điển, các khảo sát loại trừ và phân tích độ nhạy.
- Chương 5 — Kết luận và hướng phát triển: tổng kết kết quả đạt được, chỉ ra hạn chế và đề xuất hướng nghiên cứu tiếp theo.

CHƯƠNG 2. CƠ SỞ LÝ THUYẾT VÀ CÁC CÔNG TRÌNH LIÊN QUAN

2.1 Lý thuyết kiểm soát tồn kho ngẫu nhiên

2.1.1 Mô hình tồn kho và các thành phần chi phí

Bài toán kiểm soát tồn kho xoay quanh việc xác định thời điểm và số lượng đặt hàng bổ sung nhằm cân bằng giữa chi phí phát sinh khi dự trữ quá nhiều và rủi ro khi dự trữ quá ít [8]. Xét một hệ thống đơn kho – đơn mặt hàng hoạt động theo chu kỳ rời rạc. Gọi I_t là mức tồn kho tại đầu kỳ t , a_t là số lượng đặt hàng, D_t là nhu cầu phát sinh trong kỳ t (biến ngẫu nhiên) và L_t là thời gian giao hàng. Chi phí vận hành mỗi kỳ bao gồm:

- Chi phí lưu kho $C_{\text{hold}} = c_{lk} \cdot \max(I_t, 0)$: chi phí tỷ lệ với lượng hàng tồn dương trong kho, bao gồm chi phí vốn, bảo quản và kho bãi.
- Chi phí thiếu hàng $C_{\text{stock}} = c_{th} \cdot \max(D_t - I_t, 0)$: chi phí phát sinh khi nhu cầu vượt quá lượng hàng có sẵn. Trong mô hình mất đơn hàng (lost sales), phần nhu cầu không được đáp ứng bị mất hoàn toàn thay vì chuyển sang kỳ sau [15].
- Chi phí đặt hàng cố định $C_{\text{order}} = c_{dh} \cdot \mathbb{1}(a_t > 0)$: chi phí phát sinh mỗi khi hệ thống phát lệnh đặt hàng, bất kể số lượng đặt.
- Phạt tràn kho $C_{\text{over}} = p_{tk} \cdot \max(I_t + q_t - W, 0)$: chi phí phát sinh khi tổng lượng hàng tồn và hàng nhập vượt quá sức chứa W của kho, trong đó q_t là lượng hàng nhập kho trong kỳ.

Tổng chi phí vận hành của một cặp kho–mặt hàng trong kỳ t gồm bốn thành phần trên:

$$C_t = C_{\text{hold}} + C_{\text{stock}} + C_{\text{order}} + C_{\text{over}}. \quad (2.1)$$

Bên cạnh chi phí, doanh nghiệp đặt một mục tiêu mức phục vụ: tỷ lệ đáp ứng nhu cầu (fill rate) $\text{FR}_t^{(w)}$ trên cửa sổ trượt w ngày không thấp hơn ngưỡng τ . Mục tiêu này là một ràng buộc chứ không phải một khoản chi phí; trong khóa luận, nó được đưa vào tín hiệu huấn luyện dưới dạng hình phạt $P_t = \phi_{dv} \cdot \max(\tau - \text{FR}_t^{(w)}, 0)$ (ràng buộc mềm, Mục 3.2.2), và không được cộng vào chi phí vận hành báo cáo.

2.1.2 Các chính sách đặt hàng lại cổ điển

Ba chính sách cổ điển được sử dụng làm phương pháp đối chứng trong khóa luận.

Lượng đặt hàng kinh tế (EOQ). Harris [12] đề xuất công thức tối ưu hóa tần suất đặt hàng dưới giả định nhu cầu xác định và đều:

$$Q^* = \sqrt{\frac{2D \cdot c_{dh}}{c_{lk}}} \quad (2.2)$$

trong đó D là nhu cầu trung bình hàng năm. Mô hình giả định không có thiếu hàng, thời gian giao hàng cố định và không có ràng buộc sức chứa.

Chính sách (s, S) . Scarf [13] chứng minh rằng chính sách dạng (s, S) — đặt hàng để nâng mức tồn kho lên S khi mức hiện tại giảm xuống dưới s — là tối ưu cho hệ đơn kho với nhu cầu ngẫu nhiên, chi phí đặt hàng cố định, và cơ chế giữ đơn hàng chờ (backorder). Ngưỡng s thường được tính dựa trên nhu cầu trung bình và độ lệch chuẩn trong thời gian giao hàng:

$$s = \mu_L + z_\alpha \cdot \sigma_L \quad (2.3)$$

trong đó μ_L và σ_L là kỳ vọng và độ lệch chuẩn của nhu cầu tích lũy trong thời gian giao hàng, z_α là phân vị chuẩn tương ứng với mức phục vụ mong muốn.

Mô hình Newsvendor. Arrow và cộng sự [14] đề xuất mô hình cho bài toán đặt hàng đơn kỳ, trong đó lượng đặt hàng tối ưu là:

$$Q^* = F^{-1}\left(\frac{c_{th}}{c_{th} + c_{lk}}\right) \quad (2.4)$$

với F^{-1} là hàm phân vị của phân phối nhu cầu. Mô hình chỉ tối ưu cho một chu kỳ duy nhất, không xét lượng hàng đang trên đường vận chuyển.

Cả ba chính sách trên đều được xây dựng cho bài toán đơn kho – đơn mặt hàng và không tối ưu hóa đồng thời ràng buộc sức chứa dùng chung, phạt tràn kho và mức phục vụ — những đặc trưng quan trọng trong bài toán đa kho – đa mặt hàng mà khóa luận xét [1], [8].

2.1.3 Các thước đo mức phục vụ trong quản lý tồn kho

Trong quản lý tồn kho ngẫu nhiên, mức phục vụ (service level) được đánh giá thông qua ba thước đo phổ biến [1], [8]:

- *Mức phục vụ theo chu kỳ* (α – Cycle Service Level / Type-1): xác suất không xảy ra hiện tượng thiếu hàng trong một chu kỳ bổ sung tồn kho, tức $P(D_L \leq$

s) trong đó D_L là nhu cầu tích lũy trong thời gian giao hàng L và s là điểm đặt hàng lại. Tỷ số tới hạn trong mô hình Newsvendor (2.4) phản ánh chính xác phân vị z_α của thước đo này.

- *Tỷ lệ đáp ứng nhu cầu* (β – Fill Rate / Type-2): tỷ lệ phần trăm tổng nhu cầu của khách hàng được đáp ứng ngay lập tức từ lượng hàng sẵn có trong kho.
- *Tỷ lệ sẵn sàng* (γ – Ready Rate): tỷ lệ thời gian mà mức tồn kho khả dụng duy trì giá trị dương.

Cần lưu ý rằng tỷ số chi phí $c_{th}/(c_{th} + c_{lk})$ xác định mức phục vụ chu kỳ α , chứ không phải tỷ lệ fill rate β . Trong điều kiện nhu cầu ổn định và biến động vừa phải, β thường cao hơn α . Tuy nhiên, dưới tác động của nhu cầu gián đoạn (intermittent demand) và thời gian giao hàng ngẫu nhiên như trong dữ liệu M5 Walmart, mối quan hệ này không còn mang tính tuyệt đối và β có thể sụt giảm thấp hơn α [1].

Một quan sát thực nghiệm liên quan: với bộ tham số chi phí $c_{th} = 10,0$ và $c_{lk} = 1,0$ sử dụng trong thực nghiệm, tỷ số tới hạn lý thuyết của Newsvendor là $c_{th}/(c_{th} + c_{lk}) = 10/11 \approx 0,909$. Tuy nhiên, tìm kiếm lưới trên môi trường mô phỏng cho tham số tối ưu $CR^* = 0,85$ — thấp hơn nhưng không lệch quá xa lý thuyết. Chênh lệch còn lại không xuất phát từ sai lệch triển khai mà phản ánh sự khác biệt khái niệm căn bản: tỷ số tới hạn cổ điển tối ưu cho mức phục vụ chu kỳ α trong bài toán *một kỳ* không có hàng đang vận chuyển, còn môi trường thực nghiệm là bài toán *đa kỳ* với pipeline 3 ngày, ràng buộc sức chứa kho và hàm mục tiêu fill rate trên cửa sổ trượt. Khoảng cách này được ghi nhận và phân tích trong mục thảo luận kết quả (Mục 4.4.4).

2.2 Nền tảng học tăng cường

2.2.1 Quá trình quyết định Markov (MDP)

Bài toán ra quyết định tuần tự dưới bất định được mô hình hóa bằng quá trình quyết định Markov [32], xác định bởi bộ năm (S, A, P, R, γ) trong đó:

- S : không gian trạng thái (state space).
- A : không gian hành động (action space).
- $P(s' | s, a)$: hàm xác suất chuyển trạng thái.
- $R(s, a)$: hàm phần thưởng (reward function).
- $\gamma \in [0, 1)$: hệ số chiết khấu (discount factor).

Mục tiêu của tác tử là tìm chính sách π^* cực đại hóa lợi tức kỳ vọng:

$$\pi^* = \arg \max_{\pi} \mathbb{E}_{\pi} \left[\sum_{t=0}^{\infty} \gamma^t R(s_t, a_t) \right] \quad (2.5)$$

2.2.2 Hàm giá trị và phương trình Bellman

Hàm giá trị trạng thái $V^{\pi}(s) = \mathbb{E}_{\pi}[\sum_{t=0}^{\infty} \gamma^t R_t \mid s_0 = s]$ và hàm giá trị hành động $Q^{\pi}(s, a)$ thỏa mãn phương trình Bellman [10]. Hàm lợi thế (advantage function) được định nghĩa:

$$A^{\pi}(s, a) = Q^{\pi}(s, a) - V^{\pi}(s) \quad (2.6)$$

đo mức độ tốt hơn (hoặc kém hơn) của hành động a so với hành vi trung bình của chính sách π tại trạng thái s .

2.2.3 Ước lượng lợi thế tổng quát (GAE)

Schulman và cộng sự [27] đề xuất phương pháp ước lượng lợi thế tổng quát (Generalized Advantage Estimation – GAE) nhằm kiểm soát đánh đổi giữa thiên lệch (bias) và phương sai (variance) trong ước lượng gradient chính sách:

$$\hat{A}_t^{\text{GAE}(\gamma, \lambda)} = \sum_{l=0}^{\infty} (\gamma \lambda)^l \delta_{t+l} \quad (2.7)$$

trong đó $\delta_t = r_t + \gamma V(s_{t+1}) - V(s_t)$ là sai số TD (temporal difference) và $\lambda \in [0, 1]$ là tham số kiểm soát đánh đổi. Khi $\lambda = 0$, GAE suy biến thành ước lượng một bước (thiên lệch cao, phương sai thấp); khi $\lambda = 1$, GAE tương đương Monte-Carlo (không thiên lệch, phương sai cao). Khóa luận sử dụng $\lambda = 0,95$ theo khuyến nghị thực nghiệm phổ biến.

2.2.4 Thuật toán PPO (Proximal Policy Optimization)

Schulman và cộng sự [26] đề xuất PPO nhằm khắc phục nhược điểm của phương pháp tối ưu hóa chính sách: các bước cập nhật quá lớn có thể phá hủy chính sách đã học. PPO sử dụng hàm mục tiêu cắt (clipped surrogate objective):

$$L^{\text{CLIP}}(\theta) = \mathbb{E}_t [\min(r_t(\theta) \hat{A}_t, \text{clip}(r_t(\theta), 1 - \epsilon, 1 + \epsilon) \hat{A}_t)] \quad (2.8)$$

trong đó $r_t(\theta) = \frac{\pi_{\theta}(a_t|s_t)}{\pi_{\theta_{\text{old}}}(a_t|s_t)}$ là tỷ lệ xác suất giữa chính sách mới và cũ, và ϵ (thường bằng 0,2) giới hạn biên độ thay đổi tối đa. PPO kết hợp cập nhật on-policy, hiệu quả tính toán cao và tính ổn định, phù hợp cho bài toán có không gian hành động rời rạc hoặc liên tục.

Ý tưởng cốt lõi của TRPO [34] — giới hạn bước cập nhật trong vùng tin cậy — được PPO thực hiện đơn giản hơn qua phép cắt, giúp cài đặt dễ dàng và huấn luyện nhanh hơn trên thực tế.

2.3 Học tăng cường đa tác tử

2.3.1 Mô hình Dec-POMDP

Khi hệ thống có nhiều tác tử ra quyết định đồng thời, bài toán được mô hình hóa bằng quá trình quyết định Markov phi tập trung có quan sát bộ phận (Decentralized Partially Observable Markov Decision Process – Dec-POMDP) [9]. Trong mô hình này, mỗi tác tử i chỉ quan sát được một phần trạng thái toàn cục thông qua hàm quan sát $o_i = O(s, i)$ và ra quyết định dựa trên quan sát cục bộ. Bài toán tìm chính sách chung tối ưu cho tất cả tác tử đã được chứng minh thuộc lớp NEXP-đầy đủ [11], nên các lời giải chính xác không khả thi ở quy mô lớn.

Trong Dec-POMDP chuẩn, mọi tác tử cùng theo đuổi một mục tiêu hợp tác duy nhất. Khóa luận giữ nguyên mục tiêu hợp tác đó ở cấp toàn mạng lưới:

$$R_t^{\text{team}} = \sum_{i=1}^{300} r_{i,t}, \quad \max_{\theta} \mathbb{E} \left[\sum_t \gamma^t R_t^{\text{team}} \right], \quad (2.9)$$

nhưng tín hiệu dùng để *huấn luyện* được phân rã thành các phần thưởng cục bộ $r_{i,t}$ của từng cặp kho–mặt hàng (Mục 2.3.5). Nói cách khác, hệ thống có mục tiêu hợp tác ở cấp toàn mạng lưới, còn phần thưởng cục bộ là một cách phân rã tín hiệu học nhằm giảm phương sai và giảm khó khăn gán tín dụng. Vì các cặp trong cùng kho tương tác qua sức chứa chung, tối ưu riêng từng $r_{i,t}$ không tự động bảo đảm tối ưu R^{team} ; việc phân rã này có thật sự có lợi hay không là nội dung của Câu hỏi nghiên cứu 3.

Bài toán tồn kho đa kho đa mặt hàng được mô hình hóa tự nhiên dưới dạng Dec-POMDP vì bốn đặc điểm cấu trúc phù hợp với lớp bài toán này:

1. **Quyết định tuần tự, hệ quả trễ.** Đơn đặt hàng hôm nay ảnh hưởng tồn kho 1–3 ngày sau. Không phải bài toán một bước.
2. **Trạng thái thay đổi theo hành động.** Đặt hàng làm đổi tồn kho, thay đổi luôn bài toán của ngày mai.
3. **Không có nhãn hành động.** Không tồn tại nhãn hành động tối ưu quan sát trực tiếp cho từng ngày; chỉ quan sát được chi phí sau khi hành động được thực hiện. Đây là lý do không dùng học có giám sát.
4. **Mục tiêu dài hạn.** Tối thiểu chi phí cả năm, không phải chỉ hôm nay. Tích

trừ hôm nay tổn tiền nhưng tránh mất doanh thu ngày mai.

Quy hoạch động không khả dụng vì không gian trạng thái liên tục $43 \text{ chiều} \times 300 \text{ tác tử}$ và phân phối nhu cầu M5 không có dạng đóng — đây là “lời nguyền số chiều” mà các phương pháp bảng tra (tabular) không vượt qua được [35].

2.3.2 Học độc lập (*Independent Learning*)

Tan [19] đề xuất phương pháp học độc lập: mỗi tác tử coi các tác tử khác là một phần của môi trường và áp dụng thuật toán RL đơn tác tử riêng rẽ. Hạn chế lý thuyết chính là môi trường trở nên không dừng (non-stationary) do các tác tử khác cũng đang thay đổi chính sách. Tuy nhiên, các nghiên cứu thực nghiệm cho thấy phương pháp này đạt hiệu quả bất ngờ trên nhiều bài toán hợp tác [20].

2.3.3 IPPO — *Independent Multi-Agent PPO*

IPPO là biến thể đa tác tử của PPO trong đó mỗi tác tử i chạy PPO độc lập dựa trên quan sát cục bộ o_i^t và phần thưởng riêng r_i^t [20]. Yu và cộng sự [21] đánh giá hệ thống trên nhiều môi trường hợp tác và kết luận rằng IPPO đạt hiệu năng cạnh tranh hoặc vượt trội so với các phương pháp phức tạp hơn như QMIX hay MAPPO trong nhiều kịch bản.

Đặc điểm quan trọng của IPPO khiến nó phù hợp cho bài toán tồn kho:

- Không yêu cầu trạng thái toàn cục: mỗi tác tử (cặp kho–mặt hàng) chỉ cần quan sát cục bộ.
- Khả năng mở rộng: không gian hành động của mỗi tác tử có kích thước K cố định, không phụ thuộc số tác tử.
- Tính đơn giản: cài đặt dựa trên PPO chuẩn, không cần mixing network hay cơ chế truyền thông.

Cần phân biệt rõ ba tầng nghĩa của “independent” trong IPPO, vì chúng hàm ý khác nhau:

- *Độc lập về ra quyết định*: mỗi tác tử chọn hành động chỉ dựa trên quan sát cục bộ của mình, không nhận thông tin từ tác tử khác. Đúng.
- *Độc lập về tính lợi thế*: GAE tính riêng theo trục thời gian cho từng cặp i , sử dụng phần thưởng riêng r_i^t và giá trị riêng $V(o_i^t)$. Đúng.
- *Độc lập về tham số*: mỗi tác tử có bộ trọng số riêng. Không — đây là điểm chia sẻ tham số (parameter sharing) được khảo sát ở Mục 2.3.4.

Hai cặp ở hai trạng thái khác nhau sẽ hành động khác nhau dù cùng θ — vì đầu

vào khác nhau. Mỗi tác tử có chính sách riêng theo nghĩa hàm $\pi(a \mid o_i)$ nhận quan sát riêng và cho ra phân phối riêng, nhưng tham số θ dùng chung.

2.3.4 Chia sẻ tham số (Parameter Sharing)

Gupta và cộng sự [18] chỉ ra rằng khi các tác tử có cùng không gian quan sát và hành động, một mạng nơ-ron duy nhất có thể được chia sẻ giữa tất cả tác tử. Mỗi tác tử vẫn ra quyết định dựa trên quan sát riêng nhưng dùng chung bộ trọng số. Lợi ích:

- Số tham số cần học không tăng theo số tác tử (ở đây: 300).
- Mỗi bước cập nhật sử dụng dữ liệu từ tất cả tác tử, tăng hiệu quả mẫu.
- Chính sách học được có khả năng tổng quát hóa cho các mặt hàng có quy mô nhu cầu khác nhau.

Chẩn đáng lưu ý: chia sẻ tham số không tương đương với việc gộp 300 tác tử thành một tác tử duy nhất. Nếu gộp, không gian hành động sẽ là 6^{300} , không thể học được trên thực tế. Với kiến trúc chia sẻ tham số hiện tại, mạng nhận batch (300, 43) và forward một lần, nhưng mỗi tác tử chỉ xử lý $K = 6$ hành động — không gian cố định và có thể giải quyết được.

2.3.5 Phần thưởng phân rẽ cục bộ và bài toán gán tín dụng

Trong hệ đa tác tử, việc sử dụng phần thưởng toàn cục (tổng chi phí của toàn bộ hệ thống) cho mọi tác tử gây ra vấn đề gán tín dụng (credit assignment): tác tử khó phân biệt được đóng góp cá nhân trong tín hiệu tổng hợp [25]. Wolpert và Tumer đề xuất *phần thưởng chênh lệch* (difference reward) $D_i = G(z) - G(z_{-i})$, trong đó $G(z_{-i})$ là giá trị của hệ thống khi loại bỏ đóng góp của tác tử i — một đại lượng phản thực (counterfactual) phải được tính thêm.

Khóa luận *không* cài đặt phần thưởng chênh lệch theo đúng nghĩa này. Thay vào đó, khóa luận dùng *phần thưởng phân rẽ cục bộ* (local factored reward): mỗi tác tử nhận $r_{i,t} = -(C_{i,t} + P_{i,t})$, gồm chi phí vận hành $C_{i,t}$ và hình phạt mức phục vụ $P_{i,t}$ của chính cặp kho–mặt hàng mà nó quản lý, với $\sum_i r_{i,t} = R_t^{\text{team}}$ (công thức 2.9). Cách phân rẽ này dựa trên cùng động cơ giảm khó khăn gán tín dụng như phân tích của Wolpert và Tumer. Nó khả thi ở đây vì phần lớn chi phí của một cặp (lưu kho, thiếu hàng, đặt hàng) do chính quyết định của cặp đó gây ra; riêng phần tràn kho — đại lượng thực sự ghép nối giữa các cặp — được phân bổ theo tỷ trọng hàng mới về của từng cặp (Mục 3.1.4).

Khung lý thuyết định hình phần thưởng bảo toàn thế năng (Potential-Based Reward Shaping – PBRs) do Ng và cộng sự [36] chứng minh khẳng định rằng: một hàm biến đổi phần thưởng $F(s, a, s')$ bảo toàn tập chính sách tối ưu của MDP gốc khi và chỉ khi nó có dạng chênh lệch thế năng $F(s, a, s') = \gamma\Phi(s') - \Phi(s)$. Khung lý thuyết này sau đó được mở rộng sang hệ đa tác tử bởi Devlin và Kudenko [37] cũng như ứng dụng trong tồn kho bởi De Moor và cộng sự [38].

2.4 Các công trình nghiên cứu liên quan

2.4.1 Học tăng cường trong quản lý tồn kho

Oroojlooyjadid và cộng sự [16] áp dụng Deep Q-Network (DQN) cho trò chơi phân phối bia (beer game) — một bài toán chuỗi cung ứng 4 cấp cổ điển — và cho thấy DQN có thể học được chính sách giảm hiệu ứng bullwhip. Tuy nhiên, nghiên cứu giới hạn ở hệ đơn mặt hàng, bốn tác tử.

Gijsbrechts và cộng sự [17] đánh giá hệ thống khả năng của DRL trên ba lớp bài toán tồn kho: mất đơn hàng, hai nguồn cung và đa cấp. Kết quả cho thấy DRL đạt hiệu năng ngang hoặc tốt hơn chính sách cổ điển trong hầu hết trường hợp, nhưng tất cả thực nghiệm đều ở quy mô nhỏ (dưới 10 SKU).

Hubbs và cộng sự [39] giới thiệu bộ thư viện OR-Gym đóng vai trò là môi trường benchmark chuẩn cho các bài toán Vận trù học bằng RL, bao gồm cả mô hình Newsvendor và quản lý tồn kho đa cấp lost-sales.

Nghiên cứu của Ding và cộng sự [40] (CD-PPO) phát biểu chính xác bài toán tồn kho đơn cửa hàng nhiều SKU dưới dạng tài nguyên kho dùng chung làm ghép nối các tác tử vốn độc lập. Họ so sánh trực tiếp IPPO và MAPPO có chia sẻ tham số (parameter sharing), báo cáo hiệu quả cao hơn các phương pháp đối chứng khi quản lý tài nguyên kho chung.

Yang và cộng sự [41] phát triển MABIM — bộ benchmark MARL đa dạng cho tồn kho. MABIM coi mỗi SKU tại mỗi điểm lưu trữ là một tác tử độc lập, sử dụng dữ liệu nhu cầu thực tế của hơn 2.000 SKU với 51 tác vụ thử nghiệm (bao gồm nhóm tác vụ mở rộng quy mô scaling up), thử nghiệm các thuật toán MARL bao gồm IPPO dưới ràng buộc sức chứa dùng chung.

Kotecha và del Rio Chanona [42] tiến hành phân tích chuyên sâu các thuật toán MARL cho kiểm soát tồn kho phân tán, so sánh giữa IPPO thuần, IPPO chia sẻ tham số và MAPPO. Họ phát hiện rằng mặc dù parameter sharing giảm số lượng tham số cần học, hiệu năng của IPPO chia sẻ tham số có dấu hiệu giảm sút khi quy mô tác tử

tăng lên rất lớn.

Gần đây nhất, Liu và cộng sự [43] áp dụng thuật toán Heterogeneous-Agent PPO (HAPPO) cho tồn kho đa cấp. Đáng chú ý, các tác giả phát hiện việc kết hợp chi phí cục bộ và chi phí toàn hệ thống vào tín hiệu thưởng thu được chính sách có độ ổn định và hiệu năng cao hơn so với chỉ dùng chi phí toàn hệ thống thuần túy.

2.4.2 Hai công trình gần nhất cùng bối cảnh

Hai công trình công bố gần đây có bối cảnh gần với khóa luận nhất và vì vậy cần được đối chiếu chi tiết.

Zhu và Wu [22] đề xuất khung DC-STGN-MARL kết hợp một mạng đồ thị không-thời gian cho dự báo nhu cầu với học tăng cường đa tác tử theo hướng phân rã hàm giá trị, đánh giá trên chính bộ dữ liệu M5. Công trình báo cáo mức giảm 13,6% tổng chi phí so với học tăng cường đơn tác tử và mức phục vụ 95,8%. Điểm cần lưu ý đối với khóa luận nằm ở khảo sát loại trừ của họ: khi thay cơ chế phối hợp bằng học độc lập, chi phí tăng từ 125,4 lên 152,7 và mức phục vụ giảm từ 95,8% xuống 92,1%. Kết quả này đặt ra câu hỏi trực tiếp về lựa chọn học độc lập của khóa luận.

Tuy nhiên, bối cảnh của hai nghiên cứu khác nhau ở một điểm mấu chốt. Môi trường của Zhu và Wu giả định năng lực cung ứng không giới hạn và không đưa sức chứa kho vào hàm mục tiêu, nên các tác tử chỉ ghép nối với nhau qua hàm phần thưởng chung chứ không qua một nguồn lực vật lý hữu hạn. Trong khóa luận, sức chứa kho dùng chung là một ràng buộc cứng và cũng chính là kênh phối hợp gián tiếp (Mục 3.1.5); mức độ cần thiết của phối hợp tường minh trong bối cảnh này vì vậy là một câu hỏi thực nghiệm mở, chứ không thể suy trực tiếp từ kết quả của họ. Ngoài ra, một số chi tiết trong công trình cần được tiếp nhận thận trọng: các so sánh chi phí được thực hiện giữa những cấu hình có mức phục vụ khác nhau, và số lượng tác tử không được xác định rõ ràng — bài viết mô tả N tác tử “đại diện cho N kho hoặc nhóm sản phẩm” mà không xác định cụ thể.

Ở hướng thứ hai, một khung làm việc dựa trên kiến trúc hướng sự kiện kết hợp tác tử xếp vị trí lưu trữ và tác tử bổ sung hàng đã được đề xuất [23], với đóng góp chính là cơ chế *gán công liên kết hành động*: phần thưởng chỉ được tính khi lô hàng thực nhập kho sau thời gian giao hàng, rồi được quy ngược về đúng cặp trạng thái-hành động đã phát lệnh đặt. Đây là một cách xử lý trực diện độ trễ giữa quyết định và hệ quả của nó. Khảo sát loại trừ của công trình cho thấy khi bỏ cơ chế này, tỷ lệ thiếu hàng tăng đáng kể. Cần lưu ý rằng biến thể đối chứng của họ sử dụng trạng thái dự đoán tại thời điểm ra quyết định, chứ không phải ước lượng lợi thế tổng quát

như khóa luận sử dụng; do đó con số của họ không thể chuyển trực tiếp sang bối cảnh này. Hạn chế của công trình là chỉ xét một kho duy nhất, trên dữ liệu tổng hợp, và hàm phần thưởng không quy về đơn vị tiền tệ.

Bảng 2.1 tóm tắt đối chiếu.

Bảng 2.1: Đối chiếu khóa luận với hai công trình gần nhất cùng bối cảnh

Tiêu chí	[23]	[22]	Khóa luận
Số kho	1	4	10
Ràng buộc sức chứa	một kho	không xét	riêng từng kho
Nguồn dữ liệu	tổng hợp	M5	M5
Hàm mục tiêu	không quy về tiền	chi phí	chi phí
Ghép nối giữa tác tử	không	phần thưởng chung	sức chứa dùng chung
So sánh cùng mức phục vụ	không	không	có

2.4.3 Khoảng trống nghiên cứu và định vị đóng góp

Bảng 2.2 tóm tắt so sánh tổng quan giữa khóa luận này và các công trình nghiên cứu liên quan tiêu biểu.

Bảng 2.2: So sánh tổng quan các công trình nghiên cứu liên quan

Nghiên cứu	Cấu trúc mạng	Số SKU	Chia sẻ tham số	Dữ liệu thực	Thuật toán
Oroojlooyjadid (2022)	4 cấp chuỗi	1	Không	Không	DQN
Gijsbrechts (2022)	2 cấp / đa cấp	< 10	Không	Không	A2C / PPO
Hubbs et al. (2020)	Đa cấp lost-sales	Biến đổi	Không	Không	DQN / PPO
Ding et al. (2022)	1 cửa hàng	Nhiều SKU	Có	Không	CD-PPO / IPPO
Yang et al. (2023)	Đa cấp / Đa kho	> 2000	Có	Có	IPPO / MAPPO
Kotecha (2024)	Đa điểm phân tán	Biến đổi	Có	Không	IPPO / MAPPO
Liu et al. (2025)	Đa cấp phức tạp	Nhiều SKU	Có	Có	HAPPO
Khóa luận này	10 kho song song	30	Có	M5 Walmart	IPPO

Đóng góp của khóa luận được định vị theo hướng tái lập và mở rộng có kiểm

soát đối với ứng dụng học tăng cường đa tác tử trong kiểm soát tồn kho, tập trung vào ba trọng tâm sau:

1. Khảo sát cấu hình 10 kho song song thuần túy (non-multi-echelon) với ràng buộc sức chứa kho dùng chung ở quy mô 300 cặp kho–mặt hàng, tạo điểm đối sánh trực tiếp với các mô hình đa cấp (multi-echelon) của MABIM [41] và Liu và cộng sự [43].
2. Thực hiện khảo sát loại trừ có hệ thống nhằm định lượng tác động của tín hiệu phân thưởng phân rã cục bộ kèm ràng buộc tỷ lệ đáp ứng trên cửa sổ trượt, làm rõ cơ chế gán tín dụng và tốc độ hội tụ của IPPO ở quy mô 300 tác tử.
3. Hiệu chỉnh môi trường mô phỏng lost-sales trực tiếp từ dữ liệu bán lẻ thực tế M5 Walmart và thực hiện kiểm chứng đối chứng có kiểm định thống kê với các chính sách cổ điển EOQ, (s, S) và Newsvendor.

CHƯƠNG 3. PHÂN TÍCH VÀ THIẾT KẾ MÔ HÌNH

3.1 Mô hình hóa bài toán tồn kho đa kho

3.1.1 Quy trình nghiệp vụ và mô hình khái niệm

Thiết kế tác tử của khóa luận không bắt đầu từ thuật toán mà từ quy trình vận hành kho. Trình tự lập luận được giữ đúng theo thứ tự: quy trình nghiệp vụ → các quyết định cần đưa ra → ai chịu trách nhiệm cho từng quyết định → nhiệm vụ → tác tử.


Quy trình vận hành một ngày. Tại mỗi kho, với mỗi mã hàng, một chu kỳ vận hành hàng ngày gồm năm bước:

1. **Nhận hàng:** các đơn đặt trước đó đến hạn được giao tới kho. Kho chỉ nhập được trong phạm vi chỗ trống còn lại; hàng vượt sức chứa bị từ chối tại cửa nhập.
2. **Kiểm tra tình trạng:** người phụ trách mã hàng xem tồn kho hiện có, lượng hàng đã đặt nhưng chưa về, lượng bán những ngày gần đây và mức độ đầy của kho.
3. **Ra quyết định bổ sung:** quyết định hôm nay đặt thêm bao nhiêu đơn vị từ nhà cung cấp (có thể là không đặt). Đơn hàng sẽ về sau 1–3 ngày, không biết trước chính xác.
4. **Bán hàng:** khách hàng mua; phần nhu cầu vượt tồn kho bị mất (khách chuyển sang cửa hàng khác).
5. **Ghi nhận kết quả:** chi phí lưu kho, chi phí đặt hàng, tổn thất do thiếu hàng, hàng bị từ chối vì tràn kho và mức phục vụ khách hàng.

Từ quy trình đến tác tử. Trong năm bước trên, chỉ có đúng *một* quyết định cần tối ưu — lượng đặt bổ sung ở bước 3; các bước còn lại là hệ quả vật lý (nhận hàng, bán hàng) hoặc ghi nhận (chi phí). Quyết định này lặp lại cho từng mã hàng tại từng kho và do người phụ trách mã hàng đó chịu trách nhiệm, còn sức chứa kho là tài nguyên dùng chung mà không ai phân bổ tường minh. Vì vậy nhiệm vụ tổng “tối thiểu chi phí vận hành toàn mạng lưới dưới ràng buộc sức chứa và mức phục vụ” được phân rã thành $10 \times 30 = 300$ nhiệm vụ con cùng loại, mỗi nhiệm vụ con giao cho một tác tử

ứng với một cặp (kho, mặt hàng). Căn cứ chi tiết của cách phân rã này được trình bày ở Mục 3.1.3.

Mô hình khái niệm. Hình 3.1 tóm tắt bài toán ở mức nghiệp vụ, trước khi đi vào thuật toán: nhu cầu tác động lên kho, làm thay đổi trạng thái tồn kho; hệ đa tác tử đọc trạng thái và ra quyết định bổ sung hàng; quyết định đó sinh ra chi phí và mức phục vụ, đồng thời tạo ra trạng thái tồn kho mới cho ngày kế tiếp.



Hình 3.1: Mô hình khái niệm của bài toán bổ sung hàng đa kho

3.1.2 Mô tả mạng lưới

Hệ thống gồm $N = 10$ kho hoạt động song song và độc lập về nguồn cung. Mỗi kho lưu trữ $M = 30$ mặt hàng (SKU), tạo thành tổng cộng $N \times M = 300$ cặp kho–mặt hàng. Mỗi kho có dung lượng hữu hạn W được chia sẻ giữa tất cả các mặt hàng. Mỗi cặp kho–mặt hàng đặt hàng trực tiếp từ nhà cung cấp bên ngoài với thời gian giao hàng ngẫu nhiên $L \sim \text{Uniform}(1, 3)$ ngày.

Sự ràng buộc giữa các mặt hàng trong cùng kho phát sinh từ dung lượng dùng chung: khi một mặt hàng đặt quá nhiều, các mặt hàng khác có thể bị phạt tràn kho.

Đây chính là yếu tố khiến bài toán mang tính hợp tác và không thể tách rời thành 300 bài toán đơn lẻ.

Nhu cầu hàng ngày $D_t^{(i)}$ cho mỗi cặp kho–mặt hàng i được lấy từ hai nguồn:

- Dữ liệu M5 Walmart: tham số nhu cầu (λ trung bình, mẫu hình mùa vụ) được hiệu chỉnh từ chuỗi doanh số thực tế của 10 cửa hàng, mỗi cửa hàng 30 SKU [2].
- Dữ liệu giả lập: nhu cầu Poisson $D_t \sim \text{Poisson}(\lambda_i)$ với λ_i khác nhau giữa các SKU, phục vụ thử nghiệm đối chứng.

3.1.3 Thiết lập bài toán dưới dạng MDP đa tác tử

Phân rã nhiệm vụ và thiết kế tác tử. Trước khi hình thức hóa bài toán dưới dạng MDP đa tác tử, cần làm rõ vì sao hệ thống được phân rã thành đúng 300 tác tử theo cặp kho–mặt hàng, thay vì một cách phân rã khác.

Có hai hướng phân rã khả dĩ cho một hệ thống ra quyết định phân tán. Hướng thứ nhất là *phân rã theo chức năng* (functional decomposition): mỗi tác tử đảm nhận một khâu xử lý trong quy trình ra quyết định — chẳng hạn một tác tử quan sát làm nhiệm vụ tổng hợp thông tin (dự báo nhu cầu, theo dõi tồn kho toàn mạng lưới) và một tác tử điều phối riêng biệt chuyển các tổng hợp đó thành quyết định đặt hàng cho từng mặt hàng. Hướng thứ hai là *phân rã theo điểm ra quyết định nghiệp vụ* (decision-point decomposition): mỗi tác tử tương ứng chính xác với một điểm mà tổ chức thực sự đưa ra một quyết định độc lập.

Khóa luận chọn hướng thứ hai. Lý do xuất phát trực tiếp từ cách vận hành kho trong thực tế: người phụ trách một mã hàng tại một kho là người duy nhất ra quyết định đặt hàng lại cho đúng mã hàng đó, dựa trên tồn kho, lượng hàng đang về và lịch sử bán của chính mặt hàng mình phụ trách — không tồn tại một “tác tử quan sát” trung gian tổng hợp thông tin của cả 300 mã hàng rồi một “tác tử điều phối” khác mới ra quyết định. Nếu phân rã theo chức năng, khóa luận sẽ phải tự thiết kế thêm một giao diện truyền thông giữa tác tử quan sát và tác tử điều phối — một thành phần không tồn tại trong bài toán nghiệp vụ gốc và sẽ làm thay đổi chính đối tượng nghiên cứu, đồng thời đặt ra câu hỏi ai chịu trách nhiệm quyết định cuối cùng khi hai tác tử bất đồng. Phân rã theo điểm ra quyết định nghiệp vụ tránh được vấn đề này: không gian hành động của mỗi tác tử ánh xạ trực tiếp vào một đòn bẩy vận hành có thật (lượng đặt hàng lại), và bài toán gán tín dụng (credit assignment) của mỗi tác tử gắn liền với đúng một chi phí mà quyết định của nó gây ra, không phải một chi phí tổng hợp từ

nhieu quyết định của các tác tử khác.

Hệ quả trực tiếp là số lượng tác tử bằng đúng số cặp kho–mặt hàng, $N \times M = 300$, chứ không phụ thuộc vào số khâu xử lý được thiết kế trong hệ thống. Cách phân rã này cũng là tiền đề cho kiến trúc phi tập trung hoàn toàn được trình bày ở Mục 3.1.5: một khi đã phân rã theo đúng điểm ra quyết định thực tế, việc bổ sung một tác tử điều phối trung tâm sẽ mâu thuẫn với chính căn cứ phân rã ban đầu.

Bài toán được mô hình hóa dưới dạng Dec-POMDP [9] với 300 tác tử. Mỗi tác tử i (tương ứng cặp kho–mặt hàng) có:

Không gian quan sát $o_i^t \in \mathbb{R}^d$: vector quan sát cục bộ tại kỳ t bao gồm:

- Mức tồn kho hiện tại (on-hand inventory): $I_t^{(i)}$.
- Lượng hàng đang trên đường vận chuyển (in-transit): tổng các đơn hàng đã phát mà chưa nhập kho.
- Nhu cầu lịch sử w ngày gần nhất: $(D_{t-w}^{(i)}, \dots, D_{t-1}^{(i)})$.
- Tỷ lệ đáp ứng nhu cầu trên cửa sổ trượt w ngày: $\text{FR}_t^{(i,w)}$.
- Tỷ lệ sử dụng sức chứa của kho chứa tác tử i : $u_t^{(w(i))} = \sum_{j \in w(i)} I_t^{(j)} / W_{w(i)}$, trong đó $w(i)$ là kho chứa cặp i và $W_{w(i)}$ là sức chứa của kho đó.
- Tỷ trọng tồn kho của chính cặp i trong kho: $I_t^{(i)} / \sum_{j \in w(i)} I_t^{(j)}$.
- Đặc trưng quy mô $\log(1 + \bar{D}^{(i)})$ chuẩn hóa, cho phép mạng dùng chung phân biệt các mặt hàng có quy mô nhu cầu khác nhau.
- Bối cảnh thời gian: thứ trong tuần (one-hot 7 chiều) và vector đặc trưng lịch 20 chiều trích từ `calendar.csv` (ba cờ SNAP, một cờ không có sự kiện, bốn loại sự kiện, mười hai tháng).

Tổng cộng vector quan sát của mỗi tác tử có $d = 43$ chiều. Hai thành phần $u_t^{(w(i))}$ và tỷ trọng tồn kho giữ vai trò đặc biệt: hàm phần thưởng có thành phần phạt tràn kho phụ thuộc vào tổng tồn kho của cả kho, nên nếu quan sát không chứa thông tin ở cấp kho thì tác tử bị phạt vì một đại lượng nó không quan sát được, và hàm giá trị không thể nhất quán. Đây cũng chính là kênh ghép nối duy nhất giữa các tác tử trong thiết kế phi tập trung của khóa luận (Mục 3.1.5).

Bảng 3.1 đối chiếu các biến trạng thái đặc trưng của bài toán tồn kho với cách biểu diễn trong vector quan sát 43 chiều.

Ghi chú về thời gian giao hàng. Môi trường bốc thời gian giao hàng ngẫu nhiên $L \sim \text{Uniform}\{1, 2, 3\}$ cho từng đơn hàng, nhưng tác tử không quan sát trực tiếp giá trị L đã bốc. Thay vào đó, thông tin này được phản ánh gián tiếp qua vector pipeline 3

Bảng 3.1: Đối chiếu biến trạng thái và biểu diễn trong vector quan sát

Biến trạng thái	Có trong quan sát?	Ghi chú
Tồn kho hiện tại	Có (1 chiều)	Chuẩn hóa theo số ngày nhu cầu
Vị thế tồn kho (IP)	Có (1 chiều)	Tồn kho + hàng đang về
Nhu cầu lịch sử	Có (7 chiều)	7 ngày gần nhất, thang log
Nhu cầu hiện tại	Không	Có chủ ý: quyết định đặt hàng xảy ra trước khi nhu cầu ngày hôm đó phát sinh; đưa vào là rò rỉ thông tin tương lai
Hàng đang về (pipeline)	Có (3 chiều)	Lượng hàng theo từng ngày còn lại đến hạn
Thời gian giao hàng (L)	Gián tiếp	Không quan sát trực tiếp L đã bốc; phản ánh qua pipeline — partial observability có chủ ý (xem ghi chú bên dưới)
Tình trạng thiếu hàng	Có (1 chiều)	Fill rate cửa sổ trượt 30 ngày
Mức sử dụng sức chứa kho	Có (1 chiều)	$u_t^{(w(i))} = \sum_{j \in w(i)} I_t^{(j)} / W_{w(i)}$
Tỷ trọng tồn kho trong kho	Có (1 chiều)	Thông tin về mức độ chiếm dụng kho
Đặc trưng quy mô	Có (1 chiều)	$\log(1 + \bar{D}^{(i)})$, giúp mạng dùng chung phân biệt SKU
Ngày trong tuần	Có (7 chiều)	One-hot encoding
Đặc trưng lịch	Có (20 chiều)	SNAP, loại sự kiện, tháng

chiều. Đây là lựa chọn có chủ ý phù hợp với tinh thần Dec-POMDP: trong thực tế vận hành, nhà cung cấp cũng không cam kết chính xác ngày giao — tác tử chỉ biết hàng đang trên đường, không biết hôm nay hay ngày mai mới đến. Hạn chế này được ghi nhận rõ trong phân tích hạn chế thực nghiệm (Mục 4.6).

Không gian hành động $a_i^t \in \{0, 1, \dots, K-1\}$: mỗi tác tử chọn một trong $K = 6$ mức đặt hàng rời rạc. Các mức này được định nghĩa tương đối theo quy mô nhu cầu của chính cặp i :

$$q_i(k) = \left\lceil m_k \cdot \bar{D}^{(i)} \cdot \bar{L} \right\rceil, \quad \mathbf{m} = (0, 0,5; 1; 2; 3; 5), \quad (3.1)$$

trong đó $\bar{D}^{(i)}$ là nhu cầu trung bình một ngày của cặp i ước lượng trên miền huấn luyện và $\bar{L} = 2$ là thời gian giao hàng trung bình. Lựa chọn này xuất phát từ đặc điểm dữ liệu: 73,4% số chuỗi M5 có nhu cầu dưới một đơn vị mỗi ngày, nên một thang mức đặt hàng tuyệt đối dùng chung sẽ khiến mức nhỏ nhất khác không đã tương đương hàng chục ngày nhu cầu đối với các mặt hàng bán chậm, trong khi lại quá nhỏ đối với các mặt hàng bán nhanh.

Bảng mức đặt hàng được ép tăng nghiêm ngặt theo k : mức k luôn lớn hơn mức $k-1$ ít nhất một đơn vị. Nếu không có ràng buộc này, phép làm tròn sẽ khiến nhiều hành động khác nhau cho cùng một lượng đặt hàng — với các cặp có $\bar{D}^{(i)}$ nhỏ, sáu mức có thể thu về chỉ còn hai giá trị phân biệt — và tác tử nhận các tín hiệu lợi thế mâu thuẫn cho những hành động trên thực tế là đồng nhất.

Không gian hành động chung của toàn hệ thống là tích Descartes $K^{300} = 6^{300}$, nhưng mỗi tác tử chỉ xử lý $K = 6$ hành động.

Hàm chuyển trạng thái diễn ra theo sáu bước theo đúng thứ tự thực thi trong môi trường mô phỏng:

1. **Ánh xạ hành động:** hành động $a_i^t \in \{0, \dots, 5\}$ của mỗi tác tử được ánh xạ sang lượng đặt hàng $q_i(a_i^t)$ qua bảng mức tương đối (3.1).
2. **Nhận hàng từ pipeline:** hàng đang vận chuyển ở vị trí 0 của pipeline (đến hạn ngày t) được nhập kho.
3. **Thực thi ràng buộc sức chứa:** nếu lượng hàng mới về kho w vượt chỗ trống còn lại $W_w - \sum_{j \in w} I^{(j)}$, phần vượt của *hàng mới về* bị từ chối, chia theo tỷ trọng hàng về của từng mặt hàng theo (3.3); tồn kho cũ không bị ảnh hưởng.
4. **Dịch pipeline và ghi đơn mới:** pipeline dịch trái một vị trí; đơn hàng mới được ghi vào vị trí $L-1$ với $L \sim \text{Uniform}\{1, 2, 3\}$ — đây là nguồn ngẫu

nhiên thứ nhất.

5. **Phát sinh nhu cầu:** nhu cầu $D_t^{(i)}$ lấy từ chuỗi M5 thực tế — đây là nguồn ngẫu nhiên thứ hai. Bán $\min(I_t^{(i)}, D_t^{(i)})$; phần thiếu bị mất hoàn toàn (lost sales).
6. **Cập nhật lịch sử và cửa sổ fill rate:** ghi nhận nhu cầu và lượng đáp ứng vào lịch sử 7 ngày; cập nhật fill rate cửa sổ trượt 30 ngày. Tính phần thưởng r_i^t và chuyển sang $t + 1$.

Tổng hợp các thành phần MDP. Bảng 3.2 đặt các khái niệm chung của học tăng cường cạnh thành phần cụ thể tương ứng trong hệ thống kho, và Hình 3.2 minh họa một vòng tương tác $s_t \rightarrow a_t \rightarrow r_t, s_{t+1}$ của một tác tử.


Bảng 3.2: Ánh xạ các thành phần MDP vào bài toán tồn kho đa kho

Thành phần	Nội dung cụ thể trong đề tài
Môi trường	Mô phỏng 10 kho $\times$ 30 mặt hàng trên nhu cầu M5 (MultiWarehouseInventoryEnv), một bước là một ngày, một episode là 365 ngày
Trạng thái / quan sát S	Vector $o_i^t \in [0, 1]^{43}$ của từng cặp: tồn kho, vị thế tồn kho, cầu 7 ngày, hàng đang về, fill rate 30 ngày, quy mô, mức đầy kho, tỷ trọng trong kho, lịch (Bảng 3.1)
Hành động A	$a_i^t \in \{0, \dots, 5\} \mapsto$ lượng đặt $q_i = m_k \bar{D}^{(i)} \bar{L}$, với $m = (0; 0,5; 1; 2; 3; 5)$
Chuyển trạng thái P	Sáu bước ở trên; hai nguồn ngẫu nhiên là thời gian giao $L \sim \mathcal{U}\{1, 2, 3\}$ và nhu cầu thực tế $D_t^{(i)}$
Phần thưởng R	$r_i^t = -(\text{chi phí lưu kho} + \text{thiếu hàng} + \text{đặt hàng} + \text{tràn kho} + \text{phạt mức phục vụ})$ của riêng cặp i , công thức (3.4)
Chính sách π	$\pi_\theta(a \mid o_i^t)$: mạng Actor dùng chung trọng số θ cho 300 tác tử; mỗi tác tử áp dụng lên quan sát của riêng mình
Hàm giá trị	$V_\phi(o_i^t)$: mạng Critic dùng chung, ước lượng chi phí tương lai kỳ vọng của cặp i
Hệ số chiết khấu	$\gamma = 0,99$ (tầm nhìn hiệu dụng khoảng 100 ngày, dài hơn nhiều so với thời gian giao hàng)

3.1.4 Ràng buộc sức chứa kho và cơ chế từ chối nhập hàng

Mỗi kho w có một sức chứa hữu hạn W_w dùng chung cho toàn bộ M mặt hàng đặt trong kho đó. Sức chứa được xác định theo số ngày nhu cầu mà kho có thể tích trữ:

$$W_w = \kappa \cdot \sum_{j=1}^M \bar{D}^{(w,j)}, \quad \kappa = 5,0 \text{ ngày}, \quad (3.2)$$



Hình 3.2: Vòng tương tác học tăng cường của một tác tử trong môi trường kho. Cả 300 tác tử chạy vòng này đồng thời mỗi ngày với cùng θ, ϕ .

trong đó $\bar{D}^{(w,j)}$ là nhu cầu trung bình một ngày của mặt hàng j tại kho w , ước lượng trên miền huấn luyện.

Điểm cần lưu ý là sức chứa được tính riêng cho từng kho, theo chính quy mô nhu cầu của kho đó, chứ không phải một hằng số dùng chung. Trong tập dữ liệu thực nghiệm, nhu cầu giữa các kho chênh lệch tới 4,5 lần (Bảng 3.3); nếu áp một sức chứa chung, kho lớn nhất chỉ tích trữ được khoảng 1,4 ngày nhu cầu trong khi thời gian giao hàng có thể lên tới ba ngày. Khi đó mục tiêu mức phục vụ 85% trở thành bất khả thi về mặt cấu trúc: không tồn tại chính sách nào tránh được đồng thời hình phạt tràn kho và hình phạt vi phạm mức phục vụ, và tín hiệu học suy biến thành nhiễu.

Bảng 3.3: Nhu cầu và sức chứa của từng kho trong cấu hình thực nghiệm

Kho	Cầu/ngày	W_w	Kho	Cầu/ngày	W_w
CA_3	223,0	1.114,6	TX_3	101,3	506,4
CA_1	121,2	606,1	CA_2	70,3	351,6
TX_2	114,0	570,1	TX_1	89,0	444,9
WI_2	51,5	257,4	WI_1	49,1	245,4
WI_3	99,2	495,9	CA_4	54,2	270,9

Ràng buộc được thực thi tại thời điểm *nhập hàng*. Gọi $A_t^{(i)}$ là lượng hàng của cặp i đến hạn giao trong ngày t và $F_t^{(w)} = \max(0, W_w - \sum_{j \in w} I_{t-1}^{(j)})$ là chỗ trống còn lại của kho w trước khi nhận hàng. Nếu tổng hàng mới về vượt chỗ trống, phần vượt bị từ chối nhập và chia cho từng mặt hàng theo tỷ trọng *hàng mới về* của mặt hàng đó:

$$O_t^{(i)} = A_t^{(i)} \cdot \max\left(0, 1 - \frac{F_t^{(w(i))}}{\sum_{j \in w(i)} A_t^{(j)}}\right). \quad (3.3)$$

Tồn kho cũ đang nằm hợp lệ trong kho không bao giờ bị giảm bởi bước này; chỉ mặt hàng vừa đặt nhiều mới chịu phần bị từ chối tương ứng. Phiên bản đầu của môi trường phân bổ phần vượt theo tỷ trọng *toàn bộ* tồn kho, khiến hàng cũ hợp lệ cũng bị loại bỏ không đúng — lỗi này đã được sửa và có kiểm thử hồi quy riêng. Cơ chế từ chối tại cửa nhập phản ánh đúng vận hành kho thực tế, khác với cách hủy hàng sau khi đã nhập — vốn khiến chi phí đặt hàng đã bỏ ra trở nên vô nghĩa và khó biện giải về mặt nghiệp vụ.

3.1.5 Cơ chế phối hợp giữa các tác tử

Khóa luận lựa chọn kiến trúc *phi tập trung hoàn toàn*: không có tác tử điều phối trung tâm, không có kênh truyền thông tường minh giữa các tác tử. Lựa chọn này là có chủ đích, xuất phát từ hai lý do.

Thứ nhất, về mặt nghiệp vụ, điểm ra quyết định đặt hàng lại trong vận hành kho là một mã hàng tại một kho: người phụ trách ngành hàng quyết định đặt bao nhiêu cho mặt hàng mình phụ trách, dựa trên tồn kho, lượng hàng đang về và lịch sử bán của chính mặt hàng đó. Việc phân rã thành 300 tác tử vì vậy đến từ cấu trúc bài toán chứ không phải từ mong muốn áp dụng mô hình đa tác tử.

Thứ hai, về mặt thuật toán, bổ sung một critic tập trung sẽ chuyển bài toán sang lớp phương pháp huấn luyện tập trung — thực thi phi tập trung (CTDE) như MAPPO [21], tức là thay đổi chính đối tượng nghiên cứu.


Sự phối hợp giữa các tác tử vì vậy diễn ra gián tiếp, qua hai kênh đã có sẵn trong thiết kế:

- Kênh quan sát: mỗi tác tử quan sát được tỷ lệ sử dụng sức chứa $u_t^{(w(i))}$ của kho mình thuộc về, nên biết khi nào kho sắp đầy.
- Kênh phần thưởng: hình phạt tràn kho theo công thức (3.3) được phân bổ theo tỷ trọng hàng mới về, nên tác tử đặt nhiều khi kho đã chật chịu phần phạt lớn hơn.

Ngoài hai kênh trên, việc chia sẻ trọng số θ là một kênh phối hợp ở thời điểm *huấn luyện*: kinh nghiệm của mọi tác tử cùng cập nhật một chính sách, nên điều một cặp học được (ví dụ giảm lô hàng khi kho gần đầy) có tác dụng ngay với các cặp khác. Cần phát biểu chính xác quan hệ giữa “độc lập” và “chia sẻ”: *mỗi tác tử ra quyết định riêng* từ quan sát riêng và nhận phần thưởng riêng, nhưng cả 300 tác tử *dùng chung một hàm chính sách* π_θ . Chia sẻ tham số không gộp 300 tác tử thành một tác tử trung tâm — không có thành phần nào nhìn thấy toàn bộ hệ thống hay quyết định thay cho

tác tử khác.

Hình 3.3 thể hiện kiến trúc đa tác tử đầy đủ: các tác tử, vai trò, đầu vào, đầu ra, chính sách dùng chung, môi trường dùng chung và các kênh tương tác. Điểm đáng chú ý là không có khối điều phối (coordinator): việc tổng hợp thông tin cấp kho (cộng tồn kho của 30 mặt hàng để tính mức đầy $u_t^{(w)}$) do môi trường thực hiện và phát lại vào quan sát của từng tác tử trong kho đó, chứ không do một tác tử tổng hợp nào.



Mỗi tác tử $A_{w,j}$: vai trò — quyết định lượng đặt cho mặt hàng j tại kho w ; đầu vào — quan sát o_i^t 43 chiều; đầu ra — mức đặt $a_i^t \in \{0, \dots, 5\}$. Không có coordinator và không trao đổi thông điệp trực tiếp; phối hợp gián tiếp qua (1) mức đầy kho $u_t^{(w)}$ do môi trường phát lại cho 30 tác tử cùng kho, (2) phát tràn kho khi cùng tranh sức chứa, (3) trọng số dùng chung khi huấn luyện.

Hình 3.3: Kiến trúc đa tác tử: 300 tác tử (kho w , mặt hàng j) dùng chung một chính sách, tương tác gián tiếp qua sức chứa kho

Bằng chứng thực nghiệm cho thấy tác tử đã học cách sử dụng tín hiệu sức chứa. Để giải mã hành vi ẩn, khóa luận quét lưới trạng thái trên một cặp đại diện: cố định tất cả chiều quan sát ở mức trung vị và chỉ thay đổi mức sử dụng sức chứa kho $u_t^{(w)}$ từ 20% lên 95%, rồi đọc lại phân phối hành động của chính sách. Kết quả: ngưỡng đặt hàng s (số ngày nhu cầu) gần như không đổi (1,348 ngày tại $u = 20\%$ so với 1,362 ngày tại $u = 95\%$), nhưng mức đặt tối đa S giảm từ 5,65 xuống 5,09 ngày và 4 cặp ngày đặt hàng hoàn toàn khi kho đạt 95% sức chứa. Nói cách khác, tác tử không thay đổi điều kiện kích hoạt đặt hàng mà chỉ thu hẹp lô hàng khi kho chật. Đây chính là dạng phối hợp nổi lên (emergent coordination) không được lập trình tường minh mà do tác tử tự học qua tín hiệu phần thưởng. Chính sách cổ điển như (s, S) không thể thực hiện hành vi này vì chúng không quan sát được trạng thái kho.

Bảng 3.4 tóm tắt đặc tả của một tác tử. Vì toàn bộ 300 tác tử đồng nhất về vai trò và chia sẻ chung một bộ trọng số, một bảng đặc tả duy nhất mô tả đầy đủ hệ thống.

Bảng 3.4: Đặc tả tác tử trong hệ thống đề xuất

Thành phần	Nội dung
Tác tử	Cặp (kho w , mặt hàng j); tổng cộng 300 tác tử đồng nhất
Vai trò	Quyết định lượng đặt hàng lại hằng ngày cho đúng một mặt hàng tại đúng một kho
Đầu vào	Vector quan sát cục bộ $o_i^t \in \mathbb{R}^{43}$
Quan sát	Tồn kho, vị thế tồn kho, nhu cầu 7 ngày gần nhất, hàng đang về theo từng ngày còn lại, fill rate cửa sổ 30 ngày, đặc trưng quy mô, tỷ lệ sử dụng kho, tỷ trọng tồn kho trong kho, thứ trong tuần, đặc trưng lịch
Nhiệm vụ	Tác vụ con của bài toán tổng “tối thiểu tổng chi phí vận hành toàn hệ thống dưới ràng buộc sức chứa và mức phục vụ”
Hành động	$a_i^t \in \{0, \dots, 5\}$, ánh xạ sang lượng đặt hàng theo (3.1)
Chính sách	$\pi_\theta(a \mid o)$ — mạng Actor dùng chung trọng số θ cho mọi tác tử
Đầu ra	Lượng đặt hàng $q_i(a_i^t)$ phát tới nhà cung cấp
Tương tác	Không truyền thông trực tiếp; phối hợp gián tiếp qua sức chứa kho dùng chung (Mục 3.1.5)

3.2 Thiết kế hàm phần thưởng

3.2.1 Phần thưởng phân rẽ cục bộ

Mỗi tác tử i nhận phần thưởng riêng dựa trên chi phí của chính cặp kho–mặt hàng mà nó quản lý, thay vì dùng chung phần thưởng toàn cục:

$$r_i^t = - \left(c_{lk} \cdot I_t^{(i)+} + c_{th} \cdot U_t^{(i)} + c_{dh} \cdot \mathbb{1}(a_i^t > 0) + p_{tk} \cdot O_t^{(i)} \right) - \phi_{dv} \cdot c_{th} \cdot \bar{D}^{(i)} \cdot \max(\tau - \text{FR}_t^{(i,w)}, 0) \quad (3.4)$$

trong đó:

- $I_t^{(i)+} = \max(I_t^{(i)}, 0)$: mức tồn kho dương.
- $U_t^{(i)} = \max(D_t^{(i)} - I_t^{(i)}, 0)$: lượng nhu cầu không được đáp ứng.
- $O_t^{(i)}$: lượng hàng tràn kho (phần vượt sức chứa).
- $\text{FR}_t^{(i,w)}$: tỷ lệ đáp ứng trên cửa sổ trượt $w = 30$ ngày.
- $\bar{D}^{(i)}$: nhu cầu trung bình một ngày của cặp i , ước lượng trên miền huấn

luyện (cùng đại lượng dùng trong bảng mức đặt hàng (3.1)).

- $\tau = 0,85$: ngưỡng mức phục vụ mục tiêu.

Ý nghĩa nghiệp vụ của từng thành phần. Chi phí lưu kho đại diện cho vốn bị giữ và chi phí mặt bằng; chi phí thiếu hàng là doanh thu và thiện chí khách hàng bị mất; chi phí đặt hàng là chi phí cố định mỗi lần phát đơn (xử lý đơn, vận chuyển); phạt tràn kho là hàng bị từ chối nhập vì kho đầy — tổn thất do đặt vượt khả năng chứa; phạt mức phục vụ thể hiện cam kết quản trị giữ tỷ lệ đáp ứng tối thiểu 85%. Hệ thống không có chuyển hàng giữa các kho nên hàm phần thưởng không chứa chi phí điều chuyển (Mục 1.3.3).

Vì sao phần thưởng luôn âm và cách đọc đúng. Vì $r_i^t = -(\text{tổng chi phí} + \text{phạt})$ và mọi thành phần chi phí đều không âm, phần thưởng *luôn* ≤ 0 : phần thưởng bằng 0 chỉ đạt được khi không lưu kho, không thiếu hàng và không đặt hàng — điều không thể xảy ra khi có nhu cầu. Phần thưởng âm vì vậy *không* có nghĩa là mô hình kém; thứ cần quan sát là *xu hướng*: phần thưởng tăng dần về phía 0 tương đương với tổng chi phí giảm dần. Tương tự, không tồn tại một khoảng phần thưởng “chuẩn” như $[0, 1]$ hay $[-1, 1]$: độ lớn tuyệt đối phụ thuộc vào đơn giá chi phí, quy mô nhu cầu của dữ liệu, số tác tử và độ dài episode. Chẳng hạn, tổng phần thưởng một episode 365 ngày của 300 tác tử nằm ở bậc hàng triệu đơn vị âm (Mục 4.4.1). Vì thế khóa luận chỉ đánh giá phần thưởng *tương đối trong cùng bài toán*: so với chính sách khởi tạo ngẫu nhiên, so giữa các giai đoạn huấn luyện, và quy đổi về chi phí vận hành để so với các chính sách cổ điển trên cùng thang đo.

Hai cách định cỡ hình phạt mức phục vụ. Trong công thức (3.4), hình phạt vi phạm mức phục vụ tỷ lệ với nhu cầu trung bình $\bar{D}^{(i)}$ của cặp. Toàn bộ kết quả ở Chương 4 dùng cách định cỡ này (cấu hình `service_penalty_mode: demand`). Phần kiểm tra phần thưởng bằng thực nghiệm (Mục 4.5.5) cho thấy nó khiến chính sách phân bổ mức phục vụ thấp hơn cho mặt hàng bán chậm. Vì vậy khóa luận cài đặt thêm biến thể *normalized*, trong đó hình phạt được nhân với chính mẫu số chuẩn hóa của cặp:

$$\text{phạt}_i^t = \phi_{dv} \cdot (c_{th}\bar{D}^{(i)} + c_{dh}) \cdot \max(\tau - \text{FR}_t^{(i,w)}, 0). \quad (3.5)$$

Sau khi chia cho mẫu số chuẩn hóa $c_{th}\bar{D}^{(i)} + c_{dh}$ (Mục 3.2.4), mọi cặp chịu *cùng một* mức phạt $\phi_{dv} \cdot \max(\tau - \text{FR}, 0)$ bất kể quy mô nhu cầu. Biến thể này là cấu hình chính của đợt thực nghiệm bổ sung (Mục 5.3).

3.2.2 Vai trò của thành phần phạt fill rate

Thành phần $\phi_{dv} \cdot c_{th} \cdot \bar{D}^{(i)} \cdot \max(\tau - \text{FR}_t^{(i,w)}, 0)$ bổ sung tín hiệu phạt ràng buộc (constraint penalty) theo tinh thần Lagrangian: thay vì chỉ phạt thiếu hàng tức thời (vốn có phương sai cao do nhu cầu gián đoạn), tỷ lệ đáp ứng trên cửa sổ trượt cung cấp đánh giá ổn định hơn về chất lượng phục vụ. Cần nhấn mạnh rằng hình phạt này không thuộc dạng chênh lệch thế năng của Ng và cộng sự [36], mà cố ý thay đổi cấu trúc phần thưởng của MDP gốc nhằm điều hướng chính sách tìm kiếm giải pháp thỏa mãn ràng buộc mức phục vụ kinh doanh.

Tích $c_{th} \cdot \bar{D}^{(i)}$ quy đổi độ hụt fill rate — một đại lượng không thứ nguyên trong $[0, 1]$ — về cùng thang đo tiền tệ với bốn thành phần chi phí còn lại (xấp xỉ chi phí thiếu hàng của một ngày hụt hoàn toàn ở mức nhu cầu trung bình của cặp i), để ϕ_{dv} đóng đúng vai trò một hệ số nhân thuần túy thay vì phải tự gánh cả việc quy đổi đơn vị. Cần lưu ý c_{th} ở đây luôn là *hằng số thiếu hàng chung* cho toàn hệ thống, không phải $c_{th}^{(i)}$ theo từng cặp dùng trong chi phí thiếu hàng thực (Mục 3.2.3): mục tiêu mức phục vụ 85% là một cam kết quản trị áp dụng đồng loạt, nên độ mạnh của hình phạt SLA không nên tỷ lệ theo đơn giá của riêng từng mặt hàng.

Cần phân biệt rõ hai thang chi phí trong báo cáo. **Thành phần phạt mức phục vụ $\phi_{dv}(\cdot)$ là tín hiệu định hướng học, không phải chi phí kế toán**: nó không được tính vào tổng chi phí vận hành báo cáo trong Chương 4. Mọi con số so sánh giữa các phương pháp đều dựa trên bốn thành phần chi phí thực phát sinh (lưu kho, thiếu hàng, đặt hàng, tràn kho), tương đương với chi phí mà doanh nghiệp thực sự phải trả. Khóa luận dùng thống nhất hai thuật ngữ:

$$C_t^{\text{vận hành}} = C_t^{\text{lưu kho}} + C_t^{\text{thiếu hàng}} + C_t^{\text{đặt hàng}} + C_t^{\text{tràn kho}} \quad (3.6)$$

là *tổng chi phí vận hành* (total operating cost), còn P_t là *hình phạt mức phục vụ* (service-level penalty), một thành phần định hình phần thưởng và không phải một loại chi phí thứ năm.

Ràng buộc mềm và kiểm tra tính khả thi. Mục tiêu nghiệp vụ được phát biểu dưới dạng bài toán có ràng buộc:

$$\min_{\pi} \mathbb{E} \left[\sum_t C_t^{\text{vận hành}} \right] \quad \text{thỏa mãn} \quad \text{FR} \geq 85\%. \quad (3.7)$$

Khóa luận *không* giải trực tiếp bài toán có ràng buộc này bằng một biến thể PPO có ràng buộc. Trong huấn luyện, ràng buộc được triển khai dưới dạng *ràng buộc mềm*:

tác tử tối đa $\mathbb{E}[\sum_t -(C_t + P_t)]$, với P_t tăng khi fill rate trượt xuống dưới ngưỡng. Tính khả thi được kiểm tra ở khâu chọn mô hình: checkpoint IPPO được chọn là checkpoint có chi phí vận hành thấp nhất trên miền validation *trong số các checkpoint đạt* $FR_{val} \geq 85\%$; các chính sách cổ điển được tinh chỉnh theo đúng tiêu chí đó (Mục 4.3).

3.2.3 Các tham số chi phí

Bảng 3.5 liệt kê các tham số chi phí sử dụng trong thực nghiệm.

Bảng 3.5: Tham số chi phí trong môi trường mô phỏng

Thành phần	Ký hiệu	Giá trị
Chi phí lưu kho	c_{lk}	1,0 /đơn vị/ngày
Chi phí thiếu hàng	c_{th}	10,0 /đơn vị
Chi phí đặt hàng	c_{dh}	5,0 /lần đặt
Phạt tràn kho	p_{tk}	5,0 /đơn vị tràn
Phạt vi phạm mức phục vụ	ϕ_{dv}	3,0
Ngưỡng fill rate	τ	85%
Cửa sổ fill rate	w	30 ngày

Lưu ý rằng với bộ tham số chi phí $c_{th} = 10,0$ và $c_{lk} = 1,0$, tỷ số chi phí thiếu hàng ngầm định mức phục vụ chu kỳ lý thuyết $\alpha \approx 90,9\%$. Do đó, ràng buộc fill rate $\beta \geq 85\%$ có khả năng rơi vào trạng thái không có hiệu lực (non-binding) trong quá trình thực nghiệm mô phỏng. Đây là một giả thuyết cần kiểm chứng qua kết quả huấn luyện.

3.2.4 Chuẩn hóa phần thưởng theo từng cặp

Phần thưởng thô của các cặp chênh lệch nhau tới bốn bậc độ lớn: một mặt hàng bán 0,2 đơn vị mỗi ngày phát sinh chi phí ngày ở mức đơn vị, trong khi mặt hàng bán 143 đơn vị mỗi ngày có thể phát sinh chi phí ngày lên tới hàng chục nghìn. Vì toàn bộ 300 tác tử dùng chung một mạng Critic, hàm giá trị phải khớp các mục tiêu trải trên dải rộng như vậy; khi đó hàm mất mát của Critic bị chi phối hoàn toàn bởi một nhóm cặp có quy mô lớn nhất, và gradient truyền về mạng bị lệch theo.

Khóa luận vì vậy chuẩn hóa phần thưởng của từng cặp theo một đơn vị chi phí đặc trưng của chính cặp đó:

$$\tilde{r}_t^{(i)} = \frac{r_t^{(i)}}{c_{th} \cdot \bar{D}^{(i)} + c_{dh}}, \quad (3.8)$$

trong đó mẫu số là chi phí tương ứng với một ngày vận hành xấu nhất điển hình của

cặp i : hết hàng trong suốt cả ngày, cộng thêm một lần phát đơn đặt hàng. Hằng số c_{dh} giữ cho mẫu số không tiến về không đối với những mặt hàng gần như không bán. Phép chuẩn hóa này chỉ thay đổi thang đo của tín hiệu học, không thay đổi thứ tự ưu tiên giữa các hành động của cùng một tác tử; toàn bộ chi phí báo cáo trong Chương 4 đều là chi phí gốc chưa chuẩn hóa.

Ảnh hưởng của thành phần này tới quá trình hội tụ được khảo sát tường minh trong Mục 4.5.2.

3.3 Kiến trúc mạng Actor–Critic chia sẻ tham số

3.3.1 Mạng *SharedActorCritic*

Toàn bộ 300 tác tử dùng chung một mạng nơ-ron duy nhất [18], gồm:

- Mạng Actor: hai lớp ẩn fully-connected, mỗi lớp 128 nơ-ron, hàm kích hoạt Tanh, kết thúc bằng một lớp tuyến tính xuất ra phân phối xác suất trên $K = 6$ mức đặt hàng (softmax).
- Mạng Critic: cấu trúc tương tự nhưng độc lập hoàn toàn về tham số, xuất ra giá trị $V(o_i)$.

Actor và Critic được cài đặt dưới dạng hai mạng tách rời, không dùng chung thân mạng. Quyết định này xuất phát từ một quan sát thực nghiệm cụ thể. Khi hai mạng dùng chung thân, độ lớn gradient sinh ra từ hàm mất mát giá trị vượt xa gradient sinh ra từ hàm mất mát chính sách — đo được trên chính môi trường của khóa luận là 28,13 so với 0,096, tức gấp khoảng 293 lần. Vì phép cắt chuẩn gradient (`clip_grad_norm`) áp cho toàn bộ tham số của mạng, mọi gradient bị nhân với cùng một hệ số $0,5/28,13 \approx 0,018$, khiến tốc độ học hiệu dụng của Actor tụt khoảng 55 lần so với giá trị đặt. Hệ quả quan sát được là entropy của chính sách đứng yên ở gần giá trị $\ln K$ của phân phối đều trong suốt giai đoạn đầu — nghĩa là Actor hầu như không học. Tách hai mạng và cắt gradient riêng cho từng mạng là cách khắc phục triệt để; hiện tượng này được khảo sát tường minh trong Mục 4.5.3.

- Ghi chú cài đặt: khởi tạo trực giao (orthogonal) với hệ số $\sqrt{2}$ cho các lớp ẩn, 0,01 cho lớp xuất của Actor và 1,0 cho lớp xuất của Critic; chuẩn hóa mục tiêu giá trị bằng trung bình và phương sai trượt.

Kiến trúc đầu vào nhận vector quan sát cục bộ o_i^t của một tác tử bất kỳ. Mỗi forward pass xử lý một batch gồm quan sát của nhiều tác tử cùng lúc. Số tham số cần học là hằng số, không phụ thuộc vào $N \times M$.

3.3.2 Quy trình huấn luyện IPPO

1. Thu thập dữ liệu (Rollout): Chạy $n_{\text{steps}} = 1024$ bước trong môi trường. Tại mỗi bước, tất cả 300 tác tử cùng chọn hành động, tổng cộng thu được $1024 \times 300 = 307.200$ mẫu (o_i, a_i, r_i, o'_i) mỗi vòng rollout.
2. Tính GAE: Ước lượng lợi thế $\hat{A}_t^{(i)}$ cho từng tác tử i sử dụng công thức GAE (2.7) với $\gamma = 0,99$ và $\lambda = 0,95$.
3. Chuẩn hóa lợi thế theo từng cặp (per-pair advantage normalization): Chuẩn hóa $\hat{A}_t^{(i)}$ theo trung bình và độ lệch chuẩn tính riêng cho mỗi cặp kho–mặt hàng i , giúp các cặp có quy mô chi phí khác nhau đóng góp cân bằng vào gradient.
4. Cập nhật PPO: Thực hiện tối đa $E = 4$ epoch tối ưu hóa hàm mục tiêu clipped (2.8) trên toàn bộ dữ liệu rollout, với cơ chế dừng sớm khi độ lệch KL xấp xỉ vượt $1,5 \times$ ngưỡng $\text{KL}_{\text{target}} = 0,02$. Tốc độ học Actor $\eta_a = 3 \times 10^{-4}$, Critic $\eta_c = 1 \times 10^{-3}$; cả hai được suy giảm tuyến tính theo tiến độ huấn luyện.
5. Lặp lại bước 1–4 trong 1000 episode. Toàn bộ quy trình được lặp lại độc lập trên 3 hạt giống huấn luyện ($\text{seed} \in \{42, 1, 2\}$) nhằm kiểm tra độ tin cậy thống kê của kết quả theo khuyến nghị của Henderson và cộng sự [28] (Mục 4.3.1).

Bảng 3.6 tóm tắt các siêu tham số chính.

3.4 Thiết kế môi trường mô phỏng

Môi trường được xây dựng theo chuẩn Gymnasium [24], kế thừa giao diện từ OpenAI Gym [33], cung cấp các phương thức `reset()` và `step(action)` chuẩn.

MultiWarehouseInventoryEnv quản lý:

- Ma trận tồn kho $\mathbf{I} \in \mathbb{R}^{N \times M}$.
- Hàng đợi giao hàng cho mỗi cặp (tracking lead time).
- Lịch sử nhu cầu và fill rate trượt.
- Hàm tính chi phí và phần thưởng (công thức 3.4).

Mỗi episode kéo dài 365 bước (tương đương 1 năm), phản ánh chu kỳ kinh doanh thực tế.

Khóa luận lựa chọn tự xây dựng môi trường MultiWarehouseInventoryEnv thay vì sử dụng các bộ thư viện benchmark sẵn có như OR-Gym [39] hay MABIM

Bảng 3.6: Siêu tham số huấn luyện

Nhóm	Tham số	Giá trị
Môi trường	$N \times M$ (số tác tử)	$10 \times 30 = 300$
	Episode length	365 ngày
	Lead time	[1, 3] ngày
	Bội số mức đặt hàng (m)	{0; 0,5; 1; 2; 3; 5}
PPO	Rollout steps (n_{steps})	1024
	PPO epochs (E)	4
	Learning rate Actor	3×10^{-4}
	Learning rate Critic	1×10^{-3}
	γ	0,99
	λ_{GAE}	0,95
	Clip ϵ	0,2
	Total episodes	1000 ($\times 3$ hạt giống)
Mạng	Hidden layers (mỗi mạng) Actor / Critic	2×128 hai mạng tách rời
	Activation	Tanh

[41]. Lý do chính là các benchmark hiện hành chưa hỗ trợ sẵn cấu hình mạng lưới gồm 10 kho song song độc lập về nguồn cung kết hợp đồng thời với ràng buộc sức chứa kho dùng chung giữa 30 SKU và cơ chế phạt tỷ lệ đáp ứng trên cửa sổ trượt. Việc tự phát triển môi trường đảm bảo khả năng kiểm soát toàn diện các tham số mô phỏng và tính tương thích với mục tiêu nghiên cứu của đề tài.

CHƯƠNG 4. THỰC NGHIỆM VÀ ĐÁNH GIÁ KẾT QUẢ

4.1 Cấu hình thực nghiệm

4.1.1 Môi trường phần cứng và phần mềm

Môi trường thực nghiệm được triển khai trên nền tảng Python với các thư viện cốt lõi: PyTorch (cài đặt mạng Actor–Critic và thuật toán PPO), Gymnasium [24] (giao diện môi trường mô phỏng), NumPy và Pandas (xử lý dữ liệu M5 và tính toán thống kê), SciPy (kiểm định thống kê).

Toàn bộ quá trình huấn luyện được thực hiện trên CPU, không sử dụng GPU. Kết quả báo cáo trong chương này dựa trên 3 lần huấn luyện độc lập (Mục 4.3.1), mỗi lần 1.000 episode và mất khoảng 38–40 phút, tổng cộng xấp xỉ 116 phút cho cả 3 hạt giống. Con số này đáng chú ý khi đối chiếu với các công trình cùng lĩnh vực: khung DC-STGN-MARL của Zhu và Wu [22] cần khoảng 36 giờ trên một GPU NVIDIA V100 cho một lần huấn luyện duy nhất. Sự chênh lệch đến từ lựa chọn thiết kế: khóa luận không sử dụng mô-đun dự báo nhu cầu bằng học sâu mà để tác tử học trực tiếp từ lịch sử nhu cầu thô trong vector quan sát.

4.1.2 Nguồn dữ liệu và tiền xử lý

Khóa luận sử dụng hai tệp chính từ bộ dữ liệu M5 [2], [3]: `sales_train_evaluation.csv` chứa 30.490 chuỗi doanh số theo ngày ($3.049 \text{ mặt hàng} \times 10 \text{ cửa hàng}$) trên 1.941 ngày, và `calendar.csv` chứa thông tin lịch, ngày lễ và các sự kiện trợ cấp thực phẩm SNAP.

Quy trình sàng lọc mặt hàng. Không phải mọi tổ hợp cửa hàng — mặt hàng đều tạo thành một bài toán đặt hàng lại. Trong bộ dữ liệu gốc có một tỷ lệ đáng kể các cặp mà cửa hàng trên thực tế không kinh doanh mặt hàng đó, thể hiện qua chuỗi doanh số gần như bằng không suốt toàn bộ giai đoạn. Đưa những chuỗi này vào tập huấn luyện không làm bài toán khó hơn mà chỉ bổ sung nhiễu vào gradient của mạng dùng chung. Khóa luận vì vậy chỉ giữ lại các mặt hàng có nhu cầu trung bình từ 0,2 đơn vị mỗi ngày trở lên tại ít nhất 80% số cửa hàng, tính trên miền huấn luyện. Từ 3.049 mặt hàng ban đầu, 1.762 mặt hàng vượt ngưỡng; trong số đó $M = 30$ mặt hàng được chọn theo phương pháp phân tầng trên ba nhóm ngành hàng (Foods, Hobbies, Household) nhằm bảo đảm dải quy mô nhu cầu trải rộng.

Bảng 4.1 so sánh đặc trưng của tập thực nghiệm với bộ dữ liệu gốc. Điểm cần lưu ý là tỷ lệ ngày không phát sinh giao dịch vẫn ở mức 57,4%: quy trình sàng lọc loại bỏ các chuỗi thoái hóa nhưng không làm mất đi tính gián đoạn — vốn là đặc trưng khiến bài toán trở nên khó và là một trong những lập luận nền của khóa luận.

Bảng 4.1: Đặc trưng nhu cầu của tập thực nghiệm so với bộ dữ liệu gốc

Chỉ tiêu	M5 gốc	Tập thực nghiệm
Số chuỗi (cặp kho–mặt hàng)	30.490	300
Nhu cầu trung bình (đv/ngày)	1,13	3,24
Trung vị nhu cầu (đv/ngày)	0,45	0,74
Tỷ lệ ngày bằng không	68,0%	57,4%
Cặp có nhu cầu $< 0,1$ đv/ngày	—	5/300

Tách miền thời gian. Chuỗi 1.941 ngày được chia theo trục thời gian thành ba miền không chồng lấn, mỗi miền có một vai trò cố định (Bảng 4.2). Mọi đại lượng ước lượng từ dữ liệu — nhu cầu trung bình $\bar{D}^{(i)}$ dùng cho bảng mức đặt hàng, sức chứa kho, mẫu số chuẩn hóa phần thưởng — chỉ lấy từ miền huấn luyện. Miền kiểm tra không được dùng để chọn mô hình, chỉnh phần thưởng hay tinh chỉnh baseline.

Bảng 4.2: Ba miền dữ liệu và vai trò của từng miền

Miền	Ngày	Được phép dùng để
Huấn luyện	[0, 1050)	Thu rollout và cập nhật PPO; ước lượng $\bar{D}^{(i)}$, sức chứa kho, mẫu số chuẩn hóa
Validation	[1050, 1450)	Chọn checkpoint IPPO; tinh chỉnh tham số baseline; so sánh các cấu hình huấn luyện
Kiểm tra (test)	[1450, 1941)	Chỉ báo cáo kết quả cuối; không dùng cho bất kỳ quyết định thiết kế nào

4.1.3 Thiết lập kịch bản mô phỏng

Lựa chọn $\kappa = 5,0$ được xác định bằng thực nghiệm. Với $\kappa = 3,0$, mức phục vụ cao nhất mà bất kỳ chính sách nào đạt được chỉ là 79,5% — mục tiêu 85% trở thành bất khả thi. Với $\kappa \geq 12,0$, chi phí tràn kho bằng không: ràng buộc không còn hiệu lực và bài toán suy biến thành 300 bài toán độc lập, mất đi bản chất đa tác tử. Tại $\kappa = 5,0$, mục tiêu 85% khả thi trong khi chi phí tràn kho vẫn chiếm khoảng 1–2% tổng chi phí, nghĩa là ràng buộc thực sự có hiệu lực.

Bảng 4.3: Cấu hình môi trường mô phỏng

Tham số	Giá trị
Số kho (N)	10
Số mặt hàng (M)	30
Số tác tử ($N \times M$)	300
Độ dài episode	365 ngày
Cửa sổ nhìn lại (w)	7 ngày
Lead time	Uniform{1, 2, 3} ngày
Bội số mức đặt hàng ($\mathbf{m}$)	{0; 0,5; 1; 2; 3; 5}
Sức chứa kho (κ)	5,0 ngày nhu cầu của từng kho
Ngưỡng fill rate (τ)	85%

4.2 Phương pháp đối chứng

Hiệu năng của IPPO được so sánh với ba chính sách tồn kho cổ điển: EOQ [12], (s, S) [13] và Newsvendor [14].

Điều kiện so sánh công bằng. Ba yếu tố được kiểm soát. Thứ nhất, tham số của cả ba chính sách được tối ưu bằng tìm kiếm lưới trên chính môi trường mô phỏng, ở *miền validation*, theo *cùng tiêu chí* dùng để chọn checkpoint IPPO: chi phí vận hành thấp nhất trong số các cấu hình đạt fill rate $\geq 85\%$; nếu không cấu hình nào đạt, chọn cấu hình có fill rate cao nhất. Thứ hai, các chính sách cổ điển truy cập cùng một tập thông tin với tác tử IPPO: nhu cầu trung bình và độ lệch chuẩn ước lượng từ miền huấn luyện, cùng lịch sử nhu cầu gần nhất. Thứ ba, cả bốn phương pháp chịu cùng ràng buộc rời rạc hóa: lượng đặt hàng mong muốn được làm tròn về mức gần nhất trong sáu mức của công thức (3.1).

Mỗi chính sách cổ điển được đánh giá ở hai phiên bản. Phiên bản thứ nhất dùng *một bộ tham số chung* cho cả 300 cặp. Phiên bản thứ hai dùng *một bộ tham số riêng cho mỗi nhóm quy mô nhu cầu* (bốn nhóm: dưới 0,5; 0,5–2; 2–10; từ 10 đơn vị mỗi ngày trở lên), được tìm bằng tìm kiếm theo tọa độ: xuất phát từ bộ tham số chung, lần lượt tối ưu tham số của từng nhóm trong khi giữ nguyên các nhóm khác, với cùng tiêu chí chi phí thấp nhất trong số cấu hình đạt fill rate $\geq 85\%$. Phiên bản theo nhóm là đối thủ mạnh hơn và sát với cách doanh nghiệp đặt chính sách theo nhóm hàng; nó được đưa vào để tránh so sánh IPPO — vốn điều chỉnh theo trạng thái của từng cặp — với một đối thủ bị giới hạn ở một bộ tham số duy nhất.

Ràng buộc thứ ba được giữ cho mọi phương pháp vì nó mô phỏng một ràng buộc vận hành chung: đơn bổ sung hàng được đặt theo một số lô chuẩn tỷ lệ với nhu

cầu trung bình của mặt hàng, chứ không theo số lượng tùy ý. Nếu chỉ IPPO bị giới hạn ở sáu mức còn baseline được đặt số lượng liên tục, hai bên sẽ khác nhau cả về không gian hành động lẫn thuật toán, và so sánh không còn cô lập được tác động của thuật toán. Hệ quả là các baseline có thể kém hơn phiên bản đặt số lượng tùy ý của chúng; khóa luận ghi nhận đây là một giới hạn của phép so sánh (Mục 4.6).

Bảng 4.4 liệt kê tham số tối ưu tìm được.

Bảng 4.4: Tham số tối ưu của các chính sách đối chứng sau tìm kiếm lưới

Chính sách	Tham số tối ưu
EOQ	$q_{\text{factor}} = 2,0; L = 3,0$
(s, S)	$\alpha = 0,70; q_{\text{factor}} = 0,5; L = 3,0$
Newsvendor	$CR = 0,85; L = 3,0$

Một quan sát đáng chú ý: tỷ số tới hạn lý thuyết của mô hình Newsvendor với bộ tham số chi phí đang dùng là $c_{th}/(c_{th} + c_{lk}) = 10/11 \approx 0,909$, nhưng tìm kiếm lưới cho giá trị tối ưu là 0,85 — thấp hơn nhưng không lệch quá xa lý thuyết. Chênh lệch còn lại không xuất phát từ sai lệch triển khai mà phản ánh một khác biệt khái niệm: tỷ số tới hạn cổ điển tối ưu cho *mức phục vụ chu kỳ* α trong bài toán một kỳ không có hàng đang về, trong khi môi trường ở đây là nhiều kỳ, có lượng hàng trên đường vận chuyển và ràng buộc sức chứa. Kết quả thực nghiệm này ủng hộ nhận định của Zipkin [15] rằng các chính sách cổ điển mất tính tối ưu đã được chứng minh trong bối cảnh mất đơn hàng.

4.3 Giao thức đánh giá

4.3.1 Quy trình đánh giá

Chính sách IPPO được đánh giá ở chế độ tắt định (chọn hành động có xác suất cao nhất) trên *toàn bộ quỹ đạo kiểm tra*: một lần chạy đi qua trọn 491 ngày của miền test ([1450, 1941)), với chuỗi nhu cầu cố định là nhu cầu thực tế của M5. Nguồn ngẫu nhiên duy nhất còn lại là thời gian giao hàng; lần chạy được lặp lại với 30 hạt giống ngẫu nhiên của thời gian giao hàng. Mọi chính sách chạy trên đúng cùng 30 hạt giống, nên mỗi hạt giống j cho một cặp quan sát $(C_j^{\text{IPPO}}, C_j^{\text{baseline}})$. Cách làm này thay cho giao thức cũ dùng 30 cửa sổ 365 ngày cắt từ một miền chỉ dài 491 ngày — các cửa sổ đó chồng lấn mạnh với nhau nên không thể coi là 30 quan sát độc lập.

Kiểm định thống kê được thực hiện trên hiệu số theo cặp $\Delta C_j = C_j^{\text{IPPO}} - C_j^{\text{baseline}}$: báo cáo hiệu trung bình kèm khoảng tin cậy 95%, kiểm định t theo cặp, kiểm

định hạng có dấu Wilcoxon và hệ số ảnh hưởng theo cặp $d_z = \overline{\Delta C}/s_{\Delta C}$. Các lần đánh giá của IPPO ở những hạt giống huấn luyện khác nhau không được gộp chung với các lần đánh giá baseline như những quan sát độc lập.

Theo khuyến nghị của Henderson và cộng sự [28] và Agarwal và cộng sự [29] về việc không nên suy luận từ một lần huấn luyện duy nhất, IPPO được huấn luyện độc lập trên 3 hạt giống huấn luyện ($\text{seed} \in \{42, 1, 2\}$) với cùng ngân sách 4.000 episode mỗi hạt giống. Checkpoint của từng hạt giống được chọn trên miền validation theo tiêu chí ở Mục 3.2.2, rồi đánh giá riêng trên miền test theo quy trình trên. Kết quả được báo cáo *theo từng hạt giống* (mỗi hạt giống một kiểm định theo cặp), sau đó tổng hợp bằng trung bình và độ lệch chuẩn *giữa các hạt giống*, cùng số hạt giống cho kết luận có ý nghĩa thống kê. Mọi thí nghiệm loại trừ (Mục 4.5) dùng hạt giống 42 và ngân sách 1.000 episode, được so với một lần chạy tham chiếu có cùng ngân sách, vì lịch giảm tốc độ học và hệ số entropy phụ thuộc vào tổng số episode.

4.3.2 Các chỉ số đánh giá


1. Tổng chi phí vận hành (công thức 3.6): tổng bốn thành phần chi phí thực phát sinh (lưu kho, thiếu hàng, đặt hàng, tràn kho) trên toàn quỹ đạo kiểm tra và 300 cặp. Thành phần phạt vi phạm mức phục vụ không được tính vào chỉ số này, vì nó là tín hiệu định hướng học chứ không phải chi phí kế toán.
2. Tỷ lệ đáp ứng nhu cầu (fill rate β): tỷ số giữa tổng lượng hàng bán được và tổng nhu cầu phát sinh trên cả episode.
3. Cơ cấu chi phí thành phần: dùng để nhận diện chiến lược mà mỗi phương pháp áp dụng.
4. Đường cong học: phần thưởng, fill rate, entropy của chính sách và explained variance của Critic qua các episode huấn luyện.

4.4 Kết quả thực nghiệm

4.4.1 Quá trình huấn luyện và tính hội tụ

Hình 4.1 trình bày bốn chỉ số theo dõi quá trình huấn luyện của hạt giống $\text{seed} = 42$, đại diện cho hình dạng đường cong học chung của cả 3 hạt giống (Mục 4.3.1).

Phần thưởng tăng từ $-16,99$ triệu ở episode đầu lên ổn định quanh $-1,69$ triệu (trung bình 200 episode cuối, dao động trong khoảng $-1,76$ đến $-1,64$ triệu) sau khoảng 600 episode, tức giảm khoảng 90% tổng chi phí so với chính sách khởi tạo



Hình 4.1: Diễn biến huấn luyện qua 1.000 episode (hạt giống 42): (a) phần thưởng tích lũy; (b) tỷ lệ đáp ứng nhu cầu; (c) entropy của chính sách; (d) explained variance của Critic

ngẫu nhiên. Sau điểm hội tụ, đường cong không sụp đổ — đặc tính mong đợi của cơ chế mục tiêu bị chặn (clipped objective) trong PPO.

Hai chỉ số còn lại xác nhận rằng cả hai nửa của thuật toán đều thực sự học. Entropy của chính sách giảm từ 1,778 — gần đúng giá trị $\ln 6 = 1,792$ của phân phối đều trên sáu hành động — xuống 0,182 ở episode cuối, nghĩa là chính sách đã định hình rõ rệt thay vì còn chọn ngẫu nhiên. Explained variance của Critic tăng nhanh từ khoảng 0 lên trên 0,7 trong 100 episode đầu, sau đó dao động trong khoảng 0,70–0,87 (trung bình 0,77 ở 200 episode cuối), nghĩa là hàm giá trị giải thích được phần lớn phương sai của phần thưởng tích lũy thực tế trong suốt phần còn lại của quá trình huấn luyện. Độ lệch KL xấp xỉ ở episode cuối là $2,4 \times 10^{-4}$, nằm sâu dưới ngưỡng 0,02, cho thấy chính sách đã ổn định chứ không còn dao động mạnh giữa các lần cập nhật.

Tỷ lệ đáp ứng vượt ngưỡng mục tiêu 85% ngay từ khoảng episode 66 và duy trì ổn định quanh 90% (trung bình 300 episode cuối) trong suốt phần còn lại. Hai hạt giống còn lại ($\text{seed} \in \{1, 2\}$) kết thúc huấn luyện với entropy trong khoảng 0,159–0,178 và explained variance trong khoảng 0,73–0,78 — cùng bậc độ lớn với hạt giống 42 — nên các kết luận trên không phụ thuộc vào một lần khởi tạo ngẫu nhiên cụ thể.

4.4.2 So sánh trực tiếp với các chính sách cổ điển

Bảng 4.5 trình bày kết quả gộp trên 3 hạt giống huấn luyện $\times$ 30 episode đánh giá (90 lần đánh giá cho IPPO); ba chính sách đối chứng là tất định nên không đổi theo hạt giống huấn luyện, kết quả của chúng là trung bình trên đúng 30 episode đánh giá.

Bảng 4.5: Kết quả trên miền đánh giá (trung bình $\pm$ độ lệch chuẩn; IPPO trên 90 lần đánh giá gộp 3 hạt giống, baseline trên 30 episode). Chi phí tính bằng đơn vị tiền của mô hình.

Phương pháp	Tổng chi phí	Fill rate	Lưu kho	Thiếu hàng	Đặt hàng	Tràn kho
IPPO	1.594.686 ± 21.370	90,53% $\pm 0,18\%$	1.108.082	325.438	125.934	35.232
(s, S)	1.520.337 ± 14.634	84,13% $\pm 0,27\%$	807.198	545.684	149.203	18.252
Newsvendor	1.545.816 ± 13.801	84,40% $\pm 0,26\%$	808.608	536.469	184.572	16.166
EOQ	1.779.966 ± 11.244	74,76% $\pm 0,20\%$	789.953	868.000	92.864	29.148


Ở phép so sánh trực tiếp này — không kiểm soát mức phục vụ — IPPO **không** còn chiếm ưu thế Pareto như kết quả sơ bộ ở một hạt giống huấn luyện đơn lẻ từng cho thấy trước khi khóa luận kiểm chứng lại trên 3 hạt giống độc lập (Mục 4.3.1). So

với chính sách đối chứng tốt nhất theo tiêu chí chi phí thuần túy là (s, S) , IPPO đắt hơn 4,89% trung bình gộp (4,55–5,50% tùy hạt giống), đắt hơn Newsvendor 3,16%, nhưng vẫn rẻ hơn EOQ 10,41%. Đổi lại, tỷ lệ đáp ứng của IPPO cao hơn (s, S) và Newsvendor khoảng 6 điểm phần trăm và cao hơn EOQ gần 16 điểm phần trăm. Nói cách khác, ở điểm vận hành mà mỗi phương pháp tự chọn (baseline tối thiểu chi phí, IPPO tối thiểu chi phí dưới ràng buộc mức phục vụ 85%), bốn phương pháp nằm ở bốn điểm khác nhau trên đường đánh đổi chi phí — mức phục vụ, và IPPO trả một khoản phụ phí chi phí vừa phải để đổi lấy mức phục vụ cao hơn đáng kể chứ không tốt hơn baseline đồng thời trên cả hai tiêu chí.

Kiểm định thống kê xác nhận khác biệt về chi phí không phải do ngẫu nhiên, theo đúng chiều mới này: gộp 90 lần đánh giá của IPPO so với (s, S) , kiểm định t Welch cho $t = 21,27$ với $p = 5,45 \times 10^{-33}$; hệ số ảnh hưởng Cohen's $d = 4,06$, thuộc mức rất lớn theo phân loại thông dụng. Tính riêng theo từng hạt giống, cả ba lần huấn luyện độc lập đều cho $p < 10^{-18}$ và cùng chiều IPPO đắt hơn (s, S) (seed 42: +4,55%; seed 1: +4,63%; seed 2: +5,50%), nên kết luận này không phải hiện tượng ngẫu nhiên của một lần huấn luyện. Vì mỗi episode của IPPO và của baseline dùng *cùng* một hạt giống môi trường (cùng chuỗi nhu cầu, cùng thời gian giao hàng ngẫu nhiên), kiểm định *theo cặp* phù hợp hơn kiểm định Welch. Kiểm định t theo cặp cho cùng kết luận ở cả ba hạt giống: t từ 17,9 đến 26,7, $p < 10^{-16}$, hệ số ảnh hưởng theo cặp d_z từ 3,3 đến 4,9, và IPPO đắt hơn (s, S) ở cả 30/30 episode của mỗi hạt giống. Vì đây là phép so sánh chưa kiểm soát mức phục vụ, phép so sánh chặt chẽ hơn ở Mục 4.4.4 mới là căn cứ để trả lời Câu hỏi nghiên cứu 1.

4.4.3 Phân tích cơ cấu chi phí

Hình 4.2 và cơ cấu chi phí trong Bảng 4.5 cho thấy IPPO học được một chiến lược khác về chất so với ba chính sách cổ điển.



Hình 4.2: So sánh bốn phương pháp trên miền đánh giá: (a) tổng chi phí vận hành; (b) tỷ lệ đáp ứng nhu cầu; (c) cơ cấu chi phí thành phần

IPPO giữ mức tồn kho cao hơn hẳn — chi phí lưu kho 1.108.082 so với 807.198 của (s, S) , tức cao hơn 37,3% — và dùng mức tồn kho đó để cắt giảm chi phí thiếu hàng, từ 545.684 xuống 325.438, tức giảm 40,4%. Khác với kết quả sơ bộ ở một hạt giống huấn luyện, phần tăng thêm ở lưu kho lần này lớn hơn phần tiết kiệm được ở thiếu hàng về giá trị tuyệt đối, nên tổng chi phí của IPPO cao hơn (s, S) ở điểm vận hành mà mỗi phương pháp tự chọn. Nói cách khác, tác tử đã đẩy chiến lược “tích trữ nhiều hơn để giảm thiếu hàng” đi xa hơn mức tối ưu về chi phí thuần túy, đúng như thiết kế của thành phần phạt mức phục vụ (Mục 3.2.2): tác tử được thưởng vì mức phục vụ cao chứ không phải vì chi phí thấp nhất tuyệt đối.

Chiến lược này vẫn khả thi vì tác tử biết được giới hạn của mình. Chi phí trần kho của IPPO là 35.232, tức khoảng 2,2% tổng chi phí — cao hơn các chính sách cổ điển nhưng không bùng nổ dù mức tồn kho trung bình đã tăng đáng kể. Điều này cho thấy tác tử vẫn duy trì mức tồn kho sát trần sức chứa mà không vượt qua một cách mất kiểm soát, tức vẫn sử dụng được tín hiệu $u_t^{(w(i))}$ trong vector quan sát dù chiến lược tổng thể đã thay đổi so với kết quả sơ bộ. Đây là bằng chứng cho hiệu lực của cơ chế phối hợp gián tiếp mô tả ở Mục 3.1.5, độc lập với việc chiến lược đó có tối ưu về chi phí tuyệt đối hay không.

Về tần suất đặt hàng, IPPO phát trung bình 25.187 đơn trên một episode, ít hơn (s, S) (29.841 đơn) và ít hơn đáng kể Newsvendor (36.914 đơn), trong khi vẫn đạt mức phục vụ cao hơn cả hai — duy chỉ EOQ phát ít đơn hơn (18.573) nhưng đổi lại có mức phục vụ thấp nhất. Như vậy, mức phục vụ cao hơn của IPPO không đến từ việc đặt hàng thường xuyên hơn, mà đến từ việc giữ mức tồn kho đệm cao hơn cho mỗi lần đặt; đây chính là nguồn gốc của khoản chi phí lưu kho tăng thêm nói trên.

4.4.4 So sánh ở cùng mức phục vụ

So sánh tổng chi phí giữa hai chính sách có mức phục vụ khác nhau là một phép so sánh không đầy đủ — đây chính xác là hạn chế của phép so sánh trực tiếp ở Mục 4.4.2. IPPO chịu hình phạt khi fill rate xuống dưới ngưỡng τ nên dịch chuyển tới mức phục vụ 90,57% (hạt giống 42, dùng làm đại diện cho phân tích này), trong khi ba chính sách đối chứng được tìm kiếm lưới với mục tiêu tối thiểu chi phí nên dừng lại ở 75–84%. Bốn phương pháp vì vậy nằm ở bốn điểm khác nhau trên đường đánh đổi chi phí — mức phục vụ, và bảng so sánh trực tiếp không kiểm soát yếu tố này nên chưa đủ căn cứ để kết luận phương pháp nào ưu việt hơn.

Để loại bỏ yếu tố này, khóa luận thực hiện thêm một so sánh ở cùng mức phục vụ: với mỗi chính sách đối chứng, tìm kiếm lưới trên miền huấn luyện được lặp lại với

ràng buộc fill rate $\geq 90,07\%$ (bằng mức của IPPO trừ sai số cho phép 0,5 điểm phần trăm), chọn cấu hình rẻ nhất trong số các cấu hình thỏa mãn, rồi đánh giá lại trên miền đánh giá.


Bảng 4.6: So sánh ở cùng mức phục vụ: cấu hình rẻ nhất của mỗi chính sách đối chứng đạt fill rate $\geq 90,07\%$ (hạt giống 42)

Phương pháp	Tổng chi phí	Fill rate	So với IPPO	Cấu hình
IPPO	1.589.472	90,57%	—	—
(s, S)	1.770.256	89,95%	-10,2%	$\alpha = 0,95; q_f = 0,5; L = 3,0$
Newsvendor	1.856.657	90,57%	-14,4%	$CR = 0,99; L = 3,0$
EOQ	không cấu hình nào đạt được mức phục vụ này			

Kết quả ở Bảng 4.6 đảo ngược hoàn toàn kết luận của phép so sánh trực tiếp. Khi buộc phải đạt cùng mức phục vụ khoảng 90%, chi phí của (s, S) tăng đáng kể từ 1,52 triệu (Bảng 4.5) lên 1,77 triệu, và của Newsvendor tăng từ 1,55 lên 1,86 triệu; trong khi đó IPPO không cần thay đổi gì vì mức phục vụ 90,57% vốn là điểm vận hành nó tự chọn. Ở cùng mức phục vụ, IPPO trở thành phương án rẻ nhất: rẻ hơn (s, S) 10,2% và rẻ hơn Newsvendor 14,4%. Riêng EOQ không có cấu hình nào trong lưới tìm kiếm đạt được mức phục vụ 90,07% — do cấu trúc lượng đặt hàng cố định không cho phép phản ứng với biến động nhu cầu. Như vậy, kết luận về việc phương pháp nào “tốt hơn” phụ thuộc căn bản vào việc có kiểm soát mức phục vụ hay không: xét thuần chi phí tại điểm vận hành mặc định của mỗi phương pháp (Mục 4.4.2), IPPO đắt hơn (s, S) ; xét ở cùng mức phục vụ, IPPO rẻ hơn đáng kể. Khóa luận coi phép so sánh ở cùng mức phục vụ là căn cứ phù hợp hơn để trả lời Câu hỏi nghiên cứu 1, vì nó loại bỏ được sai lệch do các phương pháp tối ưu cho hai mục tiêu khác nhau (Mục 1.3.2).

Hình 4.3 biểu diễn trực quan cả hai phép so sánh trên cùng một mặt phẳng chi phí — mức phục vụ.

Nguyên nhân của khoảng cách này nằm ở cơ chế điều chỉnh của các chính sách cổ điển. Chúng chỉ có một cơ chế duy nhất để nâng mức phục vụ: nâng tham số an toàn — tăng α hoặc CR — và tham số đó áp dụng đồng loạt cho cả 300 cặp. Hệ quả là tồn kho tăng ở mọi mặt hàng, kể cả những mặt hàng vốn đã đạt mức phục vụ tốt. IPPO điều chỉnh theo từng trạng thái quan sát được, do đó có thể nâng mức phục vụ ở những cặp có nhu cầu cấp thiết mà không tích trữ thừa ở những cặp không cần.



Hình 4.3: Đường đánh đổi chi phí — mức phục vụ. Dấu chữ thập xám: cấu hình tối thiểu chi phí; dấu tròn: cấu hình ở cùng mức phục vụ với IPPO

4.5 Phân tích chuyên sâu

4.5.1 Hiệu năng theo nhóm quy mô nhu cầu (Câu hỏi 2)

Một bộ trọng số duy nhất điều khiển đồng thời 300 cặp có quy mô nhu cầu trải từ dưới 0,1 đến gần 143 đơn vị mỗi ngày. Tỷ lệ đáp ứng 90,5% ở cấp hệ thống là một con số có trọng số theo nhu cầu, nên nó chưa cho biết chính sách có hoạt động đồng đều trên mọi nhóm quy mô hay không. Để trả lời, 300 cặp được chia thành bốn nhóm theo $\bar{D}^{(i)}$ và các chỉ số được tính riêng cho từng nhóm (Bảng 4.7, hạt giống 42). Chi phí trong bảng là chi phí cục bộ trung bình mỗi cặp mỗi episode — cùng đại lượng mà tác tử thực sự tối ưu hóa, công thức (3.4) — nên bao gồm cả thành phần định hướng mức phục vụ ϕ_{dv} , khác với chi phí vận hành thuần túy đã báo cáo ở Bảng 4.5.

Bảng 4.7: Hiệu năng theo nhóm quy mô nhu cầu trên miền đánh giá (hạt giống 42). Chi phí cục bộ (gồm thành phần định hướng mức phục vụ) tính trung bình cho mỗi cặp trong một episode.

Nhóm ($\bar{D}$, đv/ngày)	Số cặp	Fill rate		Chi phí/cặp	
		IPPO	(s, S)	IPPO	(s, S)
Rất thấp (< 0,5)	105	70,5%	82,2%	2.020	1.964
Thấp (0,5–2)	126	81,0%	84,7%	3.114	3.005
Trung bình (2–10)	54	90,2%	83,6%	7.125	8.102
Cao (≥ 10)	15	96,8%	84,4%	47.312	57.710

Kết quả cho thấy sự phân hóa còn rõ rệt hơn so với kết quả sơ bộ ở một hạt giống huấn luyện, được phân tích chi tiết dưới đây.

Trên hai nhóm có nhu cầu từ 2 đơn vị mỗi ngày trở lên, IPPO đạt kết quả tốt hơn (s, S) trên *cả hai* tiêu chí: fill rate cao hơn 6,6 điểm phần trăm ở nhóm trung bình và 12,4 điểm ở nhóm cao, đồng thời rẻ hơn 12,1% ở nhóm trung bình và 18,0% ở nhóm cao. Đây chính là nơi tạo ra phần lớn lợi thế chi phí của IPPO ở phép so sánh cùng mức phục vụ (Mục 4.4.4), vì các cặp có nhu cầu lớn đóng góp phần lớn tổng chi phí hệ thống.

Ngược lại, ở hai nhóm nhu cầu thấp và rất thấp, IPPO vừa đạt mức phục vụ thấp hơn (s, S) (rất thấp: 70,5% so với 82,2%, chênh 11,7 điểm; thấp: 81,0% so với 84,7%) vừa có chi phí cục bộ nhỉnh hơn một chút (2,8% và 3,6%). Đây là sự phân hóa rõ hơn so với kết quả sơ bộ trước đó, trong đó IPPO chỉ thua kém về fill rate nhưng vẫn nhỉnh hơn về chi phí ở nhóm thấp nhất.

Diễn giải của hiện tượng này mang tính kinh tế nhiều hơn là kỹ thuật. Với một mặt hàng bán 0,3 đơn vị mỗi ngày, chi phí một lần phát đơn ($c_{dh} = 5$) xấp xỉ chi phí thiếu hàng của gần hai ngày bán ($c_{th} \cdot \bar{D} = 3$ mỗi ngày). Việc duy trì mức phục vụ cao cho nhóm này đòi hỏi đặt hàng thường xuyên với lô rất nhỏ, và tổng chi phí phát sinh vượt phần tổn thất do thiếu hàng. Tác tử — vốn tối thiểu hóa chi phí — có xu hướng hạ mức phục vụ ở nhóm bán chậm, điều này phù hợp với mục tiêu tối ưu hóa chi phí mà thuật toán huấn luyện theo đuổi. Nói cách khác, chênh lệch không phải là dấu hiệu chia sẻ tham số thất bại ở nhóm bán chậm, mà là hệ quả của việc hai phương pháp theo đuổi hai mục tiêu khác nhau: (s, S) được tham số hóa quanh một mức phục vụ mục tiêu, còn IPPO tối thiểu hóa chi phí dưới ràng buộc mức phục vụ ở cấp hệ thống.

Hệ quả cần ghi nhận nằm ở cách định cỡ thành phần phạt mức phục vụ. Hình phạt được tính theo fill rate của *từng cặp*, nhưng nhân với nhu cầu trung bình $\bar{D}^{(i)}$ của cặp đó (công thức 3.4), nên với một mặt hàng bán 0,3 đơn vị mỗi ngày, hụt mức phục vụ 10 điểm phần trăm chỉ bị phạt $3 \cdot 10 \cdot 0,3 \cdot 0,1 = 0,09$ đơn vị mỗi ngày — nhỏ hơn nhiều so với một lần đặt hàng. Trong khi đó, fill rate hệ thống là trung bình có trọng số theo khối lượng, nên tác tử vẫn đạt mục tiêu chung bằng cách phục vụ tốt nhóm bán nhanh và hạ mức phục vụ ở nhóm bán chậm (Mục 4.5.5 định lượng hiện tượng này trên phân bố fill rate của từng cặp). Nếu bài toán nghiệp vụ yêu cầu bảo đảm mức phục vụ tối thiểu cho từng mặt hàng, hình phạt cần được định cỡ độc lập với quy mô nhu cầu hoặc chuyển thành ràng buộc cứng ở cấp cặp. Đây là một hạn chế thiết kế đã xác định, không xuất phát từ sai lệch triển khai.

Cuối cùng, cần nói rõ phạm vi của kết luận này. Phân tích trên chứng minh chính sách chia sẻ tham số thích ứng được với các quy mô nhu cầu khác nhau đã gặp trong huấn luyện. Câu hỏi mạnh hơn — liệu chính sách có áp dụng được cho những mặt hàng chưa từng xuất hiện trong huấn luyện hay không — đòi hỏi một thí nghiệm tách tập mặt hàng riêng, hiện chưa được thực hiện.

Thí nghiệm này đòi hỏi huấn luyện lại trên một cấu hình mặt hàng khác nên được đưa vào hướng phát triển (Mục 5.3).

4.5.2 Thiết kế tín hiệu phần thưởng (Câu hỏi 3)

Thiết kế. Câu hỏi 3 được trả lời bằng hai thí nghiệm loại trừ, cùng hạt giống 42, cùng mạng, cùng tốc độ học, cùng ngân sách 1.000 episode và cùng môi trường như lần chạy tham chiếu:

- **Phần thưởng toàn cục** (`reward_mode: global`): mọi tác tử nhận cùng một tín hiệu là tổng phần thưởng của cả mạng lưới R_t^{team} (công thức 2.9), chia cho tổng mẫu số chuẩn hóa của các cặp để giữ cùng thang đo. Thí nghiệm này so sánh trực tiếp phần thưởng cục bộ với phần thưởng toàn cục.
- **Không chuẩn hóa theo cặp** (`normalize_reward_per_pair: false`): phần thưởng cục bộ của mọi cặp được chia cho cùng một hằng số, nên cặp có nhu cầu lớn chi phối tín hiệu học.

Hai thí nghiệm trả lời hai khía cạnh khác nhau của cùng câu hỏi thiết kế phần thưởng và không thay thế cho nhau.

Kết quả sơ bộ. Một lần chạy loại trừ đã được tiến hành với cách định cỡ phạt mức phục vụ đang dùng trong chương này. Lần chạy được dừng ở khoảng episode 625 để chuyển sang đợt thực nghiệm cuối, nên kết quả dưới đây chỉ mang tính sơ bộ. So trên cùng khoảng episode 397–446 (trung bình 50 episode) với lần huấn luyện gốc của cùng hạt giống:

- Tổng chi phí mỗi episode: 5,80 triệu khi không chuẩn hóa, so với 1,84 triệu khi chuẩn hóa theo cặp — cao gấp khoảng 3,2 lần.
- Fill rate khi huấn luyện: 80,7% so với 90,5%, tức chưa đạt ngưỡng 85%.
- Entropy chính sách: 0,61 so với 0,27; chính sách còn gần ngẫu nhiên hơn nhiều.
- Explained variance của Critic: 0,997 so với 0,725.

Chỉ số cuối cùng đáng chú ý nhất. Critic khi không chuẩn hóa giải thích *gần như toàn bộ* phương sai của return, nhưng chính sách lại học kém hơn nhiều. Điều này khớp với lập luận thiết kế ở Mục 3.2.4: khi return của các cặp chênh nhau nhiều bậc độ lớn, phương sai tổng bị chi phối bởi vài cặp nhu cầu lớn. Critic chỉ cần khớp tốt các cặp đó là đạt explained variance cao, trong khi lợi thế (advantage) của đa số cặp bán chậm gần như chỉ còn là nhiễu. Kết quả sơ bộ vì vậy ủng hộ giả thuyết của Câu hỏi 3. Làn chạy đầy đủ 1.000 episode (cùng lịch học với mốc tham chiếu) nằm trong đợt thực nghiệm bổ sung (Mục 5.3).

4.5.3 Vai trò của việc tách Actor và Critic

Bằng chứng cho quyết định tách Actor và Critic hiện đến từ phiên bản phát triển đầu tiên của môi trường (dùng chung thân mạng), trong đó gradient của hàm mất mát giá trị lớn gấp khoảng 293 lần gradient chính sách và entropy đứng yên gần $\ln 6 = 1,792$ trong giai đoạn đầu (Mục 3.3.1). Sau khi tách, entropy giảm đều từ 1,778 xuống 0,182 (Mục 4.4.1). Tuy nhiên, hai quan sát này đến từ hai phiên bản môi trường khác nhau, nên chưa phải là một thí nghiệm loại trừ có kiểm soát. Chạy lại nhánh dùng chung thân mạng trên đúng cấu hình 300 cặp hiện tại đòi hỏi bổ sung một chế độ mạng mới vào tác tử và được đưa vào hướng phát triển.

4.5.4 Thực nghiệm B: hiệu năng theo giai đoạn nhu cầu

Toàn bộ các kết quả ở trên (gọi chung là *thực nghiệm A*) lấy trung bình trên cả episode 365 ngày. Trung bình dài hạn có thể che khuất một câu hỏi quan trọng: chính sách cổ điển có tốt hơn khi nhu cầu ổn định, và học tăng cường có lợi thế rõ hơn khi nhu cầu thay đổi nhanh hay không? Thực nghiệm B tách kết quả theo loại ngày, không huấn luyện lại, chỉ đánh giá chính sách đã có trên miền test (`scripts/regime_analysis.py`).

Thiết kế. Ngày trong miền test được gán nhãn theo hai cách:


- **Mức biến động:** với mỗi ngày t và mỗi kho w , tính độ lệch $|D_t^{(w)} / \overline{D}_{28}^{(w)} - 1|$ giữa tổng nhu cầu của kho và trung bình 28 ngày trước đó, rồi lấy trung bình trên 10 kho. Chia tam phân vị: *ổn định* ($\leq 20,3\%$), *trung bình*, *biến động* ($> 30,8\%$), mỗi nhóm khoảng 164 ngày.
- **Lịch:** ngày có sự kiện (43 ngày), ngày SNAP (240), cuối tuần (141), mùa lễ tháng 11–12 (61) và ngày thường (không sự kiện, không SNAP, không cuối tuần; 164 ngày).

Ngoài giai đoạn tự nhiên, thực nghiệm còn tạo **sốc cầu nhân tạo**: nhân toàn bộ nhu cầu của 28 ngày (ngày 1650–1677) với 1,5 (tăng đột biến) hoặc 0,5 (sụt giảm), rồi đo fill rate và chi phí trong 28 ngày trước, trong và sau cú sốc. Mỗi cấu hình chạy 30 episode với cùng 30 hạt giống. Bên cạnh ba baseline tinh chỉnh trực tiếp, thực nghiệm dùng thêm hai baseline đã chỉnh về *cùng mức phục vụ* với IPPO (Bảng 4.6), vì chỉ khi fill rate tương đương thì so sánh chi phí mới công bằng.

Thực nghiệm B và Mục 4.5.5 dùng checkpoint của hạt giống 42 được huấn luyện tiếp tới khoảng 4.083 episode. Kết quả đánh giá trực tiếp của checkpoint này được báo cáo ở Mục 4.6.

Bảng 4.8: Thực nghiệm B1: fill rate và chi phí vận hành trung bình mỗi ngày theo giai đoạn nhu cầu (30 episode, miền test). Cột cuối là chênh lệch chi phí của IPPO so với (s, S) cùng mức phục vụ (âm là IPPO rẻ hơn).

Giai đoạn	IPPO		(s, S) trực tiếp		(s, S) cùng mức PV		Chênh
	Fill	CP/ngày	Fill	CP/ngày	Fill	CP/ngày	
Ổn định	90,8%	3.857	87,2%	3.764	92,1%	4.534	−14,9%
Trung bình	90,3%	3.948	85,2%	4.005	90,9%	4.693	−15,9%
Biến động	88,4%	4.620	79,9%	4.725	86,9%	5.320	−13,2%
Ngày có sự kiện	87,8%	4.357	77,5%	4.817	84,8%	5.288	−17,6%
Cuối tuần	89,5%	4.370	79,4%	4.842	87,1%	5.079	−14,0%
Mùa lễ (T11–12)	87,3%	4.922	82,7%	4.530	87,6%	5.648	−12,9%
Ngày thường	90,2%	3.958	87,4%	3.799	92,0%	4.675	−15,3%
Toàn miền test	89,9%	4.143	84,1%	4.165	90,0%	4.850	−14,6%



Hình 4.4: Thực nghiệm B1: (a) fill rate của các chính sách theo giai đoạn nhu cầu; (b) chênh lệch chi phí mỗi ngày của IPPO so với hai baseline ở cùng mức phục vụ

Kết quả B1 — giai đoạn tự nhiên. Bảng 4.8 và Hình 4.4 cho ba nhận xét. Vì các ngày gần nhau không độc lập (các episode chồng lấn và nhu cầu có tự tương quan), độ tin cậy của từng chênh lệch được ước lượng bằng *bootstrap theo khối 7 ngày*: lấy

mẫu lại nguyên từng tuần (2.000 lần) thay vì từng ngày riêng lẻ, rồi lấy khoảng tin cậy 95% của chênh lệch chi phí (Bảng 4.9).

Bảng 4.9: Chênh lệch chi phí mỗi ngày của IPPO và khoảng tin cậy 95% (bootstrap theo khối 7 ngày). Dấu *: khoảng tin cậy không chứa 0.

Giai đoạn	So với (s, S) trực tiếp	So với (s, S) cùng mức PV
Ổn định	+2,5% [+0,1; +4,9]*	-14,9% [-16,5; -13,4]*
Trung bình	-1,4% [-4,5; +1,9]	-15,9% [-17,9; -13,9]*
Biến động	-2,2% [-8,5; +3,7]	-13,2% [-16,1; -10,5]*
Ngày có sự kiện	-9,6% [-16,6; -1,8]*	-17,6% [-21,7; -13,4]*
Ngày SNAP	-0,3% [-4,0; +3,8]	-14,1% [-16,4; -11,8]*
Cuối tuần	-9,7% [-14,1; -4,7]*	-14,0% [-16,4; -11,6]*
Mùa lễ (T11-12)	+8,7% [-2,4; +18,7]	-12,9% [-18,2; -8,1]*
Ngày thường	+4,2% [+0,1; +8,2]*	-15,3% [-17,4; -13,2]*

Thứ nhất, **khí nhu cầu ổn định, chính sách cổ điển cạnh tranh được về chi phí**. Trong nhóm ngày ổn định và ngày thường, IPPO đắt hơn (s, S) tính chỉnh trực tiếp lần lượt 2,5% và 4,2% (đổi lại fill rate cao hơn khoảng 3 điểm phần trăm). Đây đúng là điều lý thuyết dự đoán: khí nhu cầu gần với trung bình trượt, công thức $s = \mu_L + z\sigma_L$ là một xấp xỉ tốt, và chính sách cổ điển không cần gì hơn. Cả hai chênh lệch này đều có ý nghĩa thống kê (Bảng 4.9).


Thứ hai, **khí nhu cầu biến động, ưu thế của IPPO thể hiện rõ ở độ bền của mức phục vụ**. Từ nhóm ổn định sang nhóm biến động, fill rate của IPPO chỉ giảm 2,4 điểm phần trăm, trong khi (s, S) trực tiếp giảm 7,3 điểm và (s, S) cùng mức phục vụ giảm 5,2 điểm. Ở ngày có sự kiện và cuối tuần, IPPO vừa rẻ hơn (s, S) trực tiếp (9,6% và 9,7%, cả hai có ý nghĩa thống kê) vừa có fill rate cao hơn khoảng 10 điểm — tức ưu thế Pareto trên nhóm ngày này. Riêng ở nhóm “biến động” theo độ lệch nhu cầu, chênh lệch chi phí so với (s, S) trực tiếp (-2,2%) chưa có ý nghĩa thống kê; ưu thế ở nhóm này thể hiện chủ yếu qua mức phục vụ.

Thứ ba, **ở cùng mức phục vụ, IPPO rẻ hơn trong mọi giai đoạn** (12,9%–17,6% so với (s, S) , 16,3%–19,9% so với Newsvendor), nhưng ưu thế tương đối không tăng theo mức biến động: lớn nhất ở ngày có sự kiện (-17,6%), nhỏ nhất ở mùa lễ (-12,9%). Mùa lễ cuối năm là giai đoạn yếu nhất của IPPO: fill rate thấp nhất (87,3%) và chi phí mỗi ngày cao hơn (s, S) trực tiếp 8,7%. Tuy nhiên, mùa lễ chỉ gồm 9 tuần trong miền test nên khoảng tin cậy rất rộng ([-2,4%; +18,7%]) và chênh lệch này chưa có ý nghĩa thống kê; nó chỉ nên được xem là một dấu hiệu cần theo dõi. Một nguyên nhân khả dĩ là miền huấn luyện (1.050 ngày đầu) chỉ chứa khoảng ba mùa lễ, và phân

tích tầm quan trọng đặc trưng (Mục 4.5.5) cho thấy tác tử gần như không khai thác các đặc trưng lịch.

Bảng 4.10: Thực nghiệm B2: fill rate (và chi phí mỗi ngày) trước, trong và sau sốc cầu 28 ngày

Chính sách	Sốc tăng $\times 1,5$			Sốc giảm $\times 0,5$		
	Trước	Trong	Sau	Trước	Trong	Sau
IPPO	90,6% (3.604)	83,8% (5.442)	92,8% (3.963)	90,6% (3.604)	97,6% (3.410)	90,1% (3.793)
(s, S) cùng mức PV	92,5% (4.269)	83,6% (7.633)	91,9% (5.153)	92,5% (4.269)	95,3% (3.000)	87,3% (4.582)
Newsvendor cùng mức PV	93,1% (4.434)	84,1% (8.061)	92,2% (5.489)	93,1% (4.434)	95,4% (3.087)	87,9% (4.754)
(s, S) trực tiếp	86,4% (3.818)	80,1% (6.259)	88,4% (4.004)	86,4% (3.818)	89,7% (2.519)	80,3% (4.320)



Hình 4.5: Thực nghiệm B2: fill rate theo ngày (trung bình trượt 7 ngày) quanh cú sốc cầu; vùng tô đỏ là 28 ngày bị sốc

Kết quả B2 — sốc cầu. Khi nhu cầu tăng đột ngột 50% (Bảng 4.10, Hình 4.5), mọi chính sách đều mất khoảng 7–9 điểm fill rate trong cú sốc và mức sụt gần như bằng nhau (83,6%–84,1% ở nhóm cùng mức phục vụ). Khác biệt nằm ở chi phí: để chống đỡ cú sốc, IPPO tốn 5.442 đơn vị mỗi ngày, còn (s, S) và Newsvendor cùng mức phục vụ tốn 7.633 và 8.061 — tức IPPO rẻ hơn khoảng 29%–32% trong đúng giai đoạn khó khăn nhất. Sau cú sốc, IPPO phục hồi lên fill rate cao nhất (92,8%).


Khi nhu cầu sụt 50% rồi quay lại bình thường, bức tranh rõ hơn nữa. Trong cú sốc mọi chính sách đều dư hàng nên fill rate tăng. Nhưng khi nhu cầu hồi phục, các chính sách cổ điển tụt mạnh (xuống 87,3%–87,9% ở nhóm cùng mức phục vụ, 80,3% với (s, S) trực tiếp, đáy trượt 7 ngày khoảng 65%), vì ước lượng μ và σ từ cửa sổ 7 ngày vẫn phản ánh giai đoạn nhu cầu thấp nên chúng đặt quá ít. IPPO gần như không

bị ảnh hưởng (90,1%, đáy khoảng 86%). Cần diễn giải đúng hiện tượng này: nó *không* chứng minh IPPO “dự đoán” được sự hồi phục, mà cho thấy chính sách học được không phụ thuộc hoàn toàn vào cửa sổ ngắn hạn — nó kết hợp lịch sử 7 ngày với đặc trưng quy mô dài hạn $\log(1 + \bar{D}^{(i)})$, đặc trưng có tầm quan trọng cao nhất trong phân tích ở Mục 4.5.5. Nói cách khác, IPPO bền hơn trước nhiễu ngắn hạn, đổi lại có thể phản ứng chậm hơn nếu thay đổi nhu cầu là vĩnh viễn.

Kết luận thực nghiệm B. Kết quả không cho thấy học tăng cường đạt chi phí thấp hơn ở mọi giai đoạn. Khi nhu cầu ổn định, (s, S) tinh chỉnh tốt vẫn là lựa chọn rẻ nhất nếu chấp nhận mức phục vụ thấp hơn. Ưu thế của IPPO tập trung ở giai đoạn biến động: giữ mức phục vụ bền hơn, rẻ hơn rõ rệt ở ngày có sự kiện và cuối tuần, và tốn ít chi phí hơn nhiều khi chống đỡ sốc cầu. Ở cùng mức phục vụ, ưu thế chi phí của IPPO có ý nghĩa thống kê ở cả tám nhóm ngày. Hai giới hạn của thực nghiệm này: (1) miền test chỉ dài 491 ngày nên các episode 365 ngày chồng lẫn nhau — bootstrap theo khối tuần giảm nhưng không loại bỏ hoàn toàn ảnh hưởng của tự tương quan; (2) mùa lễ chỉ có 61 ngày (9 tuần) nên kết luận về mùa lễ còn yếu.

4.5.5 Kiểm tra trạng thái và phần thưởng bằng thực nghiệm

Thiết kế trạng thái (Bảng 3.1) và phần thưởng (công thức 3.4) ở Chương 3 mới dựa trên lập luận. Mục này kiểm tra lại bằng thực nghiệm ba câu hỏi: chính sách có hành vi hợp lý về nghiệp vụ không, tác tử có khai thác kẽ hở của phần thưởng không, và trạng thái có biến dư thừa không (scripts/policy_behavior.py, 10 episode trên miền test, so với (s, S) cùng mức phục vụ).



Hình 4.6: (a) Xác suất đặt hàng theo số ngày tồn kho; (b) phân bố fill rate của 300 cặp; (c) mức tăng chi phí khi xáo trộn từng nhóm đặc trưng trạng thái

Hành vi có hợp lý về nghiệp vụ không? Hình 4.6a nhóm các quyết định theo số ngày tồn kho (vị thế tồn kho chia cho nhu cầu trung bình). Xác suất IPPO đặt hàng

giảm đơn điều khi tồn kho tăng: 99% khi còn 1–2 ngày hàng, 51% khi còn 2–3 ngày, 12% khi còn 5–8 ngày và 7% khi trên 8 ngày. Tương quan hạng Spearman giữa số ngày tồn kho và mức đặt là $-0,42$, mạnh hơn (s, S) ($-0,18$). IPPO chỉ dùng mức đặt lớn nhất ($5\bar{D}\bar{L}$) ở 1,4% số quyết định, và chi phí tràn kho chỉ chiếm 1,5% tổng chi phí (so với 8,9% của (s, S)). Có một điểm bất thường: khi tồn kho dưới 1 ngày, IPPO chỉ đặt hàng trong 76% trường hợp. Kiểm tra lại cho thấy *toàn bộ* các trường hợp không đặt này thuộc các cặp có nhu cầu trung bình dưới 0,5 đơn vị mỗi ngày (trung vị 0,05 — mức sàn của $\bar{D}$), nhất quán với phân tích bên dưới.

Tác tử có khai thác kẽ hở của phần thưởng không? Nếu tác tử chỉ “vừa đủ” để tránh phạt mức phục vụ, fill rate của các cặp sẽ dồn sát ngưỡng 85%. Điều này không xảy ra: chỉ 13,7% số cặp nằm trong khoảng $[85\%, 88\%)$. Tuy nhiên, phân bố fill rate theo cặp (Hình 4.6b) cho thấy một dạng khai thác khác: 39% số cặp của IPPO có fill rate dưới 85% (phân vị 10% là 68,5%), trong khi con số này của (s, S) cùng mức phục vụ chỉ là 6,3% (phân vị 10% là 86,8%). Fill rate hệ thống 89,8% của IPPO đạt được nhờ phục vụ rất tốt các mặt hàng bán chạy, bù cho các mặt hàng bán chậm. Đây là hệ quả trực tiếp của việc hình phạt mức phục vụ tỷ lệ với $\bar{D}^{(i)}$ (Mục 4.5.1): tác tử tối ưu đúng hàm mục tiêu được giao, nhưng hàm mục tiêu đó chưa mã hóa yêu cầu “mọi mặt hàng đều phải đạt mức phục vụ tối thiểu”. Đây là phát hiện quan trọng nhất của phần kiểm tra này và là lý do đề xuất điều chỉnh hình phạt trong hướng phát triển.

Bảng 4.11: Tầm quan trọng của các nhóm đặc trưng trạng thái (xáo trộn nhóm đặc trưng giữa các cặp ở mỗi bước; riêng nhóm lịch được thay bằng lịch của một ngày ngẫu nhiên)

Nhóm đặc trưng	Số chiều	Chi phí tăng	Fill rate đối
Đặc trưng quy mô $\log(1 + \bar{D})$	1	+97,9%	+0,1 điểm
Tồn kho và vị thế tồn kho	2	+93,7%	−20,4 điểm
Lịch sử cầu 7 ngày	7	+49,9%	−12,2 điểm
Fill rate của số 30 ngày	1	+16,7%	−0,2 điểm
Hàng đang về (pipeline)	3	+7,8%	−0,4 điểm
Lịch (thứ, SNAP, sự kiện, tháng)	27	+3,5%	−0,8 điểm
Tín hiệu cấp kho (mức đầy, tỷ trọng)	2	+2,8%	+0,4 điểm

Trạng thái có biến dư thừa không? Bảng 4.11 đo mức giảm hiệu năng khi phá liên hệ giữa một nhóm đặc trưng và cặp tương ứng (permutation importance), không cần huấn luyện lại. Không nhóm nào vô dụng hoàn toàn — xáo trộn nhóm nào cũng làm chi phí tăng. Ba nhóm quyết định là đặc trưng quy mô, tồn kho và lịch sử cầu; chúng

tương ứng đúng với các đại lượng mà một chính sách tồn kho cổ điển cần ($\bar{D}$, vị thế tồn kho, σ). Ngược lại, 27 chiều lịch và 2 chiều tín hiệu cấp kho chỉ đóng góp 3%–4% chi phí. Với lịch, điều này giải thích vì sao IPPO yếu nhất ở mùa lễ (Thực nghiệm B): 27/43 chiều quan sát gần như không được khai thác. Với tín hiệu cấp kho, mức đóng góp nhỏ nhất quán với việc ràng buộc sức chứa ít khi chạm ngưỡng ở cấu hình hiện tại (chi phí tràn kho chỉ 1,5%). Cần lưu ý rằng permutation importance đo mức *chính sách đã học* dựa vào một đặc trưng, không phải hiệu năng của một chính sách được huấn luyện lại khi bỏ đặc trưng đó — thí nghiệm sau được đưa vào hướng phát triển.

4.5.6 Độ nhạy của kết luận theo đơn giá chi phí

Mọi kết luận ở trên gắn với một bộ đơn giá chi phí cụ thể ($c_{lk} = 1$, $c_{th} = 10$, $c_{dh} = 5$). Để kiểm tra kết luận có phụ thuộc vào lựa chọn này không, mỗi chính sách được chạy một lần trên miền test (10 episode) và ghi lại các đại lượng vật lý: đơn vị–ngày lưu kho, đơn vị thiếu hàng, số lần đặt, đơn vị tràn kho. Tổng chi phí sau đó được tính lại trên lưới $3 \times 4 \times 3 = 36$ bộ đơn giá ($c_{lk} \in \{0,5; 1; 2\}$, $c_{th} \in \{5; 10; 20; 40\}$, $c_{dh} \in \{2; 5; 10\}$; `scripts/sensitivity.py`). Các chính sách *không* được huấn luyện hay tinh chỉnh lại cho từng bộ đơn giá, nên kết quả trả lời câu hỏi: nếu doanh nghiệp định giá chi phí khác đi thì các chính sách đã có xếp hạng thế nào.

Bảng 4.12: Chênh lệch tổng chi phí của IPPO theo đơn giá ($c_{dh} = 5$). Mỗi ô: so với (s, S) trực tiếp / so với (s, S) cùng mức phục vụ; âm là IPPO rẻ hơn.

	$c_{th} = 5$	$c_{th} = 10$	$c_{th} = 20$	$c_{th} = 40$
$c_{lk} = 0,5$	−1,2% / −20,1%	−9,6% / −17,0%	−18,1% / −12,9%	−25,0% / −8,4%
$c_{lk} = 1$	+7,7% / −15,8%	0,0% / −14,0%	−9,4% / −11,5%	−18,4% / −8,2%
$c_{lk} = 2$	+15,0% / −12,4%	+9,1% / −11,5%	+0,7% / −10,1%	−9,2% / −8,0%

Hai nhận xét rút ra (Bảng 4.12). Thứ nhất, **kết luận ở cùng mức phục vụ bền vững**: IPPO rẻ hơn (s, S) cùng mức phục vụ ở cả 36/36 bộ đơn giá (chênh −7,6% đến −20,5%), và rẻ hơn Newsvendor cùng mức phục vụ ở cả 36/36 bộ (chênh −6,8% đến −27,2%). Thứ hai, **kết luận so thẳng phụ thuộc tỷ số c_{th}/c_{lk}** : IPPO chỉ rẻ hơn (s, S) tinh chỉnh trực tiếp ở 22/36 bộ đơn giá. Khi thiếu hàng đắt so với lưu kho, IPPO đạt chi phí thấp hơn vì nó giữ mức phục vụ cao hơn; khi lưu kho đắt và thiếu hàng rẻ, (s, S) — vốn chấp nhận thiếu hàng nhiều hơn — lại rẻ hơn. Điều này nhất quán với nhận định ở Mục 4.4.2 rằng so thẳng hai chính sách nằm ở hai điểm khác nhau trên đường đánh đổi là không công bằng. Ưu thế ở cùng mức phục vụ thu hẹp dần khi c_{th} tăng, vì khi đó chi phí bị chi phối bởi phần thiếu hàng mà hai chính sách cùng mức

phục vụ có lượng gần như nhau.

4.6 Hạn chế của thực nghiệm

Ba hạn chế cần được ghi nhận khi diễn giải các kết quả trên.

Thứ nhất, số episode huấn luyện mỗi hạt giống. Để huấn luyện được cả 3 hạt giống độc lập (Mục 4.3.1) trong thời gian hợp lý, mỗi hạt giống chỉ chạy 1.000 episode thay vì một cấu hình dài hơn. Đường cong học (Mục 4.4.1) cho thấy phần thưởng, entropy và explained variance đều đã ổn định từ khoảng episode 600–800 nên 1.000 episode nhiều khả năng đủ để hội tụ, nhưng chưa loại trừ hoàn toàn khả năng huấn luyện dài hơn tiếp tục cải thiện nhẹ chiến lược, đặc biệt ở phần đánh đổi giữa lưu kho và thiếu hàng vốn quyết định vị trí của IPPO trên đường đánh đổi chi phí — mức phục vụ (Mục 4.4.2). Để kiểm tra, hạt giống 42 được huấn luyện tiếp tới khoảng 4.083 episode (chọn checkpoint theo cùng quy tắc trên miền val) rồi đánh giá lại trên đúng 30 episode test. Tổng chi phí giảm từ 1.589.472 xuống 1.512.076 trong khi fill rate gần như giữ nguyên (89,9%). Ở mức này IPPO rẻ hơn (s, S) tinh chỉnh trực tiếp 0,5% (1.520.337) dù fill rate cao hơn 5,8 điểm phần trăm; chênh lệch chi phí không có ý nghĩa thống kê theo kiểm định t Welch ($p = 0,109$), nằm sát ngưỡng theo kiểm định t theo cặp ($p = 0,050$) và có ý nghĩa theo Wilcoxon ($p = 0,023$); IPPO rẻ hơn (s, S) ở 21/30 episode. Nói cách khác, huấn luyện dài hơn đưa IPPO tới điểm vận hành *không đắt hơn* (s, S) mà vẫn phục vụ tốt hơn rõ rệt. Kết luận này lặp lại khi đánh giá trên 30 cửa sổ có ngày bắt đầu cố định, trải đều miền test thay vì rút ngẫu nhiên: IPPO 1.518.471 (fill rate 89,8%) so với (s, S) 1.520.889 (84,1%), chênh lệch $-0,2\%$, không có ý nghĩa thống kê ($p = 0,51$ theo kiểm định theo cặp). Kết quả này mới có trên một hạt giống nên chỉ được xem là bằng chứng bổ sung; các bảng chính của chương vẫn dùng kết quả 3 hạt giống $\times$ 1.000 episode. Điểm tích cực là việc lặp lại độc lập trên 3 hạt giống cho kết luận nhất quán (chênh lệch với (s, S) dao động trong khoảng hẹp 4,55–5,50%), nên phương sai giữa các lần khởi tạo ngẫu nhiên không phải là mối lo chính ở quy mô huấn luyện hiện tại.

Thứ hai, phạm vi của bộ tham số chi phí. Phân tích độ nhạy (Mục 4.5.6) cho thấy kết luận ở cùng mức phục vụ đứng vững trên cả 36 bộ đơn giá, còn kết luận so thẳng thì phụ thuộc tỷ số c_{th}/c_{lk} . Tuy nhiên, phân tích này giữ nguyên các chính sách đã học; một IPPO được huấn luyện lại với đơn giá khác có thể học được chiến lược khác.

Thứ ba, tính đại diện của tập mặt hàng. 30 mặt hàng được chọn theo phân tầng

để trải rộng dải quy mô nhu cầu, nhưng vẫn là một tập con nhỏ của 3.049 mặt hàng trong bộ dữ liệu gốc.

4.7 Thảo luận

Kết quả cho phép trả lời Câu hỏi nghiên cứu 1, nhưng câu trả lời cần được phát biểu cân trọng hơn một khẳng định đơn giản. Ở điểm vận hành mà mỗi phương pháp tự chọn (Mục 4.4.2), IPPO không rẻ hơn các chính sách cổ điển — ngược lại, đắt hơn (s, S) 4,89% và Newsvendor 3,16%, tuy vẫn rẻ hơn EOQ 10,41% — vì tác tử dịch chuyển tới mức phục vụ cao hơn hẳn (90,5% so với 75–84%) theo đúng thiết kế của thành phần phạt SLA. Khi loại bỏ yếu tố này bằng phép so sánh ở cùng mức phục vụ (Mục 4.4.4) — phép so sánh chặt chẽ hơn về phương pháp luận — kết luận đảo chiều: IPPO rẻ hơn 10,2% so với (s, S) và 14,4% so với Newsvendor, còn EOQ không có cấu hình nào đạt được mức phục vụ tương đương. Khóa luận coi phép so sánh sau là căn cứ chính đáng để trả lời Câu hỏi 1, vì nó loại bỏ được sai lệch do các phương pháp theo đuổi hai mục tiêu khác nhau; theo căn cứ đó, IPPO học được chính sách vừa rẻ hơn vừa duy trì mức phục vụ cao hơn đáng kể so với ba chính sách cổ điển. Tuy nhiên, khác với một kết quả sơ bộ ở một hạt giống huấn luyện duy nhất mà khóa luận từng có, kết quả đã kiểm chứng lại trên 3 hạt giống cho thấy ưu thế này *không* còn mang tính Pareto tuyệt đối khi không kiểm soát mức phục vụ — một phát hiện quan trọng về giới hạn của việc so sánh trực tiếp giữa các phương pháp tối ưu cho hai mục tiêu khác nhau, và là lý do phép so sánh ở cùng mức phục vụ cần được xem là bắt buộc chứ không phải một phân tích bổ sung tùy chọn.

Hai nhận xét bổ sung đáng ghi nhận.

Về vai trò của ràng buộc sức chứa, thí nghiệm hiệu chỉnh κ ở Mục 4.1.3 cho thấy khi sức chứa đủ rộng thì bài toán suy biến thành 300 bài toán độc lập. Nói cách khác, chính ràng buộc sức chứa dùng chung — chứ không phải số lượng tác tử — mới là thứ tạo nên bản chất đa tác tử của bài toán. Đây là yếu tố mà hai công trình gần nhất cùng bối cảnh đều không mô hình hóa: Zhu và Wu [22] giả định nguồn cung không giới hạn, còn Nam và cộng sự [23] chỉ xét một kho duy nhất.

Về hiệu quả tính toán, việc đạt kết quả trên sau khoảng 40 phút huấn luyện mỗi hạt giống trên CPU cho thấy không nhất thiết phải ghép một mô-đun dự báo học sâu vào trước khâu ra quyết định. Tác tử học trực tiếp từ lịch sử nhu cầu thô đã đủ để vượt các chính sách cổ điển, đồng thời tránh được sự phụ thuộc vào chất lượng của một bộ dự báo riêng biệt — hạn chế mà chính Zhu và Wu [22] nêu ra trong phần thảo luận

của họ. Kết quả này cũng phù hợp với nhận định của Gijsbrechts và cộng sự [17] rằng học tăng cường sâu có thể cạnh tranh với các chính sách được hiệu chỉnh kỹ trong lớp bài toán mất đơn hàng.

CHƯƠNG 5. KẾT LUẬN VÀ HƯỚNG PHÁT TRIỂN

5.1 Tổng kết các kết quả đạt được

Khóa luận đã hoàn thành bốn mục tiêu nghiên cứu chính và thực hiện thêm một nhóm phân tích chuyên sâu (mục thứ năm dưới đây):

1. Xây dựng môi trường mô phỏng: phát triển thành công MultiWarehouseInventoryEnv theo chuẩn Gymnasium [24], mô hình hóa đầy đủ hệ thống 10 kho, 30 mặt hàng (300 cặp tác tử), với nhu cầu ngẫu nhiên, thời gian giao hàng biến động [1, 3] ngày, ràng buộc sức chứa dùng chung tính riêng cho từng kho theo quy mô nhu cầu của kho đó, bốn thành phần chi phí vận hành (lưu kho, thiếu hàng, đặt hàng, tràn kho) và hình phạt mức phục vụ tách riêng khỏi chi phí vận hành. Nhu cầu lấy từ bộ dữ liệu M5 Walmart [2].
2. Thiết kế hàm phần thưởng: phần thưởng phân rã cục bộ (local factored reward) theo từng cặp kho–mặt hàng, với động cơ giảm khó khăn gán tín dụng [25], kèm hình phạt mức phục vụ dạng ràng buộc mềm tính trên cửa sổ trượt 30 ngày.
3. Cài đặt và huấn luyện IPPO: triển khai thuật toán Independent Multi-Agent PPO [20] với cơ chế chia sẻ tham số [18], sử dụng GAE [27] và chuẩn hóa lợi thế theo từng cặp. Mô hình hội tụ ổn định trên quy mô 300 tác tử sau khoảng 600–800 episode, với entropy giảm từ 1,778 xuống 0,18 và explained variance của Critic duy trì quanh 0,75–0,80, nhất quán trên cả 3 hạt giống huấn luyện độc lập đã kiểm chứng.
4. Đánh giá đối chứng: so sánh IPPO với ba chính sách cổ điển (EOQ, (s, S) , Newsvendor) trên 30 episode đánh giá dùng chung hạt giống, lặp lại trên 3 hạt giống huấn luyện độc lập, có kiểm định thống kê [28], [29], và bổ sung phép so sánh ở cùng mức phục vụ nhằm loại bỏ sai lệch do các phương pháp nằm ở những điểm khác nhau trên đường đánh đổi.
5. Phân tích theo giai đoạn và kiểm tra hành vi: tách kết quả theo giai đoạn nhu cầu (ổn định, biến động, sự kiện, mùa lễ) và thử sức cầu nhân tạo (thực nghiệm B); kiểm tra bằng thực nghiệm tính hợp lý của hành vi đặt hàng, dấu hiệu khai thác phần thưởng và tầm quan trọng của từng nhóm

đặc trưng trạng thái. Kết quả mô phỏng được đưa lên ứng dụng Streamlit cho phép xem diễn biến theo từng ngày của từng cặp kho–mặt hàng (nhu cầu, tồn kho, hàng đang về, lượng đặt, thiếu hàng, phần thưởng, cảnh báo thiếu hàng).

5.1.1 Trả lời các câu hỏi nghiên cứu

Câu hỏi 1 (IPPO so với các chính sách cổ điển). Câu trả lời là khẳng định, nhưng chỉ khi mức phục vụ được kiểm soát. Ở điểm vận hành mà mỗi phương pháp tự chọn, IPPO **không** rẻ hơn các chính sách cổ điển: gộp trên 3 hạt giống huấn luyện $\times$ 30 episode đánh giá, IPPO đắt hơn (s, S) 4,89% và Newsvendor 3,16% (dù vẫn rẻ hơn EOQ 10,41%), khác biệt có ý nghĩa thống kê rất cao ($p = 5,45 \times 10^{-33}$ với kiểm định t Welch; Cohen’s $d = 4,06$) và nhất quán trên cả 3 hạt giống độc lập. Nguyên nhân là IPPO dịch chuyển tới mức phục vụ 90,5% — cao hơn hẳn 75–84% của ba chính sách cổ điển — nên đây không phải là ưu thế Pareto mà là một điểm khác trên đường đánh đổi chi phí–mức phục vụ.

Khi so sánh ở cùng mức phục vụ ($\approx 90\%$) — phép so sánh chặt chẽ hơn về mặt phương pháp luận vì loại bỏ được sai lệch do hai mục tiêu tối ưu khác nhau — kết luận đảo chiều: IPPO rẻ hơn (s, S) 10,2% và rẻ hơn Newsvendor 14,4%, trong khi EOQ không có cấu hình nào đạt được mức phục vụ đó do cấu trúc lượng đặt hàng cố định. Nguyên nhân là các chính sách cổ điển chỉ có thể nâng mức phục vụ bằng cách tăng tham số an toàn áp dụng đồng loạt cho cả 300 cặp — khiến chi phí tăng đáng kể ở cả những mặt hàng vốn đã đạt mức phục vụ tốt — còn IPPO điều chỉnh theo từng trạng thái quan sát được. Khóa luận coi phép so sánh ở cùng mức phục vụ là căn cứ chính đáng để trả lời Câu hỏi 1, và ghi nhận rõ ràng rằng phép so sánh trực tiếp không kiểm soát mức phục vụ có thể dẫn tới kết luận ngược lại.

Thực nghiệm B bổ sung sắc thái cho câu trả lời này. Khi nhu cầu ổn định, (s, S) tinh chỉnh trực tiếp rẻ hơn IPPO vài phần trăm; ưu thế của IPPO tập trung ở giai đoạn biến động — fill rate chỉ giảm 2,4 điểm phần trăm từ ngày ổn định sang ngày biến động (so với 5–7 điểm của (s, S)), rẻ hơn khoảng 10% ở ngày có sự kiện và cuối tuần dù phục vụ tốt hơn, và tốn ít hơn khoảng 29%–32% chi phí khi chống đỡ một cú sốc tăng cầu 50%. Các chênh lệch ở ngày ổn định, ngày có sự kiện và cuối tuần đều có ý nghĩa thống kê theo bootstrap khối tuần. Mùa lễ cuối năm là giai đoạn IPPO yếu nhất, nhưng dữ liệu chỉ có 9 tuần nên chưa đủ để kết luận chắc chắn. Ở cùng mức phục vụ, IPPO rẻ hơn (s, S) ở cả tám nhóm ngày, và rẻ hơn ở cả 36 bộ đơn giá chi phí trong phân tích độ nhạy. Kết luận hợp lý vì vậy không phải “học tăng cường tốt hơn” một

cách chung chung, mà là: chính sách cổ điển đủ tốt khi nhu cầu ổn định, còn IPPO có giá trị khi nhu cầu biến động nhanh.

Câu hỏi 2 (hiệu năng theo nhóm quy mô nhu cầu). Câu trả lời là có điều kiện. Một bộ trọng số duy nhất điều khiển được 300 cặp có nhu cầu từ dưới 0,1 đến 143 đơn vị mỗi ngày, và ở nhóm nhu cầu trung bình và cao IPPO vượt (s, S) trên cả fill rate lẫn chi phí. Tuy nhiên, ở nhóm bán chậm (dưới 2 đơn vị mỗi ngày) IPPO phục vụ kém hơn (s, S) ; phân tích phân bố cho thấy 39% số cặp của IPPO dưới ngưỡng 85%. Nguyên nhân chủ yếu nằm ở cách định cỡ hình phạt mức phục vụ theo $\bar{D}^{(i)}$ chứ không phải ở khả năng biểu diễn của mạng dùng chung (Mục 4.5.1, 4.5.5). Khả năng áp dụng cho mặt hàng chưa từng gặp khi huấn luyện chưa được kiểm chứng.

Câu hỏi 3 (thiết kế tín hiệu phần thưởng). Về khía cạnh chuẩn hóa, có bằng chứng sơ bộ ủng hộ. Một lần chạy loại trừ tất chuẩn hóa phần thưởng theo cặp (dùng ở khoảng 625 episode) cho tổng chi phí cao gấp khoảng 3,2 lần và fill rate chỉ 80,7%, so với lần huấn luyện gốc ở cùng khoảng episode (Mục 4.5.2). Đáng chú ý là Critic khi đó đạt explained variance gần 1 nhưng chính sách vẫn kém. Điều này khớp với lập luận rằng return chênh nhau nhiều bậc độ lớn khiến tín hiệu học bị các cặp nhu cầu lớn chi phối. Kết luận định lượng đầy đủ chờ lần chạy 1.000 episode trong đợt thực nghiệm bổ sung.

5.2 Những hạn chế còn tồn tại

- Cấu trúc mạng lưới đơn giản: các kho hoạt động song song và độc lập về nguồn cung; chưa xét cấu trúc đa cấp (multi-echelon) với quan hệ cung ứng giữa các kho [30] và hiệu ứng bullwhip [31].
- Không có cơ chế phối hợp tường minh: các tác tử ra quyết định hoàn toàn dựa trên quan sát cục bộ, phối hợp chỉ diễn ra gián tiếp qua tín hiệu sức chứa kho. Khóa luận chưa định lượng được phần giá trị mà một critic tập trung theo hướng CTDE [21] có thể mang lại — đặc biệt đáng lưu ý vì Zhu và Wu [22] báo cáo mức suy giảm đáng kể khi loại bỏ cơ chế phối hợp trong khung của họ.
- Số episode mỗi hạt giống huấn luyện: kết quả chính được kiểm chứng trên 3 hạt giống độc lập theo khuyến nghị của Henderson và cộng sự [28], mỗi hạt giống 1.000 episode. Huấn luyện tiếp hạt giống 42 tới khoảng 4.083 episode đã giảm thêm khoảng 5% chi phí, cho thấy 1.000 episode chưa phải điểm bão hòa; kết quả dài hơn mới có trên một hạt giống.

- Mất cân bằng mức phục vụ giữa các mặt hàng: hình phạt mức phục vụ tỷ lệ với nhu cầu trung bình nên chính sách phân bổ mức phục vụ thấp hơn cho mặt hàng bán chậm mà vẫn đạt mục tiêu chung; 39% số cặp có fill rate dưới 85%.
- Giới hạn của thực nghiệm theo giai đoạn: miền test chỉ dài 491 ngày nên các episode chồng lấn nhau. Bootstrap theo khối tuần cho khoảng tin cậy của từng giai đoạn nhưng không loại bỏ hết tự tương quan, và mùa lễ chỉ có 9 tuần nên kết luận về mùa lễ chưa có ý nghĩa thống kê.
- Kết quả chính và các phân tích bổ sung dùng hai checkpoint khác nhau: các bảng chính dùng 3 hạt giống $\times 1.000$ episode, còn thực nghiệm B, phần kiểm tra hành vi và phân tích độ nhạy dùng checkpoint hạt giống 42 huấn luyện tiếp tới khoảng 4.083 episode. Đợt thực nghiệm bổ sung (Mục 5.3.1) thống nhất lại toàn bộ trên một cấu hình.
- Hình phạt mức phục vụ tỷ lệ theo nhu cầu: mọi kết quả ở Chương 4 dùng cách định cỡ cũ. Biểu thức chuẩn hóa (3.5) đã cài đặt nhưng chưa có kết quả huấn luyện.
- Đặc trưng lịch gần như không được khai thác: 27/43 chiều quan sát chỉ đóng góp khoảng 3,5% chi phí theo phân tích permutation importance, và IPPO yếu nhất ở mùa lễ.
- Không gian hành động rời rạc thô: chỉ có $K = 6$ mức đặt hàng; trong thực tế, doanh nghiệp có thể cần quyết định lượng đặt chính xác hơn.
- Chưa tích hợp dự báo nhu cầu: tác tử sử dụng trực tiếp nhu cầu lịch sử thay vì dự báo bằng mô hình học sâu chuỗi thời gian.
- Thực nghiệm trên môi trường mô phỏng: chưa được kiểm chứng trên hệ thống ERP thực tế hoặc dữ liệu vận hành trực tiếp.

5.3 Hướng phát triển trong tương lai

5.3.1 Đợt thực nghiệm bổ sung đã cài đặt

Các hạn chế nêu ở Mục 5.2 đều đã được chuyển thành thí nghiệm cụ thể. Toàn bộ mã nguồn đã được cài đặt và kiểm thử (tổng cộng 39 kiểm thử đơn vị), và được gom vào một kịch bản duy nhất (`scripts/campaign.py`) có khả năng huấn luyện tiếp khi bị gián đoạn. Riêng phần huấn luyện (khoảng 25 giờ CPU) chưa hoàn tất tại thời điểm viết báo cáo. Mỗi thí nghiệm loại trừ chỉ khác cấu hình tham chiếu đúng một thay đổi

(Bảng 5.1); cấu hình tham chiếu dùng hình phạt mức phục vụ chuẩn hóa (3.5).

Bảng 5.1: Đợt thực nghiệm bổ sung: mã nguồn đã sẵn sàng, đang chờ huấn luyện

Lần chạy	Thay đổi so với tham chiếu	Trả lời câu hỏi
Mô hình chính (3 hạt giống $\times$ 4.000 episode)	Hình phạt mức phục vụ chuẩn hóa	Mật hàng bán chậm còn bị phân bổ mức phục vụ thấp hơn không; kết luận “không đắt hơn (s, S)” có lặp lại trên 3 hạt giống không
Tham chiếu 1.000 episode	—	Mốc so sánh cho các thí nghiệm loại trừ
Phân thưởng toàn cục (3 hạt giống)	reward_mode: global	Câu hỏi 3: cục bộ so với toàn cục
Tắt chuẩn hóa theo cặp (3 hạt giống)	normalize_reward_per_pair: false	Câu hỏi 3: có/không chuẩn hóa
Baseline theo nhóm quy mô cầu	Mỗi nhóm cầu một bộ tham số (s, S), Newsvendor, EOQ	So sánh với đối thủ mạnh hơn
Độ bền theo điều kiện vận hành	Sức chứa 4/6 ngày, lead time 2–3 hoặc luôn 3 ngày, nhu cầu $\pm 20\%$ (không huấn luyện lại)	Kết luận có đứng vững khi môi trường thay đổi
Phạt SLA kiểu cũ	service_penalty_mode: demand	Tác động của việc định cỡ lại hình phạt
Actor–Critic chung thân	shared_trunk: true, một optimizer	Vì sao phải tách hai mạng (Mục 4.5.3)
Bỏ đặc trưng lịch / cấp kho	obs_drop	Trạng thái có biến dư thừa không
Thêm sự kiện sắp tới	2 đặc trưng: số ngày tới sự kiện kế tiếp, có sự kiện trong 7 ngày	Khắc phục điểm yếu mùa lễ
Warm-start	Lịch sử nhu cầu khởi tạo bằng dữ liệu thật	Ảnh hưởng của lịch sử rộng đầu episode
Hold-out mật hàng	Huấn luyện 24 mật hàng, đánh giá 6 mật hàng chưa gặp	Câu hỏi 2 (tổng quát hóa)

Giao thức đánh giá của đợt này cũng được củng cố: baseline tinh chỉnh trên miền val (cùng miền dùng để chọn checkpoint IPPO) thay vì miền train; báo cáo kiểm định t theo cặp cùng hệ số d_z ; đánh giá thêm trên các cửa sổ cố định trải đều miền test; và dùng khoảng tin cậy bootstrap theo khối tuần cho từng giai đoạn nhu cầu. Các công cụ phân tích này đã được áp dụng ngay cho kết quả hiện có ở Chương 4.

5.3.2 Các hướng mở rộng khác

- Lead time dài hơn 3 ngày và mục tiêu mức phục vụ khác 85% (chẳng hạn 80% hoặc 90%): phân tích độ bền hiện tại chỉ đánh giá được các thay đổi mà

chính sách đã học vẫn nhận làm đầu vào (sức chứa, lead time trong khoảng 1–3 ngày, mức nhu cầu). Số chiều quan sát phụ thuộc lead time tối đa, còn hệ số phạt được hiệu chỉnh cho mục tiêu 85%, nên hai trường hợp này đòi hỏi huấn luyện lại cho từng cấu hình.

- Nhân tử Lagrange riêng cho từng cặp: thay vì cố định hệ số ϕ_{dv} , cập nhật một nhân tử cho mỗi cặp trong lúc huấn luyện để ràng buộc mức phục vụ được thỏa mãn chặt ở từng mặt hàng.
- Điều chuyển hàng liên kho: bổ sung hành động chuyển hàng giữa các kho kèm chi phí điều chuyển vào hàm phần thưởng; khi đó không gian hành động và bảng đặc tả tác tử cần được mở rộng tương ứng.
- Mở rộng sang cấu trúc đa cấp (multi-echelon): mô hình hóa quan hệ cung ứng giữa kho trung tâm và kho khu vực, cho phép tác tử học chiến lược điều phối liên kho.
- So sánh với kiến trúc huấn luyện tập trung — thực thi phi tập trung: bổ sung một nhánh MAPPO [21] trong đó Critic nhận thêm trạng thái ở cấp kho, nhằm đo lường trực tiếp giá trị của phối hợp tường minh so với phối hợp gián tiếp qua tín hiệu sức chứa. Đây là hướng mở rộng trực tiếp nhất về mặt cài đặt, vì kiến trúc hiện tại đã tách riêng mạng Actor và Critic; kết quả sẽ cho phép định lượng rõ giá trị của phối hợp tường minh trong cấu hình nghiên cứu này.
- Tích hợp cơ chế truyền thông giữa tác tử: áp dụng các phương pháp như CommNet hoặc TarMAC để cho phép tác tử chia sẻ thông tin, đặc biệt về tình trạng sức chứa kho.
- Không gian hành động liên tục: sử dụng PPO cho hành động liên tục hoặc mạng hành động phân cấp (hierarchical action) để quyết định lượng đặt hàng chính xác.
- Gán công theo độ trễ giao hàng: chi phí phát sinh ở ngày t phần lớn là hệ quả của quyết định đặt hàng ở ngày $t - L$. Hiện việc gán công này được phác thảo cho GAE với $\gamma = 0,99$; một cơ chế liên kết phần thưởng trực tiếp với hành động sinh ra nó, theo hướng của Nam và cộng sự [23], có thể làm tín hiệu học sắc nét hơn.
- Tích hợp dự báo nhu cầu: nhúng mô hình dự báo chuỗi thời gian (LSTM, Transformer) vào vector quan sát của tác tử, tận dụng thông tin xu hướng và mùa vụ. Cần lưu ý rằng kết quả hiện tại cho thấy phương án không dùng

dự báo đã đủ vượt các chính sách cổ điển với chi phí tính toán thấp hơn nhiều bậc, nên hướng này cần được đánh giá trên tương quan lợi ích — chi phí chứ không mặc nhiên là một cải tiến.

- Triển khai thử nghiệm thực tế: xây dựng hệ thống dạng SaaS kết nối API với nền tảng quản lý kho, cho phép đánh giá mô hình trên dữ liệu vận hành trực tiếp.
- Mở rộng quy mô: thử nghiệm với toàn bộ 3.049 SKU gốc của M5 và đánh giá khả năng mở rộng của cơ chế chia sẻ tham số.
- Lớp giao tiếp ngôn ngữ qua MCP: dùng Model Context Protocol để một mô hình ngôn ngữ lớn gọi engine IPPO như một công cụ, cho phép người quản lý kho đặt câu hỏi bằng ngôn ngữ tự nhiên (ví dụ mặt hàng nào sắp thiếu) và nhận đề xuất đặt hàng. IPPO vẫn là nơi ra quyết định định lượng; MCP chỉ lo giao tiếp và điều phối công cụ. Một prototype minh họa luồng điều phối này được trình bày ở Phụ lục 5.3.2; hướng này không thuộc đóng góp chính của khóa luận.

PHỤ LỤC A. ĐỐI CHIẾU LUẬN ĐIỂM VÀ NGUỒN TRÍCH DẪN

Phụ lục này liệt kê từng luận điểm lý thuyết được sử dụng trong khóa luận kèm nguồn gốc học thuật tương ứng, nhằm bảo đảm mọi khẳng định đều truy nguyên được về tài liệu công bố chính thống.

Mục	Luận điểm	Nguồn
<i>A.1. Lý thuyết tồn kho</i>		
1.1.1	Quản lý tồn kho đa điểm, đa mặt hàng trong chuỗi cung ứng bán lẻ	Silver et al. [1]; Zipkin [8]
1.1.1	Mô tả bộ dữ liệu M5: quy mô, cấu trúc phân cấp, giai đoạn thu thập	Makridakis et al. [2]; <i>M5 Forecasting – Accuracy</i> [3]
1.1.1	Tiêu chí phân loại dạng nhu cầu (ngưỡng $p = 1,32$; $CV^2 = 0,49$)	Syntetos et al. [4]
1.1.1	Nhu cầu gián đoạn và hạn chế của phương pháp dự báo thông thường	Croston [6]; Syntetos and Boylan [7]
1.1.2	Bất định của nhu cầu và thời gian giao hàng; hiện tượng vượt đơn	Zipkin [8]; Silver et al. [1]
1.1.2	Cấu trúc chi phí tồn kho và bài toán đánh đổi	Zipkin [8]
2.1.2	Mô hình lượng đặt hàng kinh tế (EOQ)	Harris [12]
2.1.2	Tính tối ưu của chính sách (s, S) và các điều kiện kèm theo	Scarf [13]
2.1.2	Mô hình người bán báo (Newsvendor) một chu kỳ	Arrow et al. [14]
2.1.1	Bài toán mất đơn hàng không có nghiệm giải tích dạng đóng	Zipkin [15]
1.3.3	Cấu trúc tồn kho đa cấp (nằm ngoài phạm vi)	Clark and Scarf [30]
1.3.3	Hiệu ứng bullwhip (nằm ngoài phạm vi)	Lee et al. [31]

Mục	Luận điểm	Nguồn
-----	-----------	-------

A.2. Học tăng cường

2.2.1	Quá trình quyết định Markov và quy hoạch động ngẫu nhiên	Puterman [32]
2.2.2	Hàm giá trị, phương trình Bellman, hàm lợi thế, định lý policy gradient	Sutton and Barto [10]
2.2.3	Ước lượng lợi thế tổng quát (GAE) và đánh đổi bias–variance	Schulman et al. [27]
2.2.4	Vùng tin cậy trong tối ưu hóa chính sách	Schulman et al. [34]
2.2.4	Hàm mục tiêu cắt của PPO	Schulman et al. [26]
2.3.5	Điều kiện bảo toàn chính sách tối ưu khi định hình phần thưởng	Ng et al. [36]

A.3. Học tăng cường đa tác tử

2.3.1	Độ phức tạp NEXP-đầy đủ của điều khiển phi tập trung	Bernstein et al. [11]
2.3.1	Mô hình Dec-POMDP	Oliehoek and Amato [9]
2.3.2	Học độc lập và vấn đề môi trường không dừng	Tan [19]
2.3.3	Thuật toán IPPO	Schröder de Witt et al. [20]
2.3.3	MAPPO và khung huấn luyện tập trung, thực thi phân tán	Yu et al. [21]
2.3.4	Chia sẻ tham số giữa các tác tử đồng nhất	Gupta et al. [18]
2.3.5	Bài toán gán tín dụng đa tác tử; phần thưởng chênh lệch (so sánh với phần thưởng phân rã cục bộ)	Wolpert and Tumer [25]

A.4. Ứng dụng, môi trường và giao thức đánh giá

2.4.1	Học tăng cường sâu cho trò chơi phân phối bia	Oroojlooyjadid et al. [16]
2.4.1	Đánh giá học tăng cường sâu trên các lớp bài toán tồn kho	Gijsbrechts et al. [17]
3.4	Chuẩn giao diện môi trường học tăng cường	Brockman et al. [33]; Towers et al. [24]

Mục	Luận điểm	Nguồn
4.3.1	Yêu cầu đa hạt giống và tính tái lập trong đánh giá	Henderson et al. [28]
4.3.1	Phương pháp báo cáo kết quả có kiểm định thống kê	Agarwal et al. [29]

Ghi chú. Các số liệu thống kê mô tả bộ dữ liệu M5 trình bày trong Mục 1.1.1 và Bảng 1.1 do nhóm tác giả tự tính toán từ hai tệp `sales_train_evaluation.csv` và `calendar.csv`; mã nguồn tính toán được đính kèm trong kho mã của khóa luận.

PHỤ LỤC B. PROTOTYPE ĐIỀU PHỐI BẰNG MCP

Model Context Protocol (MCP) là giao thức chuẩn hóa cho phép mô hình ngôn ngữ lớn (LLM) gọi công cụ bên ngoài theo mô hình máy chủ–máy khách. Phụ lục này mô tả một prototype dùng MCP làm lớp giao tiếp phía trên engine IPPO của khóa luận. Prototype không tham gia trả lời các câu hỏi nghiên cứu.

B.1. So sánh hai kiến trúc điều phối

Bảng 5.3: So sánh kiến trúc IPPO và MCP theo các chiều điều phối

Khía cạnh	IPPO (đề tài này)	Kiến trúc MCP
Phân công nhiệm vụ	Không có: mỗi tác tử có nhiệm vụ cố định (một cặp kho–mặt hàng)	Host/LLM phân công tường minh cho từng máy chủ
Chọn hành động	Mạng chính sách $\pi_{\theta}(a \mid o)$ ánh xạ quan sát sang hành động	LLM suy luận và chọn công cụ phù hợp
Lấy ngữ cảnh	Vector quan sát 43 chiều từ môi trường	Máy chủ cung cấp ngữ cảnh qua giao thức chuẩn
Kết quả trả về	Phần thưởng và trạng thái kế tiếp từ môi trường	Kết quả công cụ trả về LLM để tiếp tục suy luận

Hai kiến trúc phục vụ hai lớp bài toán khác nhau. IPPO phù hợp khi hành động là lượng đặt hàng và tín hiệu phản hồi là chi phí. MCP phù hợp khi hệ thống cần giao tiếp ngôn ngữ với người dùng và gọi nhiều công cụ đa dạng.

B.2. Luồng điều phối và công cụ

Theo luồng ngữ cảnh $\rightarrow$ nhiệm vụ $\rightarrow$ chọn công cụ $\rightarrow$ thực thi $\rightarrow$ trả kết quả: người quản lý kho đặt câu hỏi (ví dụ “tuần tới kho CA_3 có mặt hàng nào sắp thiếu không?”); LLM nhận nhiệm vụ và chọn công cụ; máy chủ MCP lấy ngữ cảnh từ môi trường mô phỏng (tồn kho, hàng đang về, lịch) và gọi chính sách IPPO hoặc baseline; kết quả trả về LLM để tổng hợp câu trả lời. IPPO vẫn là nơi ra quyết định định lượng.

Prototype (`app/mcp_server.py`, Python MCP SDK) cung cấp năm công cụ và một tài nguyên (Bảng 5.4), tái sử dụng phần lõi mô phỏng của ứng dụng Streamlit. Prototype đã được kiểm chứng bằng một client MCP chuẩn qua giao thức stdio: client

liệt kê được đủ công cụ và gọi thành công. Prototype chưa được đánh giá với người dùng thật và chưa xử lý xác thực.

Bảng 5.4: Công cụ của prototype MCP

Công cụ / tài nguyên	Chức năng
danh_sach_kho_va_mat_hang	Liệt kê 10 kho, 30 mặt hàng và chỉ số tương ứng
canh_bao_thieu_hang	Mô phỏng tới một ngày, trả về các cặp có tồn kho cộng hàng đang về dưới ngưỡng số ngày cần
de_xuat_dat_hang	Tình trạng một cặp và lượng đặt đề xuất của IPPO cùng ba baseline
mo_phong	Chạy một chính sách trên toàn mạng, trả về chi phí, fill rate, số ngày-cấp thiếu hàng
what_if	So sánh các chính sách khi thay đổi nhu cầu, sức chứa hoặc thời gian giao
ket-qua://tong-hop	Tài nguyên chứa kết quả đánh giá chính thức để LLM trích dẫn

TÀI LIỆU THAM KHẢO

- [1] E. A. Silver, D. F. Pyke, and D. J. Thomas, *Inventory and Production Management in Supply Chains*, 4th ed. Boca Raton, FL: CRC Press, 2016.
- [2] S. Makridakis, E. Spiliotis, and V. Assimakopoulos, “The M5 competition: Background, organization, and implementation,” *International Journal of Forecasting*, vol. 38, no. 4, pp. 1325–1336, 2022. DOI: 10.1016/j.ijforecast.2021.07.007
- [3] “M5 forecasting – accuracy,” Kaggle, Accessed Sept. 1, 2026. [Online]. Available: <https://www.kaggle.com/competitions/m5-forecasting-accuracy>
- [4] A. A. Syntetos, J. E. Boylan, and J. D. Croston, “On the categorization of demand patterns,” *Journal of the Operational Research Society*, vol. 56, no. 5, pp. 495–503, 2005. DOI: 10.1057/palgrave.jors.2601841
- [5] A. I. Kostenko and R. J. Hyndman, “A note on the categorization of demand patterns,” *Journal of the Operational Research Society*, vol. 57, no. 10, pp. 1256–1257, 2006. DOI: 10.1057/palgrave.jors.2602211
- [6] J. D. Croston, “Forecasting and stock control for intermittent demands,” *Operational Research Quarterly*, vol. 23, no. 3, pp. 289–303, 1972. DOI: 10.1057/jors.1972.50
- [7] A. A. Syntetos and J. E. Boylan, “The accuracy of intermittent demand estimates,” *International Journal of Forecasting*, vol. 21, no. 2, pp. 303–314, 2005. DOI: 10.1016/j.ijforecast.2004.10.001
- [8] P. H. Zipkin, *Foundations of Inventory Management*. Boston: McGraw-Hill, 2000.
- [9] F. A. Oliehoek and C. Amato, *A Concise Introduction to Decentralized POMDPs*. Cham: Springer, 2016. DOI: 10.1007/978-3-319-28929-8
- [10] R. S. Sutton and A. G. Barto, *Reinforcement Learning: An Introduction*, 2nd ed. Cambridge, MA: MIT Press, 2018.

- [11] D. S. Bernstein, R. Givan, N. Immerman, and S. Zilberstein, “The complexity of decentralized control of Markov decision processes,” *Mathematics of Operations Research*, vol. 27, no. 4, pp. 819–840, 2002. DOI: 10.1287/moor.27.4.819.297
- [12] F. W. Harris, “How many parts to make at once,” *Factory, The Magazine of Management*, vol. 10, no. 2, pp. 135–136, 152, 1913.
- [13] H. Scarf, “The optimality of (S, s) policies in the dynamic inventory problem,” in *Mathematical Methods in the Social Sciences*, K. J. Arrow, S. Karlin, and P. Suppes, eds., Stanford, CA: Stanford University Press, 1960, pp. 196–202.
- [14] K. J. Arrow, T. Harris, and J. Marschak, “Optimal inventory policy,” *Econometrica*, vol. 19, no. 3, pp. 250–272, 1951. DOI: 10.2307/1906813
- [15] P. Zipkin, “Old and new methods for lost-sales inventory systems,” *Operations Research*, vol. 56, no. 5, pp. 1256–1263, 2008. DOI: 10.1287/opre.1070.0471
- [16] A. Oroojlooyjadid, M. Nazari, L. V. Snyder, and M. Takáč, “A deep Q-network for the beer game: Deep reinforcement learning for inventory optimization,” *Manufacturing & Service Operations Management*, vol. 24, no. 1, pp. 285–304, 2022. DOI: 10.1287/msom.2020.0939
- [17] J. Gijsbrechts, R. N. Boute, J. A. Van Mieghem, and D. J. Zhang, “Can deep reinforcement learning improve inventory management? Performance on lost sales, dual-sourcing, and multi-echelon problems,” *Manufacturing & Service Operations Management*, vol. 24, no. 3, pp. 1349–1368, 2022. DOI: 10.1287/msom.2021.1064
- [18] J. K. Gupta, M. Egorov, and M. Kochenderfer, “Cooperative multi-agent control using deep reinforcement learning,” in *Autonomous Agents and Multiagent Systems (AAMAS 2017 Workshops)*, ser. Lecture Notes in Computer Science, vol. 10642, Springer, 2017, pp. 66–83. DOI: 10.1007/978-3-319-71682-4_5
- [19] M. Tan, “Multi-agent reinforcement learning: Independent vs. cooperative agents,” in *Proceedings of the 10th International Conference on Machine Learning*, 1993, pp. 330–337.

- [20] C. Schröder de Witt et al., *Is independent learning all you need in the StarCraft multi-agent challenge?* 2020. arXiv: 2011.09533.
- [21] C. Yu et al., “The surprising effectiveness of PPO in cooperative multi-agent games,” in *Advances in Neural Information Processing Systems 35 (NeurIPS 2022), Datasets and Benchmarks Track*, 2022, pp. 24 611–24 624.
- [22] H. Zhu and H. Wu, “Deep learning and multi-agent simulation for spatiotemporal inventory management in e-commerce,” *International Journal of Simulation and Process Modelling*, vol. 23, no. 5, pp. 11–23, 2026. DOI: 10.1504/IJSPM.2026.152575
- [23] H. Nam, S. Im, J. Lee, C. Shin, and H. Ju. “Action-linked credit assignment for event-driven warehouse management via multi-agentic reinforcement learning.” Preprint, not peer reviewed, SSRN. [Online]. Available: <https://ssrn.com/abstract=7068293>
- [24] M. Towers, A. Kwiatkowski, J. Terry, J. U. Balis, G. De Cola, T. Deleu, et al., *Gymnasium: A standard interface for reinforcement learning environments*, 2024. arXiv: 2407.17032.
- [25] D. H. Wolpert and K. Tumer, “Optimal payoff functions for members of collectives,” *Advances in Complex Systems*, vol. 4, no. 2–3, pp. 265–279, 2001. DOI: 10.1142/S0219525901000188
- [26] J. Schulman, F. Wolski, P. Dhariwal, A. Radford, and O. Klimov, *Proximal policy optimization algorithms*, 2017. arXiv: 1707.06347.
- [27] J. Schulman, P. Moritz, S. Levine, M. Jordan, and P. Abbeel, “High-dimensional continuous control using generalized advantage estimation,” in *Proceedings of the 4th International Conference on Learning Representations (ICLR)*, 2016. arXiv: 1506.02438.
- [28] P. Henderson, R. Islam, P. Bachman, J. Pineau, D. Precup, and D. Meger, “Deep reinforcement learning that matters,” in *Proceedings of the 32nd AAAI Conference on Artificial Intelligence*, 2018, pp. 3207–3214.
- [29] R. Agarwal, M. Schwarzer, P. S. Castro, A. Courville, and M. G. Bellemare, “Deep reinforcement learning at the edge of the statistical precipice,” in *Ad-*

- vances in Neural Information Processing Systems 34 (NeurIPS 2021)*, 2021, pp. 29 304–29 320.
- [30] A. J. Clark and H. Scarf, “Optimal policies for a multi-echelon inventory problem,” *Management Science*, vol. 6, no. 4, pp. 475–490, 1960. DOI: 10.1287/mnsc.6.4.475
 - [31] H. L. Lee, V. Padmanabhan, and S. Whang, “Information distortion in a supply chain: The bullwhip effect,” *Management Science*, vol. 43, no. 4, pp. 546–558, 1997. DOI: 10.1287/mnsc.43.4.546
 - [32] M. L. Puterman, *Markov Decision Processes: Discrete Stochastic Dynamic Programming*. New York: John Wiley & Sons, 1994.
 - [33] G. Brockman et al., *OpenAI Gym*, 2016. arXiv: 1606.01540.
 - [34] J. Schulman, S. Levine, P. Abbeel, M. Jordan, and P. Moritz, “Trust region policy optimization,” in *Proceedings of the 32nd International Conference on Machine Learning*, 2015, pp. 1889–1897.
 - [35] R. E. Bellman, *Dynamic Programming*. Princeton, NJ: Princeton University Press, 1957.
 - [36] A. Y. Ng, D. Harada, and S. Russell, “Policy invariance under reward transformations: Theory and application to reward shaping,” in *Proceedings of the 16th International Conference on Machine Learning*, 1999, pp. 278–287.
 - [37] S. Devlin and D. Kudenko, “Theoretical considerations of potential-based reward shaping for multi-agent systems,” in *Proceedings of the 10th International Conference on Autonomous Agents and Multiagent Systems (AAMAS 2011)*, 2011, pp. 225–232.
 - [38] B. De Moor, J. Gijsbrechts, and R. N. Boute, “Reward shaping to improve the performance of deep reinforcement learning in perishable inventory management,” *European Journal of Operational Research*, vol. 301, no. 2, pp. 535–545, 2022. DOI: 10.1016/j.ejor.2021.11.026
 - [39] C. D. Hubbs, H. D. Perez, O. Sarwar, N. V. Sahinidis, I. E. Grossmann, and J. M. Wassick, *OR-Gym: A reinforcement learning library for operations research problems*, 2020. arXiv: 2008.06319.

- [40] Y. Ding et al., *Multi-agent reinforcement learning with shared resources for inventory management*, Presented at the RL4RealLife Workshop, NeurIPS 2022, 2022. arXiv: 2212.07684.
- [41] X. Yang et al., *A versatile multi-agent reinforcement learning benchmark for inventory management*, 2023. DOI: 10.48550/arXiv.2306.07542 arXiv: 2306.07542.
- [42] M. Mousa, D. van de Berg, N. Kotecha, E. A. del Rio Chanona, and M. Mowbray, “An analysis of multi-agent reinforcement learning for decentralized inventory control systems,” *Computers & Chemical Engineering*, vol. 188, p. 108783, 2024. DOI: 10.1016/j.compchemeng.2024.108783
- [43] X. Liu, M. Hu, Y. Peng, and Y. Yang, “Multi-agent deep reinforcement learning for multi-echelon inventory management,” *Production and Operations Management*, vol. 34, no. 7, pp. 1836–1856, 2025. DOI: 10.1177/10591478241305863