

**TỔNG LIÊN ĐOÀN LAO ĐỘNG VIỆT NAM
TRƯỜNG ĐẠI HỌC TÔN ĐỨC THẮNG
KHOA CÔNG NGHỆ THÔNG TIN**



**LÊ MINH LÝ - 52300220
SỬ THỊ YẾN LINH - 52300218**

**XÂY DỰNG MÔ HÌNH HỌC TĂNG
CƯỜNG TỐI ƯU HÓA CHÍNH SÁCH ĐẶT
HÀNG LẠI TRONG QUẢN LÝ TỒN KHO
ĐA KHO**

**KHÓA LUẬN TỐT NGHIỆP
MẠNG MÁY TÍNH VÀ TRUYỀN THÔNG
DỮ LIỆU**

THÀNH PHỐ HỒ CHÍ MINH, NĂM 2026

**TỔNG LIÊN ĐOÀN LAO ĐỘNG VIỆT NAM
TRƯỜNG ĐẠI HỌC TÔN ĐỨC THẮNG
KHOA CÔNG NGHỆ THÔNG TIN**



**LÊ MINH LÝ - 52300220
SỬ THỊ YẾN LINH - 52300218**

**XÂY DỰNG MÔ HÌNH HỌC TĂNG
CƯỜNG TỐI ƯU HÓA CHÍNH SÁCH ĐẶT
HÀNG LẠI TRONG QUẢN LÝ TỒN KHO
ĐA KHO**

**KHÓA LUẬN TỐT NGHIỆP
MẠNG MÁY TÍNH VÀ TRUYỀN THÔNG
DỮ LIỆU**

**Giảng viên hướng dẫn
TS. HỒ THỊ LINH**

THÀNH PHỐ HỒ CHÍ MINH, NĂM 2026

LỜI CẢM ƠN

Đầu tiên, chúng em xin gửi lời cảm ơn chân thành và sâu sắc nhất đến TS. Hồ Thị Linh, giảng viên hướng dẫn khóa luận tốt nghiệp. Sự hướng dẫn tận tình, những ý kiến đóng góp quý báu và sự hỗ trợ kịp thời của cô đã định hướng và giúp chúng em hoàn thành tốt khóa luận này.

Bên cạnh đó, chúng em cũng xin cảm ơn khoa Công nghệ Thông tin, trường Đại học Tôn Đức Thắng đã tạo điều kiện học tập và cung cấp những nền tảng kiến thức vững chắc, tạo môi trường thuận lợi để chúng em có thể áp dụng vào thực tiễn. Do thời gian và trình độ còn những hạn chế nhất định, báo cáo chắc chắn không tránh khỏi những thiếu sót. Chúng em rất mong nhận được sự cảm thông và những lời góp ý chân thành từ quý thầy cô để đề tài được hoàn thiện hơn và chúng em rút ra được những bài học quý giá.

Chúng em xin chân thành cảm ơn!

TP. Hồ Chí Minh, ngày 09 tháng 05 năm 2026

Tác giả

(Ký và ghi rõ họ tên)

Lê Minh Lý

Tác giả

(Ký và ghi rõ họ tên)

Sử Thị Yến Linh

CÔNG TRÌNH ĐƯỢC HOÀN THÀNH TẠI TRƯỜNG ĐẠI HỌC TÔN ĐỨC THẮNG

Chúng tôi xin cam đoan đây là công trình nghiên cứu của chúng tôi và được sự hướng dẫn khoa học của TS. Hồ Thị Linh. Các nội dung nghiên cứu, kết quả trong đề tài này là trung thực và chưa công bố dưới bất kỳ hình thức nào trước đây. Những số liệu trong các bảng biểu phục vụ cho việc phân tích, nhận xét, đánh giá được chính tác giả thu thập từ các nguồn khác nhau có ghi rõ trong phần tài liệu tham khảo.

Ngoài ra, trong Khóa luận tốt nghiệp còn sử dụng một số nhận xét, đánh giá cũng như số liệu của các tác giả khác, cơ quan tổ chức khác đều có trích dẫn và chú thích nguồn gốc.

Nếu phát hiện có bất kỳ sự gian lận nào chúng tôi xin hoàn toàn chịu trách nhiệm về nội dung Khóa luận tốt nghiệp của mình. Trường Đại học Tôn Đức Thắng không liên quan đến những vi phạm tác quyền, bản quyền do chúng tôi gây ra trong quá trình thực hiện (nếu có).

TP. Hồ Chí Minh, ngày 09 tháng 05 năm 2026

Tác giả

(Ký và ghi rõ họ tên)

Tác giả

(Ký và ghi rõ họ tên)

Lê Minh Lý

Sử Thị Yến Linh

PHẦN XÁC NHẬN VÀ ĐÁNH GIÁ CỦA GIẢNG VIÊN

Phần xác nhận của GV hướng dẫn

Tp. Hồ Chí Minh, ngàytháng

.....năm

(Ký và ghi họ tên)

Phần đánh giá của GV chấm bài

Tp. Hồ Chí Minh, ngàytháng

.....năm

(Ký và ghi họ tên)

XÂY DỰNG MÔ HÌNH HỌC TĂNG CƯỜNG TỐI ƯU HÓA CHÍNH SÁCH ĐẶT HÀNG LẠI TRONG QUẢN LÝ TỒN KHO ĐA KHO

TÓM TẮT

Quản lý tồn kho trong mạng lưới bán lẻ gồm nhiều kho và nhiều mặt hàng là bài toán ra quyết định tuần tự dưới điều kiện bất định, đòi hỏi cân bằng đồng thời nhiều nhóm chi phí xung đột nhau: chi phí lưu kho, chi phí thiếu hàng, chi phí đặt hàng cố định, chi phí phạt tràn kho và yêu cầu duy trì mức phục vụ khách hàng. Các chính sách cổ điển như EOQ, (s, S) và Newsvendor được xây dựng trên những giả định chặt — nhu cầu xác định hoặc dừng, thời gian giao hàng cố định, không ràng buộc sức chứa — nên khó giữ được tính tối ưu khi nhu cầu ngẫu nhiên, thời gian giao hàng biến động và các mặt hàng phải chia sẻ một dung lượng kho hữu hạn.

Khóa luận đề xuất giải quyết bài toán trên bằng học tăng cường đa tác tử. Hệ thống gồm $N = 10$ kho và $M = 30$ mặt hàng đại diện được mô hình hóa thành 300 tác tử tương ứng với 300 cặp kho–mặt hàng, mỗi tác tử tự ra quyết định đặt hàng dựa trên quan sát cục bộ của mình. Các tác tử được huấn luyện bằng thuật toán Independent Multi-Agent Proximal Policy Optimization (IPPO) kết hợp cơ chế chia sẻ tham số (parameter sharing): toàn bộ 300 tác tử dùng chung một bộ trọng số Actor–Critic duy nhất, cho phép mở rộng quy mô mà không làm bùng nổ số lượng tham số cần học. Hàm phần thưởng được thiết kế theo hướng phân rã cục bộ (local reward decomposition) kèm thành phần phạt dựa trên tỷ lệ đáp ứng nhu cầu tính trên cửa sổ trượt 30 ngày và cơ chế chuẩn hóa phần thưởng theo từng cặp, nhằm giảm phương sai của tín hiệu học giữa các mặt hàng có quy mô chi phí chênh lệch nhiều bậc độ lớn.

Môi trường mô phỏng được xây dựng theo chuẩn Gymnasium, với tham số nhu cầu và giá bán được hiệu chỉnh từ bộ dữ liệu bán lẻ thực tế M5 Walmart (10 cửa hàng, 30 mặt hàng đại diện, 1.941 ngày doanh số) và thời gian giao hàng ngẫu nhiên trong khoảng từ một đến ba ngày. Hiệu năng của mô hình đề xuất được đối chứng với ba chính sách tồn kho cổ điển (EOQ, (s, S) , Newsvendor) đã được tinh chỉnh tham số bằng tìm kiếm lưới trên cùng môi trường, theo một giao thức đánh giá thống nhất gồm nhiều hạt giống ngẫu nhiên và kiểm định thống kê, trên bốn nhóm chỉ số: tổng chi phí vận hành, tỷ lệ đáp ứng nhu cầu, và cơ cấu các thành phần chi phí.

Kết quả thực nghiệm cho thấy khi so sánh ở cùng một mức phục vụ tối thiểu,

IPPO đạt tổng chi phí vận hành thấp nhất trong cả bốn phương pháp – rẻ hơn EOQ 47,5%, rẻ hơn (s, S) 21,2% và rẻ hơn Newsvendor 11,3% – trong khi so sánh trực tiếp không kiểm soát mức phục vụ lại cho kết luận sai lệch rằng IPPO đắt hơn EOQ. Cơ chế chia sẻ tham số tổng quát hóa tốt cho các mặt hàng có nhu cầu từ trung bình trở lên, nhưng chưa bù đắp hoàn toàn cho các mặt hàng có nhu cầu thấp và gián đoạn nhất. Khóa luận đồng thời trình bày trung thực những kịch bản mà phương pháp đề xuất chưa vượt trội so với chính sách cổ điển, cùng những hạn chế và hướng nghiên cứu tiếp theo.

BUILDING A REINFORCEMENT LEARNING MODEL FOR OPTIMIZING REORDER POLICY IN MULTI-WAREHOUSE INVENTORY MANAGEMENT

ABSTRACT

Inventory control across a retail network of multiple warehouses and multiple stock-keeping units (SKUs) is a sequential decision-making problem under uncertainty that requires balancing several conflicting cost components at once: holding cost, stockout cost, fixed ordering cost, warehouse overflow penalty, and the requirement to sustain a target customer service level. Classical policies such as EOQ, (s, S) and the Newsvendor model rest on restrictive assumptions — deterministic or stationary demand, fixed lead times, and unconstrained storage capacity — and therefore lose their optimality guarantees once demand is stochastic, lead times fluctuate, and multiple SKUs must share a finite warehouse capacity.

This thesis addresses the problem through multi-agent reinforcement learning. A system of $N = 10$ warehouses and $M = 30$ representative SKUs is modelled as 300 agents, one per warehouse–SKU pair, each issuing its own replenishment decisions from local observations. The agents are trained with Independent Multi-Agent Proximal Policy Optimization (IPPO) under full parameter sharing: a single set of Actor–Critic weights is shared across all 300 agents, which keeps the number of learnable parameters constant as the system scales. The reward is designed with local decomposition, a 30-day rolling-window fill-rate penalty term, and a per-pair normalization mechanism that reduces the variance of the learning signal across SKUs whose cost scales differ by several orders of magnitude.

The simulation environment follows the Gymnasium interface, with demand and price parameters calibrated from the real-world M5 Walmart retail dataset (10 stores, 30 representative SKUs, 1,941 days of sales data) and stochastic lead times drawn from one to three days. The proposed model is benchmarked against three classical inventory policies (EOQ, (s, S) , Newsvendor), each tuned by grid search on the same environment, under a unified evaluation protocol involving multiple random seeds and statistical significance testing, across four metric groups: total operational cost, fill rate, and the breakdown of individual cost components.

Experimental results show that, when compared at a matched minimum service

level, IPPO achieves the lowest total operational cost among all four methods – 47.5% cheaper than EOQ, 21.2% cheaper than (s, S) , and 11.3% cheaper than the Newsvendor policy – whereas an unmatched direct comparison misleadingly suggests IPPO is more expensive than EOQ. The shared-parameter policy generalizes well to medium- and high-demand SKUs but does not fully close the service-level gap for the lowest-demand, most intermittent SKUs. The thesis also reports, in full honesty, the scenarios in which the proposed method does not outperform the classical baselines, together with the study’s limitations and directions for future work.

MỤC LỤC

DANH MỤC HÌNH VẼ.....	xi
DANH MỤC BẢNG BIỂU.....	xii
DANH MỤC CÁC CHỮ VIẾT TẮT	xiii
CHƯƠNG 1. TỔNG QUAN VỀ ĐỀ TÀI.....	1
1.1 Bối cảnh nghiên cứu và tính cấp thiết của đề tài	1
1.1.1 <i>Thực trạng quản lý tồn kho trong mạng lưới bán lẻ đa điểm</i>	<i>1</i>
1.1.2 <i>Thách thức trong việc tối ưu hóa chính sách đặt hàng lại.....</i>	<i>2</i>
1.1.3 <i>Hạn chế của phương pháp truyền thống và sự cần thiết của học tăng cường đa tác tử.....</i>	<i>3</i>
1.2 Mục tiêu và câu hỏi nghiên cứu	4
1.2.1 <i>Mục tiêu nghiên cứu</i>	<i>4</i>
1.2.2 <i>Câu hỏi nghiên cứu</i>	<i>4</i>
1.3 Đối tượng và phạm vi nghiên cứu	5
1.3.1 <i>Đối tượng nghiên cứu</i>	<i>5</i>
1.3.2 <i>Phạm vi trong đề tài</i>	<i>5</i>
1.3.3 <i>Giới hạn phạm vi</i>	<i>6</i>
1.4 Phương pháp nghiên cứu	6
1.5 Ý nghĩa khoa học và thực tiễn của đề tài.....	7
1.6 Bố cục của khóa luận.....	7
CHƯƠNG 2. CƠ SỞ LÝ THUYẾT VÀ CÁC CÔNG TRÌNH LIÊN QUAN	8
2.1 Lý thuyết kiểm soát tồn kho ngẫu nhiên	8
2.1.1 <i>Mô hình tồn kho và các thành phần chi phí</i>	<i>8</i>
2.1.2 <i>Các chính sách đặt hàng lại cổ điển</i>	<i>9</i>
2.1.3 <i>Các thước đo mức phục vụ trong quản lý tồn kho</i>	<i>9</i>
2.2 Nền tảng học tăng cường.....	10
2.2.1 <i>Quá trình quyết định Markov (MDP)</i>	<i>10</i>

2.2.2	Hàm giá trị và phương trình Bellman.....	10
2.2.3	Ước lượng lợi thế tổng quát (GAE).....	11
2.2.4	Thuật toán PPO (Proximal Policy Optimization).....	11
2.3	Học tăng cường đa tác tử.....	11
2.3.1	Mô hình Dec-POMDP	11
2.3.2	Học độc lập (Independent Learning).....	12
2.3.3	IPPO — Independent Multi-Agent PPO	12
2.3.4	Chia sẻ tham số (Parameter Sharing)	12
2.3.5	Phần thưởng phân rã cục bộ và bài toán gán tín dụng.....	13
2.4	Các công trình nghiên cứu liên quan	13
2.4.1	Học tăng cường trong quản lý tồn kho	13
2.4.2	Khoảng trống nghiên cứu và định vị đóng góp.....	14
	CHƯƠNG 3. PHÂN TÍCH VÀ THIẾT KẾ MÔ HÌNH	16
3.1	Mô hình hóa bài toán tồn kho đa kho	16
3.1.1	Mô tả mạng lưới.....	16
3.1.2	Thiết lập bài toán dưới dạng MDP đa tác tử.....	17
3.1.3	Phân chia miền dữ liệu huấn luyện – kiểm định – kiểm tra	19
3.2	Thiết kế hàm phần thưởng	19
3.2.1	Phần thưởng phân rã cục bộ	19
3.2.2	Chuẩn hóa phần thưởng theo từng cặp.....	20
3.2.3	Vai trò của thành phần phạt fill rate	20
3.2.4	Các tham số chi phí.....	21
3.3	Kiến trúc mạng Actor–Critic chia sẻ tham số.....	22
3.3.1	Hai mạng Actor và Critic độc lập, chia sẻ giữa các tác tử.....	22
3.3.2	Ổn định hóa quá trình huấn luyện	22
3.3.3	Quy trình huấn luyện IPPO.....	23
3.4	Thiết kế môi trường mô phỏng	24
	CHƯƠNG 4. THỰC NGHIỆM VÀ ĐÁNH GIÁ KẾT QUẢ	26

4.1	Cấu hình thực nghiệm.....	26
4.1.1	Môi trường phần cứng và phần mềm	26
4.1.2	Nguồn dữ liệu và tiền xử lý	26
4.1.3	Thiết lập kịch bản mô phỏng	27
4.2	Phương pháp đối chứng (Baselines).....	27
4.3	Giao thức đánh giá.....	28
4.3.1	Đánh giá đa hạt giống	28
4.3.2	Các chỉ số đánh giá.....	28
4.4	Kết quả thực nghiệm	28
4.4.1	Quá trình huấn luyện và tính hội tụ	28
4.4.2	So sánh trực tiếp tổng chi phí vận hành.....	29
4.4.3	So sánh ở cùng mức phục vụ	30
4.4.4	Phân tích cơ cấu chi phí.....	31
4.4.5	Đánh giá tỷ lệ đáp ứng dịch vụ theo nhiều hạt giống.....	32
4.5	Phân tích chuyên sâu	32
4.5.1	Khả năng tổng quát hóa qua parameter sharing (Câu hỏi 2)	32
4.5.2	Vai trò của cơ chế chuẩn hóa phần thưởng cục bộ (Câu hỏi 3)	33
4.5.3	Các kịch bản IPPO chưa vượt trội	34
4.6	Thảo luận	35
	CHƯƠNG 5. KẾT LUẬN VÀ HƯỚNG PHÁT TRIỂN.....	36
5.1	Tổng kết các kết quả đạt được	36
5.1.1	Trả lời các câu hỏi nghiên cứu	36
5.2	Những hạn chế còn tồn tại	37
5.3	Hướng phát triển trong tương lai.....	38
	PHỤ LỤC A. ĐỐI CHIẾU LUẬN ĐIỂM VÀ NGUỒN TRÍCH DẪN	40
	TÀI LIỆU THAM KHẢO.....	43

DANH MỤC HÌNH VẼ

Hình 4.1: Đường cong huấn luyện IPPO qua 5000 episode: phần thưởng trung bình trượt, tỷ lệ đáp ứng nhu cầu, entropy chính sách và explained variance của Critic	29
Hình 4.2: Tổng chi phí vận hành của bốn chính sách khi mọi chính sách đều đạt tối thiểu mức phục vụ mà IPPO đạt được (miền kiểm tra).....	31
Hình 4.3: So sánh trực tiếp tổng chi phí, tỷ lệ đáp ứng nhu cầu và cơ cấu chi phí giữa bốn phương pháp (miền kiểm tra)	31
Hình 4.4: Đánh đổi giữa tổng chi phí vận hành và tỷ lệ đáp ứng nhu cầu của bốn phương pháp (miền kiểm tra); điểm càng gần góc dưới bên phải càng tốt	32
Hình 4.5: Fill rate và chi phí cục bộ trung bình theo nhóm quy mô cầu (miền kiểm tra).....	33

DANH MỤC BẢNG BIỂU

Bảng 1.1: Phân loại dạng nhu cầu của 30.490 chuỗi cửa hàng–mặt hàng trong bộ dữ liệu M5 theo tiêu chí của Syntetos và cộng sự [4]	2
Bảng 1.2: Các nhóm chi phí trong bài toán tồn kho đang xét.....	2
Bảng 2.1: So sánh tổng quan các công trình nghiên cứu liên quan.....	14
Bảng 3.1: Tham số chi phí trong môi trường mô phỏng	21
Bảng 3.2: Siêu tham số huấn luyện.....	24
Bảng 4.1: Cấu hình môi trường mô phỏng.....	27
Bảng 4.2: Tham số baseline sau tìm kiếm lưới trên miền huấn luyện	27
Bảng 4.3: So sánh trực tiếp tổng chi phí vận hành trên miền kiểm tra (trung bình 30 episode).....	30
Bảng 4.4: So sánh tổng chi phí ở cùng mức phục vụ tối thiểu 84,71% (miền kiểm tra).....	30
Bảng 4.5: Fill rate và chi phí cục bộ trung bình mỗi cặp mỗi ngày theo nhóm quy mô cầu (miền kiểm tra, 30 episode)	33

DANH MỤC CÁC CHỮ VIẾT TẮT

Dec-POMDP	Decentralized Partially Observable Markov Decision Process (Quá trình quyết định Markov có quan sát bộ phận phi tập trung)
EOQ	Economic Order Quantity (Lượng đặt hàng kinh tế)
GAE	Generalized Advantage Estimation (Ước lượng lợi thế tổng quát)
IPPO	Independent Proximal Policy Optimization (Tối ưu hóa chính sách cận đại độc lập)
MARL	Multi-Agent Reinforcement Learning (Học tăng cường đa tác tử)
MDP	Markov Decision Process (Quá trình quyết định Markov)
MLP	Multilayer Perceptron (Mạng nơ-ron truyền thẳng đa tầng)
PPO	Proximal Policy Optimization (Tối ưu hóa chính sách cận đại)
RL	Reinforcement Learning (Học tăng cường)
SCM	Supply Chain Management (Quản trị chuỗi cung ứng)
SKU	Stock Keeping Unit (Đơn vị quản lý tồn kho)
SNAP	Supplemental Nutrition Assistance Program (Chương trình trợ cấp dinh dưỡng)

CHƯƠNG 1. TỔNG QUAN VỀ ĐỀ TÀI

1.1 Bối cảnh nghiên cứu và tính cấp thiết của đề tài

1.1.1 Thực trạng quản lý tồn kho trong mạng lưới bán lẻ đa điểm

Trong hoạt động bán lẻ hiện đại, hàng hóa không được lưu trữ tập trung tại một điểm duy nhất mà được phân tán trên một mạng lưới gồm nhiều kho hoặc nhiều cửa hàng đặt tại các khu vực địa lý khác nhau. Mỗi điểm lưu trữ phục vụ một tập khách hàng riêng, đối mặt với một chuỗi nhu cầu riêng và phải tự ra quyết định bổ sung hàng hóa cho hàng trăm đến hàng nghìn mặt hàng khác nhau [1]. Bài toán vì vậy không còn là việc xác định một mức đặt hàng đơn lẻ, mà là việc điều phối đồng thời một số lượng rất lớn các quyết định có ràng buộc lẫn nhau.

Đặc điểm này thể hiện rõ trong dữ liệu bán lẻ thực tế. Bộ dữ liệu M5, công bố trong cuộc thi dự báo M5 do Makridakis và cộng sự [2] tổ chức, ghi nhận doanh số bán hàng theo ngày của 3.049 mặt hàng tại 10 cửa hàng của Walmart thuộc ba bang California, Texas và Wisconsin, trải trên 1.941 ngày từ ngày 29 tháng 01 năm 2011 đến ngày 22 tháng 05 năm 2016¹. Tổ hợp của hàng và mặt hàng tạo thành 30.490 chuỗi thời gian nhu cầu ở cấp độ chi tiết nhất.

Thống kê trên toàn bộ 30.490 chuỗi này cho thấy hai đặc trưng có ảnh hưởng trực tiếp tới thiết kế chính sách đặt hàng. Thứ nhất, nhu cầu ở cấp cửa hàng–mặt hàng có quy mô rất nhỏ và phân bố lệch mạnh: nhu cầu trung bình là 1,13 đơn vị mỗi ngày, nhưng trung vị chỉ là 0,45 đơn vị, và 73,4% số chuỗi có nhu cầu trung bình dưới một đơn vị mỗi ngày. Thứ hai, nhu cầu mang tính gián đoạn rõ rệt, với tỷ lệ ngày không phát sinh giao dịch trung bình đạt 68%. Áp dụng tiêu chí phân loại của Syntetos và cộng sự [4] với các ngưỡng khoảng cách giữa hai lần phát sinh nhu cầu $p = 1,32$ và bình phương hệ số biến thiên $CV^2 = 0,49$ (trong đó Kostenko và Hyndman [5] đã chứng minh kết quả biên chính xác với giá trị giới hạn $p = 4/3 \approx 1,333$ và đề xuất quy tắc phân loại chỉnh sửa), có tới 95,2% số chuỗi thuộc hai nhóm *intermittent* và *lumpy* (Bảng 1.1).

Đặc điểm gián đoạn này khiến các phương pháp dự báo và các công thức tồn kho xây dựng trên giả định nhu cầu liên tục và phân phối chuẩn trở nên kém phù hợp

¹Các thống kê được tính từ hai tệp `calendar.csv` và `sales_train_evaluation.csv` trong bộ dữ liệu M5 [3].

Bảng 1.1: Phân loại dạng nhu cầu của 30.490 chuỗi cửa hàng–mặt hàng trong bộ dữ liệu M5 theo tiêu chí của Syntetos và cộng sự [4]

Nhóm	Đặc điểm	Tỷ lệ
Smooth	$p < 1,32; CV^2 < 0,49$	3,2%
Erratic	$p < 1,32; CV^2 \geq 0,49$	1,6%
Intermittent	$p \geq 1,32; CV^2 < 0,49$	75,7%
Lumpy	$p \geq 1,32; CV^2 \geq 0,49$	19,5%

[6], [7]. Quản lý tồn kho trên một mạng lưới như vậy đòi hỏi những công cụ ra quyết định có khả năng thích ứng, thay vì các bộ tham số tĩnh được thiết lập một lần và áp dụng cố định.

1.1.2 Thách thức trong việc tối ưu hóa chính sách đặt hàng lại

Việc xây dựng chính sách đặt hàng lại trong mạng lưới đa kho – đa mặt hàng đối mặt với bốn nhóm thách thức chính.

Thứ nhất, tính bất định kép của nhu cầu và thời gian giao hàng. Nhu cầu tiêu thụ biến động ngẫu nhiên theo thời gian, đồng thời thời gian từ lúc phát lệnh đặt hàng đến lúc hàng thực nhập kho cũng không cố định [8]. Khi thời gian giao hàng là biến ngẫu nhiên, các đơn hàng phát ra ở những thời điểm khác nhau có thể về kho không đúng thứ tự, khiến các công thức tính tồn kho an toàn cổ điển chỉ còn giữ vai trò xấp xỉ [1].

Thứ hai, bài toán đánh đổi giữa nhiều nhóm chi phí xung đột. Mục tiêu vận hành không quy về một đại lượng duy nhất mà là tổng hợp của nhiều thành phần có chiều tác động ngược nhau, được tóm tắt trong Bảng 1.2. Giảm tồn kho làm giảm chi phí lưu kho nhưng làm tăng rủi ro thiếu hàng; đặt hàng theo lô lớn làm giảm chi phí đặt hàng cố định nhưng làm tăng chi phí lưu kho và nguy cơ vượt sức chứa [8].

Bảng 1.2: Các nhóm chi phí trong bài toán tồn kho đang xét

Thành phần chi phí	Ký hiệu	Chiều tác động
Chi phí lưu kho	c_{lk}	Tăng khi mức tồn kho cao
Chi phí thiếu hàng	c_{th}	Tăng khi xảy ra hết hàng
Chi phí đặt hàng cố định	c_{dh}	Tăng theo tần suất đặt hàng
Phạt tràn kho	p_{tk}	Tăng khi vượt sức chứa kho
Phạt vi phạm mức phục vụ	ϕ_{dv}	Tăng khi tỷ lệ đáp ứng dưới ngưỡng

Thứ ba, ràng buộc sức chứa tạo ra sự phụ thuộc giữa các mặt hàng. Các mặt hàng cùng nằm trong một kho chia sẻ một dung lượng hữu hạn. Quyết định đặt hàng

của một mặt hàng do đó ảnh hưởng trực tiếp tới chi phí mà các mặt hàng khác trong cùng kho phải gánh chịu. Bài toán vì vậy không thể tách rời thành các bài toán độc lập, mà mang bản chất của một bài toán ra quyết định hợp tác [9].

Thứ tư, quy mô không gian hành động. Với N kho và M mặt hàng, mỗi cặp có K mức đặt hàng khả dĩ, không gian hành động chung là tích Descartes có kích thước K^{NM} . Với cấu hình của khóa luận ($N = 10, M = 30, K = 6$), con số này là 6^{300} — vượt xa khả năng xử lý của bất kỳ phương pháp tìm kiếm tập trung nào, và cũng vượt quá khả năng biểu diễn của các thuật toán học tăng cường dựa trên hàm giá trị vốn phải liệt kê toàn bộ hành động khả dĩ [10]. Trên phương diện lý thuyết độ phức tạp, bài toán điều khiển phi tập trung dạng này đã được chứng minh thuộc lớp NEXP-đầy đủ [11], nên các lời giải chính xác không khả thi ở quy mô thực tế.

1.1.3 Hạn chế của phương pháp truyền thống và sự cần thiết của học tăng cường đa tác tử

Các chính sách tồn kho cổ điển đều được xây dựng trên những tập giả định cụ thể. Mô hình lượng đặt hàng kinh tế của Harris [12] giả định nhu cầu xác định và đều, không có tình trạng thiếu hàng. Chính sách (s, S) được Scarf [13] chứng minh tối ưu cho hệ đơn kho với nhu cầu độc lập giữa các kỳ, chi phí đặt hàng cố định và cơ chế giữ đơn hàng chờ. Mô hình người bán báo của Arrow và cộng sự [14] chỉ tối ưu cho một chu kỳ đơn lẻ, không xét tới lượng hàng đang trên đường vận chuyển. Không mô hình nào trong số đó xử lý được đồng thời nhu cầu ngẫu nhiên, thời gian giao hàng biến động, ràng buộc sức chứa dùng chung và yêu cầu duy trì mức phục vụ tối thiểu. Riêng với cơ chế mất đơn hàng khi thiếu hàng — vốn phù hợp với bối cảnh bán lẻ — Zipkin [15] chỉ ra rằng bài toán không còn nghiệm giải tích dạng đóng và các chính sách cổ điển mất tính tối ưu đã được chứng minh.

Học tăng cường cung cấp một hướng tiếp cận khác: thay vì giả định trước dạng phân phối của nhu cầu và suy ra chính sách bằng giải tích, tác tử học chính sách trực tiếp thông qua tương tác lặp lại với môi trường [10]. Hướng này đã được kiểm chứng trên các bài toán tồn kho quy mô nhỏ: Oroojlooyjadid và cộng sự [16] áp dụng mạng Q sâu cho trò chơi phân phối bia, còn Gijsbrechts và cộng sự [17] đánh giá học tăng cường sâu trên ba lớp bài toán tồn kho gồm mất đơn hàng, hai nguồn cung và đa cấp.

Tuy nhiên, việc áp dụng học tăng cường đơn tác tử cho toàn bộ mạng lưới vấp phải chính vấn đề quy mô đã nêu ở mục trên. Học tăng cường đa tác tử với cơ chế chia sẻ tham số cho phép vượt qua trở ngại này [18]: mỗi cặp kho–mặt hàng được xem là

một tác tử ra quyết định độc lập trên quan sát cục bộ theo hướng tiếp cận học độc lập của Tan [19], trong khi toàn bộ các tác tử cùng học chung một bộ trọng số. Nhờ đó, không gian hành động mà mỗi tác tử phải xử lý thu về kích thước K , còn số tham số cần học không tăng theo quy mô hệ thống. Các nghiên cứu gần đây cho thấy phương pháp học độc lập dựa trên PPO đạt hiệu năng cạnh tranh trên nhiều môi trường hợp tác [20], [21].

Khảo sát tài liệu cho thấy phần lớn các nghiên cứu áp dụng học tăng cường cho quản lý tồn kho hiện nay được tiến hành ở quy mô nhỏ, với một vài kho và một vài mặt hàng, trên dữ liệu nhu cầu sinh theo phân phối lý thuyết. Số công trình đồng thời mở rộng tới quy mô hàng trăm cặp kho–mặt hàng bằng cơ chế chia sẻ tham số, đánh giá tường minh ảnh hưởng của cách phân rã hàm phần thưởng ở quy mô đó, và hiệu chỉnh môi trường mô phỏng từ dữ liệu bán lẻ thực tế còn hạn chế. Đây chính là khoảng trống mà khóa luận hướng tới.

1.2 Mục tiêu và câu hỏi nghiên cứu

1.2.1 Mục tiêu nghiên cứu

Khóa luận đặt ra bốn mục tiêu cụ thể:

- Xây dựng môi trường mô phỏng tồn kho đa kho – đa mặt hàng theo chuẩn Gymnasium [22], mô hình hóa đầy đủ nhu cầu ngẫu nhiên, thời gian giao hàng biến động, ràng buộc sức chứa và năm nhóm chi phí vận hành; tham số nhu cầu được hiệu chỉnh từ bộ dữ liệu M5 Walmart.
- Thiết kế hàm phần thưởng phân rã cục bộ kèm thành phần phạt dựa trên tỷ lệ đáp ứng nhu cầu tính trên cửa sổ trượt, bảo đảm tín hiệu học phản ánh đúng đóng góp của từng tác tử [23].
- Cài đặt và huấn luyện thuật toán Independent Multi-Agent PPO [20], [24] với cơ chế chia sẻ tham số cho 300 cặp kho–mặt hàng, sử dụng ước lượng lợi thế tổng quát [25] và chuẩn hóa lợi thế theo từng cặp.
- Đánh giá hiệu năng của mô hình đề xuất trong so sánh với ba chính sách tồn kho cổ điển, theo giao thức thực nghiệm đa hạt giống có kiểm định thống kê [26], [27].

1.2.2 Câu hỏi nghiên cứu

Khóa luận hướng tới trả lời ba câu hỏi:

1. Câu hỏi 1: Tác tử IPPO có học được chính sách đặt hàng lại cho tổng chi phí vận hành thấp hơn các chính sách tối ưu hóa cổ điển (EOQ, (s, S) , Newsvendor) trong môi trường đa kho – đa mặt hàng với nhu cầu ngẫu nhiên và thời gian giao hàng biến động hay không, và mức cải thiện đó có ý nghĩa thống kê hay không?
2. Câu hỏi 2: Cơ chế chia sẻ tham số giữa 300 tác tử có đủ để học một chính sách tổng quát hóa được cho các mặt hàng có quy mô nhu cầu khác biệt đáng kể hay không?
3. Câu hỏi 3: Hàm phần thưởng phân rã cục bộ kèm tỷ lệ đáp ứng theo cửa sổ trượt có cải thiện quá trình học so với hàm phần thưởng toàn cục dùng chung hay không?

1.3 Đối tượng và phạm vi nghiên cứu

1.3.1 Đối tượng nghiên cứu

Đối tượng nghiên cứu của khóa luận là bài toán tối ưu hóa chính sách đặt hàng lại trong hệ thống tồn kho đa kho – đa mặt hàng, và thuật toán học tăng cường đa tác tử Independent Multi-Agent PPO áp dụng cho bài toán này.

1.3.2 Phạm vi trong đề tài

- Cấu hình hệ thống: $N = 10$ kho, $M = 30$ mặt hàng đại diện (chọn lọc theo phương pháp phân tầng trên các nhóm ngành hàng), tương ứng 300 cặp ra quyết định; độ dài mỗi tập huấn luyện là 365 ngày; thời gian giao hàng ngẫu nhiên trong khoảng từ một đến ba ngày.
- Cấu trúc mạng lưới: các kho hoạt động song song và độc lập về nguồn cung, mỗi kho đặt hàng trực tiếp từ nhà cung cấp bên ngoài. Sự ràng buộc giữa các mặt hàng phát sinh từ dung lượng kho dùng chung.
- Nguồn dữ liệu: bộ dữ liệu bán lẻ M5 Walmart [2], cụ thể là hai tệp `sales_train_evaluation.csv` chứa 30.490 chuỗi doanh số theo ngày trên 1.941 ngày, và `calendar.csv` chứa thông tin lịch, ngày lễ và các sự kiện trợ cấp thực phẩm SNAP. Khóa luận đồng thời hỗ trợ sinh dữ liệu giả lập theo phân phối Poisson phục vụ thử nghiệm đối chứng.
- Phương pháp đối chứng: ba chính sách tồn kho cổ điển EOQ [12], (s, S) [13] và Newsvendor [14], với tham số được tối ưu bằng tìm kiếm lưới trên

chính môi trường mô phỏng nhằm bảo đảm tính công bằng của so sánh.

- Chỉ số đánh giá: tổng chi phí vận hành, tỷ lệ đáp ứng nhu cầu, và cơ cấu các thành phần chi phí lưu kho, thiếu hàng, đặt hàng.

1.3.3 Giới hạn phạm vi

Để bảo đảm chiều sâu nghiên cứu trong thời gian thực hiện, những nội dung sau được xác định nằm ngoài phạm vi khóa luận:

- Cấu trúc tồn kho đa cấp (multi-echelon) với quan hệ cung ứng giữa các kho theo mô hình của Clark và Scarf [28], cùng các hiện tượng đi kèm như hiệu ứng bullwhip [29].
- Bài toán điều chuyển hàng liên kho và tối ưu hóa tuyến vận chuyển.
- Dự báo nhu cầu bằng mô hình học sâu chuỗi thời gian; khóa luận sử dụng trực tiếp thông tin nhu cầu lịch sử trong vector quan sát.
- Cơ chế truyền thông giữa các tác tử; các tác tử ra quyết định hoàn toàn dựa trên quan sát cục bộ.
- Triển khai hệ thống thời gian thực hoặc tích hợp với nền tảng quản trị doanh nghiệp; sản phẩm của khóa luận là kết quả mô phỏng và phân tích định lượng.

1.4 Phương pháp nghiên cứu

Khóa luận kết hợp ba nhóm phương pháp. Về lý thuyết, bài toán được mô hình hóa dưới dạng quá trình quyết định Markov phi tập trung có quan sát bộ phận [9], [11], trên nền tảng lý thuyết kiểm soát tồn kho ngẫu nhiên [8] và học tăng cường [10], [30]. Về thực nghiệm, nhóm xây dựng môi trường mô phỏng có kiểm thử đơn vị theo chuẩn giao diện Gymnasium [22], [31], hiệu chỉnh tham số từ dữ liệu M5, huấn luyện tác tử và thu thập số liệu vận hành. Về phân tích, mọi so sánh giữa các phương pháp đều được thực hiện trên tối thiểu năm hạt giống ngẫu nhiên, báo cáo giá trị trung bình kèm độ lệch chuẩn, và được xác nhận bằng kiểm định thống kê phù hợp trước khi kết luận — theo khuyến nghị về tính tái lập trong đánh giá học tăng cường sâu của Henderson và cộng sự [26] và Agarwal và cộng sự [27].

1.5 Ý nghĩa khoa học và thực tiễn của đề tài

Về mặt khoa học, khóa luận đóng góp một khung mô hình hóa bài toán tồn kho đa kho – đa mặt hàng dưới dạng hệ đa tác tử hợp tác quy mô lớn, cùng với đánh giá thực nghiệm có kiểm định thống kê về ảnh hưởng của cách phân rã hàm phần thưởng và cơ chế chia sẻ tham số — hai yếu tố thiết kế thường được sử dụng nhưng ít được khảo sát tách bạch trong các nghiên cứu trước.

Về mặt thực tiễn, kết quả của khóa luận cung cấp bằng chứng định lượng về mức độ khả thi của việc thay thế các chính sách đặt hàng theo tham số tĩnh bằng chính sách học được từ dữ liệu, trên một môi trường mô phỏng được hiệu chỉnh từ dữ liệu bán lẻ thực tế. Cấu trúc mã nguồn và giao thức đánh giá được tổ chức theo hướng có thể tái lập, tạo điều kiện cho các nghiên cứu mở rộng tiếp theo.

1.6 Bố cục của khóa luận

Khóa luận được tổ chức thành năm chương:

- Chương 1 — Tổng quan về đề tài: trình bày bối cảnh, tính cấp thiết, mục tiêu, câu hỏi nghiên cứu, phạm vi và phương pháp nghiên cứu.
- Chương 2 — Cơ sở lý thuyết và các công trình liên quan: hệ thống hóa lý thuyết kiểm soát tồn kho ngẫu nhiên, các chính sách cổ điển, nền tảng học tăng cường và học tăng cường đa tác tử, cùng lược khảo các nghiên cứu tiền nhiệm.
- Chương 3 — Phân tích và thiết kế mô hình: chi tiết hóa mô hình toán học của môi trường, thiết kế không gian trạng thái, không gian hành động và hàm phần thưởng, kiến trúc mạng Actor–Critic chia sẻ tham số và quy trình huấn luyện.
- Chương 4 — Thực nghiệm và đánh giá kết quả: trình bày cấu hình thực nghiệm, kết quả so sánh với các chính sách cổ điển, các khảo sát loại trừ và phân tích độ nhạy.
- Chương 5 — Kết luận và hướng phát triển: tổng kết kết quả đạt được, chỉ ra hạn chế và đề xuất hướng nghiên cứu tiếp theo.

CHƯƠNG 2. CƠ SỞ LÝ THUYẾT VÀ CÁC CÔNG TRÌNH LIÊN QUAN

2.1 Lý thuyết kiểm soát tồn kho ngẫu nhiên

2.1.1 Mô hình tồn kho và các thành phần chi phí

Bài toán kiểm soát tồn kho xoay quanh việc xác định thời điểm và số lượng đặt hàng bổ sung nhằm cân bằng giữa chi phí phát sinh khi dự trữ quá nhiều và rủi ro khi dự trữ quá ít [8]. Xét một hệ thống đơn kho – đơn mặt hàng hoạt động theo chu kỳ rời rạc. Gọi I_t là mức tồn kho tại đầu kỳ t , a_t là số lượng đặt hàng, D_t là nhu cầu phát sinh trong kỳ t (biến ngẫu nhiên) và L_t là thời gian giao hàng. Chi phí vận hành mỗi kỳ bao gồm:

- Chi phí lưu kho $C_{\text{hold}} = c_{lk} \cdot \max(I_t, 0)$: chi phí tỷ lệ với lượng hàng tồn dương trong kho, bao gồm chi phí vốn, bảo quản và kho bãi.
- Chi phí thiếu hàng $C_{\text{stock}} = c_{th} \cdot \max(D_t - I_t, 0)$: chi phí phát sinh khi nhu cầu vượt quá lượng hàng có sẵn. Trong mô hình mất đơn hàng (lost sales), phần nhu cầu không được đáp ứng bị mất hoàn toàn thay vì chuyển sang kỳ sau [15].
- Chi phí đặt hàng cố định $C_{\text{order}} = c_{dh} \cdot \mathbb{1}(a_t > 0)$: chi phí phát sinh mỗi khi hệ thống phát lệnh đặt hàng, bất kể số lượng đặt.
- Phạt tràn kho $C_{\text{over}} = p_{tk} \cdot \max(I_t + q_t - W, 0)$: chi phí phát sinh khi tổng lượng hàng tồn và hàng nhập vượt quá sức chứa W của kho, trong đó q_t là lượng hàng nhập kho trong kỳ.
- Phạt vi phạm mức phục vụ dựa trên tỷ lệ đáp ứng nhu cầu (fill rate) trên cửa sổ trượt, phản ánh yêu cầu kinh doanh về chất lượng dịch vụ khách hàng.

Tổng chi phí vận hành của một cặp kho–mặt hàng trong kỳ t được tính:

$$C_t = C_{\text{hold}} + C_{\text{stock}} + C_{\text{order}} + C_{\text{over}} + \phi_{dv} \cdot \max(\tau - \text{FR}_t^{(w)}, 0) \quad (2.1)$$

trong đó $\text{FR}_t^{(w)}$ là tỷ lệ đáp ứng trên cửa sổ trượt w ngày, τ là ngưỡng mức phục vụ mục tiêu và ϕ_{dv} là hệ số phạt.

2.1.2 Các chính sách đặt hàng lại cổ điển

Ba chính sách cổ điển được sử dụng làm phương pháp đối chứng trong khóa luận.

Lượng đặt hàng kinh tế (EOQ). Harris [12] đề xuất công thức tối ưu hóa tần suất đặt hàng dưới giả định nhu cầu xác định và đều:

$$Q^* = \sqrt{\frac{2D \cdot c_{dh}}{c_{lk}}} \quad (2.2)$$

trong đó D là nhu cầu trung bình hàng năm. Mô hình giả định không có thiếu hàng, thời gian giao hàng cố định và không có ràng buộc sức chứa.

Chính sách (s, S) . Scarf [13] chứng minh rằng chính sách dạng (s, S) — đặt hàng để nâng mức tồn kho lên S khi mức hiện tại giảm xuống dưới s — là tối ưu cho hệ đơn kho với nhu cầu ngẫu nhiên, chi phí đặt hàng cố định, và cơ chế giữ đơn hàng chờ (backorder). Ngưỡng s thường được tính dựa trên nhu cầu trung bình và độ lệch chuẩn trong thời gian giao hàng:

$$s = \mu_L + z_\alpha \cdot \sigma_L \quad (2.3)$$

trong đó μ_L và σ_L là kỳ vọng và độ lệch chuẩn của nhu cầu tích lũy trong thời gian giao hàng, z_α là phân vị chuẩn tương ứng với mức phục vụ mong muốn.

Mô hình Newsvendor. Arrow và cộng sự [14] đề xuất mô hình cho bài toán đặt hàng đơn kỳ, trong đó lượng đặt hàng tối ưu là:

$$Q^* = F^{-1} \left(\frac{c_{th}}{c_{th} + c_{lk}} \right) \quad (2.4)$$

với F^{-1} là hàm phân vị của phân phối nhu cầu. Mô hình chỉ tối ưu cho một chu kỳ duy nhất, không xét lượng hàng đang trên đường vận chuyển.

Cả ba chính sách trên đều được xây dựng cho bài toán đơn kho – đơn mặt hàng và không tối ưu hóa đồng thời ràng buộc sức chứa dùng chung, phạt tràn và mức phục vụ — những đặc trưng quan trọng trong bài toán đa kho – đa mặt hàng mà khóa luận xét [1], [8].

2.1.3 Các thước đo mức phục vụ trong quản lý tồn kho

Trong quản lý tồn kho ngẫu nhiên, mức phục vụ (service level) được đánh giá thông qua ba thước đo phổ biến [1], [8]:

- **Mức phục vụ theo chu kỳ (α – Cycle Service Level / Type-1):** Là xác suất không xảy ra hiện tượng thiếu hàng trong một chu kỳ bổ sung tồn kho, tức

$P(D_L \leq s)$ trong đó D_L là nhu cầu tích lũy trong thời gian giao hàng L và s là điểm đặt hàng lại. Tỷ lệ critical ratio trong mô hình Newsvendor (2.4) phản ánh chính xác phân vị z_α của thước đo α .

- **Tỷ lệ đáp ứng nhu cầu (β – Fill Rate / Type-2):** Là tỷ lệ phần trăm tổng nhu cầu của khách hàng được đáp ứng ngay lập tức từ lượng hàng sẵn có trong kho.
- **Tỷ lệ sẵn sàng (γ – Ready Rate):** Là tỷ lệ thời gian mà mức tồn kho khả dụng duy trì giá trị dương.

Cần lưu ý rạch ròi rằng tỷ số chi phí $c_{th}/(c_{th} + c_{lk})$ xác định mức phục vụ chu kỳ α , chứ không phải tỷ lệ fill rate β . Trong điều kiện nhu cầu ổn định và biến động vừa phải, β thường cao hơn α . Tuy nhiên, dưới tác động của nhu cầu gián đoạn (intermittent demand) và thời gian giao hàng ngẫu nhiên như trong dữ liệu M5 Walmart, mối quan hệ này không còn mang tính tuyệt đối và β có thể sụt giảm thấp hơn α [1].

2.2 Nền tảng học tăng cường

2.2.1 Quá trình quyết định Markov (MDP)

Bài toán ra quyết định tuần tự dưới bất định được mô hình hóa bằng quá trình quyết định Markov [30], xác định bởi bộ năm (S, A, P, R, γ) trong đó:

- S : không gian trạng thái (state space).
- A : không gian hành động (action space).
- $P(s' | s, a)$: hàm xác suất chuyển trạng thái.
- $R(s, a)$: hàm phần thưởng (reward function).
- $\gamma \in [0, 1)$: hệ số chiết khấu (discount factor).

Mục tiêu của tác tử là tìm chính sách π^* cực đại hóa lợi tức kỳ vọng:

$$\pi^* = \arg \max_{\pi} \mathbb{E}_{\pi} \left[\sum_{t=0}^{\infty} \gamma^t R(s_t, a_t) \right] \quad (2.5)$$

2.2.2 Hàm giá trị và phương trình Bellman

Hàm giá trị trạng thái $V^{\pi}(s) = \mathbb{E}_{\pi}[\sum_{t=0}^{\infty} \gamma^t R_t | s_0 = s]$ và hàm giá trị hành động $Q^{\pi}(s, a)$ thỏa mãn phương trình Bellman [10]. Hàm lợi thế (advantage function) được định nghĩa:

$$A^{\pi}(s, a) = Q^{\pi}(s, a) - V^{\pi}(s) \quad (2.6)$$

đo mức độ tốt hơn (hoặc kém hơn) của hành động a so với hành vi trung bình của chính sách π tại trạng thái s .

2.2.3 Ước lượng lợi thế tổng quát (GAE)

Schulman và cộng sự [25] đề xuất phương pháp ước lượng lợi thế tổng quát (Generalized Advantage Estimation – GAE) nhằm kiểm soát đánh đổi giữa thiên lệch (bias) và phương sai (variance) trong ước lượng gradient chính sách:

$$\hat{A}_t^{\text{GAE}(\gamma, \lambda)} = \sum_{l=0}^{\infty} (\gamma\lambda)^l \delta_{t+l} \quad (2.7)$$

trong đó $\delta_t = r_t + \gamma V(s_{t+1}) - V(s_t)$ là sai số TD (temporal difference) và $\lambda \in [0, 1]$ là tham số kiểm soát đánh đổi. Khi $\lambda = 0$, GAE suy biến thành ước lượng một bước (thiên lệch cao, phương sai thấp); khi $\lambda = 1$, GAE tương đương Monte-Carlo (không thiên lệch, phương sai cao). Khóa luận sử dụng $\lambda = 0,95$ theo khuyến nghị thực nghiệm phổ biến.

2.2.4 Thuật toán PPO (Proximal Policy Optimization)

Schulman và cộng sự [24] đề xuất PPO nhằm khắc phục nhược điểm của phương pháp tối ưu hóa chính sách: các bước cập nhật quá lớn có thể phá hủy chính sách đã học. PPO sử dụng hàm mục tiêu cắt (clipped surrogate objective):

$$L^{\text{CLIP}}(\theta) = \mathbb{E}_t [\min(r_t(\theta)\hat{A}_t, \text{clip}(r_t(\theta), 1 - \epsilon, 1 + \epsilon)\hat{A}_t)] \quad (2.8)$$

trong đó $r_t(\theta) = \frac{\pi_\theta(a_t|s_t)}{\pi_{\theta_{\text{old}}}(a_t|s_t)}$ là tỷ lệ xác suất giữa chính sách mới và cũ, và ϵ (thường bằng 0,2) giới hạn biên độ thay đổi tối đa. PPO kết hợp cập nhật on-policy, hiệu quả tính toán cao và tính ổn định, phù hợp cho bài toán có không gian hành động rời rạc hoặc liên tục.

Ý tưởng cốt lõi của TRPO [32] — giới hạn bước cập nhật trong vùng tin cậy — được PPO thực hiện đơn giản hơn qua phép cắt, giúp cài đặt dễ dàng và huấn luyện nhanh hơn trên thực tế.

2.3 Học tăng cường đa tác tử

2.3.1 Mô hình Dec-POMDP

Khi hệ thống có nhiều tác tử ra quyết định đồng thời, bài toán được mô hình hóa bằng quá trình quyết định Markov phi tập trung có quan sát bộ phận (Decentralized Partially Observable Markov Decision Process – Dec-POMDP) [9]. Trong mô hình

này, mỗi tác tử i chỉ quan sát được một phần trạng thái toàn cục thông qua hàm quan sát $o_i = O(s, i)$ và ra quyết định dựa trên quan sát cục bộ. Bài toán tìm chính sách chung tối ưu cho tất cả tác tử đã được chứng minh thuộc lớp NEXP-đầy đủ [11], nên các lời giải chính xác không khả thi ở quy mô lớn.

2.3.2 Học độc lập (*Independent Learning*)

Tan [19] đề xuất phương pháp học độc lập: mỗi tác tử coi các tác tử khác là một phần của môi trường và áp dụng thuật toán RL đơn tác tử riêng rẽ. Hạn chế lý thuyết chính là môi trường trở nên không dừng (non-stationary) do các tác tử khác cũng đang thay đổi chính sách. Tuy nhiên, các nghiên cứu thực nghiệm cho thấy phương pháp này đạt hiệu quả bất ngờ trên nhiều bài toán hợp tác [20].

2.3.3 IPPO — *Independent Multi-Agent PPO*

IPPO là biến thể đa tác tử của PPO trong đó mỗi tác tử i chạy PPO độc lập dựa trên quan sát cục bộ o_i^t và phần thưởng riêng r_i^t [20]. Yu và cộng sự [21] đánh giá hệ thống trên nhiều môi trường hợp tác và kết luận rằng IPPO đạt hiệu năng cạnh tranh hoặc vượt trội so với các phương pháp phức tạp hơn như QMIX hay MAPPO trong nhiều kịch bản.

Đặc điểm quan trọng của IPPO khiến nó phù hợp cho bài toán tồn kho:

- Không yêu cầu trạng thái toàn cục: mỗi tác tử (cặp kho–mặt hàng) chỉ cần quan sát cục bộ.
- Khả năng mở rộng: không gian hành động của mỗi tác tử có kích thước K cố định, không phụ thuộc số tác tử.
- Tính đơn giản: cài đặt dựa trên PPO chuẩn, không cần mixing network hay cơ chế truyền thông.

2.3.4 Chia sẻ tham số (*Parameter Sharing*)

Gupta và cộng sự [18] chỉ ra rằng khi các tác tử có cùng không gian quan sát và hành động, một mạng nơ-ron duy nhất có thể được chia sẻ giữa tất cả tác tử. Mỗi tác tử vẫn ra quyết định dựa trên quan sát riêng nhưng dùng chung bộ trọng số. Lợi ích:

- Số tham số cần học không tăng theo số tác tử (ở đây: 300).
- Mỗi bước cập nhật sử dụng dữ liệu từ tất cả tác tử, tăng hiệu quả mẫu.
- Chính sách học được có khả năng tổng quát hóa cho các mặt hàng có quy

mô nhu cầu khác nhau.

2.3.5 *Phần thưởng phân rã cục bộ và bài toán gán tín dụng*

Trong hệ đa tác tử, việc sử dụng phần thưởng toàn cục (tổng chi phí của toàn bộ hệ thống) cho mọi tác tử gây ra vấn đề gán tín dụng (credit assignment): tác tử khó phân biệt được đóng góp cá nhân trong tín hiệu tổng hợp [23]. Khóa luận áp dụng phân rã cục bộ: mỗi tác tử nhận phần thưởng riêng dựa trên chi phí và tỷ lệ đáp ứng của chính cặp kho–mặt hàng mà nó quản lý.

Khung lý thuyết định hình phần thưởng bảo toàn thể năng (Potential-Based Reward Shaping – PBRs) do Ng và cộng sự [33] chứng minh khẳng định rằng: một hàm biến đổi phần thưởng $F(s, a, s')$ bảo toàn tập chính sách tối ưu của MDP gốc khi và chỉ khi nó có dạng chênh lệch thể năng $F(s, a, s') = \gamma\Phi(s') - \Phi(s)$. Khung lý thuyết này sau đó được mở rộng sang hệ đa tác tử bởi Devlin và Kudenko [34] cũng như ứng dụng trong tồn kho bởi De Moor và cộng sự [35].

2.4 Các công trình nghiên cứu liên quan

2.4.1 *Học tăng cường trong quản lý tồn kho*

Oroojlooyjadid và cộng sự [16] áp dụng Deep Q-Network (DQN) cho trò chơi phân phối bia (beer game) — một bài toán chuỗi cung ứng 4 cấp cổ điển — và cho thấy DQN có thể học được chính sách giảm hiệu ứng bullwhip. Tuy nhiên, nghiên cứu giới hạn ở hệ đơn mặt hàng, bốn tác tử.

Gijsbrechts và cộng sự [17] đánh giá hệ thống khả năng của DRL trên ba lớp bài toán tồn kho: mất đơn hàng, hai nguồn cung và đa cấp. Kết quả cho thấy DRL đạt hiệu năng ngang hoặc tốt hơn chính sách cổ điển trong hầu hết trường hợp, nhưng tất cả thực nghiệm đều ở quy mô nhỏ (dưới 10 SKU).

Hubbs và cộng sự [36] giới thiệu bộ thư viện OR-Gym đóng vai trò là môi trường benchmark chuẩn cho các bài toán Vận trù học bằng RL, bao gồm cả mô hình Newsvendor và quản lý tồn kho đa cấp lost-sales.

Nghiên cứu của Ding và cộng sự [37] (CD-PPO) phát biểu chính xác bài toán tồn kho đơn cửa hàng nhiều SKU dưới dạng tài nguyên kho dùng chung làm ghép nối các tác tử vốn độc lập. Họ so sánh trực tiếp IPPO và MAPPO có chia sẻ tham số (parameter sharing), chứng minh hiệu quả vượt trội khi quản lý tài nguyên kho chung.

Yang và cộng sự [38] phát triển MABIM — bộ benchmark MARL đa dạng cho tồn kho. MABIM coi mỗi SKU tại mỗi điểm lưu trữ là một tác tử độc lập, sử dụng

dữ liệu nhu cầu thực tế của hơn 2.000 SKU với 51 tác vụ thử nghiệm (bao gồm nhóm tác vụ mở rộng quy mô scaling up), thử nghiệm các thuật toán MARL bao gồm IPPO dưới ràng buộc sức chứa dùng chung.

Kotecha và del Rio Chanona [39] tiến hành phân tích chuyên sâu các thuật toán MARL cho kiểm soát tồn kho phân tán, so sánh giữa IPPO thuần, IPPO chia sẻ tham số và MAPPO. Họ phát hiện rằng mặc dù parameter sharing giảm số lượng tham số cần học, hiệu năng của IPPO chia sẻ tham số có dấu hiệu giảm sút khi quy mô tác tử tăng lên rất lớn.

Gần đây nhất, Liu và cộng sự [40] áp dụng thuật toán Heterogeneous-Agent PPO (HAPPO) cho tồn kho đa cấp. Đáng chú ý, các tác giả phát hiện việc kết hợp chi phí cục bộ và chi phí toàn hệ thống vào tín hiệu thưởng thu được chính sách có độ ổn định và hiệu năng cao hơn so với chỉ dùng chi phí toàn hệ thống thuần túy.

2.4.2 Khoảng trống nghiên cứu và định vị đóng góp

Bảng 2.1 tóm tắt so sánh tổng quan giữa khóa luận này và các công trình nghiên cứu liên quan tiêu biểu.

Bảng 2.1: So sánh tổng quan các công trình nghiên cứu liên quan

Nghiên cứu	Cấu trúc mạng	Số SKU	Chia sẻ tham số	Dữ liệu thực	Thuật toán
Oroojlooyjadid (2022)	4 cấp chuỗi	1	Không	Không	DQN
Gijsbrechts (2022)	2 cấp / đa cấp	< 10	Không	Không	A2C / PPO
Hubbs et al. (2020)	Đa cấp lost-sales	Biến đổi	Không	Không	DQN / PPO
Ding et al. (2022)	1 cửa hàng	Nhiều SKU	Có	Không	CD-PPO / IPPO
Yang et al. (2023)	Đa cấp / Đa kho	> 2000	Có	Có	IPPO / MAPPO
Kotecha (2024)	Đa điểm phân tán	Biến đổi	Có	Không	IPPO / MAPPO
Liu et al. (2025)	Đa cấp phức tạp	Nhiều SKU	Có	Có	HAPPO
Khóa luận này	10 kho song song	30	Có	M5 Walmart	IPPO

Thay vì đưa ra các khẳng định tuyệt đối về tính duy nhất hay tính "đầu tiên",

khóa luận định vị đóng góp theo hướng **tái lập và mở rộng có kiểm soát** đối với ứng dụng MARL trong kiểm soát tồn kho, tập trung vào ba trọng tâm chính:

1. Khảo sát sâu cấu hình **10 kho song song thuần túy (non-multi-echelon)** với ràng buộc sức chứa kho dùng chung ở quy mô 300 cặp kho–mặt hàng, tạo sự đối sánh rõ rệt với các mô hình đa cấp (multi-echelon) của MABIM [38] hay Liu và cộng sự [40].
2. Đánh giá **ablation study tường minh** tác động của cơ chế chuẩn hóa phần thưởng phân rã cục bộ (local reward decomposition) kèm phạt ràng buộc fill rate cửa sổ trượt ở quy mô 300 tác tử, làm rõ cơ chế gán tín dụng và tốc độ hội tụ của IPPO.
3. Hiệu chỉnh môi trường mô phỏng lost-sales trực tiếp từ dữ liệu bán lẻ thực tế M5 Walmart và thực hiện kiểm chứng đối chứng nghiêm ngặt với các chính sách cổ điển EOQ, (s, S) và Newsvendor.

CHƯƠNG 3. PHÂN TÍCH VÀ THIẾT KẾ MÔ HÌNH

3.1 Mô hình hóa bài toán tồn kho đa kho

3.1.1 Mô tả mạng lưới

Hệ thống gồm $N = 10$ kho hoạt động song song và độc lập về nguồn cung, tương ứng với 10 cửa hàng của bộ dữ liệu M5 Walmart. Mỗi kho lưu trữ $M = 30$ mặt hàng (SKU) đại diện, được chọn theo phương pháp phân tầng trên các nhóm ngành hàng và lọc bỏ những mặt hàng có nhu cầu quá thấp (dưới 0,2 đơn vị/ngày ở đa số cửa hàng) để tránh đưa vào hệ thống những cặp gần như không phát sinh giao dịch, vốn chỉ làm nhiễu tín hiệu học của mạng chia sẻ tham số. Tổng cộng hệ thống có $N \times M = 300$ cặp kho–mặt hàng, mỗi cặp là một tác tử ra quyết định độc lập trên quan sát cục bộ của chính nó.

Mỗi kho k có dung lượng hữu hạn W_k , được hiệu chỉnh *riêng theo nhu cầu của chính kho đó* thay vì dùng một con số chung cho toàn hệ thống:

$$W_k = c_{\text{cover}} \sum_{i \in k} \bar{D}_i \quad (3.1)$$

trong đó $\bar{D}_i$ là nhu cầu trung bình hàng ngày của cặp i (ước lượng chỉ từ giai đoạn dữ liệu dùng để huấn luyện, xem Mục 3.1.3) và $c_{\text{cover}} = 5$ là số ngày dự trữ mục tiêu. Việc hiệu chỉnh theo từng kho là cần thiết vì quy mô kinh doanh giữa 10 cửa hàng M5 chênh lệch nhau nhiều lần: nếu dùng một dung lượng chung cho tất cả, kho có doanh số lớn sẽ chỉ đủ chứa cho chưa tới hai ngày nhu cầu – thấp hơn cả thời gian giao hàng tối đa – khiến mục tiêu mức phục vụ trở thành bài toán vô nghiệm với kho đó, trong khi kho nhỏ lại dư thừa dung lượng đến mức ràng buộc sức chứa không còn tác dụng ghép nối các mặt hàng với nhau.

Sự ràng buộc giữa các mặt hàng trong cùng kho phát sinh chính từ dung lượng dùng chung W_k này: khi một mặt hàng chiếm nhiều chỗ, các mặt hàng khác trong cùng kho có nguy cơ bị từ chối nhập hàng vượt mức. Đây là yếu tố khiến bài toán mang bản chất hợp tác và không thể tách rời thành 300 bài toán đơn lẻ độc lập.

Nhu cầu hàng ngày $D_t^{(i)}$ cho mỗi cặp kho–mặt hàng i được lấy từ hai nguồn:

- Dữ liệu M5 Walmart: chuỗi doanh số thực tế của 10 cửa hàng, mỗi cửa hàng 30 SKU đại diện đã qua chọn lọc [2].
- Dữ liệu giả lập: nhu cầu Poisson $D_t \sim \text{Poisson}(\lambda_i)$ với λ_i khác nhau giữa

các SKU, phục vụ kiểm tra đơn vị và thử nghiệm đối chứng trong điều kiện kiểm soát.

3.1.2 Thiết lập bài toán dưới dạng MDP đa tác tử

Bài toán được mô hình hóa dưới dạng Dec-POMDP [9] với 300 tác tử. Mỗi tác tử i (tương ứng cặp kho–mặt hàng) có:

Không gian quan sát $o_i^t \in [0, 1]^d$: vector quan sát cục bộ tại kỳ t , đã được chuẩn hóa và giới hạn trong đoạn $[0, 1]$ để ổn định quá trình huấn luyện mạng nơ-ron, bao gồm:

- Mức tồn kho hiện tại, quy đổi theo số ngày cần diễn hình của chính cặp đó.
- Vị thế tồn kho (tồn kho hiện có cộng lượng hàng đang trên đường vận chuyển), cùng đơn vị quy đổi.
- Lịch sử nhu cầu 7 ngày gần nhất, biểu diễn theo thang log để giữ được thông tin ở cả những ngày cầu đột biến lẫn những ngày cầu bằng không – đặc trưng phổ biến của nhu cầu bán lẻ gián đoạn.
- Lượng hàng đang trên đường ứng với từng thời điểm còn lại cho tới khi giao hàng.
- Tỷ lệ đáp ứng nhu cầu trên cửa sổ trượt $w = 30$ ngày, $FR_t^{(i,w)}$ – thành phần bắt buộc phải có trong quan sát vì hàm phần thưởng (Mục 3.2) phạt trực tiếp theo đại lượng này; nếu thiếu, tác tử không thể suy ra được vì sao mình bị phạt và môi trường mất tính Markov tại đúng thành phần đó.
- Một đặc trưng quy mô cầu (theo thang log), giúp mạng dùng chung phân biệt được một SKU đang quan sát là loại bán chậm hay bán nhanh.
- Mức sử dụng sức chứa hiện tại của kho chứa cặp đó, $\sum_{j \in k} I_t^{(j)} / W_k$ – kênh duy nhất để một tác tử “cảm nhận” áp lực từ các mặt hàng khác cùng kho, và là điều kiện bắt buộc để môi trường giữ tính Markov tại thành phần phạt tràn kho (vốn tính trên tổng tồn kho của cả kho chứ không phải của riêng từng cặp).
- Tỷ trọng tồn kho của chính cặp đó trong tổng tồn kho của kho.
- Khi sử dụng dữ liệu giá bán thực tế: một tín hiệu phản ánh mức độ giảm giá hiện tại so với giá bán trung bình của chính cặp đó – một chỉ báo sớm cho khả năng nhu cầu tăng đột biến do khuyến mãi.
- Ngày trong tuần dạng one-hot (7 chiều) và, khi dùng dữ liệu M5 thực tế, các đặc trưng lịch (sự kiện lễ hội, chương trình trợ cấp thực phẩm SNAP,

tháng trong năm).

Không gian hành động $a_i^t \in \{0, 1, \dots, K-1\}$: mỗi tác tử chọn một trong $K = 6$ mức đặt hàng. Vì quy mô nhu cầu giữa các cặp kho–mặt hàng chênh lệch tới vài trăm lần, các mức đặt hàng được thiết kế *tương đối theo nhu cầu của chính từng cặp* thay vì theo số lượng tuyệt đối dùng chung:

$$q_i(a) = \left\lceil m_a \cdot \bar{D}_i \cdot \bar{L} \right\rceil, \quad m_a \in \{0; 0,5; 1; 2; 3; 5\} \quad (3.2)$$

trong đó $\bar{L}$ là thời gian giao hàng trung bình. Bảng lượng đặt hàng $q_i(\cdot)$ được ép tăng nghiêm ngặt giữa các mức liên tiếp (mức sau luôn lớn hơn mức trước ít nhất một đơn vị, trừ mức 0 luôn cố định là không đặt hàng); nếu không ép điều kiện này, làm tròn một hệ số nhân nhỏ trên một nhu cầu nhỏ có thể khiến nhiều mức đặt hàng khác nhau quy về cùng một số lượng thực tế, khiến tác tử nhận được cùng một hệ quả cho các hành động khác nhau và triệt tiêu tín hiệu gradient cần thiết để chính sách hội tụ. Nhờ thiết kế tương đối này, một mức đặt hàng “trung bình” luôn tương ứng với một số ngày dự trữ có ý nghĩa như nhau đối với cả SKU bán chậm lẫn SKU bán chạy nhất, dù không gian hành động mỗi tác tử chỉ có kích thước cố định $K = 6$. Không gian hành động chung của toàn hệ thống vẫn là tích Descartes $K^{300} = 6^{300}$.

Hàm chuyển trạng thái diễn ra theo trình tự sau tại mỗi kỳ:

1. Tác tử quan sát o_i^t và chọn hành động a_i^t , quy đổi thành lượng đặt hàng $q_i(a_i^t)$ theo công thức (3.2).
2. Lô hàng đã đặt trước đó và đã hết thời gian giao hàng được nhập vào kho.
3. Lượng hàng vượt quá dung lượng còn lại của kho bị từ chối ngay tại thời điểm nhập kho (không phải bị loại bỏ sau khi đã tính vào tồn kho), phân bổ theo đúng tỷ trọng tồn kho hiện có của từng mặt hàng trong kho đó.
4. Nhu cầu $D_t^{(i)}$ phát sinh; hàng được bán tối đa bằng tồn kho hiện có, phần nhu cầu vượt quá bị mất hoàn toàn (mô hình mất đơn hàng).
5. Tỷ lệ đáp ứng trên cửa sổ trượt và chi phí, phần thưởng của kỳ được cập nhật.
6. Đơn hàng $q_i(a_i^t)$ được ghi nhận vào hàng đợi giao hàng ứng với một thời gian giao hàng ngẫu nhiên $L \sim \text{Uniform}(1, 3)$ ngày, hệ thống chuyển sang kỳ $t + 1$.

3.1.3 Phân chia miền dữ liệu huấn luyện – kiểm định – kiểm tra

Để tránh rò rỉ thông tin giữa giai đoạn huấn luyện và giai đoạn báo cáo kết quả, chuỗi thời gian 1.941 ngày của M5 được cắt thành ba miền liên tiếp và không chồng lấn: miền huấn luyện (train), miền kiểm định (validation) và miền kiểm tra (test). Mọi tham số ước lượng từ dữ liệu – nhu cầu trung bình và độ lệch chuẩn của từng cặp, dung lượng mỗi kho theo công thức (3.1), bảng lượng đặt hàng theo công thức (3.2), và đơn giá bán trung bình dùng cho chi phí thiếu hàng ở Mục 3.2.4 – đều chỉ được tính trên miền huấn luyện. Mỗi tập mô phỏng (episode) dài 365 ngày luôn được giới hạn để không vượt ra khỏi ranh giới của miền mà nó thuộc về.

Miền kiểm định được dùng riêng để chọn bộ trọng số tốt nhất trong quá trình huấn luyện (thông qua đánh giá định kỳ theo chính sách xác định, không lấy mẫu ngẫu nhiên), còn miền kiểm tra chỉ được truy cập đúng một lần, ở bước đánh giá cuối cùng dùng để báo cáo và so sánh với các chính sách đối chứng (Chương 4). Việc tách bạch hai miền này là cần thiết: nếu bộ trọng số tốt nhất được chọn bằng chính hiệu năng đo trên miền dùng để báo cáo kết quả sau cùng, số liệu công bố sẽ mang một dạng rò rỉ nhẹ, vì bước chọn mô hình đã “nhìn thấy” trước đúng dữ liệu mà nó sẽ được đánh giá trên đó.

3.2 Thiết kế hàm phần thưởng

3.2.1 Phần thưởng phân rã cục bộ

Mỗi tác tử i nhận phần thưởng riêng dựa trên chi phí của chính cặp kho–mặt hàng mà nó quản lý, thay vì dùng chung phần thưởng toàn cục:

$$r_i^t = - \left[c_{lk} \cdot I_t^{(i)} + c_{th}^{(i)} \cdot U_t^{(i)} + c_{dh} \cdot \mathbb{1}(a_i^t > 0) + p_{tk} \cdot O_t^{(i)} + \phi_{dv} \cdot c_{th} \cdot \bar{D}_i \cdot \max(\tau - \text{FR}_t^{(i,w)}, 0) \right] \quad (3.3)$$

trong đó:

- $I_t^{(i)}$: mức tồn kho sau khi bán hàng trong kỳ t .
- $U_t^{(i)} = \max(D_t^{(i)} - I_t^{(i)}, 0)$: lượng nhu cầu không được đáp ứng.
- $O_t^{(i)}$: lượng hàng bị từ chối do vượt dung lượng kho.
- $c_{th}^{(i)}$: đơn giá thiếu hàng của cặp i – có thể là hằng số c_{th} dùng chung, hoặc suy ra từ giá bán thực tế của chính mặt hàng đó (Mục 3.2.4).
- $\text{FR}_t^{(i,w)}$: tỷ lệ đáp ứng trên cửa sổ trượt $w = 30$ ngày; $\tau = 0,85$: ngưỡng mức phục vụ mục tiêu.

Thành phần phạt mức phục vụ được nhân thêm với $\bar{D}_i$ – nhu cầu trung bình của chính cặp đó – để hình phạt này có cùng bậc độ lớn với các thành phần chi phí vận hành khác của cặp thay vì là một hằng số cố định dùng chung cho mọi quy mô cầu; đây cũng chính là lý do thành phần này luôn dùng đơn giá hằng số c_{th} chứ không dùng $c_{th}^{(i)}$ theo giá thực: mục tiêu “đạt tối thiểu 85% fill rate” là một cam kết quản trị cố định, không nên tỷ lệ thuận theo giá bán của từng mặt hàng.

3.2.2 Chuẩn hóa phần thưởng theo từng cặp

Vì 300 tác tử dùng chung một mạng nơ-ron (Mục 3.3), phần thưởng thô ở công thức (3.3) không thể đưa thẳng vào huấn luyện: quy mô nhu cầu giữa các cặp trong bộ dữ liệu chênh lệch tới ba bậc độ lớn (từ dưới 0,1 đến hơn 150 đơn vị/ngày), khiến phần thưởng thô của cặp bán chạy nhất lớn hơn phần thưởng thô của cặp bán chậm nhất hàng nghìn lần. Một mạng giá trị (critic) dùng chung trọng số cho toàn bộ 300 cặp buộc phải khớp đồng thời các mục tiêu trải trên nhiều bậc độ lớn như vậy, khiến sai số huấn luyện bị chi phối gần như hoàn toàn bởi nhóm nhỏ các cặp có quy mô lớn nhất, còn tín hiệu học của phần lớn các cặp còn lại gần như bị nhiễu lấn át.

Để khắc phục, phần thưởng cục bộ được chuẩn hóa theo một thang đo đặc trưng của riêng từng cặp trước khi đưa vào bộ đệm huấn luyện:

$$\tilde{r}_i^t = \frac{r_i^t}{c_{th}^{(i)} \cdot \bar{D}_i + c_{dh}} \quad (3.4)$$

Mẫu số là chi phí ước lượng của “một ngày xấu điển hình” đối với cặp i : hết hàng toàn bộ nhu cầu trong một ngày cộng thêm một lần phát sinh đơn đặt hàng. Hằng số c_{dh} ở mẫu số giữ cho phép chia không tiến về không đối với những mặt hàng gần như không có giao dịch. Phép chuẩn hóa này chỉ đổi thang đo của phần thưởng, không đổi thứ tự tốt/xấu giữa các hành động trong cùng một cặp, nên không làm thay đổi chính sách tối ưu mà tác tử cần học; nó chỉ làm cho gradient đóng góp bởi 300 cặp có độ lớn tương đương nhau, cho phép mạng dùng chung học đồng đều trên toàn bộ hệ thống thay vì chỉ tập trung vào những cặp có quy mô chi phí lớn nhất. Mục 4 trình bày bằng chứng thực nghiệm cho vai trò của cơ chế chuẩn hóa này.

3.2.3 Vai trò của thành phần phạt fill rate

Thành phần $\phi_{dv} \cdot c_{th} \cdot \bar{D}_i \cdot \max(\tau - \text{FR}_t^{(i,w)}, 0)$ trong công thức (3.3) bổ sung một tín hiệu phạt ràng buộc (constraint penalty) theo tinh thần Lagrangian: thay vì chỉ phạt thiếu hàng tức thời trong ngày – vốn có phương sai rất cao do đặc tính gián đoạn

của nhu cầu bán lẻ – tỷ lệ đáp ứng tính trên cửa sổ trượt cung cấp một đánh giá ổn định hơn về chất lượng phục vụ theo thời gian. Cần nói rõ rằng thành phần phạt này *chủ động thay đổi* nghiệm tối ưu của bài toán tối ưu hóa chi phí thuần túy, nhằm điều hướng chính sách hướng tới việc thỏa mãn một ràng buộc kinh doanh (mức phục vụ tối thiểu) mà bản thân hàm chi phí vận hành không tự nhiên tạo ra động lực để đạt tới.

3.2.4 Các tham số chi phí

Bảng 3.1 liệt kê các tham số chi phí sử dụng trong thực nghiệm.

Bảng 3.1: Tham số chi phí trong môi trường mô phỏng

Thành phần	Ký hiệu	Giá trị
Chi phí lưu kho	c_{lk}	1,0 /đơn vị/ngày
Chi phí đặt hàng	c_{dh}	5,0 /lần đặt
Phạt tràn kho	p_{tk}	5,0 /đơn vị tràn
Phạt vi phạm mức phục vụ	ϕ_{dv}	3,0
Ngưỡng fill rate	τ	85%
Cửa sổ fill rate	w	30 ngày
Đơn giá thiếu hàng dùng cho phạt mức phục vụ	c_{th}	10,0 /đơn vị

Với $c_{th} = 10,0$ và $c_{lk} = 1,0$, tỷ số chi phí thiếu hàng ngầm định mức phục vụ chu kỳ lý thuyết $\alpha \approx 90,9\%$ (Mục 2.1.3). Do đó, ràng buộc fill rate $\beta \geq 85\%$ có khả năng rơi vào trạng thái không có hiệu lực bắt buộc (non-binding) nếu chỉ xét riêng phần chi phí thiếu hàng thuần túy; Chương 4 kiểm chứng lại giả thuyết này bằng kết quả huấn luyện thực tế.

Ngoài đơn giá hằng số c_{th} dùng cho thành phần phạt mức phục vụ, đơn giá thiếu hàng thực tế $c_{th}^{(i)}$ dùng trong công thức (3.3) và (3.4) có thể được suy ra từ giá bán trung bình thực tế của chính mặt hàng đó thay vì dùng một hằng số chung cho tất cả:

$$c_{th}^{(i)} = \max(\bar{P}_i \cdot \rho, c_{th}^{\min}) \quad (3.5)$$

trong đó $\bar{P}_i$ là giá bán trung bình của cặp i (ước lượng chỉ trên miền huấn luyện, lấy từ dữ liệu giá bán theo tuần của M5), $\rho = 0,3$ là tỷ lệ biên lợi nhuận giả định, và $c_{th}^{\min} = 0,5$ là mức sàn để tránh các mặt hàng giá rất thấp có đơn giá thiếu hàng gần bằng không. **Đây là một giả định phương pháp luận cần nêu rõ:** bộ dữ liệu M5 không công bố giá vốn của từng mặt hàng, nên ρ phản ánh giả định rằng một đơn vị thiếu hàng làm mất đúng phần lợi nhuận biên của giao dịch đó, chứ không phải toàn bộ giá bán – đây là một tham số cần trình bày tường minh như một giả định, không phải một đại lượng

đo được trực tiếp từ dữ liệu. Với cấu hình này, đơn giá thiếu hàng suy ra trên 300 cặp dao động trong khoảng 0,50 đến 3,82, trung bình 1,20 – thấp hơn đáng kể so với hằng số $c_{th} = 10,0$ dùng cho thành phần phạt mức phục vụ, đúng theo chủ đích thiết kế đã nêu ở Mục 3.2.1.

3.3 Kiến trúc mạng Actor–Critic chia sẻ tham số

3.3.1 Hai mạng Actor và Critic độc lập, chia sẻ giữa các tác tử

Toàn bộ 300 tác tử dùng chung một bộ trọng số nơ-ron duy nhất [18]: tại mỗi bước, quan sát của cả 300 cặp được xếp thành một batch và đi qua cùng một mạng trong một lượt tính toán duy nhất, thay vì huấn luyện 300 mạng riêng biệt. Nhờ đó, số tham số cần học là một hằng số, không phụ thuộc vào quy mô hệ thống $N \times M$.

Điểm cần nhấn mạnh trong thiết kế là Actor (đầu ra phân phối xác suất trên $K = 6$ mức đặt hàng) và Critic (đầu ra ước lượng giá trị trạng thái) là **hai mạng hoàn toàn độc lập**, mỗi mạng gồm hai lớp ẩn kích thước 128 với hàm kích hoạt tanh và khởi tạo trọng số trực giao, được tối ưu bằng hai bộ tối ưu Adam riêng biệt và cắt chuẩn gradient (gradient clipping) riêng cho từng mạng. Quyết định thiết kế này xuất phát từ một quan sát thực nghiệm quan trọng trong quá trình phát triển: nếu Actor và Critic dùng chung một thân mạng và một phép cắt gradient áp dụng cho tổng gradient của cả hai nhánh, độ lớn gradient sinh ra từ hàm mất mát giá trị (value loss) có thể lớn hơn gradient sinh ra từ hàm mất mát chính sách (policy loss) tới hàng trăm lần – vì hai hàm mất mát này có đơn vị và thang đo hoàn toàn khác nhau. Khi đó, phép cắt gradient chung sẽ thu nhỏ toàn bộ gradient theo tỷ lệ do nhánh giá trị áp đảo quyết định, khiến tốc độ học hiệu dụng của Actor bị giảm đi hàng chục đến hàng trăm lần so với tốc độ học danh nghĩa, và chính sách gần như không nhận được tín hiệu học trong giai đoạn đầu huấn luyện. Tách hai mạng và hai bước tối ưu độc lập loại bỏ hoàn toàn sự giao thoa gradient này, trong khi vẫn giữ nguyên luận điểm chia sẻ tham số *giữa các tác tử* là không đổi.

3.3.2 Ổn định hóa quá trình huấn luyện

Bên cạnh việc tách hai mạng, ba cơ chế bổ sung được áp dụng để ổn định quá trình huấn luyện trên quy mô 300 tác tử:

- **Chuẩn hóa mục tiêu giá trị (value normalization):** thay vì huấn luyện Critic khớp trực tiếp giá trị lợi tức thô – vốn có thang đo thay đổi theo cấu hình chi phí – lợi tức được chuẩn hóa bằng trung bình và phương sai

trượt trước khi đưa vào hàm mất mát, và được khử chuẩn hóa khi trả giá trị ước lượng về cho quá trình thu thập dữ liệu. Cơ chế này tương tự kỹ thuật PopArt được sử dụng trong nhiều cài đặt MAPPO [21], giữ hàm mất mát giá trị luôn ở một thang đo ổn định bất kể độ lớn tuyệt đối của chi phí vận hành.

- **Cắt giá trị (value clipping):** mỗi lần cập nhật, ước lượng giá trị mới bị giới hạn không lệch quá xa so với ước lượng cũ, tránh một lô dữ liệu bất thường kéo Critic đi quá xa trong một bước cập nhật.
- **Ràng buộc bước cập nhật chính sách:** huấn luyện được dừng sớm trong một vòng lặp cập nhật nếu độ phân kỳ Kullback–Leibler ước lượng giữa chính sách mới và chính sách cũ vượt quá một ngưỡng cho phép, theo đúng tinh thần vùng tin cậy của TRPO [32] mà PPO kế thừa. Hệ số entropy và tốc độ học được giảm dần (annealing) theo tiến độ huấn luyện: hệ số entropy lớn ở giai đoạn đầu khuyến khích khám phá, sau đó giảm dần để chính sách hội tụ dứt khoát hơn ở giai đoạn cuối.

3.3.3 Quy trình huấn luyện IPPO

1. Thu thập dữ liệu (rollout): chạy $n_{\text{steps}} = 1024$ bước trong môi trường. Tại mỗi bước, cả 300 tác tử cùng chọn hành động dựa trên quan sát cục bộ, tổng cộng thu được khoảng $1024 \times 300 \approx 307.000$ mẫu (o_i, a_i, r_i, o'_i) mỗi vòng thu thập.
2. Tính GAE: ước lượng lợi thế $\hat{A}_t^{(i)}$ cho từng tác tử i độc lập theo trục thời gian bằng công thức GAE (2.7) với $\gamma = 0,99$ và $\lambda = 0,95$ – đây chính là ý nghĩa chữ “Independent” trong IPPO: độc lập về cách tính lợi tức của từng tác tử, trong khi vẫn chia sẻ chung một bộ tham số mạng.
3. Chuẩn hóa lợi thế theo từng cặp (per-pair advantage normalization): chuẩn hóa $\hat{A}_t^{(i)}$ theo trung bình và độ lệch chuẩn tính riêng cho mỗi cặp kho–mặt hàng i , cùng mục đích với phép chuẩn hóa phần thưởng ở Mục 3.2.2: giúp các cặp có quy mô chi phí khác nhau đóng góp cân bằng vào gradient của mạng dùng chung.
4. Cập nhật PPO: thực hiện tối đa $E = 4$ epoch tối ưu hóa hàm mục tiêu clipped (2.8) trên toàn bộ dữ liệu rollout, chia thành các minibatch 16.384 mẫu. Tốc độ học Actor $\eta_a = 3 \times 10^{-4}$, Critic $\eta_c = 1 \times 10^{-3}$, cả hai được giảm dần tuyến tính theo tiến độ huấn luyện.

5. Lặp lại bước 1–4 trong 5000 episode; cứ mỗi 25 episode, chính sách được đánh giá theo phương thức xác định (không lấy mẫu ngẫu nhiên) trên miền kiểm định để chọn ra bộ trọng số tốt nhất, theo đúng phân chia miền dữ liệu ở Mục 3.1.3.

Bảng 3.2 tóm tắt các siêu tham số chính.

Bảng 3.2: Siêu tham số huấn luyện

Nhóm	Tham số	Giá trị
Môi trường	$N \times M$ (số tác tử)	$10 \times 30 = 300$
	Episode length	365 ngày
	Lead time	$[1, 3]$ ngày
	Hệ số mức đặt hàng (K)	$\{0; 0,5; 1; 2; 3; 5\}$
PPO	Rollout steps (n_{steps})	1024
	PPO epochs (E)	4
	Kích thước minibatch	16.384
	Learning rate Actor	3×10^{-4}
	Learning rate Critic	1×10^{-3}
	γ	0,99
	λ_{GAE}	0,95
	Clip ϵ	0,2
	Hệ số entropy (đầu $\rightarrow$ cuối)	$0,02 \rightarrow 0,002$
	Ngưỡng KL cho dừng sớm	0,02
	Total episodes	5000
Mạng	Kiến trúc	2 mạng độc lập, mỗi mạng 2×128
	Activation	tanh

3.4 Thiết kế môi trường mô phỏng

Môi trường được xây dựng theo chuẩn giao diện Gymnasium [22], kế thừa từ chuẩn giao diện OpenAI Gym [31]: mỗi tập mô phỏng có thể được khởi tạo lại một cách độc lập và tái lập được nếu cùng một hạt giống ngẫu nhiên, và tiến triển theo từng bước thời gian rời rạc dựa trên hành động đồng thời của toàn bộ tác tử. Môi trường quản lý ma trận tồn kho của 300 cặp kho–mặt hàng, hàng đợi giao hàng đang trên đường theo từng cặp, lịch sử nhu cầu và tỷ lệ đáp ứng trượt, cùng hàm tính chi phí và phần thưởng theo công thức (3.3). Mỗi episode kéo dài 365 bước, tương đương một năm kinh doanh.

Khóa luận chủ động tự xây dựng môi trường mô phỏng này thay vì sử dụng trực tiếp các bộ thư viện benchmark sẵn có như OR-Gym [36] hay MABIM [38]. Lý

do cốt lõi là các benchmark hiện hành chưa hỗ trợ sẵn đồng thời cấu hình mạng lưới 10 kho song song độc lập nguồn cung, ràng buộc sức chứa kho hiệu chỉnh riêng theo từng kho và dùng chung giữa 30 SKU, cùng cơ chế phạt mức phục vụ theo cửa sổ trượt như mô tả ở Mục 3.2. Việc tự phát triển môi trường giúp đảm bảo khả năng kiểm soát toàn diện các tham số mô phỏng và tính tương thích cao nhất với mục tiêu nghiên cứu của đề tài.

CHƯƠNG 4. THỰC NGHIỆM VÀ ĐÁNH GIÁ KẾT QUẢ

4.1 Cấu hình thực nghiệm

4.1.1 Môi trường phần cứng và phần mềm

Toàn bộ quá trình huấn luyện và đánh giá được thực hiện trên CPU (không yêu cầu GPU): với kích thước mạng nơ-ron nhỏ (hai lớp ẩn 128 nơ-ron cho mỗi nhánh Actor và Critic, Mục 3.3.1), một lần huấn luyện đầy đủ 5000 episode mất khoảng 80 phút trên một nhân CPU. Môi trường thực nghiệm được cài đặt bằng Python với các thư viện cốt lõi: PyTorch (mạng Actor–Critic và thuật toán PPO), Gymnasium (giao diện môi trường mô phỏng), NumPy và Pandas (xử lý dữ liệu M5 và tính toán thống kê), SciPy (kiểm định thống kê) và Matplotlib (trực quan hóa).

4.1.2 Nguồn dữ liệu và tiền xử lý

Dữ liệu M5 Walmart. Khóa luận sử dụng hai tệp chính từ bộ dữ liệu M5 [2], [3]:

- `sales_train_evaluation.csv`: chứa 30.490 chuỗi doanh số theo ngày (3.049 mặt hàng $\times$ 10 cửa hàng) trên 1.941 ngày.
- `calendar.csv`: chứa thông tin lịch, ngày lễ và các sự kiện SNAP.
- `sell_prices.csv`: giá bán theo tuần của từng mặt hàng tại từng cửa hàng, dùng để suy ra đơn giá thiếu hàng theo giá thực tế (Mục 3.2.4).

Từ tổng số 3.049 mặt hàng, khóa luận chọn $M = 30$ mặt hàng đại diện cho mỗi cửa hàng trong số 10 cửa hàng (tương ứng 10 kho), theo hai bước: (i) loại bỏ các mặt hàng có nhu cầu trung bình dưới 0,2 đơn vị/ngày tại phần lớn số cửa hàng – những mặt hàng mà cửa hàng đó gần như không kinh doanh và chỉ đóng góp nhiều vào gradient của mạng chia sẻ tham số; (ii) trong số các mặt hàng còn lại, chọn theo phương pháp phân tầng đều trên các nhóm ngành hàng (thực phẩm, sở thích, gia dụng) để bảo đảm đa dạng về quy mô nhu cầu. Việc lọc và ước lượng tham số nhu cầu chỉ sử dụng phần dữ liệu thuộc miền huấn luyện (Mục 3.1.3), tránh rò rỉ thông tin từ các miền dùng để đánh giá.

Dữ liệu giả lập (Poisson synthetic). Song song, khóa luận sinh dữ liệu nhu cầu theo phân phối Poisson $D_t \sim \text{Poisson}(\lambda_i)$ để phục vụ kiểm thử đơn vị của môi trường mô phỏng trong điều kiện kiểm soát.

4.1.3 Thiết lập kịch bản mô phỏng

Mỗi episode huấn luyện/đánh giá kéo dài 365 ngày. Bảng 4.1 tóm tắt cấu hình môi trường (xem Chương 3 để biết thiết kế chi tiết).

Bảng 4.1: Cấu hình môi trường mô phỏng

Tham số	Giá trị
Số kho (N)	10
Số mặt hàng đại diện (M)	30
Số tác tử ($N \times M$)	300
Độ dài episode	365 ngày
Lead time	Uniform(1, 3) ngày
Hệ số mức đặt hàng (K , tương đối theo cầu mỗi cặp)	$\{0; 0,5; 1; 2; 3; 5\}$
Ngưỡng fill rate (τ)	85%

4.2 Phương pháp đối chứng (Baselines)

Hiệu năng của IPPO được so sánh với ba chính sách tồn kho cổ điển, cùng chạy trên chính môi trường mô phỏng của khóa luận:

- EOQ [12]: lượng đặt hàng cố định theo công thức (2.2), đặt hàng khi vị thế tồn kho giảm xuống dưới điểm đặt hàng lại.
- Chính sách (s, S) [13]: ngưỡng s và mức trần S .
- Newsvendor [14]: lượng đặt hàng tối ưu đơn kỳ theo công thức (2.4), áp dụng lại mỗi ngày.

Mỗi chính sách có các tham số có thể tinh chỉnh (hệ số nhân lượng đặt, mức phục vụ giả định, thời gian giao hàng giả định). Toàn bộ tham số này được xác định bằng tìm kiếm lưới (grid search) trực tiếp trên môi trường mô phỏng, **chỉ dùng miền huấn luyện**, trước khi đánh giá lại trên miền kiểm tra – nhằm bảo đảm các chính sách cổ điển được so sánh ở cấu hình tốt nhất có thể của chính chúng, thay vì dùng tham số lý thuyết mặc định. Bảng 4.2 liệt kê cấu hình tốt nhất tìm được cho từng chính sách.

Bảng 4.2: Tham số baseline sau tìm kiếm lưới trên miền huấn luyện

Chính sách	Tham số tốt nhất
EOQ	hệ số nhân $Q^* = 2,0$; thời gian giao hàng giả định = 3 ngày
(s, S)	mức phục vụ giả định = 70%; hệ số nhân = 0,5; thời gian giao hàng giả định = 3 ngày
Newsvendor	tỷ số tới hạn thay thế = 0,85; thời gian giao hàng giả định = 3 ngày

4.3 Giao thức đánh giá

4.3.1 Đánh giá đa hạt giống

Theo tinh thần khuyến nghị của Henderson và cộng sự [26] và Agarwal và cộng sự [27] về tính tái lập trong học tăng cường sâu, khóa luận huấn luyện và đánh giá IPPO trên 3 hạt giống ngẫu nhiên độc lập (42, 1, 2), mỗi hạt giống tương ứng một lần khởi tạo trọng số mạng khác nhau. Kết quả tổng hợp qua các hạt giống được báo cáo dưới dạng trung bình $\pm$ độ lệch chuẩn (Mục 4.4.5). Đây là một giới hạn cần nêu rõ: số hạt giống thực hiện được (3) thấp hơn khuyến nghị phổ biến (5 trở lên) do giới hạn thời gian tính toán trên CPU; kết quả chi tiết theo từng chỉ số so sánh với baseline (Mục 4.4.2) được báo cáo trên một hạt giống đại diện (42) với kiểm định thống kê trên 30 episode đánh giá độc lập của chính hạt giống đó, còn độ ổn định qua nhiều hạt giống được xác nhận riêng ở Mục 4.4.5.

4.3.2 Các chỉ số đánh giá

Bốn nhóm chỉ số chính:


1. Tổng chi phí vận hành (Total Cost): tổng chi phí lưu kho, thiếu hàng, đặt hàng và phạt tràn kho trên toàn bộ 365 ngày và 300 cặp kho–mặt hàng (không tính phần phạt mức phục vụ mang tính định hình hành vi ở công thức (3.3), vì đây là chi phí vận hành thực tế chứ không phải tín hiệu huấn luyện).
2. Tỷ lệ đáp ứng nhu cầu (Fill Rate): tỷ lệ nhu cầu được đáp ứng trên tổng nhu cầu, tính trung bình trên toàn hệ thống. Mục tiêu $\geq 85\%$.
3. Cơ cấu chi phí thành phần: phân tách tổng chi phí thành holding, stockout, ordering và overflow để phân tích chiến lược mà mỗi phương pháp áp dụng.
4. Đường cong học (Learning Curve): phần thưởng tích lũy, tỷ lệ đáp ứng nhu cầu, entropy chính sách và explained variance của Critic qua các episode huấn luyện, dùng để xác nhận tính hội tụ.

4.4 Kết quả thực nghiệm

4.4.1 Quá trình huấn luyện và tính hội tụ

Hình 4.1 trình bày diễn biến bốn đại lượng theo dõi trong suốt 5000 episode huấn luyện. Phần thưởng tích lũy trung bình trượt tăng nhanh và ổn định sau khoảng

300–500 episode đầu, không có dấu hiệu sụp đổ sau khi hội tụ. Entropy của chính sách giảm đều đặn từ giá trị gần với entropy tối đa lý thuyết của phân phối đều trên 6 hành động xuống một giá trị thấp và ổn định, cho thấy chính sách phân hóa hành động theo trạng thái thay vì giữ nguyên phân phối gần như ngẫu nhiên ban đầu. Explained variance của Critic đạt trên 0,97 ngay trong vài chục episode đầu và duy trì ổn định trong suốt phần còn lại của quá trình huấn luyện, cho thấy hàm giá trị khớp tốt với lợi tức thực tế trên cả 300 tác tử dùng chung một bộ trọng số. Tỷ lệ đáp ứng nhu cầu đo bằng đánh giá theo chính sách xác định trên miền kiểm định hội tụ quanh ngưỡng mục tiêu 85% sau khoảng 500 episode.



Hình 4.1: Đường cong huấn luyện IPPO qua 5000 episode: phần thưởng trung bình trượt, tỷ lệ đáp ứng nhu cầu, entropy chính sách và explained variance của Critic

4.4.2 So sánh trực tiếp tổng chi phí vận hành

Bảng 4.3 trình bày kết quả so sánh trực tiếp trên miền kiểm tra, trung bình trên 30 episode đánh giá độc lập (hạt giống 42).

Dem so sánh trực tiếp, IPPO có tổng chi phí cao hơn EOQ khoảng 3,8% ($t = 7,087$; $p_{\text{Welch}} = 3,64 \times 10^{-9}$; Wilcoxon $p = 1,86 \times 10^{-9}$; Cohen's $d = 1,83$ – khác biệt có ý nghĩa thống kê rất mạnh), nhưng thấp hơn cả (s, S) và Newsvendor. Tuy nhiên, cách so sánh này chưa công bằng: bốn chính sách đang đạt các mức phục vụ khác

Bảng 4.3: So sánh trực tiếp tổng chi phí vận hành trên miền kiểm tra (trung bình 30 episode)

Phương pháp	Total Cost	Fill Rate	So với IPPO
EOQ	951.263	75,01%	−3,7% (rẻ hơn)
(s, S)	1.003.584	84,23%	+1,6% (đắt hơn)
Newsvendor	1.039.680	84,47%	+5,3% (đắt hơn)
IPPO	987.745	85,21%	—

nhau. IPPO bị phạt trực tiếp khi tỷ lệ đáp ứng dưới ngưỡng 85% (công thức 3.3) nên tự nâng mức phục vụ lên 85,21%, trong khi ba baseline được tinh chỉnh bằng tìm kiếm lưới để *tối thiểu hóa chi phí thuần túy* nên dừng lại ở mức thấp hơn – EOQ đặc biệt chỉ đạt 75,01%, thấp hơn ngưỡng mục tiêu tới 10 điểm phần trăm. Kết luận “IPPO đắt hơn EOQ” rút ra từ Bảng 4.3 vì vậy là một kết luận sai lệch nếu không kiểm soát theo mức phục vụ.


4.4.3 So sánh ở cùng mức phục vụ

Để so sánh công bằng, với từng chính sách đối chứng, tham số được tìm kiếm lại bằng lưới trên miền huấn luyện để tìm cấu hình *rẻ nhất vẫn đạt được mức phục vụ tối thiểu bằng mức mà IPPO đạt được* trên miền kiểm tra ($\geq 84,71\%$, đã trừ một biên độ sai số cho phép), rồi đánh giá lại cấu hình đó trên miền kiểm tra. Bảng 4.4 và Hình 4.2 trình bày kết quả.

Bảng 4.4: So sánh tổng chi phí ở cùng mức phục vụ tối thiểu 84,71% (miền kiểm tra)

Phương pháp	Total Cost	Fill Rate	So với IPPO
IPPO	987.745	85,21%	—
EOQ	1.882.296	92,81%	IPPO rẻ hơn 47,5%
(s, S)	1.254.160	89,22%	IPPO rẻ hơn 21,2%
Newsvendor	1.113.546	86,28%	IPPO rẻ hơn 11,3%


Ở cùng một ngưỡng mức phục vụ, IPPO có chi phí thấp nhất trong cả bốn phương pháp, và khoảng cách càng lớn khi ngưỡng mức phục vụ càng cao: không có cấu hình EOQ nào trong lưới tìm kiếm vượt qua ngưỡng 85% một cách hiệu quả về chi phí – cấu hình rẻ nhất đạt được ngưỡng này phải hy sinh tới 47,5% chi phí tăng thêm so với IPPO. Đây là bằng chứng cho thấy các chính sách tham số tĩnh cổ điển, dù đã được tối ưu hóa tham số bằng tìm kiếm lưới trên chính môi trường mô phỏng, không thích ứng hiệu quả khi yêu cầu mức phục vụ tăng lên, trong khi chính sách học theo trạng thái của IPPO duy trì mức phục vụ đó với chi phí thấp hơn đáng kể.



Hình 4.2: Tổng chi phí vận hành của bốn chính sách khi mọi chính sách đều đạt tối thiểu mức phục vụ mà IPPO đạt được (miền kiểm tra)


4.4.4 Phân tích cơ cấu chi phí

Hình 4.3 trình bày cơ cấu bốn thành phần chi phí của từng chính sách trong so sánh trực tiếp. Trong cơ cấu chi phí của IPPO (987.745), chi phí lưu kho chiếm 83,0%, chi phí đặt hàng 12,7%, chi phí thiếu hàng 3,9% và chi phí tràn kho chỉ 0,4%. So với EOQ (lưu kho 82,6%, thiếu hàng 5,5%, đặt hàng 9,8%, tràn kho 2,1%), IPPO đạt chi phí tràn kho thấp hơn khoảng 5 lần và chi phí thiếu hàng thấp hơn tương đối, đổi lại chi phí đặt hàng cao hơn – phản ánh một chiến lược đặt hàng thường xuyên hơn với lô nhỏ hơn để vừa duy trì mức phục vụ cao vừa tránh vượt sức chứa kho, thay vì gom đơn hàng thành các lô lớn như EOQ.



Hình 4.3: So sánh trực tiếp tổng chi phí, tỷ lệ đáp ứng nhu cầu và cơ cấu chi phí giữa bốn phương pháp (miền kiểm tra)

Hình 4.4 thể hiện rõ vị trí của bốn chính sách trên mặt phẳng đánh đổi chi phí – mức phục vụ: EOQ nằm ở góc chi phí thấp nhất nhưng mức phục vụ thấp nhất; IPPO nằm ở góc mức phục vụ cao nhất với chi phí chỉ nhỉnh hơn EOQ một biên độ nhỏ,



Hình 4.4: Đánh đổi giữa tổng chi phí vận hành và tỷ lệ đáp ứng nhu cầu của bốn phương pháp (miền kiểm tra); điểm càng gần góc dưới bên phải càng tốt

trong khi (s, S) và Newsvendor không đạt được vị trí tốt hơn IPPO trên cả hai trục đồng thời.

4.4.5 Đánh giá tỷ lệ đáp ứng dịch vụ theo nhiều hạt giống

Trên 3 hạt giống ngẫu nhiên độc lập (42, 1, 2), IPPO đạt tổng chi phí trung bình $1.043.125 \pm 9.272$ và tỷ lệ đáp ứng nhu cầu trung bình $86,10\% \pm 0,15\%$. Độ lệch chuẩn nhỏ (dưới 1% chi phí và dưới 0,2 điểm phần trăm fill rate) cho thấy chính sách học được ổn định qua các lần khởi tạo trọng số khác nhau, không phụ thuộc quá mức vào một hạt giống ngẫu nhiên cụ thể – dù mức độ tin cậy này vẫn bị giới hạn bởi số hạt giống còn khiêm tốn đã nêu ở Mục 4.3.1.

4.5 Phân tích chuyên sâu


4.5.1 Khả năng tổng quát hóa qua parameter sharing (Câu hỏi 2)

Để trả lời Câu hỏi nghiên cứu 2, khóa luận phân chia 300 cặp kho–mặt hàng thành ba nhóm tam phân vị theo nhu cầu trung bình ước lượng trên miền huấn luyện: nhóm thấp (100 cặp, nhu cầu trung bình 0,05–0,47 đơn vị/ngày), nhóm trung bình (100 cặp, 0,47–1,16 đơn vị/ngày) và nhóm cao (100 cặp, 1,17–158,6 đơn vị/ngày), rồi đánh giá lại chính sách IPPO đã huấn luyện trên miền kiểm tra theo từng nhóm riêng biệt. Bảng 4.5 và Hình 4.5 trình bày kết quả.

Kết quả cho thấy khả năng tổng quát hóa của cơ chế chia sẻ tham số là **có điều**

Bảng 4.5: Fill rate và chi phí cục bộ trung bình mỗi cặp mỗi ngày theo nhóm quy mô cầu (miền kiểm tra, 30 episode)

Nhóm	Fill rate trung bình	Fill rate thấp nhất	Chi phí/cặp/ngày
Thấp (tercile 1)	72,79%	9,38%	3,59
Trung bình (tercile 2)	83,57%	53,58%	5,03
Cao (tercile 3)	86,31%	62,06%	23,65



Hình 4.5: Fill rate và chi phí cục bộ trung bình theo nhóm quy mô cầu (miền kiểm tra)

kiện, không đồng đều tuyệt đối giữa các nhóm quy mô cầu. Nhóm cầu cao đạt fill rate trung bình 86,31%, vượt ngưỡng mục tiêu 85% với biên độ an toàn hợp lý. Nhóm cầu trung bình đạt 83,57%, xấp xỉ nhưng chưa hoàn toàn đạt ngưỡng. Nhóm cầu thấp – những mặt hàng có đặc trưng gián đoạn rõ rệt, thường có nhiều ngày liên tiếp không phát sinh nhu cầu – chỉ đạt trung bình 72,79%, thấp hơn ngưỡng mục tiêu tới hơn 12 điểm phần trăm, và một số cặp trong nhóm này có fill rate thấp tới 9,38%. Nguyên nhân có thể đến từ hai phía: (i) với nhu cầu rất thưa, một vài lần thiếu hàng hiếm hoi cũng làm fill rate của sổ trượt dao động rất mạnh so với nhóm cầu dày đặc; (ii) bảng mức đặt hàng tương đối theo cầu của chính từng cặp (công thức 3.2) khiến các mức đặt hàng khả dĩ của nhóm này có bước nhảy rất thô (ví dụ 0, 1, 2 đơn vị), giới hạn khả năng tinh chỉnh lượng đặt so với các cặp có cầu lớn hơn. Như vậy, mạng chia sẻ tham số học được một chính sách hoạt động tốt trên phần lớn hệ thống, nhưng chưa bù đắp hoàn toàn cho nhóm SKU có nhu cầu gián đoạn nhất – đây là một giới hạn cụ thể của thiết kế hiện tại, không phải một thất bại toàn diện của cơ chế chia sẻ tham số.

4.5.2 Vai trò của cơ chế chuẩn hóa phần thưởng cục bộ (Câu hỏi 3)

Thiết kế hàm phần thưởng được triển khai và đánh giá xuyên suốt khóa luận là phần thưởng phân rã cục bộ có chuẩn hóa theo từng cặp (Mục 3.2.1–3.2.2). Trong quá trình phát triển môi trường mô phỏng, nhóm thực hiện có quan sát định lượng làm rõ

tầm quan trọng của cơ chế chuẩn hóa này: ở một cấu hình sơ bộ ban đầu (trước khi hiệu chỉnh số lượng SKU và bổ sung phép chuẩn hóa theo từng cặp), phần thưởng thô chưa chuẩn hóa khiến entropy chính sách giữ nguyên ở giá trị tối đa trong phần lớn quá trình huấn luyện rồi sụp đổ đột ngột, phần lớn tác tử hội tụ về hành động “không đặt hàng” bất kể trạng thái quan sát được, và tỷ lệ đáp ứng nhu cầu cuối cùng chỉ đạt khoảng 73% – thấp hơn cả ba chính sách cổ điển đối chứng. Quan sát này phù hợp với lý do kỹ thuật đã trình bày ở Mục 3.2.2: khi phần thưởng thô của các cặp chênh lệch tới hàng nghìn lần, tín hiệu học của phần lớn hệ thống bị nhiễu của một số ít cặp có quy mô chi phí lớn nhất lấn át.

Cần nêu rõ giới hạn của bằng chứng này: đây là một quan sát trong quá trình phát triển ở một cấu hình môi trường sơ bộ, **không phải** một thí nghiệm loại trừ (ablation) có kiểm soát được thực hiện lại đầy đủ trên đúng cấu hình 300 cặp và bộ siêu tham số cuối cùng dùng để báo cáo ở Chương 4. Việc lặp lại thí nghiệm này – tắt cơ chế chuẩn hóa phần thưởng theo từng cặp trên đúng cấu hình hiện tại và huấn luyện lại với cùng hạt giống, cùng số episode – là một thực nghiệm loại trừ có giá trị nhưng nằm ngoài phạm vi thời gian thực hiện của khóa luận này, và được đề xuất là hướng thực nghiệm bổ sung ở Chương 5. Tương tự, phương án thay thế hoàn toàn bằng một phần thưởng toàn cục dùng chung cho cả 300 tác tử (thay vì phân rã cục bộ) chưa được cài đặt và thực nghiệm trong phạm vi khóa luận.

4.5.3 Các kịch bản IPPO chưa vượt trội

Khóa luận trình bày trung thực hai kịch bản mà IPPO không thể hiện lợi thế tuyệt đối:

- So sánh trực tiếp không kiểm soát mức phục vụ (Mục 4.4.2): IPPO có tổng chi phí cao hơn EOQ khoảng 3,8%. Đây không phải một điểm yếu của chính sách học được, mà là hệ quả trực tiếp của việc IPPO theo đuổi một mục tiêu mức phục vụ cao hơn hẳn (85,2% so với 75,0% của EOQ) do chịu tác động của thành phần phạt ràng buộc trong hàm phần thưởng.
- Nhóm SKU có nhu cầu thấp và gián đoạn nhất (Mục 4.5.1): chính sách chia sẻ tham số chưa đạt được mức phục vụ mục tiêu một cách đồng đều trên nhóm này, với một số cặp có fill rate thấp tới dưới 10%. Đây là giới hạn thực tế của việc dùng một bảng mức đặt hàng rời rạc có bước nhảy thô cho những mặt hàng có quy mô cầu rất nhỏ, kết hợp với bản chất phương sai cao của tỷ lệ đáp ứng khi đo trên một lượng giao dịch rất thưa thớt.

4.6 Thảo luận

Tổng hợp lại, kết quả thực nghiệm cho thấy bức tranh nhiều sắc thái hơn một kết luận đơn giản “IPPO tốt hơn hay kém hơn các phương pháp cổ điển”. Với Câu hỏi nghiên cứu 1, khi so sánh ở cùng một mức phục vụ – điều kiện so sánh đúng đắn về mặt kinh tế – IPPO có tổng chi phí thấp hơn cả ba baseline, với khoảng cách tăng dần theo yêu cầu mức phục vụ, và EOQ hoàn toàn không tìm được cấu hình nào đạt ngưỡng 85% một cách hiệu quả về chi phí. Điều này phù hợp với nhận định của Gijsbrechts và cộng sự [17] rằng học tăng cường sâu có xu hướng thể hiện lợi thế rõ rệt nhất trong các chế độ vận hành nhạy cảm với chi phí thiếu hàng và ràng buộc mức phục vụ, dù quy mô thực nghiệm của khóa luận này (300 cặp kho–mặt hàng) lớn hơn đáng kể so với quy mô dưới 10 SKU trong nghiên cứu của họ.

Với Câu hỏi nghiên cứu 2, cơ chế chia sẻ tham số tổng quát hóa tốt cho các nhóm SKU có nhu cầu từ trung bình trở lên, nhưng chưa bù đắp hoàn toàn cho nhóm nhu cầu thấp và gián đoạn nhất – một giới hạn cụ thể cần được ghi nhận khi áp dụng thiết kế này vào các danh mục hàng hóa có tỷ trọng SKU bán chậm cao.

Với Câu hỏi nghiên cứu 3, cơ chế phân rã phần thưởng cục bộ kèm chuẩn hóa theo từng cặp là thiết kế trung tâm giúp một mạng nơ-ron duy nhất học được đồng thời trên 300 cặp có quy mô chi phí chênh lệch nhiều bậc độ lớn, được củng cố bởi quan sát định lượng trong quá trình phát triển (Mục 4.5.2). Tuy nhiên, khóa luận thừa nhận rằng bằng chứng cho câu hỏi này chưa đạt tới mức một thí nghiệm loại trừ có kiểm soát hoàn chỉnh trên cấu hình cuối cùng, và đây là hạn chế cần được khắc phục trong các nghiên cứu tiếp theo (Chương 5).

CHƯƠNG 5. KẾT LUẬN VÀ HƯỚNG PHÁT TRIỂN

5.1 Tổng kết các kết quả đạt được

Khóa luận đã hoàn thành bốn mục tiêu nghiên cứu đề ra:

1. Xây dựng môi trường mô phỏng: phát triển thành công một môi trường mô phỏng theo chuẩn Gymnasium [22], mô hình hóa đầy đủ hệ thống 10 kho, 30 mặt hàng đại diện (300 cặp tác tử), với nhu cầu ngẫu nhiên, thời gian giao hàng biến động [1, 3] ngày, dung lượng kho hiệu chỉnh riêng theo từng kho và năm nhóm chi phí vận hành. Tham số nhu cầu và giá bán được hiệu chỉnh từ bộ dữ liệu M5 Walmart [2].
2. Thiết kế hàm phần thưởng: đề xuất hàm phần thưởng phân rã cục bộ (dựa trên nguyên lý phần thưởng chênh lệch [23]) kèm thành phần phạt fill rate ràng buộc theo tinh thần Lagrangian trên cửa sổ trượt 30 ngày, cùng cơ chế chuẩn hóa phần thưởng theo từng cặp giúp một mạng nơ-ron duy nhất học đồng thời trên các cặp có quy mô chi phí chênh lệch nhiều bậc độ lớn.
3. Cài đặt và huấn luyện IPPO: triển khai thuật toán Independent Multi-Agent PPO [20] với hai mạng Actor và Critic độc lập chia sẻ tham số giữa các tác tử [18], sử dụng GAE [25], chuẩn hóa lợi thế theo từng cặp, chuẩn hóa mục tiêu giá trị và các cơ chế kiểm soát bước cập nhật. Mô hình hội tụ ổn định trên quy mô 300 tác tử sau khoảng 500 episode.
4. Đánh giá đối chứng: so sánh IPPO với ba chính sách cổ điển (EOQ, (s, S) , Newsvendor) đã được tinh chỉnh tham số bằng tìm kiếm lưới, theo giao thức đa hạt giống có kiểm định thống kê [26], [27], cả trong so sánh trực tiếp và so sánh ở cùng mức phục vụ.

5.1.1 Trả lời các câu hỏi nghiên cứu

Câu hỏi 1 (IPPO so với các baseline cổ điển): so sánh trực tiếp không kiểm soát mức phục vụ cho thấy IPPO có tổng chi phí cao hơn EOQ khoảng 3,8% nhưng đạt fill rate 85,21% so với 75,01% của EOQ – một so sánh không công bằng vì hai chính sách đang vận hành ở hai mức phục vụ khác nhau. Khi so sánh ở cùng ngưỡng mức phục vụ tối thiểu ($\geq 84,71\%$), IPPO có tổng chi phí thấp nhất trong cả bốn phương pháp: rẻ hơn EOQ 47,5%, rẻ hơn (s, S) 21,2% và rẻ hơn Newsvendor 11,3% (Mục 4.4.3). Câu

trả lời cho Câu hỏi 1 vì vậy là **có, với điều kiện**: IPPO không rẻ hơn tuyệt đối trong mọi phép so sánh, nhưng vượt trội rõ rệt khi so sánh đúng đắn ở cùng một mức phục vụ – đúng là điều kiện so sánh có ý nghĩa kinh tế thực sự.

Câu hỏi 2 (Tổng quát hóa qua parameter sharing): phân tích theo ba nhóm tam phân vị quy mô cầu (Mục 4.5.1) cho thấy khả năng tổng quát hóa là **có điều kiện**. Chính sách chia sẻ tham số đạt fill rate gần hoặc vượt ngưỡng mục tiêu ở nhóm cầu trung bình (83,57%) và cao (86,31%), nhưng chỉ đạt 72,79% ở nhóm cầu thấp và gián đoạn nhất, với một số cặp cá biệt xuống dưới 10%. Cơ chế chia sẻ tham số vì vậy tổng quát hóa tốt cho phần lớn hệ thống nhưng chưa đủ để bù đắp hoàn toàn cho các mặt hàng có đặc trưng nhu cầu cực đoan nhất.

Câu hỏi 3 (Local reward so với global reward): khóa luận triển khai và đánh giá đầy đủ phương án phân thưởng phân rã cục bộ có chuẩn hóa theo từng cặp trên toàn bộ thực nghiệm ở Chương 4, được củng cố bởi một quan sát định lượng trong giai đoạn phát triển cho thấy việc thiếu cơ chế chuẩn hóa từng gây ra hiện tượng không hội tụ (Mục 4.5.2). Tuy nhiên, một thí nghiệm loại trừ (ablation) có kiểm soát, so sánh trực tiếp phân thưởng cục bộ với một phân thưởng toàn cục dùng chung trên đúng cấu hình 300 cặp cuối cùng, **chưa được thực hiện** trong phạm vi khóa luận này. Câu hỏi 3 vì vậy chỉ được trả lời một phần, và được xác định là hạn chế cùng hướng nghiên cứu tiếp theo quan trọng nhất (Mục 5.3).

5.2 Những hạn chế còn tồn tại

- Cấu trúc mạng lưới đơn giản: các kho hoạt động song song và độc lập về nguồn cung; chưa xét cấu trúc đa cấp (multi-echelon) với quan hệ cung ứng giữa các kho [28] và hiệu ứng bullwhip [29].
- Không có truyền thông giữa các tác tử: các tác tử ra quyết định hoàn toàn dựa trên quan sát cục bộ, chưa tận dụng thông tin từ các cặp kho–mặt hàng khác ngoài tín hiệu mức sử dụng sức chứa kho dùng chung.
- Không gian hành động rời rạc: chỉ có $K = 6$ mức đặt hàng tương đối theo cầu; với các mặt hàng có nhu cầu rất thấp, bước nhảy giữa các mức trở nên thô và góp phần vào hạn chế nêu ở Mục 4.5.1.
- Chưa tích hợp dự báo nhu cầu: tác tử sử dụng trực tiếp nhu cầu lịch sử thay vì dự báo bằng mô hình học sâu chuỗi thời gian.
- Số hạt giống thực nghiệm còn khiêm tốn: kết quả đa hạt giống được báo cáo trên 3 hạt giống, thấp hơn khuyến nghị phổ biến (5 trở lên) do giới hạn

thời gian huấn luyện trên CPU.

- Thiếu thí nghiệm loại trừ (ablation) trên cấu hình cuối cùng: như đã nêu ở Câu hỏi nghiên cứu 3, vai trò của cơ chế chuẩn hóa phần thưởng theo từng cặp và phương án phần thưởng toàn cục dùng chung chưa được kiểm chứng bằng một thí nghiệm đối chứng trực tiếp trên đúng cấu hình 300 cặp báo cáo ở Chương 4.
- Thực nghiệm trên môi trường mô phỏng: chưa được kiểm chứng trên hệ thống ERP thực tế hoặc dữ liệu vận hành trực tiếp; đơn giá thiếu hàng theo giá thực tế còn dựa trên một giả định về tỷ lệ biên lợi nhuận (30%) do bộ dữ liệu M5 không công bố giá vốn (Mục 3.2.4).

5.3 Hướng phát triển trong tương lai

- Hoàn thiện thí nghiệm loại trừ cho Câu hỏi nghiên cứu 3: huấn luyện lại trên đúng cấu hình 300 cặp hiện tại với cơ chế chuẩn hóa phần thưởng theo từng cặp bị tắt, và với một phương án phần thưởng toàn cục dùng chung, cùng hạt giống và số episode, để có bằng chứng đối chứng trực tiếp thay vì chỉ dựa trên quan sát phát triển sơ bộ.
- Mở rộng số hạt giống đánh giá: chạy thêm hạt giống để đạt tối thiểu 5 hạt giống độc lập theo khuyến nghị về tính tái lập trong học tăng cường sâu.
- Cải thiện chính sách cho nhóm SKU nhu cầu thấp: xem xét không gian hành động liên tục hoặc bảng mức đặt hàng có độ phân giải mịn hơn cho các cặp có nhu cầu rất thấp, nhằm thu hẹp khoảng cách fill rate đã ghi nhận ở nhóm này (Mục 4.5.1).
- Mở rộng sang cấu trúc đa cấp (multi-echelon): mô hình hóa quan hệ cung ứng giữa kho trung tâm và kho khu vực, cho phép tác tử học chiến lược điều phối liên kho.
- Tích hợp cơ chế truyền thông giữa tác tử: áp dụng các phương pháp như CommNet hoặc TarMAC để cho phép tác tử chia sẻ thông tin, đặc biệt về tình trạng sức chứa kho.
- Tích hợp dự báo nhu cầu: nhúng mô hình dự báo chuỗi thời gian (LSTM, Transformer) vào vector quan sát của tác tử, tận dụng thông tin xu hướng và mùa vụ.
- Kiểm chứng giả định kinh tế về đơn giá thiếu hàng: thu thập hoặc ước lượng

dữ liệu giá vốn thực tế để thay thế giả định tỷ lệ biên lợi nhuận hiện tại, và phân tích độ nhạy của kết quả theo tỷ lệ này.

- Mở rộng quy mô: thử nghiệm với số lượng SKU lớn hơn trong bộ dữ liệu M5 gốc và đánh giá lại khả năng mở rộng của cơ chế chia sẻ tham số khi quy mô hệ thống tăng lên.
- Triển khai thử nghiệm thực tế: xây dựng hệ thống dạng SaaS kết nối API với nền tảng quản lý kho, cho phép đánh giá mô hình trên dữ liệu vận hành trực tiếp.

PHỤ LỤC A. ĐỐI CHIẾU LUẬN ĐIỂM VÀ NGUỒN TRÍCH DẪN

Phụ lục này liệt kê từng luận điểm lý thuyết được sử dụng trong khóa luận kèm nguồn gốc học thuật tương ứng, nhằm bảo đảm mọi khẳng định đều truy nguyên được về tài liệu công bố chính thống.

Mục	Luận điểm	Nguồn
<i>A.1. Lý thuyết tồn kho</i>		
1.1.1	Quản lý tồn kho đa điểm, đa mặt hàng trong chuỗi cung ứng bán lẻ	Silver and others [1]; Zipkin [8]
1.1.1	Mô tả bộ dữ liệu M5: quy mô, cấu trúc phân cấp, giai đoạn thu thập	Makridakis and others [2]; Howard and others [3]
1.1.1	Tiêu chí phân loại dạng nhu cầu (ngưỡng $p = 1,32$; $CV^2 = 0,49$)	Syntetos and others [4]
1.1.1	Nhu cầu gián đoạn và hạn chế của phương pháp dự báo thông thường	Croston [6]; Syntetos and Boylan [7]
1.1.2	Bất định của nhu cầu và thời gian giao hàng; hiện tượng vượt đơn	Zipkin [8]; Silver and others [1]
1.1.2	Cấu trúc chi phí tồn kho và bài toán đánh đổi	Zipkin [8]
1.1.3	Mô hình lượng đặt hàng kinh tế (EOQ)	Harris [12]
1.1.3	Tính tối ưu của chính sách (s, S) và các điều kiện kèm theo	Scarf [13]
1.1.3	Mô hình người bán báo (Newsvendor) một chu kỳ	Arrow and others [14]
1.1.3	Bài toán mất đơn hàng không có nghiệm giải tích dạng đóng	Zipkin [15]
1.3.3	Cấu trúc tồn kho đa cấp (nằm ngoài phạm vi)	Clark and Scarf [28]
1.3.3	Hiệu ứng bullwhip (nằm ngoài phạm vi)	Lee and others [29]

Mục	Luận điểm	Nguồn
-----	-----------	-------

A.2. Học tăng cường

2.3.1	Quá trình quyết định Markov và quy hoạch động ngẫu nhiên	Puterman [30]
2.3.1	Hàm giá trị, phương trình Bellman, hàm lợi thế, định lý policy gradient	Sutton and Barto [10]
2.3.3	Ước lượng lợi thế tổng quát (GAE) và đánh đổi bias–variance	Schulman and others [25]
2.3.4	Vùng tin cậy trong tối ưu hóa chính sách	Schulman and others [32]
2.3.4	Hàm mục tiêu cắt của PPO	Schulman and others [24]
2.5.4	Điều kiện bảo toàn chính sách tối ưu khi định hình phần thưởng	Ng and others [33]

A.3. Học tăng cường đa tác tử

1.1.2	Độ phức tạp NEXP-đầy đủ của điều khiển phi tập trung	Bernstein and others [11]
2.4.1	Mô hình Dec-POMDP	Oliehoek and Amato [9]
2.4.2	Học độc lập và vấn đề môi trường không dừng	Tan [19]
2.4.3	Thuật toán IPPO	Schröder de Witt and others [20]
2.4.3	MAPPO và khung huấn luyện tập trung, thực thi phân tán	Yu and others [21]
2.4.4	Chia sẻ tham số giữa các tác tử đồng nhất	Gupta and others [18]
2.4.5	Phần thưởng chênh lệch và bài toán gán tín dụng đa tác tử	Wolpert and Tumer [23]

A.4. Ứng dụng, môi trường và giao thức đánh giá

2.8	Học tăng cường sâu cho trò chơi phân phối bia	Oroojlooyjadid and others [16]
2.8	Đánh giá học tăng cường sâu trên các lớp bài toán tồn kho	Gijsbrechts and others [17]
3.2	Chuẩn giao diện môi trường học tăng cường	Brockman and others [31]; Towers and others [22]

Mục	Luận điểm	Nguồn
2.7	Yêu cầu đa hạt giống và tính tái lập trong đánh giá	Henderson and others [26]
2.7	Phương pháp báo cáo kết quả có kiểm định thống kê	Agarwal and others [27]

Ghi chú. Các số liệu thống kê mô tả bộ dữ liệu M5 trình bày trong Mục 1.1.1 và Bảng 1.1 do nhóm tác giả tự tính toán từ hai tệp `sales_train_evaluation.csv` và `calendar.csv`; mã nguồn tính toán được đính kèm trong kho mã của khóa luận.

TÀI LIỆU THAM KHẢO

E. A. Silver, D. F. Pyke **and** D. J. Thomas, *Inventory and Production Management in Supply Chains*, 4 **edition**. Boca Raton, FL: CRC Press, 2016.

S. Makridakis, E. Spiliotis **and** V. Assimakopoulos, “The M5 competition: Background, organization, and implementation,” *International Journal of Forecasting*, **jourvol** 38, **number** 4, **pages** 1325–1336, 2022. DOI: 10.1016/j.ijforecast.2021.07.007

A. Howard, N. Vandeput, Makridakis, Spyros, Assimakopoulos, Vassilios **and** inversion, *M5 Forecasting – Accuracy*, Kaggle competition, 2020. **url**: <https://www.kaggle.com/competitions/m5-forecasting-accuracy>

A. A. Syntetos, J. E. Boylan **and** J. D. Croston, “On the categorization of demand patterns,” *Journal of the Operational Research Society*, **jourvol** 56, **number** 5, **pages** 495–503, 2005. DOI: 10.1057/palgrave.jors.2601841

A. I. Kostenko **and** R. J. Hyndman, “A note on the categorization of demand patterns,” *Journal of the Operational Research Society*, **jourvol** 57, **number** 10, **pages** 1256–1257, 2006. DOI: 10.1057/palgrave.jors.2602211

J. D. Croston, “Forecasting and stock control for intermittent demands,” *Operational Research Quarterly*, **jourvol** 23, **number** 3, **pages** 289–303, 1972. DOI: 10.1057/jors.1972.50

A. A. Syntetos **and** J. E. Boylan, “The accuracy of intermittent demand estimates,” *International Journal of Forecasting*, **jourvol** 21, **number** 2, **pages** 303–314, 2005. DOI: 10.1016/j.ijforecast.2004.10.001

P. H. Zipkin, *Foundations of Inventory Management*. Boston: McGraw-Hill, 2000.

F. A. Oliehoek **and** C. Amato, *A Concise Introduction to Decentralized POMDPs*. Cham: Springer, 2016. DOI: 10.1007/978-3-319-28929-8

R. S. Sutton **and** A. G. Barto, *Reinforcement Learning: An Introduction*, 2 **edition**. Cambridge, MA: MIT Press, 2018.

D. S. Bernstein, R. Givan, N. Immerman **and** S. Zilberstein, “The complexity of decentralized control of Markov decision processes,” *Mathematics of Operations Research*, **jourvol** 27, **number** 4, **pages** 819–840, 2002. DOI: 10.1287/moor.27.4.819.297

F. W. Harris, “How many parts to make at once,” *Factory, The Magazine of Management*, **jourvol** 10, **number** 2, **pages** 135–136, 152, 1913.

H. Scarf, “The optimality of (S, s) policies in the dynamic inventory problem,” in *Mathematical Methods in the Social Sciences* K. J. Arrow, S. Karlin **and** P. Suppes, **editors**, Stanford, CA: Stanford University Press, 1960, **pages** 196–202.

K. J. Arrow, T. Harris **and** J. Marschak, “Optimal inventory policy,” *Econometrica*, **jourvol** 19, **number** 3, **pages** 250–272, 1951. DOI: 10.2307/1906813

P. Zipkin, “Old and new methods for lost-sales inventory systems,” *Operations Research*, **jourvol** 56, **number** 5, **pages** 1256–1263, 2008. DOI: 10.1287/opre.1070.0471

A. Oroojlooyjadid, M. Nazari, L. V. Snyder **and** M. Takáč, “A deep Q-network for the beer game: Deep reinforcement learning for inventory optimization,” *Manufacturing & Service Operations Management*, **jourvol** 24, **number** 1, **pages** 285–304, 2022. DOI: 10.1287/msom.2020.0939

J. Gijsbrechts, R. N. Boute, J. A. Van Mieghem **and** D. J. Zhang, “Can deep reinforcement learning improve inventory management? Performance on lost sales, dual-sourcing, and multi-echelon problems,” *Manufacturing & Service Operations Management*, **jourvol** 24, **number** 3, **pages** 1349–1368, 2022. DOI: 10.1287/msom.2021.1064

J. K. Gupta, M. Egorov **and** M. Kochenderfer, “Cooperative multi-agent control using deep reinforcement learning,” in *Autonomous Agents and Multiagent Systems (AAMAS 2017 Workshops)* **jourser** Lecture Notes in Computer Science, **volume** 10642, Springer, 2017, **pages** 66–83. DOI: 10.1007/978-3-319-71682-4_5

M. Tan, “Multi-agent reinforcement learning: Independent vs. cooperative agents,” in *Proceedings of the 10th International Conference on Machine Learning* 1993, **pages** 330–337.

C. Schröder de Witt **and others**, *Is independent learning all you need in the StarCraft multi-agent challenge?* arXiv preprint arXiv:2011.09533, 2020. arXiv: 2011.09533.

C. Yu **and others**, “The surprising effectiveness of PPO in cooperative multi-agent games,” **in** *Advances in Neural Information Processing Systems 35 (NeurIPS 2022), Datasets and Benchmarks Track 2022*, **pages** 24 611–24 624.

M. Towers, A. Kwiatkowski, J. Terry, J. U. Balis, G. De Cola, T. Deleu **and others**, *Gymnasium: A standard interface for reinforcement learning environments*, arXiv preprint arXiv:2407.17032, 2024. arXiv: 2407.17032.

D. H. Wolpert **and** K. Tumer, “Optimal payoff functions for members of collectives,” *Advances in Complex Systems*, **journal** 4, **number** 2–3, **pages** 265–279, 2001. DOI: 10.1142/S0219525901000188

J. Schulman, F. Wolski, P. Dhariwal, A. Radford **and** O. Klimov, *Proximal policy optimization algorithms*, arXiv preprint arXiv:1707.06347, 2017. arXiv: 1707.06347.

J. Schulman, P. Moritz, S. Levine, M. Jordan **and** P. Abbeel, “High-dimensional continuous control using generalized advantage estimation,” **in** *Proceedings of the 4th International Conference on Learning Representations (ICLR) 2016*. arXiv: 1506.02438.

P. Henderson, R. Islam, P. Bachman, J. Pineau, D. Precup **and** D. Meger, “Deep reinforcement learning that matters,” **in** *Proceedings of the 32nd AAAI Conference on Artificial Intelligence 2018*, **pages** 3207–3214.

R. Agarwal, M. Schwarzer, P. S. Castro, A. Courville **and** M. G. Bellemare, “Deep reinforcement learning at the edge of the statistical precipice,” **in** *Advances in Neural Information Processing Systems 34 (NeurIPS 2021) 2021*, **pages** 29 304–29 320.

A. J. Clark **and** H. Scarf, “Optimal policies for a multi-echelon inventory problem,” *Management Science*, **journal** 6, **number** 4, **pages** 475–490, 1960. DOI: 10.1287/mnsc.6.4.475

H. L. Lee, V. Padmanabhan **and** S. Whang, “Information distortion in a supply chain: The bullwhip effect,” *Management Science*, **jourvol** 43, **number** 4, **pages** 546–558, 1997. DOI: 10.1287/mnsc.43.4.546

M. L. Puterman, *Markov Decision Processes: Discrete Stochastic Dynamic Programming*. New York: John Wiley & Sons, 1994.

G. Brockman **and others**, *OpenAI Gym*, arXiv preprint arXiv:1606.01540, 2016. arXiv: 1606.01540.

J. Schulman, S. Levine, P. Abbeel, M. Jordan **and** P. Moritz, “Trust region policy optimization,” *in Proceedings of the 32nd International Conference on Machine Learning* 2015, **pages** 1889–1897.

A. Y. Ng, D. Harada **and** S. Russell, “Policy invariance under reward transformations: Theory and application to reward shaping,” *in Proceedings of the 16th International Conference on Machine Learning* 1999, **pages** 278–287.

S. Devlin **and** D. Kudenko, “Theoretical considerations of potential-based reward shaping for multi-agent systems,” *in Proceedings of the 10th International Conference on Autonomous Agents and Multiagent Systems (AAMAS 2011)* 2011, **pages** 225–232.

B. De Moor, J. Gijsbrechts **and** R. N. Boute, “Reward shaping to improve the performance of deep reinforcement learning in perishable inventory management,” *European Journal of Operational Research*, **jourvol** 301, **number** 2, **pages** 535–545, 2022. DOI: 10.1016/j.ejor.2021.11.026

C. D. Hubbs, H. D. Perez, O. Sarwar, N. V. Sahinidis, I. E. Grossmann **and** J. M. Wassick, *OR-Gym: A Reinforcement Learning Library for Operations Research Problems*, arXiv preprint arXiv:2008.06319, 2020. arXiv: 2008.06319.

J. Ding **and others**, *Multi-Agent Reinforcement Learning with Shared Resources for Inventory Management*, arXiv preprint arXiv:2212.07684 (NeurIPS 2022 RL4RealLife Workshop), 2022. arXiv: 2212.07684.

Y. Yang **and others**, *A Versatile Multi-Agent Reinforcement Learning Benchmark for Inventory Management*, arXiv preprint arXiv:2306.07542, 2023. arXiv: 2306.07542.

P. Kotecha **and** E. A. del Rio Chanona, “An analysis of multi-agent reinforcement learning for decentralized inventory control systems,” *Computers & Chemical Engineering*, 2024. arXiv: 2307.11432.

X. Liu, Y. Hu, Z. Peng **and** Y. Yang, “Multi-Agent Deep Reinforcement Learning for Multi-Echelon Inventory Management,” *Production and Operations Management*, 2025. DOI: 10.1177/10591478241305863