TỔNG LIÊN ĐOÀN LAO ĐỘNG VIỆT NAM
TRƯỜNG ĐẠI HỌC TÔN ĐỨC THẮNG
KHOA CÔNG NGHỆ THÔNG TIN



LÊ MINH LÝ - 52300220
SỬ THỊ YẾN LINH - 52300218

XÂY DỰNG MÔ HÌNH HỌC TĂNG CƯỜNG TỐI ƯU HÓA CHÍNH SÁCH ĐẶT HÀNG LẠI TRONG QUẢN LÝ TỒN KHO ĐA KHO

KHÓA LUẬN TỐT NGHIỆP

MẠNG MÁY TÍNH VÀ TRUYỀN THÔNG DỮ LIỆU

THÀNH PHỐ HỒ CHÍ MINH, NĂM 2026

TỔNG LIÊN ĐOÀN LAO ĐỘNG VIỆT NAM
TRƯỜNG ĐẠI HỌC TÔN ĐỨC THẮNG
KHOA CÔNG NGHỆ THÔNG TIN



LÊ MINH LÝ - 52300220
SỬ THỊ YẾN LINH - 52300218

XÂY DỰNG MÔ HÌNH HỌC TĂNG CƯỜNG TỐI ƯU HÓA CHÍNH SÁCH ĐẶT HÀNG LẠI TRONG QUẢN LÝ TỒN KHO ĐA KHO

KHÓA LUẬN TỐT NGHIỆP

MẠNG MÁY TÍNH VÀ TRUYỀN THÔNG DỮ LIỆU

Giảng viên hướng dẫn
TS. HỒ THỊ LINH

THÀNH PHỐ HỒ CHÍ MINH, NĂM 2026

LỜI CẢM ƠN

Đầu tiên, chúng em xin gửi lời cảm ơn chân thành và sâu sắc nhất đến TS. Hồ Thị Linh, giảng viên hướng dẫn khóa luận tốt nghiệp. Sự hướng dẫn tận tình, những ý kiến đóng góp quý báu và sự hỗ trợ kịp thời của cô đã định hướng và giúp chúng em hoàn thành tốt khóa luận này.

Bên cạnh đó, chúng em cũng xin cảm ơn khoa Công nghệ Thông tin, trường Đại học Tôn Đức Thắng đã tạo điều kiện học tập và cung cấp những nền tảng kiến thức vững chắc, tạo môi trường thuận lợi để chúng em có thể áp dụng vào thực tiễn. Do thời gian và trình độ còn những hạn chế nhất định, báo cáo chắc chắn không tránh khỏi những thiếu sót. Chúng em rất mong nhận được sự cảm thông và những lời góp ý chân thành từ quý thầy cô để đề tài được hoàn thiện hơn và chúng em rút ra được những bài học quý giá.

Chúng em xin chân thành cảm ơn!

TP. Hồ Chí Minh, ngày 09 tháng 05 năm 2026

Tác giả	**Tác giả**
(Ký và ghi rõ họ tên)	*(Ký và ghi rõ họ tên)*
Lê Minh Lý	**Sử Thị Yến Linh**

CÔNG TRÌNH ĐƯỢC HOÀN THÀNH TẠI TRƯỜNG ĐẠI HỌC TÔN ĐỨC THẮNG

Chúng tôi xin cam đoan đây là công trình nghiên cứu của chúng tôi và được sự hướng dẫn khoa học của TS. Hồ Thị Linh. Các nội dung nghiên cứu, kết quả trong đề tài này là trung thực và chưa công bố dưới bất kỳ hình thức nào trước đây. Những số liệu trong các bảng biểu phục vụ cho việc phân tích, nhận xét, đánh giá được chính tác giả thu thập từ các nguồn khác nhau có ghi rõ trong phần tài liệu tham khảo.

Ngoài ra, trong Khóa luận tốt nghiệp còn sử dụng một số nhận xét, đánh giá cũng như số liệu của các tác giả khác, cơ quan tổ chức khác đều có trích dẫn và chú thích nguồn gốc.

Nếu phát hiện có bất kỳ sự gian lận nào chúng tôi xin hoàn toàn chịu trách nhiệm về nội dung Khóa luận tốt nghiệp của mình. Trường Đại học Tôn Đức Thắng không liên quan đến những vi phạm tác quyền, bản quyền do chúng tôi gây ra trong quá trình thực hiện (nếu có).

TP. Hồ Chí Minh, ngày 09 tháng 05 năm 2026

Tác giả	**Tác giả**
(Ký và ghi rõ họ tên)	*(Ký và ghi rõ họ tên)*
Lê Minh Lý	**Sử Thị Yến Linh**

PHẦN XÁC NHẬN VÀ ĐÁNH GIÁ CỦA GIẢNG VIÊN

Phần xác nhận của GV hướng dẫn

Tp. Hồ Chí Minh, ngày ……tháng ……năm ……
(Ký và ghi họ tên)

Phần đánh giá của GV chấm bài

Tp. Hồ Chí Minh, ngày ……tháng ……năm ……
(Ký và ghi họ tên)

XÂY DỰNG MÔ HÌNH HỌC TĂNG CƯỜNG TỐI ƯU HÓA CHÍNH SÁCH ĐẶT HÀNG LẠI TRONG QUẢN LÝ TỒN KHO ĐA KHO

TÓM TẮT

Quản lý tồn kho trong mạng lưới bán lẻ nhiều kho, nhiều mặt hàng là bài toán ra quyết định tuần tự dưới bất định: phải cân bằng chi phí lưu kho, thiếu hàng, đặt hàng và tràn kho trong khi vẫn giữ mức phục vụ khách hàng. Các chính sách cổ điển như EOQ, (s, S) và Newsvendor dựa trên giả định nhu cầu dừng, thời gian giao hàng cố định và không ràng buộc sức chứa, nên khó giữ tính tối ưu khi các giả định này bị vi phạm.

Khóa luận mô hình hóa 10 kho $\times$ 30 mặt hàng thành 300 tác tử, mỗi tác tử quyết định lượng đặt hàng cho một cặp kho–mặt hàng từ quan sát cục bộ, và các tác tử trong cùng kho chia sẻ một sức chứa hữu hạn. Các tác tử được huấn luyện bằng IPPO với chia sẻ tham số (PS-IPPO), dùng phần thưởng phân rã cục bộ theo từng cặp, chuẩn hóa theo quy mô chi phí của từng cặp, và mục tiêu mức phục vụ 85% triển khai dưới dạng ràng buộc mềm.

Môi trường mô phỏng dùng nhu cầu thực tế của bộ dữ liệu M5 Walmart (1.941 ngày), chia thành ba miền huấn luyện, validation và kiểm tra, với thời gian giao hàng ngẫu nhiên từ một đến ba ngày. PS-IPPO được so sánh với ba chính sách cổ điển đã tinh chỉnh trên miền validation, qua nhiều hạt giống huấn luyện và kiểm định thống kê theo cặp.

Kết quả (mô hình chính 10.000 episode $\times$ 3 hạt giống) cho thấy ở điểm vận hành mà mỗi phương pháp tự chọn, PS-IPPO có tổng chi phí xấp xỉ các chính sách cổ điển tốt nhất — thấp hơn (s, S) $1{,}7\%$ và EOQ $17{,}8\%$, ngang các phiên bản tinh chỉnh theo nhóm quy mô cầu — nhưng với mức phục vụ cao hơn khoảng 4–5 điểm phần trăm ($90{,}9\%$ so với $85{,}8$–$86{,}2\%$). Khi các chính sách cổ điển được buộc đạt mức phục vụ tương đương ($\approx 90\%$), chúng đắt hơn PS-IPPO $17{,}3$–$25{,}7\%$ (cận trên do lưới tham số thô), còn EOQ không đạt được mức đó. Khi nhu cầu ổn định, chính sách cổ điển tinh chỉnh theo nhóm ngang hoặc rẻ hơn; ưu thế của PS-IPPO tập trung ở giai đoạn nhu cầu biến động (ngày có sự kiện, cuối tuần, sốc cầu). Chia sẻ tham số duy trì hiệu năng tốt ở nhóm mặt hàng có nhu cầu trung bình và cao, nhưng mức phục vụ ở nhóm nhu cầu thấp chưa đạt ngưỡng ($28{,}7\%$ số cặp dưới 85%). Đóng góp của khóa luận là

một khung PS-IPPO có ràng buộc sức chứa dùng chung trên dữ liệu bán lẻ thực tế, một giao thức đánh giá tách biệt rõ chi phí vận hành, mức phục vụ và tín hiệu huấn luyện, và một ứng dụng mô phỏng đề xuất đơn đặt hàng từ mô hình đã huấn luyện.

Từ khóa: quản lý tồn kho; học tăng cường đa tác tử; IPPO; chia sẻ tham số; M5.

BUILDING A REINFORCEMENT LEARNING MODEL FOR OPTIMIZING REORDER POLICY IN MULTI-WAREHOUSE INVENTORY MANAGEMENT

ABSTRACT

Inventory control in a retail network with many warehouses and many products is a sequential decision problem under uncertainty: holding, stockout, ordering and overflow costs must be balanced while a customer service level is maintained. Classical policies such as EOQ, (s, S) and the Newsvendor model assume stationary demand, fixed lead times and unconstrained storage, and lose their optimality when these assumptions are violated.

This thesis models 10 warehouses $\times$ 30 products as 300 agents, each choosing the replenishment quantity of one warehouse–product pair from local observations, with the products of a warehouse sharing a finite capacity. The agents are trained with Independent PPO under parameter sharing (PS-IPPO), using a local factored reward per pair, per-pair reward normalization, and an 85% service-level target implemented as a soft constraint.

The simulation uses the real demand of the M5 Walmart dataset ($1{,}941$ days), split into training, validation and test periods, with stochastic lead times of one to three days. PS-IPPO is compared with three classical policies tuned on the validation period, over several training seeds and with paired statistical tests.

With the main model ($10{,}000$ episodes $\times$ 3 seeds), at the operating point each method selects for itself, PS-IPPO has a total cost close to the best classical policies — 1.7% below (s, S) and 17.8% below EOQ, and on par with the versions tuned per demand-scale group — while reaching a service level about 4–5 percentage points higher (90.9% versus 85.8–86.2%). When the classical policies are forced to a comparable service level ($\approx 90\%$) they cost 17.3–25.7% more than PS-IPPO (an upper bound, because the parameter grid is coarse), and EOQ cannot reach it. Under stable demand, group-tuned classical policies match or beat PS-IPPO; its advantage is concentrated in volatile demand periods (event days, weekends, demand shocks). Parameter sharing maintains performance for medium- and high-demand products, but the service level of low-demand products falls short of the target (28.7% of pairs below 85%). The contributions are a PS-IPPO framework with shared warehouse capacity on real

retail data, an evaluation protocol that separates operating cost, service level and the training signal, and a simulation application that proposes purchase orders from the trained model.

Keywords: inventory management; multi-agent reinforcement learning; IPPO; parameter sharing; M5.

MỤC LỤC

DANH MỤC HÌNH VẼ ..... **xii**

DANH MỤC BẢNG BIỂU ..... **xiii**

DANH MỤC CÁC CHỮ VIẾT TẮT ..... **xv**

CHƯƠNG 1. TỔNG QUAN VỀ ĐỀ TÀI **1**

1.1 Bối cảnh nghiên cứu và tính cấp thiết của đề tài 1

1.1.1 Thực trạng quản lý tồn kho trong mạng lưới bán lẻ đa điểm *1*

1.1.2 Thách thức trong việc tối ưu hóa chính sách đặt hàng lại *2*

1.1.3 Hạn chế của phương pháp truyền thống và sự cần thiết của học tăng cường đa tác tử *3*

1.2 Mục tiêu và câu hỏi nghiên cứu 5

1.2.1 Mục tiêu nghiên cứu *5*

1.2.2 Câu hỏi nghiên cứu *6*

1.3 Đối tượng và phạm vi nghiên cứu 6

1.3.1 Đối tượng nghiên cứu *6*

1.3.2 Phạm vi trong đề tài *6*

1.3.3 Giới hạn phạm vi *7*

1.4 Phương pháp nghiên cứu 8

1.5 Ý nghĩa khoa học và thực tiễn của đề tài 8

1.6 Bố cục của khóa luận 8

CHƯƠNG 2. CƠ SỞ LÝ THUYẾT VÀ CÁC CÔNG TRÌNH LIÊN QUAN **10**

2.1 Lý thuyết kiểm soát tồn kho ngẫu nhiên 10

2.1.1 Mô hình tồn kho và các thành phần chi phí *10*

2.1.2 Các chính sách đặt hàng lại cổ điển *11*

2.1.3 Các thước đo mức phục vụ trong quản lý tồn kho *11*

2.2 Nền tảng học tăng cường 12

2.2.1 Quá trình quyết định Markov (MDP) *12*

2.2.2 Hàm giá trị và phương trình Bellman..... 13
2.2.3 Ước lượng lợi thế tổng quát (GAE)..... 13
2.2.4 Thuật toán PPO (Proximal Policy Optimization)..... 13
2.3 Học tăng cường đa tác tử..... 14
2.3.1 Mô hình Dec-POMDP 14
2.3.2 Học độc lập (Independent Learning)..... 15
2.3.3 IPPO — Independent Multi-Agent PPO 15
2.3.4 Chia sẻ tham số (Parameter Sharing) 16
2.3.5 Phần thưởng phân rã cục bộ và bài toán gán tín dụng..... 16
2.4 Các công trình nghiên cứu liên quan..... 17
2.4.1 Học tăng cường trong quản lý tồn kho 17
2.4.2 Hai công trình gần nhất cùng bối cảnh 18
2.4.3 Khoảng trống nghiên cứu và định vị đóng góp..... 19
CHƯƠNG 3. PHÂN TÍCH VÀ THIẾT KẾ MÔ HÌNH 21
3.1 Mô hình hóa bài toán tồn kho đa kho 21
3.1.1 Quy trình nghiệp vụ và mô hình khái niệm 21
3.1.2 Mô tả mạng lưới..... 23
3.1.3 Thiết lập bài toán dưới dạng MDP đa tác tử..... 24
3.1.4 Ràng buộc sức chứa kho và cơ chế từ chối nhập hàng..... 30
3.1.5 Cơ chế phối hợp giữa các tác tử 31
3.2 Thiết kế hàm phần thưởng 33
3.2.1 Phần thưởng phân rã cục bộ 33
3.2.2 Vai trò của thành phần phạt fill rate 35
3.2.3 Các tham số chi phí..... 36
3.2.4 Chuẩn hóa phần thưởng theo từng cặp..... 36
3.3 Kiến trúc mạng Actor–Critic chia sẻ tham số..... 37
3.3.1 Mạng SharedActorCritic 37
3.3.2 Quy trình huấn luyện IPPO..... 38

3.4 Thiết kế môi trường mô phỏng 38
CHƯƠNG 4. THỰC NGHIỆM VÀ ĐÁNH GIÁ KẾT QUẢ 40
4.1 Cấu hình thực nghiệm 40
4.1.1 Môi trường phần cứng và phần mềm 40
4.1.2 Nguồn dữ liệu và tiền xử lý 40
4.1.3 Thiết lập kịch bản mô phỏng 42
4.2 Phương pháp đối chứng 42
4.3 Giao thức đánh giá 44
4.3.1 Quy trình đánh giá 44
4.3.2 Các chỉ số đánh giá 45
4.4 Kết quả thực nghiệm 45
4.4.1 Quá trình huấn luyện và tính hội tụ 45
4.4.2 So sánh trực tiếp với các chính sách cổ điển 46
4.4.3 Phân tích cơ cấu chi phí 48
4.4.4 So sánh ở cùng mức phục vụ 49
4.5 Phân tích chuyên sâu 51
4.5.1 Hiệu năng theo nhóm quy mô nhu cầu (Câu hỏi 2) 51
4.5.2 Thiết kế tín hiệu phần thưởng (Câu hỏi 3) 53
4.5.3 Vai trò của việc tách Actor và Critic 54
4.5.4 Các thí nghiệm loại trừ khác 54
4.5.5 Thực nghiệm B: hiệu năng theo giai đoạn nhu cầu 55
4.5.6 Kiểm tra trạng thái và phần thưởng bằng thực nghiệm 60
4.5.7 Độ nhạy của kết luận theo đơn giá chi phí 62
4.5.8 Độ bền khi điều kiện vận hành thay đổi 63
4.6 Hạn chế của thực nghiệm 63
4.7 Thảo luận 64
CHƯƠNG 5. KẾT LUẬN VÀ HƯỚNG PHÁT TRIỂN 66
5.1 Tổng kết các kết quả đạt được 66

5.1.1 Trả lời các câu hỏi nghiên cứu 67

5.2 Những hạn chế còn tồn tại 69

5.3 Hướng phát triển trong tương lai 70

5.3.1 Đợt thực nghiệm cuối đã hoàn tất và các thí nghiệm còn lại 70

5.3.2 Các hướng mở rộng khác 72

PHỤ LỤC A. ĐỐI CHIẾU LUẬN ĐIỂM VÀ NGUỒN TRÍCH DẪN 74

PHỤ LỤC B. PROTOTYPE ĐIỀU PHỐI BẰNG MCP 77

TÀI LIỆU THAM KHẢO..... 79

DANH MỤC HÌNH VẼ

Hình 3.1: Mô hình khái niệm của bài toán bổ sung hàng đa kho 22
Hình 3.2: Ba miền dữ liệu trên trục thời gian của M5 23
Hình 3.3: Kiến trúc đa tác tử: 300 tác tử (kho w, mặt hàng j) dùng chung một chính sách, tương tác gián tiếp qua sức chứa kho 24
Hình 3.4: Vòng tương tác học tăng cường của một tác tử trong môi trường kho. Cả 300 tác tử chạy vòng này đồng thời mỗi ngày với cùng θ, ϕ..... 25

Hình 4.1: Diễn biến huấn luyện qua 10.000 episode (hạt giống 42): (a) phần thưởng tích lũy; (b) tỷ lệ đáp ứng nhu cầu; (c) entropy của chính sách; (d) explained variance của Critic 46
Hình 4.2: So sánh các phương pháp trên miền test (hạt giống huấn luyện 42): (a) tổng chi phí vận hành; (b) tỷ lệ đáp ứng nhu cầu; (c) cơ cấu chi phí thành phần 48
Hình 4.3: Đường đánh đổi chi phí — mức phục vụ (hạt giống 42). Dấu chữ thập xám: cấu hình tối thiểu chi phí của các baseline; dấu tròn xanh dương: baseline chỉnh cùng mức phục vụ; chấm xanh lá: IPPO 50
Hình 4.4: Thực nghiệm B1: (a) fill rate của các chính sách theo giai đoạn nhu cầu; (b) chênh lệch chi phí mỗi ngày của IPPO so với hai baseline ở cùng mức phục vụ 57
Hình 4.5: Thực nghiệm B2: fill rate theo ngày (trung bình trượt 7 ngày) quanh cú sốc cầu; vùng tô đỏ là 28 ngày bị sốc 59
Hình 4.6: (a) Xác suất đặt hàng theo số ngày tồn kho; (b) phân bố fill rate của 300 cặp; (c) mức tăng chi phí khi xáo trộn từng nhóm đặc trưng trạng thái 60

DANH MỤC BẢNG BIỂU

Bảng 1.1: Phân loại dạng nhu cầu của 30.490 chuỗi cửa hàng–mặt hàng trong bộ dữ liệu M5 theo tiêu chí của Syntetos và cộng sự [4] 2
Bảng 1.2: Bốn thành phần chi phí vận hành và mục tiêu mức phục vụ trong bài toán tồn kho đang xét 3

Bảng 2.1: Đối chiếu khóa luận với hai công trình gần nhất cùng bối cảnh 19
Bảng 2.2: So sánh tổng quan các công trình nghiên cứu liên quan 19

Bảng 3.1: Ngày lịch và độ dài của ba miền dữ liệu 23
Bảng 3.2: Các thành phần của mô hình học tăng cường trong bài toán tồn kho đa kho 25
Bảng 3.3: Đối chiếu biến trạng thái, nhóm tín hiệu và cách mã hóa trong vector quan sát 28
Bảng 3.4: Nhu cầu và sức chứa của từng kho trong cấu hình thực nghiệm 30
Bảng 3.5: Đặc tả tác tử trong hệ thống đề xuất 33
Bảng 3.6: Tham số chi phí trong môi trường mô phỏng 36
Bảng 3.7: Siêu tham số huấn luyện 39

Bảng 4.1: Đặc trưng nhu cầu của tập thực nghiệm so với bộ dữ liệu gốc 41
Bảng 4.2: Ba miền dữ liệu và vai trò của từng miền 41
Bảng 4.3: Cấu hình môi trường mô phỏng 42
Bảng 4.4: Tham số tối ưu của các chính sách đối chứng (một bộ tham số chung cho 300 cặp), tìm kiếm lưới trên miền validation 43
Bảng 4.5: Kết quả trên miền test (trung bình; $\pm$ là độ lệch chuẩn giữa các hạt giống huấn luyện đối với IPPO, và giữa 30 lần đánh giá đối với baseline). Chi phí tính bằng đơn vị tiền của mô hình. 47
Bảng 4.6: So sánh ở cùng mức phục vụ: cấu hình rẻ nhất của mỗi chính sách đối chứng đạt fill rate $\geq 90{,}15\%$ (hạt giống 42). Cột cuối: chênh lệch chi phí của IPPO so với baseline (âm là IPPO rẻ hơn). 49
Bảng 4.7: Hiệu năng theo nhóm quy mô nhu cầu trên miền test (hạt giống 42). Chi phí cục bộ (gồm thành phần định hướng mức phục vụ) tính trung bình cho mỗi cặp trong một episode. 51

Bảng 4.8: Thiết kế phần thưởng (1.000 episode mỗi lần chạy): tổng chi phí trên miền test, fill rate và chênh lệch so với lần tham chiếu cùng hạt giống. Dấu *: kiểm định theo cặp có ý nghĩa ($p < 0{,}05$). 53
Bảng 4.9: Thí nghiệm loại trừ (1.000 episode, hạt giống 42). Δ là chênh lệch tổng chi phí so với `abl_ref`; $\Delta(s, S)$ là chênh lệch so với (s, S) trong cùng môi trường. Dấu *: có ý nghĩa thống kê; †: môi trường đánh giá khác tham chiếu nên đọc cột $\Delta(s, S)$. 55
Bảng 4.10: Thực nghiệm B1: fill rate và chi phí vận hành trung bình mỗi ngày theo giai đoạn nhu cầu (30 episode, miền test). Cột cuối là chênh lệch chi phí của IPPO so với (s, S) cùng mức phục vụ (âm là IPPO rẻ hơn). 56
Bảng 4.11: Chênh lệch chi phí mỗi ngày của IPPO và khoảng tin cậy 95% (bootstrap theo khối 7 ngày). Dấu *: khoảng tin cậy không chứa 0. 57
Bảng 4.12: Thực nghiệm B2: fill rate (và chi phí mỗi ngày) trước, trong và sau sốc cầu 28 ngày..... 58
Bảng 4.13: Tầm quan trọng của các nhóm đặc trưng trạng thái (xáo trộn nhóm đặc trưng giữa các cặp ở mỗi bước; riêng nhóm lịch được thay bằng lịch của một ngày ngẫu nhiên) 61
Bảng 4.14: Chênh lệch tổng chi phí của IPPO theo đơn giá ($c_{dh} = 5$). Mỗi ô: so với (s, S) trực tiếp / so với (s, S) cùng mức phục vụ; âm là IPPO rẻ hơn. 62
Bảng 4.15: Độ bền zero-shot: chi phí và fill rate của IPPO, và chênh lệch chi phí của IPPO so với từng baseline (âm là IPPO rẻ hơn). Dấu *: có ý nghĩa thống kê; $^\sim$: kịch bản tất định, không kiểm định được. 63

Bảng 5.1: Đợt thực nghiệm cuối: các lần chạy, và nơi báo cáo kết quả 71
Bảng 5.3: So sánh kiến trúc IPPO và MCP theo các chiều điều phối..... 77
Bảng 5.4: Công cụ của prototype MCP..... 78

DANH MỤC CÁC CHỮ VIẾT TẮT

Dec-POMDP	Decentralized Partially Observable Markov Decision Process (Quá trình quyết định Markov có quan sát bộ phận phi tập trung)
EOQ	Economic Order Quantity (Lượng đặt hàng kinh tế)
GAE	Generalized Advantage Estimation (Ước lượng lợi thế tổng quát)
IPPO	Independent Proximal Policy Optimization (Tối ưu hóa chính sách cận đại độc lập)
MARL	Multi-Agent Reinforcement Learning (Học tăng cường đa tác tử)
MDP	Markov Decision Process (Quá trình quyết định Markov)
MLP	Multilayer Perceptron (Mạng nơ-ron truyền thẳng đa tầng)
PPO	Proximal Policy Optimization (Tối ưu hóa chính sách cận đại)
RL	Reinforcement Learning (Học tăng cường)
SCM	Supply Chain Management (Quản trị chuỗi cung ứng)
SKU	Stock Keeping Unit (Đơn vị quản lý tồn kho)
SNAP	Supplemental Nutrition Assistance Program (Chương trình trợ cấp dinh dưỡng)

CHƯƠNG 1. TỔNG QUAN VỀ ĐỀ TÀI

1.1 Bối cảnh nghiên cứu và tính cấp thiết của đề tài

1.1.1 Thực trạng quản lý tồn kho trong mạng lưới bán lẻ đa điểm

Trong hoạt động bán lẻ hiện đại, hàng hóa không được lưu trữ tập trung tại một điểm duy nhất mà được phân tán trên một mạng lưới gồm nhiều kho hoặc nhiều cửa hàng đặt tại các khu vực địa lý khác nhau. Mỗi điểm lưu trữ phục vụ một tập khách hàng riêng, đối mặt với một chuỗi nhu cầu riêng và phải tự ra quyết định bổ sung hàng hóa cho hàng trăm đến hàng nghìn mặt hàng khác nhau [1]. Bài toán vì vậy không còn là việc xác định một mức đặt hàng đơn lẻ, mà là việc điều phối đồng thời một số lượng rất lớn các quyết định có ràng buộc lẫn nhau.

Đặc điểm này thể hiện rõ trong dữ liệu bán lẻ thực tế. Bộ dữ liệu M5, công bố trong cuộc thi dự báo M5 do Makridakis và cộng sự [2] tổ chức, ghi nhận doanh số bán hàng theo ngày của 3.049 mặt hàng tại 10 cửa hàng của Walmart thuộc ba bang California, Texas và Wisconsin, trải trên 1.941 ngày từ ngày 29 tháng 01 năm 2011 đến ngày 22 tháng 05 năm 2016[1]. Tổ hợp cửa hàng và mặt hàng tạo thành 30.490 chuỗi thời gian nhu cầu ở cấp độ chi tiết nhất.

Thống kê trên toàn bộ 30.490 chuỗi này cho thấy hai đặc trưng có ảnh hưởng trực tiếp tới thiết kế chính sách đặt hàng. Thứ nhất, nhu cầu ở cấp cửa hàng–mặt hàng có quy mô rất nhỏ và phân bố lệch mạnh: nhu cầu trung bình là $1{,}13$ đơn vị mỗi ngày, nhưng trung vị chỉ là $0{,}45$ đơn vị, và $73{,}4\%$ số chuỗi có nhu cầu trung bình dưới một đơn vị mỗi ngày. Thứ hai, nhu cầu mang tính gián đoạn rõ rệt, với tỷ lệ ngày không phát sinh giao dịch trung bình đạt 68%. Áp dụng tiêu chí phân loại của Syntetos và cộng sự [4] với các ngưỡng khoảng cách giữa hai lần phát sinh nhu cầu $p = 1{,}32$ và bình phương hệ số biến thiên $CV^2 = 0{,}49$ (trong đó Kostenko và Hyndman [5] đã chứng minh kết quả biên chính xác với giá trị giới hạn $p = 4/3 \approx 1{,}333$ và đề xuất quy tắc phân loại chỉnh sửa), có tới $95{,}2\%$ số chuỗi thuộc hai nhóm *intermittent* và *lumpy* (Bảng 1.1).

Cần nói rõ rằng các thống kê trên được tính trên toàn bộ 30.490 chuỗi của bộ dữ liệu gốc. Tập thực nghiệm của khóa luận là một tập con đã qua sàng lọc: các mặt hàng

[1] Các thống kê được tính từ hai tệp `calendar.csv` và `sales_train_evaluation.csv` trong bộ dữ liệu M5 [3].

Bảng 1.1: Phân loại dạng nhu cầu của 30.490 chuỗi cửa hàng–mặt hàng trong bộ dữ liệu M5 theo tiêu chí của Syntetos và cộng sự [4]

Nhóm	**Đặc điểm**	**Tỷ lệ**
Smooth	$p < 1{,}32$; $CV^2 < 0{,}49$	$3{,}2\%$
Erratic	$p < 1{,}32$; $CV^2 \geq 0{,}49$	$1{,}6\%$
Intermittent	$p \geq 1{,}32$; $CV^2 < 0{,}49$	$75{,}7\%$
Lumpy	$p \geq 1{,}32$; $CV^2 \geq 0{,}49$	$19{,}5\%$

mà cửa hàng trên thực tế không kinh doanh (nhu cầu trung bình dưới $0{,}2$ đơn vị mỗi ngày ở phần lớn cửa hàng) bị loại bỏ, vì chúng không tạo thành bài toán đặt hàng lại mà chỉ thêm nhiễu vào tín hiệu học. Sau sàng lọc, tập 300 cặp dùng trong thực nghiệm vẫn giữ tỷ lệ ngày không phát sinh giao dịch ở mức $57{,}4\%$ — nghĩa là tính gián đoạn được bảo toàn — với nhu cầu trung bình $3{,}24$ và trung vị $0{,}74$ đơn vị mỗi ngày. Chi tiết quy trình sàng lọc được trình bày ở Mục 4.1.2.

Đặc điểm gián đoạn này khiến các phương pháp dự báo và các công thức tồn kho xây dựng trên giả định nhu cầu liên tục và phân phối chuẩn trở nên kém phù hợp [6], [7]. Quản lý tồn kho trên một mạng lưới như vậy đòi hỏi những công cụ ra quyết định có khả năng thích ứng, thay vì các bộ tham số tĩnh được thiết lập một lần và áp dụng cố định.

1.1.2 Thách thức trong việc tối ưu hóa chính sách đặt hàng lại

Việc xây dựng chính sách đặt hàng lại trong mạng lưới đa kho – đa mặt hàng đối mặt với bốn nhóm thách thức chính.

Thứ nhất, tính bất định kép của nhu cầu và thời gian giao hàng. Nhu cầu tiêu thụ biến động ngẫu nhiên theo thời gian, đồng thời thời gian từ lúc phát lệnh đặt hàng đến lúc hàng thực nhập kho cũng không cố định [8]. Khi thời gian giao hàng là biến ngẫu nhiên, các đơn hàng phát ra ở những thời điểm khác nhau có thể về kho không đúng thứ tự, khiến các công thức tính tồn kho an toàn cổ điển chỉ còn giữ vai trò xấp xỉ [1].

Thứ hai, bài toán đánh đổi giữa nhiều nhóm chi phí xung đột. Mục tiêu vận hành không quy về một đại lượng duy nhất mà là tổng hợp của nhiều thành phần có chiều tác động ngược nhau, được tóm tắt trong Bảng 1.2. Giảm tồn kho làm giảm chi phí lưu kho nhưng làm tăng rủi ro thiếu hàng; đặt hàng theo lô lớn làm giảm chi phí đặt hàng cố định nhưng làm tăng chi phí lưu kho và nguy cơ vượt sức chứa [8].

Thứ ba, ràng buộc sức chứa tạo ra sự phụ thuộc giữa các mặt hàng. Các mặt

Bảng 1.2: Bốn thành phần chi phí vận hành và mục tiêu mức phục vụ trong bài toán tồn kho đang xét

Thành phần	**Ký hiệu**	**Chiều tác động**
Chi phí lưu kho	c_{lk}	Tăng khi mức tồn kho cao
Chi phí thiếu hàng	c_{th}	Tăng khi xảy ra hết hàng
Chi phí đặt hàng cố định	c_{dh}	Tăng theo tần suất đặt hàng
Phạt tràn kho	p_{tk}	Tăng khi hàng về vượt sức chứa kho
Mục tiêu mức phục vụ	$\tau = 85\%$	Ràng buộc nghiệp vụ, không phải chi phí; khi huấn luyện được đưa vào dưới dạng hình phạt với hệ số ϕ_{dv}

hàng cùng nằm trong một kho chia sẻ một dung lượng hữu hạn. Quyết định đặt hàng của một mặt hàng do đó ảnh hưởng trực tiếp tới chi phí mà các mặt hàng khác trong cùng kho phải gánh chịu. Bài toán vì vậy không thể tách rời thành các bài toán độc lập, mà mang bản chất của một bài toán ra quyết định hợp tác [9].

Thứ tư, quy mô không gian hành động. Với N kho và M mặt hàng, mỗi cặp có K mức đặt hàng khả dĩ, không gian hành động chung là tích Descartes có kích thước K^{NM}. Với cấu hình của khóa luận ($N = 10$, $M = 30$, $K = 6$), con số này là 6^{300} — vượt xa khả năng xử lý của bất kỳ phương pháp tìm kiếm tập trung nào, và cũng vượt quá khả năng biểu diễn của các thuật toán học tăng cường dựa trên hàm giá trị vốn phải liệt kê toàn bộ hành động khả dĩ [10]. Trên phương diện lý thuyết độ phức tạp, bài toán điều khiển phi tập trung dạng này đã được chứng minh thuộc lớp NEXP-đầy đủ [11], nên các lời giải chính xác không khả thi ở quy mô thực tế.

1.1.3 Hạn chế của phương pháp truyền thống và sự cần thiết của học tăng cường đa tác tử

Các chính sách tồn kho cổ điển đều được xây dựng trên những tập giả định cụ thể. Mô hình lượng đặt hàng kinh tế của Harris [12] giả định nhu cầu xác định và đều, không có tình trạng thiếu hàng. Chính sách (s, S) được Scarf [13] chứng minh tối ưu cho hệ đơn kho với nhu cầu độc lập giữa các kỳ, chi phí đặt hàng cố định và cơ chế giữ đơn hàng chờ. Mô hình người bán báo của Arrow và cộng sự [14] chỉ tối ưu cho một chu kỳ đơn lẻ, không xét tới lượng hàng đang trên đường vận chuyển. Không mô hình nào trong số đó xử lý được đồng thời nhu cầu ngẫu nhiên, thời gian giao hàng

biến động, ràng buộc sức chứa dùng chung và yêu cầu duy trì mức phục vụ tối thiểu. Riêng với cơ chế mất đơn hàng khi thiếu hàng — vốn phù hợp với bối cảnh bán lẻ — Zipkin [15] chỉ ra rằng bài toán không còn nghiệm giải tích dạng đóng và các chính sách cổ điển mất tính tối ưu đã được chứng minh.

Học tăng cường cung cấp một hướng tiếp cận khác: thay vì giả định trước dạng phân phối của nhu cầu và suy ra chính sách bằng giải tích, tác tử học chính sách trực tiếp thông qua tương tác lặp lại với môi trường [10]. Hướng này đã được kiểm chứng trên các bài toán tồn kho quy mô nhỏ: Oroojlooyjadid và cộng sự [16] áp dụng mạng Q sâu cho trò chơi phân phối bia, còn Gijsbrechts và cộng sự [17] đánh giá học tăng cường sâu trên ba lớp bài toán tồn kho gồm mất đơn hàng, hai nguồn cung và đa cấp.

Tuy nhiên, việc áp dụng học tăng cường đơn tác tử cho toàn bộ mạng lưới vấp phải chính vấn đề quy mô đã nêu ở mục trên. Học tăng cường đa tác tử với cơ chế chia sẻ tham số cho phép vượt qua trở ngại này [18]: mỗi cặp kho–mặt hàng được xem là một tác tử ra quyết định độc lập trên quan sát cục bộ theo hướng tiếp cận học độc lập của Tan [19], trong khi toàn bộ các tác tử cùng học chung một bộ trọng số. Nhờ đó, không gian hành động mà mỗi tác tử phải xử lý thu về kích thước K, còn số tham số cần học không tăng theo quy mô hệ thống. Các nghiên cứu gần đây cho thấy phương pháp học độc lập dựa trên PPO đạt hiệu năng cạnh tranh trên nhiều môi trường hợp tác [20], [21].

Khảo sát tài liệu cho thấy phần lớn các nghiên cứu áp dụng học tăng cường cho quản lý tồn kho hiện nay được tiến hành ở quy mô nhỏ, với một vài kho và một vài mặt hàng, trên dữ liệu nhu cầu sinh theo phân phối lý thuyết. Ngay cả những công trình gần đây nhất cùng bối cảnh cũng để lại những khoảng trống rõ rệt. Zhu và Wu [22] cũng sử dụng bộ dữ liệu M5 và học tăng cường đa tác tử, nhưng giả định nguồn cung không giới hạn và không đưa sức chứa kho vào hàm mục tiêu, nên sự ràng buộc giữa các mặt hàng trong cùng một kho không được mô hình hóa. Ở chiều ngược lại, khung làm việc của Nam và cộng sự [23] có xét ràng buộc sức chứa nhưng chỉ trên một kho duy nhất và trên dữ liệu tổng hợp, đồng thời hàm phần thưởng không quy về đơn vị tiền tệ nên khó diễn giải về mặt kinh tế.

Khoảng trống mà khóa luận hướng tới nằm ở giao của ba yếu tố: mở rộng tới quy mô hàng trăm cặp kho–mặt hàng bằng cơ chế chia sẻ tham số; mô hình hóa ràng buộc sức chứa hữu hạn dùng chung giữa các mặt hàng, tính riêng cho từng kho theo quy mô nhu cầu không đồng nhất của kho đó; và đánh giá so sánh với các chính sách cổ điển ở cùng một mức phục vụ, trên môi trường mô phỏng hiệu chỉnh từ dữ liệu bán

lẻ thực tế.

1.2 Mục tiêu và câu hỏi nghiên cứu

1.2.1 Mục tiêu nghiên cứu

Phát biểu bài toán. Các chính sách đặt hàng lại truyền thống như EOQ, (s, S) hay Newsvendor đặt tham số một lần từ nhu cầu trung bình và độ biến động đã ước lượng, nên kém nhạy khi nhu cầu thay đổi do giá, ngày lễ, sự kiện hoặc một đợt tăng cầu bất thường. Khóa luận vì vậy xây dựng một *mô hình học tăng cường* để các tác tử tự quyết định đặt hàng lại từ quan sát hằng ngày, với mục tiêu giảm tổng chi phí vận hành mà vẫn giữ mức phục vụ tối thiểu. Mô hình được kiểm tra ở cả giai đoạn nhu cầu ổn định lẫn khi có sốc cầu, vì chỉ khi nhu cầu biến động thì lợi thế của một chính sách thích nghi so với chính sách tĩnh mới có thể xuất hiện (Chương 4).

Khóa luận đặt ra năm mục tiêu cụ thể:

- Xây dựng môi trường mô phỏng tồn kho đa kho – đa mặt hàng theo chuẩn Gymnasium [24], mô hình hóa đầy đủ nhu cầu ngẫu nhiên, thời gian giao hàng biến động, ràng buộc sức chứa, bốn thành phần chi phí vận hành (lưu kho, thiếu hàng, đặt hàng, tràn kho) và mục tiêu mức phục vụ; nhu cầu lấy từ bộ dữ liệu M5 Walmart.
- Thiết kế tín hiệu phần thưởng phân rã cục bộ (local factored reward) cho từng cặp kho–mặt hàng, kèm thành phần phạt mức phục vụ tính trên cửa sổ trượt, nhằm giảm khó khăn của bài toán gán tín dụng giữa các tác tử [25].
- Cài đặt và huấn luyện thuật toán Independent Multi-Agent PPO [20], [26] với cơ chế chia sẻ tham số cho 300 cặp kho–mặt hàng, sử dụng ước lượng lợi thế tổng quát [27] và chuẩn hóa lợi thế theo từng cặp.
- Đánh giá hiệu năng của mô hình đề xuất trong so sánh với ba chính sách tồn kho cổ điển, theo giao thức thực nghiệm đa hạt giống có kiểm định thống kê [28], [29].
- Xây dựng ứng dụng *mô phỏng* nạp mô hình đã huấn luyện và chạy suy luận trên dữ liệu kiểm tra để xem kết quả, các phiếu đề nghị đặt hàng và kịch bản tăng cầu. Đây là ứng dụng mô phỏng minh họa kết quả mô hình, không phải một hệ thống vận hành thực tế.

1.2.2 Câu hỏi nghiên cứu

Khóa luận hướng tới trả lời ba câu hỏi:

1. Câu hỏi 1: Trong cùng điều kiện mức phục vụ — tức khi mọi chính sách đều phải đạt tỷ lệ đáp ứng nhu cầu tối thiểu 85% — PS-IPPO (IPPO với chia sẻ tham số) có đạt tổng chi phí vận hành thấp hơn các chính sách tồn kho cổ điển (EOQ, (s, S), Newsvendor) hay không, và khác biệt đó có ý nghĩa thống kê hay không?
2. Câu hỏi 2: Cơ chế chia sẻ tham số có duy trì được hiệu năng trên các cặp kho–mặt hàng có quy mô nhu cầu khác nhau hay không; và, như một câu hỏi mở rộng, chính sách học được có áp dụng được cho những mặt hàng không xuất hiện trong huấn luyện hay không?
3. Câu hỏi 3: Thiết kế tín hiệu phần thưởng — phần thưởng phân rã cục bộ theo từng cặp so với phần thưởng toàn cục của cả mạng lưới, và chuẩn hóa phần thưởng theo từng cặp so với không chuẩn hóa — ảnh hưởng như thế nào đến độ ổn định huấn luyện và hiệu năng của PS-IPPO?

Câu hỏi 1 là câu hỏi chính. Mức 85% là mục tiêu nghiệp vụ được đặt trước khi thực nghiệm; phép so sánh ở một mức phục vụ cao hơn (bằng đúng mức IPPO đạt được) chỉ được dùng như phân tích bổ sung.

1.3 Đối tượng và phạm vi nghiên cứu

1.3.1 Đối tượng nghiên cứu

Đối tượng nghiên cứu của khóa luận là bài toán tối ưu hóa chính sách đặt hàng lại trong hệ thống tồn kho đa kho – đa mặt hàng, và thuật toán học tăng cường đa tác tử Independent Multi-Agent PPO áp dụng cho bài toán này.

1.3.2 Phạm vi trong đề tài

– Cấu hình hệ thống: $N = 10$ kho, $M = 30$ mặt hàng, tương ứng 300 cặp ra quyết định; độ dài mỗi tập huấn luyện là 365 ngày; thời gian giao hàng ngẫu nhiên trong khoảng từ một đến ba ngày.

– Cấu trúc mạng lưới: các kho hoạt động song song và độc lập về nguồn cung, mỗi kho đặt hàng từ nhà cung cấp bên ngoài (được mô phỏng bằng thời gian giao ngẫu nhiên). Sự ràng buộc giữa các mặt hàng phát sinh từ dung lượng kho dùng chung. Đầu ra của mô hình là *yêu cầu đặt hàng lại*: số lượng và

thời điểm đặt cho từng cặp kho–mặt hàng (xem Mục 1.3.3).

- Nguồn dữ liệu: bộ dữ liệu bán lẻ M5 Walmart [2], cụ thể là hai tệp `sales_train_evaluation.csv` chứa 30.490 chuỗi doanh số theo ngày trên 1.941 ngày, và `calendar.csv` chứa thông tin lịch, ngày lễ và các sự kiện trợ cấp thực phẩm SNAP. Khóa luận đồng thời hỗ trợ sinh dữ liệu giả lập theo phân phối Poisson phục vụ thử nghiệm đối chứng.
- Phương pháp đối chứng: ba chính sách tồn kho cổ điển EOQ [12], (s, S) [13] và Newsvendor [14], với tham số được tối ưu bằng tìm kiếm lưới trên chính môi trường mô phỏng nhằm bảo đảm tính công bằng của so sánh.
- Chỉ số đánh giá: tổng chi phí vận hành, tỷ lệ đáp ứng nhu cầu, và cơ cấu các thành phần chi phí lưu kho, thiếu hàng, đặt hàng, tràn kho. Việc so sánh chi phí được thực hiện bổ sung ở cùng một mức phục vụ nhằm tránh kết luận sai lệch khi hai chính sách nằm ở hai điểm khác nhau trên đường đánh đổi chi phí — mức phục vụ.

1.3.3 Giới hạn phạm vi

Để bảo đảm chiều sâu nghiên cứu trong thời gian thực hiện, những nội dung sau được xác định nằm ngoài phạm vi khóa luận:

- Cấu trúc tồn kho đa cấp (multi-echelon) với quan hệ cung ứng giữa các kho theo mô hình của Clark và Scarf [30], cùng các hiện tượng đi kèm như hiệu ứng bullwhip [31].
- Bài toán điều chuyển hàng liên kho và tối ưu hóa tuyến vận chuyển.
- Dự báo nhu cầu bằng mô hình học sâu chuỗi thời gian; khóa luận sử dụng trực tiếp thông tin nhu cầu lịch sử trong vector quan sát.
- Cơ chế truyền thông giữa các tác tử; các tác tử ra quyết định hoàn toàn dựa trên quan sát cục bộ.
- Triển khai vận hành thời gian thực hoặc tích hợp với nền tảng quản trị doanh nghiệp; sản phẩm của khóa luận là kết quả mô phỏng, phân tích định lượng và một ứng dụng mô phỏng chỉ chạy suy luận từ mô hình đã huấn luyện (không huấn luyện lại trong ứng dụng).
- Các bước sau khi có yêu cầu đặt hàng: hỏi báo giá, chọn và gửi đơn tới nhà cung cấp. Trong quy trình thực tế, bộ phận có nhu cầu gửi phiếu đề nghị sang phòng mua hàng và phòng mua hàng mới hỏi báo giá; khóa luận dừng ở bước lập và duyệt phiếu đề nghị đặt hàng gửi phòng mua hàng. Bộ dữ liệu

M5 không có thông tin nhà cung cấp nên các bước này không thể mô hình hóa từ dữ liệu. Đây là *giới hạn phạm vi*, không phải hạn chế của phương pháp: khi có dữ liệu nhà cung cấp, đầu ra của mô hình có thể nối vào luồng tự động hóa này.

1.4 Phương pháp nghiên cứu

Khóa luận kết hợp ba nhóm phương pháp. Về lý thuyết, bài toán được mô hình hóa dưới dạng quá trình quyết định Markov phi tập trung có quan sát bộ phận [9], [11], trên nền tảng lý thuyết kiểm soát tồn kho ngẫu nhiên [8] và học tăng cường [10], [32]. Về thực nghiệm, nhóm xây dựng môi trường mô phỏng có kiểm thử đơn vị theo chuẩn giao diện Gymnasium [24], [33], hiệu chỉnh tham số từ dữ liệu M5, huấn luyện tác tử và thu thập số liệu vận hành. Về phân tích, mọi so sánh giữa các phương pháp đều được thực hiện trên cùng một tập hạt giống đánh giá, báo cáo giá trị trung bình kèm độ lệch chuẩn, và được xác nhận bằng kiểm định thống kê phù hợp trước khi kết luận — theo khuyến nghị về tính tái lập trong đánh giá học tăng cường sâu của Henderson và cộng sự [28] và Agarwal và cộng sự [29].

1.5 Ý nghĩa khoa học và thực tiễn của đề tài

Về mặt khoa học, khóa luận đóng góp một khung mô hình hóa bài toán tồn kho đa kho – đa mặt hàng dưới dạng hệ đa tác tử hợp tác quy mô lớn, cùng với đánh giá thực nghiệm có kiểm định thống kê về ảnh hưởng của cách phân rã hàm phần thưởng và cơ chế chia sẻ tham số — hai yếu tố thiết kế thường được sử dụng nhưng ít được khảo sát tách bạch trong các nghiên cứu trước.

Về mặt thực tiễn, kết quả của khóa luận cung cấp bằng chứng định lượng về mức độ khả thi của việc thay thế các chính sách đặt hàng theo tham số tĩnh bằng chính sách học được từ dữ liệu, trên một môi trường mô phỏng được hiệu chỉnh từ dữ liệu bán lẻ thực tế. Cấu trúc mã nguồn và giao thức đánh giá được tổ chức theo hướng có thể tái lập, tạo điều kiện cho các nghiên cứu mở rộng tiếp theo.

1.6 Bố cục của khóa luận

Khóa luận được tổ chức thành năm chương:

– Chương 1 — Tổng quan về đề tài: trình bày bối cảnh, tính cấp thiết, mục tiêu, câu hỏi nghiên cứu, phạm vi và phương pháp nghiên cứu.

- Chương 2 — Cơ sở lý thuyết và các công trình liên quan: hệ thống hóa lý thuyết kiểm soát tồn kho ngẫu nhiên, các chính sách cổ điển, nền tảng học tăng cường và học tăng cường đa tác tử, cùng lược khảo các nghiên cứu tiền nhiệm.
- Chương 3 — Phân tích và thiết kế mô hình: chi tiết hóa mô hình toán học của môi trường, thiết kế không gian trạng thái, không gian hành động và hàm phần thưởng, kiến trúc mạng Actor–Critic chia sẻ tham số và quy trình huấn luyện.
- Chương 4 — Thực nghiệm và đánh giá kết quả: trình bày cấu hình thực nghiệm, kết quả so sánh với các chính sách cổ điển, các khảo sát loại trừ và phân tích độ nhạy.
- Chương 5 — Kết luận và hướng phát triển: tổng kết kết quả đạt được, chỉ ra hạn chế và đề xuất hướng nghiên cứu tiếp theo.

CHƯƠNG 2. CƠ SỞ LÝ THUYẾT VÀ CÁC CÔNG TRÌNH LIÊN QUAN

2.1 Lý thuyết kiểm soát tồn kho ngẫu nhiên

2.1.1 Mô hình tồn kho và các thành phần chi phí

Bài toán kiểm soát tồn kho xoay quanh việc xác định thời điểm và số lượng đặt hàng bổ sung nhằm cân bằng giữa chi phí phát sinh khi dự trữ quá nhiều và rủi ro khi dự trữ quá ít [8]. Xét một hệ thống đơn kho – đơn mặt hàng hoạt động theo chu kỳ rời rạc. Gọi I_t là mức tồn kho tại đầu kỳ t, a_t là số lượng đặt hàng, D_t là nhu cầu phát sinh trong kỳ t (biến ngẫu nhiên) và L_t là thời gian giao hàng. Chi phí vận hành mỗi kỳ bao gồm:

- Chi phí lưu kho $C_{\text{hold}} = c_{lk} \cdot \max(I_t, 0)$: chi phí tỷ lệ với lượng hàng tồn dương trong kho, bao gồm chi phí vốn, bảo quản và kho bãi.
- Chi phí thiếu hàng $C_{\text{stock}} = c_{th} \cdot \max(D_t - I_t, 0)$: chi phí phát sinh khi nhu cầu vượt quá lượng hàng có sẵn. Trong mô hình mất đơn hàng (lost sales), phần nhu cầu không được đáp ứng bị mất hoàn toàn thay vì chuyển sang kỳ sau [15].
- Chi phí đặt hàng cố định $C_{\text{order}} = c_{dh} \cdot \mathbb{1}(a_t > 0)$: chi phí phát sinh mỗi khi hệ thống phát lệnh đặt hàng, bất kể số lượng đặt.
- Phạt tràn kho $C_{\text{over}} = p_{tk} \cdot \max(I_t + q_t - W, 0)$: chi phí phát sinh khi tổng lượng hàng tồn và hàng nhập vượt quá sức chứa W của kho, trong đó q_t là lượng hàng nhập kho trong kỳ.

Tổng chi phí vận hành của một cặp kho–mặt hàng trong kỳ t gồm bốn thành phần trên:

$$C_t = C_{\text{hold}} + C_{\text{stock}} + C_{\text{order}} + C_{\text{over}}. \tag{2.1}$$

Bên cạnh chi phí, doanh nghiệp đặt một mục tiêu mức phục vụ: tỷ lệ đáp ứng nhu cầu (fill rate) $\text{FR}_t^{(w)}$ trên cửa sổ trượt w ngày không thấp hơn ngưỡng τ. Mục tiêu này là một *ràng buộc* chứ không phải một khoản chi phí; trong khóa luận, nó được đưa vào tín hiệu huấn luyện dưới dạng hình phạt $P_t = \phi_{dv} \cdot \max\big(\tau - \text{FR}_t^{(w)},\ 0\big)$ (ràng buộc mềm, Mục 3.2.2), và không được cộng vào chi phí vận hành báo cáo.

2.1.2 Các chính sách đặt hàng lại cổ điển

Ba chính sách cổ điển được sử dụng làm phương pháp đối chứng trong khóa luận.

Lượng đặt hàng kinh tế (EOQ). Harris [12] đề xuất công thức tối ưu hóa tần suất đặt hàng dưới giả định nhu cầu xác định và đều:

$$Q^* = \sqrt{\frac{2D \cdot c_{dh}}{c_{lk}}} \tag{2.2}$$

trong đó D là nhu cầu trung bình hàng năm. Mô hình giả định không có thiếu hàng, thời gian giao hàng cố định và không có ràng buộc sức chứa.

Chính sách (s, S). Scarf [13] chứng minh rằng chính sách dạng (s, S) — đặt hàng để nâng mức tồn kho lên S khi mức hiện tại giảm xuống dưới s — là tối ưu cho hệ đơn kho với nhu cầu ngẫu nhiên, chi phí đặt hàng cố định, và cơ chế giữ đơn hàng chờ (backorder). Ngưỡng s thường được tính dựa trên nhu cầu trung bình và độ lệch chuẩn trong thời gian giao hàng:

$$s = \mu_L + z_\alpha \cdot \sigma_L \tag{2.3}$$

trong đó μ_L và σ_L là kỳ vọng và độ lệch chuẩn của nhu cầu tích lũy trong thời gian giao hàng, z_α là phân vị chuẩn tương ứng với mức phục vụ mong muốn.

Mô hình Newsvendor. Arrow và cộng sự [14] đề xuất mô hình cho bài toán đặt hàng đơn kỳ, trong đó lượng đặt hàng tối ưu là:

$$Q^* = F^{-1}\left(\frac{c_{th}}{c_{th} + c_{lk}}\right) \tag{2.4}$$

với F^{-1} là hàm phân vị của phân phối nhu cầu. Mô hình chỉ tối ưu cho một chu kỳ duy nhất, không xét lượng hàng đang trên đường vận chuyển.

Cả ba chính sách trên đều được xây dựng cho bài toán đơn kho – đơn mặt hàng và không tối ưu hóa đồng thời ràng buộc sức chứa dùng chung, phạt tràn kho và mức phục vụ — những đặc trưng quan trọng trong bài toán đa kho – đa mặt hàng mà khóa luận xét [1], [8].

2.1.3 Các thước đo mức phục vụ trong quản lý tồn kho

Trong quản lý tồn kho ngẫu nhiên, mức phục vụ (service level) được đánh giá thông qua ba thước đo phổ biến [1], [8]:

– *Mức phục vụ theo chu kỳ* (α – Cycle Service Level / Type-1): xác suất không xảy ra hiện tượng thiếu hàng trong một chu kỳ bổ sung tồn kho, tức $P(D_L \leq$

s) trong đó D_L là nhu cầu tích lũy trong thời gian giao hàng L và s là điểm đặt hàng lại. Tỷ số tới hạn trong mô hình Newsvendor (2.4) phản ánh chính xác phân vị z_α của thước đo này.

- *Tỷ lệ đáp ứng nhu cầu* (β – Fill Rate / Type-2): tỷ lệ phần trăm tổng nhu cầu của khách hàng được đáp ứng ngay lập tức từ lượng hàng sẵn có trong kho.
- *Tỷ lệ sẵn sàng* (γ – Ready Rate): tỷ lệ thời gian mà mức tồn kho khả dụng duy trì giá trị dương.

Cần lưu ý rạch ròi rằng tỷ số chi phí $c_{th}/(c_{th}+c_{lk})$ xác định mức phục vụ chu kỳ α, chứ không phải tỷ lệ fill rate β. Trong điều kiện nhu cầu ổn định và biến động vừa phải, β thường cao hơn α. Tuy nhiên, dưới tác động của nhu cầu gián đoạn (intermittent demand) và thời gian giao hàng ngẫu nhiên như trong dữ liệu M5 Walmart, mối quan hệ này không còn mang tính tuyệt đối và β có thể sụt giảm thấp hơn α [1].

Một quan sát thực nghiệm liên quan: với bộ tham số chi phí $c_{th} = 10{,}0$ và $c_{lk} = 1{,}0$ sử dụng trong thực nghiệm, tỷ số tới hạn lý thuyết của Newsvendor là $c_{th}/(c_{th} + c_{lk}) = 10/11 \approx 0{,}909$. Tuy nhiên, tìm kiếm lưới trên môi trường mô phỏng cho tham số tối ưu $CR^* = 0{,}85$ — thấp hơn nhưng không lệch quá xa lý thuyết. Chênh lệch còn lại không xuất phát từ sai lệch triển khai mà phản ánh sự khác biệt khái niệm căn bản: tỷ số tới hạn cổ điển tối ưu cho mức phục vụ chu kỳ α trong bài toán *một kỳ* không có hàng đang vận chuyển, còn môi trường thực nghiệm là bài toán *đa kỳ* với pipeline 3 ngày, ràng buộc sức chứa kho và hàm mục tiêu fill rate trên cửa sổ trượt. Khoảng cách này được ghi nhận và phân tích trong mục thảo luận kết quả (Mục 4.4.4).

2.2 Nền tảng học tăng cường

2.2.1 Quá trình quyết định Markov (MDP)

Bài toán ra quyết định tuần tự dưới bất định được mô hình hóa bằng quá trình quyết định Markov [32], xác định bởi bộ năm (S, A, P, R, γ) trong đó:

- S: không gian trạng thái (state space).
- A: không gian hành động (action space).
- $P(s' \mid s, a)$: hàm xác suất chuyển trạng thái.
- $R(s, a)$: hàm phần thưởng (reward function).
- $\gamma \in [0, 1)$: hệ số chiết khấu (discount factor).

Mục tiêu của tác tử là tìm chính sách π^* cực đại hóa lợi tức kỳ vọng:

$$\pi^* = \arg\max_{\pi} \ \mathbb{E}_{\pi}\left[\sum_{t=0}^{\infty} \gamma^t R(s_t, a_t)\right] \tag{2.5}$$

2.2.2 Hàm giá trị và phương trình Bellman

Hàm giá trị trạng thái $V^{\pi}(s) = \mathbb{E}_{\pi}[\sum_{t=0}^{\infty} \gamma^t R_t \mid s_0 = s]$ và hàm giá trị hành động $Q^{\pi}(s,a)$ thỏa mãn phương trình Bellman [10]. Hàm lợi thế (advantage function) được định nghĩa:

$$A^{\pi}(s,a) = Q^{\pi}(s,a) - V^{\pi}(s) \tag{2.6}$$

đo mức độ tốt hơn (hoặc kém hơn) của hành động a so với hành vi trung bình của chính sách π tại trạng thái s.

2.2.3 Ước lượng lợi thế tổng quát (GAE)

Schulman và cộng sự [27] đề xuất phương pháp ước lượng lợi thế tổng quát (Generalized Advantage Estimation – GAE) nhằm kiểm soát đánh đổi giữa thiên lệch (bias) và phương sai (variance) trong ước lượng gradient chính sách:

$$\hat{A}_t^{\mathrm{GAE}(\gamma,\lambda)} = \sum_{l=0}^{\infty} (\gamma\lambda)^l \delta_{t+l} \tag{2.7}$$

trong đó $\delta_t = r_t + \gamma V(s_{t+1}) - V(s_t)$ là sai số TD (temporal difference) và $\lambda \in [0,1]$ là tham số kiểm soát đánh đổi. Khi $\lambda = 0$, GAE suy biến thành ước lượng một bước (thiên lệch cao, phương sai thấp); khi $\lambda = 1$, GAE tương đương Monte-Carlo (không thiên lệch, phương sai cao). Khóa luận sử dụng $\lambda = 0{,}95$ theo khuyến nghị thực nghiệm phổ biến.

2.2.4 Thuật toán PPO (Proximal Policy Optimization)

Schulman và cộng sự [26] đề xuất PPO nhằm khắc phục nhược điểm của phương pháp tối ưu hóa chính sách: các bước cập nhật quá lớn có thể phá hủy chính sách đã học. PPO sử dụng hàm mục tiêu cắt (clipped surrogate objective):

$$L^{\mathrm{CLIP}}(\theta) = \mathbb{E}_t\left[\min\big(r_t(\theta)\hat{A}_t,\ \mathrm{clip}\big(r_t(\theta), 1-\epsilon, 1+\epsilon\big)\hat{A}_t\big)\right] \tag{2.8}$$

trong đó $r_t(\theta) = \frac{\pi_\theta(a_t|s_t)}{\pi_{\theta_{\mathrm{old}}}(a_t|s_t)}$ là tỷ lệ xác suất giữa chính sách mới và cũ, và ϵ (thường bằng $0{,}2$) giới hạn biên độ thay đổi tối đa. PPO kết hợp cập nhật on-policy, hiệu quả tính toán cao và tính ổn định, phù hợp cho bài toán có không gian hành động rời rạc hoặc liên tục.

Ý tưởng cốt lõi của TRPO [34] — giới hạn bước cập nhật trong vùng tin cậy — được PPO thực hiện đơn giản hơn qua phép cắt, giúp cài đặt dễ dàng và huấn luyện nhanh hơn trên thực tế.

2.3 Học tăng cường đa tác tử

2.3.1 Mô hình Dec-POMDP

Khi hệ thống có nhiều tác tử ra quyết định đồng thời, bài toán được mô hình hóa bằng quá trình quyết định Markov phi tập trung có quan sát bộ phận (Decentralized Partially Observable Markov Decision Process – Dec-POMDP) [9]. Trong mô hình này, mỗi tác tử i chỉ quan sát được một phần trạng thái toàn cục thông qua hàm quan sát $o_i = O(s, i)$ và ra quyết định dựa trên quan sát cục bộ. Bài toán tìm chính sách chung tối ưu cho tất cả tác tử đã được chứng minh thuộc lớp NEXP-đầy đủ [11], nên các lời giải chính xác không khả thi ở quy mô lớn.

Trong Dec-POMDP chuẩn, mọi tác tử cùng theo đuổi một mục tiêu hợp tác duy nhất. Khóa luận giữ nguyên mục tiêu hợp tác đó ở cấp toàn mạng lưới:

$$R_t^{\text{team}} = \sum_{i=1}^{300} r_{i,t}, \qquad \max_{\theta} \ \mathbb{E}\Big[\sum_{t} \gamma^t R_t^{\text{team}}\Big], \tag{2.9}$$

nhưng tín hiệu dùng để *huấn luyện* được phân rã thành các phần thưởng cục bộ $r_{i,t}$ của từng cặp kho–mặt hàng (Mục 2.3.5). Nói cách khác, hệ thống có mục tiêu hợp tác ở cấp toàn mạng lưới, còn phần thưởng cục bộ là một cách phân rã tín hiệu học nhằm giảm phương sai và giảm khó khăn gán tín dụng. Vì các cặp trong cùng kho tương tác qua sức chứa chung, tối ưu riêng từng $r_{i,t}$ không tự động bảo đảm tối ưu R^{team}; việc phân rã này có thật sự có lợi hay không là nội dung của Câu hỏi nghiên cứu 3.

Bài toán tồn kho đa kho đa mặt hàng được mô hình hóa tự nhiên dưới dạng Dec-POMDP vì bốn đặc điểm cấu trúc phù hợp với lớp bài toán này:

1. **Quyết định tuần tự, hệ quả trễ**. Đơn đặt hàng hôm nay ảnh hưởng tồn kho 1–3 ngày sau. Không phải bài toán một bước.
2. **Trạng thái thay đổi theo hành động**. Đặt hàng làm đổi tồn kho, thay đổi luôn bài toán của ngày mai.
3. **Không có nhãn hành động**. Không tồn tại nhãn hành động tối ưu quan sát trực tiếp cho từng ngày; chỉ quan sát được chi phí sau khi hành động được thực hiện. Đây là lý do không dùng học có giám sát.
4. **Mục tiêu dài hạn**. Tối thiểu chi phí cả năm, không phải chỉ hôm nay. Tích

trữ hôm nay tốn tiền nhưng tránh mất doanh thu ngày mai.

Quy hoạch động không khả dụng vì không gian trạng thái liên tục 44 chiều $\times 300$ tác tử và phân phối nhu cầu M5 không có dạng đóng — đây là "lời nguyền số chiều" mà các phương pháp bảng tra (tabular) không vượt qua được [35].

2.3.2 Học độc lập (Independent Learning)

Tan [19] đề xuất phương pháp học độc lập: mỗi tác tử coi các tác tử khác là một phần của môi trường và áp dụng thuật toán RL đơn tác tử riêng rẽ. Hạn chế lý thuyết chính là môi trường trở nên không dừng (non-stationary) do các tác tử khác cũng đang thay đổi chính sách. Tuy nhiên, các nghiên cứu thực nghiệm cho thấy phương pháp này đạt hiệu quả bất ngờ trên nhiều bài toán hợp tác [20].

2.3.3 IPPO — Independent Multi-Agent PPO

IPPO là biến thể đa tác tử của PPO trong đó mỗi tác tử i chạy PPO độc lập dựa trên quan sát cục bộ o_i^t và phần thưởng riêng r_i^t [20]. Yu và cộng sự [21] đánh giá hệ thống trên nhiều môi trường hợp tác và kết luận rằng IPPO đạt hiệu năng cạnh tranh hoặc vượt trội so với các phương pháp phức tạp hơn như QMIX hay MAPPO trong nhiều kịch bản.

Đặc điểm quan trọng của IPPO khiến nó phù hợp cho bài toán tồn kho:

- Không yêu cầu trạng thái toàn cục: mỗi tác tử (cặp kho–mặt hàng) chỉ cần quan sát cục bộ.
- Khả năng mở rộng: không gian hành động của mỗi tác tử có kích thước K cố định, không phụ thuộc số tác tử.
- Tính đơn giản: cài đặt dựa trên PPO chuẩn, không cần mixing network hay cơ chế truyền thông.

Cần phân biệt rõ ba tầng nghĩa của "independent" trong IPPO, vì chúng hàm ý khác nhau:

- *Độc lập về ra quyết định*: mỗi tác tử chọn hành động chỉ dựa trên quan sát cục bộ của mình, không nhận thông tin từ tác tử khác. Đúng.
- *Độc lập về tính lợi thế*: GAE tính riêng theo trục thời gian cho từng cặp i, sử dụng phần thưởng riêng r_i^t và giá trị riêng $V(o_i^t)$. Đúng.
- *Độc lập về tham số*: mỗi tác tử có bộ trọng số riêng. Không — đây là điểm chia sẻ tham số (parameter sharing) được khảo sát ở Mục 2.3.4.

Hai cặp ở hai trạng thái khác nhau sẽ hành động khác nhau dù cùng θ — vì đầu

vào khác nhau. Mỗi tác tử có chính sách riêng theo nghĩa hàm $\pi(a \mid o_i)$ nhận quan sát riêng và cho ra phân phối riêng, nhưng tham số θ dùng chung.

2.3.4 Chia sẻ tham số (Parameter Sharing)

Gupta và cộng sự [18] chỉ ra rằng khi các tác tử có cùng không gian quan sát và hành động, một mạng nơ-ron duy nhất có thể được chia sẻ giữa tất cả tác tử. Mỗi tác tử vẫn ra quyết định dựa trên quan sát riêng nhưng dùng chung bộ trọng số. Lợi ích:

- Số tham số cần học không tăng theo số tác tử (ở đây: 300).
- Mỗi bước cập nhật sử dụng dữ liệu từ tất cả tác tử, tăng hiệu quả mẫu.
- Chính sách học được có khả năng tổng quát hóa cho các mặt hàng có quy mô nhu cầu khác nhau.

Chẳn đáng lưu ý: chia sẻ tham số không tương đương với việc gộp 300 tác tử thành một tác tử duy nhất. Nếu gộp, không gian hành động sẽ là 6^{300}, không thể học được trên thực tế. Với kiến trúc chia sẻ tham số hiện tại, mạng nhận batch $(300, 44)$ và forward một lần, nhưng mỗi tác tử chỉ xử lý $K = 6$ hành động — không gian cố định và có thể giải quyết được.

2.3.5 Phần thưởng phân rã cục bộ và bài toán gán tín dụng

Trong hệ đa tác tử, việc sử dụng phần thưởng toàn cục (tổng chi phí của toàn bộ hệ thống) cho mọi tác tử gây ra vấn đề gán tín dụng (credit assignment): tác tử khó phân biệt được đóng góp cá nhân trong tín hiệu tổng hợp [25]. Wolpert và Tumer đề xuất *phần thưởng chênh lệch* (difference reward) $D_i = G(z) - G(z_{-i})$, trong đó $G(z_{-i})$ là giá trị của hệ thống khi loại bỏ đóng góp của tác tử i — một đại lượng phản thực (counterfactual) phải được tính thêm.

Khóa luận *không* cài đặt phần thưởng chênh lệch theo đúng nghĩa này. Thay vào đó, khóa luận dùng *phần thưởng phân rã cục bộ* (local factored reward): mỗi tác tử nhận $r_{i,t} = -(C_{i,t} + P_{i,t})$, gồm chi phí vận hành $C_{i,t}$ và hình phạt mức phục vụ $P_{i,t}$ của chính cặp kho–mặt hàng mà nó quản lý, với $\sum_i r_{i,t} = R_t^{\text{team}}$ (công thức 2.9). Cách phân rã này dựa trên cùng động cơ giảm khó khăn gán tín dụng như phân tích của Wolpert và Tumer. Nó khả thi ở đây vì phần lớn chi phí của một cặp (lưu kho, thiếu hàng, đặt hàng) do chính quyết định của cặp đó gây ra; riêng phần tràn kho — đại lượng thực sự ghép nối giữa các cặp — được phân bổ theo tỷ trọng hàng mới về của từng cặp (Mục 3.1.4).

Khung lý thuyết định hình phần thưởng bảo toàn thế năng (Potential-Based Reward Shaping – PBRS) do Ng và cộng sự [36] chứng minh khẳng định rằng: một hàm biến đổi phần thưởng $F(s, a, s')$ bảo toàn tập chính sách tối ưu của MDP gốc khi và chỉ khi nó có dạng chênh lệch thế năng $F(s, a, s') = \gamma\Phi(s') - \Phi(s)$. Khung lý thuyết này sau đó được mở rộng sang hệ đa tác tử bởi Devlin và Kudenko [37] cũng như ứng dụng trong tồn kho bởi De Moor và cộng sự [38].

2.4 Các công trình nghiên cứu liên quan

2.4.1 Học tăng cường trong quản lý tồn kho

Oroojlooyjadid và cộng sự [16] áp dụng Deep Q-Network (DQN) cho trò chơi phân phối bia (beer game) — một bài toán chuỗi cung ứng 4 cấp cổ điển — và cho thấy DQN có thể học được chính sách giảm hiệu ứng bullwhip. Tuy nhiên, nghiên cứu giới hạn ở hệ đơn mặt hàng, bốn tác tử.

Gijsbrechts và cộng sự [17] đánh giá hệ thống khả năng của DRL trên ba lớp bài toán tồn kho: mất đơn hàng, hai nguồn cung và đa cấp. Kết quả cho thấy DRL đạt hiệu năng ngang hoặc tốt hơn chính sách cổ điển trong hầu hết trường hợp, nhưng tất cả thực nghiệm đều ở quy mô nhỏ (dưới 10 SKU).

Hubbs và cộng sự [39] giới thiệu bộ thư viện OR-Gym đóng vai trò là môi trường benchmark chuẩn cho các bài toán Vận trù học bằng RL, bao gồm cả mô hình Newsvendor và quản lý tồn kho đa cấp lost-sales.

Nghiên cứu của Ding và cộng sự [40] (CD-PPO) phát biểu chính xác bài toán tồn kho đơn cửa hàng nhiều SKU dưới dạng tài nguyên kho dùng chung làm ghép nối các tác tử vốn độc lập. Họ so sánh trực tiếp IPPO và MAPPO có chia sẻ tham số (parameter sharing), báo cáo hiệu quả cao hơn các phương pháp đối chứng khi quản lý tài nguyên kho chung.

Yang và cộng sự [41] phát triển MABIM — bộ benchmark MARL đa dạng cho tồn kho. MABIM coi mỗi SKU tại mỗi điểm lưu trữ là một tác tử độc lập, sử dụng dữ liệu nhu cầu thực tế của hơn 2.000 SKU với 51 tác vụ thử nghiệm (bao gồm nhóm tác vụ mở rộng quy mô scaling up), thử nghiệm các thuật toán MARL bao gồm IPPO dưới ràng buộc sức chứa dùng chung.

Kotecha và del Rio Chanona [42] tiến hành phân tích chuyên sâu các thuật toán MARL cho kiểm soát tồn kho phân tán, so sánh giữa IPPO thuần, IPPO chia sẻ tham số và MAPPO. Họ phát hiện rằng mặc dù parameter sharing giảm số lượng tham số cần học, hiệu năng của IPPO chia sẻ tham số có dấu hiệu giảm sút khi quy mô tác tử

tăng lên rất lớn.

Gần đây nhất, Liu và cộng sự [43] áp dụng thuật toán Heterogeneous-Agent PPO (HAPPO) cho tồn kho đa cấp. Đáng chú ý, các tác giả phát hiện việc kết hợp chi phí cục bộ và chi phí toàn hệ thống vào tín hiệu thưởng thu được chính sách có độ ổn định và hiệu năng cao hơn so với chỉ dùng chi phí toàn hệ thống thuần túy.

2.4.2 Hai công trình gần nhất cùng bối cảnh

Hai công trình công bố gần đây có bối cảnh gần với khóa luận nhất và vì vậy cần được đối chiếu chi tiết.

Zhu và Wu [22] đề xuất khung DC-STGN-MARL kết hợp một mạng đồ thị không–thời gian cho dự báo nhu cầu với học tăng cường đa tác tử theo hướng phân rã hàm giá trị, đánh giá trên chính bộ dữ liệu M5. Công trình báo cáo mức giảm $13{,}6\%$ tổng chi phí so với học tăng cường đơn tác tử và mức phục vụ $95{,}8\%$. Điểm cần lưu ý đối với khóa luận nằm ở khảo sát loại trừ của họ: khi thay cơ chế phối hợp bằng học độc lập, chi phí tăng từ $125{,}4$ lên $152{,}7$ và mức phục vụ giảm từ $95{,}8\%$ xuống $92{,}1\%$. Kết quả này đặt ra câu hỏi trực tiếp về lựa chọn học độc lập của khóa luận.

Tuy nhiên, bối cảnh của hai nghiên cứu khác nhau ở một điểm mấu chốt. Môi trường của Zhu và Wu giả định năng lực cung ứng không giới hạn và không đưa sức chứa kho vào hàm mục tiêu, nên các tác tử chỉ ghép nối với nhau qua hàm phần thưởng chung chứ không qua một nguồn lực vật lý hữu hạn. Trong khóa luận, sức chứa kho dùng chung là một ràng buộc cứng và cũng chính là kênh phối hợp gián tiếp (Mục 3.1.5); mức độ cần thiết của phối hợp tường minh trong bối cảnh này vì vậy là một câu hỏi thực nghiệm mở, chứ không thể suy trực tiếp từ kết quả của họ. Ngoài ra, một số chi tiết trong công trình cần được tiếp nhận thận trọng: các so sánh chi phí được thực hiện giữa những cấu hình có mức phục vụ khác nhau, và số lượng tác tử không được xác định rõ ràng — bài viết mô tả N tác tử "đại diện cho N kho hoặc nhóm sản phẩm" mà không xác định cụ thể.

Ở hướng thứ hai, một khung làm việc dựa trên kiến trúc hướng sự kiện kết hợp tác tử xếp vị trí lưu trữ và tác tử bổ sung hàng đã được đề xuất [23], với đóng góp chính là cơ chế *gán công liên kết hành động*: phần thưởng chỉ được tính khi lô hàng thực nhập kho sau thời gian giao hàng, rồi được quy ngược về đúng cặp trạng thái–hành động đã phát lệnh đặt. Đây là một cách xử lý trực diện độ trễ giữa quyết định và hệ quả của nó. Khảo sát loại trừ của công trình cho thấy khi bỏ cơ chế này, tỷ lệ thiếu hàng tăng đáng kể. Cần lưu ý rằng biến thể đối chứng của họ sử dụng trạng thái dự đoán tại thời điểm ra quyết định, chứ không phải ước lượng lợi thế tổng quát

như khóa luận sử dụng; do đó con số của họ không thể chuyển trực tiếp sang bối cảnh này. Hạn chế của công trình là chỉ xét một kho duy nhất, trên dữ liệu tổng hợp, và hàm phần thưởng không quy về đơn vị tiền tệ.

Bảng 2.1 tóm tắt đối chiếu.

Bảng 2.1: Đối chiếu khóa luận với hai công trình gần nhất cùng bối cảnh

Tiêu chí	**[23]**	**[22]**	**Khóa luận**
Số kho	1	4	10
Ràng buộc sức chứa	một kho	không xét	riêng từng kho
Nguồn dữ liệu	tổng hợp	M5	M5
Hàm mục tiêu	không quy về tiền	chi phí	chi phí
Ghép nối giữa tác tử	không	phần thưởng chung	sức chứa dùng chung
So sánh cùng mức phục vụ	không	không	có

2.4.3 Khoảng trống nghiên cứu và định vị đóng góp

Bảng 2.2 tóm tắt so sánh tổng quan giữa khóa luận này và các công trình nghiên cứu liên quan tiêu biểu.

Bảng 2.2: So sánh tổng quan các công trình nghiên cứu liên quan

Nghiên cứu	**Cấu trúc mạng**	**Số SKU**	**Chia sẻ tham số**	**Dữ liệu thực**	**Thuật toán**
Oroojlooyjadid (2022)	4 cấp chuỗi	1	Không	Không	DQN
Gijsbrechts (2022)	2 cấp / đa cấp	< 10	Không	Không	A2C / PPO
Hubbs et al. (2020)	Đa cấp lost-sales	Biến đổi	Không	Không	DQN / PPO
Ding et al. (2022)	1 cửa hàng	Nhiều SKU	Có	Không	CD-PPO / IPPO
Yang et al. (2023)	Đa cấp / Đa kho	> 2000	Có	Có	IPPO / MAPPO
Kotecha (2024)	Đa điểm phân tán	Biến đổi	Có	Không	IPPO / MAPPO
Liu et al. (2025)	Đa cấp phức tạp	Nhiều SKU	Có	Có	HAPPO
Khóa luận này	10 kho song song	30	Có	M5 Walmart	IPPO

Đóng góp của khóa luận được định vị theo hướng tái lập và mở rộng có kiểm

soát đối với ứng dụng học tăng cường đa tác tử trong kiểm soát tồn kho, tập trung vào ba trọng tâm sau:

1. Khảo sát cấu hình 10 kho song song thuần túy (non-multi-echelon) với ràng buộc sức chứa kho dùng chung ở quy mô 300 cặp kho–mặt hàng, tạo điểm đối sánh trực tiếp với các mô hình đa cấp (multi-echelon) của MABIM [41] và Liu và cộng sự [43].
2. Thực hiện khảo sát loại trừ có hệ thống nhằm định lượng tác động của tín hiệu phần thưởng phân rã cục bộ kèm ràng buộc tỷ lệ đáp ứng trên cửa sổ trượt, làm rõ cơ chế gán tín dụng và tốc độ hội tụ của IPPO ở quy mô 300 tác tử.
3. Hiệu chỉnh môi trường mô phỏng lost-sales trực tiếp từ dữ liệu bán lẻ thực tế M5 Walmart và thực hiện kiểm chứng đối chứng có kiểm định thống kê với các chính sách cổ điển EOQ, (s, S) và Newsvendor.

CHƯƠNG 3. PHÂN TÍCH VÀ THIẾT KẾ MÔ HÌNH

3.1 Mô hình hóa bài toán tồn kho đa kho

3.1.1 Quy trình nghiệp vụ và mô hình khái niệm

Thiết kế tác tử của khóa luận không bắt đầu từ thuật toán mà từ quy trình vận hành kho. Trình tự lập luận được giữ đúng theo thứ tự: quy trình nghiệp vụ $\rightarrow$ các quyết định cần đưa ra $\rightarrow$ ai chịu trách nhiệm cho từng quyết định $\rightarrow$ nhiệm vụ $\rightarrow$ tác tử.

Quy trình vận hành một ngày. Tại mỗi kho, với mỗi mã hàng, một chu kỳ vận hành hằng ngày gồm năm bước:

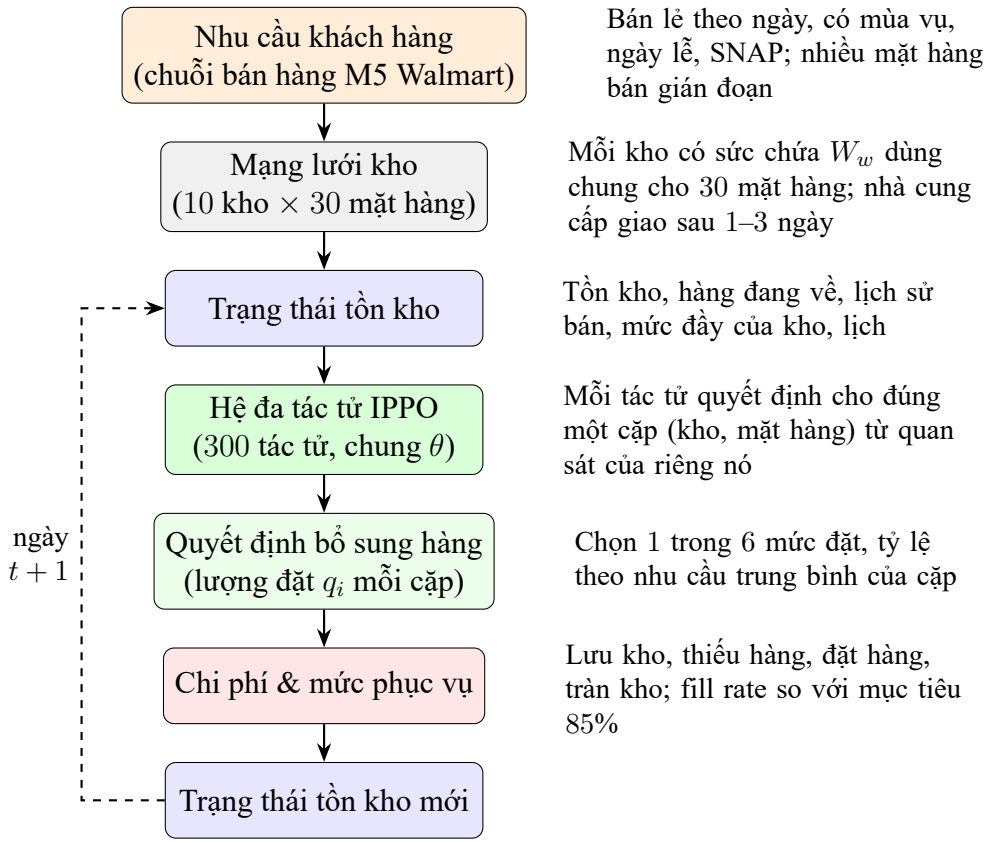
1. **Nhận hàng**: các đơn đặt trước đó đến hạn được giao tới kho. Kho chỉ nhập được trong phạm vi chỗ trống còn lại; hàng vượt sức chứa bị từ chối tại cửa nhập.
2. **Kiểm tra tình trạng**: người phụ trách mã hàng xem tồn kho hiện có, lượng hàng đã đặt nhưng chưa về, lượng bán những ngày gần đây và mức độ đầy của kho.
3. **Ra quyết định bổ sung**: quyết định hôm nay đặt thêm bao nhiêu đơn vị từ nhà cung cấp (có thể là không đặt). Đơn hàng sẽ về sau 1–3 ngày, không biết trước chính xác.
4. **Bán hàng**: khách hàng mua; phần nhu cầu vượt tồn kho bị mất (khách chuyển sang cửa hàng khác).
5. **Ghi nhận kết quả**: chi phí lưu kho, chi phí đặt hàng, tổn thất do thiếu hàng, hàng bị từ chối vì tràn kho và mức phục vụ khách hàng.

Từ quy trình đến tác tử. Trong năm bước trên, chỉ có đúng *một* quyết định cần tối ưu — lượng đặt bổ sung ở bước 3; các bước còn lại là hệ quả vật lý (nhận hàng, bán hàng) hoặc ghi nhận (chi phí). Quyết định này lặp lại cho từng mã hàng tại từng kho và do người phụ trách mã hàng đó chịu trách nhiệm, còn sức chứa kho là tài nguyên dùng chung mà không ai phân bổ tường minh. Vì vậy nhiệm vụ tổng "tối thiểu chi phí vận hành toàn mạng lưới dưới ràng buộc sức chứa và mức phục vụ" được phân rã thành $10 \times 30 = 300$ nhiệm vụ con cùng loại, mỗi nhiệm vụ con giao cho một tác tử

ứng với một cặp (kho, mặt hàng). Căn cứ chi tiết của cách phân rã này được trình bày ở Mục 3.1.3.

Phạm vi của quy trình: dừng ở yêu cầu đặt hàng. Đầu ra của mô hình là *yêu cầu đặt hàng lại*: số lượng và thời điểm đặt cho từng cặp kho–mặt hàng. Trong quy trình thực tế, bộ phận có nhu cầu gửi phiếu đề nghị sang phòng mua hàng, và phòng mua hàng mới hỏi báo giá, chọn nhà cung cấp rồi gửi đơn. Khóa luận dừng ở bước lập và duyệt phiếu đề nghị gửi phòng mua hàng; hai bước sau không được mô hình hóa vì bộ dữ liệu M5 không có thông tin nhà cung cấp. Đây là giới hạn phạm vi (Mục 1.3.3), không phải giới hạn của phương pháp. Trong mô phỏng, nhà cung cấp được thay bằng thời gian giao ngẫu nhiên $L \sim \text{Uniform}\{1, 2, 3\}$ ngày.

Mô hình khái niệm. Hình 3.1 tóm tắt bài toán ở mức nghiệp vụ, trước khi đi vào thuật toán: nhu cầu tác động lên kho, làm thay đổi trạng thái tồn kho; hệ đa tác tử đọc trạng thái và ra quyết định bổ sung hàng; quyết định đó sinh ra chi phí và mức phục vụ, đồng thời tạo ra trạng thái tồn kho mới cho ngày kế tiếp.



Hình 3.1: Mô hình khái niệm của bài toán bổ sung hàng đa kho

3.1.2 Mô tả mạng lưới

Hệ thống gồm $N = 10$ kho hoạt động song song và độc lập về nguồn cung. Mỗi kho lưu trữ $M = 30$ mặt hàng (SKU), tạo thành tổng cộng $N \times M = 300$ cặp kho–mặt hàng. Mỗi kho có dung lượng hữu hạn W được chia sẻ giữa tất cả các mặt hàng. Mỗi cặp kho–mặt hàng đặt hàng từ nhà cung cấp bên ngoài (được mô phỏng bằng thời gian giao hàng ngẫu nhiên $L \sim \text{Uniform}(1, 3)$ ngày).

Sự ràng buộc giữa các mặt hàng trong cùng kho phát sinh từ dung lượng dùng chung: khi một mặt hàng đặt quá nhiều, các mặt hàng khác có thể bị phạt tràn kho. Đây chính là yếu tố khiến bài toán mang tính hợp tác và không thể tách rời thành 300 bài toán đơn lẻ.

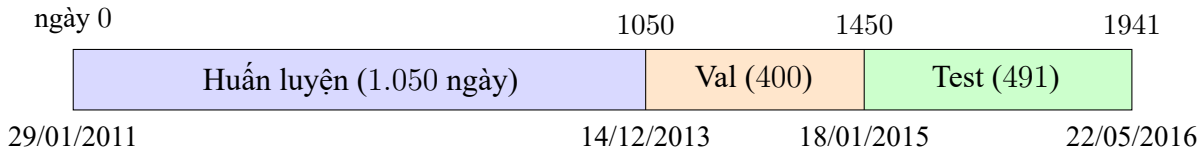
Nhu cầu hàng ngày $D_t^{(i)}$ cho mỗi cặp kho–mặt hàng i được lấy từ hai nguồn:

- Dữ liệu M5 Walmart: tham số nhu cầu (λ trung bình, mẫu hình mùa vụ) được hiệu chỉnh từ chuỗi doanh số thực tế của 10 cửa hàng, mỗi cửa hàng 30 SKU [2].
- Dữ liệu giả lập: nhu cầu Poisson $D_t \sim \text{Poisson}(\lambda_i)$ với λ_i khác nhau giữa các SKU, phục vụ thử nghiệm đối chứng.

Chia miền dữ liệu và các cửa sổ thời gian. Chuỗi 1.941 ngày của M5 được chia theo trục thời gian thành ba miền không chồng lấn. Ngày 0 là dòng đầu của `calendar.csv`, tức 29/01/2011. Bảng 3.1 ghi ngày lịch và độ dài từng miền, Hình 3.2 minh họa trên trục thời gian; vai trò của từng miền được nêu ở Bảng 4.2 (Chương 4).

Bảng 3.1: Ngày lịch và độ dài của ba miền dữ liệu

Miền	Chỉ số ngày	Từ	Đến	Số ngày
Huấn luyện	$[0,\ 1050)$	29/01/2011	13/12/2013	1.050
Validation	$[1050,\ 1450)$	14/12/2013	17/01/2015	400
Kiểm tra (test)	$[1450,\ 1941)$	18/01/2015	22/05/2016	491



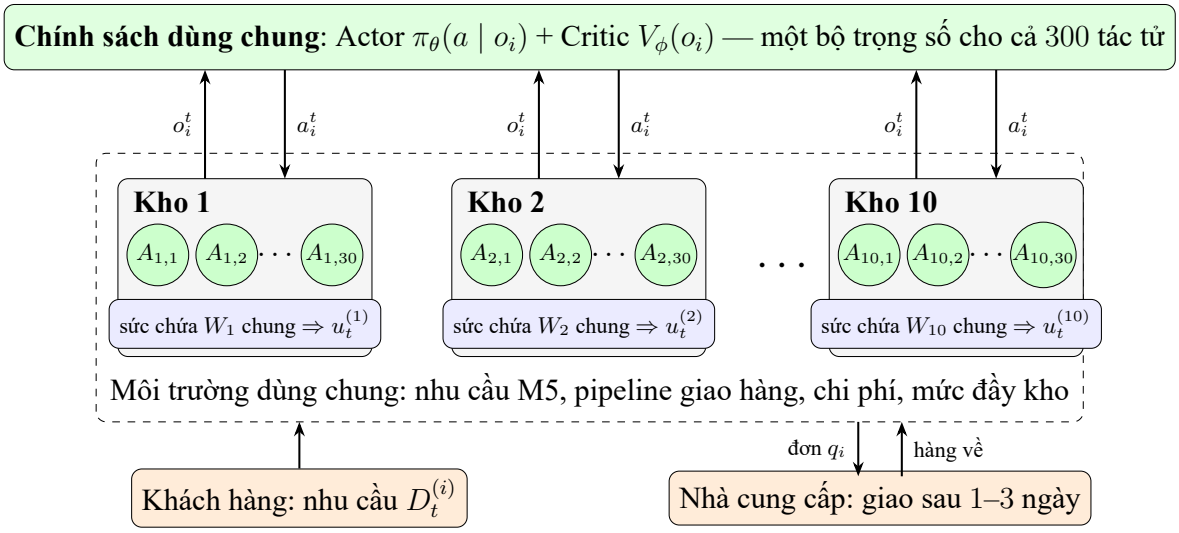
Hình 3.2: Ba miền dữ liệu trên trục thời gian của M5

Bên cạnh các miền, mô hình dùng ba cửa sổ thời gian ngắn hơn: lịch sử nhu cầu 7 ngày gần nhất trong quan sát, cửa sổ fill rate trượt 30 ngày, và độ dài mỗi episode

huấn luyện 365 ngày (mỗi vòng rollout gồm 1024 bước).

3.1.3 Thiết lập bài toán dưới dạng MDP đa tác tử

Tổng quan. Bài toán có 300 tác tử, ứng với 10 kho $\times$ 30 mặt hàng, nhưng chỉ có *một* mạng chính sách π_θ dùng chung: chỉ một bộ tham số được huấn luyện, không phải 300 mô hình riêng. Hình 3.3 cho thấy kiến trúc đó, và Bảng 3.2 liệt kê từng thành phần của mô hình học tăng cường kèm công thức và nơi cài đặt trong mã nguồn; các mục sau giải thích chi tiết từng thành phần.



Mỗi tác tử $A_{w,j}$: vai trò — quyết định lượng đặt cho mặt hàng j tại kho w; đầu vào — quan sát o_i^t 44 chiều; đầu ra — mức đặt $a_i^t \in \{0, \ldots, 5\}$. Không có coordinator và không trao đổi thông điệp trực tiếp; phối hợp gián tiếp qua (1) mức đầy kho $u_t^{(w)}$ do môi trường phát lại cho 30 tác tử cùng kho, (2) phạt tràn kho khi cùng tranh sức chứa, (3) trọng số dùng chung khi huấn luyện.

Hình 3.3: Kiến trúc đa tác tử: 300 tác tử (kho w, mặt hàng j) dùng chung một chính sách, tương tác gián tiếp qua sức chứa kho

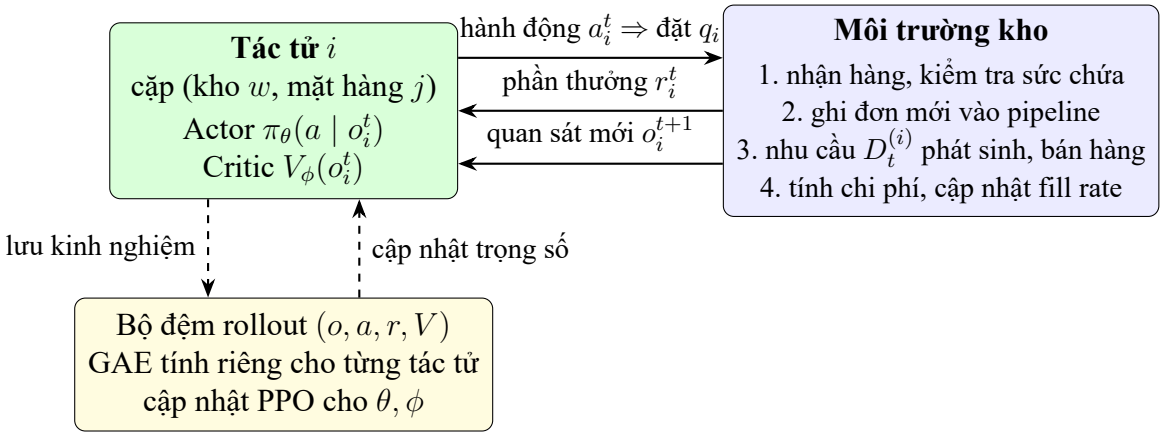
Tổng hợp các thành phần MDP. Bảng 3.2 đặt các khái niệm chung của học tăng cường cạnh thành phần cụ thể tương ứng trong hệ thống kho, và Hình 3.4 minh họa một vòng tương tác $s_t \to a_t \to r_t, s_{t+1}$ của một tác tử.

Phân rã nhiệm vụ và thiết kế tác tử. Trước khi hình thức hóa bài toán dưới dạng MDP đa tác tử, cần làm rõ vì sao hệ thống được phân rã thành đúng 300 tác tử theo cặp kho–mặt hàng, thay vì một cách phân rã khác.

Có hai hướng phân rã khả dĩ cho một hệ thống ra quyết định phân tán. Hướng thứ nhất là *phân rã theo chức năng* (functional decomposition): mỗi tác tử đảm nhận

Bảng 3.2: Các thành phần của mô hình học tăng cường trong bài toán tồn kho đa kho

Thành phần	**Định nghĩa trong đề tài**	**Công thức / mã nguồn**
Tác tử	Một cặp (kho w, mặt hàng j); 300 tác tử, cùng dùng một mạng chính sách	Mục 3.1.3; `env/inventory_env.py`
Môi trường	Mô phỏng 10 kho $\times$ 30 mặt hàng trên nhu cầu M5, một bước là một ngày, một episode là 365 ngày	`MultiWarehouseInventoryEnv`
Quan sát S	Vector $o_i^t \in [0,1]^{44}$ của từng cặp: tồn kho, vị thế tồn kho, cầu 7 ngày, hàng đang về, fill rate 30 ngày, quy mô, mức đầy kho, tỷ trọng trong kho, tín hiệu giảm giá, lịch	Bảng 3.3; `_get_observation()`
Hành động A	$a_i^t \in \{0,\dots,5\} \mapsto$ lượng đặt $q_i = \lceil m_k \bar{D}^{(i)} \bar{L} \rceil$, với $m = (0;\ 0{,}5;\ 1;\ 2;\ 3;\ 5)$	Công thức (3.1); `env/inventory_env.py`
Chuyển trạng thái P	Sáu bước trong một ngày; hai nguồn ngẫu nhiên là thời gian giao $L \sim \mathcal{U}\{1,2,3\}$ và nhu cầu thực tế $D_t^{(i)}$	Sáu bước ở trên; `step()`
Phần thưởng R	$r_i^t = -$(chi phí lưu kho + thiếu hàng + đặt hàng + tràn kho + phạt mức phục vụ) của riêng cặp i, chuẩn hóa theo cặp	Công thức (3.4), (3.8); `_calculate_reward()`
Chính sách π và hàm giá trị V	$\pi_\theta(a \mid o_i^t)$ và $V_\phi(o_i^t)$: hai mạng Actor, Critic tách rời, dùng chung trọng số cho 300 tác tử	Mục 3.3.1; `agents/ppo_agent.py`
Cập nhật chính sách	PS-IPPO: GAE tính riêng từng tác tử ($\lambda = 0{,}95$), chuẩn hóa lợi thế theo cặp, hàm mục tiêu PPO có cắt $\epsilon = 0{,}2$	Công thức (2.7), (2.8); Mục 3.3.2; `PPOAgent.update()`
Hệ số chiết khấu	$\gamma = 0{,}99$ (tầm nhìn hiệu dụng khoảng 100 ngày, dài hơn nhiều so với thời gian giao hàng)	Bảng 3.7



Hình 3.4: Vòng tương tác học tăng cường của một tác tử trong môi trường kho. Cả 300 tác tử chạy vòng này đồng thời mỗi ngày với cùng θ, ϕ.

một khâu xử lý trong quy trình ra quyết định — chẳng hạn một tác tử quan sát làm nhiệm vụ tổng hợp thông tin (dự báo nhu cầu, theo dõi tồn kho toàn mạng lưới) và một tác tử điều phối riêng biệt chuyển các tổng hợp đó thành quyết định đặt hàng cho từng mặt hàng. Hướng thứ hai là *phân rã theo điểm ra quyết định nghiệp vụ* (decision-point decomposition): mỗi tác tử tương ứng chính xác với một điểm mà tổ chức thực sự đưa ra một quyết định độc lập.

Khóa luận chọn hướng thứ hai. Lý do xuất phát trực tiếp từ cách vận hành kho trong thực tế: người phụ trách một mã hàng tại một kho là người duy nhất ra quyết định đặt hàng lại cho đúng mã hàng đó, dựa trên tồn kho, lượng hàng đang về và lịch sử bán của chính mặt hàng mình phụ trách — không tồn tại một "tác tử quan sát" trung gian tổng hợp thông tin của cả 300 mã hàng rồi một "tác tử điều phối" khác mới ra quyết định. Nếu phân rã theo chức năng, khóa luận sẽ phải tự thiết kế thêm một giao diện truyền thông giữa tác tử quan sát và tác tử điều phối — một thành phần không tồn tại trong bài toán nghiệp vụ gốc và sẽ làm thay đổi chính đối tượng nghiên cứu, đồng thời đặt ra câu hỏi ai chịu trách nhiệm quyết định cuối cùng khi hai tác tử bất đồng. Phân rã theo điểm ra quyết định nghiệp vụ tránh được vấn đề này: không gian hành động của mỗi tác tử ánh xạ trực tiếp vào một đòn bẩy vận hành có thật (lượng đặt hàng lại), và bài toán gán tín dụng (credit assignment) của mỗi tác tử gắn liền với đúng một chi phí mà quyết định của nó gây ra, không phải một chi phí tổng hợp từ nhiều quyết định của các tác tử khác.

Hệ quả trực tiếp là số lượng tác tử bằng đúng số cặp kho–mặt hàng, $N \times M = 300$, chứ không phụ thuộc vào số khâu xử lý được thiết kế trong hệ thống. Cách phân rã này cũng là tiền đề cho kiến trúc phi tập trung hoàn toàn được trình bày ở Mục 3.1.5: một khi đã phân rã theo đúng điểm ra quyết định thực tế, việc bổ sung một tác tử điều phối trung tâm sẽ mâu thuẫn với chính căn cứ phân rã ban đầu.

Bài toán được mô hình hóa dưới dạng Dec-POMDP [9] với 300 tác tử. Mỗi tác tử i (tương ứng cặp kho–mặt hàng) có:

Không gian quan sát $o_i^t \in \mathbb{R}^d$: vector quan sát cục bộ tại kỳ t bao gồm:

- Mức tồn kho hiện tại (on-hand inventory): $I_t^{(i)}$.
- Lượng hàng đang trên đường vận chuyển (in-transit): tổng các đơn hàng đã phát mà chưa nhập kho.
- Nhu cầu lịch sử w ngày gần nhất: $(D_{t-w}^{(i)}, \ldots, D_{t-1}^{(i)})$.
- Tỷ lệ đáp ứng nhu cầu trên cửa sổ trượt w ngày: $\mathrm{FR}_t^{(i,w)}$.
- Tỷ lệ sử dụng sức chứa của kho chứa tác tử i: $u_t^{(w(i))} = \sum_{j \in w(i)} I_t^{(j)} / W_{w(i)}$,

trong đó $w(i)$ là kho chứa cặp i và $W_{w(i)}$ là sức chứa của kho đó.

- Tỷ trọng tồn kho của chính cặp i trong kho: $I_t^{(i)} / \sum_{j \in w(i)} I_t^{(j)}$.
- Đặc trưng quy mô $\log(1+\bar{D}^{(i)})$ chuẩn hóa, cho phép mạng dùng chung phân biệt các mặt hàng có quy mô nhu cầu khác nhau.
- Tín hiệu giảm giá $g_t^{(i)} = \text{clip}\big(1 - p_t^{(i)}/\bar{p}^{(i)}, 0, 1\big)$, trong đó $p_t^{(i)}$ là giá bán của cặp i tại ngày t (trích từ `sell_prices.csv`) và $\bar{p}^{(i)}$ là giá bán trung bình của chính cặp đó, chỉ ước lượng trên miền huấn luyện. $g_t^{(i)} = 0$ khi giá bình thường hoặc tăng, tiến gần 1 khi giảm giá càng sâu. Giá bán trong M5 thay đổi theo tuần do khuyến mãi, và đợt giảm giá thường đi trước hoặc trùng với thời điểm nhu cầu tăng đột biến, nên đặc trưng này đóng vai trò chỉ báo sớm (leading indicator) của nhu cầu.
- Bối cảnh thời gian: thứ trong tuần (one-hot 7 chiều) và vector đặc trưng lịch 20 chiều trích từ `calendar.csv` (ba cờ SNAP theo bang CA, TX, WI, trong đó mỗi tác tử chỉ giữ cờ của bang chứa kho mình và hai cờ còn lại bằng 0; một cờ không có sự kiện, bốn loại sự kiện, mười hai tháng).

Tổng cộng vector quan sát của mỗi tác tử có $d = 44$ chiều. Hai thành phần $u_t^{(w(i))}$ và tỷ trọng tồn kho giữ vai trò đặc biệt: hàm phần thưởng có thành phần phạt tràn kho phụ thuộc vào tổng tồn kho của cả kho, nên nếu quan sát không chứa thông tin ở cấp kho thì tác tử bị phạt vì một đại lượng nó không quan sát được, và hàm giá trị không thể nhất quán. Đây cũng chính là kênh ghép nối duy nhất giữa các tác tử trong thiết kế phi tập trung của khóa luận (Mục 3.1.5).

Bảng 3.3 đối chiếu các biến trạng thái đặc trưng của bài toán tồn kho với cách biểu diễn trong vector quan sát 44 chiều.

Mô hình biết tín hiệu mạnh hay yếu bằng cách nào. Với tín hiệu liên tục như mức giảm giá $g_t^{(i)}$, độ mạnh nằm ngay trong giá trị quan sát (0 là giá bình thường, gần 1 là giảm sâu). Với các cờ nhị phân (SNAP, sự kiện, tháng) quan sát chỉ cho biết "có" hay "không": mạng không được cho biết mức tác động, mà tự học nó qua trọng số từ phần thưởng. Mức đóng góp của từng nhóm tín hiệu được đo bằng hai thí nghiệm ở Chương 4: xáo trộn từng nhóm đặc trưng (Bảng 4.13), cho biết chính sách đã học dựa vào nhóm nào; và huấn luyện lại sau khi bỏ một nhóm (ablation). Hai cách đo trả lời hai câu hỏi khác nhau nên cần đọc cùng nhau.

Bảng 3.3: Đối chiếu biến trạng thái, nhóm tín hiệu và cách mã hóa trong vector quan sát

Nhóm	Biến	Chiều	Mã hóa, thang đo	Ghi chú
Trạng thái của cặp	Tồn kho hiện tại	1	Chia cho số ngày nhu cầu, thang $[0, 1]$	
	Vị thế tồn kho (IP)	1	Tồn kho + hàng đang về, cùng thang	
	Hàng đang về (pipeline)	3	Lượng đến hạn theo từng ngày còn lại, cùng thang	Phản ánh gián tiếp thời gian giao L
	Tình trạng thiếu hàng	1	Fill rate cửa sổ trượt 30 ngày, $[0, 1]$	
	Đặc trưng quy mô	1	$\log(1 + \bar{D}^{(i)})$ chuẩn hóa	Giúp mạng dùng chung phân biệt SKU
	Mức sử dụng sức chứa kho	1	$u_t^{(w(i))} = \sum_{j \in w(i)} I_t^{(j)} / W_{w(i)}$	Tín hiệu cấp kho
	Tỷ trọng tồn kho trong kho	1	Tỷ trọng của cặp i trong tổng tồn kho kho, chuẩn hóa về $[0, 1]$	Tín hiệu cấp kho
Lịch sử nhu cầu	Nhu cầu 7 ngày gần nhất	7	Thang $\log(1 + \cdot)$, chuẩn hóa theo quy mô của cặp	
Tín hiệu ngoại sinh	Giá bán / khuyến mãi	1	*Liên tục*: $g_t^{(i)} \in [0, 1]$, mức giảm so với giá trung bình của chính cặp (ước lượng trên miền huấn luyện)	Càng gần 1 càng giảm sâu
	Ngày trong tuần	7	One-hot, $0/1$	
	Đặc trưng lịch	20	Cờ $0/1$: 3 SNAP (chỉ giữ cờ của bang chứa kho), 1 "không sự kiện", 4 loại sự kiện, 12 tháng	Mức tác động do mạng tự học qua trọng số
Không đưa vào	Nhu cầu hiện tại	0	—	Có chủ ý: quyết định đặt hàng xảy ra trước khi nhu cầu ngày đó phát sinh; đưa vào là rò rỉ thông tin tương lai
	Thời gian giao hàng L	0	—	Không quan sát trực tiếp L đã bốc (xem ghi chú bên dưới)

Ghi chú về thời gian giao hàng. Môi trường bốc thời gian giao hàng ngẫu nhiên $L \sim \text{Uniform}\{1, 2, 3\}$ cho từng đơn hàng, nhưng tác tử không quan sát trực tiếp giá trị L đã bốc. Thay vào đó, thông tin này được phản ánh gián tiếp qua vector pipeline 3 chiều. Đây là lựa chọn có chủ ý phù hợp với tinh thần Dec-POMDP: trong thực tế vận hành, nhà cung cấp cũng không cam kết chính xác ngày giao — tác tử chỉ biết hàng đang trên đường, không biết hôm nay hay ngày mai mới đến. Hạn chế này được ghi nhận rõ trong phân tích hạn chế thực nghiệm (Mục 4.6).

Không gian hành động $a_i^t \in \{0, 1, \ldots, K-1\}$: mỗi tác tử chọn một trong $K = 6$ mức đặt hàng rời rạc. Các mức này được định nghĩa tương đối theo quy mô nhu cầu của chính cặp i:

$$q_i(k) = \left\lceil m_k \cdot \bar{D}^{(i)} \cdot \bar{L} \right\rceil, \qquad \mathbf{m} = (0,\ 0{,}5;\ 1;\ 2;\ 3;\ 5), \tag{3.1}$$

trong đó $\bar{D}^{(i)}$ là nhu cầu trung bình một ngày của cặp i ước lượng trên miền huấn luyện và $\bar{L} = 2$ là thời gian giao hàng trung bình. Lựa chọn này xuất phát từ đặc điểm dữ liệu: $73{,}4\%$ số chuỗi M5 có nhu cầu dưới một đơn vị mỗi ngày, nên một thang mức đặt hàng tuyệt đối dùng chung sẽ khiến mức nhỏ nhất khác không đã tương đương hàng chục ngày nhu cầu đối với các mặt hàng bán chậm, trong khi lại quá nhỏ đối với các mặt hàng bán nhanh.

Bảng mức đặt hàng được ép tăng nghiêm ngặt theo k: mức k luôn lớn hơn mức $k-1$ ít nhất một đơn vị. Nếu không có ràng buộc này, phép làm tròn sẽ khiến nhiều hành động khác nhau cho cùng một lượng đặt hàng — với các cặp có $\bar{D}^{(i)}$ nhỏ, sáu mức có thể thu về chỉ còn hai giá trị phân biệt — và tác tử nhận các tín hiệu lợi thế mâu thuẫn cho những hành động trên thực tế là đồng nhất.

Không gian hành động chung của toàn hệ thống là tích Descartes $K^{300} = 6^{300}$, nhưng mỗi tác tử chỉ xử lý $K = 6$ hành động.

Hàm chuyển trạng thái diễn ra theo sáu bước theo đúng thứ tự thực thi trong môi trường mô phỏng:

1. **Ánh xạ hành động**: hành động $a_i^t \in \{0, \ldots, 5\}$ của mỗi tác tử được ánh xạ sang lượng đặt hàng $q_i(a_i^t)$ qua bảng mức tương đối (3.1).
2. **Nhận hàng từ pipeline**: hàng đang vận chuyển ở vị trí 0 của pipeline (đến hạn ngày t) được nhập kho.
3. **Thực thi ràng buộc sức chứa**: nếu lượng hàng mới về kho w vượt chỗ trống còn lại $W_w - \sum_{j \in w} I^{(j)}$, phần vượt của *hàng mới về* bị từ chối, chia theo tỷ trọng hàng về của từng mặt hàng theo (3.3); tồn kho cũ không bị

ảnh hưởng.

4. **Dịch pipeline và ghi đơn mới**: pipeline dịch trái một vị trí; đơn hàng mới được ghi vào vị trí $L-1$ với $L \sim \text{Uniform}\{1,2,3\}$ — đây là nguồn ngẫu nhiên thứ nhất.
5. **Phát sinh nhu cầu**: nhu cầu $D_t^{(i)}$ lấy từ chuỗi M5 thực tế — đây là nguồn ngẫu nhiên thứ hai. Bán $\min(I_t^{(i)}, D_t^{(i)})$; phần thiếu bị mất hoàn toàn (lost sales).
6. **Cập nhật lịch sử và cửa sổ fill rate**: ghi nhận nhu cầu và lượng đáp ứng vào lịch sử 7 ngày; cập nhật fill rate cửa sổ trượt 30 ngày. Tính phần thưởng r_i^t và chuyển sang $t+1$.

3.1.4 Ràng buộc sức chứa kho và cơ chế từ chối nhập hàng

Mỗi kho w có một sức chứa hữu hạn W_w dùng chung cho toàn bộ M mặt hàng đặt trong kho đó. Sức chứa được xác định theo số ngày nhu cầu mà kho có thể tích trữ:

$$W_w = \kappa \cdot \sum_{j=1}^{M} \bar{D}^{(w,j)}, \qquad \kappa = 5{,}0 \text{ ngày}, \tag{3.2}$$

trong đó $\bar{D}^{(w,j)}$ là nhu cầu trung bình một ngày của mặt hàng j tại kho w, ước lượng trên miền huấn luyện.

Điểm cần lưu ý là sức chứa được tính riêng cho từng kho, theo chính quy mô nhu cầu của kho đó, chứ không phải một hằng số dùng chung. Trong tập dữ liệu thực nghiệm, nhu cầu giữa các kho chênh lệch tới $4{,}5$ lần (Bảng 3.4); nếu áp một sức chứa chung, kho lớn nhất chỉ tích trữ được khoảng $1{,}4$ ngày nhu cầu trong khi thời gian giao hàng có thể lên tới ba ngày. Khi đó mục tiêu mức phục vụ 85% trở thành bất khả thi về mặt cấu trúc: không tồn tại chính sách nào tránh được đồng thời hình phạt tràn kho và hình phạt vi phạm mức phục vụ, và tín hiệu học suy biến thành nhiễu.

Bảng 3.4: Nhu cầu và sức chứa của từng kho trong cấu hình thực nghiệm

Kho	**Cầu/ngày**	W_w	**Kho**	**Cầu/ngày**	W_w
CA_3	223,0	1.114,6	TX_3	101,3	506,4
CA_1	121,2	606,1	CA_2	70,3	351,6
TX_2	114,0	570,1	TX_1	89,0	444,9
WI_2	51,5	257,4	WI_1	49,1	245,4
WI_3	99,2	495,9	CA_4	54,2	270,9

Ràng buộc được thực thi tại thời điểm *nhập hàng*. Gọi $A_t^{(i)}$ là lượng hàng của

cặp i đến hạn giao trong ngày t và $F_t^{(w)} = \max\big(0,\ W_w - \sum_{j \in w} I_{t-1}^{(j)}\big)$ là chỗ trống còn lại của kho w trước khi nhận hàng. Nếu tổng hàng mới về vượt chỗ trống, phần vượt bị từ chối nhập và chia cho từng mặt hàng theo tỷ trọng *hàng mới về* của mặt hàng đó:

$$O_t^{(i)} = A_t^{(i)} \cdot \max\left(0,\ 1 - \frac{F_t^{(w(i))}}{\sum_{j \in w(i)} A_t^{(j)}}\right). \tag{3.3}$$

Tồn kho cũ đang nằm hợp lệ trong kho không bao giờ bị giảm bởi bước này; chỉ mặt hàng vừa đặt nhiều mới chịu phần bị từ chối tương ứng. Phiên bản đầu của môi trường phân bổ phần vượt theo tỷ trọng *toàn bộ* tồn kho, khiến hàng cũ hợp lệ cũng bị loại bỏ không đúng — lỗi này đã được sửa và có kiểm thử hồi quy riêng. Cơ chế từ chối tại cửa nhập phản ánh đúng vận hành kho thực tế, khác với cách hủy hàng sau khi đã nhập — vốn khiến chi phí đặt hàng đã bỏ ra trở nên vô nghĩa và khó biện giải về mặt nghiệp vụ.

3.1.5 Cơ chế phối hợp giữa các tác tử

Khóa luận lựa chọn kiến trúc *phi tập trung hoàn toàn*: không có tác tử điều phối trung tâm, không có kênh truyền thông tường minh giữa các tác tử. Lựa chọn này là có chủ đích, xuất phát từ hai lý do.

Thứ nhất, về mặt nghiệp vụ, điểm ra quyết định đặt hàng lại trong vận hành kho là một mã hàng tại một kho: người phụ trách ngành hàng quyết định đặt bao nhiêu cho mặt hàng mình phụ trách, dựa trên tồn kho, lượng hàng đang về và lịch sử bán của chính mặt hàng đó. Việc phân rã thành 300 tác tử vì vậy đến từ cấu trúc bài toán chứ không phải từ mong muốn áp dụng mô hình đa tác tử.

Thứ hai, về mặt thuật toán, bổ sung một critic tập trung sẽ chuyển bài toán sang lớp phương pháp huấn luyện tập trung — thực thi phi tập trung (CTDE) như MAPPO [21], tức là thay đổi chính đối tượng nghiên cứu.

Sự phối hợp giữa các tác tử vì vậy diễn ra gián tiếp, qua hai kênh đã có sẵn trong thiết kế:

- Kênh quan sát: mỗi tác tử quan sát được tỷ lệ sử dụng sức chứa $u_t^{(w(i))}$ của kho mình thuộc về, nên biết khi nào kho sắp đầy.
- Kênh phần thưởng: hình phạt tràn kho theo công thức (3.3) được phân bổ theo tỷ trọng hàng mới về, nên tác tử đặt nhiều khi kho đã chật chịu phần phạt lớn hơn.

Ngoài hai kênh trên, việc chia sẻ trọng số θ là một kênh phối hợp ở thời điểm

huấn luyện: kinh nghiệm của mọi tác tử cùng cập nhật một chính sách, nên điều một cặp học được (ví dụ giảm lô hàng khi kho gần đầy) có tác dụng ngay với các cặp khác. Cần phát biểu chính xác quan hệ giữa "độc lập" và "chia sẻ": *mỗi tác tử ra quyết định riêng* từ quan sát riêng và nhận phần thưởng riêng, nhưng cả 300 tác tử *dùng chung một hàm chính sách* π_θ. Chia sẻ tham số không gộp 300 tác tử thành một tác tử trung tâm — không có thành phần nào nhìn thấy toàn bộ hệ thống hay quyết định thay cho tác tử khác.

Hình 3.3 thể hiện kiến trúc đa tác tử đầy đủ: các tác tử, vai trò, đầu vào, đầu ra, chính sách dùng chung, môi trường dùng chung và các kênh tương tác. Điểm đáng chú ý là không có khối điều phối (coordinator): việc tổng hợp thông tin cấp kho (cộng tồn kho của 30 mặt hàng để tính mức đầy $u_t^{(w)}$) do môi trường thực hiện và phát lại vào quan sát của từng tác tử trong kho đó, chứ không do một tác tử tổng hợp nào.

Lớp tổng hợp báo cáo cho người quản lý. Người quản lý cần nhìn được kết quả toàn cục chứ không thể đọc 300 quyết định rời rạc. Vì vậy ứng dụng mô phỏng có thêm một *lớp tổng hợp báo cáo* (reporting layer) nằm *sau* các tác tử: lớp này chỉ *đọc* quyết định và kết quả của 300 tác tử rồi tính chỉ số theo kho, theo ngành hàng và toàn mạng (chi phí, fill rate, tồn kho, số phiếu đặt hàng). Cần phân biệt "tổng hợp để báo cáo" với "điều phối để ra quyết định": lớp này không gửi thông tin ngược lại tác tử nào, không thay đổi quan sát, hành động hay phần thưởng, nên thuật toán không đổi và bài toán không trở thành huấn luyện tập trung (CTDE).

Bằng chứng thực nghiệm cho thấy tác tử đã học cách sử dụng tín hiệu sức chứa. Để giải mã hành vi ẩn, khóa luận quét lưới trạng thái trên một cặp đại diện: cố định tất cả chiều quan sát ở mức trung vị và chỉ thay đổi mức sử dụng sức chứa kho $u_t^{(w)}$ từ 20% lên 95%, rồi đọc lại phân phối hành động của chính sách. Kết quả: ngưỡng đặt hàng s (số ngày nhu cầu) gần như không đổi ($1{,}348$ ngày tại $u = 20\%$ so với $1{,}362$ ngày tại $u = 95\%$), nhưng mức đặt tối đa S giảm từ $5{,}65$ xuống $5{,}09$ ngày và 4 cặp ngừng đặt hàng hoàn toàn khi kho đạt 95% sức chứa. Nói cách khác, tác tử không thay đổi điều kiện kích hoạt đặt hàng mà chỉ thu hẹp lô hàng khi kho chật. Đây chính là dạng phối hợp nổi lên (emergent coordination) không được lập trình tường minh mà do tác tử tự học qua tín hiệu phần thưởng. Chính sách cổ điển như (s, S) không thể thực hiện hành vi này vì chúng không quan sát được trạng thái kho.

Bảng 3.5 tóm tắt đặc tả của một tác tử. Vì toàn bộ 300 tác tử đồng nhất về vai trò và chia sẻ chung một bộ trọng số, một bảng đặc tả duy nhất mô tả đầy đủ hệ thống.

Bảng 3.5: Đặc tả tác tử trong hệ thống đề xuất

Thành phần	**Nội dung**
Tác tử	Cặp (kho w, mặt hàng j); tổng cộng 300 tác tử đồng nhất
Vai trò	Quyết định lượng đặt hàng lại hằng ngày cho đúng một mặt hàng tại đúng một kho
Đầu vào	Vector quan sát cục bộ $o_i^t \in \mathbb{R}^{44}$
Quan sát	Tồn kho, vị thế tồn kho, nhu cầu 7 ngày gần nhất, hàng đang về theo từng ngày còn lại, fill rate cửa sổ 30 ngày, đặc trưng quy mô, tỷ lệ sử dụng kho, tỷ trọng tồn kho trong kho, thứ trong tuần, đặc trưng lịch
Nhiệm vụ	Tác vụ con của bài toán tổng "tối thiểu tổng chi phí vận hành toàn hệ thống dưới ràng buộc sức chứa và mức phục vụ"
Hành động	$a_i^t \in \{0, \ldots, 5\}$, ánh xạ sang lượng đặt hàng theo (3.1)
Chính sách	$\pi_\theta(a \mid o)$ — mạng Actor dùng chung trọng số θ cho mọi tác tử
Đầu ra	Yêu cầu đặt hàng $q_i(a_i^t)$ (phiếu đề nghị gửi phòng mua hàng, không đi tiếp tới nhà cung cấp)
Tương tác	Không truyền thông trực tiếp; phối hợp gián tiếp qua sức chứa kho dùng chung (Mục 3.1.5)

3.2 Thiết kế hàm phần thưởng

3.2.1 Phần thưởng phân rã cục bộ

Mỗi tác tử i nhận phần thưởng riêng dựa trên chi phí của chính cặp kho–mặt hàng mà nó quản lý, thay vì dùng chung phần thưởng toàn cục:

$$\begin{aligned} r_i^t = & -\left(c_{lk} \cdot I_t^{(i)+} + c_{th} \cdot U_t^{(i)} + c_{dh} \cdot \mathbb{1}(a_i^t > 0) + p_{tk} \cdot O_t^{(i)}\right) \\ & - \phi_{dv} \cdot c_{th} \cdot \bar{D}^{(i)} \cdot \max\left(\tau - \mathrm{FR}_t^{(i,w)},\ 0\right) \end{aligned} \tag{3.4}$$

trong đó:

- $I_t^{(i)+} = \max(I_t^{(i)}, 0)$: mức tồn kho dương.
- $U_t^{(i)} = \max(D_t^{(i)} - I_t^{(i)}, 0)$: lượng nhu cầu không được đáp ứng.
- $O_t^{(i)}$: lượng hàng tràn kho (phần vượt sức chứa).
- $\mathrm{FR}_t^{(i,w)}$: tỷ lệ đáp ứng trên cửa sổ trượt $w = 30$ ngày.
- $\bar{D}^{(i)}$: nhu cầu trung bình một ngày của cặp i, ước lượng trên miền huấn luyện (cùng đại lượng dùng trong bảng mức đặt hàng (3.1)).
- $\tau = 0{,}85$: ngưỡng mức phục vụ mục tiêu.

Ý nghĩa nghiệp vụ của từng thành phần. Chi phí lưu kho đại diện cho vốn bị giữ và chi phí mặt bằng; chi phí thiếu hàng là doanh thu và thiện chí khách hàng bị mất; chi phí đặt hàng là chi phí cố định mỗi lần phát đơn (xử lý đơn, vận chuyển); phạt tràn kho là hàng bị từ chối nhập vì kho đầy — tổn thất do đặt vượt khả năng chứa; phạt mức phục vụ thể hiện cam kết quản trị giữ tỷ lệ đáp ứng tối thiểu 85%. Hệ thống không có chuyển hàng giữa các kho nên hàm phần thưởng không chứa chi phí điều chuyển (Mục 1.3.3).

Vì sao phần thưởng luôn âm và cách đọc đúng. Vì $r_i^t = -(\text{tổng chi phí} + \text{phạt})$ và mọi thành phần chi phí đều không âm, phần thưởng *luôn* ≤ 0: phần thưởng bằng 0 chỉ đạt được khi không lưu kho, không thiếu hàng và không đặt hàng — điều không thể xảy ra khi có nhu cầu. Phần thưởng âm vì vậy *không* có nghĩa là mô hình kém; thứ cần quan sát là *xu hướng*: phần thưởng tăng dần về phía 0 tương đương với tổng chi phí giảm dần. Tương tự, không tồn tại một khoảng phần thưởng "chuẩn" như $[0, 1]$ hay $[-1, 1]$: độ lớn tuyệt đối phụ thuộc vào đơn giá chi phí, quy mô nhu cầu của dữ liệu, số tác tử và độ dài episode. Chẳng hạn, tổng phần thưởng một episode 365 ngày của 300 tác tử nằm ở bậc hàng triệu đơn vị âm (Mục 4.4.1). Vì thế khóa luận chỉ đánh giá phần thưởng *tương đối trong cùng bài toán*: so với chính sách khởi tạo ngẫu nhiên, so giữa các giai đoạn huấn luyện, và quy đổi về chi phí vận hành để so với các chính sách cổ điển trên cùng thang đo.

Hai cách định cỡ hình phạt mức phục vụ. Trong công thức (3.4), hình phạt vi phạm mức phục vụ ban đầu tỷ lệ với nhu cầu trung bình $\bar{D}^{(i)}$ của cặp (cấu hình `service_penalty_mode: demand`). Phần kiểm tra phần thưởng bằng thực nghiệm (Mục 4.5.6) cho thấy cách này khiến chính sách phân bổ mức phục vụ thấp hơn cho mặt hàng bán chậm. Vì vậy khóa luận dùng biến thể `normalized`, trong đó hình phạt được nhân với chính mẫu số chuẩn hóa của cặp:

$$\text{phạt}_i^t = \phi_{dv} \cdot \left(c_{th}\bar{D}^{(i)} + c_{dh}\right) \cdot \max\left(\tau - \text{FR}_t^{(i,w)},\ 0\right). \tag{3.5}$$

Sau khi chia cho mẫu số chuẩn hóa $c_{th}\bar{D}^{(i)} + c_{dh}$ (Mục 3.2.4), mọi cặp chịu *cùng một* mức phạt $\phi_{dv} \cdot \max(\tau - \text{FR}, 0)$ bất kể quy mô nhu cầu. Biến thể `normalized` là cấu hình của mô hình chính trong Chương 4; cấu hình `demand` chỉ còn dùng cho thí nghiệm loại trừ `abl_reward_cu`.

3.2.2 Vai trò của thành phần phạt fill rate

Thành phần $\phi_{dv} \cdot c_{th} \cdot \bar{D}^{(i)} \cdot \max(\tau - \mathrm{FR}_t^{(i,w)}, 0)$ bổ sung tín hiệu phạt ràng buộc (constraint penalty) theo tinh thần Lagrangian: thay vì chỉ phạt thiếu hàng tức thời (vốn có phương sai cao do nhu cầu gián đoạn), tỷ lệ đáp ứng trên cửa sổ trượt cung cấp đánh giá ổn định hơn về chất lượng phục vụ. Cần nhấn mạnh rằng hình phạt này không thuộc dạng chênh lệch thế năng của Ng và cộng sự [36], mà cố ý thay đổi cấu trúc phần thưởng của MDP gốc nhằm điều hướng chính sách tìm kiếm giải pháp thỏa mãn ràng buộc mức phục vụ kinh doanh.

Tích $c_{th} \cdot \bar{D}^{(i)}$ quy đổi độ hụt fill rate — một đại lượng không thứ nguyên trong $[0, 1]$ — về cùng thang đo tiền tệ với bốn thành phần chi phí còn lại (xấp xỉ chi phí thiếu hàng của một ngày hụt hoàn toàn ở mức nhu cầu trung bình của cặp i), để ϕ_{dv} đóng đúng vai trò một hệ số nhân thuần túy thay vì phải tự gánh cả việc quy đổi đơn vị. Cần lưu ý c_{th} ở đây luôn là *hằng số thiếu hàng chung* cho toàn hệ thống, không phải $c_{th}^{(i)}$ theo từng cặp dùng trong chi phí thiếu hàng thực (Mục 3.2.3): mục tiêu mức phục vụ 85% là một cam kết quản trị áp dụng đồng loạt, nên độ mạnh của hình phạt SLA không nên tỷ lệ theo đơn giá của riêng từng mặt hàng.

Cần phân biệt rõ hai thang chi phí trong báo cáo. **Thành phần phạt mức phục vụ $\phi_{dv}(\cdot)$ là tín hiệu định hướng học, không phải chi phí kế toán**: nó không được tính vào tổng chi phí vận hành báo cáo trong Chương 4. Mọi con số so sánh giữa các phương pháp đều dựa trên bốn thành phần chi phí thực phát sinh (lưu kho, thiếu hàng, đặt hàng, tràn kho), tương đương với chi phí mà doanh nghiệp thực sự phải trả. Khóa luận dùng thống nhất hai thuật ngữ:

$$C_t^{\text{vận hành}} = C_t^{\text{lưu kho}} + C_t^{\text{thiếu hàng}} + C_t^{\text{đặt hàng}} + C_t^{\text{tràn kho}} \tag{3.6}$$

là *tổng chi phí vận hành* (total operating cost), còn P_t là *hình phạt mức phục vụ* (service-level penalty), một thành phần định hình phần thưởng và không phải một loại chi phí thứ năm.

Ràng buộc mềm và kiểm tra tính khả thi. Mục tiêu nghiệp vụ được phát biểu dưới dạng bài toán có ràng buộc:

$$\min_{\pi} \ \mathbb{E}\Big[\sum_t C_t^{\text{vận hành}}\Big] \quad \text{thỏa mãn} \quad \mathrm{FR} \geq 85\%. \tag{3.7}$$

Khóa luận *không* giải trực tiếp bài toán có ràng buộc này bằng một biến thể PPO có ràng buộc. Trong huấn luyện, ràng buộc được triển khai dưới dạng *ràng buộc mềm*:

tác tử tối đa $\mathbb{E}\left[\sum_t -(C_t + P_t)\right]$, với P_t tăng khi fill rate trượt xuống dưới ngưỡng. Tính khả thi được kiểm tra ở khâu chọn mô hình: checkpoint IPPO được chọn là checkpoint có chi phí vận hành thấp nhất trên miền validation *trong số các checkpoint đạt* $\text{FR}_{\text{val}} \geq 85\%$; các chính sách cổ điển được tinh chỉnh theo đúng tiêu chí đó (Mục 4.3).

3.2.3 Các tham số chi phí

Bảng 3.6 liệt kê các tham số chi phí sử dụng trong thực nghiệm.

Bảng 3.6: Tham số chi phí trong môi trường mô phỏng

Thành phần	**Ký hiệu**	**Giá trị**
Chi phí lưu kho	c_{lk}	1,0 /đơn vị/ngày
Chi phí thiếu hàng	c_{th}	10,0 /đơn vị
Chi phí đặt hàng	c_{dh}	5,0 /lần đặt
Phạt tràn kho	p_{tk}	5,0 /đơn vị tràn
Phạt vi phạm mức phục vụ	ϕ_{dv}	3,0
Ngưỡng fill rate	τ	85%
Cửa sổ fill rate	w	30 ngày

Lưu ý rằng với bộ tham số chi phí $c_{th} = 10{,}0$ và $c_{lk} = 1{,}0$, tỷ số chi phí thiếu hàng ngầm định mức phục vụ chu kỳ lý thuyết $\alpha \approx 90{,}9\%$. Do đó, ràng buộc fill rate $\beta \geq 85\%$ có khả năng rơi vào trạng thái không có hiệu lực (non-binding) trong quá trình thực nghiệm mô phỏng. Đây là một giả thuyết cần kiểm chứng qua kết quả huấn luyện.

Khóa luận giữ nguyên bộ đơn giá ở Bảng 3.6 cho mọi thực nghiệm chính và không thêm một cấu hình chi phí phụ (chẳng hạn $c_{th} = 3$). Lý do là đơn giá chi phí trong M5 không có sẵn nên là giả định của đề tài; thay vì chọn thêm một bộ giá trị khác, mức độ phụ thuộc của kết luận vào đơn giá được kiểm tra bằng quét lưới nhiều bộ đơn giá (Mục 4.5.7). Giả định đơn giá là một giới hạn của khóa luận.

3.2.4 Chuẩn hóa phần thưởng theo từng cặp

Phần thưởng thô của các cặp chênh lệch nhau tới bốn bậc độ lớn: một mặt hàng bán $0{,}2$ đơn vị mỗi ngày phát sinh chi phí ngày ở mức đơn vị, trong khi mặt hàng bán 143 đơn vị mỗi ngày có thể phát sinh chi phí ngày lên tới hàng chục nghìn. Vì toàn bộ 300 tác tử dùng chung một mạng Critic, hàm giá trị phải khớp các mục tiêu trải trên dải rộng như vậy; khi đó hàm mất mát của Critic bị chi phối hoàn toàn bởi một nhúm cặp có quy mô lớn nhất, và gradient truyền về mạng bị lệch theo.

Khóa luận vì vậy chuẩn hóa phần thưởng của từng cặp theo một đơn vị chi phí

đặc trưng của chính cặp đó:

$$\tilde{r}_t^{(i)} = \frac{r_t^{(i)}}{c_{th} \cdot \bar{D}^{(i)} + c_{dh}}, \tag{3.8}$$

trong đó mẫu số là chi phí tương ứng với một ngày vận hành xấu nhất điển hình của cặp i: hết hàng trong suốt cả ngày, cộng thêm một lần phát đơn đặt hàng. Hằng số c_{dh} giữ cho mẫu số không tiến về không đối với những mặt hàng gần như không bán. Phép chuẩn hóa này chỉ thay đổi thang đo của tín hiệu học, không thay đổi thứ tự ưu tiên giữa các hành động của cùng một tác tử; toàn bộ chi phí báo cáo trong Chương 4 đều là chi phí gốc chưa chuẩn hóa.

Ảnh hưởng của thành phần này tới quá trình hội tụ được khảo sát tường minh trong Mục 4.5.2.

3.3 Kiến trúc mạng Actor–Critic chia sẻ tham số

3.3.1 Mạng SharedActorCritic

Toàn bộ 300 tác tử dùng chung một mạng nơ-ron duy nhất [18], gồm:

- Mạng Actor: hai lớp ẩn fully-connected, mỗi lớp 128 nơ-ron, hàm kích hoạt Tanh, kết thúc bằng một lớp tuyến tính xuất ra phân phối xác suất trên $K = 6$ mức đặt hàng (softmax).
- Mạng Critic: cấu trúc tương tự nhưng độc lập hoàn toàn về tham số, xuất ra giá trị $V(o_i)$.

Actor và Critic được cài đặt dưới dạng hai mạng tách rời, không dùng chung thân mạng. Quyết định này xuất phát từ một quan sát thực nghiệm cụ thể. Khi hai mạng dùng chung thân, độ lớn gradient sinh ra từ hàm mất mát giá trị vượt xa gradient sinh ra từ hàm mất mát chính sách — đo được trên chính môi trường của khóa luận là $28{,}13$ so với $0{,}096$, tức gấp khoảng 293 lần. Vì phép cắt chuẩn gradient (`clip_grad_norm_`) áp cho toàn bộ tham số của mạng, mọi gradient bị nhân với cùng một hệ số $0{,}5/28{,}13 \approx 0{,}018$, khiến tốc độ học hiệu dụng của Actor tụt khoảng 55 lần so với giá trị đặt. Hệ quả quan sát được là entropy của chính sách đứng yên ở gần giá trị $\ln K$ của phân phối đều trong suốt giai đoạn đầu — nghĩa là Actor hầu như không học. Tách hai mạng và cắt gradient riêng cho từng mạng là cách khắc phục triệt để; hiện tượng này được khảo sát tường minh trong Mục 4.5.3.

- Ghi chú cài đặt: khởi tạo trực giao (orthogonal) với hệ số $\sqrt{2}$ cho các lớp ẩn, $0{,}01$ cho lớp xuất của Actor và $1{,}0$ cho lớp xuất của Critic; chuẩn hóa

mục tiêu giá trị bằng trung bình và phương sai trượt.

Kiến trúc đầu vào nhận vector quan sát cục bộ o_i^t của một tác tử bất kỳ. Mỗi forward pass xử lý một batch gồm quan sát của nhiều tác tử cùng lúc. Số tham số cần học là hằng số, không phụ thuộc vào $N \times M$.

3.3.2 Quy trình huấn luyện IPPO

1. Thu thập dữ liệu (Rollout): Chạy $n_{\text{steps}} = 1024$ bước trong môi trường. Tại mỗi bước, tất cả 300 tác tử cùng chọn hành động, tổng cộng thu được $1024 \times 300 = 307.200$ mẫu (o_i, a_i, r_i, o_i') mỗi vòng rollout.
2. Tính GAE: Ước lượng lợi thế $\hat{A}_t^{(i)}$ cho từng tác tử i sử dụng công thức GAE (2.7) với $\gamma = 0{,}99$ và $\lambda = 0{,}95$.
3. Chuẩn hóa lợi thế theo từng cặp (per-pair advantage normalization): Chuẩn hóa $\hat{A}_t^{(i)}$ theo trung bình và độ lệch chuẩn tính riêng cho mỗi cặp kho–mặt hàng i, giúp các cặp có quy mô chi phí khác nhau đóng góp cân bằng vào gradient.
4. Cập nhật PPO: Thực hiện tối đa $E = 4$ epoch tối ưu hóa hàm mục tiêu clipped (2.8) trên toàn bộ dữ liệu rollout, với cơ chế dừng sớm khi độ lệch KL xấp xỉ vượt $1{,}5\times$ ngưỡng $\text{KL}_{\text{target}} = 0{,}02$. Tốc độ học Actor $\eta_a = 3 \times 10^{-4}$, Critic $\eta_c = 1 \times 10^{-3}$; cả hai được suy giảm tuyến tính theo tiến độ huấn luyện.
5. Lặp lại bước 1–4 trong 10.000 episode đối với mô hình chính (1.000 episode đối với các thực nghiệm ablation). Toàn bộ quy trình được lặp lại độc lập trên 3 hạt giống huấn luyện ($\texttt{seed} \in \{42, 1, 2\}$) nhằm kiểm tra độ tin cậy thống kê của kết quả theo khuyến nghị của Henderson và cộng sự [28] (Mục 4.3.1).

Bảng 3.7 tóm tắt các siêu tham số chính.

3.4 Thiết kế môi trường mô phỏng

Môi trường được xây dựng theo chuẩn Gymnasium [24], kế thừa giao diện từ OpenAI Gym [33], cung cấp các phương thức `reset()` và `step(action)` chuẩn.

`MultiWarehouseInventoryEnv` quản lý:

– Ma trận tồn kho $\mathbf{I} \in \mathbb{R}^{N \times M}$.

– Hàng đợi giao hàng cho mỗi cặp (tracking lead time).

Bảng 3.7: Siêu tham số huấn luyện

Nhóm	**Tham số**	**Giá trị**
Môi trường	$N \times M$ (số tác tử)	$10 \times 30 = 300$
	Episode length	365 ngày
	Lead time	$[1, 3]$ ngày
	Bội số mức đặt hàng (**m**)	$\{0;\ 0{,}5;\ 1;\ 2;\ 3;\ 5\}$
PPO	Rollout steps (n_{steps})	1024
	PPO epochs (E)	4
	Learning rate Actor	3×10^{-4}
	Learning rate Critic	1×10^{-3}
	γ	0,99
	λ_{GAE}	0,95
	Clip ϵ	0,2
	Total episodes	10.000 mô hình chính, 1.000 ablation ($\times 3$ hạt giống)
Mạng	Hidden layers (mỗi mạng) Actor / Critic	2×128 hai mạng tách rời
	Activation	Tanh

– Lịch sử nhu cầu và fill rate trượt.

– Hàm tính chi phí và phần thưởng (công thức 3.4).

Mỗi episode kéo dài 365 bước (tương đương 1 năm), phản ánh chu kỳ kinh doanh thực tế.

Khóa luận lựa chọn tự xây dựng môi trường `MultiWarehouseInventoryEnv` thay vì sử dụng các bộ thư viện benchmark sẵn có như OR-Gym [39] hay MABIM [41]. Lý do chính là các benchmark hiện hành chưa hỗ trợ sẵn cấu hình mạng lưới gồm 10 kho song song độc lập về nguồn cung kết hợp đồng thời với ràng buộc sức chứa kho dùng chung giữa 30 SKU và cơ chế phạt tỷ lệ đáp ứng trên cửa sổ trượt. Việc tự phát triển môi trường đảm bảo khả năng kiểm soát toàn diện các tham số mô phỏng và tính tương thích với mục tiêu nghiên cứu của đề tài.

CHƯƠNG 4. THỰC NGHIỆM VÀ ĐÁNH GIÁ KẾT QUẢ

4.1 Cấu hình thực nghiệm

4.1.1 Môi trường phần cứng và phần mềm

Môi trường thực nghiệm được triển khai trên nền tảng Python với các thư viện cốt lõi: PyTorch (cài đặt mạng Actor–Critic và thuật toán PPO), Gymnasium [24] (giao diện môi trường mô phỏng), NumPy và Pandas (xử lý dữ liệu M5 và tính toán thống kê), SciPy (kiểm định thống kê).

Quá trình huấn luyện của đợt thực nghiệm cuối chạy trên một GPU NVIDIA GeForce RTX 3050 Laptop (PyTorch, CUDA); phần mô phỏng môi trường vector hóa và các chính sách cổ điển chạy trên CPU. Kết quả báo cáo trong chương này dựa trên 3 lần huấn luyện độc lập (Mục 4.3.1), mỗi lần 10.000 episode, mất lần lượt 280, 243 và 219 phút (hạt giống 42, 1, 2), tổng cộng khoảng $12{,}4$ giờ. Mỗi thí nghiệm loại trừ 1.000 episode mất khoảng 22–34 phút. Khóa luận không đối chiếu thời gian huấn luyện với các công trình khác, vì khác bài toán, phần cứng và quy mô nên đó không phải là bằng chứng so sánh.

4.1.2 Nguồn dữ liệu và tiền xử lý

Khóa luận sử dụng hai tệp chính từ bộ dữ liệu M5 [2], [3]: `sales_train_evaluation.csv` chứa 30.490 chuỗi doanh số theo ngày (3.049 mặt hàng $\times$ 10 cửa hàng) trên 1.941 ngày, và `calendar.csv` chứa thông tin lịch, ngày lễ và các sự kiện trợ cấp thực phẩm SNAP.

Quy trình sàng lọc mặt hàng. Không phải mọi tổ hợp cửa hàng — mặt hàng đều tạo thành một bài toán đặt hàng lại. Trong bộ dữ liệu gốc có một tỷ lệ đáng kể các cặp mà cửa hàng trên thực tế không kinh doanh mặt hàng đó, thể hiện qua chuỗi doanh số gần như bằng không suốt toàn bộ giai đoạn. Đưa những chuỗi này vào tập huấn luyện không làm bài toán khó hơn mà chỉ bổ sung nhiễu vào gradient của mạng dùng chung. Khóa luận vì vậy chỉ giữ lại các mặt hàng có nhu cầu trung bình từ $0{,}2$ đơn vị mỗi ngày trở lên tại ít nhất 80% số cửa hàng, tính trên miền huấn luyện. Từ 3.049 mặt hàng ban đầu, 1.762 mặt hàng vượt ngưỡng; trong số đó $M = 30$ mặt hàng được chọn theo phương pháp phân tầng trên ba nhóm ngành hàng (Foods, Hobbies, Household) nhằm bảo đảm dải quy mô nhu cầu trải rộng.

Bảng 4.1 so sánh đặc trưng của tập thực nghiệm với bộ dữ liệu gốc. Điểm cần lưu ý là tỷ lệ ngày không phát sinh giao dịch vẫn ở mức $57{,}4\%$: quy trình sàng lọc loại bỏ các chuỗi thoái hóa nhưng không làm mất đi tính gián đoạn — vốn là đặc trưng khiến bài toán trở nên khó và là một trong những lập luận nền của khóa luận.

Bảng 4.1: Đặc trưng nhu cầu của tập thực nghiệm so với bộ dữ liệu gốc

Chỉ tiêu	**M5 gốc**	**Tập thực nghiệm**
Số chuỗi (cặp kho–mặt hàng)	30.490	300
Nhu cầu trung bình (đv/ngày)	$1{,}13$	$3{,}24$
Trung vị nhu cầu (đv/ngày)	$0{,}45$	$0{,}74$
Tỷ lệ ngày bằng không	$68{,}0\%$	$57{,}4\%$
Cặp có nhu cầu $< 0{,}1$ đv/ngày	—	$5/300$

Tách miền thời gian. Chuỗi 1.941 ngày được chia theo trục thời gian thành ba miền không chồng lấn, mỗi miền có một vai trò cố định (Bảng 4.2). Mọi đại lượng ước lượng từ dữ liệu — nhu cầu trung bình $\bar{D}^{(i)}$ dùng cho bảng mức đặt hàng, sức chứa kho, mẫu số chuẩn hóa phần thưởng — chỉ lấy từ miền huấn luyện. Miền kiểm tra không được dùng để chọn mô hình, chỉnh phần thưởng hay tinh chỉnh baseline.

Bảng 4.2: Ba miền dữ liệu và vai trò của từng miền

Miền	**Chỉ số ngày**	**Ngày lịch (số ngày)**	**Được phép dùng để**
Huấn luyện	$[0,\ 1050)$	29/01/2011–13/12/2013 (1.050)	Thu rollout và cập nhật PPO; ước lượng $\bar{D}^{(i)}$, sức chứa kho, mẫu số chuẩn hóa
Validation	$[1050,\ 1450)$	14/12/2013–17/01/2015 (400)	Chọn checkpoint IPPO; tinh chỉnh tham số baseline; so sánh các cấu hình huấn luyện
Kiểm tra (test)	$[1450,\ 1941)$	18/01/2015–22/05/2016 (491)	*Chỉ* báo cáo kết quả cuối; không dùng cho bất kỳ quyết định thiết kế nào

Ngày 0 là dòng đầu tiên của `calendar.csv` (29/01/2011). Các cửa sổ thời gian đặc trưng của mô hình gồm: lịch sử nhu cầu $w = 7$ ngày trong vector quan sát, fill rate trên cửa sổ trượt 30 ngày, mỗi episode huấn luyện dài 365 ngày cắt từ miền huấn luyện, và mỗi lần đánh giá chạy trọn 491 ngày của miền test. Cú sốc cầu nhân tạo ở Mục 4.5.5 bắt đầu ở ngày 1650 (06/08/2015) và kéo dài 28 ngày, tức nằm trong miền test.

Bảng 4.3: Cấu hình môi trường mô phỏng

Tham số	**Giá trị**
Số kho (N)	10
Số mặt hàng (M)	30
Số tác tử ($N \times M$)	300
Độ dài episode	365 ngày
Cửa sổ nhìn lại (w)	7 ngày
Lead time	Uniform$\{1, 2, 3\}$ ngày
Bội số mức đặt hàng (**m**)	$\{0;\ 0{,}5;\ 1;\ 2;\ 3;\ 5\}$
Sức chứa kho (κ)	5,0 ngày nhu cầu của từng kho
Ngưỡng fill rate (τ)	85%

4.1.3 Thiết lập kịch bản mô phỏng

Lựa chọn $\kappa = 5{,}0$ được xác định bằng thực nghiệm. Với $\kappa = 3{,}0$, mức phục vụ cao nhất mà bất kỳ chính sách nào đạt được chỉ là 79,5% — mục tiêu 85% trở thành bất khả thi. Với $\kappa \geq 12{,}0$, chi phí tràn kho bằng không: ràng buộc không còn hiệu lực và bài toán suy biến thành 300 bài toán độc lập, mất đi bản chất đa tác tử. Tại $\kappa = 5{,}0$, mục tiêu 85% khả thi trong khi chi phí tràn kho vẫn chiếm khoảng 1–2% tổng chi phí, nghĩa là ràng buộc thực sự có hiệu lực.

4.2 Phương pháp đối chứng

Hiệu năng của IPPO được so sánh với ba chính sách tồn kho cổ điển: EOQ [12], (s, S) [13] và Newsvendor [14].

Điều kiện so sánh công bằng. Ba yếu tố được kiểm soát. Thứ nhất, tham số của cả ba chính sách được tối ưu bằng tìm kiếm lưới trên chính môi trường mô phỏng, ở *miền validation*, theo *cùng tiêu chí* dùng để chọn checkpoint IPPO: chi phí vận hành thấp nhất trong số các cấu hình đạt fill rate $\geq 85\%$; nếu không cấu hình nào đạt, chọn cấu hình có fill rate cao nhất. Thứ hai, các chính sách cổ điển truy cập cùng một tập thông tin với tác tử IPPO: nhu cầu trung bình và độ lệch chuẩn ước lượng từ miền huấn luyện, cùng lịch sử nhu cầu gần nhất. Thứ ba, cả bốn phương pháp chịu cùng ràng buộc rời rạc hóa: lượng đặt hàng mong muốn được làm tròn về mức gần nhất trong sáu mức của công thức (3.1).

Mỗi chính sách cổ điển được đánh giá ở hai phiên bản. Phiên bản thứ nhất dùng *một bộ tham số chung* cho cả 300 cặp. Phiên bản thứ hai dùng *một bộ tham số riêng cho mỗi nhóm quy mô nhu cầu* (bốn nhóm: dưới 0,5; 0,5–2; 2–10; từ 10 đơn vị mỗi

ngày trở lên), được tìm bằng tìm kiếm theo tọa độ: xuất phát từ bộ tham số chung, lần lượt tối ưu tham số của từng nhóm trong khi giữ nguyên các nhóm khác, với cùng tiêu chí chi phí thấp nhất trong số cấu hình đạt fill rate $\geq 85\%$. Phiên bản theo nhóm là đối thủ mạnh hơn và sát với cách doanh nghiệp đặt chính sách theo nhóm hàng; nó được đưa vào để tránh so sánh IPPO — vốn điều chỉnh theo trạng thái của từng cặp — với một đối thủ bị giới hạn ở một bộ tham số duy nhất.

Ràng buộc thứ ba được giữ cho mọi phương pháp vì nó mô phỏng một ràng buộc vận hành chung: đơn bổ sung hàng được đặt theo một số lô chuẩn tỷ lệ với nhu cầu trung bình của mặt hàng, chứ không theo số lượng tùy ý. Nếu chỉ IPPO bị giới hạn ở sáu mức còn baseline được đặt số lượng liên tục, hai bên sẽ khác nhau cả về không gian hành động lẫn thuật toán, và so sánh không còn cô lập được tác động của thuật toán. Hệ quả là các baseline có thể kém hơn phiên bản đặt số lượng tùy ý của chúng; khóa luận ghi nhận đây là một giới hạn của phép so sánh (Mục 4.6).

Bảng 4.4 liệt kê tham số tối ưu tìm được.

Bảng 4.4: Tham số tối ưu của các chính sách đối chứng (một bộ tham số chung cho 300 cặp), tìm kiếm lưới trên miền validation

Chính sách	**Tham số tối ưu**
EOQ	$q_{\text{factor}} = 3{,}0$; $L = 4{,}0$
(s, S)	$\alpha = 0{,}70$; $q_{\text{factor}} = 1{,}0$; $L = 3{,}0$
Newsvendor	$CR = 0{,}60$; $L = 4{,}0$

Ở phiên bản theo nhóm, bộ tham số thay đổi theo quy mô nhu cầu; chẳng hạn q_{factor} của EOQ tăng từ $1{,}0$ (nhóm dưới $0{,}5$ đơn vị mỗi ngày) lên $3{,}0$ (nhóm từ 10 đơn vị mỗi ngày trở lên), và CR của Newsvendor là $0{,}60$; $0{,}75$; $0{,}85$; $0{,}60$ lần lượt theo bốn nhóm. Cả ba chính sách theo nhóm đều đạt fill rate trên miền validation sát ngưỡng 85% ($85{,}0$–$85{,}3\%$), tức tiêu chí chọn cấu hình rẻ nhất đẩy các baseline về sát biên ràng buộc.

Một quan sát đáng chú ý: tỷ số tới hạn lý thuyết của mô hình Newsvendor với bộ tham số chi phí đang dùng là $c_{th}/(c_{th} + c_{lk}) = 10/11 \approx 0{,}909$, nhưng tìm kiếm lưới trên miền validation cho $CR = 0{,}60$ — thấp hơn nhiều. Chênh lệch này không xuất phát từ sai lệch triển khai mà phản ánh hai khác biệt. Thứ nhất, tỷ số tới hạn cổ điển tối ưu cho *mức phục vụ chu kỳ* α trong bài toán một kỳ không có hàng đang về, trong khi môi trường ở đây là nhiều kỳ, có lượng hàng trên đường vận chuyển và ràng buộc sức chứa. Thứ hai, tiêu chí chọn tham số là chi phí vận hành thấp nhất trong số cấu hình đạt fill rate $\geq 85\%$, chứ không phải mức phục vụ cao nhất. Kết quả này phù hợp

với nhận định của Zipkin [15] rằng các chính sách cổ điển không còn tối ưu đã được chứng minh trong bối cảnh mất đơn hàng.

4.3 Giao thức đánh giá

4.3.1 Quy trình đánh giá

Chính sách IPPO được đánh giá ở chế độ tất định (chọn hành động có xác suất cao nhất) trên *toàn bộ quỹ đạo kiểm tra*: một lần chạy đi qua trọn 491 ngày của miền test ($[1450,\ 1941)$), với chuỗi nhu cầu cố định là nhu cầu thực tế của M5. Nguồn ngẫu nhiên duy nhất còn lại là thời gian giao hàng; lần chạy được lặp lại với 30 hạt giống ngẫu nhiên của thời gian giao hàng. Mọi chính sách chạy trên đúng cùng 30 hạt giống, nên mỗi hạt giống j cho một cặp quan sát $(C_j^{\text{IPPO}}, C_j^{\text{baseline}})$. Cách làm này thay cho giao thức cũ dùng 30 cửa sổ 365 ngày cắt từ một miền chỉ dài 491 ngày — các cửa sổ đó chồng lấn mạnh với nhau nên không thể coi là 30 quan sát độc lập.

Kiểm định thống kê được thực hiện trên hiệu số theo cặp $\Delta C_j = C_j^{\text{IPPO}} - C_j^{\text{baseline}}$: báo cáo hiệu trung bình kèm khoảng tin cậy 95%, kiểm định t theo cặp, kiểm định hạng có dấu Wilcoxon và hệ số ảnh hưởng theo cặp $d_z = \overline{\Delta C}/s_{\Delta C}$. Các lần đánh giá của IPPO ở những hạt giống huấn luyện khác nhau không được gộp chung với các lần đánh giá baseline như những quan sát độc lập.

Theo khuyến nghị của Henderson và cộng sự [28] và Agarwal và cộng sự [29] về việc không nên suy luận từ một lần huấn luyện duy nhất, IPPO được huấn luyện độc lập trên 3 hạt giống huấn luyện ($\texttt{seed} \in \{42, 1, 2\}$) với cùng ngân sách 10.000 episode mỗi hạt giống. Checkpoint của từng hạt giống được chọn trên miền validation theo tiêu chí ở Mục 3.2.2 (chi phí validation thấp nhất trong các lần đánh giá đạt fill rate $\geq 85\%$; được chọn ở episode 3.775, 4.950 và 5.250 tương ứng), rồi đánh giá riêng trên miền test theo quy trình trên. Kết quả được báo cáo *theo từng hạt giống* (mỗi hạt giống một kiểm định theo cặp), sau đó tổng hợp bằng trung bình và độ lệch chuẩn *giữa các hạt giống*, cùng số hạt giống cho kết luận có ý nghĩa thống kê. Mọi thí nghiệm loại trừ (Mục 4.5) dùng ngân sách 1.000 episode, được so với một lần chạy tham chiếu cùng hạt giống và cùng ngân sách, vì lịch giảm tốc độ học và hệ số entropy phụ thuộc vào tổng số episode; các thí nghiệm về thiết kế phần thưởng được lặp lại trên cả 3 hạt giống, còn các thí nghiệm loại trừ khác và thí nghiệm hold-out chỉ chạy một hạt giống (42).

4.3.2 Các chỉ số đánh giá

1. Tổng chi phí vận hành (công thức 3.6): tổng bốn thành phần chi phí thực phát sinh (lưu kho, thiếu hàng, đặt hàng, tràn kho) trên toàn quỹ đạo kiểm tra và 300 cặp. Thành phần phạt vi phạm mức phục vụ không được tính vào chỉ số này, vì nó là tín hiệu định hướng học chứ không phải chi phí kế toán.
2. Tỷ lệ đáp ứng nhu cầu (fill rate β): tỷ số giữa tổng lượng hàng bán được và tổng nhu cầu phát sinh trên cả episode.
3. Cơ cấu chi phí thành phần: dùng để nhận diện chiến lược mà mỗi phương pháp áp dụng.
4. Đường cong học: phần thưởng, fill rate, entropy của chính sách và explained variance của Critic qua các episode huấn luyện.

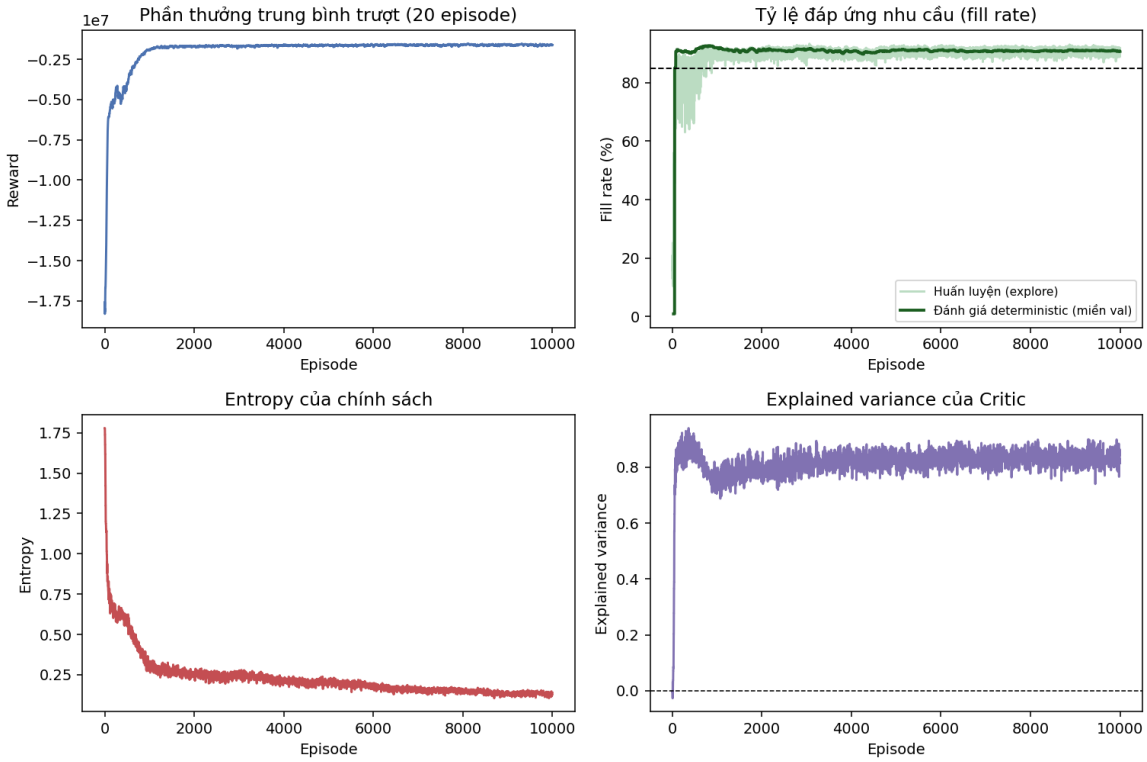
4.4 Kết quả thực nghiệm

4.4.1 Quá trình huấn luyện và tính hội tụ

Hình 4.1 trình bày bốn chỉ số theo dõi quá trình huấn luyện của hạt giống $\texttt{seed} = 42$, đại diện cho hình dạng đường cong học chung của cả 3 hạt giống (Mục 4.3.1).

Phần thưởng tăng từ $-17{,}59$ triệu ở episode đầu lên quanh $-1{,}61$ triệu (trung bình 200 episode cuối, dao động trong khoảng $-2{,}25$ đến $-1{,}48$ triệu), tức giảm khoảng 91% tổng chi phí so với chính sách khởi tạo ngẫu nhiên. Phần thưởng làm mượt đi vào khoảng 5% quanh giá trị cuối từ khoảng episode 1.200 và từ đó đi ngang: chi phí validation tốt nhất ở 20% episode cuối chỉ lệch $+1{,}6\%$ so với phần trước đó ở hạt giống 42 ($+0{,}2\%$ và $+1{,}3\%$ ở hai hạt giống còn lại), nên huấn luyện dài hơn 10.000 episode không còn cải thiện đáng kể. Đường cong không sụp đổ sau điểm hội tụ — đặc tính mong đợi của cơ chế mục tiêu bị chặn (clipped objective) trong PPO.

Hai chỉ số còn lại xác nhận rằng cả hai nửa của thuật toán đều thực sự học. Entropy của chính sách giảm từ $1{,}779$ — gần đúng giá trị $\ln 6 = 1{,}792$ của phân phối đều trên sáu hành động — xuống $0{,}138$ ở episode cuối ($0{,}128$ trung bình 100 episode cuối), nghĩa là chính sách đã định hình rõ rệt thay vì còn chọn ngẫu nhiên. Explained variance của Critic vượt $0{,}6$ sau khoảng 50 episode đầu, sau đó dao động trong khoảng $0{,}69$–$0{,}94$ (trung bình $0{,}84$ ở 200 episode cuối), nghĩa là hàm giá trị giải thích được phần lớn phương sai của phần thưởng tích lũy thực tế. Độ lệch KL xấp xỉ ở episode cuối là $2{,}4 \times 10^{-4}$, nằm sâu dưới ngưỡng $0{,}02$, cho thấy chính sách đã ổn định chứ



Hình 4.1: Diễn biến huấn luyện qua 10.000 episode (hạt giống 42): (a) phần thưởng tích lũy; (b) tỷ lệ đáp ứng nhu cầu; (c) entropy của chính sách; (d) explained variance của Critic

không còn dao động mạnh giữa các lần cập nhật.

Tỷ lệ đáp ứng khi huấn luyện vượt ngưỡng mục tiêu 85% lần đầu ở khoảng episode 85 (hạt giống 42), 79 (hạt giống 1) và 73 (hạt giống 2), và duy trì quanh 91% (trung bình 300 episode cuối: 90,9%, 91,2%, 91,0%). Hai hạt giống còn lại kết thúc huấn luyện với entropy 0,126 và 0,125 và explained variance 0,84 ở 200 episode cuối — cùng bậc độ lớn với hạt giống 42 — nên các kết luận trên không phụ thuộc vào một lần khởi tạo ngẫu nhiên cụ thể.

4.4.2 So sánh trực tiếp với các chính sách cổ điển

Bảng 4.5 trình bày kết quả trên miền test. IPPO là trung bình của 3 hạt giống huấn luyện, mỗi hạt giống đánh giá 30 lần; sáu chính sách đối chứng (ba bản dùng một bộ tham số chung và ba bản theo nhóm quy mô cầu) là tất định nên không đổi theo hạt giống huấn luyện, kết quả của chúng là trung bình trên đúng 30 lần đánh giá dùng chung hạt giống thời gian giao hàng với IPPO.

Ở phép so sánh trực tiếp này — không kiểm soát mức phục vụ — IPPO đạt tổng chi phí xấp xỉ các chính sách cổ điển tốt nhất chứ không vượt chúng ở mọi nơi.

Bảng 4.5: Kết quả trên miền test (trung bình; ± là độ lệch chuẩn giữa các hạt giống huấn luyện đối với IPPO, và giữa 30 lần đánh giá đối với baseline). Chi phí tính bằng đơn vị tiền của mô hình.

Phương pháp	Tổng chi phí	Fill rate	Lưu kho	Thiếu hàng	Đặt hàng	Tràn kho
IPPO (3 hạt giống)	2.055.442 ±14.358	90,9% ±0,33%	1.410.006	420.908	178.140	46.388
(s, S)	2.091.665 ±9.258	86,2% ±0,17%	1.233.832	639.569	151.834	66.430
(s, S) theo nhóm	2.048.883 ±8.117	85,9% ±0,16%	1.171.638	655.293	176.198	45.754
EOQ	2.500.198 ±11.329	89,5% ±0,14%	1.601.700	485.725	121.240	291.533
EOQ theo nhóm	2.074.745 ±7.209	85,8% ±0,08%	1.243.129	657.556	133.283	40.777
Newsvendor	2.062.190 ±8.241	87,4% ±0,14%	1.197.437	586.138	244.125	34.491
Newsvendor theo nhóm	2.022.942 ±7.972	85,8% ±0,14%	1.101.764	661.207	244.228	15.743

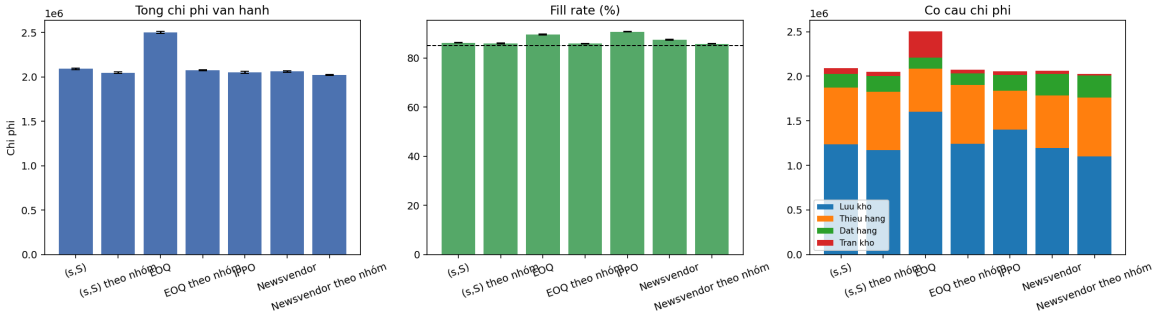
Tính trên trung bình 3 hạt giống, IPPO rẻ hơn (s, S) 1,7% và rẻ hơn EOQ 17,8%, rẻ hơn EOQ theo nhóm 0,9% và Newsvendor 0,3%, ngang (s, S) theo nhóm (+0,3%), và **đắt hơn** Newsvendor theo nhóm 1,6%. Các chênh lệch có dấu không nhất quán giữa các hạt giống ở (s, S) theo nhóm (từ $-0{,}3\%$ đến $+1{,}1\%$) và Newsvendor (từ $-0{,}9\%$ đến $+0{,}4\%$). Chỉ ba so sánh nhất quán trên cả 3 hạt giống: IPPO rẻ hơn (s, S) (từ $-1{,}0\%$ đến $-2{,}3\%$) và EOQ (từ $-17{,}2\%$ đến $-18{,}3\%$); và IPPO đắt hơn Newsvendor theo nhóm (từ $+1{,}0\%$ đến $+2{,}4\%$). Đổi lại, tỷ lệ đáp ứng của IPPO cao hơn: 90,9% so với 85,8–86,2% của bốn bản (s, S), (s, S) theo nhóm, EOQ theo nhóm và Newsvendor theo nhóm (khoảng 4–5 điểm phần trăm), 87,4% của Newsvendor và 89,5% của EOQ. Không chính sách nào rơi dưới ngưỡng 85%. Nói cách khác, ở điểm vận hành mà mỗi phương pháp tự chọn (baseline tối thiểu chi phí sát ràng buộc 85%, IPPO tối thiểu chi phí dưới ràng buộc đó nhưng dừng ở mức phục vụ cao hơn), IPPO không đạt ưu thế chi phí rõ rệt: nó đưa mức phục vụ lên cao hơn mà tổng chi phí vẫn ngang các baseline mạnh nhất.

Kiểm định theo cặp (30 lần đánh giá dùng chung hạt giống thời gian giao hàng, Phụ lục kết quả) xác nhận các kết luận trên về mặt thống kê. Ở hạt giống 42, IPPO rẻ hơn (s, S) 39.169 đơn vị mỗi lần đánh giá (khoảng tin cậy 95%: 34.404–43.933; $p = 1{,}7 \times 10^{-16}$; $d_z = -3{,}07$; rẻ hơn ở $30/30$ lần), và đắt hơn Newsvendor theo nhóm 29.554 đơn vị (khoảng tin cậy 95%: 26.140–32.967; $p = 4{,}3 \times 10^{-17}$; $d_z = +3{,}23$; không lần nào rẻ hơn). So với (s, S) theo nhóm ở cùng hạt giống, chênh lệch $+0{,}2\%$ không có ý nghĩa ($p = 0{,}088$). Vì đây là phép so sánh chưa kiểm soát mức phục vụ, phép so sánh

ở Mục 4.4.4 cần đọc cùng với bảng này để trả lời Câu hỏi nghiên cứu 1.

4.4.3 Phân tích cơ cấu chi phí

Hình 4.2 và cơ cấu chi phí trong Bảng 4.5 cho thấy IPPO học được một chiến lược khác về chất so với các chính sách cổ điển.



Hình 4.2: So sánh các phương pháp trên miền test (hạt giống huấn luyện 42): (a) tổng chi phí vận hành; (b) tỷ lệ đáp ứng nhu cầu; (c) cơ cấu chi phí thành phần

IPPO giữ mức tồn kho cao hơn — chi phí lưu kho 1.410.006 so với 1.233.832 của (s, S) (cao hơn 14,3%) và 1.101.764 của Newsvendor theo nhóm (cao hơn 28,0%) — và dùng mức tồn kho đó để cắt giảm chi phí thiếu hàng, từ 639.569 xuống 420.908 so với (s, S) (giảm 34,2%) và từ 661.207 so với Newsvendor theo nhóm (giảm 36,3%). Với (s, S), phần tiết kiệm ở thiếu hàng lớn hơn phần tăng thêm ở lưu kho nên tổng chi phí của IPPO thấp hơn; với các baseline theo nhóm, hai phần gần như bù nhau nên tổng chi phí xấp xỉ bằng nhau (Newsvendor theo nhóm thậm chí rẻ hơn 1,6%). Đây đúng là chiến lược "tích trữ nhiều hơn để giảm thiếu hàng" mà thành phần phạt mức phục vụ (Mục 3.2.2) khuyến khích: tác tử được thưởng vì mức phục vụ cao chứ không phải vì chi phí thấp nhất tuyệt đối.

Chiến lược này vẫn khả thi vì tác tử biết được giới hạn của mình. Chi phí tràn kho của IPPO là 46.388, tức khoảng 2,3% tổng chi phí — thấp hơn (s, S) (3,2%) và thấp hơn nhiều so với EOQ (11,7%), nhưng cao hơn Newsvendor (34.491) và Newsvendor theo nhóm (15.743). Điều này cho thấy tác tử duy trì mức tồn kho sát trần sức chứa mà không vượt qua một cách mất kiểm soát. Cần thận trọng khi gán điều này cho cơ chế phối hợp gián tiếp ở Mục 3.1.5: nó nhất quán với việc tác tử dùng tín hiệu $u_t^{(w(i))}$ trong vector quan sát, nhưng phân tích tầm quan trọng đặc trưng ở Mục 4.5.6 cho thấy chính sách đã học dựa rất ít vào tín hiệu cấp kho khi suy luận; khác biệt nằm ở chỗ thí nghiệm bỏ hẳn tín hiệu này khi huấn luyện (Mục 4.5.4) làm chi phí tăng hơn gấp đôi và huấn luyện không ổn định.

Về tần suất đặt hàng, IPPO phát trung bình 35.628 đơn trên một episode, nhiều hơn (s, S) (30.367 đơn), ngang (s, S) theo nhóm (35.240) và ít hơn đáng kể Newsvendor (48.825); EOQ phát ít đơn nhất (24.248). Như vậy mức phục vụ cao hơn của IPPO không đến từ việc đặt hàng ít hơn mà cũng không đến từ việc đặt dồn dập hơn các baseline mạnh nhất; nó đến từ việc giữ mức tồn kho đệm cao hơn, đúng với cơ cấu chi phí nêu trên.

4.4.4 So sánh ở cùng mức phục vụ

So sánh tổng chi phí giữa hai chính sách có mức phục vụ khác nhau là một phép so sánh không đầy đủ — đây chính xác là hạn chế của phép so sánh trực tiếp ở Mục 4.4.2. IPPO chịu hình phạt khi fill rate xuống dưới ngưỡng τ nên dịch chuyển tới mức phục vụ $90{,}65\%$ (hạt giống 42, dùng làm đại diện cho phân tích này), trong khi các chính sách đối chứng được tìm kiếm lưới với mục tiêu tối thiểu chi phí nên dừng lại ở $85{,}8$–$89{,}5\%$. Các phương pháp vì vậy nằm ở những điểm khác nhau trên đường đánh đổi chi phí — mức phục vụ, và bảng so sánh trực tiếp không kiểm soát yếu tố này nên chưa đủ căn cứ để kết luận phương pháp nào ưu việt hơn.

Để loại bỏ yếu tố này, khóa luận thực hiện thêm một so sánh ở cùng mức phục vụ: với mỗi chính sách đối chứng, tìm kiếm lưới được lặp lại với ràng buộc fill rate $\geq 90{,}15\%$ (bằng mức của IPPO trừ sai số cho phép $0{,}5$ điểm phần trăm), chọn cấu hình rẻ nhất trong số các cấu hình thỏa mãn, rồi đánh giá lại trên miền test.

Bảng 4.6: So sánh ở cùng mức phục vụ: cấu hình rẻ nhất của mỗi chính sách đối chứng đạt fill rate $\geq 90{,}15\%$ (hạt giống 42). Cột cuối: chênh lệch chi phí của IPPO so với baseline (âm là IPPO rẻ hơn).

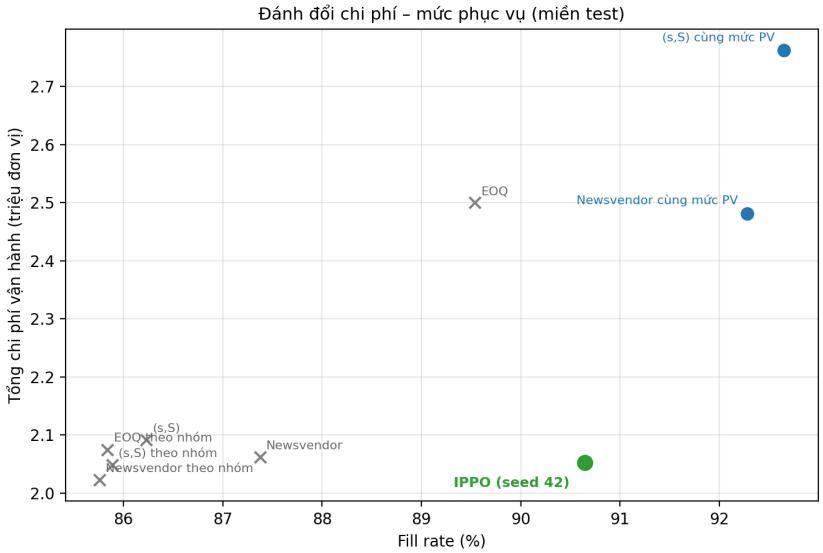
Phương pháp	**Tổng chi phí**	**Fill rate**	**Δ IPPO**	**Cấu hình**
IPPO	$2.052.496$	$90{,}65\%$	—	—
(s, S)	$2.762.256$	$92{,}65\%$	$-25{,}7\%$	$\alpha = 0{,}90$; $q_f = 0{,}5$; $L = 4{,}0$
Newsvendor	$2.481.517$	$92{,}28\%$	$-17{,}3\%$	$CR = 0{,}90$; $L = 4{,}0$
EOQ	không cấu hình nào đạt được mức phục vụ này			

Kết quả ở Bảng 4.6 cho thấy khi buộc phải đạt mức phục vụ cao cỡ IPPO, chi phí của (s, S) tăng từ $2{,}09$ triệu (Bảng 4.5) lên $2{,}76$ triệu, và của Newsvendor từ $2{,}06$ lên $2{,}48$ triệu; IPPO không cần thay đổi gì vì mức phục vụ $90{,}65\%$ vốn là điểm vận hành nó tự chọn. Ở cùng mức phục vụ, IPPO rẻ hơn (s, S) $25{,}7\%$ và Newsvendor $17{,}3\%$. Riêng EOQ không có cấu hình nào trong lưới tìm kiếm đạt mức phục vụ này — do cấu trúc lượng đặt hàng cố định không cho phép phản ứng với biến động nhu cầu.

Cần đọc các con số này với một cảnh báo. Lưới tham số của baseline thô nên

cấu hình được chọn vượt mục tiêu phục vụ: (s, S) đạt $92{,}65\%$ và Newsvendor $92{,}28\%$, cao hơn IPPO $2{,}0$ và $1{,}6$ điểm phần trăm và cao hơn ngưỡng $90{,}15\%$ hơn một điểm. Phần chi phí tăng thêm do nâng mức phục vụ vượt mức cần thiết bị tính vào khoảng cách này, nên mức $-25{,}7\%$ và $-17{,}3\%$ là *cận trên* của lợi thế chi phí của IPPO chứ không phải ước lượng chính xác; một lưới mịn hơn quanh ngưỡng $90{,}15\%$ sẽ thu hẹp khoảng cách này. Phát biểu chắc chắn hơn là: để lên tới mức phục vụ $\approx 90\%$, các baseline phải trả một khoản chi phí lớn hơn IPPO một cách rõ rệt, trong khi ở mức 85–86% chúng ngang IPPO về chi phí (Mục 4.4.2). Kết luận về việc phương pháp nào "tốt hơn" vì thế phụ thuộc căn bản vào việc có kiểm soát mức phục vụ hay không, và khóa luận coi phép so sánh ở cùng mức phục vụ — kèm cảnh báo trên — là căn cứ phù hợp hơn để trả lời Câu hỏi nghiên cứu 1, vì nó loại bỏ được sai lệch do các phương pháp tối ưu cho hai mục tiêu khác nhau (Mục 1.3.2).

Hình 4.3 biểu diễn trực quan cả hai phép so sánh trên cùng một mặt phẳng chi phí — mức phục vụ.



Hình 4.3: Đường đánh đổi chi phí — mức phục vụ (hạt giống 42). Dấu chữ thập xám: cấu hình tối thiểu chi phí của các baseline; dấu tròn xanh dương: baseline chỉnh cùng mức phục vụ; chấm xanh lá: IPPO

Nguyên nhân của khoảng cách này nằm ở cơ chế điều chỉnh của các chính sách cổ điển. Chúng chỉ có một cơ chế duy nhất để nâng mức phục vụ: nâng tham số an toàn — tăng α hoặc CR — và tham số đó áp dụng đồng loạt cho cả 300 cặp. Hệ quả là tồn kho tăng ở mọi mặt hàng, kể cả những mặt hàng vốn đã đạt mức phục vụ tốt. IPPO điều chỉnh theo từng trạng thái quan sát được, do đó có thể nâng mức phục vụ

ở những cặp có nhu cầu cấp thiết mà không tích trữ thừa ở những cặp không cần.

4.5 Phân tích chuyên sâu

4.5.1 Hiệu năng theo nhóm quy mô nhu cầu (Câu hỏi 2)

Một bộ trọng số duy nhất điều khiển đồng thời 300 cặp có quy mô nhu cầu trải từ dưới 0,1 đến gần 143 đơn vị mỗi ngày. Tỷ lệ đáp ứng 90,6% ở cấp hệ thống là một con số có trọng số theo nhu cầu, nên nó chưa cho biết chính sách có hoạt động đồng đều trên mọi nhóm quy mô hay không. Để trả lời, 300 cặp được chia thành bốn nhóm theo $\bar{D}^{(i)}$ và các chỉ số được tính riêng cho từng nhóm (Bảng 4.7, hạt giống 42). Chi phí trong bảng là chi phí cục bộ trung bình mỗi cặp mỗi episode — cùng đại lượng mà tác tử thực sự tối ưu hóa, công thức (3.4) — nên bao gồm cả thành phần định hướng mức phục vụ ϕ_{dv}, khác với chi phí vận hành thuần túy đã báo cáo ở Bảng 4.5.

Bảng 4.7: Hiệu năng theo nhóm quy mô nhu cầu trên miền test (hạt giống 42). Chi phí cục bộ (gồm thành phần định hướng mức phục vụ) tính trung bình cho mỗi cặp trong một episode.

Nhóm ($\bar{D}$, đv/ngày)	**Số cặp**	**Fill rate**		**Chi phí/cặp**	
		IPPO	(s, S)	**IPPO**	(s, S)
Rất thấp ($< 0{,}5$)	105	74,2%	84,3%	3.164	2.979
Thấp (0,5–2)	126	83,2%	87,0%	4.235	4.185
Trung bình (2–10)	54	89,5%	85,7%	9.618	10.837
Cao (≥ 10)	15	95,8%	86,4%	57.542	70.926

Trên hai nhóm có nhu cầu từ 2 đơn vị mỗi ngày trở lên, IPPO đạt kết quả tốt hơn (s, S) trên *cả hai* tiêu chí: fill rate cao hơn 3,8 điểm phần trăm ở nhóm trung bình và 9,4 điểm ở nhóm cao, đồng thời rẻ hơn 11,2% ở nhóm trung bình và 18,9% ở nhóm cao. Các cặp có nhu cầu lớn đóng góp phần lớn tổng chi phí hệ thống, nên đây là nơi tạo ra phần lớn lợi thế chi phí của IPPO so với (s, S) ở Mục 4.4.2.

Ngược lại, ở hai nhóm nhu cầu thấp và rất thấp, IPPO vừa đạt mức phục vụ thấp hơn (s, S) (rất thấp: 74,2% so với 84,3%, chênh 10,1 điểm; thấp: 83,2% so với 87,0%) vừa có chi phí cục bộ nhỉnh hơn (6,2% và 1,2%). Ở cấp từng cặp, 28,7% số cặp của IPPO có fill rate dưới 85% (phân vị 10% là 71,2%), trong khi (s, S) cùng mức phục vụ chỉ có 5,7% (Mục 4.5.6). Cả hai nhóm này đều nằm dưới ngưỡng 85% ở IPPO hoặc sát ngưỡng, nên mục tiêu mức phục vụ *không* được đáp ứng đồng đều trên mọi mặt hàng.

Diễn giải của hiện tượng này mang tính kinh tế nhiều hơn là kỹ thuật. Với một mặt hàng bán 0,3 đơn vị mỗi ngày, chi phí một lần phát đơn ($c_{dh} = 5$) xấp xỉ chi phí

thiếu hàng của gần hai ngày bán ($c_{th} \cdot \bar{D} = 3$ mỗi ngày). Việc duy trì mức phục vụ cao cho nhóm này đòi hỏi đặt hàng thường xuyên với lô rất nhỏ, và tổng chi phí phát sinh vượt phần tổn thất do thiếu hàng. Tác tử — vốn tối thiểu hóa chi phí — có xu hướng hạ mức phục vụ ở nhóm bán chậm, điều này phù hợp với mục tiêu tối ưu hóa chi phí mà thuật toán huấn luyện theo đuổi. Nói cách khác, chênh lệch không phải là dấu hiệu chia sẻ tham số thất bại ở nhóm bán chậm, mà là hệ quả của việc hai phương pháp theo đuổi hai mục tiêu khác nhau: (s, S) được tham số hóa quanh một mức phục vụ mục tiêu, còn IPPO tối thiểu hóa chi phí dưới ràng buộc mức phục vụ ở cấp hệ thống.

Hệ quả cần ghi nhận nằm ở cách định cỡ thành phần phạt mức phục vụ. Mô hình chính dùng hình phạt chuẩn hóa (`service_penalty_mode: normalized`, công thức 3.5), trong đó sau khi chia cho mẫu số chuẩn hóa mọi cặp chịu cùng một mức phạt $\phi_{dv} \cdot \max(\tau - \text{FR}, 0)$ bất kể quy mô nhu cầu. Cách định cỡ này giảm nhưng không loại bỏ sự thiên lệch: ở cùng ngân sách 1.000 episode và cùng hạt giống, tỷ lệ cặp có fill rate dưới 85% là $28{,}3\%$ với hình phạt chuẩn hóa (`abl_ref`) so với $33{,}0\%$ với hình phạt tỷ lệ theo nhu cầu (`abl_reward_cu`); mô hình chính 10.000 episode đạt $28{,}7\%$. Khi đó mặt hàng bán chậm vẫn là nơi chi phí đặt hàng cố định lớn so với phần tổn thất được tránh, và fill rate hệ thống là trung bình có trọng số theo khối lượng, nên tác tử vẫn đạt mục tiêu chung bằng cách phục vụ tốt nhóm bán nhanh và hạ mức phục vụ ở nhóm bán chậm (Mục 4.5.6 định lượng hiện tượng này trên phân bố fill rate của từng cặp). Nếu bài toán nghiệp vụ yêu cầu bảo đảm mức phục vụ tối thiểu cho từng mặt hàng, cần chuyển mục tiêu thành ràng buộc cứng ở cấp cặp (chẳng hạn nhân tử Lagrange riêng cho từng cặp, Mục 5.3). Đây là một hạn chế thiết kế đã xác định, không xuất phát từ sai lệch triển khai.

Mặt hàng chưa gặp khi huấn luyện (hold-out). Để kiểm tra riêng khả năng áp dụng cho mặt hàng chưa từng xuất hiện trong huấn luyện, một mô hình được huấn luyện chỉ trên 24 mặt hàng (1.000 episode, một hạt giống) rồi đánh giá trên 6 mặt hàng bị giữ lại ($6 \times 10 = 60$ cặp). So với mô hình chính của hạt giống 42 — đã huấn luyện trên cả 30 mặt hàng — chi phí của mô hình hold-out trên 60 cặp này là 293.002 (fill rate $86{,}3\%$) so với 292.774 ($86{,}8\%$), chênh $+0{,}1\%$ và không có ý nghĩa thống kê ($p = 0{,}67$). Không có dấu hiệu suy giảm khi gặp mặt hàng mới. So với baseline, IPPO trên các mặt hàng chưa gặp rẻ hơn (s, S) $6{,}2\%$ và EOQ $28{,}4\%$ nhưng đắt hơn EOQ theo nhóm $1{,}2\%$, Newsvendor $1{,}3\%$ và Newsvendor theo nhóm $3{,}3\%$ (đều có ý nghĩa thống kê). Có hai lưu ý: cả sáu baseline đều có fill rate dưới 85% trên tập này ($79{,}5$–$83{,}2\%$) nên so chi phí không cùng mức phục vụ; và kết quả chỉ trên một hạt giống với 6 mặt hàng.

Phép so sánh "chưa gặp rẻ hơn 6,1% so với mô hình đã gặp cùng 1.000 episode" không nên diễn giải là mô hình học tốt hơn từ ít dữ liệu, vì mô hình đối chiếu 1.000 episode đơn giản là chưa hội tụ bằng mô hình chính (10.000 episode).

4.5.2 Thiết kế tín hiệu phần thưởng (Câu hỏi 3)

Thiết kế. Câu hỏi 3 được trả lời bằng hai thí nghiệm loại trừ, cùng mạng, cùng tốc độ học, cùng ngân sách 1.000 episode và cùng môi trường như lần chạy tham chiếu (`abl_ref`), và mỗi thí nghiệm được lặp lại trên 3 hạt giống (42, 1, 2) để so với lần tham chiếu cùng hạt giống:

- **Phần thưởng toàn cục** (`reward_mode: global`): mọi tác tử nhận cùng một tín hiệu là tổng phần thưởng của cả mạng lưới R_t^{team} (công thức 2.9), chia cho tổng mẫu số chuẩn hóa của các cặp để giữ cùng thang đo. Thí nghiệm này so sánh trực tiếp phần thưởng cục bộ với phần thưởng toàn cục.
- **Không chuẩn hóa theo cặp** (`normalize_reward_per_pair: false`): phần thưởng cục bộ của mọi cặp được chia cho cùng một hằng số, nên cặp có nhu cầu lớn chi phối tín hiệu học.

Hai thí nghiệm trả lời hai khía cạnh khác nhau của cùng câu hỏi thiết kế phần thưởng và không thay thế cho nhau.

Bảng 4.8: Thiết kế phần thưởng (1.000 episode mỗi lần chạy): tổng chi phí trên miền test, fill rate và chênh lệch so với lần tham chiếu cùng hạt giống. Dấu *: kiểm định theo cặp có ý nghĩa ($p < 0{,}05$).

Lần chạy	Hạt giống	Tổng chi phí	Fill rate	Δ tham chiếu
Tham chiếu	42	2.183.787	91,4%	—
	1	2.149.861	91,2%	—
	2	2.179.541	91,4%	—
Phần thưởng toàn cục	42	7.711.359	86,0%	+253,1%*
	1	11.819.736	81,3%	+449,8%*
	2	14.293.080	81,2%	+555,8%*
Không chuẩn hóa theo cặp	42	8.972.578	86,8%	+310,9%*
	1	5.716.403	87,7%	+165,9%*
	2	5.798.585	87,6%	+166,0%*

Kết quả. Cả hai biến thể đều kém hơn rõ rệt lần tham chiếu ở cả 3 hạt giống (Bảng 4.8): phần thưởng toàn cục làm tổng chi phí tăng trung bình 419,6% và không chuẩn hóa theo cặp tăng trung bình 214,3%, trong khi dao động chi phí giữa 3 hạt

giống của lần tham chiếu chỉ là 1,6%. Hai hạt giống 1 và 2 của phần thưởng toàn cục thậm chí không đạt fill rate 85% trên miền validation, nên checkpoint của chúng chỉ là mô hình dự phòng và chỉ có giá trị định tính. Entropy cuối huấn luyện của hai biến thể vẫn cao (0,74 với phần thưởng toàn cục và 0,48 với không chuẩn hóa, ở hạt giống 42, so với 0,19 của tham chiếu), nghĩa là chính sách còn gần ngẫu nhiên hơn nhiều.

Chỉ số đáng chú ý nhất là explained variance của Critic ở hạt giống 42: 1,00 khi không chuẩn hóa và 0,96 với phần thưởng toàn cục, so với 0,72 của tham chiếu. Critic giải thích *gần như toàn bộ* phương sai của return, nhưng chính sách lại học kém hơn nhiều. Điều này khớp với lập luận thiết kế ở Mục 3.2.4: khi return của các cặp chênh nhau nhiều bậc độ lớn, phương sai tổng bị chi phối bởi vài cặp nhu cầu lớn. Critic chỉ cần khớp tốt các cặp đó là đạt explained variance cao, trong khi lợi thế (advantage) của đa số cặp bán chậm gần như chỉ còn là nhiễu. Kết quả ủng hộ giả thuyết của Câu hỏi 3 rằng phần thưởng cục bộ có chuẩn hóa theo cặp là cần thiết trong cấu hình này. Giới hạn: các lần chạy chỉ dài 1.000 episode, và entropy còn cao cho thấy các biến thể có thể chỉ học chậm hơn chứ chưa chắc kém hơn ở trạng thái hội tụ; khóa luận chưa huấn luyện chúng tới 10.000 episode.

4.5.3 Vai trò của việc tách Actor và Critic

Bằng chứng ban đầu cho quyết định tách Actor và Critic đến từ phiên bản phát triển đầu tiên của môi trường (dùng chung thân mạng), trong đó gradient của hàm mất mát giá trị lớn gấp khoảng 293 lần gradient chính sách và entropy đứng yên gần $\ln 6 = 1{,}792$ trong giai đoạn đầu (Mục 3.3.1). Quan sát đó đến từ một phiên bản môi trường khác nên chưa phải thí nghiệm có kiểm soát; thí nghiệm `abl_trunk` bổ sung điều này trên đúng cấu hình hiện tại (300 cặp, 44 chiều): Actor và Critic chung thân mạng, một optimizer, và tắt chuẩn hóa giá trị (value normalization). Kết quả (một hạt giống, 1.000 episode): tổng chi phí 2.471.782, cao hơn lần tham chiếu 13,2% (có ý nghĩa thống kê) và cao hơn (s, S) 18,2%, fill rate chỉ 85,7%, và 20% episode cuối vẫn không đạt 85% trên miền validation. Mức chênh 13,2% lớn hơn nhiều dao động giữa hạt giống (1,6%), nhưng thí nghiệm thay đồng thời hai thành phần (chung thân mạng và tắt value normalization) nên chưa tách được đóng góp của riêng việc tách hai mạng.

4.5.4 Các thí nghiệm loại trừ khác

Các thí nghiệm sau chạy 1.000 episode, một hạt giống (42), so với lần tham chiếu `abl_ref` (Bảng 4.9). Vì mỗi thí nghiệm chỉ có một hạt giống, chênh lệch nhỏ

hơn dao động $1{,}6\%$ giữa hạt giống của lần tham chiếu (Mục 4.5.2) chưa đủ để kết luận.

Bảng 4.9: Thí nghiệm loại trừ (1.000 episode, hạt giống 42). Δ là chênh lệch tổng chi phí so với `abl_ref`; $\Delta(s,S)$ là chênh lệch so với (s,S) trong cùng môi trường. Dấu *: có ý nghĩa thống kê; †: môi trường đánh giá khác tham chiếu nên đọc cột $\Delta(s,S)$.

Lần chạy	Thay đổi	Tổng chi phí	Fill	Δ	$\Delta(s,S)$
`abl_ref`	Mốc: cấu hình chính, 1.000 ep	2.183.787	91,4%	—	$+4{,}4\%^*$
`abl_reward_cu`	Phạt SLA kiểu cũ	2.129.529	90,8%	$-2{,}5\%^*$	$+1{,}8\%^*$
`abl_trunk`	Chung thân, tắt value norm	2.471.782	85,7%	$+13{,}2\%^*$	$+18{,}2\%^*$
`abl_nocal`	Bỏ đặc trưng lịch	2.149.459	91,1%	$-1{,}6\%^*$	$+2{,}8\%^*$
`abl_nowh`	Bỏ tín hiệu cấp kho	5.273.773	91,2%	$+141{,}5\%^*$	$+152{,}1\%^*$
`abl_event`	Thêm đặc trưng sự kiện tới	2.166.864	90,9%	$-0{,}8\%^*$	$+3{,}6\%^*$
`abl_warm`	Warm-start lịch sử cầu	2.064.993	90,8%	$-5{,}4\%^{*\dagger}$	$-1{,}1\%^*$

Đọc kết quả một cách thận trọng. Bỏ đặc trưng lịch ($-1{,}6\%$) và thêm đặc trưng sự kiện sắp tới ($-0{,}8\%$) đều nằm trong dao động giữa hạt giống, nên không có bằng chứng rằng các đặc trưng lịch giúp ích — nhất quán với việc chúng đóng góp ít ở phân tích tầm quan trọng đặc trưng (Mục 4.5.6), và đặc trưng sự kiện sắp tới không khắc phục được điểm yếu mùa lễ. Phạt SLA kiểu cũ rẻ hơn $2{,}5\%$, chỉ hơi vượt dao động giữa hạt giống ($1{,}6\%$) nên cần nhiều hạt giống hơn để kết luận. Warm-start lịch sử cầu rẻ hơn $5{,}4\%$ nhưng môi trường đánh giá khác nên chỉ nên đọc theo cột $\Delta(s,S)$ ($-1{,}1\%$). Kết quả nổi bật nhất là bỏ tín hiệu cấp kho: tổng chi phí tăng $141{,}5\%$ và 20% episode cuối không đạt 85% trên miền validation, tức huấn luyện không ổn định. Điều này mâu thuẫn bề ngoài với việc xáo trộn tín hiệu này ở bước suy luận gần như không đổi chi phí (Mục 4.5.6); hai thí nghiệm đo hai việc khác nhau: tín hiệu cấp kho có thể cần thiết để *học* ra việc phối hợp qua sức chứa dù chính sách đã học không còn dựa vào nó khi vận hành. Đây là một giả thuyết cần kiểm chứng thêm trên nhiều hạt giống.

4.5.5 Thực nghiệm B: hiệu năng theo giai đoạn nhu cầu

Toàn bộ các kết quả ở trên (gọi chung là *thực nghiệm A*) lấy trung bình trên cả episode 365 ngày. Trung bình dài hạn có thể che khuất một câu hỏi quan trọng: chính sách cổ điển có tốt hơn khi nhu cầu ổn định, và học tăng cường có lợi thế rõ hơn khi nhu cầu thay đổi nhanh hay không? Thực nghiệm B tách kết quả theo loại ngày, không huấn luyện lại, chỉ đánh giá chính sách đã có trên miền test (`scripts/regime_analysis.py`).

Thiết kế. Ngày trong miền test được gán nhãn theo hai cách:

– **Mức biến động**: với mỗi ngày t và mỗi kho w, tính độ lệch $\left|D_t^{(w)}/\overline{D}_{28}^{(w)} - 1\right|$

giữa tổng nhu cầu của kho và trung bình 28 ngày trước đó, rồi lấy trung bình trên 10 kho. Chia tam phân vị: *ổn định* ($\leq$ 20,3%), *trung bình*, *biến động* ($>$ 30,8%), mỗi nhóm khoảng 164 ngày.

– **Lịch**: ngày có sự kiện (43 ngày), ngày SNAP (240), cuối tuần (141), mùa lễ tháng 11–12 (61) và ngày thường (không sự kiện, không SNAP, không cuối tuần; 164 ngày).

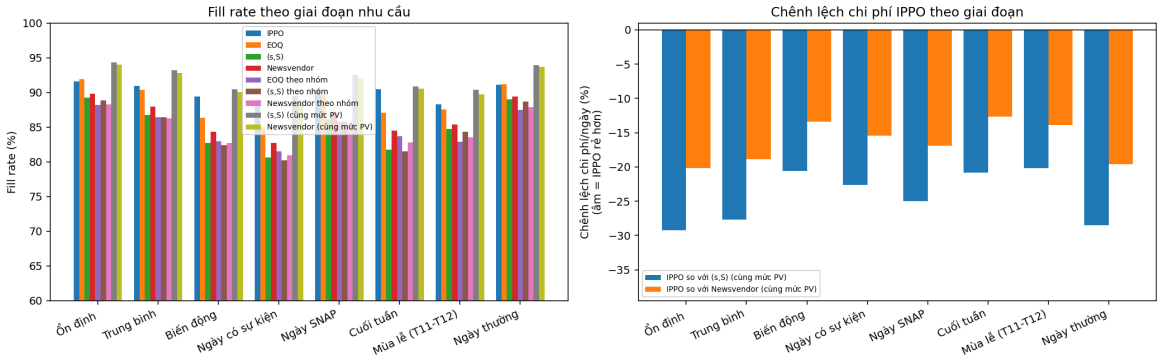
Ngoài giai đoạn tự nhiên, thực nghiệm còn tạo **sốc cầu nhân tạo**: nhân toàn bộ nhu cầu của 28 ngày (ngày 1650–1677) với 1,5 (tăng đột biến) hoặc 0,5 (sụt giảm), rồi đo fill rate và chi phí trong 28 ngày trước, trong và sau cú sốc. Mỗi cấu hình chạy 30 episode với cùng 30 hạt giống. Bên cạnh sáu baseline tinh chỉnh trực tiếp, thực nghiệm dùng thêm hai baseline đã chỉnh về *cùng mức phục vụ* với IPPO (Bảng 4.6), vì chỉ khi fill rate tương đương thì so sánh chi phí mới công bằng.

Thực nghiệm B và Mục 4.5.6 dùng checkpoint của hạt giống 42 (10.000 episode), cùng checkpoint với các phân tích ở Mục 4.4.2–4.4.4.

Bảng 4.10: Thực nghiệm B1: fill rate và chi phí vận hành trung bình mỗi ngày theo giai đoạn nhu cầu (30 episode, miền test). Cột cuối là chênh lệch chi phí của IPPO so với (s, S) cùng mức phục vụ (âm là IPPO rẻ hơn).

Giai đoạn	**IPPO**		(s, S) **trực tiếp**		(s, S) **cùng mức PV**		**Chênh**
	Fill	CP/ngày	Fill	CP/ngày	Fill	CP/ngày	
Ổn định	91,6%	3.874	89,2%	3.896	94,3%	5.475	−29,2%
Trung bình	90,9%	3.981	86,8%	4.117	93,2%	5.502	−27,6%
Biến động	89,4%	4.684	82,7%	4.767	90,5%	5.899	−20,6%
Ngày có sự kiện	88,9%	4.439	80,6%	4.801	89,5%	5.738	−22,6%
Ngày SNAP	90,4%	4.278	86,1%	4.329	92,6%	5.706	−25,0%
Cuối tuần	90,5%	4.408	81,8%	4.824	90,9%	5.567	−20,8%
Mùa lễ (T11–12)	88,3%	5.057	84,7%	4.676	90,4%	6.332	−20,1%
Ngày thường	91,1%	3.962	89,0%	3.943	94,0%	5.540	−28,5%
Toàn miền test	90,6%	4.180	86,2%	4.260	92,7%	5.626	−25,7%

Kết quả B1 — giai đoạn tự nhiên. Bảng 4.10 và Hình 4.4 cho ba nhận xét. Vì các ngày gần nhau không độc lập (các episode chồng lấn và nhu cầu có tự tương quan), độ tin cậy của từng chênh lệch được ước lượng bằng *bootstrap theo khối 7 ngày*: lấy mẫu lại nguyên từng tuần (2.000 lần) thay vì từng ngày riêng lẻ, rồi lấy khoảng tin cậy 95% của chênh lệch chi phí (Bảng 4.11). Bảng này so IPPO với ba đối thủ: (s, S) tinh chỉnh trực tiếp, (s, S) cùng mức phục vụ, và Newsvendor theo nhóm — baseline mạnh nhất ở phép so sánh trực tiếp (Mục 4.4.2).



Hình 4.4: Thực nghiệm B1: (a) fill rate của các chính sách theo giai đoạn nhu cầu; (b) chênh lệch chi phí mỗi ngày của IPPO so với hai baseline ở cùng mức phục vụ

Bảng 4.11: Chênh lệch chi phí mỗi ngày của IPPO và khoảng tin cậy 95% (bootstrap theo khối 7 ngày). Dấu *: khoảng tin cậy không chứa 0.

Giai đoạn	So với (s, S)	So với (s, S) cùng mức PV	So với Newsvendor theo nhóm
Ổn định	$-0{,}6\%$ $[-2{,}3;\ +1{,}3]$	$-29{,}2\%$ $[-31{,}0;\ -27{,}4]^*$	$+2{,}3\%$ $[+0{,}7;\ +4{,}0]^*$
Trung bình	$-3{,}3\%$ $[-5{,}8;\ -0{,}6]^*$	$-27{,}6\%$ $[-30{,}0;\ -24{,}8]^*$	$+0{,}3\%$ $[-1{,}8;\ +2{,}6]$
Biến động	$-1{,}7\%$ $[-7{,}5;\ +3{,}7]$	$-20{,}6\%$ $[-23{,}6;\ -17{,}7]^*$	$+1{,}8\%$ $[-2{,}5;\ +5{,}9]$
Ngày có sự kiện	$-7{,}5\%$ $[-14{,}7;\ -0{,}2]^*$	$-22{,}6\%$ $[-26{,}0;\ -19{,}2]^*$	$-3{,}4\%$ $[-9{,}4;\ +2{,}5]$
Ngày SNAP	$-1{,}2\%$ $[-4{,}6;\ +2{,}5]$	$-25{,}0\%$ $[-27{,}5;\ -22{,}3]^*$	$+1{,}5\%$ $[-1{,}0;\ +4{,}1]$
Cuối tuần	$-8{,}6\%$ $[-12{,}9;\ -4{,}0]^*$	$-20{,}8\%$ $[-23{,}1;\ -18{,}6]^*$	$-2{,}6\%$ $[-6{,}2;\ +1{,}1]$
Mùa lễ (T11–12)	$+8{,}2\%$ $[-3{,}3;\ +17{,}8]$	$-20{,}1\%$ $[-28{,}1;\ -12{,}7]^*$	$+10{,}1\%$ $[+2{,}5;\ +16{,}2]^*$
Ngày thường	$+0{,}5\%$ $[-2{,}9;\ +3{,}8]$	$-28{,}5\%$ $[-31{,}3;\ -25{,}2]^*$	$+3{,}3\%$ $[+1{,}0;\ +5{,}7]^*$

Thứ nhất, **khi nhu cầu ổn định, chính sách cổ điển cạnh tranh được, thậm chí tốt hơn về chi phí**. Ở nhóm ngày ổn định và ngày thường, IPPO ngang (s, S) tinh chỉnh trực tiếp ($-0{,}6\%$ và $+0{,}5\%$, đều không có ý nghĩa thống kê, đổi lại fill rate cao hơn khoảng 2 điểm phần trăm), nhưng đắt hơn Newsvendor theo nhóm $2{,}3\%$ và $3{,}3\%$ (có ý nghĩa thống kê); ngoài ra IPPO cũng đắt hơn (s, S) theo nhóm $1{,}8\%$ ở ngày ổn định. Đây đúng là điều lý thuyết dự đoán: khi nhu cầu gần với trung bình trượt, công thức $s = \mu_L + z\sigma_L$ là một xấp xỉ tốt, và chính sách cổ điển được chỉnh theo nhóm không cần gì hơn.

Thứ hai, **khi nhu cầu biến động, ưu thế của IPPO thể hiện rõ ở độ bền của mức phục vụ và ở ngày có tính chu kỳ**. Từ nhóm ổn định sang nhóm biến động, fill rate của IPPO giảm $2{,}2$ điểm phần trăm ($91{,}6\% \to 89{,}4\%$), trong khi (s, S) trực tiếp giảm $6{,}5$ điểm ($89{,}2\% \to 82{,}7\%$) và (s, S) cùng mức phục vụ giảm $3{,}8$ điểm. Ở ngày có sự kiện và cuối tuần, IPPO vừa rẻ hơn (s, S) trực tiếp ($7{,}5\%$ và $8{,}6\%$, cả hai có ý nghĩa thống kê) vừa có fill rate cao hơn khoảng 8–9 điểm — tức ưu thế trên cả hai tiêu chí ở nhóm ngày này. Tuy nhiên, so với Newsvendor theo nhóm, chênh lệch ở các ngày đó ($-3{,}4\%$ và $-2{,}6\%$) không có ý nghĩa thống kê; riêng cuối tuần IPPO còn rẻ hơn có ý

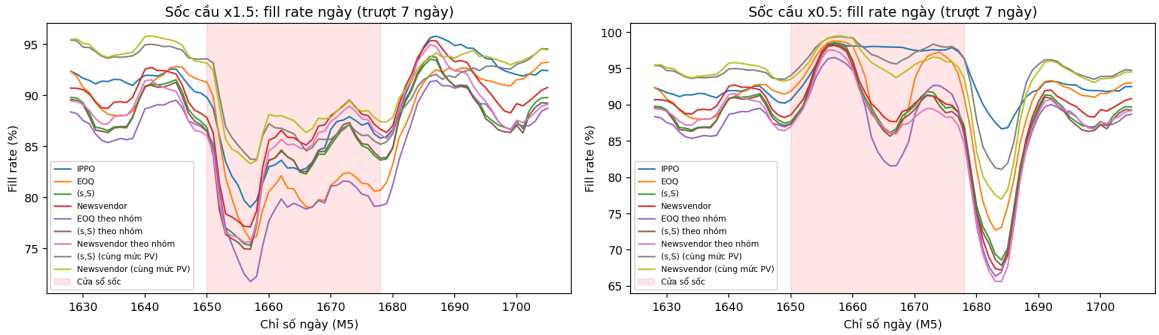
nghĩa thống kê so với (s, S) theo nhóm ($-7{,}2\%$) và EOQ theo nhóm ($-3{,}6\%$). Ở nhóm "biến động" theo độ lệch nhu cầu, chênh lệch chi phí so với (s, S) trực tiếp ($-1{,}7\%$) chưa có ý nghĩa thống kê; ưu thế ở nhóm này thể hiện chủ yếu qua mức phục vụ.

Thứ ba, **ở cùng mức phục vụ, IPPO rẻ hơn trong mọi giai đoạn** ($20{,}1\%$–$29{,}2\%$ so với (s, S), $12{,}7\%$–$20{,}1\%$ so với Newsvendor, đều có ý nghĩa thống kê). Con số này cần đọc cùng cảnh báo ở Mục 4.4.4: hai baseline cùng mức phục vụ giữ fill rate cao hơn IPPO ở hầu hết các nhóm ngày (chẳng hạn $94{,}3\%$ so với $91{,}6\%$ ở ngày ổn định), nên khoảng cách bị phóng đại. Ưu thế tương đối *không* tăng theo mức biến động: lớn nhất ở ngày ổn định ($-29{,}2\%$), nhỏ nhất ở nhóm biến động, cuối tuần và mùa lễ. Mùa lễ cuối năm là giai đoạn yếu nhất của IPPO: fill rate thấp nhất ($88{,}3\%$) và chi phí mỗi ngày cao hơn (s, S) trực tiếp $8{,}2\%$ (chưa có ý nghĩa thống kê), cao hơn Newsvendor theo nhóm $10{,}1\%$ và EOQ theo nhóm $7{,}0\%$ (cả hai có ý nghĩa thống kê). Mùa lễ chỉ gồm 9 tuần trong miền test nên khoảng tin cậy rất rộng; nó nên được xem là một điểm yếu cần theo dõi chứ không phải một kết luận chắc chắn. Một nguyên nhân khả dĩ là miền huấn luyện (1.050 ngày đầu) chỉ chứa khoảng ba mùa lễ, và phân tích tầm quan trọng đặc trưng (Mục 4.5.6) cho thấy tác tử gần như không khai thác các đặc trưng lịch.

Bảng 4.12: Thực nghiệm B2: fill rate (và chi phí mỗi ngày) trước, trong và sau sốc cầu 28 ngày

Chính sách	**Sốc tăng** $\times 1{,}5$			**Sốc giảm** $\times 0{,}5$		
	Trước	Trong	Sau	Trước	Trong	Sau
IPPO	$91{,}6\%$ (3.724)	$83{,}5\%$ $(\mathbf{5.451})$	$\mathbf{93{,}3\%}$ (4.150)	$91{,}6\%$ (3.724)	$97{,}8\%$ (3.354)	$\mathbf{90{,}8\%}$ (3.865)
(s, S) trực tiếp	$88{,}6\%$ (3.925)	$81{,}2\%$ (6.552)	$89{,}6\%$ (4.253)	$88{,}6\%$ (3.925)	$91{,}7\%$ (2.680)	$82{,}9\%$ (4.291)
Newsvendor trực tiếp	$90{,}2\%$ (3.809)	$83{,}7\%$ (6.278)	$91{,}5\%$ (4.121)	$90{,}2\%$ (3.809)	$92{,}0\%$ (2.579)	$83{,}4\%$ (4.285)
(s, S) cùng mức PV	$94{,}3\%$ (5.346)	$84{,}8\%$ (9.392)	$92{,}2\%$ (6.578)	$94{,}3\%$ (5.346)	$97{,}8\%$ (3.590)	$90{,}5\%$ (5.290)
Newsvendor cùng mức PV	$94{,}6\%$ (4.617)	$86{,}1\%$ (8.169)	$93{,}3\%$ (5.637)	$94{,}6\%$ (4.617)	$96{,}6\%$ (3.189)	$89{,}2\%$ (4.820)

Kết quả B2 — sốc cầu. Khi nhu cầu tăng đột ngột 50% (Bảng 4.12, Hình 4.5), mọi chính sách đều mất khoảng 6–10 điểm fill rate trong cú sốc: IPPO từ $91{,}6\%$ xuống $83{,}5\%$, (s, S) trực tiếp $81{,}2\%$, Newsvendor trực tiếp $83{,}7\%$. Ở mức fill rate gần như nhau với Newsvendor trực tiếp, IPPO tốn 5.451 đơn vị mỗi ngày so với 6.278 của



Hình 4.5: Thực nghiệm B2: fill rate theo ngày (trung bình trượt 7 ngày) quanh cú sốc cầu; vùng tô đỏ là 28 ngày bị sốc

Newsvendor ($-13{,}2\%$) và 6.552 của (s, S) ($-16{,}8\%$, kèm fill rate cao hơn $2{,}3$ điểm). So với hai baseline cùng mức phục vụ (9.392 và 8.169), IPPO rẻ hơn 42% và 33% nhưng các baseline này giữ fill rate cao hơn $1{,}3$ và $2{,}6$ điểm trong cú sốc, nên khoảng cách một phần phản ánh mức phục vụ cao hơn. Sau cú sốc, IPPO phục hồi lên fill rate $93{,}3\%$, bằng Newsvendor cùng mức phục vụ và cao hơn các baseline còn lại.

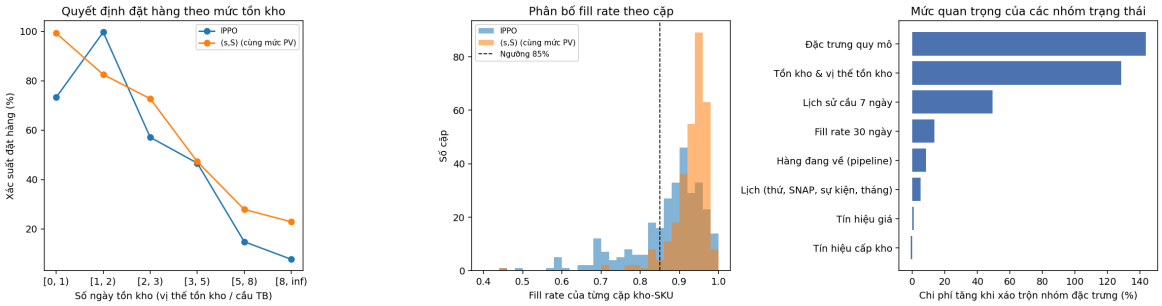
Khi nhu cầu sụt 50% rồi quay lại bình thường, khác biệt rõ hơn. Trong cú sốc mọi chính sách đều dư hàng nên fill rate tăng. Nhưng khi nhu cầu hồi phục, các chính sách cổ điển tinh chỉnh trực tiếp tụt mạnh ($82{,}9\%$ với (s, S) và $83{,}4\%$ với Newsvendor; đáy của fill rate trượt 7 ngày, đọc từ Hình, khoảng 65–73%), và hai baseline cùng mức phục vụ xuống $90{,}5\%$ và $89{,}2\%$ (đáy trượt khoảng 77–81%), vì ước lượng μ và σ từ cửa sổ 7 ngày vẫn phản ánh giai đoạn nhu cầu thấp nên chúng đặt quá ít. IPPO giữ $90{,}8\%$ (đáy trượt khoảng 87%). Cần diễn giải đúng hiện tượng này: nó *không* chứng minh IPPO "dự đoán" được sự hồi phục, mà cho thấy chính sách học được không phụ thuộc hoàn toàn vào cửa sổ ngắn hạn — nó kết hợp lịch sử 7 ngày với đặc trưng quy mô dài hạn $\log(1 + \bar{D}^{(i)})$, đặc trưng có tầm quan trọng cao nhất trong phân tích ở Mục 4.5.6. Nói cách khác, IPPO bền hơn trước nhiễu ngắn hạn, đổi lại có thể phản ứng chậm hơn nếu thay đổi nhu cầu là vĩnh viễn.

Kết luận thực nghiệm B. Kết quả không cho thấy học tăng cường đạt chi phí thấp hơn ở mọi giai đoạn. Khi nhu cầu ổn định hoặc vào ngày thường, các chính sách cổ điển được tinh chỉnh tốt — đặc biệt Newsvendor theo nhóm — rẻ hơn IPPO vài phần trăm, dù IPPO cho fill rate cao hơn; ở mùa lễ IPPO kém nhất. Ưu thế của IPPO tập trung ở: (1) độ bền của mức phục vụ khi nhu cầu biến động và khi hồi phục sau cú sụt; (2) chi phí thấp hơn (s, S) và (s, S) theo nhóm ở ngày có sự kiện và cuối tuần (nhưng không có ý nghĩa thống kê so với Newsvendor theo nhóm); và (3) chi phí thấp hơn

khi chống đỡ sốc tăng cầu so với các baseline cùng mức phục vụ. Hai giới hạn của thực nghiệm này: (1) miền test chỉ dài 491 ngày nên các episode 365 ngày chồng lấn nhau — bootstrap theo khối tuần giảm nhưng không loại bỏ hoàn toàn ảnh hưởng của tự tương quan; (2) mùa lễ chỉ có 61 ngày (9 tuần) nên kết luận về mùa lễ còn yếu.

4.5.6 Kiểm tra trạng thái và phần thưởng bằng thực nghiệm

Thiết kế trạng thái (Bảng 3.3) và phần thưởng (công thức 3.4) ở Chương 3 mới dựa trên lập luận. Mục này kiểm tra lại bằng thực nghiệm ba câu hỏi: chính sách có hành vi hợp lý về nghiệp vụ không, tác tử có khai thác kẽ hở của phần thưởng không, và trạng thái có biến dư thừa không (`scripts/policy_behavior.py`, 10 episode trên miền test, so với (s, S) cùng mức phục vụ).



Hình 4.6: (a) Xác suất đặt hàng theo số ngày tồn kho; (b) phân bố fill rate của 300 cặp; (c) mức tăng chi phí khi xáo trộn từng nhóm đặc trưng trạng thái

Hành vi có hợp lý về nghiệp vụ không? Hình 4.6a nhóm các quyết định theo số ngày tồn kho (vị thế tồn kho chia cho nhu cầu trung bình). Xác suất IPPO đặt hàng giảm gần đơn điệu khi tồn kho tăng từ 2 ngày trở lên: 57% khi còn 2–3 ngày hàng, 47% khi còn 3–5 ngày, 15% khi còn 5–8 ngày và 8% khi trên 8 ngày; khi còn 1–2 ngày, IPPO đặt hàng trong gần 100% trường hợp. Tương quan hạng Spearman giữa số ngày tồn kho và mức đặt là $-0{,}42$, mạnh hơn (s, S) cùng mức phục vụ ($-0{,}17$). IPPO chỉ dùng mức đặt lớn nhất ($5\bar{D}\bar{L}$) ở 1,3% số quyết định, và chi phí tràn kho chỉ chiếm 2,0% tổng chi phí (so với 17,1% của (s, S) cùng mức phục vụ). Có một điểm bất thường: khi tồn kho dưới 1 ngày, IPPO chỉ đặt hàng trong 73% trường hợp, thấp hơn nhóm 1–2 ngày. Khóa luận chưa kiểm tra lại với mô hình cuối xem các trường hợp không đặt này có tập trung ở các cặp bán rất chậm hay không; giả thuyết này nhất quán với phân tích bên dưới nhưng cần xác minh.

Tác tử có khai thác kẽ hở của phần thưởng không? Nếu tác tử chỉ "vừa đủ" để tránh phạt mức phục vụ, fill rate của các cặp sẽ dồn sát ngưỡng 85%. Điều này không xảy ra: chỉ $12{,}0\%$ số cặp nằm trong khoảng $[85\%, 88\%)$. Tuy nhiên, phân bố fill rate theo cặp (Hình 4.6b) cho thấy một dạng khai thác khác: $28{,}7\%$ số cặp của IPPO có fill rate dưới 85% (phân vị 10% là $71{,}2\%$), trong khi con số này của (s, S) cùng mức phục vụ chỉ là $5{,}7\%$ (phân vị 10% là $87{,}9\%$). Fill rate hệ thống $90{,}7\%$ của IPPO đạt được nhờ phục vụ rất tốt các mặt hàng bán chạy, bù cho các mặt hàng bán chậm. Hình phạt chuẩn hóa giảm hiện tượng này so với hình phạt tỷ lệ theo nhu cầu ($28{,}3\%$ so với $33{,}0\%$ cặp dưới 85% ở cùng ngân sách 1.000 episode) nhưng không xóa bỏ nó (Mục 4.5.1): tác tử tối ưu đúng hàm mục tiêu được giao, nhưng hàm mục tiêu đó chưa mã hóa yêu cầu "mọi mặt hàng đều phải đạt mức phục vụ tối thiểu". Đây là phát hiện quan trọng nhất của phần kiểm tra này và là lý do đề xuất ràng buộc mức phục vụ ở cấp cặp trong hướng phát triển.

Bảng 4.13: Tầm quan trọng của các nhóm đặc trưng trạng thái (xáo trộn nhóm đặc trưng giữa các cặp ở mỗi bước; riêng nhóm lịch được thay bằng lịch của một ngày ngẫu nhiên)

Nhóm đặc trưng	**Số chiều**	**Chi phí tăng**	**Fill rate đổi**
Đặc trưng quy mô $\log(1+\bar{D})$	1	$+143{,}6\%$	$-0{,}8$ điểm
Tồn kho và vị thế tồn kho	2	$+128{,}3\%$	$-28{,}9$ điểm
Lịch sử cầu 7 ngày	7	$+49{,}3\%$	$-12{,}5$ điểm
Fill rate cửa sổ 30 ngày	1	$+13{,}7\%$	$-0{,}5$ điểm
Hàng đang về (pipeline)	3	$+8{,}6\%$	$-0{,}5$ điểm
Lịch (thứ, SNAP, sự kiện, tháng)	27	$+5{,}3\%$	$-0{,}2$ điểm
Tín hiệu giá (mức giảm giá)	1	$+0{,}8\%$	$+0{,}1$ điểm
Tín hiệu cấp kho (mức đầy, tỷ trọng)	2	$-0{,}8\%$	$-0{,}3$ điểm

Trạng thái có biến dư thừa không? Bảng 4.13 đo mức giảm hiệu năng khi phá liên hệ giữa một nhóm đặc trưng và cặp tương ứng (permutation importance), không cần huấn luyện lại. Ba nhóm quyết định là đặc trưng quy mô, tồn kho và lịch sử cầu; chúng tương ứng đúng với các đại lượng mà một chính sách tồn kho cổ điển cần ($\bar{D}$, vị thế tồn kho, σ). Ngược lại, 27 chiều lịch chỉ đóng góp $5{,}3\%$ chi phí, còn tín hiệu giá (1 chiều) và tín hiệu cấp kho (2 chiều) gần như không có đóng góp (xáo trộn chúng thay đổi chi phí dưới 1%). Với lịch, điều này giải thích vì sao IPPO yếu nhất ở mùa lễ (Thực nghiệm B): $27/44$ chiều quan sát gần như không được khai thác. Tín hiệu giá — chiều quan sát thứ 44 được thêm vào ở đợt cuối — cũng không được chính sách đã học khai thác; khóa luận chưa chạy thí nghiệm loại trừ riêng cho tín hiệu này. Với tín

hiệu cấp kho, mức đóng góp nhỏ ở bước suy luận nhất quán với việc ràng buộc sức chứa ít khi chạm ngưỡng (chi phí tràn kho $2{,}0\%$), nhưng thí nghiệm bỏ tín hiệu này khi huấn luyện lại làm huấn luyện không ổn định (Bảng 4.9). Cần lưu ý rằng permutation importance đo mức *chính sách đã học* dựa vào một đặc trưng, không phải hiệu năng của một chính sách được huấn luyện lại khi bỏ đặc trưng đó; thí nghiệm sau chỉ có cho nhóm lịch và nhóm cấp kho, một hạt giống.

4.5.7 Độ nhạy của kết luận theo đơn giá chi phí

Mọi kết luận ở trên gắn với một bộ đơn giá chi phí cụ thể ($c_{lk} = 1$, $c_{th} = 10$, $c_{dh} = 5$). Để kiểm tra kết luận có phụ thuộc vào lựa chọn này không, mỗi chính sách được chạy một lần trên miền test (10 episode) và ghi lại các đại lượng vật lý: đơn vị–ngày lưu kho, đơn vị thiếu hàng, số lần đặt, đơn vị tràn kho. Tổng chi phí sau đó được tính lại trên lưới $3 \times 4 \times 3 = 36$ bộ đơn giá ($c_{lk} \in \{0{,}5;\ 1;\ 2\}$, $c_{th} \in \{5;\ 10;\ 20;\ 40\}$, $c_{dh} \in \{2;\ 5;\ 10\}$; `scripts/sensitivity.py`). Các chính sách *không* được huấn luyện hay tinh chỉnh lại cho từng bộ đơn giá, nên kết quả trả lời câu hỏi: nếu doanh nghiệp định giá chi phí khác đi thì các chính sách đã có xếp hạng thế nào.

Bảng 4.14: Chênh lệch tổng chi phí của IPPO theo đơn giá ($c_{dh} = 5$). Mỗi ô: so với (s, S) trực tiếp / so với (s, S) cùng mức phục vụ; âm là IPPO rẻ hơn.

	$c_{th} = 5$	$c_{th} = 10$	$c_{th} = 20$	$c_{th} = 40$
$c_{lk} = 0{,}5$	$-1{,}7\%$ / $-34{,}3\%$	$-8{,}3\%$ / $-28{,}7\%$	$-15{,}5\%$ / $-20{,}0\%$	$-21{,}8\%$ / $-8{,}8\%$
$c_{lk} = 1$	$+3{,}6\%$ / $-29{,}2\%$	$-1{,}9\%$ / $-25{,}6\%$	$-9{,}0\%$ / $-19{,}7\%$	$-16{,}3\%$ / $-11{,}1\%$
$c_{lk} = 2$	$+7{,}6\%$ / $-25{,}0\%$	$+3{,}8\%$ / $-23{,}0\%$	$-2{,}0\%$ / $-19{,}4\%$	$-9{,}3\%$ / $-13{,}5\%$

Hai nhận xét rút ra (Bảng 4.14). Thứ nhất, **kết luận ở cùng mức phục vụ nhất quán về dấu**: IPPO rẻ hơn (s, S) cùng mức phục vụ ở cả $36/36$ bộ đơn giá (chênh $-8{,}1\%$ đến $-35{,}4\%$), và rẻ hơn Newsvendor cùng mức phục vụ ở cả $36/36$ bộ (chênh $-2{,}1\%$ đến $-25{,}6\%$); nhưng như đã nêu ở Mục 4.4.4, độ lớn của khoảng cách bị phóng đại vì baseline vượt mục tiêu phục vụ. Thứ hai, **kết luận so thẳng phụ thuộc tỷ số** c_{th}/c_{lk}: IPPO rẻ hơn (s, S) tinh chỉnh trực tiếp ở $26/36$ bộ đơn giá (chênh $-22{,}8\%$ đến $+8{,}1\%$), rẻ hơn Newsvendor ở $24/36$ bộ ($-18{,}3\%$ đến $+10{,}8\%$), và với các baseline theo nhóm chỉ rẻ hơn ở 18–$24/36$ bộ ((s, S) theo nhóm $18/36$, Newsvendor theo nhóm $21/36$, EOQ theo nhóm $24/36$; khoảng chênh rộng nhất là $-23{,}5\%$ đến $+18{,}0\%$ so với Newsvendor theo nhóm). Trong các baseline tinh chỉnh trực tiếp, chỉ EOQ bị IPPO vượt ở cả $36/36$ bộ ($-13{,}2\%$ đến $-25{,}7\%$). Khi thiếu hàng đắt so với lưu kho, IPPO đạt chi phí thấp hơn vì nó giữ mức phục vụ cao hơn; khi lưu kho đắt và thiếu hàng rẻ,

(s, S) — vốn chấp nhận thiếu hàng nhiều hơn — lại rẻ hơn. Điều này nhất quán với nhận định ở Mục 4.4.2 rằng so thẳng hai chính sách nằm ở hai điểm khác nhau trên đường đánh đổi là không công bằng, và rằng so với các baseline tinh chỉnh theo nhóm, IPPO không có ưu thế chi phí ổn định.

4.5.8 Độ bền khi điều kiện vận hành thay đổi

Thí nghiệm cuối kiểm tra độ bền *zero-shot*: chỉ đổi môi trường đánh giá, giữ nguyên chính sách đã học và các baseline đã tinh chỉnh (10 lần đánh giá mỗi kịch bản, `scripts/robustness.py`). Chỉ những thay đổi mà chính sách đã học vẫn nhận làm đầu vào mới được thử: sức chứa kho, thời gian giao hàng, mức nhu cầu.

Bảng 4.15: Độ bền zero-shot: chi phí và fill rate của IPPO, và chênh lệch chi phí của IPPO so với từng baseline (âm là IPPO rẻ hơn). Dấu *: có ý nghĩa thống kê; $^\sim$: kịch bản tất định, không kiểm định được.

Kịch bản	**IPPO**	**Fill**	(s, S)	(s, S)-N	EOQ	EOQ-N	NV	NV-N
Gốc	2.051.839	90,7%	$-1{,}9^*$	$+0{,}2$	$-18{,}0^*$	$-1{,}1^*$	$-0{,}5^*$	$+1{,}4^*$
Sức chứa 4 ngày	2.191.998	89,0%	$-3{,}0^*$	$+0{,}7^*$	$-23{,}1^*$	$+0{,}5^*$	$+1{,}0^*$	$+4{,}6^*$
Sức chứa 6 ngày	2.032.325	91,1%	$-0{,}3$	$+1{,}1^*$	$-14{,}3^*$	$-0{,}9^*$	$-0{,}3^*$	$+1{,}0^*$
Lead time luôn 3	2.156.456	88,1%	$-3{,}1^\sim$	$-2{,}0^\sim$	$-20{,}4^\sim$	$-10{,}5^\sim$	$-0{,}0^\sim$	$+0{,}2^\sim$
Lead time 2–3	2.100.304	89,3%	$-2{,}4^*$	$-1{,}0^*$	$-17{,}5^*$	$-4{,}2^*$	$-0{,}1$	$+0{,}9^*$
Nhu cầu $+20\%$	2.351.070	87,8%	$-7{,}7^*$	$-5{,}4^*$	$-21{,}4^*$	$-5{,}7^*$	$-5{,}6^*$	$-3{,}3^*$
Nhu cầu -20%	1.826.196	93,3%	$+7{,}0^*$	$+8{,}5^*$	$-12{,}7^*$	$+4{,}2^*$	$+6{,}8^*$	$+8{,}7^*$

Kết quả (Bảng 4.15) cho thấy chính sách đã học bền với thay đổi sức chứa và thời gian giao hàng — IPPO vẫn rẻ hơn (s, S) và EOQ ở mọi kịch bản đó, và ngang hoặc hơi đắt hơn các baseline theo nhóm ($+0{,}5\%$ đến $+4{,}6\%$ ở sức chứa 4 ngày). Khi nhu cầu tăng 20%, IPPO rẻ hơn tất cả sáu baseline ($-3{,}3\%$ đến $-21{,}4\%$). Điểm yếu là khi nhu cầu giảm 20%: IPPO đắt hơn năm trong sáu baseline ($+4{,}2\%$ đến $+8{,}7\%$), dù fill rate đạt $93{,}3\%$; tức chính sách tiếp tục giữ mức phục vụ cao khi không còn cần thiết. Cần nhớ các baseline vẫn giữ tham số đã tinh chỉnh cho môi trường gốc, nên kết quả chỉ trả lời câu hỏi "chính sách đã có chịu đựng thay đổi thế nào" chứ không so sánh các chính sách được chỉnh lại cho từng kịch bản.

4.6 Hạn chế của thực nghiệm

Bốn hạn chế cần được ghi nhận khi diễn giải các kết quả trên.

Thứ nhất, số hạt giống và độ dài huấn luyện của từng thí nghiệm. Mô hình chính được huấn luyện 10.000 episode trên 3 hạt giống độc lập; chi phí validation tốt nhất đi ngang ở 20% episode cuối ($+0{,}2\%$ đến $+1{,}6\%$), và checkpoint được chọn ở episode 3.775–5.250, nên 10.000 episode đủ để hội tụ trong cấu hình này. Tuy vậy các

phân tích sâu (Thực nghiệm B, so sánh cùng mức phục vụ, kiểm tra hành vi, độ nhạy đơn giá, độ bền zero-shot) chỉ dùng checkpoint của hạt giống 42; chênh lệch giữa 3 hạt giống ở kết quả chính khá hẹp (tổng chi phí 2.042.786–2.071.045, độ lệch chuẩn 14.358) nên rủi ro phụ thuộc một hạt giống không lớn, nhưng chưa được kiểm chứng bằng cả 3 hạt giống cho từng phân tích. Các thí nghiệm loại trừ 1.000 episode khác (ngoài thiết kế phần thưởng) và thí nghiệm hold-out chỉ có một hạt giống, và chưa được huấn luyện tới 10.000 episode.

Thứ hai, độ chính xác của phép so sánh ở cùng mức phục vụ. Lưới tham số của baseline thô nên cấu hình được chọn vượt mục tiêu 90,15% hơn một điểm phần trăm (92,65% và 92,28%), làm khoảng cách chi phí (25,7% và 17,3%) bị phóng đại (Mục 4.4.4). Ở phép so sánh trực tiếp, IPPO chỉ ngang các baseline theo nhóm về chi phí, nên ưu thế duy nhất không bị nghi ngờ là mức phục vụ cao hơn khoảng 4–5 điểm phần trăm.

Thứ ba, phạm vi của bộ tham số chi phí. Phân tích độ nhạy (Mục 4.5.7) cho thấy kết luận ở cùng mức phục vụ nhất quán về dấu trên cả 36 bộ đơn giá, còn kết luận so thẳng phụ thuộc tỷ số c_{th}/c_{lk} và IPPO chỉ rẻ hơn các baseline theo nhóm ở 18–24 trong 36 bộ. Tuy nhiên, phân tích này giữ nguyên các chính sách đã học; một IPPO được huấn luyện lại với đơn giá khác có thể học được chiến lược khác.

Thứ tư, tính đại diện của dữ liệu và mức phục vụ giữa các mặt hàng. 30 mặt hàng được chọn theo phân tầng để trải rộng dải quy mô nhu cầu, nhưng vẫn là một tập con nhỏ của 3.049 mặt hàng trong bộ dữ liệu gốc, và toàn bộ dữ liệu là dữ liệu bán lẻ của Walmart (Hoa Kỳ). Ngoài ra, 28,7% số cặp của IPPO có fill rate dưới 85% (Mục 4.5.6), tức mục tiêu mức phục vụ chỉ được đáp ứng ở cấp hệ thống.

4.7 Thảo luận

Kết quả cho phép trả lời Câu hỏi nghiên cứu 1, nhưng câu trả lời cần được phát biểu cẩn trọng hơn một khẳng định đơn giản. Ở điểm vận hành mà mỗi phương pháp tự chọn (Mục 4.4.2), IPPO đạt tổng chi phí xấp xỉ các chính sách cổ điển tốt nhất: rẻ hơn (s, S) 1,7% và EOQ 17,8%, ngang (s, S) theo nhóm, EOQ theo nhóm và Newsvendor, và đắt hơn Newsvendor theo nhóm 1,6%. Cái IPPO đạt thêm là mức phục vụ cao hơn khoảng 4–5 điểm phần trăm (90,9% so với 85,8–86,2%) với cùng một mức chi phí, theo đúng thiết kế của thành phần phạt SLA. Khi buộc các baseline đạt mức phục vụ tương đương (Mục 4.4.4), chúng đắt hơn IPPO 25,7% ((s, S)) và 17,3% (Newsvendor), còn EOQ không có cấu hình nào đạt được; nhưng do lưới tham số thô, baseline vượt mục

tiêu phục vụ hơn một điểm phần trăm nên khoảng cách này là cận trên. Khóa luận coi phép so sánh ở cùng mức phục vụ — kèm cảnh báo đó — là căn cứ phù hợp để nói rằng IPPO cho mức phục vụ cao với chi phí thấp hơn các baseline phải nâng tham số an toàn đồng loạt, chứ không phải rằng IPPO thắng chi phí ở mọi nơi. Tóm lại, khẳng định phù hợp với số liệu là: IPPO *không đắt hơn* các chính sách cổ điển ở mức phục vụ cao hơn, và *rẻ hơn rõ rệt* khi các chính sách cổ điển phải tăng mức phục vụ lên tương đương; ưu thế này không mang tính Pareto tuyệt đối. Thực nghiệm theo giai đoạn nhu cầu (Mục 4.5.5) làm rõ thêm: khi nhu cầu ổn định hoặc vào mùa lễ, baseline tinh chỉnh theo nhóm rẻ hơn hoặc ngang IPPO; ưu thế của IPPO tập trung ở độ bền của mức phục vụ khi nhu cầu biến động, ở ngày sự kiện và cuối tuần, và khi chống đỡ sốc cầu. Kết luận này khớp với góp ý rằng mô hình tĩnh như EOQ có thể đủ tốt khi nhu cầu ổn định, và học tăng cường phù hợp hơn khi giá và nhu cầu biến động.

Hai nhận xét bổ sung đáng ghi nhận.

Về vai trò của ràng buộc sức chứa, thí nghiệm hiệu chỉnh κ ở Mục 4.1.3 cho thấy khi sức chứa đủ rộng thì bài toán suy biến thành 300 bài toán độc lập. Nói cách khác, chính ràng buộc sức chứa dùng chung — chứ không phải số lượng tác tử — mới là thứ tạo nên bản chất đa tác tử của bài toán. Đây là yếu tố mà hai công trình gần nhất cùng bối cảnh đều không mô hình hóa: Zhu và Wu [22] giả định nguồn cung không giới hạn, còn Nam và cộng sự [23] chỉ xét một kho duy nhất.

Về hiệu quả tính toán, mô hình chính cần khoảng 220–280 phút huấn luyện mỗi hạt giống trên một GPU phổ thông (RTX 3050 Laptop) và không cần mô-đun dự báo nhu cầu học sâu: tác tử học trực tiếp từ lịch sử nhu cầu thô trong vector quan sát. Điều này tránh được sự phụ thuộc vào chất lượng của một bộ dự báo riêng biệt — hạn chế mà chính Zhu và Wu [22] nêu ra trong phần thảo luận của họ. Khóa luận không đưa ra kết luận về việc cách làm này vượt hay kém các phương pháp dùng dự báo, vì chưa thực hiện phép so sánh trực tiếp với chúng; các công trình như Gijsbrechts và cộng sự [17] chỉ được dùng để đặt bối cảnh rằng học tăng cường sâu có thể cạnh tranh với các chính sách được hiệu chỉnh kỹ trong lớp bài toán mất đơn hàng, một nhận định phù hợp với kết quả ở trên nhưng không phải bằng chứng của khóa luận.

CHƯƠNG 5. KẾT LUẬN VÀ HƯỚNG PHÁT TRIỂN

5.1 Tổng kết các kết quả đạt được

Khóa luận đã hoàn thành bốn mục tiêu nghiên cứu chính và thực hiện thêm một nhóm phân tích chuyên sâu (mục thứ năm dưới đây):

1. Xây dựng môi trường mô phỏng: phát triển thành công `MultiWarehouseInventoryEnv` theo chuẩn Gymnasium [24], mô hình hóa đầy đủ hệ thống 10 kho, 30 mặt hàng (300 cặp tác tử), với nhu cầu ngẫu nhiên, thời gian giao hàng biến động $[1, 3]$ ngày, ràng buộc sức chứa dùng chung tính riêng cho từng kho theo quy mô nhu cầu của kho đó, bốn thành phần chi phí vận hành (lưu kho, thiếu hàng, đặt hàng, tràn kho) và hình phạt mức phục vụ tách riêng khỏi chi phí vận hành. Nhu cầu lấy từ bộ dữ liệu M5 Walmart [2].
2. Thiết kế hàm phần thưởng: phần thưởng phân rã cục bộ (local factored reward) theo từng cặp kho–mặt hàng, với động cơ giảm khó khăn gán tín dụng [25], kèm hình phạt mức phục vụ dạng ràng buộc mềm tính trên cửa sổ trượt 30 ngày.
3. Cài đặt và huấn luyện IPPO: triển khai thuật toán Independent Multi-Agent PPO [20] với cơ chế chia sẻ tham số [18], sử dụng GAE [27] và chuẩn hóa lợi thế theo từng cặp; 300 tác tử dùng chung một mạng chính sách. Mô hình chính được huấn luyện 10.000 episode trên 3 hạt giống độc lập và hội tụ ổn định: phần thưởng đi ngang từ khoảng episode 1.200, entropy giảm từ $1{,}779$ xuống $0{,}13$ và explained variance của Critic duy trì quanh $0{,}84$, nhất quán trên cả 3 hạt giống.
4. Đánh giá đối chứng: so sánh IPPO với ba chính sách cổ điển (EOQ, (s, S), Newsvendor) trên 30 episode đánh giá dùng chung hạt giống, lặp lại trên 3 hạt giống huấn luyện độc lập, có kiểm định thống kê [28], [29], và bổ sung phép so sánh ở cùng mức phục vụ nhằm loại bỏ sai lệch do các phương pháp nằm ở những điểm khác nhau trên đường đánh đổi.
5. Phân tích theo giai đoạn và kiểm tra hành vi: tách kết quả theo giai đoạn nhu cầu (ổn định, biến động, sự kiện, mùa lễ) và thử sốc cầu nhân tạo (thực nghiệm B); kiểm tra bằng thực nghiệm tính hợp lý của hành vi đặt

hàng, dấu hiệu khai thác phần thưởng và tầm quan trọng của từng nhóm đặc trưng trạng thái. Kết quả mô phỏng được đưa lên một ứng dụng mô phỏng (Streamlit) chỉ nạp checkpoint đã huấn luyện và chạy trên miền test, không huấn luyện lại. Ứng dụng cho phép xem kết quả tổng hợp, xem diễn biến theo từng ngày của từng cặp kho–mặt hàng (nhu cầu, tồn kho, hàng đang về, lượng đặt, thiếu hàng), so sánh các chính sách, thử kịch bản tăng cầu, và xem đơn đặt hàng đề xuất theo ngày kèm bước duyệt phiếu (Nháp, Đã duyệt, Từ chối).

Phạm vi của sản phẩm là *mô phỏng và đề xuất*: đầu ra của mô hình là yêu cầu đặt hàng lại (số lượng, thời điểm, cho từng kho–mặt hàng) và dừng ở bước phiếu đề nghị gửi sang bộ phận mua hàng. Hỏi báo giá, chọn và gửi nhà cung cấp nằm ngoài phạm vi, vì dữ liệu M5 không có thông tin nhà cung cấp; đây là giới hạn phạm vi chứ không phải giới hạn kỹ thuật, và có thể mở rộng thành luồng tự động khi có dữ liệu nhà cung cấp.

5.1.1 Trả lời các câu hỏi nghiên cứu

Câu hỏi 1 (IPPO so với các chính sách cổ điển). Câu trả lời là khẳng định có điều kiện, và không mang tính chiếm ưu thế tuyệt đối. Ở điểm vận hành mà mỗi phương pháp tự chọn, IPPO đạt tổng chi phí xấp xỉ các chính sách cổ điển tốt nhất: gộp trên 3 hạt giống huấn luyện $\times$ 30 lần đánh giá, IPPO rẻ hơn (s, S) $1{,}7\%$ và EOQ $17{,}8\%$ (nhất quán ở cả 3 hạt giống), ngang (s, S) theo nhóm ($+0{,}3\%$), EOQ theo nhóm ($-0{,}9\%$) và Newsvendor ($-0{,}3\%$) — các chênh lệch này đổi dấu giữa các hạt giống — và đắt hơn Newsvendor theo nhóm $1{,}6\%$ ở cả 3 hạt giống. Điều IPPO đạt thêm là mức phục vụ cao hơn: $90{,}9\%$ so với $85{,}8$–$86{,}2\%$ của bốn bản (s, S), (s, S) theo nhóm, EOQ theo nhóm và Newsvendor theo nhóm, tức cao hơn khoảng 4–5 điểm phần trăm với cùng một mức chi phí.

Khi so sánh ở cùng mức phục vụ ($\approx 90\%$), các baseline phải nâng tham số an toàn áp dụng đồng loạt cho cả 300 cặp nên chi phí tăng mạnh: (s, S) đắt hơn IPPO $25{,}7\%$ và Newsvendor đắt hơn $17{,}3\%$, còn EOQ không có cấu hình nào đạt được mức phục vụ đó do cấu trúc lượng đặt hàng cố định. Cần đọc các con số này với một cảnh báo: lưới tham số của baseline thô nên chúng vượt mục tiêu phục vụ hơn một điểm phần trăm ($92{,}65\%$ và $92{,}28\%$ so với $90{,}15\%$), vì vậy $25{,}7\%$ và $17{,}3\%$ là cận trên của lợi thế chi phí chứ không phải ước lượng chính xác. Khóa luận không khẳng định IPPO rẻ hơn các chính sách cổ điển ở mọi nơi, mà khẳng định: IPPO duy trì mức phục vụ

cao hơn mà không đắt hơn các baseline mạnh nhất, và rẻ hơn rõ rệt khi các baseline phải nâng mức phục vụ lên tương đương.

Thực nghiệm B (theo giai đoạn nhu cầu) bổ sung sắc thái cho câu trả lời này và khớp với nhận định rằng chính sách tĩnh như EOQ hay (s, S) đã tinh chỉnh có thể đủ tốt khi nhu cầu ổn định, còn học tăng cường có giá trị khi nhu cầu biến động. Khi nhu cầu ổn định hoặc vào ngày thường, IPPO ngang (s, S) tinh chỉnh trực tiếp nhưng đắt hơn Newsvendor theo nhóm $2{,}3$–$3{,}3\%$ (có ý nghĩa thống kê). Ưu thế của IPPO tập trung ở giai đoạn biến động: fill rate chỉ giảm $2{,}2$ điểm phần trăm từ ngày ổn định sang ngày biến động (so với $6{,}5$ điểm của (s, S)), rẻ hơn (s, S) $7{,}5\%$ ở ngày có sự kiện và $8{,}6\%$ ở cuối tuần dù phục vụ tốt hơn (nhưng không có ý nghĩa thống kê so với Newsvendor theo nhóm), và tốn ít chi phí hơn khoảng 13%–17% so với (s, S) và Newsvendor trực tiếp khi chống đỡ một cú sốc tăng cầu 50% (fill rate tương đương hoặc cao hơn); sau cú sụt cầu 50%, các chính sách cổ điển tinh chỉnh trực tiếp tụt xuống $82{,}9$–$83{,}4\%$ còn IPPO giữ $90{,}8\%$. Mùa lễ cuối năm là giai đoạn IPPO yếu nhất (đắt hơn Newsvendor theo nhóm $10{,}1\%$, có ý nghĩa thống kê), nhưng dữ liệu chỉ có 9 tuần nên chưa đủ để kết luận chắc chắn. Về độ nhạy, ở cùng mức phục vụ IPPO rẻ hơn ở cả $36/36$ bộ đơn giá, còn so thẳng với các baseline theo nhóm IPPO chỉ rẻ hơn ở 18–24 trong 36 bộ. Kết luận hợp lý vì vậy không phải "học tăng cường tốt hơn" một cách chung chung, mà là: chính sách cổ điển đủ tốt khi nhu cầu ổn định, còn IPPO có giá trị khi nhu cầu biến động nhanh và khi cần mức phục vụ cao.

Câu hỏi 2 (hiệu năng theo nhóm quy mô nhu cầu). Câu trả lời là có điều kiện. Một bộ trọng số duy nhất điều khiển được 300 cặp có nhu cầu từ dưới $0{,}1$ đến 143 đơn vị mỗi ngày, và ở nhóm nhu cầu trung bình và cao IPPO vượt (s, S) trên cả fill rate lẫn chi phí. Tuy nhiên, ở nhóm bán chậm (dưới 2 đơn vị mỗi ngày) IPPO phục vụ kém hơn (s, S) ($74{,}2\%$ so với $84{,}3\%$ ở nhóm dưới $0{,}5$ đơn vị mỗi ngày); phân tích phân bố cho thấy $28{,}7\%$ số cặp của IPPO dưới ngưỡng 85% (so với $5{,}7\%$ của (s, S) cùng mức phục vụ). Hình phạt chuẩn hóa giảm nhưng không loại bỏ hiện tượng này ($28{,}3\%$ so với $33{,}0\%$ cặp dưới 85% khi so với hình phạt tỷ lệ theo nhu cầu, cùng ngân sách 1.000 episode). Về mặt hàng chưa từng gặp khi huấn luyện, một thí nghiệm hold-out (6 mặt hàng bị giữ lại, 60 cặp, một hạt giống) cho chi phí tương đương mô hình đã gặp mặt hàng đó ($+0{,}1\%$, $p = 0{,}67$), tức không có dấu hiệu suy giảm; kết quả này chỉ trên một hạt giống và một tập 6 mặt hàng nên cần kiểm chứng thêm.

Câu hỏi 3 (thiết kế tín hiệu phần thưởng). Có bằng chứng ủng hộ phần thưởng cục bộ có chuẩn hóa theo cặp. Trên 3 hạt giống, mỗi lần chạy 1.000 episode và so với

lần tham chiếu cùng hạt giống, phần thưởng toàn cục làm tổng chi phí tăng trung bình 419,6% và việc tắt chuẩn hóa theo cặp làm tăng trung bình 214,3%, đều có ý nghĩa thống kê ở cả 3 hạt giống và lớn hơn nhiều dao động 1,6% giữa các hạt giống của lần tham chiếu (Mục 4.5.2). Đáng chú ý là Critic khi không chuẩn hóa đạt explained variance 1,00 nhưng chính sách vẫn kém, khớp với lập luận rằng return chênh nhau nhiều bậc độ lớn khiến tín hiệu học bị các cặp nhu cầu lớn chi phối. Giới hạn: các lần chạy chỉ dài 1.000 episode và entropy còn cao, nên chưa thể loại trừ khả năng các biến thể chỉ học chậm hơn.

5.2 Những hạn chế còn tồn tại

- Cấu trúc mạng lưới đơn giản: các kho hoạt động song song và độc lập về nguồn cung; chưa xét cấu trúc đa cấp (multi-echelon) với quan hệ cung ứng giữa các kho [30] và hiệu ứng bullwhip [31].
- Không có cơ chế phối hợp tường minh: các tác tử ra quyết định hoàn toàn dựa trên quan sát cục bộ, phối hợp chỉ diễn ra gián tiếp qua tín hiệu sức chứa kho. Khóa luận chưa định lượng được phần giá trị mà một critic tập trung theo hướng CTDE [21] có thể mang lại — đặc biệt đáng lưu ý vì Zhu và Wu [22] báo cáo mức suy giảm đáng kể khi loại bỏ cơ chế phối hợp trong khung của họ.
- Số hạt giống của từng phân tích: kết quả chính được kiểm chứng trên 3 hạt giống độc lập, mỗi hạt giống 10.000 episode theo khuyến nghị của Henderson và cộng sự [28]. Nhưng các phân tích sâu (Thực nghiệm B, so sánh cùng mức phục vụ, kiểm tra hành vi, độ nhạy đơn giá, độ bền zero-shot) chỉ dùng hạt giống 42, còn các thí nghiệm loại trừ ngoài thiết kế phần thưởng và thí nghiệm hold-out chỉ chạy một hạt giống, 1.000 episode.
- Phép so sánh cùng mức phục vụ bị phóng đại: lưới tham số baseline thô nên các baseline vượt mục tiêu phục vụ hơn một điểm phần trăm, làm khoảng cách chi phí (25,7% và 17,3%) là cận trên. Ở phép so sánh trực tiếp, IPPO chỉ ngang các baseline theo nhóm về chi phí.
- Mất cân bằng mức phục vụ giữa các mặt hàng: dù đã dùng hình phạt chuẩn hóa, 28,7% số cặp có fill rate dưới 85% (so với 33,0% khi dùng hình phạt tỷ lệ theo nhu cầu ở cùng ngân sách 1.000 episode), tập trung ở nhóm mặt hàng bán chậm; mục tiêu mức phục vụ chỉ được đáp ứng ở cấp hệ thống.
- Giới hạn của thực nghiệm theo giai đoạn: miền test chỉ dài 491 ngày nên

các episode chồng lấn nhau. Bootstrap theo khối tuần cho khoảng tin cậy của từng giai đoạn nhưng không loại bỏ hết tự tương quan, và mùa lễ chỉ có 9 tuần nên kết luận về mùa lễ chưa chắc chắn.

- Đặc trưng lịch và đặc trưng giá gần như không được khai thác: 27 chiều lịch chỉ đóng góp khoảng $5{,}3\%$ chi phí và 1 chiều tín hiệu giá đóng góp dưới 1% theo phân tích permutation importance (tổng cộng $28/44$ chiều quan sát), thêm đặc trưng sự kiện sắp tới không cải thiện vượt dao động giữa hạt giống, và IPPO yếu nhất ở mùa lễ.
- Dữ liệu từ một thị trường duy nhất: dữ liệu M5 là dữ liệu bán lẻ của Walmart tại Hoa Kỳ, và vector lịch (sự kiện, SNAP) phản ánh lịch của Hoa Kỳ. Mô hình học từ dữ liệu (data-driven) nên khi áp dụng cho Việt Nam *không* thể dùng lại trọng số đã học: cần huấn luyện lại trên dữ liệu bán hàng của Việt Nam và thay vector lịch bằng lịch lễ Việt Nam (Tết Nguyên đán, các ngày nghỉ lễ, mùa khuyến mãi), trong khi kiến trúc mô hình và quy trình huấn luyện được giữ nguyên.
- Không gian hành động rời rạc thô: chỉ có $K = 6$ mức đặt hàng; trong thực tế, doanh nghiệp có thể cần quyết định lượng đặt chính xác hơn.
- Chưa tích hợp dự báo nhu cầu: tác tử sử dụng trực tiếp nhu cầu lịch sử thay vì dự báo bằng mô hình học sâu chuỗi thời gian.
- Thực nghiệm trên môi trường mô phỏng: chưa được kiểm chứng trên hệ thống ERP thực tế hoặc dữ liệu vận hành trực tiếp.

5.3 Hướng phát triển trong tương lai

5.3.1 Đợt thực nghiệm cuối đã hoàn tất và các thí nghiệm còn lại

Các hạn chế nêu ở Mục 5.2 đã được chuyển thành thí nghiệm cụ thể và đợt thực nghiệm cuối (19 lần huấn luyện, gom vào một kịch bản duy nhất `scripts/campaign.py` có khả năng huấn luyện tiếp khi bị gián đoạn) đã chạy xong; kết quả nằm ở Chương 4 (Bảng 5.1 liệt kê từng lần chạy). Mỗi thí nghiệm loại trừ chỉ khác cấu hình tham chiếu đúng một thay đổi; cấu hình tham chiếu và mô hình chính dùng hình phạt mức phục vụ chuẩn hóa (3.5).

Giao thức đánh giá của đợt này cũng được củng cố: baseline tinh chỉnh trên miền val (cùng miền dùng để chọn checkpoint IPPO) thay vì miền train; báo cáo kiểm định t theo cặp cùng hệ số d_z; đánh giá thêm trên các cửa sổ cố định trải đều miền

Bảng 5.1: Đợt thực nghiệm cuối: các lần chạy, và nơi báo cáo kết quả

Lần chạy	**Thay đổi so với tham chiếu**	**Kết quả**
Mô hình chính (3 hạt giống $\times$ 10.000 episode)	Hình phạt mức phục vụ chuẩn hóa	Mục 4.4.2: ngang các baseline mạnh nhất về chi phí, mức phục vụ cao hơn 4–5 điểm
Tham chiếu 1.000 episode	—	Mốc so sánh cho các thí nghiệm loại trừ
Phần thưởng toàn cục (3 hạt giống)	`reward_mode: global`	Mục 4.5.2: chi phí tăng 419,6%
Tắt chuẩn hóa theo cặp (3 hạt giống)	`normalize_reward_per_pair: false`	Mục 4.5.2: chi phí tăng 214,3%
Baseline theo nhóm quy mô cầu	Mỗi nhóm cầu một bộ tham số (s,S), Newsvendor, EOQ	Mục 4.4.2: đối thủ mạnh nhất, ngang IPPO về chi phí
Độ bền theo điều kiện vận hành	Sức chứa 4/6 ngày, lead time 2–3 hoặc luôn 3 ngày, nhu cầu $\pm$20% (không huấn luyện lại)	Mục 4.5.8: bền, yếu khi nhu cầu giảm 20%
Phạt SLA kiểu cũ	`service_penalty_mode: demand`	Mục 4.5.4: $-2{,}5\%$, một hạt giống
Actor–Critic chung thân	`shared_trunk: true`, một optimizer, tắt value norm	Mục 4.5.3: $+13{,}2\%$
Bỏ đặc trưng lịch / cấp kho	`obs_drop`	Mục 4.5.4: lịch $-1{,}6\%$ (trong dao động), cấp kho $+141{,}5\%$
Thêm sự kiện sắp tới	2 đặc trưng: số ngày tới sự kiện kế tiếp, có sự kiện trong 7 ngày	Mục 4.5.4: $-0{,}8\%$ (trong dao động)
Warm-start	Lịch sử nhu cầu khởi tạo bằng dữ liệu thật	Mục 4.5.4: $-5{,}4\%$ (môi trường khác)
Hold-out mặt hàng	Huấn luyện 24 mặt hàng, đánh giá 6 mặt hàng chưa gặp	Mục 4.5.1: $+0{,}1\%$, không khác biệt

test; và dùng khoảng tin cậy bootstrap theo khối tuần cho từng giai đoạn nhu cầu. Còn lại chưa làm: lặp các thí nghiệm loại trừ trên nhiều hạt giống và huấn luyện chúng tới 10.000 episode; lưới tham số mịn hơn quanh mức phục vụ $90{,}15\%$ cho phép so sánh cùng mức phục vụ; thí nghiệm loại trừ riêng cho tín hiệu giá.

5.3.2 Các hướng mở rộng khác

- Lead time dài hơn 3 ngày và mục tiêu mức phục vụ khác 85% (chẳng hạn 80% hoặc 90%): phân tích độ bền hiện tại chỉ đánh giá được các thay đổi mà chính sách đã học vẫn nhận làm đầu vào (sức chứa, lead time trong khoảng 1–3 ngày, mức nhu cầu). Số chiều quan sát phụ thuộc lead time tối đa, còn hệ số phạt được hiệu chỉnh cho mục tiêu 85%, nên hai trường hợp này đòi hỏi huấn luyện lại cho từng cấu hình.
- Nhân tử Lagrange riêng cho từng cặp: thay vì cố định hệ số ϕ_{dv}, cập nhật một nhân tử cho mỗi cặp trong lúc huấn luyện để ràng buộc mức phục vụ được thỏa mãn chặt ở từng mặt hàng.
- Điều chuyển hàng liên kho: bổ sung hành động chuyển hàng giữa các kho kèm chi phí điều chuyển vào hàm phần thưởng; khi đó không gian hành động và bảng đặc tả tác tử cần được mở rộng tương ứng.
- Mở rộng sang cấu trúc đa cấp (multi-echelon): mô hình hóa quan hệ cung ứng giữa kho trung tâm và kho khu vực, cho phép tác tử học chiến lược điều phối liên kho.
- So sánh với kiến trúc huấn luyện tập trung — thực thi phi tập trung: bổ sung một nhánh MAPPO [21] trong đó Critic nhận thêm trạng thái ở cấp kho, nhằm đo lường trực tiếp giá trị của phối hợp tường minh so với phối hợp gián tiếp qua tín hiệu sức chứa. Đây là hướng mở rộng trực tiếp nhất về mặt cài đặt, vì kiến trúc hiện tại đã tách riêng mạng Actor và Critic; kết quả sẽ cho phép định lượng rõ giá trị của phối hợp tường minh trong cấu hình nghiên cứu này.
- Tích hợp cơ chế truyền thông giữa tác tử: áp dụng các phương pháp như CommNet hoặc TarMAC để cho phép tác tử chia sẻ thông tin, đặc biệt về tình trạng sức chứa kho.
- Không gian hành động liên tục: sử dụng PPO cho hành động liên tục hoặc mạng hành động phân cấp (hierarchical action) để quyết định lượng đặt hàng chính xác.

- Gán công theo độ trễ giao hàng: chi phí phát sinh ở ngày t phần lớn là hệ quả của quyết định đặt hàng ở ngày $t - L$. Hiện việc gán công này được phó thác cho GAE với $\gamma = 0{,}99$; một cơ chế liên kết phần thưởng trực tiếp với hành động sinh ra nó, theo hướng của Nam và cộng sự [23], có thể làm tín hiệu học sắc nét hơn.
- Tích hợp dự báo nhu cầu: nhúng mô hình dự báo chuỗi thời gian (LSTM, Transformer) vào vector quan sát của tác tử, tận dụng thông tin xu hướng và mùa vụ. Phương án hiện tại không dùng dự báo và có chi phí tính toán thấp (khoảng 220–280 phút huấn luyện mỗi hạt giống), nên hướng này cần được đánh giá trên tương quan lợi ích — chi phí chứ không mặc nhiên là một cải tiến.
- Triển khai thử nghiệm thực tế: nâng ứng dụng mô phỏng hiện tại thành một hệ thống kết nối API với nền tảng quản lý kho (hướng dạng SaaS), cho phép đánh giá mô hình trên dữ liệu vận hành trực tiếp, và nối luồng phiếu đề nghị đặt hàng với bộ phận mua hàng (hỏi báo giá, chọn nhà cung cấp) khi có dữ liệu nhà cung cấp. Khóa luận hiện dừng ở bước phiếu đề nghị.
- Áp dụng cho thị trường Việt Nam: thu thập dữ liệu bán hàng của doanh nghiệp Việt Nam, thay vector lịch Hoa Kỳ bằng lịch lễ Việt Nam (Tết Nguyên đán, các ngày nghỉ lễ), và huấn luyện lại mô hình với kiến trúc giữ nguyên; trọng số học từ dữ liệu Walmart không được dùng lại.
- Mở rộng quy mô: thử nghiệm với toàn bộ 3.049 SKU gốc của M5 và đánh giá khả năng mở rộng của cơ chế chia sẻ tham số.
- Lớp giao tiếp ngôn ngữ qua MCP: dùng Model Context Protocol để một mô hình ngôn ngữ lớn gọi engine IPPO như một công cụ, cho phép người quản lý kho đặt câu hỏi bằng ngôn ngữ tự nhiên (ví dụ mặt hàng nào sắp thiếu) và nhận đề xuất đặt hàng. IPPO vẫn là nơi ra quyết định định lượng; MCP chỉ lo giao tiếp và điều phối công cụ. Một prototype minh họa luồng điều phối này được trình bày ở Phụ lục 5.3.2; hướng này không thuộc đóng góp chính của khóa luận.

PHỤ LỤC A. ĐỐI CHIẾU LUẬN ĐIỂM VÀ NGUỒN TRÍCH DẪN

Phụ lục này liệt kê từng luận điểm lý thuyết được sử dụng trong khóa luận kèm nguồn gốc học thuật tương ứng, nhằm bảo đảm mọi khẳng định đều truy nguyên được về tài liệu công bố chính thống.

Mục	Luận điểm	Nguồn
A.1. Lý thuyết tồn kho		
1.1.1	Quản lý tồn kho đa điểm, đa mặt hàng trong chuỗi cung ứng bán lẻ	Silver et al. [1]; Zipkin [8]
1.1.1	Mô tả bộ dữ liệu M5: quy mô, cấu trúc phân cấp, giai đoạn thu thập	Makridakis et al. [2]; *M5 Forecasting – Accuracy* [3]
1.1.1	Tiêu chí phân loại dạng nhu cầu (ngưỡng $p = 1{,}32$; $CV^2 = 0{,}49$)	Syntetos et al. [4]
1.1.1	Nhu cầu gián đoạn và hạn chế của phương pháp dự báo thông thường	Croston [6]; Syntetos and Boylan [7]
1.1.2	Bất định của nhu cầu và thời gian giao hàng; hiện tượng vượt đơn	Zipkin [8]; Silver et al. [1]
1.1.2	Cấu trúc chi phí tồn kho và bài toán đánh đổi	Zipkin [8]
2.1.2	Mô hình lượng đặt hàng kinh tế (EOQ)	Harris [12]
2.1.2	Tính tối ưu của chính sách (s, S) và các điều kiện kèm theo	Scarf [13]
2.1.2	Mô hình người bán báo (Newsvendor) một chu kỳ	Arrow et al. [14]
2.1.1	Bài toán mất đơn hàng không có nghiệm giải tích dạng đóng	Zipkin [15]
1.3.3	Cấu trúc tồn kho đa cấp (nằm ngoài phạm vi)	Clark and Scarf [30]
1.3.3	Hiệu ứng bullwhip (nằm ngoài phạm vi)	Lee et al. [31]

Mục	Luận điểm	Nguồn
A.2. Học tăng cường		
2.2.1	Quá trình quyết định Markov và quy hoạch động ngẫu nhiên	Puterman [32]
2.2.2	Hàm giá trị, phương trình Bellman, hàm lợi thế, định lý policy gradient	Sutton and Barto [10]
2.2.3	Ước lượng lợi thế tổng quát (GAE) và đánh đổi bias–variance	Schulman et al. [27]
2.2.4	Vùng tin cậy trong tối ưu hóa chính sách	Schulman et al. [34]
2.2.4	Hàm mục tiêu cắt của PPO	Schulman et al. [26]
2.3.5	Điều kiện bảo toàn chính sách tối ưu khi định hình phần thưởng	Ng et al. [36]
A.3. Học tăng cường đa tác tử		
2.3.1	Độ phức tạp NEXP-đầy đủ của điều khiển phi tập trung	Bernstein et al. [11]
2.3.1	Mô hình Dec-POMDP	Oliehoek and Amato [9]
2.3.2	Học độc lập và vấn đề môi trường không dừng	Tan [19]
2.3.3	Thuật toán IPPO	Schröder de Witt et al. [20]
2.3.3	MAPPO và khung huấn luyện tập trung, thực thi phân tán	Yu et al. [21]
2.3.4	Chia sẻ tham số giữa các tác tử đồng nhất	Gupta et al. [18]
2.3.5	Bài toán gán tín dụng đa tác tử; phần thưởng chênh lệch (so sánh với phần thưởng phân rã cục bộ)	Wolpert and Tumer [25]
A.4. Ứng dụng, môi trường và giao thức đánh giá		
2.4.1	Học tăng cường sâu cho trò chơi phân phối bia	Oroojlooyjadid et al. [16]
2.4.1	Đánh giá học tăng cường sâu trên các lớp bài toán tồn kho	Gijsbrechts et al. [17]
3.4	Chuẩn giao diện môi trường học tăng cường	Brockman et al. [33]; Towers et al. [24]

Mục	Luận điểm	Nguồn
4.3.1	Yêu cầu đa hạt giống và tính tái lập trong đánh giá	Henderson et al. [28]
4.3.1	Phương pháp báo cáo kết quả có kiểm định thống kê	Agarwal et al. [29]

Ghi chú. Các số liệu thống kê mô tả bộ dữ liệu M5 trình bày trong Mục 1.1.1 và Bảng 1.1 do nhóm tác giả tự tính toán từ hai tệp `sales_train_evaluation.csv` và `calendar.csv`; mã nguồn tính toán được đính kèm trong kho mã của khóa luận.

PHỤ LỤC B. PROTOTYPE ĐIỀU PHỐI BẰNG MCP

Model Context Protocol (MCP) là giao thức chuẩn hóa cho phép mô hình ngôn ngữ lớn (LLM) gọi công cụ bên ngoài theo mô hình máy chủ–máy khách. Phụ lục này mô tả một prototype dùng MCP làm lớp giao tiếp phía trên engine IPPO của khóa luận. Prototype không tham gia trả lời các câu hỏi nghiên cứu.

B.1. So sánh hai kiến trúc điều phối

Bảng 5.3: So sánh kiến trúc IPPO và MCP theo các chiều điều phối

Khía cạnh	IPPO (đề tài này)	Kiến trúc MCP
Phân công nhiệm vụ	Không có: mỗi tác tử có nhiệm vụ cố định (một cặp kho–mặt hàng)	Host/LLM phân công tường minh cho từng máy chủ
Chọn hành động	Mạng chính sách $\pi_\theta(a \mid o)$ ánh xạ quan sát sang hành động	LLM suy luận và chọn công cụ phù hợp
Lấy ngữ cảnh	Vector quan sát 44 chiều từ môi trường	Máy chủ cung cấp ngữ cảnh qua giao thức chuẩn
Kết quả trả về	Phần thưởng và trạng thái kế tiếp từ môi trường	Kết quả công cụ trả về LLM để tiếp tục suy luận

Hai kiến trúc phục vụ hai lớp bài toán khác nhau. IPPO phù hợp khi hành động là lượng đặt hàng và tín hiệu phản hồi là chi phí. MCP phù hợp khi hệ thống cần giao tiếp ngôn ngữ với người dùng và gọi nhiều công cụ đa dạng.

B.2. Luồng điều phối và công cụ

Theo luồng ngữ cảnh $\rightarrow$ nhiệm vụ $\rightarrow$ chọn công cụ $\rightarrow$ thực thi $\rightarrow$ trả kết quả: người quản lý kho đặt câu hỏi (ví dụ "tuần tới kho CA_3 có mặt hàng nào sắp thiếu không?"); LLM nhận nhiệm vụ và chọn công cụ; máy chủ MCP lấy ngữ cảnh từ môi trường mô phỏng (tồn kho, hàng đang về, lịch) và gọi chính sách IPPO hoặc baseline; kết quả trả về LLM để tổng hợp câu trả lời. IPPO vẫn là nơi ra quyết định định lượng.

Prototype (`app/mcp_server.py`, Python MCP SDK) cung cấp năm công cụ và một tài nguyên (Bảng 5.4), tái sử dụng phần lõi mô phỏng của ứng dụng Streamlit. Prototype đã được kiểm chứng bằng một client MCP chuẩn qua giao thức stdio: client

liệt kê được đủ công cụ và gọi thành công. Prototype chưa được đánh giá với người dùng thật và chưa xử lý xác thực.

Bảng 5.4: Công cụ của prototype MCP

Công cụ / tài nguyên	**Chức năng**
`danh_sach_kho_va_mat_hang`	Liệt kê 10 kho, 30 mặt hàng và chỉ số tương ứng
`canh_bao_thieu_hang`	Mô phỏng tới một ngày, trả về các cặp có tồn kho cộng hàng đang về dưới ngưỡng số ngày cầu
`de_xuat_dat_hang`	Tình trạng một cặp và lượng đặt đề xuất của IPPO cùng ba baseline
`mo_phong`	Chạy một chính sách trên toàn mạng, trả về chi phí, fill rate, số ngày–cặp thiếu hàng
`what_if`	So sánh các chính sách khi thay đổi nhu cầu, sức chứa hoặc thời gian giao
`ket-qua://tong-hop`	Tài nguyên chứa kết quả đánh giá chính thức để LLM trích dẫn

TÀI LIỆU THAM KHẢO

[1] E. A. Silver, D. F. Pyke, and D. J. Thomas, *Inventory and Production Management in Supply Chains*, 4th ed. Boca Raton, FL: CRC Press, 2016.

[2] S. Makridakis, E. Spiliotis, and V. Assimakopoulos, "The M5 competition: Background, organization, and implementation," *International Journal of Forecasting*, vol. 38, no. 4, pp. 1325–1336, 2022. DOI: 10.1016/j.ijforecast.2021.07.007

[3] "M5 forecasting – accuracy," Kaggle, Accessed Sept. 1, 2026. [Online]. Available: https://www.kaggle.com/competitions/m5-forecasting-accuracy

[4] A. A. Syntetos, J. E. Boylan, and J. D. Croston, "On the categorization of demand patterns," *Journal of the Operational Research Society*, vol. 56, no. 5, pp. 495–503, 2005. DOI: 10.1057/palgrave.jors.2601841

[5] A. I. Kostenko and R. J. Hyndman, "A note on the categorization of demand patterns," *Journal of the Operational Research Society*, vol. 57, no. 10, pp. 1256–1257, 2006. DOI: 10.1057/palgrave.jors.2602211

[6] J. D. Croston, "Forecasting and stock control for intermittent demands," *Operational Research Quarterly*, vol. 23, no. 3, pp. 289–303, 1972. DOI: 10.1057/jors.1972.50

[7] A. A. Syntetos and J. E. Boylan, "The accuracy of intermittent demand estimates," *International Journal of Forecasting*, vol. 21, no. 2, pp. 303–314, 2005. DOI: 10.1016/j.ijforecast.2004.10.001

[8] P. H. Zipkin, *Foundations of Inventory Management*. Boston: McGraw-Hill, 2000.

[9] F. A. Oliehoek and C. Amato, *A Concise Introduction to Decentralized POMDPs*. Cham: Springer, 2016. DOI: 10.1007/978-3-319-28929-8

[10] R. S. Sutton and A. G. Barto, *Reinforcement Learning: An Introduction*, 2nd ed. Cambridge, MA: MIT Press, 2018.

[11] D. S. Bernstein, R. Givan, N. Immerman, and S. Zilberstein, "The complexity of decentralized control of Markov decision processes," *Mathematics of Operations Research*, vol. 27, no. 4, pp. 819–840, 2002. DOI: 10.1287/moor.27.4.819.297

[12] F. W. Harris, "How many parts to make at once," *Factory, The Magazine of Management*, vol. 10, no. 2, pp. 135–136, 152, 1913.

[13] H. Scarf, "The optimality of (S, s) policies in the dynamic inventory problem," in *Mathematical Methods in the Social Sciences*, K. J. Arrow, S. Karlin, and P. Suppes, eds., Stanford, CA: Stanford University Press, 1960, pp. 196–202.

[14] K. J. Arrow, T. Harris, and J. Marschak, "Optimal inventory policy," *Econometrica*, vol. 19, no. 3, pp. 250–272, 1951. DOI: 10.2307/1906813

[15] P. Zipkin, "Old and new methods for lost-sales inventory systems," *Operations Research*, vol. 56, no. 5, pp. 1256–1263, 2008. DOI: 10.1287/opre.1070.0471

[16] A. Oroojlooyjadid, M. Nazari, L. V. Snyder, and M. Takáč, "A deep Q-network for the beer game: Deep reinforcement learning for inventory optimization," *Manufacturing & Service Operations Management*, vol. 24, no. 1, pp. 285–304, 2022. DOI: 10.1287/msom.2020.0939

[17] J. Gijsbrechts, R. N. Boute, J. A. Van Mieghem, and D. J. Zhang, "Can deep reinforcement learning improve inventory management? Performance on lost sales, dual-sourcing, and multi-echelon problems," *Manufacturing & Service Operations Management*, vol. 24, no. 3, pp. 1349–1368, 2022. DOI: 10.1287/msom.2021.1064

[18] J. K. Gupta, M. Egorov, and M. Kochenderfer, "Cooperative multi-agent control using deep reinforcement learning," in *Autonomous Agents and Multiagent Systems (AAMAS 2017 Workshops)*, ser. Lecture Notes in Computer Science, vol. 10642, Springer, 2017, pp. 66–83. DOI: 10.1007/978-3-319-71682-4_5

[19] M. Tan, "Multi-agent reinforcement learning: Independent vs. cooperative agents," in *Proceedings of the 10th International Conference on Machine Learning*, 1993, pp. 330–337.

[20] C. Schröder de Witt et al., *Is independent learning all you need in the StarCraft multi-agent challenge?* 2020. arXiv: 2011.09533.

[21] C. Yu et al., "The surprising effectiveness of PPO in cooperative multi-agent games," in *Advances in Neural Information Processing Systems 35 (NeurIPS 2022), Datasets and Benchmarks Track*, 2022, pp. 24 611–24 624.

[22] H. Zhu and H. Wu, "Deep learning and multi-agent simulation for spatiotemporal inventory management in e-commerce," *International Journal of Simulation and Process Modelling*, vol. 23, no. 5, pp. 11–23, 2026. DOI: 10.1504/IJSPM.2026.152575

[23] H. Nam, S. Im, J. Lee, C. Shin, and H. Ju. "Action-linked credit assignment for event-driven warehouse management via multi-agentic reinforcement learning." Preprint, not peer reviewed, SSRN. [Online]. Available: https://ssrn.com/abstract=7068293

[24] M. Towers, A. Kwiatkowski, J. Terry, J. U. Balis, G. De Cola, T. Deleu, et al., *Gymnasium: A standard interface for reinforcement learning environments*, 2024. arXiv: 2407.17032.

[25] D. H. Wolpert and K. Tumer, "Optimal payoff functions for members of collectives," *Advances in Complex Systems*, vol. 4, no. 2–3, pp. 265–279, 2001. DOI: 10.1142/S0219525901000188

[26] J. Schulman, F. Wolski, P. Dhariwal, A. Radford, and O. Klimov, *Proximal policy optimization algorithms*, 2017. arXiv: 1707.06347.

[27] J. Schulman, P. Moritz, S. Levine, M. Jordan, and P. Abbeel, "High-dimensional continuous control using generalized advantage estimation," in *Proceedings of the 4th International Conference on Learning Representations (ICLR)*, 2016. arXiv: 1506.02438.

[28] P. Henderson, R. Islam, P. Bachman, J. Pineau, D. Precup, and D. Meger, "Deep reinforcement learning that matters," in *Proceedings of the 32nd AAAI Conference on Artificial Intelligence*, 2018, pp. 3207–3214.

[29] R. Agarwal, M. Schwarzer, P. S. Castro, A. Courville, and M. G. Bellemare, "Deep reinforcement learning at the edge of the statistical precipice," in *Ad-*

vances in Neural Information Processing Systems 34 (NeurIPS 2021), 2021, pp. 29 304–29 320.

[30] A. J. Clark and H. Scarf, "Optimal policies for a multi-echelon inventory problem," *Management Science*, vol. 6, no. 4, pp. 475–490, 1960. DOI: 10.1287/mnsc.6.4.475

[31] H. L. Lee, V. Padmanabhan, and S. Whang, "Information distortion in a supply chain: The bullwhip effect," *Management Science*, vol. 43, no. 4, pp. 546–558, 1997. DOI: 10.1287/mnsc.43.4.546

[32] M. L. Puterman, *Markov Decision Processes: Discrete Stochastic Dynamic Programming*. New York: John Wiley & Sons, 1994.

[33] G. Brockman et al., *OpenAI Gym*, 2016. arXiv: 1606.01540.

[34] J. Schulman, S. Levine, P. Abbeel, M. Jordan, and P. Moritz, "Trust region policy optimization," in *Proceedings of the 32nd International Conference on Machine Learning*, 2015, pp. 1889–1897.

[35] R. E. Bellman, *Dynamic Programming*. Princeton, NJ: Princeton University Press, 1957.

[36] A. Y. Ng, D. Harada, and S. Russell, "Policy invariance under reward transformations: Theory and application to reward shaping," in *Proceedings of the 16th International Conference on Machine Learning*, 1999, pp. 278–287.

[37] S. Devlin and D. Kudenko, "Theoretical considerations of potential-based reward shaping for multi-agent systems," in *Proceedings of the 10th International Conference on Autonomous Agents and Multiagent Systems (AAMAS 2011)*, 2011, pp. 225–232.

[38] B. De Moor, J. Gijsbrechts, and R. N. Boute, "Reward shaping to improve the performance of deep reinforcement learning in perishable inventory management," *European Journal of Operational Research*, vol. 301, no. 2, pp. 535–545, 2022. DOI: 10.1016/j.ejor.2021.11.026

[39] C. D. Hubbs, H. D. Perez, O. Sarwar, N. V. Sahinidis, I. E. Grossmann, and J. M. Wassick, *OR-Gym: A reinforcement learning library for operations research problems*, 2020. arXiv: 2008.06319.

[40] Y. Ding et al., *Multi-agent reinforcement learning with shared resources for inventory management*, Presented at the RL4RealLife Workshop, NeurIPS 2022, 2022. arXiv: 2212.07684.

[41] X. Yang et al., *A versatile multi-agent reinforcement learning benchmark for inventory management*, 2023. DOI: 10.48550/arXiv.2306.07542 arXiv: 2306.07542.

[42] M. Mousa, D. van de Berg, N. Kotecha, E. A. del Rio Chanona, and M. Mowbray, "An analysis of multi-agent reinforcement learning for decentralized inventory control systems," *Computers & Chemical Engineering*, vol. 188, p. 108 783, 2024. DOI: 10.1016/j.compchemeng.2024.108783

[43] X. Liu, M. Hu, Y. Peng, and Y. Yang, "Multi-agent deep reinforcement learning for multi-echelon inventory management," *Production and Operations Management*, vol. 34, no. 7, pp. 1836–1856, 2025. DOI: 10.1177/10591478241305863