

**TỔNG LIÊN ĐOÀN LAO ĐỘNG VIỆT NAM
TRƯỜNG ĐẠI HỌC TÔN ĐỨC THẮNG
KHOA CÔNG NGHỆ THÔNG TIN**



**LÊ MINH LÝ - 52300220
SỬ THỊ YẾN LINH - 52300218**

**XÂY DỰNG MÔ HÌNH HỌC TĂNG
CƯỜNG TỐI ƯU HÓA CHÍNH SÁCH ĐẶT
HÀNG LẠI TRONG QUẢN LÝ TỒN KHO
ĐA KHO**

**KHÓA LUẬN TỐT NGHIỆP
MẠNG MÁY TÍNH VÀ TRUYỀN THÔNG
DỮ LIỆU**

THÀNH PHỐ HỒ CHÍ MINH, NĂM 2026

**TỔNG LIÊN ĐOÀN LAO ĐỘNG VIỆT NAM
TRƯỜNG ĐẠI HỌC TÔN ĐỨC THẮNG
KHOA CÔNG NGHỆ THÔNG TIN**



**LÊ MINH LÝ - 52300220
SỬ THỊ YẾN LINH - 52300218**

**XÂY DỰNG MÔ HÌNH HỌC TĂNG
CƯỜNG TỐI ƯU HÓA CHÍNH SÁCH ĐẶT
HÀNG LẠI TRONG QUẢN LÝ TỒN KHO
ĐA KHO**

**KHÓA LUẬN TỐT NGHIỆP
MẠNG MÁY TÍNH VÀ TRUYỀN THÔNG
DỮ LIỆU**

Giảng viên hướng dẫn
TS. HỒ THỊ LINH

THÀNH PHỐ HỒ CHÍ MINH, NĂM 2026

LỜI CẢM ƠN

Đầu tiên, chúng em xin gửi lời cảm ơn chân thành và sâu sắc nhất đến TS. Hồ Thị Linh, giảng viên hướng dẫn khóa luận tốt nghiệp. Sự hướng dẫn tận tình, những ý kiến đóng góp quý báu và sự hỗ trợ kịp thời của cô đã định hướng và giúp chúng em hoàn thành tốt khóa luận này.

Bên cạnh đó, chúng em cũng xin cảm ơn khoa Công nghệ Thông tin, trường Đại học Tôn Đức Thắng đã tạo điều kiện học tập và cung cấp những nền tảng kiến thức vững chắc, tạo môi trường thuận lợi để chúng em có thể áp dụng vào thực tiễn. Do thời gian và trình độ còn những hạn chế nhất định, báo cáo chắc chắn không tránh khỏi những thiếu sót. Chúng em rất mong nhận được sự cảm thông và những lời góp ý chân thành từ quý thầy cô để đề tài được hoàn thiện hơn và chúng em rút ra được những bài học quý giá.

Chúng em xin chân thành cảm ơn!

TP. Hồ Chí Minh, ngày 09 tháng 05 năm 2026

Tác giả

(Ký và ghi rõ họ tên)

Lê Minh Lý

Tác giả

(Ký và ghi rõ họ tên)

Sử Thị Yến Linh

CÔNG TRÌNH ĐƯỢC HOÀN THÀNH TẠI TRƯỜNG ĐẠI HỌC TÔN ĐỨC THẮNG

Chúng tôi xin cam đoan đây là công trình nghiên cứu của chúng tôi và được sự hướng dẫn khoa học của TS. Hồ Thị Linh. Các nội dung nghiên cứu, kết quả trong đề tài này là trung thực và chưa công bố dưới bất kỳ hình thức nào trước đây. Những số liệu trong các bảng biểu phục vụ cho việc phân tích, nhận xét, đánh giá được chính tác giả thu thập từ các nguồn khác nhau có ghi rõ trong phần tài liệu tham khảo.

Ngoài ra, trong Khóa luận tốt nghiệp còn sử dụng một số nhận xét, đánh giá cũng như số liệu của các tác giả khác, cơ quan tổ chức khác đều có trích dẫn và chú thích nguồn gốc.

Nếu phát hiện có bất kỳ sự gian lận nào chúng tôi xin hoàn toàn chịu trách nhiệm về nội dung Khóa luận tốt nghiệp của mình. Trường Đại học Tôn Đức Thắng không liên quan đến những vi phạm tác quyền, bản quyền do chúng tôi gây ra trong quá trình thực hiện (nếu có).

TP. Hồ Chí Minh, ngày 09 tháng 05 năm 2026

Tác giả

(Ký và ghi rõ họ tên)

Tác giả

(Ký và ghi rõ họ tên)

Lê Minh Lý

Sử Thị Yến Linh

PHẦN XÁC NHẬN VÀ ĐÁNH GIÁ CỦA GIẢNG VIÊN

Phần xác nhận của GV hướng dẫn

Tp. Hồ Chí Minh, ngàytháng

.....năm

(Ký và ghi họ tên)

Phần đánh giá của GV chấm bài

Tp. Hồ Chí Minh, ngàytháng

.....năm

(Ký và ghi họ tên)

XÂY DỰNG MÔ HÌNH HỌC TĂNG CƯỜNG TỐI ƯU HÓA CHÍNH SÁCH ĐẶT HÀNG LẠI TRONG QUẢN LÝ TỒN KHO ĐA KHO

TÓM TẮT

Quản lý tồn kho trong mạng lưới bán lẻ gồm nhiều kho và nhiều mặt hàng là bài toán ra quyết định tuần tự dưới điều kiện bất định, đòi hỏi cân bằng đồng thời nhiều nhóm chi phí xung đột nhau: chi phí lưu kho, chi phí thiếu hàng, chi phí đặt hàng cố định, chi phí phạt tràn kho và yêu cầu duy trì mức phục vụ khách hàng. Các chính sách cổ điển như EOQ, (s, S) và Newsvendor được xây dựng trên những giả định chặt — nhu cầu xác định hoặc dừng, thời gian giao hàng cố định, không ràng buộc sức chứa — nên khó giữ được tính tối ưu khi nhu cầu ngẫu nhiên, thời gian giao hàng biến động và các mặt hàng phải chia sẻ một dung lượng kho hữu hạn.

Khóa luận đề xuất giải quyết bài toán trên bằng học tăng cường đa tác tử. Hệ thống gồm $N = 10$ kho và $M = 50$ mặt hàng được mô hình hóa thành 500 tác tử tương ứng với 500 cặp kho–mặt hàng, mỗi tác tử tự ra quyết định đặt hàng dựa trên quan sát cục bộ của mình. Các tác tử được huấn luyện bằng thuật toán Independent Multi-Agent Proximal Policy Optimization (IPPO) kết hợp cơ chế chia sẻ tham số (parameter sharing): toàn bộ 500 tác tử dùng chung một mạng Actor–Critic duy nhất, cho phép mở rộng quy mô mà không làm bùng nổ số lượng tham số cần học. Hàm phần thưởng được thiết kế theo hướng phân rã cục bộ (local reward decomposition) kèm thành phần phạt dựa trên tỷ lệ đáp ứng nhu cầu tính trên cửa sổ trượt 30 ngày, nhằm giảm phương sai của tín hiệu học so với phần thưởng toàn cục dùng chung.

Môi trường mô phỏng được xây dựng theo chuẩn Gymnasium, với tham số nhu cầu được hiệu chỉnh từ bộ dữ liệu bán lẻ thực tế M5 Walmart (10 cửa hàng, 50 mặt hàng, 1.941 ngày doanh số) và thời gian giao hàng ngẫu nhiên trong khoảng từ một đến ba ngày. Hiệu năng của mô hình đề xuất được đối chứng với ba chính sách tồn kho cổ điển (EOQ, (s, S) , Newsvendor) trên cùng môi trường, theo một giao thức đánh giá thống nhất gồm nhiều hạt giống ngẫu nhiên và kiểm định thống kê, trên bốn nhóm chỉ số: tổng chi phí vận hành, tỷ lệ đáp ứng nhu cầu, và cơ cấu các thành phần chi phí thành phần.

Kết quả thực nghiệm được phân tích trên ba khía cạnh: (i) so sánh giữa tác tử IPPO và các chính sách cổ điển về tổng chi phí vận hành và mức phục vụ; (ii) khả

năng tổng quát hóa của chính sách chia sẻ tham số sang những mặt hàng có quy mô nhu cầu khác nhau; và (iii) ảnh hưởng của cách thiết kế hàm phần thưởng phân rã cục bộ tới quá trình học. Khóa luận đồng thời trình bày những kịch bản mà phương pháp đề xuất chưa vượt trội so với chính sách cổ điển kèm phân tích nguyên nhân.

BUILDING A REINFORCEMENT LEARNING MODEL FOR OPTIMIZING REORDER POLICY IN MULTI-WAREHOUSE INVENTORY MANAGEMENT

ABSTRACT

Inventory control across a retail network of multiple warehouses and multiple stock-keeping units (SKUs) is a sequential decision-making problem under uncertainty that requires balancing several conflicting cost components at once: holding cost, stockout cost, fixed ordering cost, warehouse overflow penalty, and the requirement to sustain a target customer service level. Classical policies such as EOQ, (s, S) and the Newsvendor model rest on restrictive assumptions — deterministic or stationary demand, fixed lead times, and unconstrained storage capacity — and therefore lose their optimality guarantees once demand is stochastic, lead times fluctuate, and multiple SKUs must share a finite warehouse capacity.

This thesis addresses the problem through multi-agent reinforcement learning. A system of $N = 10$ warehouses and $M = 50$ SKUs is modelled as 500 agents, one per warehouse–SKU pair, each issuing its own replenishment decisions from local observations. The agents are trained with Independent Multi-Agent Proximal Policy Optimization (IPPO) under full parameter sharing: a single Actor–Critic network is shared across all 500 agents, which keeps the number of learnable parameters constant as the system scales. The reward is designed with local decomposition and a 30-day rolling-window fill-rate penalty term, reducing the variance of the learning signal relative to a single shared global reward.

The simulation environment follows the Gymnasium interface, with demand parameters calibrated from the real-world M5 Walmart retail dataset (10 stores, 50 SKUs, 1,941 days of sales data) and stochastic lead times drawn from one to three days. The proposed model is benchmarked against three classical inventory policies (EOQ, (s, S) , Newsvendor) within the same environment under a unified evaluation protocol involving multiple random seeds and statistical significance testing, across four metric groups: total operational cost, fill rate, and the breakdown of individual cost components.

Experimental results are analysed along three dimensions: (i) the comparison between the IPPO agent and the classical baselines in terms of total operational cost

and service level; (ii) the generalization capability of the shared-parameter policy across SKUs of differing demand scale; and (iii) the effect of local reward decomposition on the learning process. The thesis also reports scenarios in which the proposed method does not outperform the classical baselines, together with an analysis of the underlying causes.

MỤC LỤC

DANH MỤC HÌNH VẼ.....	xi
DANH MỤC BẢNG BIỂU.....	xii
DANH MỤC CÁC CHỮ VIẾT TẮT	xiii
CHƯƠNG 1. TỔNG QUAN VỀ ĐỀ TÀI.....	1
1.1 Bối cảnh nghiên cứu và tính cấp thiết của đề tài	1
1.1.1 <i>Thực trạng quản lý tồn kho trong mạng lưới bán lẻ đa điểm</i>	<i>1</i>
1.1.2 <i>Thách thức trong việc tối ưu hóa chính sách đặt hàng lại.....</i>	<i>2</i>
1.1.3 <i>Hạn chế của phương pháp truyền thống và sự cần thiết của học tăng cường đa tác tử.....</i>	<i>3</i>
1.2 Mục tiêu và câu hỏi nghiên cứu	4
1.2.1 <i>Mục tiêu nghiên cứu</i>	<i>4</i>
1.2.2 <i>Câu hỏi nghiên cứu</i>	<i>4</i>
1.3 Đối tượng và phạm vi nghiên cứu	5
1.3.1 <i>Đối tượng nghiên cứu</i>	<i>5</i>
1.3.2 <i>Phạm vi trong đề tài</i>	<i>5</i>
1.3.3 <i>Giới hạn phạm vi</i>	<i>6</i>
1.4 Phương pháp nghiên cứu	6
1.5 Ý nghĩa khoa học và thực tiễn của đề tài.....	6
1.6 Bố cục của khóa luận.....	7
CHƯƠNG 2. CƠ SỞ LÝ THUYẾT VÀ CÁC CÔNG TRÌNH LIÊN QUAN	8
2.1 Lý thuyết kiểm soát tồn kho ngẫu nhiên	8
2.1.1 <i>Mô hình tồn kho và các thành phần chi phí</i>	<i>8</i>
2.1.2 <i>Các chính sách đặt hàng lại cổ điển</i>	<i>9</i>
2.1.3 <i>Các thước đo mức phục vụ trong quản lý tồn kho</i>	<i>9</i>
2.2 Nền tảng học tăng cường.....	10
2.2.1 <i>Quá trình quyết định Markov (MDP)</i>	<i>10</i>

2.2.2	Hàm giá trị và phương trình Bellman.....	10
2.2.3	Ước lượng lợi thế tổng quát (GAE).....	11
2.2.4	Thuật toán PPO (Proximal Policy Optimization).....	11
2.3	Học tăng cường đa tác tử.....	11
2.3.1	Mô hình Dec-POMDP	11
2.3.2	Học độc lập (Independent Learning).....	12
2.3.3	IPPO — Independent Multi-Agent PPO	12
2.3.4	Chia sẻ tham số (Parameter Sharing)	12
2.3.5	Phần thưởng phân rã cục bộ và bài toán gán tín dụng.....	13
2.4	Các công trình nghiên cứu liên quan	13
2.4.1	Học tăng cường trong quản lý tồn kho	13
2.4.2	Khoảng trống nghiên cứu và định vị đóng góp.....	14
	CHƯƠNG 3. PHÂN TÍCH VÀ THIẾT KẾ MÔ HÌNH	16
3.1	Mô hình hóa bài toán tồn kho đa kho	16
3.1.1	Mô tả mạng lưới.....	16
3.1.2	Thiết lập bài toán dưới dạng MDP đa tác tử.....	16
3.2	Thiết kế hàm phần thưởng	17
3.2.1	Phần thưởng phân rã cục bộ.....	17
3.2.2	Vai trò của thành phần phạt fill rate	17
3.2.3	Các tham số chi phí.....	18
3.3	Kiến trúc mạng Actor–Critic chia sẻ tham số.....	18
3.3.1	Mạng SharedActorCritic	18
3.3.2	Quy trình huấn luyện IPPO.....	18
3.4	Thiết kế môi trường mô phỏng	19
	CHƯƠNG 4. THỰC NGHIỆM VÀ ĐÁNH GIÁ KẾT QUẢ	21
4.1	Cấu hình thực nghiệm.....	21
4.1.1	Môi trường phần cứng và phần mềm	21
4.1.2	Nguồn dữ liệu và tiền xử lý	21

4.1.3	<i>Thiết lập kịch bản mô phỏng</i>	21
4.2	Phương pháp đối chứng (Baselines).....	21
4.3	Giao thức đánh giá	22
4.3.1	<i>Đánh giá đa hạt giống</i>	22
4.3.2	<i>Các chỉ số đánh giá</i>	22
4.4	Kết quả thực nghiệm	23
4.4.1	<i>Quá trình huấn luyện và tính hội tụ</i>	23
4.4.2	<i>So sánh tổng chi phí vận hành</i>	23
4.4.3	<i>Phân tích cơ cấu chi phí</i>	23
4.4.4	<i>Đánh giá tỷ lệ đáp ứng dịch vụ</i>	23
4.5	Phân tích chuyên sâu	24
4.5.1	<i>Khả năng tổng quát hóa qua parameter sharing (Câu hỏi 2)</i>	24
4.5.2	<i>Ảnh hưởng của hàm phần thưởng phân rã cục bộ (Câu hỏi 3)</i>	24
4.5.3	<i>Các kịch bản IPPO chưa vượt trội</i>	24
4.6	Thảo luận	24
	CHƯƠNG 5. KẾT LUẬN VÀ HƯỚNG PHÁT TRIỂN	25
5.1	Tổng kết các kết quả đạt được	25
5.1.1	<i>Trả lời các câu hỏi nghiên cứu</i>	25
5.2	Những hạn chế còn tồn tại	25
5.3	Hướng phát triển trong tương lai	26
	PHỤ LỤC A. ĐỐI CHIẾU LUẬN ĐIỂM VÀ NGUỒN TRÍCH DẪN	27
	TÀI LIỆU THAM KHẢO	30

DANH MỤC HÌNH VẼ

DANH MỤC BẢNG BIỂU

Bảng 1.1: Phân loại dạng nhu cầu của 30.490 chuỗi cửa hàng–mặt hàng trong bộ dữ liệu M5 theo tiêu chí của Syntetos và cộng sự [4]	2
Bảng 1.2: Các nhóm chi phí trong bài toán tồn kho đang xét.....	2
Bảng 2.1: So sánh tổng quan các công trình nghiên cứu liên quan.....	14
Bảng 3.1: Tham số chi phí trong môi trường mô phỏng	18
Bảng 3.2: Siêu tham số huấn luyện.....	19
Bảng 4.1: Cấu hình môi trường mô phỏng.....	22
Bảng 4.2: Tổng chi phí vận hành (trung bình $\pm$ độ lệch chuẩn, 5 seeds)	23

DANH MỤC CÁC CHỮ VIẾT TẮT

Dec-POMDP	Decentralized Partially Observable Markov Decision Process (Quá trình quyết định Markov có quan sát bộ phận phi tập trung)
EOQ	Economic Order Quantity (Lượng đặt hàng kinh tế)
GAE	Generalized Advantage Estimation (Ước lượng lợi thế tổng quát)
IPPO	Independent Proximal Policy Optimization (Tối ưu hóa chính sách cận đại độc lập)
MARL	Multi-Agent Reinforcement Learning (Học tăng cường đa tác tử)
MDP	Markov Decision Process (Quá trình quyết định Markov)
MLP	Multilayer Perceptron (Mạng nơ-ron truyền thẳng đa tầng)
PPO	Proximal Policy Optimization (Tối ưu hóa chính sách cận đại)
RL	Reinforcement Learning (Học tăng cường)
SCM	Supply Chain Management (Quản trị chuỗi cung ứng)
SKU	Stock Keeping Unit (Đơn vị quản lý tồn kho)
SNAP	Supplemental Nutrition Assistance Program (Chương trình trợ cấp dinh dưỡng)

CHƯƠNG 1. TỔNG QUAN VỀ ĐỀ TÀI

1.1 Bối cảnh nghiên cứu và tính cấp thiết của đề tài

1.1.1 Thực trạng quản lý tồn kho trong mạng lưới bán lẻ đa điểm

Trong hoạt động bán lẻ hiện đại, hàng hóa không được lưu trữ tập trung tại một điểm duy nhất mà được phân tán trên một mạng lưới gồm nhiều kho hoặc nhiều cửa hàng đặt tại các khu vực địa lý khác nhau. Mỗi điểm lưu trữ phục vụ một tập khách hàng riêng, đối mặt với một chuỗi nhu cầu riêng và phải tự ra quyết định bổ sung hàng hóa cho hàng trăm đến hàng nghìn mặt hàng khác nhau [1]. Bài toán vì vậy không còn là việc xác định một mức đặt hàng đơn lẻ, mà là việc điều phối đồng thời một số lượng rất lớn các quyết định có ràng buộc lẫn nhau.

Đặc điểm này thể hiện rõ trong dữ liệu bán lẻ thực tế. Bộ dữ liệu M5, công bố trong cuộc thi dự báo M5 do Makridakis và cộng sự [2] tổ chức, ghi nhận doanh số bán hàng theo ngày của 3.049 mặt hàng tại 10 cửa hàng của Walmart thuộc ba bang California, Texas và Wisconsin, trải trên 1.941 ngày từ ngày 29 tháng 01 năm 2011 đến ngày 22 tháng 05 năm 2016¹. Tổ hợp của hàng và mặt hàng tạo thành 30.490 chuỗi thời gian nhu cầu ở cấp độ chi tiết nhất.

Thống kê trên toàn bộ 30.490 chuỗi này cho thấy hai đặc trưng có ảnh hưởng trực tiếp tới thiết kế chính sách đặt hàng. Thứ nhất, nhu cầu ở cấp cửa hàng–mặt hàng có quy mô rất nhỏ và phân bố lệch mạnh: nhu cầu trung bình là 1,13 đơn vị mỗi ngày, nhưng trung vị chỉ là 0,45 đơn vị, và 73,4% số chuỗi có nhu cầu trung bình dưới một đơn vị mỗi ngày. Thứ hai, nhu cầu mang tính gián đoạn rõ rệt, với tỷ lệ ngày không phát sinh giao dịch trung bình đạt 68%. Áp dụng tiêu chí phân loại của Syntetos và cộng sự [4] với các ngưỡng khoảng cách giữa hai lần phát sinh nhu cầu $p = 1,32$ và bình phương hệ số biến thiên $CV^2 = 0,49$ (trong đó Kostenko và Hyndman [5] đã chứng minh kết quả biên chính xác với giá trị giới hạn $p = 4/3 \approx 1,333$ và đề xuất quy tắc phân loại chỉnh sửa), có tới 95,2% số chuỗi thuộc hai nhóm *intermittent* và *lumpy* (Bảng 1.1).

Đặc điểm gián đoạn này khiến các phương pháp dự báo và các công thức tồn kho xây dựng trên giả định nhu cầu liên tục và phân phối chuẩn trở nên kém phù hợp

¹Các thống kê được tính từ hai tệp `calendar.csv` và `sales_train_evaluation.csv` trong bộ dữ liệu M5 [3].

Bảng 1.1: Phân loại dạng nhu cầu của 30.490 chuỗi cửa hàng–mặt hàng trong bộ dữ liệu M5 theo tiêu chí của Syntetos và cộng sự [4]

Nhóm	Đặc điểm	Tỷ lệ
Smooth	$p < 1,32; CV^2 < 0,49$	3,2%
Erratic	$p < 1,32; CV^2 \geq 0,49$	1,6%
Intermittent	$p \geq 1,32; CV^2 < 0,49$	75,7%
Lumpy	$p \geq 1,32; CV^2 \geq 0,49$	19,5%

[6], [7]. Quản lý tồn kho trên một mạng lưới như vậy đòi hỏi những công cụ ra quyết định có khả năng thích ứng, thay vì các bộ tham số tĩnh được thiết lập một lần và áp dụng cố định.

1.1.2 Thách thức trong việc tối ưu hóa chính sách đặt hàng lại

Việc xây dựng chính sách đặt hàng lại trong mạng lưới đa kho – đa mặt hàng đối mặt với bốn nhóm thách thức chính.

Thứ nhất, tính bất định kép của nhu cầu và thời gian giao hàng. Nhu cầu tiêu thụ biến động ngẫu nhiên theo thời gian, đồng thời thời gian từ lúc phát lệnh đặt hàng đến lúc hàng thực nhập kho cũng không cố định [8]. Khi thời gian giao hàng là biến ngẫu nhiên, các đơn hàng phát ra ở những thời điểm khác nhau có thể về kho không đúng thứ tự, khiến các công thức tính tồn kho an toàn cổ điển chỉ còn giữ vai trò xấp xỉ [1].

Thứ hai, bài toán đánh đổi giữa nhiều nhóm chi phí xung đột. Mục tiêu vận hành không quy về một đại lượng duy nhất mà là tổng hợp của nhiều thành phần có chiều tác động ngược nhau, được tóm tắt trong Bảng 1.2. Giảm tồn kho làm giảm chi phí lưu kho nhưng làm tăng rủi ro thiếu hàng; đặt hàng theo lô lớn làm giảm chi phí đặt hàng cố định nhưng làm tăng chi phí lưu kho và nguy cơ vượt sức chứa [8].

Bảng 1.2: Các nhóm chi phí trong bài toán tồn kho đang xét

Thành phần chi phí	Ký hiệu	Chiều tác động
Chi phí lưu kho	c_{lk}	Tăng khi mức tồn kho cao
Chi phí thiếu hàng	c_{th}	Tăng khi xảy ra hết hàng
Chi phí đặt hàng cố định	c_{dh}	Tăng theo tần suất đặt hàng
Phạt tràn kho	p_{tk}	Tăng khi vượt sức chứa kho
Phạt vi phạm mức phục vụ	ϕ_{dv}	Tăng khi tỷ lệ đáp ứng dưới ngưỡng

Thứ ba, ràng buộc sức chứa tạo ra sự phụ thuộc giữa các mặt hàng. Các mặt hàng cùng nằm trong một kho chia sẻ một dung lượng hữu hạn. Quyết định đặt hàng

của một mặt hàng do đó ảnh hưởng trực tiếp tới chi phí mà các mặt hàng khác trong cùng kho phải gánh chịu. Bài toán vì vậy không thể tách rời thành các bài toán độc lập, mà mang bản chất của một bài toán ra quyết định hợp tác [9].

Thứ tư, quy mô không gian hành động. Với N kho và M mặt hàng, mỗi cặp có K mức đặt hàng khả dĩ, không gian hành động chung là tích Descartes có kích thước K^{NM} . Với cấu hình của khóa luận ($N = 10, M = 50, K = 6$), con số này là 6^{500} — vượt xa khả năng xử lý của bất kỳ phương pháp tìm kiếm tập trung nào, và cũng vượt quá khả năng biểu diễn của các thuật toán học tăng cường dựa trên hàm giá trị vốn phải liệt kê toàn bộ hành động khả dĩ [10]. Trên phương diện lý thuyết độ phức tạp, bài toán điều khiển phi tập trung dạng này đã được chứng minh thuộc lớp NEXP-đầy đủ [11], nên các lời giải chính xác không khả thi ở quy mô thực tế.

1.1.3 Hạn chế của phương pháp truyền thống và sự cần thiết của học tăng cường đa tác tử

Các chính sách tồn kho cổ điển đều được xây dựng trên những tập giả định cụ thể. Mô hình lượng đặt hàng kinh tế của Harris [12] giả định nhu cầu xác định và đều, không có tình trạng thiếu hàng. Chính sách (s, S) được Scarf [13] chứng minh tối ưu cho hệ đơn kho với nhu cầu độc lập giữa các kỳ, chi phí đặt hàng cố định và cơ chế giữ đơn hàng chờ. Mô hình người bán báo của Arrow và cộng sự [14] chỉ tối ưu cho một chu kỳ đơn lẻ, không xét tới lượng hàng đang trên đường vận chuyển. Không mô hình nào trong số đó xử lý được đồng thời nhu cầu ngẫu nhiên, thời gian giao hàng biến động, ràng buộc sức chứa dùng chung và yêu cầu duy trì mức phục vụ tối thiểu. Riêng với cơ chế mất đơn hàng khi thiếu hàng — vốn phù hợp với bối cảnh bán lẻ — Zipkin [15] chỉ ra rằng bài toán không còn nghiệm giải tích dạng đóng và các chính sách cổ điển mất tính tối ưu đã được chứng minh.

Học tăng cường cung cấp một hướng tiếp cận khác: thay vì giả định trước dạng phân phối của nhu cầu và suy ra chính sách bằng giải tích, tác tử học chính sách trực tiếp thông qua tương tác lặp lại với môi trường [10]. Hướng này đã được kiểm chứng trên các bài toán tồn kho quy mô nhỏ: Oroojlooyjadid và cộng sự [16] áp dụng mạng Q sâu cho trò chơi phân phối bia, còn Gijsbrechts và cộng sự [17] đánh giá học tăng cường sâu trên ba lớp bài toán tồn kho gồm mất đơn hàng, hai nguồn cung và đa cấp.

Tuy nhiên, việc áp dụng học tăng cường đơn tác tử cho toàn bộ mạng lưới vấp phải chính vấn đề quy mô đã nêu ở mục trên. Học tăng cường đa tác tử với cơ chế chia sẻ tham số cho phép vượt qua trở ngại này [18]: mỗi cặp kho–mặt hàng được xem là

một tác tử ra quyết định độc lập trên quan sát cục bộ theo hướng tiếp cận học độc lập của Tan [19], trong khi toàn bộ các tác tử cùng học chung một bộ trọng số. Nhờ đó, không gian hành động mà mỗi tác tử phải xử lý thu về kích thước K , còn số tham số cần học không tăng theo quy mô hệ thống. Các nghiên cứu gần đây cho thấy phương pháp học độc lập dựa trên PPO đạt hiệu năng cạnh tranh trên nhiều môi trường hợp tác [20], [21].

Khảo sát tài liệu cho thấy phần lớn các nghiên cứu áp dụng học tăng cường cho quản lý tồn kho hiện nay được tiến hành ở quy mô nhỏ, với một vài kho và một vài mặt hàng, trên dữ liệu nhu cầu sinh theo phân phối lý thuyết. Số công trình đồng thời mở rộng tới quy mô hàng trăm cặp kho–mặt hàng bằng cơ chế chia sẻ tham số, đánh giá tường minh ảnh hưởng của cách phân rã hàm phần thưởng ở quy mô đó, và hiệu chỉnh môi trường mô phỏng từ dữ liệu bán lẻ thực tế còn hạn chế. Đây chính là khoảng trống mà khóa luận hướng tới.

1.2 Mục tiêu và câu hỏi nghiên cứu

1.2.1 Mục tiêu nghiên cứu

Khóa luận đặt ra bốn mục tiêu cụ thể:

- Xây dựng môi trường mô phỏng tồn kho đa kho – đa mặt hàng theo chuẩn Gymnasium [22], mô hình hóa đầy đủ nhu cầu ngẫu nhiên, thời gian giao hàng biến động, ràng buộc sức chứa và năm nhóm chi phí vận hành; tham số nhu cầu được hiệu chỉnh từ bộ dữ liệu M5 Walmart.
- Thiết kế hàm phần thưởng phân rã cục bộ kèm thành phần phạt dựa trên tỷ lệ đáp ứng nhu cầu tính trên cửa sổ trượt, bảo đảm tín hiệu học phản ánh đúng đóng góp của từng tác tử [23].
- Cài đặt và huấn luyện thuật toán Independent Multi-Agent PPO [20], [24] với cơ chế chia sẻ tham số cho 500 cặp kho–mặt hàng, sử dụng ước lượng lợi thế tổng quát [25] và chuẩn hóa lợi thế theo từng cặp.
- Đánh giá hiệu năng của mô hình đề xuất trong so sánh với ba chính sách tồn kho cổ điển, theo giao thức thực nghiệm đa hạt giống có kiểm định thống kê [26], [27].

1.2.2 Câu hỏi nghiên cứu

Khóa luận hướng tới trả lời ba câu hỏi:

1. Câu hỏi 1: Tác tử IPPO có học được chính sách đặt hàng lại cho tổng chi phí vận hành thấp hơn các chính sách tối ưu hóa cổ điển (EOQ, (s, S) , Newsvendor) trong môi trường đa kho – đa mặt hàng với nhu cầu ngẫu nhiên và thời gian giao hàng biến động hay không, và mức cải thiện đó có ý nghĩa thống kê hay không?
2. Câu hỏi 2: Cơ chế chia sẻ tham số giữa 500 tác tử có đủ để học một chính sách tổng quát hóa được cho các mặt hàng có quy mô nhu cầu khác biệt đáng kể hay không?
3. Câu hỏi 3: Hàm phần thưởng phân rã cục bộ kèm tỷ lệ đáp ứng theo cửa sổ trượt có cải thiện quá trình học so với hàm phần thưởng toàn cục dùng chung hay không?

1.3 Đối tượng và phạm vi nghiên cứu

1.3.1 Đối tượng nghiên cứu

Đối tượng nghiên cứu của khóa luận là bài toán tối ưu hóa chính sách đặt hàng lại trong hệ thống tồn kho đa kho – đa mặt hàng, và thuật toán học tăng cường đa tác tử Independent Multi-Agent PPO áp dụng cho bài toán này.

1.3.2 Phạm vi trong đề tài

- Cấu hình hệ thống: $N = 10$ kho, $M = 50$ mặt hàng, tương ứng 500 cặp ra quyết định; độ dài mỗi tập huấn luyện là 365 ngày; thời gian giao hàng ngẫu nhiên trong khoảng từ một đến ba ngày.
- Cấu trúc mạng lưới: các kho hoạt động song song và độc lập về nguồn cung, mỗi kho đặt hàng trực tiếp từ nhà cung cấp bên ngoài. Sự ràng buộc giữa các mặt hàng phát sinh từ dung lượng kho dùng chung.
- Nguồn dữ liệu: bộ dữ liệu bán lẻ M5 Walmart [2], cụ thể là hai tệp `sales_train_evaluation.csv` chứa 30.490 chuỗi doanh số theo ngày trên 1.941 ngày, và `calendar.csv` chứa thông tin lịch, ngày lễ và các sự kiện trợ cấp thực phẩm SNAP. Khóa luận đồng thời hỗ trợ sinh dữ liệu giả lập theo phân phối Poisson phục vụ thử nghiệm đối chứng.
- Phương pháp đối chứng: ba chính sách tồn kho cổ điển EOQ [12], (s, S) [13] và Newsvendor [14], với tham số được tối ưu bằng tìm kiếm lưới trên chính môi trường mô phỏng nhằm bảo đảm tính công bằng của so sánh.

- Chỉ số đánh giá: tổng chi phí vận hành, tỷ lệ đáp ứng nhu cầu, và cơ cấu các thành phần chi phí lưu kho, thiếu hàng, đặt hàng.

1.3.3 Giới hạn phạm vi

Để bảo đảm chiều sâu nghiên cứu trong thời gian thực hiện, những nội dung sau được xác định nằm ngoài phạm vi khóa luận:

- Cấu trúc tồn kho đa cấp (multi-echelon) với quan hệ cung ứng giữa các kho theo mô hình của Clark và Scarf [28], cùng các hiện tượng đi kèm như hiệu ứng bullwhip [29].
- Bài toán điều chuyển hàng liên kho và tối ưu hóa tuyến vận chuyển.
- Dự báo nhu cầu bằng mô hình học sâu chuỗi thời gian; khóa luận sử dụng trực tiếp thông tin nhu cầu lịch sử trong vector quan sát.
- Cơ chế truyền thông giữa các tác tử; các tác tử ra quyết định hoàn toàn dựa trên quan sát cục bộ.
- Triển khai hệ thống thời gian thực hoặc tích hợp với nền tảng quản trị doanh nghiệp; sản phẩm của khóa luận là kết quả mô phỏng và phân tích định lượng.

1.4 Phương pháp nghiên cứu

Khóa luận kết hợp ba nhóm phương pháp. Về lý thuyết, bài toán được mô hình hóa dưới dạng quá trình quyết định Markov phi tập trung có quan sát bộ phận [9], [11], trên nền tảng lý thuyết kiểm soát tồn kho ngẫu nhiên [8] và học tăng cường [10], [30]. Về thực nghiệm, nhóm xây dựng môi trường mô phỏng có kiểm thử đơn vị theo chuẩn giao diện Gymnasium [22], [31], hiệu chỉnh tham số từ dữ liệu M5, huấn luyện tác tử và thu thập số liệu vận hành. Về phân tích, mọi so sánh giữa các phương pháp đều được thực hiện trên tối thiểu năm hạt giống ngẫu nhiên, báo cáo giá trị trung bình kèm độ lệch chuẩn, và được xác nhận bằng kiểm định thống kê phù hợp trước khi kết luận — theo khuyến nghị về tính tái lập trong đánh giá học tăng cường sâu của Henderson và cộng sự [26] và Agarwal và cộng sự [27].

1.5 Ý nghĩa khoa học và thực tiễn của đề tài

Về mặt khoa học, khóa luận đóng góp một khung mô hình hóa bài toán tồn kho đa kho – đa mặt hàng dưới dạng hệ đa tác tử hợp tác quy mô lớn, cùng với đánh giá thực nghiệm có kiểm định thống kê về ảnh hưởng của cách phân rã hàm phần thưởng

và cơ chế chia sẻ tham số — hai yếu tố thiết kế thường được sử dụng nhưng ít được khảo sát tách bạch trong các nghiên cứu trước.

Về mặt thực tiễn, kết quả của khóa luận cung cấp bằng chứng định lượng về mức độ khả thi của việc thay thế các chính sách đặt hàng theo tham số tĩnh bằng chính sách học được từ dữ liệu, trên một môi trường mô phỏng được hiệu chỉnh từ dữ liệu bán lẻ thực tế. Cấu trúc mã nguồn và giao thức đánh giá được tổ chức theo hướng có thể tái lập, tạo điều kiện cho các nghiên cứu mở rộng tiếp theo.

1.6 Bố cục của khóa luận

Khóa luận được tổ chức thành năm chương:

- Chương 1 — Tổng quan về đề tài: trình bày bối cảnh, tính cấp thiết, mục tiêu, câu hỏi nghiên cứu, phạm vi và phương pháp nghiên cứu.
- Chương 2 — Cơ sở lý thuyết và các công trình liên quan: hệ thống hóa lý thuyết kiểm soát tồn kho ngẫu nhiên, các chính sách cổ điển, nền tảng học tăng cường và học tăng cường đa tác tử, cùng lược khảo các nghiên cứu tiền nhiệm.
- Chương 3 — Phân tích và thiết kế mô hình: chi tiết hóa mô hình toán học của môi trường, thiết kế không gian trạng thái, không gian hành động và hàm phần thưởng, kiến trúc mạng Actor–Critic chia sẻ tham số và quy trình huấn luyện.
- Chương 4 — Thực nghiệm và đánh giá kết quả: trình bày cấu hình thực nghiệm, kết quả so sánh với các chính sách cổ điển, các khảo sát loại trừ và phân tích độ nhạy.
- Chương 5 — Kết luận và hướng phát triển: tổng kết kết quả đạt được, chỉ ra hạn chế và đề xuất hướng nghiên cứu tiếp theo.

CHƯƠNG 2. CƠ SỞ LÝ THUYẾT VÀ CÁC CÔNG TRÌNH LIÊN QUAN

2.1 Lý thuyết kiểm soát tồn kho ngẫu nhiên

2.1.1 Mô hình tồn kho và các thành phần chi phí

Bài toán kiểm soát tồn kho xoay quanh việc xác định thời điểm và số lượng đặt hàng bổ sung nhằm cân bằng giữa chi phí phát sinh khi dự trữ quá nhiều và rủi ro khi dự trữ quá ít [8]. Xét một hệ thống đơn kho – đơn mặt hàng hoạt động theo chu kỳ rời rạc. Gọi I_t là mức tồn kho tại đầu kỳ t , a_t là số lượng đặt hàng, D_t là nhu cầu phát sinh trong kỳ t (biến ngẫu nhiên) và L_t là thời gian giao hàng. Chi phí vận hành mỗi kỳ bao gồm:

- Chi phí lưu kho $C_{\text{hold}} = c_{lk} \cdot \max(I_t, 0)$: chi phí tỷ lệ với lượng hàng tồn dương trong kho, bao gồm chi phí vốn, bảo quản và kho bãi.
- Chi phí thiếu hàng $C_{\text{stock}} = c_{th} \cdot \max(D_t - I_t, 0)$: chi phí phát sinh khi nhu cầu vượt quá lượng hàng có sẵn. Trong mô hình mất đơn hàng (lost sales), phần nhu cầu không được đáp ứng bị mất hoàn toàn thay vì chuyển sang kỳ sau [15].
- Chi phí đặt hàng cố định $C_{\text{order}} = c_{dh} \cdot \mathbb{1}(a_t > 0)$: chi phí phát sinh mỗi khi hệ thống phát lệnh đặt hàng, bất kể số lượng đặt.
- Phạt tràn kho $C_{\text{over}} = p_{tk} \cdot \max(I_t + q_t - W, 0)$: chi phí phát sinh khi tổng lượng hàng tồn và hàng nhập vượt quá sức chứa W của kho, trong đó q_t là lượng hàng nhập kho trong kỳ.
- Phạt vi phạm mức phục vụ dựa trên tỷ lệ đáp ứng nhu cầu (fill rate) trên cửa sổ trượt, phản ánh yêu cầu kinh doanh về chất lượng dịch vụ khách hàng.

Tổng chi phí vận hành của một cặp kho–mặt hàng trong kỳ t được tính:

$$C_t = C_{\text{hold}} + C_{\text{stock}} + C_{\text{order}} + C_{\text{over}} + \phi_{dv} \cdot \max(\tau - \text{FR}_t^{(w)}, 0) \quad (2.1)$$

trong đó $\text{FR}_t^{(w)}$ là tỷ lệ đáp ứng trên cửa sổ trượt w ngày, τ là ngưỡng mức phục vụ mục tiêu và ϕ_{dv} là hệ số phạt.

2.1.2 Các chính sách đặt hàng lại cổ điển

Ba chính sách cổ điển được sử dụng làm phương pháp đối chứng trong khóa luận.

Lượng đặt hàng kinh tế (EOQ). Harris [12] đề xuất công thức tối ưu hóa tần suất đặt hàng dưới giả định nhu cầu xác định và đều:

$$Q^* = \sqrt{\frac{2D \cdot c_{dh}}{c_{lk}}} \quad (2.2)$$

trong đó D là nhu cầu trung bình hàng năm. Mô hình giả định không có thiếu hàng, thời gian giao hàng cố định và không có ràng buộc sức chứa.

Chính sách (s, S) . Scarf [13] chứng minh rằng chính sách dạng (s, S) — đặt hàng để nâng mức tồn kho lên S khi mức hiện tại giảm xuống dưới s — là tối ưu cho hệ đơn kho với nhu cầu ngẫu nhiên, chi phí đặt hàng cố định, và cơ chế giữ đơn hàng chờ (backorder). Ngưỡng s thường được tính dựa trên nhu cầu trung bình và độ lệch chuẩn trong thời gian giao hàng:

$$s = \mu_L + z_\alpha \cdot \sigma_L \quad (2.3)$$

trong đó μ_L và σ_L là kỳ vọng và độ lệch chuẩn của nhu cầu tích lũy trong thời gian giao hàng, z_α là phân vị chuẩn tương ứng với mức phục vụ mong muốn.

Mô hình Newsvendor. Arrow và cộng sự [14] đề xuất mô hình cho bài toán đặt hàng đơn kỳ, trong đó lượng đặt hàng tối ưu là:

$$Q^* = F^{-1}\left(\frac{c_{th}}{c_{th} + c_{lk}}\right) \quad (2.4)$$

với F^{-1} là hàm phân vị của phân phối nhu cầu. Mô hình chỉ tối ưu cho một chu kỳ duy nhất, không xét lượng hàng đang trên đường vận chuyển.

Cả ba chính sách trên đều được xây dựng cho bài toán đơn kho – đơn mặt hàng và không tối ưu hóa đồng thời ràng buộc sức chứa dùng chung, phạt tràn và mức phục vụ — những đặc trưng quan trọng trong bài toán đa kho – đa mặt hàng mà khóa luận xét [1], [8].

2.1.3 Các thước đo mức phục vụ trong quản lý tồn kho

Trong quản lý tồn kho ngẫu nhiên, mức phục vụ (service level) được đánh giá thông qua ba thước đo phổ biến [1], [8]:

- **Mức phục vụ theo chu kỳ (α – Cycle Service Level / Type-1):** Là xác suất không xảy ra hiện tượng thiếu hàng trong một chu kỳ bổ sung tồn kho, tức

$P(D_L \leq s)$ trong đó D_L là nhu cầu tích lũy trong thời gian giao hàng L và s là điểm đặt hàng lại. Tỷ lệ critical ratio trong mô hình Newsvendor (2.4) phản ánh chính xác phân vị z_α của thước đo α .

- **Tỷ lệ đáp ứng nhu cầu (β – Fill Rate / Type-2):** Là tỷ lệ phần trăm tổng nhu cầu của khách hàng được đáp ứng ngay lập tức từ lượng hàng sẵn có trong kho.
- **Tỷ lệ sẵn sàng (γ – Ready Rate):** Là tỷ lệ thời gian mà mức tồn kho khả dụng duy trì giá trị dương.

Cần lưu ý rằng tỷ số chi phí $c_{th}/(c_{th} + c_{lk})$ xác định mức phục vụ chu kỳ α , chứ không phải tỷ lệ fill rate β . Trong điều kiện nhu cầu ổn định và biến động vừa phải, β thường cao hơn α . Tuy nhiên, dưới tác động của nhu cầu gián đoạn (intermittent demand) và thời gian giao hàng ngẫu nhiên như trong dữ liệu M5 Walmart, mối quan hệ này không còn mang tính tuyệt đối và β có thể sụt giảm thấp hơn α [1].

2.2 Nền tảng học tăng cường

2.2.1 Quá trình quyết định Markov (MDP)

Bài toán ra quyết định tuần tự dưới bất định được mô hình hóa bằng quá trình quyết định Markov [30], xác định bởi bộ năm (S, A, P, R, γ) trong đó:

- S : không gian trạng thái (state space).
- A : không gian hành động (action space).
- $P(s' | s, a)$: hàm xác suất chuyển trạng thái.
- $R(s, a)$: hàm phần thưởng (reward function).
- $\gamma \in [0, 1)$: hệ số chiết khấu (discount factor).

Mục tiêu của tác tử là tìm chính sách π^* cực đại hóa lợi tức kỳ vọng:

$$\pi^* = \arg \max_{\pi} \mathbb{E}_{\pi} \left[\sum_{t=0}^{\infty} \gamma^t R(s_t, a_t) \right] \quad (2.5)$$

2.2.2 Hàm giá trị và phương trình Bellman

Hàm giá trị trạng thái $V^{\pi}(s) = \mathbb{E}_{\pi}[\sum_{t=0}^{\infty} \gamma^t R_t | s_0 = s]$ và hàm giá trị hành động $Q^{\pi}(s, a)$ thỏa mãn phương trình Bellman [10]. Hàm lợi thế (advantage function) được định nghĩa:

$$A^{\pi}(s, a) = Q^{\pi}(s, a) - V^{\pi}(s) \quad (2.6)$$

đo mức độ tốt hơn (hoặc kém hơn) của hành động a so với hành vi trung bình của chính sách π tại trạng thái s .

2.2.3 Ước lượng lợi thế tổng quát (GAE)

Schulman và cộng sự [25] đề xuất phương pháp ước lượng lợi thế tổng quát (Generalized Advantage Estimation – GAE) nhằm kiểm soát đánh đổi giữa thiên lệch (bias) và phương sai (variance) trong ước lượng gradient chính sách:

$$\hat{A}_t^{\text{GAE}(\gamma, \lambda)} = \sum_{l=0}^{\infty} (\gamma \lambda)^l \delta_{t+l} \quad (2.7)$$

trong đó $\delta_t = r_t + \gamma V(s_{t+1}) - V(s_t)$ là sai số TD (temporal difference) và $\lambda \in [0, 1]$ là tham số kiểm soát đánh đổi. Khi $\lambda = 0$, GAE suy biến thành ước lượng một bước (thiên lệch cao, phương sai thấp); khi $\lambda = 1$, GAE tương đương Monte-Carlo (không thiên lệch, phương sai cao). Khóa luận sử dụng $\lambda = 0,95$ theo khuyến nghị thực nghiệm phổ biến.

2.2.4 Thuật toán PPO (Proximal Policy Optimization)

Schulman và cộng sự [24] đề xuất PPO nhằm khắc phục nhược điểm của phương pháp tối ưu hóa chính sách: các bước cập nhật quá lớn có thể phá hủy chính sách đã học. PPO sử dụng hàm mục tiêu cắt (clipped surrogate objective):

$$L^{\text{CLIP}}(\theta) = \mathbb{E}_t [\min(r_t(\theta) \hat{A}_t, \text{clip}(r_t(\theta), 1 - \epsilon, 1 + \epsilon) \hat{A}_t)] \quad (2.8)$$

trong đó $r_t(\theta) = \frac{\pi_{\theta}(a_t|s_t)}{\pi_{\theta_{\text{old}}}(a_t|s_t)}$ là tỷ lệ xác suất giữa chính sách mới và cũ, và ϵ (thường bằng 0,2) giới hạn biên độ thay đổi tối đa. PPO kết hợp cập nhật on-policy, hiệu quả tính toán cao và tính ổn định, phù hợp cho bài toán có không gian hành động rời rạc hoặc liên tục.

Ý tưởng cốt lõi của TRPO [32] — giới hạn bước cập nhật trong vùng tin cậy — được PPO thực hiện đơn giản hơn qua phép cắt, giúp cài đặt dễ dàng và huấn luyện nhanh hơn trên thực tế.

2.3 Học tăng cường đa tác tử

2.3.1 Mô hình Dec-POMDP

Khi hệ thống có nhiều tác tử ra quyết định đồng thời, bài toán được mô hình hóa bằng quá trình quyết định Markov phi tập trung có quan sát bộ phận (Decentralized Partially Observable Markov Decision Process – Dec-POMDP) [9]. Trong mô hình

này, mỗi tác tử i chỉ quan sát được một phần trạng thái toàn cục thông qua hàm quan sát $o_i = O(s, i)$ và ra quyết định dựa trên quan sát cục bộ. Bài toán tìm chính sách chung tối ưu cho tất cả tác tử đã được chứng minh thuộc lớp NEXP-đầy đủ [11], nên các lời giải chính xác không khả thi ở quy mô lớn.

2.3.2 Học độc lập (*Independent Learning*)

Tan [19] đề xuất phương pháp học độc lập: mỗi tác tử coi các tác tử khác là một phần của môi trường và áp dụng thuật toán RL đơn tác tử riêng rẽ. Hạn chế lý thuyết chính là môi trường trở nên không dừng (non-stationary) do các tác tử khác cũng đang thay đổi chính sách. Tuy nhiên, các nghiên cứu thực nghiệm cho thấy phương pháp này đạt hiệu quả bất ngờ trên nhiều bài toán hợp tác [20].

2.3.3 IPPO — *Independent Multi-Agent PPO*

IPPO là biến thể đa tác tử của PPO trong đó mỗi tác tử i chạy PPO độc lập dựa trên quan sát cục bộ o_i^t và phần thưởng riêng r_i^t [20]. Yu và cộng sự [21] đánh giá hệ thống trên nhiều môi trường hợp tác và kết luận rằng IPPO đạt hiệu năng cạnh tranh hoặc vượt trội so với các phương pháp phức tạp hơn như QMIX hay MAPPO trong nhiều kịch bản.

Đặc điểm quan trọng của IPPO khiến nó phù hợp cho bài toán tồn kho:

- Không yêu cầu trạng thái toàn cục: mỗi tác tử (cặp kho–mặt hàng) chỉ cần quan sát cục bộ.
- Khả năng mở rộng: không gian hành động của mỗi tác tử có kích thước K cố định, không phụ thuộc số tác tử.
- Tính đơn giản: cài đặt dựa trên PPO chuẩn, không cần mixing network hay cơ chế truyền thông.

2.3.4 Chia sẻ tham số (*Parameter Sharing*)

Gupta và cộng sự [18] chỉ ra rằng khi các tác tử có cùng không gian quan sát và hành động, một mạng nơ-ron duy nhất có thể được chia sẻ giữa tất cả tác tử. Mỗi tác tử vẫn ra quyết định dựa trên quan sát riêng nhưng dùng chung bộ trọng số. Lợi ích:

- Số tham số cần học không tăng theo số tác tử (ở đây: 500).
- Mỗi bước cập nhật sử dụng dữ liệu từ tất cả tác tử, tăng hiệu quả mẫu.
- Chính sách học được có khả năng tổng quát hóa cho các mặt hàng có quy

mô nhu cầu khác nhau.

2.3.5 *Phần thưởng phân rã cục bộ và bài toán gán tín dụng*

Trong hệ đa tác tử, việc sử dụng phần thưởng toàn cục (tổng chi phí của toàn bộ hệ thống) cho mọi tác tử gây ra vấn đề gán tín dụng (credit assignment): tác tử khó phân biệt được đóng góp cá nhân trong tín hiệu tổng hợp [23]. Khóa luận áp dụng phân rã cục bộ: mỗi tác tử nhận phần thưởng riêng dựa trên chi phí và tỷ lệ đáp ứng của chính cặp kho–mặt hàng mà nó quản lý.

Khung lý thuyết định hình phần thưởng bảo toàn thể năng (Potential-Based Reward Shaping – PBRS) do Ng và cộng sự [33] chứng minh khẳng định rằng: một hàm biến đổi phần thưởng $F(s, a, s')$ bảo toàn tập chính sách tối ưu của MDP gốc khi và chỉ khi nó có dạng chênh lệch thể năng $F(s, a, s') = \gamma\Phi(s') - \Phi(s)$. Khung lý thuyết này sau đó được mở rộng sang hệ đa tác tử bởi Devlin và Kudenko [34] cũng như ứng dụng trong tồn kho bởi De Moor và cộng sự [35].

2.4 Các công trình nghiên cứu liên quan

2.4.1 *Học tăng cường trong quản lý tồn kho*

Oroojlooyjadid và cộng sự [16] áp dụng Deep Q-Network (DQN) cho trò chơi phân phối bia (beer game) — một bài toán chuỗi cung ứng 4 cấp cổ điển — và cho thấy DQN có thể học được chính sách giảm hiệu ứng bullwhip. Tuy nhiên, nghiên cứu giới hạn ở hệ đơn mặt hàng, bốn tác tử.

Gijsbrechts và cộng sự [17] đánh giá hệ thống khả năng của DRL trên ba lớp bài toán tồn kho: mất đơn hàng, hai nguồn cung và đa cấp. Kết quả cho thấy DRL đạt hiệu năng ngang hoặc tốt hơn chính sách cổ điển trong hầu hết trường hợp, nhưng tất cả thực nghiệm đều ở quy mô nhỏ (dưới 10 SKU).

Hubbs và cộng sự [36] giới thiệu bộ thư viện OR-Gym đóng vai trò là môi trường benchmark chuẩn cho các bài toán Vận trù học bằng RL, bao gồm cả mô hình Newsvendor và quản lý tồn kho đa cấp lost-sales.

Nghiên cứu của Ding và cộng sự [37] (CD-PPO) phát biểu chính xác bài toán tồn kho đơn cửa hàng nhiều SKU dưới dạng tài nguyên kho dùng chung làm ghép nối các tác tử vốn độc lập. Họ so sánh trực tiếp IPPO và MAPPO có chia sẻ tham số (parameter sharing), chứng minh hiệu quả vượt trội khi quản lý tài nguyên kho chung.

Yang và cộng sự [38] phát triển MABIM — bộ benchmark MARL đa dạng cho tồn kho. MABIM coi mỗi SKU tại mỗi điểm lưu trữ là một tác tử độc lập, sử dụng

dữ liệu nhu cầu thực tế của hơn 2.000 SKU với 51 tác vụ thử nghiệm (bao gồm nhóm tác vụ mở rộng quy mô scaling up), thử nghiệm các thuật toán MARL bao gồm IPPO dưới ràng buộc sức chứa dùng chung.

Kotecha và del Rio Chanona [39] tiến hành phân tích chuyên sâu các thuật toán MARL cho kiểm soát tồn kho phân tán, so sánh giữa IPPO thuần, IPPO chia sẻ tham số và MAPPO. Họ phát hiện rằng mặc dù parameter sharing giảm số lượng tham số cần học, hiệu năng của IPPO chia sẻ tham số có dấu hiệu giảm sút khi quy mô tác tử tăng lên rất lớn.

Gần đây nhất, Liu và cộng sự [40] áp dụng thuật toán Heterogeneous-Agent PPO (HAPPO) cho tồn kho đa cấp. Đáng chú ý, các tác giả phát hiện việc kết hợp chi phí cục bộ và chi phí toàn hệ thống vào tín hiệu thưởng thu được chính sách có độ ổn định và hiệu năng cao hơn so với chỉ dùng chi phí toàn hệ thống thuần túy.

2.4.2 Khoảng trống nghiên cứu và định vị đóng góp

Bảng 2.1 tóm tắt so sánh tổng quan giữa khóa luận này và các công trình nghiên cứu liên quan tiêu biểu.

Bảng 2.1: So sánh tổng quan các công trình nghiên cứu liên quan

Nghiên cứu	Cấu trúc mạng	Số SKU	Chia sẻ tham số	Dữ liệu thực	Thuật toán
Oroojlooyjadid (2022)	4 cấp chuỗi	1	Không	Không	DQN
Gijsbrechts (2022)	2 cấp / đa cấp	< 10	Không	Không	A2C / PPO
Hubbs et al. (2020)	Đa cấp lost-sales	Biến đổi	Không	Không	DQN / PPO
Ding et al. (2022)	1 cửa hàng	Nhiều SKU	Có	Không	CD-PPO / IPPO
Yang et al. (2023)	Đa cấp / Đa kho	> 2000	Có	Có	IPPO / MAPPO
Kotecha (2024)	Đa điểm phân tán	Biến đổi	Có	Không	IPPO / MAPPO
Liu et al. (2025)	Đa cấp phức tạp	Nhiều SKU	Có	Có	HAPPO
Khóa luận này	10 kho song song	50	Có	M5 Walmart	IPPO

Thay vì đưa ra các khẳng định tuyệt đối về tính duy nhất hay tính "đầu tiên",

khóa luận định vị đóng góp theo hướng **tái lập và mở rộng có kiểm soát** đối với ứng dụng MARL trong kiểm soát tồn kho, tập trung vào ba trọng tâm chính:

1. Khảo sát sâu cấu hình **10 kho song song thuần túy (non-multi-echelon)** với ràng buộc sức chứa kho dùng chung ở quy mô 500 cặp kho–mặt hàng, tạo sự đối sánh rõ rệt với các mô hình đa cấp (multi-echelon) của MABIM [38] hay Liu và cộng sự [40].
2. Đánh giá **ablation study tường minh** tác động của tín hiệu thưởng phân rã cục bộ (local reward decomposition) kèm phạt ràng buộc fill rate cửa sổ trượt ở quy mô 500 tác tử, làm rõ cơ chế gán tín dụng và tốc độ hội tụ của IPPO.
3. Hiệu chỉnh môi trường mô phỏng lost-sales trực tiếp từ dữ liệu bán lẻ thực tế M5 Walmart và thực hiện kiểm chứng đối chứng nghiêm ngặt với các chính sách cổ điển EOQ, (s, S) và Newsvendor.

CHƯƠNG 3. PHÂN TÍCH VÀ THIẾT KẾ MÔ HÌNH

3.1 Mô hình hóa bài toán tồn kho đa kho

3.1.1 Mô tả mạng lưới

Hệ thống gồm $N = 10$ kho hoạt động song song và độc lập về nguồn cung. Mỗi kho lưu trữ $M = 50$ mặt hàng (SKU), tạo thành tổng cộng $N \times M = 500$ cặp kho–mặt hàng. Mỗi kho có dung lượng hữu hạn W được chia sẻ giữa tất cả các mặt hàng. Mỗi cặp kho–mặt hàng đặt hàng trực tiếp từ nhà cung cấp bên ngoài với thời gian giao hàng ngẫu nhiên $L \sim \text{Uniform}(1, 3)$ ngày.

Sự ràng buộc giữa các mặt hàng trong cùng kho phát sinh từ dung lượng dùng chung: khi một mặt hàng đặt quá nhiều, các mặt hàng khác có thể bị phạt tràn kho. Đây chính là yếu tố khiến bài toán mang tính hợp tác và không thể tách rời thành 500 bài toán đơn lẻ.

Nhu cầu hàng ngày $D_t^{(i)}$ cho mỗi cặp kho–mặt hàng i được lấy từ hai nguồn:

- Dữ liệu M5 Walmart: tham số nhu cầu (λ trung bình, mẫu hình mùa vụ) được hiệu chỉnh từ chuỗi doanh số thực tế của 10 cửa hàng, mỗi cửa hàng 50 SKU [2].
- Dữ liệu giả lập: nhu cầu Poisson $D_t \sim \text{Poisson}(\lambda_i)$ với λ_i khác nhau giữa các SKU, phục vụ thử nghiệm đối chứng.

3.1.2 Thiết lập bài toán dưới dạng MDP đa tác tử

Bài toán được mô hình hóa dưới dạng Dec-POMDP [9] với 500 tác tử. Mỗi tác tử i (tương ứng cặp kho–mặt hàng) có:

Không gian quan sát $o_i^t \in \mathbb{R}^d$: vector quan sát cục bộ tại kỳ t bao gồm:

- Mức tồn kho hiện tại (on-hand inventory): $I_t^{(i)}$.
- Lượng hàng đang trên đường vận chuyển (in-transit): tổng các đơn hàng đã phát mà chưa nhập kho.
- Nhu cầu lịch sử w ngày gần nhất: $(D_{t-w}^{(i)}, \dots, D_{t-1}^{(i)})$.
- Tỷ lệ đáp ứng nhu cầu trên cửa sổ trượt w ngày: $\text{FR}_t^{(i,w)}$.
- Tỷ lệ sử dụng kho hiện tại: $\sum_j I_t^{(j)} / W$ (tất cả mặt hàng trong cùng kho).

Không gian hành động $a_i^t \in \{0, 1, \dots, K-1\}$: mỗi tác tử chọn một trong $K = 6$

mức đặt hàng rời rạc $\{0, 10, 20, 30, 40, 50\}$ đơn vị. Không gian hành động chung của toàn hệ thống là tích Descartes $K^{500} = 6^{500}$, nhưng mỗi tác tử chỉ xử lý $K = 6$ hành động.

Hàm chuyển trạng thái: diễn ra theo trình tự mỗi kỳ:

1. Tác tử quan sát o_i^t và chọn hành động a_i^t .
2. Hàng đã đặt trước đây đến kho (nếu lead time đã hết).
3. Nhu cầu $D_t^{(i)}$ phát sinh; hàng được cấp phát nếu có đủ, phần thiếu bị mất (lost sales).
4. Tính chi phí và phần thưởng cho kỳ t .
5. Chuyển sang kỳ $t + 1$.

3.2 Thiết kế hàm phần thưởng

3.2.1 Phần thưởng phân rã cục bộ

Mỗi tác tử i nhận phần thưởng riêng dựa trên chi phí của chính cặp kho–mặt hàng mà nó quản lý, thay vì dùng chung phần thưởng toàn cục:

$$r_i^t = - \left(c_{lk} \cdot I_t^{(i)+} + c_{th} \cdot U_t^{(i)} + c_{dh} \cdot \mathbb{1}(a_i^t > 0) + p_{tk} \cdot O_t^{(i)} \right) - \phi_{dv} \cdot \max(\tau - \text{FR}_t^{(i,w)}, 0) \quad (3.1)$$

trong đó:

- $I_t^{(i)+} = \max(I_t^{(i)}, 0)$: mức tồn kho dương.
- $U_t^{(i)} = \max(D_t^{(i)} - I_t^{(i)}, 0)$: lượng nhu cầu không được đáp ứng.
- $O_t^{(i)}$: lượng hàng tràn kho (phần vượt sức chứa).
- $\text{FR}_t^{(i,w)}$: tỷ lệ đáp ứng trên cửa sổ trượt $w = 30$ ngày.
- $\tau = 0,85$: ngưỡng mức phục vụ mục tiêu.

3.2.2 Vai trò của thành phần phạt fill rate

Thành phần $\phi_{dv} \cdot \max(\tau - \text{FR}_t^{(i,w)}, 0)$ bổ sung tín hiệu phạt ràng buộc (constraint penalty) theo tinh thần Lagrangian: thay vì chỉ phạt thiếu hàng tức thời (vốn có phương sai cao do nhu cầu gián đoạn), tỷ lệ đáp ứng trên cửa sổ trượt cung cấp đánh giá ổn định hơn về chất lượng phục vụ. Cần nhấn mạnh rằng hình phạt này không thuộc dạng chênh lệch thế năng của Ng và cộng sự [33], mà cố ý thay đổi cấu trúc phần thưởng của MDP gốc nhằm điều hướng chính sách tìm kiếm giải pháp thỏa mãn ràng buộc mức phục vụ kinh doanh.

3.2.3 Các tham số chi phí

Bảng 3.1 liệt kê các tham số chi phí sử dụng trong thực nghiệm.

Bảng 3.1: Tham số chi phí trong môi trường mô phỏng

Thành phần	Ký hiệu	Giá trị
Chi phí lưu kho	c_{lk}	1,0 /đơn vị/ngày
Chi phí thiếu hàng	c_{th}	10,0 /đơn vị
Chi phí đặt hàng	c_{dh}	50,0 /lần đặt
Phạt tràn kho	p_{tk}	5,0 /đơn vị tràn
Phạt vi phạm mức phục vụ	ϕ_{dv}	1,5
Ngưỡng fill rate	τ	85%
Cửa sổ fill rate	w	30 ngày

Lưu ý rằng với bộ tham số chi phí $c_{th} = 10,0$ và $c_{lk} = 1,0$, tỷ số chi phí thiếu hàng ngầm định mức phục vụ chu kỳ lý thuyết $\alpha \approx 90,9\%$. Do đó, ràng buộc fill rate $\beta \geq 85\%$ có khả năng rơi vào trạng thái không có hiệu lực (non-binding) trong quá trình thực nghiệm mô phỏng. Đây là một giả thuyết cần kiểm chứng qua kết quả huấn luyện.

3.3 Kiến trúc mạng Actor–Critic chia sẻ tham số

3.3.1 Mạng SharedActorCritic

Toàn bộ 500 tác tử dùng chung một mạng nơ-ron duy nhất [18], gồm:

- Thân chung (shared trunk): hai lớp ẩn fully-connected, mỗi lớp 128 nơ-ron, hàm kích hoạt ReLU.
- Đầu Actor: một lớp tuyến tính xuất ra phân phối xác suất trên $K = 6$ mức đặt hàng (softmax).
- Đầu Critic: một lớp tuyến tính xuất ra giá trị $V(o_i)$.

Kiến trúc đầu vào nhận vector quan sát cục bộ o_i^t của một tác tử bất kỳ. Mỗi forward pass xử lý một batch gồm quan sát của nhiều tác tử cùng lúc. Số tham số cần học là hằng số, không phụ thuộc vào $N \times M$.

3.3.2 Quy trình huấn luyện IPPPO

1. Thu thập dữ liệu (Rollout): Chạy $n_{\text{steps}} = 4096$ bước trong môi trường. Tại mỗi bước, tất cả 500 tác tử cùng chọn hành động, tổng cộng thu được $4096 \times 500 \approx 2$ triệu mẫu (o_i, a_i, r_i, o'_i) mỗi vòng rollout.

2. Tính GAE: Ước lượng lợi thế $\hat{A}_t^{(i)}$ cho từng tác tử i sử dụng công thức GAE (2.7) với $\gamma = 0,99$ và $\lambda = 0,95$.
3. Chuẩn hóa lợi thế theo từng cặp (per-pair advantage normalization): Chuẩn hóa $\hat{A}_t^{(i)}$ theo trung bình và độ lệch chuẩn tính riêng cho mỗi cặp kho–mặt hàng i , giúp các cặp có quy mô chi phí khác nhau đóng góp cân bằng vào gradient.
4. Cập nhật PPO: Thực hiện $E = 6$ epoch tối ưu hóa hàm mục tiêu clipped (2.8) trên toàn bộ dữ liệu rollout. Tốc độ học Actor $\eta_a = 3 \times 10^{-5}$, Critic $\eta_c = 3 \times 10^{-4}$.
5. Lặp lại bước 1–4 trong 6000 episode.

Bảng 3.2 tóm tắt các siêu tham số chính.

Bảng 3.2: Siêu tham số huấn luyện

Nhóm	Tham số	Giá trị
Môi trường	$N \times M$ (số tác tử)	$10 \times 50 = 500$
	Episode length	365 ngày
	Lead time	[1, 3] ngày
	Order levels (K)	{0, 10, 20, 30, 40, 50}
PPO	Rollout steps (n_{steps})	4096
	PPO epochs (E)	6
	Learning rate Actor	3×10^{-5}
	Learning rate Critic	3×10^{-4}
	γ	0,99
	λ_{GAE}	0,95
	Clip ϵ	0,2
	Total episodes	6000
Mạng	Hidden layers	2×128
	Activation	ReLU

3.4 Thiết kế môi trường mô phỏng

Môi trường được xây dựng theo chuẩn Gymnasium [22], kế thừa giao diện từ OpenAI Gym [31], cung cấp các phương thức `reset()` và `step(action)` chuẩn.

MultiWarehouseInventoryEnv quản lý:

- Ma trận tồn kho $\mathbf{I} \in \mathbb{R}^{N \times M}$.
- Hàng đợi giao hàng cho mỗi cặp (tracking lead time).
- Lịch sử nhu cầu và fill rate trượt.

- Hàm tính chi phí và phần thưởng (công thức 3.1).

Mỗi episode kéo dài 365 bước (tương đương 1 năm), phản ánh chu kỳ kinh doanh thực tế.

Khóa luận chủ động tự xây dựng môi trường `MultiWarehouseInventoryEnv` thay vì sử dụng trực tiếp các bộ thư viện benchmark sẵn có như `OR-Gym` [36] hay `MABIM` [38]. Lý do cốt lõi là các benchmark hiện hành chưa hỗ trợ sẵn cấu hình mạng lưới 10 kho song song độc lập nguồn cung kết hợp đồng thời với ràng buộc sức chứa kho dùng chung giữa 50 SKU và cơ chế phạt fill rate cửa sổ trượt. Việc tự phát triển môi trường giúp đảm bảo khả năng kiểm soát toàn diện các tham số mô phỏng và tính tương thích cao nhất với mục tiêu nghiên cứu của đề tài.

CHƯƠNG 4. THỰC NGHIỆM VÀ ĐÁNH GIÁ KẾT QUẢ

4.1 Cấu hình thực nghiệm

4.1.1 Môi trường phần cứng và phần mềm

Môi trường thực nghiệm được triển khai trên nền tảng Python với các thư viện cốt lõi: PyTorch (cài đặt mạng Actor–Critic và thuật toán PPO), Gymnasium (giao diện môi trường mô phỏng), NumPy và Pandas (xử lý dữ liệu M5 và tính toán thống kê).

4.1.2 Nguồn dữ liệu và tiền xử lý

Dữ liệu M5 Walmart. Khóa luận sử dụng hai tệp chính từ bộ dữ liệu M5 [2], [3]:

- `sales_train_evaluation.csv`: chứa 30.490 chuỗi doanh số theo ngày (3.049 mặt hàng $\times$ 10 cửa hàng) trên 1.941 ngày.
- `calendar.csv`: chứa thông tin lịch, ngày lễ và các sự kiện SNAP.

Từ tổng số 3.049 mặt hàng, khóa luận chọn $M = 50$ mặt hàng đại diện cho 10 cửa hàng (tương ứng 10 kho), đảm bảo đa dạng về quy mô nhu cầu: từ các SKU có nhu cầu thấp ($\lambda < 0,5$ đơn vị/ngày) đến các SKU có nhu cầu cao ($\lambda > 5$ đơn vị/ngày). Tham số nhu cầu (λ_i trung bình hàng ngày) cho mỗi cặp kho–mặt hàng được tính từ dữ liệu gốc.

Dữ liệu giả lập (Poisson synthetic). Song song, khóa luận sinh dữ liệu nhu cầu theo phân phối Poisson $D_t \sim \text{Poisson}(\lambda_i)$ để kiểm chứng kết quả trong điều kiện kiểm soát.

4.1.3 Thiết lập kịch bản mô phỏng

Mỗi episode huấn luyện/đánh giá kéo dài 365 ngày. Bảng 4.1 tóm tắt cấu hình môi trường.

4.2 Phương pháp đối chứng (Baselines)

Hiệu năng của IPPO được so sánh với ba chính sách tồn kho cổ điển:

- EOQ [12]: lượng đặt hàng cố định $Q^* = \sqrt{2D \cdot c_{dh}/c_{tk}}$, với D tính từ nhu cầu trung bình của mỗi SKU. Đặt hàng khi tồn kho giảm xuống dưới ngưỡng

Bảng 4.1: Cấu hình môi trường mô phỏng

Tham số	Giá trị
Số kho (N)	10
Số mặt hàng (M)	50
Số tác tử ($N \times M$)	500
Độ dài episode	365 ngày
Lead time	Uniform(1, 3) ngày
Mức đặt hàng (K)	$\{0, 10, 20, 30, 40, 50\}$
Ngưỡng fill rate (τ)	85%

$$r = \mu_L.$$

- Chính sách (s, S) [13]: ngưỡng s và mức trần S được tối ưu bằng tìm kiếm lưới (grid search) trên chính môi trường mô phỏng, bảo đảm tính công bằng khi so sánh.
- Newsvendor [14]: lượng đặt hàng tối ưu đơn kỳ $Q^* = F^{-1}(c_{th}/(c_{th} + c_{lk}))$, áp dụng lại mỗi ngày dựa trên phân phối nhu cầu ước lượng.

Tất cả baselines được chạy trên cùng một môi trường và cùng các hạt giống ngẫu nhiên với IPPO để bảo đảm tính so sánh.

4.3 Giao thức đánh giá

4.3.1 Đánh giá đa hạt giống

Theo khuyến nghị của Henderson và cộng sự [26] và Agarwal và cộng sự [27], mọi kết quả được báo cáo trên tối thiểu 5 hạt giống ngẫu nhiên. Mỗi seed tương ứng với:

- Khởi tạo trọng số mạng khác nhau.
- Chuỗi nhu cầu ngẫu nhiên khác nhau (cùng phân phối).
- Chuỗi lead time ngẫu nhiên khác nhau.

Kết quả báo cáo gồm giá trị trung bình $\pm$ độ lệch chuẩn. Sự khác biệt giữa các phương pháp được xác nhận bằng kiểm định thống kê phù hợp (t-test hoặc Wilcoxon signed-rank test).

4.3.2 Các chỉ số đánh giá

Bốn nhóm chỉ số chính:

1. Tổng chi phí vận hành (Total Cost): tổng C_t theo công thức (2.1) trên toàn

bộ 365 ngày và 500 cặp kho–mặt hàng.

2. Tỷ lệ đáp ứng nhu cầu (Fill Rate): $FR = \sum \text{fulfilled} / \sum \text{demand}$, tính trung bình trên toàn hệ thống. Mục tiêu $\geq 85\%$.
3. Cơ cấu chi phí thành phần: phân tách tổng chi phí thành holding, stockout, ordering và overflow để phân tích chiến lược mà mỗi phương pháp áp dụng.
4. Đường cong học (Learning Curve): phần thưởng tích lũy trung bình qua các episode huấn luyện, chứng minh tính hội tụ.

4.4 Kết quả thực nghiệm

4.4.1 Quá trình huấn luyện và tính hội tụ

Đường cong phần thưởng tích lũy trung bình qua các episode huấn luyện cho thấy mô hình IPPO hội tụ sau khoảng *[cần điền]* episode. Phần thưởng ổn định và không sụp đổ sau hội tụ, chứng minh tính ổn định của thuật toán PPO với cơ chế clipped objective.

4.4.2 So sánh tổng chi phí vận hành

Bảng 4.2 trình bày tổng chi phí vận hành sau 365 ngày, trung bình trên 5 hạt giống.

Bảng 4.2: Tổng chi phí vận hành (trung bình $\pm$ độ lệch chuẩn, 5 seeds)

Phương pháp	Total Cost	Fill Rate	<i>p</i> -value
EOQ	<i>[cần điền]</i>	<i>[cần điền]</i>	—
(<i>s</i> , <i>S</i>)	<i>[cần điền]</i>	<i>[cần điền]</i>	—
Newsvendor	<i>[cần điền]</i>	<i>[cần điền]</i>	—
IPPO	<i>[cần điền]</i>	<i>[cần điền]</i>	<i>[cần điền]</i>

4.4.3 Phân tích cơ cấu chi phí

Phân tích cơ cấu chi phí cho thấy IPPO *[cần phân tích: chiến lược đặt hàng thiên về tần suất thấp lô lớn hay tần suất cao lô nhỏ so với baselines?]*.

4.4.4 Đánh giá tỷ lệ đáp ứng dịch vụ

Tỷ lệ đáp ứng trung bình của IPPO đạt *[cần điền]*%, so với ngưỡng mục tiêu 85%. Phân tích theo nhóm SKU (nhu cầu cao/thấp/gián đoạn) cho thấy *[cần phân tích: IPPO có duy trì fill rate đồng đều hay có nhóm SKU bị hy sinh?]*.

4.5 Phân tích chuyên sâu

4.5.1 Khả năng tổng quát hóa qua parameter sharing (Câu hỏi 2)

Để trả lời Câu hỏi nghiên cứu 2, khóa luận phân tích hiệu năng của chính sách chia sẻ tham số theo nhóm SKU có quy mô nhu cầu khác nhau. Các SKU được phân thành 3 nhóm dựa trên λ_i trung bình: nhu cầu thấp ($\lambda < 1$), trung bình ($1 \leq \lambda < 5$), và cao ($\lambda \geq 5$).

4.5.2 Ảnh hưởng của hàm phần thưởng phân rã cục bộ (Câu hỏi 3)

Để trả lời Câu hỏi nghiên cứu 3, khóa luận so sánh hai cấu hình:

- Local reward (công thức 3.1): mỗi tác tử nhận phần thưởng riêng.
- Global reward: tất cả tác tử nhận cùng phần thưởng $r_{\text{global}} = \sum_i r_i / (N \times M)$.

4.5.3 Các kịch bản IPPO chưa vượt trội

Khóa luận trình bày trung thực những kịch bản mà IPPO không đạt hiệu năng tốt hơn chính sách cổ điển, kèm phân tích nguyên nhân:

4.6 Thảo luận

Kết quả thực nghiệm cho thấy *[cần tổng hợp sau khi có đầy đủ số liệu]*.

CHƯƠNG 5. KẾT LUẬN VÀ HƯỚNG PHÁT TRIỂN

5.1 Tổng kết các kết quả đạt được

Khóa luận đã hoàn thành bốn mục tiêu nghiên cứu đề ra:

1. Xây dựng môi trường mô phỏng: phát triển thành công `MultiWarehouseInventoryEnv` theo chuẩn Gymnasium [22], mô hình hóa đầy đủ hệ thống 10 kho, 50 mặt hàng (500 cặp tác tử), với nhu cầu ngẫu nhiên, thời gian giao hàng biến động [1, 3] ngày, ràng buộc sức chứa dùng chung và năm nhóm chi phí vận hành. Tham số nhu cầu được hiệu chỉnh từ bộ dữ liệu M5 Walmart [2].
2. Thiết kế hàm phần thưởng: đề xuất hàm phần thưởng phân rã cục bộ (dựa trên nguyên lý phần thưởng chênh lệch [23]) kèm thành phần phạt fill rate ràng buộc theo tinh thần Lagrangian trên cửa sổ trượt 30 ngày.
3. Cài đặt và huấn luyện IPPO: triển khai thuật toán Independent Multi-Agent PPO [20] với cơ chế chia sẻ tham số [18], sử dụng GAE [25] và chuẩn hóa lợi thế theo từng cặp. Mô hình hội tụ ổn định trên quy mô 500 tác tử.
4. Đánh giá đối chứng: so sánh IPPO với ba chính sách cổ điển (EOQ, (s, S) , Newsvendor) theo giao thức đa hạt giống có kiểm định thống kê [26], [27].

5.1.1 Trả lời các câu hỏi nghiên cứu

Câu hỏi 1 (IPPO vs. baselines): *[Cần điền kết luận dựa trên bảng 4.2 — IPPO có tổng chi phí thấp hơn và fill rate đạt ngưỡng 85% hay không?]*

Câu hỏi 2 (Tổng quát hóa qua parameter sharing): *[Cần điền dựa trên phân tích mục 4.5.1 — chính sách chia sẻ tham số có hoạt động đồng đều trên các nhóm SKU khác nhau?]*

Câu hỏi 3 (Local vs. global reward): *[Cần điền dựa trên ablation study mục 4.5.2 — local reward có cải thiện tốc độ hội tụ và/hoặc hiệu năng cuối cùng?]*

5.2 Những hạn chế còn tồn tại

- Cấu trúc mạng lưới đơn giản: các kho hoạt động song song và độc lập về nguồn cung; chưa xét cấu trúc đa cấp (multi-echelon) với quan hệ cung ứng giữa các kho [28] và hiệu ứng bullwhip [29].
- Không có truyền thông giữa các tác tử: các tác tử ra quyết định hoàn toàn

dựa trên quan sát cục bộ, chưa tận dụng thông tin từ các cấp kho–mặt hàng khác.

- Không gian hành động rời rạc thô: chỉ có $K = 6$ mức đặt hàng; trong thực tế, doanh nghiệp có thể cần quyết định lượng đặt chính xác hơn.
- Chưa tích hợp dự báo nhu cầu: tác tử sử dụng trực tiếp nhu cầu lịch sử thay vì dự báo bằng mô hình học sâu chuỗi thời gian.
- Thực nghiệm trên môi trường mô phỏng: chưa được kiểm chứng trên hệ thống ERP thực tế hoặc dữ liệu vận hành trực tiếp.

5.3 Hướng phát triển trong tương lai

- Mở rộng sang cấu trúc đa cấp (multi-echelon): mô hình hóa quan hệ cung ứng giữa kho trung tâm và kho khu vực, cho phép tác tử học chiến lược điều phối liên kho.
- Tích hợp cơ chế truyền thông giữa tác tử: áp dụng các phương pháp như CommNet hoặc TarMAC để cho phép tác tử chia sẻ thông tin, đặc biệt về tình trạng sức chứa kho.
- Không gian hành động liên tục: sử dụng PPO cho hành động liên tục hoặc mạng hành động phân cấp (hierarchical action) để quyết định lượng đặt hàng chính xác.
- Tích hợp dự báo nhu cầu: nhúng mô hình dự báo chuỗi thời gian (LSTM, Transformer) vào vector quan sát của tác tử, tận dụng thông tin xu hướng và mùa vụ.
- Triển khai thử nghiệm thực tế: xây dựng hệ thống dạng SaaS kết nối API với nền tảng quản lý kho, cho phép đánh giá mô hình trên dữ liệu vận hành trực tiếp.
- Mở rộng quy mô: thử nghiệm với toàn bộ 3.049 SKU gốc của M5 và đánh giá khả năng mở rộng của cơ chế chia sẻ tham số.

PHỤ LỤC A. ĐỐI CHIẾU LUẬN ĐIỂM VÀ NGUỒN TRÍCH DẪN

Phụ lục này liệt kê từng luận điểm lý thuyết được sử dụng trong khóa luận kèm nguồn gốc học thuật tương ứng, nhằm bảo đảm mọi khẳng định đều truy nguyên được về tài liệu công bố chính thống.

Mục	Luận điểm	Nguồn
<i>A.1. Lý thuyết tồn kho</i>		
1.1.1	Quản lý tồn kho đa điểm, đa mặt hàng trong chuỗi cung ứng bán lẻ	Silver and others [1]; Zipkin [8]
1.1.1	Mô tả bộ dữ liệu M5: quy mô, cấu trúc phân cấp, giai đoạn thu thập	Makridakis and others [2]; Howard and others [3]
1.1.1	Tiêu chí phân loại dạng nhu cầu (ngưỡng $p = 1,32$; $CV^2 = 0,49$)	Syntetos and others [4]
1.1.1	Nhu cầu gián đoạn và hạn chế của phương pháp dự báo thông thường	Croston [6]; Syntetos and Boylan [7]
1.1.2	Bất định của nhu cầu và thời gian giao hàng; hiện tượng vượt đơn	Zipkin [8]; Silver and others [1]
1.1.2	Cấu trúc chi phí tồn kho và bài toán đánh đổi	Zipkin [8]
1.1.3	Mô hình lượng đặt hàng kinh tế (EOQ)	Harris [12]
1.1.3	Tính tối ưu của chính sách (s, S) và các điều kiện kèm theo	Scarf [13]
1.1.3	Mô hình người bán báo (Newsvendor) một chu kỳ	Arrow and others [14]
1.1.3	Bài toán mất đơn hàng không có nghiệm giải tích dạng đóng	Zipkin [15]
1.3.3	Cấu trúc tồn kho đa cấp (nằm ngoài phạm vi)	Clark and Scarf [28]
1.3.3	Hiệu ứng bullwhip (nằm ngoài phạm vi)	Lee and others [29]

Mục	Luận điểm	Nguồn
-----	-----------	-------

A.2. Học tăng cường

2.3.1	Quá trình quyết định Markov và quy hoạch động ngẫu nhiên	Puterman [30]
2.3.1	Hàm giá trị, phương trình Bellman, hàm lợi thế, định lý policy gradient	Sutton and Barto [10]
2.3.3	Ước lượng lợi thế tổng quát (GAE) và đánh đổi bias–variance	Schulman and others [25]
2.3.4	Vùng tin cậy trong tối ưu hóa chính sách	Schulman and others [32]
2.3.4	Hàm mục tiêu cắt của PPO	Schulman and others [24]
2.5.4	Điều kiện bảo toàn chính sách tối ưu khi định hình phần thưởng	Ng and others [33]

A.3. Học tăng cường đa tác tử

1.1.2	Độ phức tạp NEXP-đầy đủ của điều khiển phi tập trung	Bernstein and others [11]
2.4.1	Mô hình Dec-POMDP	Oliehoek and Amato [9]
2.4.2	Học độc lập và vấn đề môi trường không dừng	Tan [19]
2.4.3	Thuật toán IPPO	Schröder de Witt and others [20]
2.4.3	MAPPO và khung huấn luyện tập trung, thực thi phân tán	Yu and others [21]
2.4.4	Chia sẻ tham số giữa các tác tử đồng nhất	Gupta and others [18]
2.4.5	Phần thưởng chênh lệch và bài toán gán tín dụng đa tác tử	Wolpert and Tumer [23]

A.4. Ứng dụng, môi trường và giao thức đánh giá

2.8	Học tăng cường sâu cho trò chơi phân phối bia	Oroojlooyjadid and others [16]
2.8	Đánh giá học tăng cường sâu trên các lớp bài toán tồn kho	Gijsbrechts and others [17]
3.2	Chuẩn giao diện môi trường học tăng cường	Brockman and others [31]; Towers and others [22]

Mục	Luận điểm	Nguồn
2.7	Yêu cầu đa hạt giống và tính tái lập trong đánh giá	Henderson and others [26]
2.7	Phương pháp báo cáo kết quả có kiểm định thống kê	Agarwal and others [27]

Ghi chú. Các số liệu thống kê mô tả bộ dữ liệu M5 trình bày trong Mục 1.1.1 và Bảng 1.1 do nhóm tác giả tự tính toán từ hai tệp `sales_train_evaluation.csv` và `calendar.csv`; mã nguồn tính toán được đính kèm trong kho mã của khóa luận.

TÀI LIỆU THAM KHẢO

E. A. Silver, D. F. Pyke **and** D. J. Thomas, *Inventory and Production Management in Supply Chains*, 4 **edition**. Boca Raton, FL: CRC Press, 2016.

S. Makridakis, E. Spiliotis **and** V. Assimakopoulos, “The M5 competition: Background, organization, and implementation,” *International Journal of Forecasting*, **jourvol** 38, **number** 4, **pages** 1325–1336, 2022. DOI: 10.1016/j.ijforecast.2021.07.007

A. Howard, N. Vandeput, Makridakis, Spyros, Assimakopoulos, Vassilios **and** inversion, *M5 Forecasting – Accuracy*, Kaggle competition, 2020. **url**: <https://www.kaggle.com/competitions/m5-forecasting-accuracy>

A. A. Syntetos, J. E. Boylan **and** J. D. Croston, “On the categorization of demand patterns,” *Journal of the Operational Research Society*, **jourvol** 56, **number** 5, **pages** 495–503, 2005. DOI: 10.1057/palgrave.jors.2601841

A. I. Kostenko **and** R. J. Hyndman, “A note on the categorization of demand patterns,” *Journal of the Operational Research Society*, **jourvol** 57, **number** 10, **pages** 1256–1257, 2006. DOI: 10.1057/palgrave.jors.2602211

J. D. Croston, “Forecasting and stock control for intermittent demands,” *Operational Research Quarterly*, **jourvol** 23, **number** 3, **pages** 289–303, 1972. DOI: 10.1057/jors.1972.50

A. A. Syntetos **and** J. E. Boylan, “The accuracy of intermittent demand estimates,” *International Journal of Forecasting*, **jourvol** 21, **number** 2, **pages** 303–314, 2005. DOI: 10.1016/j.ijforecast.2004.10.001

P. H. Zipkin, *Foundations of Inventory Management*. Boston: McGraw-Hill, 2000.

F. A. Oliehoek **and** C. Amato, *A Concise Introduction to Decentralized POMDPs*. Cham: Springer, 2016. DOI: 10.1007/978-3-319-28929-8

R. S. Sutton **and** A. G. Barto, *Reinforcement Learning: An Introduction*, 2 **edition**. Cambridge, MA: MIT Press, 2018.

D. S. Bernstein, R. Givan, N. Immerman **and** S. Zilberstein, “The complexity of decentralized control of Markov decision processes,” *Mathematics of Operations Research*, **jourvol** 27, **number** 4, **pages** 819–840, 2002. DOI: 10.1287/moor.27.4.819.297

F. W. Harris, “How many parts to make at once,” *Factory, The Magazine of Management*, **jourvol** 10, **number** 2, **pages** 135–136, 152, 1913.

H. Scarf, “The optimality of (S, s) policies in the dynamic inventory problem,” in *Mathematical Methods in the Social Sciences* K. J. Arrow, S. Karlin **and** P. Suppes, **editors**, Stanford, CA: Stanford University Press, 1960, **pages** 196–202.

K. J. Arrow, T. Harris **and** J. Marschak, “Optimal inventory policy,” *Econometrica*, **jourvol** 19, **number** 3, **pages** 250–272, 1951. DOI: 10.2307/1906813

P. Zipkin, “Old and new methods for lost-sales inventory systems,” *Operations Research*, **jourvol** 56, **number** 5, **pages** 1256–1263, 2008. DOI: 10.1287/opre.1070.0471

A. Oroojlooyjadid, M. Nazari, L. V. Snyder **and** M. Takáč, “A deep Q-network for the beer game: Deep reinforcement learning for inventory optimization,” *Manufacturing & Service Operations Management*, **jourvol** 24, **number** 1, **pages** 285–304, 2022. DOI: 10.1287/msom.2020.0939

J. Gijsbrechts, R. N. Boute, J. A. Van Mieghem **and** D. J. Zhang, “Can deep reinforcement learning improve inventory management? Performance on lost sales, dual-sourcing, and multi-echelon problems,” *Manufacturing & Service Operations Management*, **jourvol** 24, **number** 3, **pages** 1349–1368, 2022. DOI: 10.1287/msom.2021.1064

J. K. Gupta, M. Egorov **and** M. Kochenderfer, “Cooperative multi-agent control using deep reinforcement learning,” in *Autonomous Agents and Multiagent Systems (AAMAS 2017 Workshops)* **jourser** Lecture Notes in Computer Science, **volume** 10642, Springer, 2017, **pages** 66–83. DOI: 10.1007/978-3-319-71682-4_5

M. Tan, “Multi-agent reinforcement learning: Independent vs. cooperative agents,” in *Proceedings of the 10th International Conference on Machine Learning* 1993, **pages** 330–337.

C. Schröder de Witt **and others**, *Is independent learning all you need in the StarCraft multi-agent challenge?* arXiv preprint arXiv:2011.09533, 2020. arXiv: 2011.09533.

C. Yu **and others**, “The surprising effectiveness of PPO in cooperative multi-agent games,” **in** *Advances in Neural Information Processing Systems 35 (NeurIPS 2022), Datasets and Benchmarks Track 2022*, **pages** 24 611–24 624.

M. Towers, A. Kwiatkowski, J. Terry, J. U. Balis, G. De Cola, T. Deleu **and others**, *Gymnasium: A standard interface for reinforcement learning environments*, arXiv preprint arXiv:2407.17032, 2024. arXiv: 2407.17032.

D. H. Wolpert **and** K. Tumer, “Optimal payoff functions for members of collectives,” *Advances in Complex Systems*, **journal** 4, **number** 2–3, **pages** 265–279, 2001. DOI: 10.1142/S0219525901000188

J. Schulman, F. Wolski, P. Dhariwal, A. Radford **and** O. Klimov, *Proximal policy optimization algorithms*, arXiv preprint arXiv:1707.06347, 2017. arXiv: 1707.06347.

J. Schulman, P. Moritz, S. Levine, M. Jordan **and** P. Abbeel, “High-dimensional continuous control using generalized advantage estimation,” **in** *Proceedings of the 4th International Conference on Learning Representations (ICLR) 2016*. arXiv: 1506.02438.

P. Henderson, R. Islam, P. Bachman, J. Pineau, D. Precup **and** D. Meger, “Deep reinforcement learning that matters,” **in** *Proceedings of the 32nd AAAI Conference on Artificial Intelligence 2018*, **pages** 3207–3214.

R. Agarwal, M. Schwarzer, P. S. Castro, A. Courville **and** M. G. Bellemare, “Deep reinforcement learning at the edge of the statistical precipice,” **in** *Advances in Neural Information Processing Systems 34 (NeurIPS 2021) 2021*, **pages** 29 304–29 320.

A. J. Clark **and** H. Scarf, “Optimal policies for a multi-echelon inventory problem,” *Management Science*, **journal** 6, **number** 4, **pages** 475–490, 1960. DOI: 10.1287/mnsc.6.4.475

H. L. Lee, V. Padmanabhan **and** S. Whang, “Information distortion in a supply chain: The bullwhip effect,” *Management Science*, **jourvol** 43, **number** 4, **pages** 546–558, 1997. DOI: 10.1287/mnsc.43.4.546

M. L. Puterman, *Markov Decision Processes: Discrete Stochastic Dynamic Programming*. New York: John Wiley & Sons, 1994.

G. Brockman **and others**, *OpenAI Gym*, arXiv preprint arXiv:1606.01540, 2016. arXiv: 1606.01540.

J. Schulman, S. Levine, P. Abbeel, M. Jordan **and** P. Moritz, “Trust region policy optimization,” *in Proceedings of the 32nd International Conference on Machine Learning* 2015, **pages** 1889–1897.

A. Y. Ng, D. Harada **and** S. Russell, “Policy invariance under reward transformations: Theory and application to reward shaping,” *in Proceedings of the 16th International Conference on Machine Learning* 1999, **pages** 278–287.

S. Devlin **and** D. Kudenko, “Theoretical considerations of potential-based reward shaping for multi-agent systems,” *in Proceedings of the 10th International Conference on Autonomous Agents and Multiagent Systems (AAMAS 2011)* 2011, **pages** 225–232.

B. De Moor, J. Gijsbrechts **and** R. N. Boute, “Reward shaping to improve the performance of deep reinforcement learning in perishable inventory management,” *European Journal of Operational Research*, **jourvol** 301, **number** 2, **pages** 535–545, 2022. DOI: 10.1016/j.ejor.2021.11.026

C. D. Hubbs, H. D. Perez, O. Sarwar, N. V. Sahinidis, I. E. Grossmann **and** J. M. Wassick, *OR-Gym: A Reinforcement Learning Library for Operations Research Problems*, arXiv preprint arXiv:2008.06319, 2020. arXiv: 2008.06319.

J. Ding **and others**, *Multi-Agent Reinforcement Learning with Shared Resources for Inventory Management*, arXiv preprint arXiv:2212.07684 (NeurIPS 2022 RL4RealLife Workshop), 2022. arXiv: 2212.07684.

Y. Yang **and others**, *A Versatile Multi-Agent Reinforcement Learning Benchmark for Inventory Management*, arXiv preprint arXiv:2306.07542, 2023. arXiv: 2306.07542.

P. Kotecha **and** E. A. del Rio Chanona, “An analysis of multi-agent reinforcement learning for decentralized inventory control systems,” *Computers & Chemical Engineering*, 2024. arXiv: 2307.11432.

X. Liu, Y. Hu, Z. Peng **and** Y. Yang, “Multi-Agent Deep Reinforcement Learning for Multi-Echelon Inventory Management,” *Production and Operations Management*, 2025. DOI: 10.1177/10591478241305863